

基于 CEEMD-GRU 模型的矿井涌水量预测

李占利, 邢金莎, 靳红梅, 李洪安

(西安科技大学计算机科学与技术学院, 西安 710600)

摘 要: 为了提高矿井涌水量的预测精度, 提出基于互补集合经验模态分解(complementary ensemble empirical mode decomposition, CEEMD) 与门控循环单元(gated recurrent unit, GRU) 相结合的矿井涌水量预测模型(CEEMD-GRU) 。首先, 通过 CEEMD 算法将一维涌水量数据分解为多个本征模态函数(intrinsic mode function, IMF) 分量和一个残差余量, 本征模态函数分量反映涌水量数据在不同时间尺度的波动特征, 残差余量反映数据长期变化的趋势特征; 然后, 针对各分量分别建立 GRU 神经网络模型, 将对一维数据的研究转换为对其分解后多维子分量的研究, 训练学习各分量的时序变化规律并进行预测; 最后, 将预测结果融合得到最终涌水量预测值。将 CEEMD-GRU 与反向传播(back propagation, BP) 、支持向量机(support vector machine, SVM) 、GRU 神经网络进行了对比实验, 结果表明, 基于 CEEMD-GRU 的均方根误差平均降低了 60.8%, 该研究为进一步提高矿井涌水量预测精度提供了思路。

关键词: 矿井涌水量; 互补集合经验模态分解; BP 神经网络; 数据分解; 门控循环单元; 支持向量机

中图分类号: U 461; TP 308

文献标志码: A

文章编号: 0254-0037(2021)08-0904-08

doi: 10.11936/bjntxb2020120022

Prediction of Mine Water Inflow Based on CEEMD-GRU Model

LI Zhanli, XING Jinsha, JIN Hongmei, LI Hongan

(College of Computer Science and Technology, Xi'an University of Science and Technology, Xi'an 710600, China)

Abstract: To improve the prediction accuracy of mine water inflow, a mine inflow prediction model (CEEMD-GRU) based on the combination of complementary ensemble empirical mode decomposition (CEEMD) and gated recurrent unit (GRU) neural network. First, the one-dimensional water inflow data was decomposed into several intrinsic mode function (IMF) components and a residual margin by CEEMD algorithm. The fluctuation characteristics of the water inflow data at different time scales were reflected by the intrinsic mode components while the trend characteristics of long-term changes of the data was reflected by the residual margin. Then, the GRU neural network model was established for each component, and the study of one-dimensional data was transformed into the study of the decomposed multidimensional sub-components so as to train and learn the time-series change rules of each component and make predictions. Finally, the predicted water inflow was obtained by combining the predicted results. By comparing CEEMD-GRU with back propagation (BP) , SVM and GRU neural network, the results show that the RMSE based on CEEMD-GRU prediction model is reduced by 60.8% on average. This study provides a new idea for further improving the prediction accuracy of mine water inflow.

Key words: mine water inflow; complementary ensemble empirical mode decomposition (CEEMD) ; back propagation (BP) neural network; data decomposition; gated recurrent unit(GRU) ; support vector machine (SVM)

矿井涌水量是指矿井开采过程中,地表水或地下水通过裂隙、断层等各种通道在单位时间内涌入

收稿日期: 2020-12-28

基金项目: 陕西省自然科学基金研究计划资助项目(2019JM-348, 2019JLM-10)

作者简介: 李占利(1964—), 男, 教授, 主要从事机器学习、计算机图形图像处理方面的研究, E-mail: lizl@xust.edu.cn

并巷系统的水量。当矿井涌水量超过矿井自身排水能力时会导致矿井水害事故的发生^[1],涌水量直接关系到煤矿采掘方案和排水能力设计的合理性,更决定了煤矿是否能够安全生产,因此,矿井涌水量的准确预测具有重要意义^[2]。

在矿井生产过程中,形成了许多关于涌水量预测的方法。解析法运用地下水动力学原理,对一定边界条件和初始条件下的地下水流动问题建立定解方程,以此预测涌水量,实现较为简便,但在大降深、不规则的条件下,涌水量预测结果误差较大^[3]。水均衡法通过对矿井内的补给、径流、排泄及源汇等补排条件关系的研究,建立水均衡方程以预测涌水量,该方法需要的参数较少,但难以计算地下水均衡的各个组成部分^[4]。数值法通过求解渗流偏微分方程获得涌水量的近似值,它适用于解决许多复杂条件下的矿井涌水量问题,但由于开采条件变化大、不确定因素多,方程的建立是在一定假设和地质结构简化的基础上,预测结果只是近似值^[5]。水文地质比拟法以现有生产矿井的实际水文地质资料类比计算预测水文地质条件相同矿井的涌水量,该方法计算简单,但精度低,应用范围受限制^[6]。反向传播(back propagation, BP)神经网络通过训练学习涌水量相关因素和涌水量实测值间的非线性关系来完成涌水量的预测^[7]。要保证上述方法预测的准确性,必须满足各方法的适用条件并提供可靠的参数,而现场地质及水文地质资料很难满足这种要求,因此,此类方法难以推广,不具备通用性^[8]。部分学者对一维涌水量数据本身进行问题分析,归纳规律。乔美英等^[9]提出利用(genetic algorithm, GA)优化的支持向量机(support vector machine, SVM)模型实现涌水量的预测。王猛等^[10]以模型定阶、参数估计和假设检验等过程建立合适的差分整合移动平均自回归模型(autoregressive integrated moving average model, ARIMA)对涌水量进行预测。施龙青等^[11]对原始涌水量数据进行一次累加生成、均值生成、光滑性检验等处理后建立涌水量与时间的灰色预测模型。以上方法对原始数据进行分析处理,通过建模发现涌水量变化规律,进一步实现预测,提高了模型的通用性。但涌水量数据受水文地质参数和各方面因素影响,具有随机性、非平稳性等特点,使得模型预测精度不高^[12]。

本文旨在提出一种通用性强、预测精度高的涌水量预测模型。首先,通过互补集合经验模态分解(complementary ensemble empirical mode decomposition, CEEMD)算法将一维涌水量分解为从高频到低频的

多维子分量,其中最后一个子分量反映长期趋势特征,剩余子分量反映原始数据在不同时间尺度上的波动特征,通过 CEEMD 分解使得原始数据蕴含的信息充分显露出来;其次,通过偏自相关函数(partial autocorrelation function, PACF)确定各分量的滞后期数,从而确定各分量输入神经元个数;然后,利用门控循环单元(gated recurrent unit, GRU)适合处理时序数据的特点,通过 GRU 神经网络学习各子分量变化规律并进一步预测;最后,将各分量预测结果融合得到最终的涌水量预测值。

1 基于 CEEMD-GRU 的预测模型

本文提出的基于 CEEMD-GRU 的矿井涌水量预测模型流程图如图 1 所示。




图1 CEEMD-GRU 预测模型流程图

Fig. 1 Flow chart of CEEMD-GRU prediction model

该模型通过 CEEMD 将涌水量数据进行分解,因为分解后的各子分量拥有不同的特征尺度,所以它们之间的相互影响被隔离,利用这种隔离可以减小涌水量本身的非平稳性和非线性在预测中带来的误差。

GRU 神经网络对各分量分别建立子模型,学习各分量的变化规律。因为涌水量作为时序数据,用传统的 BP 或 SVM 神经网络进行预测,存在网络结构难以确定、预测精度低等问题^[13],而 GRU 网络作为具有记忆能力的循环神经网络,能够有效地利用长时序信息。并且本文引入 PACF 来确定各分量当前时刻与滞后 k 个时刻之间的相关性,不考虑中间时刻的影响,从而确定 GRU 神经网络输入层神经元个数,减少人为主观因素影响,进一步提高涌水量预测精度。

基于 CEEMD-GRU 的涌水量预测模型具体步骤如下:

1) 将涌水量通过 CEEMD 算法分解,得到各本征模态函数(intrinsic mode function, IMF)分量和残差余量。

2) 引入 PACF 来确定各分量的滞后期数,从而确定各分量输入神经元个数。

3) 对各分量分别划分为训练集和测试集,通过 GRU 神经网络学习各分量变化规律并进行预测。

4) 将各分量预测结果融合,得到最终的预测值。

1.1 CEEMD 算法原理

CEEMD 是针对经验模态分解(empirical mode decomposition, EMD)和集合经验模态分解(ensemble empirical mode decomposition, EEMD)提出的改进方法^[14]。EEMD 在 EMD 的基础上添加白噪声使信号在不同时间尺度上具有连续性,从而更好地抑制 EMD 在分解过程中由于 IMF 不连续造成的模态混叠现象^[15]。但由于 EEMD 分解过程中引入的噪声会存在残余,对原始数据产生不良影响^[16],CEEMD 在 EEMD 基础上引入互补的噪声,不仅解决了模态混叠现象,同时提高了原信号重构的精度,提升了计算效率^[17]。CEEMD 算法分解步骤如下。

1) 对原始数据加入正、负成对的白噪声,得到新的信号

$$\begin{bmatrix} M_1 \\ M_2 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} S \\ N \end{bmatrix} \quad (1)$$

式中: S 为原始数据; N 为白噪声; M_1 、 M_2 分别为混入正、负白噪声的原始信号。

2) 通过

$$\begin{cases} H(t) = \sum_{j=1}^n c_j(t) + r(t) \\ c_j(t) = \frac{1}{\lambda} \sum_{i=1}^k c_{ij}(t) \end{cases} \quad (2)$$

对 M_1 、 M_2 进行分解。式中: c_{ij} 为第 i 次加入白噪声分解后得到的第 j 个 IMF 分量; $c_j(t)$ 为 C_1 、 C_2 在第 j 个 IMF 分量的平均值; r 为残差余量; λ 为加入白噪声的次数。分解后得到 2 组 IMF 分量,将 2 组 IMF 分量表示为 C_1 、 C_2 , 然后对每组分量对应的同一阶 IMF 分量求平均值,得到最终的分解结果 H 。

1.2 GRU 神经网络

GRU 和长短时记忆(long short-term memory, LSTM)网络的内部单元很相似,不同之处在于 GRU 将 LSTM 中的输入门和遗忘门合并成一个单一的更新门,因此,GRU 中只有 2 个门结构,分别为更新门和重置门。更新门用于确定是否保留上一时刻状态的信息以及保留

的程度,更新门的值越大表示前一时刻的状态信息保留越多。重置门用于确定是否要结合当前状态与先前的信息,重置门的值小说明忽略的信息越多^[18]。

GRU 结构单元如图 2 所示。 x_t 为当前时刻输入, h_{t-1} 为 $t-1$ 时刻隐藏层输出, z_t 和 r_t 分别为更新门和重置门, $\tilde{h}_t$ 为经过重置门处理后的输出候选值, “1-”表示用 1 减去向量中每个元素。




图 2 GRU 网络的单元结构

Fig. 2 Unit structure of GRU network

GRU 神经网络的计算过程为

$$z_t = \sigma(W_z [h_{t-1}, x_t]) \quad (3)$$

$$r_t = \sigma(W_r [h_{t-1}, x_t]) \quad (4)$$

$$\tilde{h}_t = \tanh(W_h [r_t * h_{t-1}, x_t]) \quad (5)$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t \quad (6)$$

式中: W_z 和 W_r 分别为更新门和重置门的权值矩阵; W_h 为求 $\tilde{h}_t$ 时的权值矩阵; “[]”表示 2 个向量的连接; “*”表示矩阵间对应点元素相乘。

1.3 PACF

PACF 是确定自回归滑动平均模型中滞后阶数的常用方法,可以反映一维数据中任意 2 个时刻在排除中间时刻影响后的纯相关性^[19],比如:在 $t-3$ 对 t 的影响中,不会考虑 $t-2$ 和 $t-1$ 时刻对 t 的影响。本文通过 PACF 确定 x_t 与 k 个时间单位 x_{t-k} 之间的相关性,从而确定各分量的滞后期数,进一步确定各分量建立 GRU 神经网络的输入层神经元个数。

1.4 模型搭建

本文建立的 GRU 神经网络模型如图 3 所示。基本结构包括输入层、隐藏层和输出层。

1) 输入层:通过 PACF 确定各分量滞后期数 k , 将一维数据 s 根据滞后期数 k 将前 k 个时刻数据作为特征、第 $k+1$ 时刻数据作为标签构造样本对 X , 将样本对划分为训练集和测试集。

2) 隐藏层:GRU 层的作用是为了记住重要的信息,忽略不重要的信息。因为目前没有具体的计算标准来确定隐藏层神经元的个数,本文通过多次实验最终确定 GRU 层神经元个数为 32 时误差最小。




图3 GRU网络模型

Fig.3 GRU network model

3) 输出层: 通过全连接层实现, 激活函数为 ReLU.

4) 优化器: 是用来更新和计算影响模型训练和模型输出的网络参数, 使其逼近或达到最优值. 模型训练的优化器为 Adam 优化器, 它结合了 AdaGrad 和 RMSProp 两种算法的优点, 计算高效, 对内存需求少, 参数的更新不受梯度的伸缩变换影响.

5) 损失函数: 是神经网络训练时试图最小化的目标函数. 训练过程中损失函数的选取取决于输入标签数据的类型, 因为本文输入的是数值, 所以将损失函数参数设置为均方误差 (mean square error, MSE).

2 实例分析

2.1 数据处理

本文实验验证采用的数据包括 2 组: 一是山东省郛城煤矿 1301 开采工作面在 2017 年实测的涌水量数据, 每天统计一次, 共 170 条; 二是开滦集团东欢陀煤矿在 2019 年 1 月 11 日至 26 日实测的明渠流量数据, 每 5 min 统计一次, 共 4 473 条. 通过 CEEMD 对数据进行分解得到各子分量. 将各分量分别划分为训练集和测试集, 然后根据各子分量不同的变化规律和多次实验尝试将训练集构造样本对 $\{x_{t-k}, x_{t-k-1}, \dots, x_{t-1}, x_t\}$, 共 $k+1$ 列. k 为步长, 即前 k 个时刻数据作为模型的输入向量, 第 $k+1$ 时刻数据作为模型的输出值, 通过 GRU 模型学习前 k 个时刻的数据与第 $k+1$ 时刻的非线性映射关系. 对每个分量的数据集都做同样的处理, 但因为各分量数据变化规律不同, 所以 k 的设置不同, 即 GRU 神经网络输入层神经元个数也不同.

例如: 将第 1 个本征模态分量输入神经元个数确定为 3, 前 3 列作为特征, 最后一列作为标签, 然后通过

$$X = \begin{bmatrix} x_1 & x_2 & x_3 & x_4 \\ x_2 & x_3 & x_4 & x_5 \\ \vdots & \vdots & \vdots & \vdots \\ x_{t-3} & x_{t-2} & x_{t-1} & x_t \end{bmatrix} \quad (7)$$

构造样本对, 将数据输入神经网络学习标签和特征的关系, 即学习前 3 个时间点的数据和第 4 个时间点的非线性映射关系.

2.2 评价指标

为了更好地评估模型预测结果, 本文采用预测评价指标: 均方根误差 (root mean squared error, RMSE) 和平均绝对百分比误差 (mean absolute percentage error, MAPE). 值越小代表预测精度越高, 预测指标为

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (x_a - x_f)^2}{n}} \quad (8)$$

式中: x_a 为真实值; x_f 为预测值; n 为预测值和真实值个数.

2.3 实验

本文实验在 Win10 64 位系统下进行, 处理器为 Inter(R) Core(TM) i5-8300H CPU @ 2.30 GHz 2.30 GHz, 基于 python3.6 环境和 keras 框架, keras 版本为 2.2.4. 通过 CEEMD 将涌水量和明渠流量进行分解, 分解结果如图 4、5 所示.




图4 涌水量 CEEMD 分解结果

Fig.4 CEEMD decomposition results of water inflow




图5 明渠流量 CEEMD 分解结果

Fig. 5 CEEMD decomposition results of open channel flow

为了进一步说明 CEEMD-GRU 模型的实用性,将涌水量各分量预测结果进行融合,并分别与现有的预测模型 GRU、BP 和 SVR 神经网络进行对比实验。基于涌水量数据集的各模型预测结果如图 6 所示。

从图 6 可以看出,CEEMD-GRU 模型对涌水量的预测效果具有很好的跟随性和波动性,预测趋势与实测数据基本一致,未存在预测滞后,而单一 BP、

SVM 和 GRU 神经网络模型的预测结果均有滞后的现象,说明模型未能及时预测出下一时刻的数值,预测效果不佳。




图6 涌水量各模型预测结果

Fig. 6 Prediction results of each model of water inflow

将明渠流量数据集各分量预测结果进行融合,同样与现有的预测模型 GRU、BP 和 SVR 神经网络进行对比实验。基于明渠流量数据集的各模型预测结果如图 7 所示,并将图 7 中 [80,600] 的部分预测结果放大,如图 8 所示。

从图 7、8 可以看出,CEEMD-GRU 模型对明渠流量数据集同样具有很好的预测效果,更能预测出原始数据的波动特性,如: 对应图 8 原始数据在 [27,37] 和 [51,59] 范围内,CEEMD-GRU 模型预测效果均好于其他单一模型。将涌水量和明渠流量各预测模型的预测误差进行对比,分别如图 9、10 所示。

从图 9、10 可以看出,BP、SVM 和 GRU 神经网络模型的预测误差范围波动较大,而 CEEMD-GRU 模型的预测误差相对平稳,说明 CEEMD-GRU 模型的预测精度和平稳性较好。针对各预测模型采用预




图7 明渠流量各模型预测结果

Fig. 7 Prediction results of each model of open channel inflow




图8 480~600 区间明渠流量各模型预测放大结果

Fig. 8 Prediction and amplification results of each model of open channel inflow in 480-600 interval




图9 涌水量各模型预测误差

Fig. 9 Prediction error of each model of water inflow

测评价指标 RMSE 对预测结果进一步分析,各模型预测性能评估如表 1 所示。

从表 1 中各模型预测性能评估值来看,本文所提出模型在涌水量和明渠流量预测中的均方根误差

表1 各模型预测误差值对比

Table 1 Comparison of prediction error values of each mode

预测模型	涌水量	明渠流量
BP	17.890	1.033
SVM	24.489	0.960
GRU	15.883	0.842
CEEMD_GRU	7.339	0.595

分别比单一预测模型 BP 神经网络降低了 58.9%、42.4%,比单一预测模型 SVM 降低了 70.0%、38.0%,比 GRU 降低了 53.7%、29.3%。依据误差指标来看,本文所提模型预测精度最高,说明将数据通过 CEEMD 分解转换为多个子分量,然后建立 GRU 模型进行预测可以在原有 GRU 的基础上提高预测精度。




图10 明渠流量各模型预测误差

Fig. 10 Prediction error of each model of open channel inflow

3 结论

1) 通过 CEEMD 将数据分解为一系列较为平稳的 IMF 分量和残差余量,将对一维数据的研究转换为对多维子分量的研究,从而进行建模. 与 BP、SVM、GRU 神经网络相比,涌水量和明渠流量的均方根误差平均分别降低了 60.8%、44.7%. 结果表明,基于 CEEMD-GRU 模型预测效果最好. 利用 GRU 模型进行预测可以在原有 GRU 的基础上提高预测精度.

2) 基于 CEEMD-GRU 模型利用矿井水文数据历史信息,通过 CEEMD 分解将数据中蕴藏的信息充分显露出来,可以准确预测未来趋势,为矿井生产过程中水害防治和排水系统设计提供新思路.

3) CEEMD-GRU 模型是假定水文数据的未来趋势仍基于现有历史数据变化所建立的预测模型,矿井水文数据是区域水文地质条件和采掘动态过程复合作用的结果,虽然涌水量和明渠流量在一定程度上可以反映地质参数影响下水文数据变化的规律,但它仍然受其他突发因素的影响,需考虑如何将随机、突发的因素引入模型.

参考文献:

- [1] 沈中芹, 曾旺, 王瑞强, 等. 基于改进 HFACS-MI 模型的煤矿透水事故致因分析 [J]. 安全与环境工程, 2020, 27(3): 178-184.
SHEN Z Q, ZENG W, WANG R Q, et al. Cause analysis of water inrush accidents in coal mines based on improved HFACS-MI model [J]. Safety and Environmental Engineering, 2020, 27(3): 178-184. (in Chinese)
- [2] 黄欢. 矿井涌水量预测方法及发展趋势 [J]. 煤炭科学技术, 2016, 44(增刊 1): 127-130.
HUANG H. Prediction method of mine inflow and its development [J]. Coal Science and Technology, 2016, 44(Suppl 1): 127-130. (in Chinese)
- [3] 谢伟, 杨绪波. 基于解析法对折多山隧道进行分段涌水量预测计算 [J]. 公路, 2019, 64(4): 318-324.
XIE W, YANG X B. Prediction of sectional water inflow of the Zheduoshan mountain tunnel based on analytic method [J]. Highway, 2019, 64(4): 318-324. (in Chinese)
- [4] 彭辉才, 徐卫东, 付青, 等. 贵州绿塘煤矿涌水量预测研究 [J]. 南水北调与水利科技, 2013, 11(2): 58-61.
PENG H C, XU W D, FU Q, et al. Research on prediction of water inflow in Lvtang coal mine of Guizhou province [J]. South-to-North Water Transfers and Water Science & Technology, 2013, 11(2): 58-61. (in Chinese)
- [5] 王春刚, 方刚, 刘洋. 榆横北区巴拉素井田不同时期矿井涌水量预测 [J]. 煤矿安全, 2020, 51(6): 212-217.
WANG C G, FANG G, LIU Y. Prediction of mine water inflow at different periods in Balasu Coal Field of northern Yuheng Mining Area [J]. Safety in Coal Mines, 2020, 51(6): 212-217. (in Chinese)
- [6] 苗霖田, 贺晓浪, 张建军, 等. 矿井涌水量的时间序列分析-水文地质比拟法预测 [J]. 中国煤炭, 2017, 43(3): 32-35.
MIAO L T, HE X L, ZHANG J J, et al. Time series analysis-hydrogeological analogy method for mine water inflow prediction [J]. China Coal, 2017, 43(3): 32-35. (in Chinese)
- [7] 谭大国. BP 神经网络在矿井涌水预测中的应用 [J]. 制造业自动化, 2015, 37(5): 66-68.
TAN D G. Application of BP network in predicting mine gushing water [J]. Manufacturing Automation, 2015, 37(5): 66-68. (in Chinese)
- [8] 施龙青, 王雅茹, 邱梅, 等. 时间序列模型在工作面涌水量预测中的应用 [J]. 煤田地质与勘探, 2020, 48(3): 108-115.
SHI L Q, WANG Y R, QIU M, et al. Application of time series model in water inflow prediction of working face [J]. Coal Geology & Exploration, 2020, 48(3): 108-115. (in Chinese)
- [9] 乔美英, 程鹏飞, 刘震震. 基于 GA-SVM 的矿井涌水量预测 [J]. 煤田地质与勘探, 2017, 45(6): 117-122.
QIAO M Y, CHENG P F, LIU Z Z. Min water inflow prediction based on GA-SVM [J]. Coal Geology & Exploration, 2017, 45(6): 117-122. (in Chinese)
- [10] 王猛, 殷博超, 张凯歌, 等. 基于 ARIMA 乘积季节模型的矿井涌水量预测研究 [J]. 煤炭科学技术, 2017, 45(11): 199-204.
WANG M, YIN B C, ZHANG K G, et al. Study on prediction of mine water inflow volume based on ARIMA product seasonal model [J]. Coal Science and Technology, 2017, 45(11): 199-204. (in Chinese)
- [11] 施龙青, 赵云平, 王颖, 等. 基于灰色理论的矿井涌水量预测 [J]. 煤炭技术, 2016, 35(9): 115-118.
SHI L Q, ZHAO Y P, WANG Y, et al. Prediction of mine water inflow based on gray theory [J]. Coal Technology, 2016, 35(9): 115-118. (in Chinese)
- [12] 王晓蕾. 煤矿开采矿井涌水量预测方法现状及发展趋势 [J]. 科学技术与工程, 2020, 20(30): 12255-12267.
WANG X L. Present situation and development trend of coal mine discharge forecast method [J]. Science

- Technology and Engineering, 2020, 20 (30): 12255-12267. (in Chinese)
- [[3] 马莉, 潘少波, 代新冠, 等. 基于 PSO-Adam-GRU 的煤矿瓦斯浓度预测模型 [J]. 西安科技大学学报, 2020, 40(2): 363-368.
- MA L, PAN S B, DAI X G, et al. Gas concentration prediction model of working face based on PSO-Adam-GRU [J]. Journal of Xi'an University of Science and Technology, 2020, 40(2): 363-368. (in Chinese)
- [[4] 王栋, 魏加华, 章四龙, 等. 基于 CEEMD-BP 模型的水文时间序列月径流预测 [J]. 北京师范大学学报 (自然科学版), 2020, 56(3): 376-386.
- WANG D, WEI J H, ZHANG S L, et al. Hydrological temporal series of monthly runoff prediction by CEEMD-BP model [J]. Journal of Beijing Normal University (Natural Science), 2020, 56 (3): 376-386. (in Chinese)
- [[5] VROCHIDOU E, ALVANITOPOULOS P, ANDREADIS I, et al. Artificial accelerograms composition based on the CEEMD [J]. Transactions of the Institute of Measurement and Control, 2018, 40(1): 239-250.
- [[6] 赵征, 汪向硕. 基于 CEEMD 和改进时间序列模型的超短期风功率多步预测 [J]. 太阳能学报, 2020, 41 (7): 352-358.
- ZHAO Z, WANG X S. Ultra-short-term multistep wind power prediction based on CEEMD and improved time series model [J]. Acta Energiæ Solaris Sinica, 2020, 41 (7): 352-358. (in Chinese)
- [[7] 乐友喜, 杨涛, 曾贤德. CEEMD 与 KSVD 字典训练相结合的去噪方法 [J]. 石油地球物理勘探, 2019, 54 (4): 729-736.
- LE Y X, YANG T, ZENG X D. Seismic denoising with CEEMD and KSVD dictionary combined training [J]. Oil Geophysical Prospecting, 2019, 54 (4): 729-736. (in Chinese)
- [[8] 王增平, 赵兵, 纪维佳, 等. 基于 GRU-NN 模型的短期负荷预测方法 [J]. 电力系统自动化, 2019, 43 (5): 53-62.
- WANG Z P, ZHAO B, JI W J, et al. Short-term load forecasting method based on GRU-NN model [J]. Automation of Electric Power Systems, 2019, 43 (5): 53-62. (in Chinese)
- [[9] 宋菁华, 杨春节, 周哲, 等. 改进型 EMD-Elman 神经网络在铁水硅含量预测中的应用 [J]. 化工学报, 2016, 67(3): 729-735.
- SONG J H, YANG C J, ZHOU Z, et al. Application of improved EMD-Elman neural network to predict silicon content in hot metal [J]. CIESC Journal, 2016, 67(3): 729-735. (in Chinese)

(责任编辑 梁 洁)