



引用格式:侯恩科,夏冰冰,吴章涛,等.基于 CEEMDAN-BO-BiGRU 的矿井涌水量预测研究[J].科学技术与工程,2023,23(28):12012-12019.

Hou Enke, Xia Bingbing, Wu Zhangtao, et al. Mine water inflow prediction based on CEEMDAN-BO-BiGRU[J]. Science Technology and Engineering, 2023, 23(28): 12012-12019.

矿冶工程

# 基于 CEEMDAN-BO-BiGRU 的矿井涌水量预测研究

侯恩科<sup>1</sup>, 夏冰冰<sup>1\*</sup>, 吴章涛<sup>2</sup>, 荣统瑞<sup>1</sup>

(1. 西安科技大学地质与环境学院, 西安 710054, 2. 陕西彬长小庄矿业有限公司, 咸阳 713500)

**摘 要** 为提高矿井涌水量预测的准确度,基于涌水量数据的不稳定性及随机性,提出一种自适应噪声完备集合经验模态分解(complete ensemble empirical mode decomposition with adaptive noise,CEEMDAN)、贝叶斯优化(Bayesian optimization,BO)与双向门控循环单元(bi-directional gated recurrent unit,BiGRU)相结合的矿井涌水量预测模型 CEEMDAN-BO-BiGRU。所提模型通过 CEEMDAN 将涌水量数据分解为多个较平稳的固有模态分量(intrinsic mode function,IMF)和残差分量(residual components,Res),过滤数据噪声,提取数据不同时间尺度波动特征,降低预测误差。利用贝叶斯优化对 BiGRU 模型多个超参数进行迭代寻优,进一步提高模型的预测精度。之后对各分量进行超前 1~3 步预测,最终将各分量预测结果加和得到涌水量多步预测结果。以小庄煤矿矿井涌水量数据进行试验,并将 CEEMDAN-BO-BiGRU 预测结果与其他多种预测模型结果进行对比分析。结果表明:采用 CEEMDAN-BO-BiGRU 组合网络模型对矿井涌水量预测结果更准确,该方法对涌水量的短时预测提供了一种新思路。

**关键词** 矿井涌水量;贝叶斯优化(BO);双向门控循环单元(BiGRU);时间序列

中图分类号 TD742;

文献标志码 A

## Mine Water Inflow Prediction Based on CEEMDAN-BO-BiGRU

HOU En-ke<sup>1</sup>, XIA Bing-bing<sup>1\*</sup>, WU Zhang-tao<sup>2</sup>, RONG Tong-rui<sup>1</sup>

(1. School of Geology and Environment, Xi'an University of Science and Technology, Xi'an 710054, China;

2. Shaanxi Binchang Xiaozhuang Mining Company Limited, Xianyang 713500, China)

**[Abstract]** In order to improve the accuracy of the mine water surge prediction, based on the instability and randomness of the water surge data, a mine water surge prediction model CEEMDAN-BO-BiGRU was proposed, combining complete ensemble empirical mode decomposition with adaptive noise (CEEMDAN), Bayesian optimization (BO) and bi-directional gated circulation unit (BiGRU). The proposed model decomposed the influx of water data into a number of smoother intrinsic mode function (IMF) and residual components (Res) through the CEEMDAN, filtered data noise, extracted of data fluctuations in different time scales characteristics, reduced the prediction error. Bayesian optimization was used to iteratively seek the optimization of multiple hyperparameters of the BiGRU model to further improve the prediction accuracy of the model. Afterwards, each component was predicted 1 to 3 steps ahead of the prediction, and finally the prediction results of each component were summed to obtain the multi-step prediction results of the water influx. The CEEMDAN-BO-BiGRU prediction results were compared and analyzed with other prediction models. The results show that the CEEMDAN-BO-BiGRU combined network model is more accurate for the prediction of mine water surges, and the method provides a new idea for the short-time prediction of water surges.

**[Keywords]** mine water influx; Bayesian optimization (BO); bidirectional gated recurrent unit (BiGRU); time series

矿井涌水量是指在矿山建设和生产过程中,地表水和地下水通过各种途径和方式,在单位时间内涌入井巷中的水量,是选择开采方案、矿井排水系统设计的重要依据,提高矿井涌水量预测的准确度对于预防透水事故、保证安全生产十分重要<sup>[1-2]</sup>。

由于矿井水文地质条件复杂多样,且影响因素众多,导致矿井涌水量预测成为一项比较困难且复杂的工作<sup>[3-4]</sup>。因此,研究提高矿井涌水量预测准确度的方法具有重要意义。

中国矿井涌水量预测方法经过长期发展,主要有

收稿日期:2022-11-09 修订日期:2023-07-07

基金项目:国家自然科学基金(42177174);陕煤集团科研计划项目(2021SMHK-BK-J-01,2020SMHK-J-C-52)

第一作者:侯恩科(1963—),男,汉族,陕西扶风人,博士,教授。研究方向:矿井水害防治。E-mail:houlk@xust.edu.cn。

\*通信作者:夏冰冰(1997—),男,汉族,河南安阳人,硕士研究生。研究方向:矿井水害防治。E-mail:781410114@qq.com。

投稿网址:www.stae.com.cn

解析法、水均衡法、数值模拟法、经验公式法、回归分析法、模糊数学、灰色预测等<sup>[5]</sup>。此外还有神经网络、支持向量机等方法也运用到矿井涌水量预测<sup>[6-7]</sup>。但由于水文地质条件复杂、所选参数缺乏代表、模型选择不当往往导致预测结果偏差较大<sup>[8]</sup>。因此有部分学者选择从涌水量的时间序列特征进行分析,研究其特征。李建林等<sup>[9]</sup>将混沌理论与广义回归神经网络(generalized regression neural network, GRNN)结合在一起,利用涌水量时间序列相空间重构来确定 GRNN 输入层神经元的个数及其取值,建立混沌-广义回归神经网络模型,对矿井涌水量进行预测。刘晓丹等<sup>[10]</sup>分别建立 X12 季节调整模型、差分整合移动平均自回归模型(autoregressive integrated moving average model, ARIMA)和季节性差分整合移动平均自回归模型(seasonal autoregressive integrated moving average model, SARIMA)模型,比较 3 种模型预测结果的误差,探讨涌水量预测最优模型。乔美英等<sup>[11]</sup>提出了利用遗传算法(genetic algorithm, GA)优化支持向量机(support vector machines, SVM)寻找其最优参数,提高涌水量预测的准确率。但由于涌水量数据的不稳定性及随机波动性,导致涌水量预测精度不高。

对于数据的波动性,经验模态分解(empirical mode decomposition, EMD),集合经验模态分解(ensemble empirical mode decomposition, EEMD)可将不稳定原始变形序列分解为若干稳定的分量,揭示原始序列的内在规律,提高预测精度,但 EMD 与 EEMD 存在模态混叠和噪声残留问题导致分解效果不佳。对此 María 等<sup>[12]</sup>提出自适应白噪声平均总体经验模态分解(complete ensemble empirical mode decomposition with adaptive noise, CEEMDAN)算法可有效地将振动信号突变分解为高频本征模态函数分量特征,该算法已广泛应用于电力、交通、矿山等<sup>[13-15]</sup>领域的预测。且近年来随着深度学习的发展,循环神经网络(recurrent neural network, RNN)凭借其记忆能力被用于处理时序性和非线性问题,门控循环单元(gated recurrent unit, GRU)是传统循环神经网络的优秀变体,其最大特点是不仅解决了 RNN 存在的梯度爆炸问题,而且提高了收敛速度与预测精度,但 GRU 只能单向处理数据,只能学习过去时刻数据进行预测<sup>[16]</sup>。双向门控循环单元(bi-directional gated recurrent unit, BiGRU)由前向与后向两个 GRU 网络构成,能学习某一时刻前后数据信息进行预测<sup>[17]</sup>,提高预测准确性。

深度学习算法在进行预测时需要对其参数进行调优,如隐藏层节点个数、迭代周期、学习率等,不同的参数取值会影响预测的精度,为此常采用优

化算法进行调优,贝叶斯优化算法对目标函数进行次数很少的评估就能获得最优解,非常适用于求解目标函数表达式未知以及评估代价高昂的复杂优化问题,且不需要大量的采样点便可以得到最优解,适合深度学习模型的超参数调优问题<sup>[18-19]</sup>。

综上,为去除涌水量数据不稳定性即随机波动性的影响,提高涌水量预测精度,提出基于自适应噪声完备集合经验模态分解和贝叶斯优化算法优化双向门控循环单元神经网络时间序列组合预测模型 CEEMDAN-BO-BiGRU 对矿井涌水量进行预测,首先通过 CEEMDAN 对涌水量数据进行分解,分解为多个子固有模态分量(intrinsic mode function, IMF)分量。然后利用贝叶斯优化算法对 BiGRU 的超参数组合进行寻优,建立贝叶斯优化(Bayesian optimization, BO)-BiGRU 模型对各分量分别进行预测,最后叠加得到最终的涌水量多步预测结果。应用小庄煤矿矿井涌水量数据对该模型进行验证。该方法可应用于矿井涌水量的预测,为矿井水害防治提供指引。

## 1 模型基本原理

### 1.1 CEEMDAN 算法原理

CEEMDAN 是一种针对 EMD 和 EEMD 改进的自适应后验分解算法,通过在原始数据所分解的 IMF 分量中加入自适应的白噪声,解决了 EMD 和 EEMD 算法存在的模态混叠和噪声残留问题。CEEMDAN 具体步骤如下。

**步骤 1** 将满足正态分布的白噪声  $n(i)$  添加  $i$  次到涌水量序列数据  $x$  中,得到新序列表示为  $x(i) = x + \varepsilon_0 n(i)$ ,其中,  $\varepsilon_0$  为噪声相对于原始序列的信噪比,  $n(i)$  为白噪声,  $i$  为添加的次数,  $i = 1, 2, \dots, N$ 。令  $IMF_i^1$  为  $x(i)$  采用 EMD 分解得到的一阶模态分量,则 CEEMDAN 分解的第一个本征模态分量  $IMF_1$  和第一个残余分量  $r_1$  分别表示为

$$IMF_1 = \frac{1}{N} \sum_{i=1}^N IMF_i^1 \quad (1)$$

$$r_1 = x - IMF_1 \quad (2)$$

**步骤 2** 定义  $E_k(\cdot)$  为 EMD 分解中获得的第  $k$  阶模态分量的算子,再次向残余分量中添加白噪声,得到新序列  $r_1(i) = r_1 + \varepsilon_1 E_1[n(i)]$ ,对  $r_1(i)$  再次进行 EMD 分解得到  $IMF_2$ 。

$$IMF_2 = \frac{1}{N} \sum_{i=1}^N E_1 \{r_1 + \varepsilon_1 E_1[n(i)]\} \quad (3)$$

式(3)中:  $\varepsilon_1$  为添加的白噪声。

去除二阶分量 IMF 后的残差  $r_2$  为

$$r_2 = r_1 - IMF_2 \quad (4)$$

**步骤 3** 通过重复步骤 2,得到第  $k+1$  阶本征

模态分量  $\text{IMF}_{k+1}$  和第  $k$  个残余分量  $r_k$ 。

$$\text{IMF}_{k+1} = \frac{1}{N} \sum_{i=1}^N E_1 \{ r_k + \varepsilon_k E_k [n(i)] \} \quad (5)$$

$$r_k = r_{k-1} - \text{IMF}_k \quad (6)$$

直到残余分量信号极值点个数不超过 2 个为止, 可得到  $k$  个本征模态分量  $\text{IMF}_k$ , 原始涌水量序列可表示为

$$x = \sum_{k=1}^k \text{IMF}_k + R \quad (7)$$

式(7)中:  $R$  为最终残差。

## 1.2 贝叶斯优化超参数算法原理

贝叶斯优化算法是一种利用概率代理模型对目标函数进行拟合, 根据后验概率分布构造采集函数, 采样函数在最大概率出现全局最优区域选取新的样本点, 通过不断迭代更新样本点, 使目标函数最小的全局优化算法<sup>[18-19]</sup>。

贝叶斯优化的核心是概率代理模型和采集函数的选取, 常用的概率代理模型主要有高斯过程 (gaussian process, GP), 树形 Parzen 估计器 (tree parzen estimator, TPE), 由于 TPE 相较于 GP 在效率和精度上均有提高, 采用 TPE 作为贝叶斯优化的概率代理模型, 其定义为

$$p(c|q) = \begin{cases} t(c), & q < q^* \\ u(c), & q > q^* \end{cases} \quad (8)$$

式(8)中:  $p(c|q)$  为模型损失函数为  $q$ , 超参数为  $c$  的后验概率;  $c$  为超参数组合;  $q$  为目标函数评价目标值;  $q^*$  为目标函数评价最大值;  $t(c)$  为观测值  $c^i$  损失函数小于  $q^*$  时的概率密度;  $u(c)$  为观测值  $c^i$  损失函数大于  $q^*$  时的概率密度。

采集函数主要用来衡量观测点对函数拟合的影响并选取影响最大的点进行下一步观测, 采集函数采用期望增量 (expected increment, EI), 其定义为

$$\text{EI}_{q^*}(c) = \frac{\gamma q^* t(c) \int_{-\infty}^{q^*} p(c) dc}{\gamma t(c) + (1 - \gamma) u(c)} \propto \left[ \gamma + \frac{u(c)}{t(c)} (1 - \gamma) \right]^{-1} \quad (9)$$

式(9)中:  $\gamma = p(q < q^*)$ 。

当  $t(c)$  越大,  $u(c)$  越小时, EI 越大, 即可以根据  $\frac{u(c)}{t(c)}$  最小时, 获得一个新的超参数值  $c^*$ , 将该值代入目标函数再次拟合函数  $t(c)$  和  $u(c)$ , 选出最大值 EI 对应的超参数值, 根据式(8)和式(9)不断迭代最终选择出准确率最优的超参数。

## 1.3 BiGRU 原理

门控循环单元 (GRU) 由 Cho 等<sup>[20]</sup> 在 2014 年提出, 相比 RNN 的另一种变体长短期记忆神经网络

(long short-term memory, LSTM) 它具有快速收敛和参数更少的优点, 在保证预测性能的前提下, 简化了复杂的结构, 提高了运算速度。因此, GRU 更简单、更有效。该网络能够学习时间序列的长期依赖关系, 并对于时间序列相关问题的解决具有独特优势。

GRU 网络主要由复位门和更新门组成, 其单元结构如图 1 所示。

复位门  $r_t$  由当前时刻输入  $x_t$  和上一时刻输出  $h_{t-1}$  变换得到, 如式(10)所示。 $r_t$  只控制上一时刻输出  $h_{t-1}$  不会控制前时刻输入  $x_t$ , 从而决定了前一时刻的单元状态需要保留到当前时刻的程度, 经式(11)得到新输入  $\tilde{h}_t$ 。

$$r_t = \sigma(W_r h_{t-1} + U_r x_t + b_r) \quad (10)$$

$$\tilde{h}_t = \tanh(W_h x_t + U_h r_t h_{t-1} + b_h) \quad (11)$$

式中:  $W_r$ 、 $W_h$  为不同门控机制对当前时刻输入  $x_t$  的权重;  $U_r$ 、 $U_h$  为不同门控机制对隐藏层输入  $h_t$  的权重;  $b_r$ 、 $b_h$  为偏置向量。


更新门  $z_t$  用于控制上一时刻输入  $h_{t-1}$  和新输入  $\tilde{h}_t$  对隐藏层输出  $h_t$  的影响程度,  $z_t$  由式(12)得到。 $z_t$  用于控制新输入  $\tilde{h}_t$ ,  $1 - z_t$  用于控制上一时刻输入  $h_{t-1}$ , 经式(13)等到当前时刻输出  $h_t$ 。

$$z_t = \tanh(W_z h_{t-1} + U_z x_t + b_z) \quad (12)$$

$$h_t = (1 - z_t) h_{t-1} + z_t \tilde{h}_t \quad (13)$$

式中:  $W_z$  为不同门控机制对当前时刻输入  $x_t$  的权重;  $U_z$  为不同门控机制对隐藏层输入  $h_t$  的权重;  $b_z$  为偏置向量。

GRU 网络记忆功能强大, 但其预测只依赖于之前所有时刻的信息规律, 而输出也与未来时刻的信息有一定关系。双向门控循环单元神经网络 BiGRU 是传统 GRU 的改进, 通过结合一个前向 GRU 层, 与一个后向 GRU 层组成, 可以充分学习数据的前后信息特征, 其结构如图 2 所示。




$h_t$  为隐藏层的输出;  $x_t$  为当前时刻输入;  $\sigma$ 、 $\tanh$  分别为

Sigmoid 激活函数和激活函数

图 1 GRU 单元结构

Fig. 1 Structure of GRU unit





$h_t^f$  表示从初始到最终时刻正向计算隐藏层的状态;  $h_t^b$  表示从最终到初始时刻反向计算隐藏层的状态

图2 BiGRU 网络结构

Fig. 2 BiGRU network structure

最终结合前向层与后向层输出结果,得到相应时刻的输出结果  $y_t$ , 相应表达式分别为

$$h_t^f = f_1(\omega_1 x_t + \omega_2 h_{t-1}^f) \quad (14)$$

$$h_t^b = f_2(\omega_3 x_t + \omega_4 h_{t-1}^b) \quad (15)$$

$$y_t = f_3(\omega_5 h_t^f + \omega_6 h_t^b) \quad (16)$$

式中:  $f_1$ 、 $f_2$ 、 $f_3$  为不同层间的激活函数;  $\omega_1 \sim \omega_6$  为各层相应权重。

## 2 CEEMDAN-BO-BiGRU 多步预测模型构建

### 2.1 组合模型构建

为消除矿井涌水量数据波动所带来的预测误差和进一步提高 BiGRU 模型的预测精度,将 3 种算法进行组合,构建 CEEMDAN-BO-BiGRU 组合模型。首先将矿井水量序列数据进行分解,得到有限个 IMF 分量。然后将各分量依次代入 BiGRU 模型,利用贝叶斯优化确定模型最优参数,提高模型预测的准确性,最后对各 IMF 分量进行预测,并将各分量预测结果相加得到最终涌水量预测结果。具体步骤如下,流程图如图 3 所示。

**步骤 1** 针对矿井涌水量的随机性和不稳定性利用 CEEMDAN 对矿井涌水量序列数据进行分解得到若干个平稳且具有规律性的分量 IMF 和残差余量。

**步骤 2** 构建 BiGRU,本次采用 python3.10 语言环境与 tensorflow2.9.1 框架下进行 BiGRU 网络模型构建如图 4 所示,主要由一层 BiGRU 层,一层 Dropout 层,两层 Dense 层构成。其中 Dropout 层可以避免模型过拟合,提升泛化能力;Dense 层为全连接层,最后一层全连接层通过转换输出维度得到最终的预测结果。该模型隐藏层激活函数采用 Relu 激活函数,优化器采用 Adam 优化器,损失函数采用 MSE。

**步骤 3** 对各分量进行归一化处理,然后采用

滑动窗口以一定步长  $n$  对各分量进行划分,如式(17)所示,把前  $n$  时刻的数据  $(x_{t-n}, x_{t-n-1}, \dots, x_{t-1})$  做为输入,第  $n+1$  时刻数据  $x_t$  作为输出,构建监督学习模型 BiGRU 训练输入集与输出集,由于各分量数据规律存在差异,为使预测结果更准确,因此采用贝叶斯优化确定各分量最优模型输入步长  $n$ 。

$$\begin{array}{c|c} \text{输入} & \text{输出} \\ \hline \begin{bmatrix} x_1 & x_2 & \cdots & x_n \\ x_2 & x_3 & \cdots & x_{n+1} \\ \vdots & \vdots & & \vdots \\ x_{t-n} & x_{t-n+1} & \cdots & x_{t-1} \end{bmatrix} & \begin{bmatrix} x_{n+1} \\ x_{n+2} \\ \vdots \\ x_t \end{bmatrix} \end{array} \quad (17)$$

**步骤 4** 确定贝叶斯优化采样点个数与迭代次数,将所构建模型的学习率、隐藏层神经元个数、迭代次数、滑动窗口步长设为寻优超参数并设置参数寻优范围。把各分量训练集及超参数的初始采样点代入步骤 3 构建的 BiGRU 模型进行训练,以测试集的均方根误差作为目标函数输出,由式(8)和式(9)迭代更新得到各分量基于 BiGRU 模型关于学习率、隐藏层神经元个数、迭代次数、滑动窗口步长的最优超参数组合,以此构建 BO-BiGRU 模型。

**步骤 5** 利用 BO-BiGRU 模型及其对应分量进行训练及预测,将各分量结果相加得到最终涌水量预测结果,之后采用平均绝对误差(mean absolute error, MAE)、均方根误差(root mean square error, RMSE)和平均绝对百分比误差(mean absolute percentage error, MAPE)对 CEEMDAN-BO-BiGRU 涌水量预测模型预测精度进行评价,各评价指标表达式分别为

$$MAE = \frac{1}{n} \sum_{i=1}^n |x_i - \hat{x}_i| \quad (18)$$

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (x_i - \hat{x}_i)^2}{n}} \quad (19)$$

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{x_i - \hat{x}_i}{x_i} \right| \times 100\% \quad (20)$$

式中:  $n$  为样本数量;  $x_i$  为真实值;  $\hat{x}_i$  为预测值。

### 2.2 递归多步预测过程

采用递归策略进行涌水量多部预测,首先利用上述构建模型进行预测输出  $x_{t+1}$ ,得到超前一步预测结果;然后将一步预测结果  $x_{t+1}$  与前  $n-1$  步数据结合作为历史数据,输入模型得到超前两步预测结果  $x_{t+2}$ ,以此类推得到超前三步预测结果,其过程如图 5 所示。




图3 CEEMDAN-BO-BiGRU 组合模型结构图  
Fig. 3 CEEMDAN-BO-BiGRU combined model structure




图4 BiGRU 模型结构  
Fig. 4 BiGRU model structure




图6 矿井涌水量序列图  
Fig. 6 Sequence diagram of mine water surge




图5 递归多部预测过程图  
Fig. 5 Recursive multi-part prediction process diagram

### 3 实例分析

#### 3.1 涌水量数据选取及预处理

陕西彬长小庄矿业有限公司位于陕西省咸阳市彬长矿区中部,隶属于陕西彬长矿业集团有限公司。井田面积约46.2275 km<sup>2</sup>,主采4煤层,生产能力6×10<sup>6</sup> t/a,矿井充水水源主要为大气降水、地表水和侧向补给等。本次实验数据采集该矿2019年2月12日—2019年12月31日矿井单位涌水量日监测数据,共201条,如图6所示,把2019年2月12

日—2019年7月22日数据作为训练集,2019年7月23日—2019年8月31日划分为测试集,并利用以上数据进行建模与验证。

从图6中可以看出,小庄矿井涌水量数据波动大,平稳性差,矿井涌水量最大值为1217.33 m<sup>3</sup>/h,最小值为692.25 m<sup>3</sup>/h,采用原始序列进行模型预测较困难,因此利用CEEMDAN方法对于矿井涌水量进行降噪和分解,最终分解为5个IMF分量和一个残差分量,其结果如图7所示,可以看出,分解后各分量更平稳,波动性更小,有利于BiGRU神经网络的学习。

#### 3.2 贝叶斯超参数优化

为进一步提高BiGRU模型预测精度,分别利用贝叶斯优化对以上6个涌水量子分量建立BO-BiGRU模型。首先划分合理的参数寻优范围,如表1所示,并设置贝叶斯优化迭代周期为200;然后利用贝叶斯优化算法对BiGRU模型超参数进行优化。经过优化,得到各分量最优参数组如表2所示。




图7 涌水量 CEEMDAN 分解结果

Fig. 7 CEEMDAN decomposition results of the influx of water

表 1 超参数约束条件

| Table 1 Hyperparameter constraints |               |                |
|------------------------------------|---------------|----------------|
| 名称                                 | 标识            | 取值范围           |
| 学习率                                | Learning Rate | 0.000 1 ~ 0.01 |
| 隐藏层神经元个数                           | Units         | 20 ~ 200       |
| 迭代次数                               | Epochs        | 50 ~ 500       |
| 滑动窗口步长                             | Step Size     | 2 ~ 20         |

表 2 各分量参数优化结果

| Table 2 Optimization results of each IMF component parameter |         |          |      |        |
|--------------------------------------------------------------|---------|----------|------|--------|
| IMF                                                          | 学习率     | 隐藏层神经元个数 | 迭代次数 | 滑动窗口步长 |
| IMF <sub>1</sub>                                             | 0.005 7 | 84       | 285  | 3      |
| IMF <sub>2</sub>                                             | 0.009 7 | 177      | 489  | 6      |
| IMF <sub>3</sub>                                             | 0.007 3 | 156      | 489  | 6      |
| IMF <sub>4</sub>                                             | 0.008 1 | 96       | 492  | 6      |
| IMF <sub>5</sub>                                             | 0.004 9 | 159      | 414  | 3      |
| Res                                                          | 0.003 4 | 51       | 483  | 9      |

3.3 涌水量预测结果分析

利用 BO-BiGRU 模型对与其对应的 IMF 分别进行递归三步预测,将各个 IMF 和残差分量(residual components, Res) 预测结果加和最终得到的未来 1~3 d 单位涌水量预测结果,如图 8 所示。可以看出,CEEMDAN-BO-BiGRU 模型在单步及多步预测对




图 8 1~3 步涌水量预测结果与真实值对比图

Fig. 8 1 to 3 step surge prediction results and the real value of the comparison chart

于涌水量的变化趋势均可以有效跟随,且预测误差较为平稳。为说明 CEEMDAN-BO-BiGRU 模型的实用性,将预测结果与 CEEMDAN-BiGRU 模型、BiGRU 模型、BP 神经网络、SVM 进行对比实验,各模型未来 1~3 d 预测结果对比如图 9 所示。



可以看出,CEEMDAN-BO-BiGRU 模型在单步及多步预测对于涌水量的变化趋势均可以有效跟随,但随着预测步数的增加,决定系数  $R^2$  减小,即预测误差逐步增大,这是由于递归多部预测采用前一步预测值作为真实值对后一步进行预测,产生的预测误差累积造成的。对于采用 CEEMDAN 方法的模型在进行一步预测时对真实值均有较好的拟合,且没有明显的滞后显现,预测误差相对平稳,没有较大波动,尤其在数据变化较大的时候也有很好的跟

随性,在 2 步和 3 步预测也可以较好预测真实值,而 BiGRU 模型,BP 神经网络,SVM 不仅误差大而且存在明显的延迟现象,预测效果差,这是由于通过 CEEMDAN 方法的分解可以解释原始数据在不同时间频率下的周期变化规律,减少涌水量数据的非平稳性与随机波动性,解决了 BiGRU 存在的预测滞后现象,提高预测精度。

针对各模型预测效果,采用 MAE、RMSE、MAPE 进一步对模型预测精度进行评价,其结果如表 3 所示,可以看出,CEEMDAN-BO-BiGRU 相比 CEEMDAN-BiGRU 预测误差略有降低,表明贝叶斯优化对模型参数进行寻优也在一定程度提升了预测精度。综合来看本文提出的 CEEMDAN-BO-BiGRU 模型涌水量对未来 1~3 步预测结果 MAE、RMSE 与 MAPE 均最小,拥有最好的预测效果。由此可见,CEEMDAN-BO-BiGRU 模型可以有效学习矿井涌水量数据的历史时刻的深层次特征信息进行预测,使其具有较高的预测精度。

## 4 结论

针对涌水量不稳定性及随机波动性,建立一种 CEEMDAN-BO-BiGRU 的矿井涌水量预测方法,利用彬长矿区小庄煤矿矿井涌水量数据对未来 3 步进行预测及对比分析。通过验证得到以下结论。

(1)通过 CEEMDAN 分解矿井涌水量时间序列之后再预测,可以将复杂的涌水量数据分解为多个平稳的子分量,减少数据不稳定性即波动性所带来的误差,解决了 BiGRU 存在的预测滞后现象,提高模型预测精度。

(2)采用贝叶斯优化算法对 BiGRU 模型超参数组合进行寻优,对于模型的预测精度在一定程度上有所提升。

(3)通过模型对比,CEEMDAN-BO-BiGRU 可以充分挖掘和学习矿井涌水量历史信息隐藏变化规律,对未来矿井涌水量 1 步进行准确预测,对 2~3 步进行较准确预测。该方法可应用于矿井涌水量短期预测,为矿井防治水提供依据。




图 9 各模型涌水量预测结果对比

Fig. 9 Comparison of the predicted results of each model surge

表 3 几种模型评价指标比较

Table 3 Comparison of several model evaluation indexes

| 模型               | MAE   |       |       | RMSE  |       |       | MAPE/% |      |      |
|------------------|-------|-------|-------|-------|-------|-------|--------|------|------|
|                  | 1 步   | 2 步   | 3 步   | 1 步   | 2 步   | 3 步   | 1 步    | 2 步  | 3 步  |
| CEEMDAN-BO-BiGRU | 13.33 | 19.26 | 26.14 | 18.02 | 25.30 | 34.28 | 1.40   | 1.98 | 2.62 |
| CEEMDAN-BiGRU    | 15.41 | 20.90 | 27.40 | 19.85 | 28.74 | 36.11 | 1.69   | 2.14 | 2.83 |
| BiGRU            | 28.09 | 36.86 | 43.63 | 41.92 | 48.22 | 55.74 | 2.92   | 3.67 | 4.19 |
| BP               | 32.85 | 40.41 | 45.58 | 45.90 | 52.44 | 59.97 | 3.51   | 4.03 | 4.37 |
| SVM              | 31.50 | 38.01 | 45.84 | 46.87 | 53.32 | 60.46 | 3.31   | 3.73 | 4.38 |

投稿网址:www. stae. com. cn

(4)总体上该方法随着预测步数增加,预测精度受影响变大,在今后的研究中可以通过引入涌水量相关因素,在模型中增加注意力机制,进一步减小多步预测误差。

### 参 考 文 献

- [1] 黄欢. 矿井涌水量预测方法及发展趋势[J]. 煤炭科学技术, 2016, 44(S1): 127-130.  
Huang Huan. Prediction method of mine inflow and its development [J]. Coal Science and Technology, 2016, 44(S1): 127-130.
- [2] 张耀辉,熊祖强,李西凡,等. 复杂水文地质条件下矿井水害防治技术研究[J]. 煤炭科学技术, 2021, 49(3): 167-174.  
Zhang Yaohui, Xiong Zuqiang, Li Xifan, et al. Study on technology of mine water disaster prevention and control in underground mine under complex hydrogeological conditions [J]. Coal Science and Technology, 2021, 49(3): 167-174.
- [3] 高瑞忠,姬腾达,于婵,等. 基于钻探-物探数据融合的矿井涌水量预测及效果评估[J]. 煤矿安全, 2021, 52(8): 66-74.  
Gao Ruizhong, Ji Tengda, Yu Chan, et al. Mine water inflow prediction and effect evaluation based on fused drilling-geophysical data [J]. Safety in Coal Mines, 2021, 52(8): 66-74.
- [4] 李建林,王树威,王心义,等. 矿井涌水对大气降水响应的非线性研究[J]. 河南理工大学学报(自然科学版), 2020, 39(6): 36-42.  
Li Jianlin, Wang Shuwei, Wang Xinyi, et al. Nonlinear study on the response of mine water inflow to atmospheric precipitation [J]. Journal of Henan Polytechnic University (Natural Science), 2020, 39(6): 36-42.
- [5] 王晓蕾. 煤矿开采矿井涌水量预测方法现状及发展趋势[J]. 科学技术与工程, 2020, 20(30): 12255-12267.  
Wang Xiaolei. Present situation and development trend of coal mine discharge forecast method [J]. Science Technology and Engineering, 2020, 20(30): 12255-12267.
- [6] Golnosh A, Mashaallah M, Ali S. Software fault prediction using BP-based crisp artificial neural networks [J]. International Journal of Intelligent Information and Database Systems, 2015, 9: 15-31.
- [7] 黄存捍,陈魁奎,李振华,等. 基于相空间重构和支持向量机的矿井涌水量预测[J]. 河南理工大学学报(自然科学版), 2016, 35(2): 202-205, 211.  
Huang Cunhan, Chen Kuikui, Li Zhenhua, et al. Mine water inrush prediction based on phase space reconstruction and support vector machines [J]. Journal of Henan Polytechnic University (Natural Science), 2016, 35(2): 202-205, 211.
- [8] 刘启蒙,胡友彪,张宇通,等. 矿井涌水量预测方法探讨[J]. 安徽理工大学学报(自然科学版), 2017, 37(6): 1-7.  
Liu Qimeng, Hu Youbiao, Zhang Yutong, et al. Exploration on the prediction methods of coal mining water inflow [J]. Journal of Anhui University of Science and Technology (Natural Science), 2017, 37(6): 1-7.
- [9] 李建林,高培强,王心义,等. 基于混沌-广义回归神经网络的矿井涌水量预测[J]. 煤炭科学技术, 2022, 50(4): 149-155.  
Li Jianlin, Gao Peiqiang, Wang Xinyi, et al. Prediction of mine water inflow based on chaos-generalized regression neural network [J]. Coal Science and Technology, 2022, 50(4): 149-155.
- [10] 刘晓丹,潘国营. 基于三种时间序列模型的矿井涌水量预测[J]. 矿业安全与环保, 2022, 49(2): 91-95, 101.  
Liu Xiaodan, Pan Guoying. Prediction of mine water inflow based on three time series models [J]. Mining Safety & Environmental Protection, 2022, 49(2): 91-95, 101.
- [11] 乔美英,程鹏飞,刘震震. 基于 GA-SVM 的矿井涌水量预测[J]. 煤田地质与勘探, 2017, 45(6): 117-122.  
Qiao Meiyang, Cheng Pengfei, Liu Zhenzhen. Mine water inflow prediction based on GA-SVM [J]. Coal Geology & Exploration, 2017, 45(6): 117-122.
- [12] María E T, Marcelo A C, Gastón S, et al. A complete ensemble empirical mode decomposition with adaptive noise [C]//IEEE International Conference on Acoustics, Speech Signal Processing. New York: IEEE, 2011: 4144-4147.
- [13] 闫群民,刘语忱,董新洲,等. 基于 CEEMDAN-HT 的平抑光伏出力混合储能容量优化配置[J]. 电力系统保护与控制, 2022, 50(21): 43-53.  
Yan Qunmin, Liu Yuchen, Dong Xinzhou, et al. Hybrid energy storage capacity optimization configuration for smoothing PV output based on CEEMDAN-HT [J]. Power System Protection and Control, 2022, 50(21): 43-53.
- [14] 张佳,赵岩. 基于 CEEMDAN 法的隧道爆破信号趋势项去除[J]. 爆破器材, 2021, 50(6): 58-64.  
Zhang Jia, Zhao Yan. Removal of trend items of tunnel blasting signals based on CEEMDAN [J]. Explosive Materials, 2021, 50(6): 58-64.
- [15] 张向阳,吴梦云,张卫华. 基于 CEEMDAN-组合预测模型的短时交通流预测[J]. 安徽理工大学学报(自然科学版), 2022, 42(6): 8-17.  
Zhang Xiangyang, Wu Mengyun, Zhang Weihua. Short-term traffic flow prediction based on CEEMDAN-combined prediction model [J]. Journal of Anhui University of Science and Technology (Natural Science), 2022, 42(6): 8-17.
- [16] Zhao S, Zhang Y, Wang S, et al. A recurrent neural network approach for remaining useful life prediction utilizing a novel trend features construction method [J]. Measurement, 2019, 146: 1-10.
- [17] Liu S Y, You S T, Zeng C J, et al. Data source authentication of synchrophasor measurement devices based on 1D-CNN and GRU [J]. Electric Power Systems Research, 2021, 196: 107207.
- [18] Bobak S, Kevin S, Wang Z Y, et al. Taking the human out of the loop: a review of Bayesian optimization [J]. Proceedings of the IEEE, 2016, 104: 148-175.
- [19] 崔佳旭,杨博. 贝叶斯优化方法和应用综述[J]. 软件学报, 2018, 29(10): 3068-3090.  
Cui Jiaxu, Yang Bo. Survey on Bayesian optimization methodology and applications [J]. Journal of Software, 2018, 29(10): 3068-3090.
- [20] Cho K, van Merriënboer B, Çaglar G, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation [J]. EMNLP, 2014, 1: 1031-1040.