

doi:10.13301/j.cnki.ct.2025.07.049

基于 CNN-LSTM 模型的矿坑涌水量预测方法研究

秦家翔¹, 徐世光^{1,2}, 张 兵¹, 宗吉松¹, 张佳伟¹

(1. 昆明理工大学 国土资源工程学院, 昆明 650093; 2. 云南地矿工程勘察集团有限公司, 昆明 650032)

摘 要: 为解决矿坑涌水量预测问题, 提高预测精度, 以云南先锋露天煤矿为研究对象, 选取 2018 年 1 月—2023 年 12 月涌水量为样本数据, 结合卷积神经网络(CNN)和长短期记忆神经网络(LSTM)建立 CNN-LSTM 矿坑涌水量复合预测模型, 按 7:3 比例划分训练集和测试集, 选取 ReLU 作为模型激活函数, 在训练过程中通过 Adam 算法不断优化模型参数。将模型预测结果分别与 CNN、LSTM、RF 和 SVM 单一模型及 GA-BP 复合模型作对比, 结果表明: CNN-LSTM 涌水量预测模型的均方根误差 E_{RMS} 、绝对百分比误差 E_{MAP} 、绝对平均误差 E_{MA} 和相关系数 R^2 分别为 489.52、28.33%、420.00 和 0.96, CNN-LSTM 模型的预测效果更好, 精度更高。研究结果可为矿坑涌水量预测和矿山水害防治提供一定的理论依据和现实意义。

关键词: 矿坑涌水量预测; CNN-LSTM 模型; 卷积神经网络; 长短期记忆神经网络

中图分类号: TD742

文献标志码: A

文章编号: 1008-8725(2025)07-234-06

Research on Mine Water Inflow Prediction Method Based on CNN-LSTM Model

QIN Jiaxiang¹, XU Shiguang^{1,2}, ZHANG Bing¹, ZONG Jisong¹, ZHANG Jiawei¹

(1. Faculty of Land and Resources Engineering, Kunming University of Science and Technology, Kunming 650093, China;

2. Yunnan Geology and Mining Engineering Exploration Group Corporation Limited, Kunming 650032, China)

Abstract: In order to solve the problem of predicting water inflow and improve the prediction accuracy, takes Yunnan Xianfeng opencut coal mine as the research object, selects the influx volume from January 2018 to December 2023 as the sample data, establishes a CNN-LSTM pit influx composite prediction model by combining convolutional neural network (CNN) and long and short-term memory neural network (LSTM), and divides the training set and the test set according to the ratio of 7:3. ReLU was selected as the activation function of the model, and the model parameters were continuously optimized by Adam algorithm during the training process. The model prediction results were compared with the CNN, LSTM, RF and SVM single model and GA-BP composite model respectively, and the results showed that the root mean square error E_{RMS} , absolute percentage error E_{MAP} , absolute average error E_{MA} and correlation coefficient R^2 of the CNN-LSTM water inflow prediction model were 489.52, 28.33%, 420.00 and 0.96, and the CNN-LSTM model has better prediction and higher accuracy. The results of the study can provide certain theoretical basis and practical significance for the prediction of mine pit influx and mine water damage prevention.

Key words: prediction of mine water inflow; CNN-LSTM model; convolutional neural network; long short-term memory neural network

0 前言

矿坑涌水是指在矿坑生产建设阶段, 大气降水、地表水、地下水通过多种途径如构造通道、岩土层渗透等进入矿坑底部, 随着采掘工作的进行, 从矿坑底部或隔水层顶板较薄弱地段涌出, 其直接威胁矿山正常建设开采和生产安全, 且涌水量会在一定时间

内出现大幅度变化, 轻则矿坑区域性生产中断, 重则直接淹没矿坑, 甚至造成人员伤亡的严重安全事故。因此, 为降低涌水事故的发生概率、降低涌水事故风险, 提前做好水害防范措施确保矿山生产安全, 加强涌水量预测技术的研究与应用, 提高涌水量预测精度具有深远的意义^[1-3]。

在矿坑涌水量预测的发展历程中,国内外的研究学者及矿山技术人员付诸大量精力做了许多研究工作,提出众多预测模型,从不同角度出发,对矿坑涌水量进行了深入的预测分析,且这一领域的研究至今仍在不断进步与发展^[4]。崔杰^[5]将涌水量预测方法分为分布参数法和集中参数法2类,分别用偏微分方程和常微分方程表示。陈酪知等^[6]将矿井涌水量预测方法分为确定性数学模型法和统计分析方法2类。张鹤宾^[7]引入等维新息思想,建立了等维GM(1,1)-马尔科夫预测模型,进行了涌水量预测研究,该模型通过解决数据贡献值低的问题,进一步提高了预测精度。李建林等^[8]用多步马尔科夫模型,对单一灰色GM(1,1)模型预测值的相对残差序列进行再处理,预测下一步的相对残差,对灰色模型的预测值进行修正提出了灰色-多步马尔科夫模型。侯恩科等^[9]将3种模型算法组合构建了CEEMDAN-BO-BiGRU模型,进行矿井涌水量预测研究,该组合模型减少了数据不稳定性即波动性带来的影响。丁莹莹等^[10]结合微震能量数据和钻孔水位,提出了多因素预测模型,相较于单因素模型,其可以更全面地考虑涌水量的关联因素,且准确率更高,更加稳定。Yang Songlin 等^[11]应用鲁棒深度学习模型提出的DIFF-TCN和DIFF-LSTM模型,能提高非平稳矿井涌水量的可预测性,此外,通过SHAP值进一步评估DIFF-TCN模型能增加模型的精度。梁满玉等^[12]提出了DRN-BiLSTM预测模型,结合小波分解涌水量数据,提高预测精度。还有学者引入深度学习理论,结合长短期记忆网络(LSTM)和门控循环单元(GRU),构建了一种LSTM-GRU的矿井涌水预测复合模型。

基于上述研究,本文结合卷积神经网络(CNN)和长短期记忆神经网络(LSTM),提出一种基于CNN-LSTM的涌水量预测模型。CNN具有优异的数据特征提取能力,利用LSTM解析序列数据中前后的相互依赖关系^[13]。并与传统的预测模型进行对比研究,验证CNN-LSTM模型的可行性和准确性,为矿山水害防治、矿山安全运营提供有力保障,为矿坑涌水量预测开辟新思路,激发更多的学者和专家对矿坑涌水量预测领域的深入研究和探索。

1 模型原理

1.1 卷积神经网络(CNN)

CNN是一种深度学习算法,能从原始数据中捕

捉时空依赖性,具有局部连接和权值共享的特点,原始数据体量较大时,CNN能对其进行降维,在降低模型的复杂度、减少建模参数的情况下,还可以更高效地提取特征信息,使学习效果更准确、更高效且更简洁^[14]。

CNN网络主要由输入层、隐含层(卷积层、池化层、全连接层)和输出层构成。CNN网络结构,如图1所示。




图1 CNN模型网络结构图

1.2 长短期记忆神经网络(LSTM)

LSTM是为了解决RNN在时间序列过长时出现梯度消失,为避免出现长期依赖而提出的一个改进网络。LSTM在RNN的基础上添加“门”的结构,引入细胞状态的连接,3个门分别是遗忘门、输入门和输出门^[15-19]。LSTM记忆单元结构,如图2所示。




图2 LSTM记忆单元结构图

遗忘门决定模型中的细胞单元需要舍弃的信息;输入门确认哪些细胞单元中增加了多少新信息;输出门决定要输出的信息。遗忘门

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \quad (1)$$

输入门

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad (2)$$

即时记忆单元的内容

$$\tilde{C}_t = \tanh(W_c[h_{t-1}, x_t] + b_c) \quad (3)$$

记忆单元的内容

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (4)$$

输出门

$$O_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (5)$$

单元输出信息

$$h_t = O_t * \tanh(C_t) \quad (6)$$

式中 σ ——sigmoid 函数;
 $\tanh(\cdot)$ ——双曲正切函数;
 W_f ——遗忘门的权重矩阵;
 b_f ——遗忘门偏置量;
 W_i ——输入门的权重矩阵;
 b_i ——输入门偏置量;
 W_c ——即时记忆单元的权重矩阵;
 b_c ——即时记忆单元的偏置量;
 W_o ——输出门的权重矩阵;
 b_o ——输出门的偏置量;
 h_{t-1} —— t 时刻输出值;
 x_t —— t 时刻输入值。

2 CNN-LSTM-Attention 复合模型

2.1 模型构建

基于上述模块,构建 CNN-LSTM 复合模型的矿坑涌水量预测方法,主要分为 5 层:输入层、CNN 层、LSTM 层、全连接层和输出层。首先将输入的时间序列数据变换为矩阵,通过 CNN 网络提取数据特征并降维进入 LSTM 层训练,最后经过全连接层进行预测,输出。复合模型网络结构,如图 3 所示。




图 3 CNN-LSTM 模型网络结构图

2.2 模型评价

计算均方根误差

$$E_{RMS} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2} \quad (7)$$

绝对百分比误差

$$E_{MAP} = \left(\frac{1}{n} \sum_{i=1}^n \left| \frac{\hat{y}_i - y_i}{\hat{y}_i} \right| \right) \times 100\% \quad (8)$$

绝对平均误差

$$E_{MA} = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i| \quad (9)$$

相关系数

$$R^2 = 1 - \frac{\sum_{i=1}^n (\hat{y}_i - y_i)^2}{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2} \quad (10)$$

式中 $\hat{y}_i$ ——涌水量真实值;
 y_i ——涌水量预测值;
 $\bar{y}$ ——涌水量平均值;
 i ——涌水量样本数。

E_{RMS} 、 E_{MAP} 、 E_{MA} 越小,证明模型的准确度越高;而 R^2 越接近 1,则模型预测性能越优异,与涌水量实际数据序列拟合效果更好。

3 研究区概况与数据来源

3.1 研究区概况

云南先锋露天煤矿区为一近东西向的狭长山间盆地,北、东、南三面由中高山环绕。矿区位于一背斜构造之上,下伏前震旦系昆阳群因民组(P_{kn}^y)隆起与上覆震旦系灯影组(Z_{ldn})呈不整合接触。新近系小龙潭组第二段(N_1^2)为井田主要含煤地层,属一弱裂隙潜水含水层,新近系下龙潭组第一段(N_1^1)和第三段(N_1^3)属于隔水层;前震旦系昆阳群因民组(P_{kn}^y)板岩砂岩浅部表层岩体的节理裂隙较为发育,故而赋存着一定量的浅层风化裂隙水;而岩层深部,由于岩体节理裂隙发育较弱,岩体透水性较差,进而起到一定程度的隔水作用。矿区主要充水含水层是震旦系灯影组(Z_{ldn})白云岩岩溶裂隙含水层,各含水层间水力联系,如图 4 所示。




图 4 各含水层之间水力联系示意图

3.2 数据来源

收集整理先锋露天煤矿 2018 年 1 月—2023 年 12 月每月平均涌水量数据,矿坑涌水量数据变化,如图 5 所示,此期间涌水量最大为 123 m³/d、最小为 7 035 m³/d。




图 5 矿坑涌水量变化图

4 模型预测结果与讨论

4.1 模型参数选取

以 7:3 划分训练集和测试集,2018 年 1 月—2023 年 2 月涌水量数据作为训练集来训练模型,2023 年 3 月—2023 年 12 月涌水量数据作为测试集检验模型的泛化性。

模型激活函数选用 ReLU 函数,可有效防止梯度爆炸和梯度消失问题,活跃度的分散性能简化网络的计算;添加一个内部丢弃阈值为 0.2 的 dropout 层,减小 CNN-LSTM 模型过载的风险,模型训练时,该层会随机移除一定数量的神经元,当模型恢复使用时,这些暂时被丢弃的神经元就会重新连接起来,以预防模型过拟合;迭代次数设置为 600 次,初始学习速率设置为 0.01,训练权重使用 Adam 算法更新,不断优化梯度、调整模型参数。在模型训练过程中分别优化模型的各参数条件,使其达最优状态。具体参数如表 1 所示。

表 1 CNN-LSTM 模型参数表

参数	设定值	含义
Num_size	0.7	训练集和测试集划分比例 7:3
CNN	32	32 通道
LSTM	10	10 个隐藏单元
BN layer	1	批量归一化层,输入数据标准化处理
Mini Batch Size	12	单批次处理样本
Dropout	0.2	内部丢弃阈值
Sequence Unfolding Layer	1	序列展开层,恢复数据结构
Flatten Layer	1	数据扁平化,转化数据维度
Optimizer	Adam	自适应模型优化算法
Activation	ReLU	激活函数
Learning rate	0.01	学习率
L2 Regularization	0.000 1	L2 正则化,限制模型参数范围,防止过拟合
Fully Connected Layer	1	全连接输出层
Epochs	600	模型迭代次数

4.2 模型预测

以 2018 年 1 月—2023 年 2 月涌水量数据作为训练集来训练模型,以 2023 年 3 月—2023 年 12 月涌水量数据来验证模型的准确性。涌水量实际值和 CNN-LSTM 模型预测值对比,如图 6 所示;预测值与实际值的误差结果,如图 7 所示。CNN-LSTM 模型预测结果与涌水量实际值高度契合,模型整体拟合程度较高(见图 8)。CNN-LSTM 模型各指标评价结果,如表 2 所示, E_{RMS} 、 E_{MAP} 、 E_{MA} 和 R^2 分别为 489.52、28.33%、420.00、0.956 3。极个别样本数据偏差较大,误差为 73.96%,最小误差 0.53%,预测结果 50%以上的误差在 5%以内,90%以上的误差在 20%以内,说明 CNN-LSTM 模型整体拟合程度较好,预测精度较高。

表 2 CNN-LSTM 模型评价结果表

E_{RMS}	E_{MAP}	E_{MA}	R^2
489.52	28.33%	420.00	0.956 3




图 6 CNN-LSTM 模型预测值和涌水量实际值对比图




图 7 CNN-LSTM 预测值与实际值误差图




图 8 CNN-LSTM 预测涌水量拟合情况图

4.3 对比分析

为进一步评价 CNN-LSTM 模型的预测性能,将其与 CNN(卷积神经网络)模型、LSTM(长短期记忆网络)模型、RF(随机森林)模型、SVM(支持向量机)模型和 GA-BP(遗传算法-BP 神经网络)模型进行对比分析。不同模型的预测结果和涌水量原始数据对比结果,如图 9 所示。由图 9 可知,对比其他 5 种

模型, CNN-LSTM 模型的预测值与涌水量实际值曲线变化趋势更接近, 2 条曲线更贴合, 说明预测误差均比其他模型更小, 拟合度、准确度更高, CNN-LSTM 模型的预测性能表现更加优异。




图 9 模型预测对比图

通过各模型的评价指标进行对比分析, 将各模型的 4 种指标评价结果进行分类比较, 如图 10~图 13 所示。CNN-LSTM 模型的 E_{RMS} 、 E_{MAP} 、 E_{MA} 和 R^2 这 4 个评价指标结果均优于其他 5 个模型, 其中 SVM 模型的预测表现和评价指标结果最差; CNN-LSTM 与 CNN 和 LSTM 相比, E_{RMS} 、 E_{MAP} 、 E_{MA} 分别下降了 500.46 和 390.55、22.03% 和 5.95%、381.19 和 236.84, R^2 都高于 CNN 和 LSTM, 分别高 0.14 和 0.10, 且更接近于 1, 说明 CNN 和 LSTM 的组合模型比单一模型的预测精度更高, CNN-LSTM 组合模型表现出比单一模型更好的优越性; CNN-LSTM 和 GA-BP 相比, E_{RMS} 、 E_{MAP} 、 E_{MA} 分别下降了 385.41、25.86%、305.08, R^2 提高了 0.10, 进一步验证了 CNN-LSTM 组合模型用于矿坑涌水量预测问题的优越性, 能更准确、有效地预测涌水量。




图 10 模型 E_{RMS} 对比图




图 11 模型 E_{MAP} 对比图




图 12 模型 E_{MA} 对比图




图 13 模型 R^2 对比图

5 结语

(1) 对比 CNN、LSTM、RF、SVM 这 4 个单一模型以及 1 个 GA-BP 组合模型, 结合 CNN 模型和 LSTM 模型构建的 CNN-LSTM 组合模型在涌水量预测问题上预测效果明显提升, 表现更好, 精度更高。

(2) CNN-LSTM 模型综合 CNN 提取数据特征信息能力和 LSTM 解决长期依赖、梯度消失的能力, 模型的 E_{RMS} 、 E_{MAP} 、 E_{MA} 比其他 5 类模型更低, 而 R^2 更高, CNN-LSTM 模型的涌水量预测性能更加优异。

(3)综合试验结果,此次研究提出的 CNN-LSTM 模型,可以较为准确地预测矿坑涌水量,能为矿坑涌水量预测方法的选取给予参考且提供一个新思路。

参考文献:

- [1]王颖,刘郑秋,李成帅,等. 基于 ARIMA-GM 模型的矿井涌水量预测[J]. 煤炭技术,2024,43(9):154-157.
- [2]连会青,李启兴,王瑞,等. 基于深度学习的 LSTM-GRU 复合模型矿井涌水量预测方法研究[J]. 煤矿安全,2024,55(9):166-172.
- [3]左文喆,王斌海,程紫华,等. 矿井涌水量预测方法综述[J]. 化工矿物与加工,2016,45(9):71-74.
- [4]郭海. 河北省秦皇岛某铁矿矿坑涌水量预测[D]. 石家庄:河北地质大学,2016.
- [5]崔杰. 矿井涌水量计算方法评述[J]. 水力采煤与管道运输,2009(4):1-4,95.
- [6]陈酩知,刘树才,杨国勇. 矿井涌水量预测方法的发展[J]. 工程地球物理学报,2009,6(1):68-72.
- [7]张鹤缤. 基于等维 GM(1,1)-马尔可夫链模型的涌水量预测研究[J]. 数学的实践与认识,2023,53(8):139-145.
- [8]李建林,王路扬,李松营,等. 基于灰色-多步马尔科夫模型的矿井涌水量预测[J]. 河南理工大学学报(自然科学版),2023,42(5):66-71.
- [9]侯恩科,夏冰冰,吴章涛,等. 基于 CEEMDAN-BO-BiGRU 的矿井涌水量预测研究[J]. 科学技术与工程,2023,23(28):12012-12019.
- [10]丁莹莹,尹尚先,连会青,等. 基于 SSA-CG-Attention 模型的多因素采煤工作面涌水量预测[J]. 煤田地质与勘探,2024,52(4):111-119.
- [11]Yang Songlin ,Lian Huiqing ,Xu Bin, et al.Application of robust deep learning models to predict mine water inflow: Implication for ground water environment management [J]. Science of the Total Environment,2023,871:162056-162056.
- [12]梁满玉,尹尚先,姚辉,等. 基于 DRN-BiLSTM 模型的矿井涌水量预测[J]. 煤矿安全,2023,54(5):56-62.
- [13]韩星晖,何永玲,蒙古彬,等. 基于 CNN-LSTM-Attention 的短期风向预测研究[J]. 广西科学院学报,2023,39(2):192-198.
- [14]路梦雨,毛经坤,赵洪阳. 基于贝叶斯优化的 CNN-LSTM-Attention 的个性化商品推荐算法[J/OL]. 天津理工大学学报,1-7[2025-03-26].
- [15]曹梅,杨超宇. 基于小波的 CNN-LSTM-Attention 瓦斯预测模型研究[J]. 中国安全生产科学技术,2023,19(9):69-75.
- [16]Hossein Abbasimehr,Mostafa Shabani,Mohsen Yousefi. An optimized model using LSTM network for demand forecasting [J]. Computers & Industrial Engineering,2020,143(C):106435-106435.
- [17]Long Huang,Wenhao Li,Runyu Liu, et al.Dynamic characteristics of the internal flow field of a rotary centrifugal air classifier and pressure prediction through attention mechanism-enhanced CNN-LSTM[J]. Advanced Powder Technology,2024,35(8):104578-104578.
- [18]童光泽,李计生,牛最荣,等. 基于 CNN-LSTM 组合模型在地下水位预测中的应用[J]. 水利规划与设计,2024(9):58-62,76.
- [19]袁利伟,杨柳,何涛,等. 结合 CNN-LSTM 优化模型在尾矿坝浸润线预测中的应用[J]. 安全与环境学报,2024,24(10):3770-3779.

作者简介: 秦家翔(2001-), 贵州毕节人, 硕士研究生, 研究方向: 水文地质, 电子信箱: 486780605@qq.com; 通信作者: 徐世光(1963-), 云南大理人, 教授级高级工程师, 博士生导师, 博士(后), 研究方向: 水文地质、工程地质等, 电子信箱: 1033450155@qq.com.

责任编辑: 李景奇 收稿日期: 2024-11-01