



移动扫码阅读

DOI: 10.13347/j.cnki.mkaq.2023.05.009

梁满玉,尹尚先,姚辉,等.基于DRN-BiLSTM模型的矿井涌水量预测[J].煤矿安全,2023,54(5):56-62.

LIANG Manyu, YIN Shangxian, YAO Hui, et al. Mine water inflow prediction based on DRN-BiLSTM model[J]. Safety in Coal Mines, 2023, 54(5): 56-62.

基于DRN-BiLSTM模型的矿井涌水量预测

梁满玉¹,尹尚先¹,姚辉²,夏向学¹,徐斌¹,李书乾³,张丐卓³

(1.华北科技学院 河北省矿井灾害防治重点实验室,河北 三河 065201;2.西安科技大学 地质与环境学院,陕西 西安 710054;3.中国矿业大学(北京) 地球科学与测绘工程学院,北京 100083)

摘要:针对矿井涌水量预测中存在的深度学习模型预测精度不高和适用性不强的问题,提出了一种基于深度残差网络(Deep Residual Network, DRN)和双向长短记忆网络(Bidirectional short and long memory network, BiLSTM)的矿井涌水量预测方法。首先,将矿井涌水量数据进行小波分解和归一化处理,得到趋势项数据和细节项数据;其次,采用DRN网络方法对趋势项数据进行预测,采用BiLSTM网络方法对细节项数据进行预测;最后,将2部分预测结果进行重构得到矿井涌水量预测结果。研究表明:DRN-BiLSTM模型相比于单一模型预测精度更高,说明该模型具有更好的泛化性。

关键词:矿井涌水量;DRN-BiLSTM模型;深度残差网络;双向长短记忆网络;小波分解

中图分类号:TD745

文献标志码:A

文章编号:1003-496X(2023)05-0056-07

Mine water inflow prediction based on DRN-BiLSTM model

LIANG Manyu¹, YIN Shangxian¹, YAO Hui², XIA Xiangxue¹, XU Bin¹, LI Shuqian³, ZHANG Gaizhuo³

(1.Hebei State Key Laboratory of Mine Disaster Prevention, North China Institute of Science and Technology, Sanhe 065201, China; 2.School of Geology and Environment, Xi'an University of Science and Technology, Xi'an 710054, China; 3.College of Geoscience and Surveying Engineering, China University of Mining & Technology (Beijing), Beijing 100083, China)

Abstract: For the problem of low accuracy and applicability of the model prediction in the study of mine water inflow, a method of mine water inflow prediction based on bidirectional short and long memory network (BiLSTM) and deep residual network (DRN) is proposed. First, the data of mine water inflow is processed by wavelet decomposition and normalization to obtain trend item data and detail item data. Secondly, the trend item data was predicted by DRN network method, and the detail item data was predicted by BiLSTM network method. Finally, the two parts of the prediction results will be combined to get the mine water inflow prediction results. The results show that the DRN-BiLSTM model has higher prediction accuracy than a single model, indicating that the model has better generalization.

Key words: mine water inflow; DRN-BiLSTM model; deep residual network (DRN); bidirectional short and long memory network (BiLSTM); wavelet transform

矿井涌水量是指在矿山生产过程中单位时间内涌入井巷中的总水量,伴随矿井整个生产周期。涌水量预测的可靠性是设置适当排水系统的基础,对保障矿井安全运行具有重要作用^[1-3]。矿井涌水量众

收稿日期:2022-03-01 责任编辑:庚馨杰

基金项目:国家自然科学基金资助项目(51974126,42202291);教育部“创新团队发展计划”滚动支持资助项目(IRT_17R37);中央高校基本科研业务费资助项目(3142022003)

作者简介:梁满玉(1996—),女,河北石家庄人,硕士研究生,研究方向为矿井水灾与地质勘探安全技术。E-mail: 17703340912@126.com

通讯作者:尹尚先(1964—),男,山西朔州人,教授,博士研究生导师,博士,主要从事煤矿防治水方面的研究与教学工作。E-mail: yinshx03@126.com

多影响因素包含长期影响因素和短期影响因素,所以实际矿井涌水量存在较大的周期性变化和短期波动^[4]。长期影响因素主要有开采条件(开采强度、开采时间长短、开采规模、开采范围)和地质条件等^[5];短期影响因素主要有水源补给的条件和强度(空水期、丰水期)等。

因为矿井涌水量影响因素众多,导致使用定量方法如解析法、水均衡法预测具有较大误差。随机预测方法(水文地质比拟法、模糊数学模型、传统的灰色理论模型如灰色 TPGM(1,1)、DNGM(1,1)和 ARIMA 预测模型等)的预测精度受数据量的影响较大^[6-7]。随着大数据技术的发展,矿井涌水量预测方法不断更新,利用深度学习模型处理和预测矿井涌水量的方法越来越多^[8]。

传统预测方法 BP 神经网络对于时间序列数据的处理准确度不高,其预测精度并不随迭代次数成正比,反而容易增加训练模型的时间^[9];而深度学习应用方法在预测中的模型主要有卷积神经网络(Convolutional Neural Network, CNN)和循环神经网络(Recurrent Neural Networks, RNN),其中 RNN 循环神经网络可以很好的处理与时间有关的数据,但是其记忆能力不足,无法处理很长的输入序列^[10-12]。长短期记忆网络(Long Short-Term Memory, LSTM)在 RNN 的基础上,改进了此问题,可以更好地发现序列数据中远距离依存关系。在实际矿井涌水量预测任务中,当前时刻涌水量与之前和之后数值都有关联,单一的 LSTM 模型无法获取从后到前的信息,所以预测效果不太理想^[13]。为此,提出了 DRN-BiLSTM 模型,该模型考虑矿井涌水量因长期影响因素表现出的长期规律和周期性特征、短期影响因素造成的局部波动来预测矿井涌水量。

DRN-BiLSTM 模型使用小波分解将矿井涌水量数据分解为趋势数据和细节数据^[14-16];其中使用深度残差网络(Deep Residual Network, DRN)对趋势数据进行预测,该网络改进了经典卷积神经网络存在的梯度消失和训练退化问题^[17];使用双向长短期记忆网络(Bi-directional Long Short-Term Memory, BiLSTM)对细节数据进行预测。双向长短期记忆网络作为一种新的非线性预测方法,相较于单一 LSTM 模型, BiLSTM 模型不依赖环境因子, 可以获取当前涌水量的之前之后的信息, 只需要利用有限样本观测值就能有效预测出矿井涌水量^[18], 最终预测数据为 DRN 模型和 BiLSTM 模型预测结果相结合的数据;一方面避免了因影响因素较多造成的预测精度较低

问题,另一方面也较好的利用了涌水量数据的时序特征,降低了对涌水量数据容量的要求。

1 基础理论

1.1 小波分解与重构

Haar 小波,也叫 db1,用函数调用此小波,将矿井涌水量的数据先与高通做卷积得出高频系数即细节数据,再与低通做卷积得出低频系数即趋势数据^[19-20]。小波重构过程与小波分解过程整个是相反的。其中 Harr 小波是由 Harr 函数衍生而来的,它是支撑域 $t \in [0, 1)$ 范围内的单个矩阵波,即:

$$\phi(t) = \begin{cases} 1 & 0 \leq t \leq 1/2 \\ -1 & 1/2 \leq t < 1 \\ 0 & \text{其他} \end{cases} \quad (1)$$

Harr 小波是一种最简单的正交小波,引入具有正交性的特征函数 $\phi_H(x)$:

$$\phi_H(x) = \begin{cases} 1 & 0 \leq x < 1 \\ 0 & \text{其他} \end{cases} \quad (2)$$

特征函数 $\phi_H(x)$ 就是尺度函数, Harr 小波可用 $\phi_H(x)$ 表示为:

$$\phi(t) = \phi_H\left(\frac{n-1}{2}, \frac{n}{2}\right)(x) - \phi_H\left(\frac{n-1}{2}, \frac{n}{2}\right)(x), \\ n = \pm 1, \pm 2, \dots \quad (3)$$

1.2 深度残差网络

深度残差网络(DRN)是在经典卷积神经网络基础上发展出来的一种深度神经网络模型。DRN 通过引入 1 个“跳跃连接(shortcut connection)”结构有效地缓解了由于卷积层数增加而引起的信息损耗和丢失、识别率降低、梯度消失和训练退化等问题^[21-23]。DRN 的基本残差框架如图 1。




图 1 基本残差框架

Fig.1 Basic residual framework

图 1 中: x 为输入; $H(x)$ 为输出; $F(x)$ 为残差映射函数。其中实际映射换为了拟合残差函数, 得到网络的最优映射^[24]:

$$x_{l+1} = f(y_l) \quad (4)$$

$$y_l = h(x_l) + F(x_l \cdot W_l) \quad (5)$$

式中: W_l 为参数; x_l 为每个残差单元的输入; x_{l+1} 为每个残差单元的输出。

当 $h(x_l) = x_l, f(y_l) = y_l$ 时, 可转化为:

$$x_{l+1} = x_l + F(x_l \cdot W_l) \quad (6)$$

通过递归迭代可以推导出第 L 组残差块的输出 x_L 为:

$$x_L = x_1 + \sum_{i=1}^{L-1} F(x_i \cdot W_i) \quad (7)$$

1.3 LSTM 和 BiLSTM

长短期记忆 (LSTM) 神经网络是建立在标准 RNN 上的一种新型深度机器学习神经网络。LSTM 神经网络依靠内部复杂的门运算和引入细胞态, 有效缓解标准 RNN 的长期依赖问题和因数据序列过长出现的训练参数梯度消失的问题, 实现信息选择性传递^[25]。

相比于 LSTM 只能通过上一时刻信息预测下一时刻信息, BiLSTM 模型则充分学习了数据双向的依赖信息, 有效提高了对输入数据特征获取的效果。模型最终输出是由正向处理输入序列和反向处理输入序列的 2 个 LSTM 网络层对态势值计算后的输出组合而成。

2 DRN-BiLSTM 模型

为充分发挥 DRN 模型和 BiLSTM 模型各自的优势, 将其有机结合, 建立 DRN-BiLSTM 预测模型。具体步骤如下:

1) 使用 db1 小波分析技术对历史数据进行小波变换处理, 将数据分解成为高频数据和低频数据, 其中低频数据为矿井涌水量的趋势数据, 高频数据为矿井涌水量的细节数据, 然后将得到的数据进行归一化处理。

$$x^* = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (8)$$

式中: x^* 为数据归一化后的值; x 为原数据值; $x_{\min}$ 为数据中的最小值; $x_{\max}$ 为数据中的最大值。

2) 将数据集划分为训练数据集和测试数据集, 根据样本集数据的总数, 将 80% 的样本数据作为训练集, 20% 的数据作为测试集; 使用深度残差网络 (DRN) 对归一化处理后的趋势数据进行预测, 使用 BiLSTM 对细节数据进行预测。将上述 2 种模型预测值进行反归一化处理和数据重构, 得到最终预测结果。预测步骤如图 2。

3) 为了验证 DRN-BiLSTM 模型的预测精度, 使




图 2 预测步骤

Fig.2 Prediction step

用单一深度残差网络、双向长短期记忆网络、BP 神经网络和 SARIMA 预测模型作为对比。将平均百分比误差 (MAPE) 和均方根误差 (RMSE) 作为检验模型的评价指标。其中, MAPE 是衡量预测准确性的统计指标, MAPE 值越小, 表示预测精度越高; 反之, 则表示预测精度低。RMSE 是矿井涌水量预测值和实际值之间偏差的平方与样本总数 n 比值的平方根, 均方根误差能够用来衡量矿井涌水量预测值和实际值之间的误差。RMSE 的值越小, 表示预测精度越高, 反之, 则表示预测精度越低。

3 矿井涌水量预测结果

矿井涌水量数据集共分为 3 组: 第 1 组为 A 煤矿 2016 年 1 月至 2022 年 12 月的矿井每月涌水量; 第 2 组为 B 煤矿 2006 年 4 月至 2022 年 8 月矿井每月涌水量; 第 3 组为 C 煤矿 2000 年 1 月至 2019 年 12 月矿井每月涌水量。

在每组数据中, 将前 80% 数据作为实验样本数据, 后 20% 数据作为检验样本数据, 利用深度残差网络模型和双向长短期记忆神经网络模型分别对趋势数据和细节数据进行建模预测^[26-29]。2 种模型的预测值进行数据重构即是该组矿井涌水量的预测结果。以第 3 组数据为例, 第 3 组数据在 DRN-BiLSTM 模型下的预测数据及真实数据见表 1。

由表 1 可知: 第 3 组数据波动频繁, 前后数据相差较大; DRN-BiLSTM 模型对该数据预测相对误差范围在 0.02% 至 6.4% 之间, 平均相对误差为 1.11%, 表明 DRN-BiLSTM 模型的预测效果较好。

将 DRN-BiLSTM 模型的矿井涌水量预测结果与单一的深度残差网络、双向长短期记忆网络、BP 神经网络和 SARIMA 预测模型对矿井涌水量的预测结果进行对比。A 煤矿每月涌水量预测结果如图 3,

表 1 第 3 组数据预测结果

Table 1 Data prediction results of Group 3			
日期	预测数据	真实数据	相对误差/%
2017-09-01	458.407	462	0.778
2017-10-01	459.011	460	0.215
2017-11-01	459.594	458	0.348
2017-12-01	460.136	465	1.046
2018-01-01	471.267	469	0.483
2018-02-01	470.901	470	0.192
2018-03-01	473.240	469	0.904
2018-04-01	472.635	475	0.498
2018-05-01	472.357	467	1.147
2018-06-01	472.449	479	1.368
2018-07-01	462.980	462	0.212
2018-08-01	463.107	465	0.407
2018-09-01	469.717	472	0.484
2018-10-01	469.330	467	0.499
2018-11-01	488.106	485	0.640
⋮	⋮	⋮	⋮
2019-06-01	480.113	478	0.442
2019-07-01	471.670	473	0.281
2019-08-01	471.877	476	0.866
2019-09-01	476.230	481	0.992
2019-10-01	476.290	476	0.060
2019-11-01	473.318	472	0.280
2019-12-01	481.533	479	0.529

B 煤矿每月涌水量预测结果如图 4,C 煤矿每月涌水量预测结果如图 5。不同模型预测结果的评价指标对比见表 2。




图 3 A 煤矿每月涌水量预测结果

Fig.3 Prediction result of monthly mine inflow in A coal mine

由预测结果可知：对于预测不同特点的矿井涌水量,4 种单一模型对其预测效果差距较大,不能完全适用于不同矿井的涌水量预测;DRN-BiLSTM 模型对于处理时间相关有周期性和短期波动特征的数据比其他单一模型有较高的准确度;DRN-BiLSTM




图 4 B 煤矿每月涌水量预测结果

Fig.4 Prediction result of monthly mine inflow in B coal mine




图 5 C 煤矿每月涌水量预测结果

Fig.5 Prediction result of monthly mine inflow in C coal mine

表 2 预测误差对比

Table 2 Prediction error comparison			
数据组	模型	MAPE	RMSE
1	DRN-BiLSTM	0.09	7.776
	DRN	0.469	23.996
	BiLSTM	0.237	20.024
	BP	0.368	21.672
	SARIMA	0.515	38.184
	DRN-BiLSTM	0.024	95.139
2	DRN	—	—
	BiLSTM	0.042	154.518
	BP	0.076	224.12
	SARIMA	0.324	1 079.588
3	DRN-BiLSTM	0.012	8.228
	DRN	—	—
	BiLSTM	0.176	85.004
	BP	0.022	12.116
	SARIMA	0.025	16.061

预测模型通过小波分解,使得趋势数据和细节数据的趋势性和周期性对比于小波分解之前的数据集更为突出和明显,降低了矿井涌水量数据因为数据

波动复杂对模型预测精度的影响,因此其预测结果的精度、稳定性和对预测数据的包容性都有很大的提高。

4 结 语

围绕矿井涌水量预测,引入了深度学习中的DRN模型和BiLSTM模型,结合小波分析,分解所选取的矿井涌水量数据;分别对趋势项数据和细节项数据进行预测,探索了DRN-BiLSTM模型在矿井涌水量预测上的应用。

1)采用小波分析对矿井涌水量数据进行高频和低频分解,分解后的趋势数据和细节数据各自的周期性和趋势性特征更为突出,提高了DRN预测模型和BiLSTM神经网络模型在预测时的准确度。

2)根据预测结果及预测数据集得到,DRN-BiLSTM预测模型具有捕捉长期、短期复杂趋势的优点,相较于其他4种单一预测模型(DRN、BiLSTM、BP和SARIMA)对数据具有更强的包容性,更适合用于有不同特点的矿井涌水量预测。

3)DRN-BiLSTM预测模型在3组矿井涌水量数据预测中的预测稳定性和精度均优于其他4种单一预测模型,该模型在矿井涌水量预测方面具有较好的泛化能力。

参考文献(References):

- [1] 尹尚先,王玉国,李文生.矿井水灾害:原因·对策·出路[J].煤田地质与勘探,2023,51(1):214-221.
YIN Shangxian, WANG Yuguo, LI Wensheng. Cause, countermeasures and solutions of water hazards in coal mines in China[J]. Coal Geology & Exploration, 2023, 51(1): 214-221.
- [2] 尹尚先,连会青,刘德民,等.华北型煤田岩溶陷落柱研究70年:成因·机理·防治[J].煤炭科学技术,2019,47(11):1-29.
YIN Shangxian, LIAN Huiqing, LIU Demin, et al. 70 years of investigation on karst collapse columns in North China Colfield: cause of origin, mechanism and prevention[J]. Coal Science and Technology, 2019, 47(11): 1-29.
- [3] 尹尚先,徐维,尹慧超,等.深部开采底板厚隔水层突水危险性评价方法研究[J].煤炭科学技术,2020,48(1):83-89.
YIN Shangxian, XU Wei, YIN Huichao, et al. Study on risk assessment method of water inrush from thick floor aquifuge in deep mining[J]. Coal Science and Technolo-

gy, 2020, 48(1): 83-89.

- [4] 尹尚先,王屹,尹慧超,等.深部底板奥灰薄灰突水机理及全时空防治技术[J].煤炭学报,2020,45(5):1855-1864.
YIN Shangxian, WANG Yi, YIN Huichao, et al. Mechanism and full-time-space prevention and control technology of water inrush from Ordovician and thin limestone in deep mines[J]. Journal of China Coal Society, 2020, 45(5): 1855-1864.
- [5] 尹尚先,连会青,徐斌,等.深部带压开采:传承与创新[J].煤田地质与勘探,2021,49(1):170-181.
YIN Shangxian, LIAN Huiqing, XU Bin, et al. Deep mining under safe water pressure of aquifer: Inheritance and innovation[J]. Coal Geology & Exploration, 2021, 49(1): 170-181.
- [6] YIN Huichao, WU Qiang, YIN Shangxian, et al. Predicting mine water inrush accidents based on water level anomalies of borehole groups using Long short-term memory and Isolation forest[J]. Journal of Hydrology, 2023, 616: 128813.
- [7] 李燕,孙亚军,徐智敏,等.影响矿井安全的多含水层矿井涌水构成分析[J].采矿与安全工程学报,2010,27(3):433-437.
LI Yan, SUN Yajun, XU Zhimin, et al. Analysis of composition of mine inflow from complicated multiaquifer affecting safety production in coal mines[J]. Journal of Mining & Safety Engineering, 2010, 27(3): 433-437.
- [8] 朱赛君,姜春露,毕波,等.基于组合权-改进灰色关联度理论的矿井突水水源识别[J].煤炭科学技术,2022,50(4):165-172.
ZHU Saijun, JIANG Chunlu, BI Bo, et al. Identification of mine water inrush source based on combination weight-theory of improved grey relational degree[J]. Coal Science and Technology, 2022, 50(4): 165-172.
- [9] 徐小峰,余乐安,林姿汝,等.基于特征融合的生鲜商品短期销量组合预测[J].管理科学学报,2022,25(12):102-123.
XU Xiaofeng, YU Lean, LIN Zirui, et al. Combination forecasting of short-term sales for fresh products based on feature fusion[J]. Journal of Management Sciences in China, 2022, 25(12): 102-123.
- [10] 刘晓丹,潘国营.基于三种时间序列模型的矿井涌水量预测[J].矿业安全与环保,2022,49(2):91-95.
LIU Xiaodan, PAN Guoying. Prediction of mine water inflow based on three time series models[J]. Mining Safety & Environmental Protection, 2022, 49(2): 91-95.
- [11] 刘浪,陈建宏,杨珊,等.基于灰色关联分析的PSO-

- BP算法预测矿震危险性[J].中南大学学报(自然科学版), 2011, 42(8): 2400-2405.
- LIU Lang, CHEN Jianhong, YANG Shan, et al. Application of PSO-BP algorithm in risk prediction of mine earthquake based on grey correlation analysis[J]. Journal of Central South University(Science and Technology), 2011, 42(8): 2400-2405.
- [12] 程志友, 汪德胜. 基于机器学习与疫情关联特征的短期负荷预测[J]. 电力系统保护与控制, 2022, 50(23): 1-8.
- CHENG Zhiyou, WANG Desheng. Short-term load forecasting based on machine learning and epidemic association features[J]. Power System Protection and Control, 2022, 50(23): 1-8.
- [13] 欧阳添, 闪锟, 周博天, 等. 基于LSTM网络的在线藻类时序数据预测研究: 以三峡水库为例[J]. 湖泊科学, 2021, 33(4): 1031-1042.
- OUYANG Tian, SHAN Kun, ZHOU Botian, et al. Research on the online forecasting of algal kinetics based on time-series data and LSTM neural network: Taking Three Gorges Reservoir as an example[J]. Journal of Lake Sciences, 2021, 33(4): 1031-1042.
- [14] 徐精诚, 连增增, 董佳琪, 等. 基于小波包分解重构算法的北斗抗多路径误差[J]. 科学技术与工程, 2022, 22(35): 15477-15484.
- XU Jingcheng, LIAN Zengzeng, DONG Jiaqi, et al. Anti-multipath error of BDS Based on WPT decomposition and reconstruction algorithm[J]. Science Technology and Engineering, 2022, 22(35): 15477-15484.
- [15] 刘译文, 赵一帆, 张兰兰, 等. 基于小波包分解的长短期记忆网络光伏功率预测[J]. 计算机与数字工程, 2022, 50(9): 2114-2118.
- LIU Yiwen, ZHAO Yifan, ZHANG Lanlan, et al. Photovoltaic power forecasting based on wavelet packet decomposition of long short-term memory network[J]. Computer & Digital Engineering, 2022, 50(9): 2114-2118.
- [16] 李禄德, 崔东文. 基于小波包分解与相空间重构的SSA-ELM水文时间序列预报模型[J]. 人民珠江, 2022, 43(8): 100-108.
- LI Lude, CUI Dongwen. SSA-ELM hydrological time series forecast model based on wavelet packet decomposition and phase space reconstruction[J]. Pearl River, 2022, 43(8): 100-108.
- [17] 陈倩倩, 林天然. 基于DRN-BiGRU模型的滚动轴承剩余寿命预测[J]. 机电工程, 2022, 39(11): 1575-1581.
- CHEN Qianqian, LIN Tianran. Remaining useful life prediction of rolling bearings based on DRN-BiGRU algorithm[J]. Journal of Mechanical & Electrical Engineering, 2022, 39(11): 1575-1581.
- [18] PAN Shi-Yuan, LIAO Qi, LIANG Yong-Tu. Multi-variable sales prediction for filling stations via GA improved BiLSTM[J]. Petroleum Science, 2022, 19(5): 2483-2496.
- [19] 周星, 张志军, 李英, 等. 基于小波包分解重构的超压预测技术及其应用[J]. 物探化探计算技术, 2021, 43(4): 429-434.
- ZHOU Xing, ZHANG Zhijun, LI Ying, et al. The application of overpressure prediction based on wavelet packet decomposition and reconstruction[J]. Computing Techniques for Geophysical and Geochemical Exploration, 2021, 43(4): 429-434.
- [20] 冯晶晶, 陈文利, 董丹凤. 基于小波变换的图像信号分解与重构[J]. 电子设计工程, 2021, 29(16): 177-180.
- FENG Jingjing, CHEN Wenli, DONG Danfeng. Image signal decomposition and reconstruction based on wavelets[J]. Electronic Design Engineering, 2021, 29(16): 177-180.
- [21] 蒋明峰, 鲁慧, 李杨, 等. 基于金字塔卷积结构的深度残差网络心电信号分类方法研究[J]. 生物医学工程学杂志, 2020, 37(4): 692-698.
- JIANG Mingfeng, LU Yi, LI Yang, et al. Research on electrocardiogram classification using deep residual network with pyramid convolution structure[J]. Journal of Biomedical Engineering, 2020, 37(4): 692-698.
- [22] 孟安波, 许炫淙, 陈嘉铭, 等. 基于强化学习和组合式深度学习模型的超短期光伏功率预测[J]. 电网技术, 2021, 45(12): 4721-4728.
- MENG Anbo, XU Xuancong, CHEN Jiaming, et al. Ultra short term photovoltaic power prediction based on reinforcement learning and combined deep learning model[J]. Power System Technology, 2021, 45(12): 4721-4728.
- [23] 王彦博, 吴俊勇, 季佳伸, 等. 基于深度残差收缩网络的电力系统暂态频率安全集成评估[J]. 电网技术, 2023, 47(2): 482-494.
- WANG Yanbo, WU Junyong, JI Jiashen, et al. Integrated assessment of power system transient frequency security based on deep residual shrinkage network[J]. Power System Technology, 2023, 47(2): 482-494.
- [24] 季佳伸, 吴俊勇, 王彦博, 等. 基于深度残差网络的电力系统暂态电压稳定评估[J]. 电网技术, 2022, 46(7): 2500-2511.
- JI Jiashen, WU Junyong, WANG Yanbo, et al. Power

- system transient voltage stability assessment based on deep residual network[J]. Power System Technology, 2022, 46(7): 2500–2511.
- [25] 尹佳,陈翔,董曼,等.基于小波分解-长短期记忆网络预测模型的酱卤肉制品安全预测分析[J].食品科学,2022,43(3):121–128.
- YIN Jia, CHEN Xiang, DONG Man, et al. Prediction and analysis of marinated meat product safety risk using wavelet transform-long short-term memory prediction model[J]. Food Science, 2022, 43(3): 121–128.
- [26] 欧阳福莲,王俊,周杭霞.基于改进迁移学习和多尺度 CNN-BiLSTM-Attention 的短期电力负荷预测方法[J].电力系统保护与控制,2023,51(2):132–140.
- OUYANG Fulian, WANG Jun, ZHOU Hangxia. Short-term power load forecasting method based on improved hierarchical transfer learning and multi-scale CNN-BiLSTM-Attention[J]. Power System Protection and Control, 2023, 51(2): 132–140.
- [27] 魏佳恒,郭惠勇.基于贝叶斯优化 BiLSTM 模型的输电塔损伤识别[J].振动与冲击,2023,42(1):238–248.
- WEI Jiaheng, GUO Huiyong. Damage identification of transmission tower based on BO-BiLSTM model[J]. Journal of Vibration and Shock, 2023, 42(1): 238–248.
- [28] 李小平,白超,石森.基于 CNN-BiLSTM 模型的机车变压器油中溶解气体浓度预测方法[J].铁道学报,2022,44(5):42–48.
- LI Xiaoping, BAI Chao, SHI Sen. Prediction method of dissolved gas concentration in transformer oil based on CNN-BiLSTM model[J]. Journal of the China Railway Society, 2022, 44(5): 42–48.
- [29] 任建吉,位慧慧,邹卓霖,等.基于 CNN-BiLSTM-Attention 的超短期电力负荷预测[J].电力系统保护与控制,2022,50(8):108–116.
- REN Jianji, WEI Huihui, ZOU Zhuolin, et al. Ultra-short-term power load forecasting based on CNN-BiLSTM-Attention[J]. Power System Protection and Control, 2022, 50(8): 108–116.