



移动阅读

刘慧, 刘桂芹, 宁殿艳, 等. 基于 VMD-DBN 的矿井涌水量预测方法[J]. 煤田地质与勘探, 2023, 51(6): 13–21. doi: 10.12363/issn.1001-1986.22.11.0869

LIU Hui, LIU Guiqin, NING Dianyan, et al. Mine water inrush prediction method based on VMD-DBN model[J]. Coal Geology & Exploration, 2023, 51(6): 13–21. doi: 10.12363/issn.1001-1986.22.11.0869

基于 VMD-DBN 的矿井涌水量预测方法

刘 慧^{1,2,3}, 刘桂芹¹, 宁殿艳^{1,2}, 樊 娟^{1,2}, 陈卫明³

(1. 中煤科工西安研究院(集团)有限公司, 陕西 西安 710077; 2. 陕西省煤矿水害防治技术重点实验室, 陕西 西安 710077; 3. 中国地质大学(武汉) 工程学院, 湖北 武汉 430074)

摘要: 在煤矿采掘过程中, 因矿井涌(突)水造成的人员和财产损失极为严重。为预防涌(突)水灾害事故的发生, 掌握涌水量的发展变化规律, 开展涌水预测预报尤其是矿井涌水量的精准预计尤为重要, 是矿井水害防治中一项重要的工作任务。为提高矿井涌水量的预测准确性, 针对随时间无明显变化规律的涌水量序列, 提出了变分模态分解(Variational Mode Decomposition, VMD)和深度置信网络(Deep Belief Network, DBN)相结合的高效时间序列预测模型。首先通过 VMD 模态分解技术对原始数据进行去噪, 将原始矿井涌水量时间序列分解为若干个本征模态函数(Intrinsic Mode Function, IMF)分量, 使各个 IMF 分量都具有原始时间序列在不同时间尺度下的统计学特征量, 降低了原始时间序列的强震荡性和非稳定性。其次针对每个 IMF 分量, 分别建立各自的 DBN 模型进行训练学习, 进而建立起相应的预测网络模型。最后融合各分量预测值得到最终结果。结果显示, VMD-DBN 的 E_{MA} 、 E_{MAP} 、 E_{RMS} 和 R^2 分别为 9.23、0.76%、11.55 和 0.97, 通过与 GA-BP、LSTM、VMD-LSTM、RBM、VMD-RBM 和 DBN 模型的预测值进行对比发现, VMD-DBN 模型进行矿井涌水量预测具有更高的预测精度。VMD-DBN 模型对于涌水量随时间无明显变化规律、且具有较强震荡性和非平稳的工况具有相对明显的优势, 丰富了矿井涌水量预测方法, 为智慧矿山的安全监测提供一种新型的技术手段, 具有一定的理论价值和现实意义。

关键词: 矿井涌水量预测; 变分模态分解 VMD; 深度学习; 深度置信网络 DBN; 时间序列

中图分类号: TD742 **文献标志码:** A **文章编号:** 1001-1986(2023)06-0013-09

Mine water inrush prediction method based on VMD-DBN model

LIU Hui^{1,2,3}, LIU Guiqin¹, NING Dianyan^{1,2}, FAN Juan^{1,2}, CHEN Weiming³

(1. CCTEG Xi'an Research Institute (Group) Co., Ltd., Xi'an 710077, China; 2. Shaanxi Key Laboratory of Prevention and Control Technology for Coal Mine Water Hazard, Xi'an 710077, China; 3. Faculty of Engineering, China University of Geosciences (Wuhan), Wuhan 430074, China)

Abstract: In the process of coal mining, the loss of people and property caused by mine water inrush is extremely serious. To prevent the occurrence of water inrush accidents and grasp the law of change of water inrush, the water inrush prediction and forecasting, especially the accurate estimation of mine water inrush, is very important, which is also an important task in the prevention and control of mine water damage. To increase the prediction accuracy of mine water inrush, an efficient time series prediction model combining Variational Mode Decomposition (VMD) and Deep Belief Network (DBN) was proposed for the series of water inrush with no obvious change with time. Firstly, the original data were initially denoised by VMD to break up the original mine water inrush time series into multiple Intrinsic Mode Function (IMF) components, so that each IMF component has the statistical characteristic quantity of the original time series at different time scales, which reduces the strong oscillation and instability of the original time series. Secondly,

收稿日期: 2022-11-15; 修回日期: 2023-05-03

基金项目: 陕西省煤矿水害防治技术重点实验室开放基金项目(2021SKMS07)

第一作者: 刘慧, 1998 年生, 男, 河南周口人, 硕士研究生, 从事多源数据融合的研究工作. E-mail: 1076352356@qq.com

通信作者: 陈卫明, 1981 年生, 男, 湖北汉川人, 博士, 副教授, 从事态势智能感知的研究工作. E-mail: chenweiming@cug.edu.cn

DBN model was established separately to each IMF component for training and learning, and then the corresponding prediction network model was built. Finally, the predicted values of each component were fused as a result. The results show that the E_{MA} , E_{MAP} , E_{RMS} and R^2 of VMD-DBN are 9.23, 0.76%, 11.55 and 0.97 respectively, which are compared with the predicted values of GA-BP, LSTM, VMD-LSTM, RBM, VMD-RBM, and DBN models, finding that the mine water inrush prediction with VMD-DBN model has a higher accuracy. Therefore, the VMD-DBN model has relatively obvious advantages under the conditions that the water inrush has no obvious change law over time but with strong oscillation and instability, thus enriching the mine water inrush prediction methods, providing a new technical means for the intelligent mine safety monitoring, with some theoretical value and practical significance.

Keywords: mine water inrush prediction; Variational Mode Decomposition (VMD); deep learning; Deep Belief Network (DBN); time series

矿井水害防治是保障矿井安全生产的重要一环,从矿井的设计阶段到整个生产过程中,涌水量都是矿井水害防治工作中重要的基础数据^[1]。范立民等^[2]总结其 20 年左右的实际工作经验,发现榆神矿区矿井涌水量的实际值一般为预测值的 3~5 倍。虎维岳^[3]在统计分析大量资料后,提出矿井开采后的涌水量实际值与勘探阶段的预测值相比,80% 的矿井误差超过 50%。杨建等^[4]针对鄂尔多斯盆地北部煤炭区深埋某工作面的分析,指出导水裂隙带的发育变化,导致工作面回采初期的涌水量预测值偏大,中后期较为接近。表明当前矿井涌水量预测值与实际值存在不同程度的误差,涌水量预测的精准度不高。而矿井涌水量的准确预测对于水害的发生具有预见作用,如果预测值偏小,可能使人疏于防备,导致危险的发生,所以涌水量的准确预测对于煤矿安全生产具有重要作用。

传统的预测方法大致分为两大类,一是确定性的数学模型方法,二是非确定性(随机)的统计分析方法^[5],其中确定性方法有解析法、数值模拟法和水均衡法等。马青山等^[6]针对内蒙古巴彦淖尔井田涌水量进行预测,比较得出数值法比解析法具有更高的预测精度。戴岩柯等^[7]通过实验得出,简单水文地质条件下水均衡法更适合,且时间短,成本低。确定性方法的公式一般根据地下水动力学、水力学等理论建立,模型结构较为简单,计算便利。但有时因为地质情况复杂,人为测量误差等,都可能造成地质参数的不准确,使最终的预测结果与真实值出现较大的偏差,通用性较差。非确定性方法有水文地质比拟法、相关分析法、模糊数学模型和灰色系统等。张子祥^[8]在甘肃核桃峪煤矿的研究中,比较大井法、水平廊道法和比拟法后得出比拟法相对更优的结论。王家乐等^[9]使用 SPSS 软件并利用相关系数法得出某矿井涌水量为 145.85 m³/h。苏培东等^[10]利用模糊数学模型预测得到的平均涌水量与实际涌水量的误差很小,满足了工程预测的精度要求。非确定性方法以统计学为基础,通过统计分析工况相似的矿井进行预测。资料越翔实丰富,非确定性方法

的预测效果越准确。相较于确定性方法,非确定性方法虽然提高了精度,但对于一些地质条件、生产条件不同且历史数据少的矿井,很难进行统计预测,也缺乏通用性。

随着现代传感器技术的发展,传感器也逐渐应用于矿井涌水量预测领域。传感器的测量值相较于传统人工测量更为精确,但又因为传感器储存了大量的时间序列数据,人工进行建模预测并不现实,由此出现了处理大量数据的传感器时间序列预测方法。目前传感器时间序列预测^[11]主要有统计学、机器学习和深度学习三大类。统计学主要包括自回归移动平均(AutoRegressive Moving Average, ARMA)预测模型和改进的差分自回归移动平均(AutoRegressive Integrated Moving Average, ARIMA)预测模型等。其中,ARMA 在平稳时间序列预测领域应用较为广泛,ARIMA 则应用于将原始数据差分为平稳的时间序列预测。齐晓峰等^[12]将非平稳分量差分化处理,使其趋于平稳后,构建 ARMA 预测模型对矿井涌水量进行预测。安欣等^[13]建立 ARIMA(1, 1, 1)预测模型,实现对矿井涌水量的短期预测。对于此类统计学模型,优点是建模简单,运算高效;但对于非平稳序列,需要先进行差分处理,不具有通用性。机器学习主要有反向传播(Back Propagation, BP)神经网络、支持向量机(Support Vector Machine, SVM)回归和随机森林(Random Forest, RF)模型等。孟璐^[14]首先使用主成分分析算法优选出影响涌水量的主要因子,然后建立 BP 神经网络模型进行预测,得到的预测结果精度较高。乔美英等^[15]使用遗传算法(Genetic Algorithm, GA)自动寻优功能设置 SVM 的最佳参数,提高了矿井涌水量预测精度。黄永刚等^[16]利用随机森林(Random Forest, RF)算法,训练 20 组矿井涌水量数据,再通过训练好的模型预测另外 3 组矿井涌水量数据,结果表明 RF 预测比 BP 预测更易跳出局部极值点,同时 RF 的操作简单,收敛速度更快。机器学习模型相比统计学模型,针对非线性和非平稳时间序列的预测更准确。但传统机器学习的预测

值仅考虑前一时刻的输入,并没有考虑完整的历史输入数据,使得精度并不能完全满足某些工程项目的高精度要求。深度学习主要分为循环神经网络类,包括长短期记忆(Long Short-Term Memory, LSTM)和门控循环单元(Gate Recurrent Unit, GRU);卷积神经网络;基于 Attention(注意力机制)的 Transformer 类模型;以及其他种类的 Seq2Seq,深度置信网络(Deep Belief Network, DBN)等模型。Li Zhanli 等^[17]使用注意力机制与 GRU 结合的模型用于矿井明渠水流的实时预测,而明渠流量的连续预测可以反映矿井涌水量的实时变化情况^[18]。降海荣等^[19]使用 DBN 间接预测矿井涌水量比直接预测精度更高,运行时间更短。深度学习相较于机器学习,擅长于大量数据集的学习,更适用于煤矿中大量使用的高精度传感器的海量数据需求。

基于以上分析,提出一种基于深度学习的矿井涌水量预测模型。首先,通过变分模态分解(Variational Mode Decomposition, VMD)算法将具有强烈震荡特性的原始涌水量数据分解为指定数量的本征模态函数(Intrinsic Mode Function, IMF)分量,使其平稳化。然后通过 DBN 进行特征提取,学习各子分量的内在规律,通过训练好的模型去预测,再将所有子分量的预测结果融合为最终的预测结果。最后将基于遗传算法的 BP 神经网络优化算法(GA-BP)、LSTM、VMD-LSTM、RBM、VMD-RBM、DBN 和 VMD-DBN 算法与真实值进行对比,以期评价所提出的 VMD-DBN 预测模型的预测效果。

1 基于 VMD-DBN 的预测模型

1.1 VMD 算法原理

20 世纪末, N. E. Huang 等^[20]提出经验模态分解(Empirical Mode Decomposition, EMD)算法,其特点是将信号递归分解,但可能存在模态混叠和端点效应。为降低对噪声的敏感性,增强分解模型的稳健性, K. Dragomiretskiy 等^[21]提出一种自适应信号处理方式的 VMD 算法,使用完全非递归的方法,现已广泛应用于信号处理等领域。VMD 信号处理方法能够实现将复杂时间序列分解为给定数量的本征模态函数,而 EMD 不可指定分解个数。同时分解后的分量具备原数据在相应时间尺度上的所有特征。

设原始输入信号为 $f(t)$, t 为时间变量;模态函数为 u_k , $k = 1, 2, \dots, K$, K 为模态分量的总个数,则 VMD 构建的具体过程如下。

(1) 通过 Hilbert 变换,将各个模态分量 $u_k(t)$ 的频谱传送到相应的基带。然后将其与一个指标对应的估计中心频率 ω_k 对应,最后根据解调信号梯度的平方范

数估计该带宽,得到约束变分问题为:

$$\begin{cases} \min_{\{u_k\}, \{\omega_k\}} \left\{ \sum_{k=1}^K \left\| \partial_t \left[\left(\delta(t) + \frac{j}{\pi t} \right) * u_k(t) \right] \exp(-j\omega_k t) \right\|_2^2 \right\} \\ \text{s.t.} \sum_{k=1}^K u_k(t) = f(t) \end{cases} \quad (1)$$

式中: ∂_t 为求解函数对时间 t 的偏导数; $\delta(t)$ 为狄拉克分布; j 为虚数单位; $*$ 为卷积计算; $\|\cdot\|_2^2$ 中的上标和下标分别为平方和 L2 范数。

(2) 采用二次惩罚因子 α 和拉格朗日乘法算子 $\lambda(t)$, 将式(1)的约束性变分问题转变为非约束性变分问题:

$$\begin{aligned} \mathcal{L}(\{u_k\}, \{\omega_k\}, \lambda) = & \alpha \sum_{k=1}^K \left\| \partial_t \left[\left(\delta(t) + \frac{j}{\pi t} \right) * u_k(t) \right] \exp(-j\omega_k t) \right\|_2^2 + \\ & \left\| f(t) - \sum_{k=1}^K u_k(t) \right\|_2^2 + \left\langle \lambda(t), f(t) - \sum_{k=1}^K u_k(t) \right\rangle \end{aligned} \quad (2)$$

(3) 更新模态分量 u_k , 即:

$$\hat{u}_k^{m+1}(\omega) = \frac{\hat{f}(\omega) - \sum_{i \neq k} \hat{u}_i^m(\omega) + \frac{\hat{\lambda}^m(\omega)}{2}}{1 + 2\alpha(\omega - \omega_k^m)^2} \quad (3)$$

式中: $\mathcal{L}$ 为拉格朗日符号; i 和 m 为不同参数取得的任意值; ω 为信号从时间域向 t 频率域变换的符号; $\hat{u}$ 、 $\hat{f}(\omega)$ 和 $\hat{\lambda}(\omega)$ 为傅里叶变换后的 u 、 $f(\omega)$ 和 $\lambda(\omega)$ 。

(4) 以式(3)的方式更新 ω_k^{m+1} 与 λ_k^{m+1} , 即:

$$\omega_k^{m+1} = \frac{\int_0^\infty \omega |\hat{u}_k^{m+1}(\omega)|^2 d\omega}{\int_0^\infty |\hat{u}_k^{m+1}(\omega)|^2 d\omega} \quad (4)$$

$$\hat{\lambda}^{m+1}(\omega) = \hat{\lambda}^m(\omega) + \tau \left[\hat{f}(\omega) - \sum_k \hat{u}_k^{m+1}(\omega) \right] \quad (5)$$

式中: τ 为噪声容限的参数。

(5) 直到满足收敛条件(下式)时,停止循环迭代。

$$\frac{\sum_{k=1}^K \|\hat{u}_k^{m+1} - \hat{u}_k^m\|_2^2}{\|\hat{u}_k^m\|_2^2} < \varepsilon \quad (6)$$

式中: ε 为收敛准则限度。

1.2 DBN 算法原理

1.2.1 RBM 算法

玻尔兹曼机(Boltzmann Machines, BM)是没有输出层的无向神经网络,结构如图1所示。BM 包含可见层(V)和隐藏层(H)2层结构。为降低 BM 网络结构的复杂度,出现了受限玻尔兹曼机(Restricted Boltzmann Machine, RBM),其网络结构如图2所示,是无监督拟合训练数据分布的一种方法。将图2与图1对比可知,

RBM 取消了 BM 可见层和隐藏层的层内连接,层与层之间是全连接,层内部每个节点互相独立。其中, $\mathbf{v}$ 和 $\mathbf{h}$ 分别为可见层节点和隐藏层节点的状态向量 v_1, v_2, v_3, v_4 为可见层 V 的神经元; h_1, h_2, h_3 为隐藏层 H 中的神经元; 参数 $\mathbf{W}$ 为两层节点的连接权值矩阵, 给定训练数据通过 $\mathbf{W}$ 将 $\mathbf{v}$ 和 $\mathbf{h}$ 相互转换。




图 1 BM 结构
Fig.1 BM structure




图 2 RBM 结构
Fig.2 RBM structure

1.2.2 DBN 算法

多个 RBM 堆叠成深度玻尔兹曼机(Deep Boltzmann Machine, DBM), 前一个 RBM 的隐藏层作为下一个 RBM 的可见层, 若在靠近可见层的部分使用有向图网络模型, 则变为 DBN。DBN 的结构一般由若干 RBM 层和一层 BP 组成, 图 3 为一个两层 RBM 和




图 3 DBN 结构
Fig.3 DBN structure

层 BP 的 DBN 神经网络模型结构图。DBN 训练过程主要分为两大部分: 第一步如图中向上箭头, RBM 逐层预训练^[22], 每次训练时, 将下层的 RBM 训练好后再训练上层的 RBM, 每次训练一层, 直至最后; 第二步如图中向下箭头, 为多层 BP 神经网络, 属于微调训练。与传统的深度学习算法对比, DBN 通过较短的预训练过程, 减少整体的学习时间^[23], 进而提高整个模型的训练效率。

1.3 VMD-DBN 预测模型构建

VMD-DBN 预测模型流程如图 4 所示, 主要包括: 数据的预处理、VMD 模态分解和 DBN 神经网络预测三大模块。




图 4 基于 VMD-DBN 预测模型流程
Fig.4 Flow chart of VMD-DBN based prediction model

基于 VMD-DBN 的矿井涌水量预测模型具体步骤如下。

(1) 数据预处理: 主要包括异常值检验与处理、缺失值的处理和平稳性检验。

(2) 归一化: 将时间序列数据进行(0, 1)内的归一化处理, 使模型训练效率更高, 提高梯度下降求最优解的速度。

(3) VMD 模态分解: 通过 VMD 将归一化后的时间序列分解为有限数量的子信号(即本征模态函数

IMF), 这些子信号包含输入信号在不同时刻的特征信息。此步骤可以有效地处理非平稳、非线性的信号, 为提高预测精度提供了可能。

(4) DBN 预测并融合: 针对不同的 IMF 序列, 分别通过 DBN 进行训练, 充分挖掘不同 IMF 序列的规律特性。然后通过训练后的各个模型分别进行预测, 最后将各预测值融合为最终的预测结果。

(5) 反归一化: 将测试集的预测结果反归一化, 以便比较不同模型的预测效果。

(6) 评价指标: 使用评价指标对模型准确性和拟合程度进行分析, 得出最优模型。

2 矿井涌水量的预处理

实验数据来源于国内某矿山 2020 年的涌水量监测数据, 共 358 个数据, 组成涌水量数据集。

2.1 异常值检验与处理

对于时间序列, 可能会存在某些明显偏离正常数据的点, 其值即为异常值。水文观测数据一般时间跨度较长, 数据集较大, 一般采用较为方便简单的拉依达准则(3σ)剔除这些异常值^[24]。具体计算过程如下:

设原始数据为 $\{x_1, x_2, \dots, x_d\}$, d 为数据个数, 其平均值记为 $\bar{x}$ 。首先, 计算 x_i 的标准方差, 记为 σ 。其次, 计算 x_i 与 $\bar{x}$ 的绝对差, 当其大于 3σ 时, 则认为是异常值。标准方差和绝对差的计算公式如下:

$$\sigma = \sqrt{\frac{\sum_{i=1}^d (x_i - \bar{x})^2}{d-1}} \quad (7)$$

$$|x_i - \bar{x}| > 3\sigma \quad (8)$$

对于异常值, 采用删除的方法去除。

2.2 缺失值的处理

由 2.1 节的方法去除的异常值即成为缺失值, 与原始数据中的缺失值一同构成全部的缺失值集合。对于缺失值采用线性插值进行处理, 具体计算过程如下:

设已知两时刻 t_0 和 t_2 上的原始值分别为 $f(t_0)$ 和 $f(t_2)$, 求区间 $[t_0, t_2]$ 上某一点 t_1 插值后的 $f(t_1)$ 。可得公式:

$$\frac{f(t_2) - f(t_0)}{t_2 - t_0} = \frac{f(t_1) - f(t_0)}{t_1 - t_0} \quad (9)$$

由式(9)可进一步变换得:

$$f(t_1) = f(t_0) + (t_1 - t_0) \frac{f(t_2) - f(t_0)}{t_2 - t_0} \quad (10)$$

2.3 平稳性分析

传统单一模型对非平稳序列的预测较为困难, 因此可先对其进行平稳性分析, 来决定使用单一模型或者组合模型, 以期达到更好的预测效果。当时间序列为非平稳序列时, 可采用与模态分解算法组合的模型,

消除各个时间尺度特征之间产生的相互影响, 组合模型通过对每个模态进行单独有效的预测, 进而达到提升整体预测精度的任务要求^[25]。

增广迪基-富勒(Augmented Dickey-Fuller, ADF)检验^[26]可以分析数据的平稳性。ADF 检验的原假设是存在单位根, 只要统计量 $T(\text{ADF 统计量})$ 小于 1% 水平下的临界值, 即认为是极其显著(99% 的可能性)地拒绝原假设, 即不存在单位根, 也即序列平稳。若概率 $P < 0.05$, 即不存在单位根, 也即序列平稳。

插值后的涌水量进行 ADF 单位根检验。ADF 计算结果见表 1。其中 $T = -1.72 > -2.57$, 即 T 同时大于 1%、5%、10% 置信区间下的统计量值, 所以不能拒绝原假设; 同时 $P = 0.42 > 0.05$, 也不能拒绝原假设。综上所述, 不能拒绝原假设, 存在单位根, 也即序列不平稳。

表 1 ADF 结果
Table 1 ADF result

T	P	1%临界值	5%临界值	10%临界值
-1.72	0.42	-3.45	-2.87	-2.57

3 实验验证

本实验基于 Python3.9 解释器、PyTorch1.12.1 框架和 CUDA11.6 环境。

3.1 基于 VMD 分解的数据平稳化处理

经过预处理得到的涌水量时间序列如图 5 所示, 为非线性的时间序列。涌水量随时间并无明显的规律, 且变化具有强烈的震荡性, 因为瞬时涌水量随时间变化呈现一种忽大忽小急剧变化的趋势, 所以属于脉冲式涌水类型^[27], 普通模型难以进行准确的预测。涌水量的大小与该地的降水量有关^[28], 降水量又有明显的季节特性。近年来, V. Vanitha 等^[29]利用 VMD 对时间序列进行模态分解, 使数据更加规则, 提高了预测的准确性。所以为将涌水量时间序列的内在规律充分显露出来, 同时降低时间序列的噪声, 本文采用 VMD 模态分解对涌水量数据进行平稳化处理。

经过多次实验, 得出分解个数 $K=6$ 时的预测效果




图 5 涌水量时间序列

Fig.5 Time series of water inrush

最好,故分解为 6 个 IMF 子序列。将预处理后的涌水量时间序列归一化,将数据收敛到(0, 1), 记为 Original。然后通过 VMD 分解为 6 个子序列如图 6 所示,使原本单一无规律的时间序列挖掘出多个具有特征

的子序列。通过观察看出,每个子序列的变化都不尽相同。 IMF_1 为低频子分量,代表着原始序列的整体变化趋势; IMF_2 、 IMF_3 为中频子分量; IMF_4 、 IMF_5 和 IMF_6 为高频子分量。




图 6 VMD 模态分解子序列

Fig.6 VMD modal decomposition sub-series

3.2 基于 VMD-DBN 模型的矿井涌水量预测

经过 VMD 分解后的子序列,分别划分为 80% 的训练集及 20% 的测试集。通过 DBN 对子序列进行训练,然后预测未来值。最终的子序列预测结果如图 7

所示,各个时间子序列的预测都较为准确。通过 VMD 将原本需要预测具有强烈震荡的涌水量时间序列变为较为平稳的 6 个子分量的预测过程,用于提高预测精度。




图 7 VMD 模态分解子序列预测

Fig.7 VMD modal decomposition sub-series prediction

GA-BP、LSTM、VMD-LSTM、RBM、VMD-RBM、DBN 和 VMD-DBN 模型的预测结果如图 8 所示。通过观察,RBM、DBN、VMD-LSTM、VMD-RBM 和 VMD-DBN 都可以预测出时间序列的整体变化趋势;GA-BP 的多数点预测比较准确,但个别点误差较大,比如 $t=293$ d 处 GA-BP 预测值比真实值大约 $200 \text{ m}^3/\text{h}$,分析此处可能是因为原始时间序列不平稳,震荡剧烈,

GA-BP 模型无法学习到完整的非线性参数,导致预测趋势与实际趋势相反。若现实生产中,某一天的预测值比真实值偏大时,可能导致生产停滞,降低矿区的生产能力,但若这一天的预测值比真实值偏小时,可能使安全人员对于矿井水害的防范措施不充分,造成安全隐患,进而导致安全事故的发生。在预测区间内,LSTM 相比于其他模型的预测效果最差。因为涌水量

数据的非稳定性, 所以 LSTM 很难学习其中的各种变化规律, 导致整条曲线趋于平缓。离真实值偏差大, 仅预测出部分趋势, 对于突变点、细节部分的预测效果很差或者没有预测。又比如在 $t=[338, 342]$, VMD-DBN

较其他模型更为贴近真实值, 具有更强的跟随性。综上, VMD-DBN 的整体趋势正确, 且对一些突变点的预测更为准确, 因此可以作为一种高效精准的预测工具对矿山涌水量变化进行科学合理的预测。




图8 各模型预测对比结果

Fig.8 Comparison results of predictions by models

3.3 评价指标

本文采用平均绝对误差(E_{MA})、平均绝对百分比误差(E_{MAP})、均方根误差(E_{RMS})和拟合度 R^2 这4个评价指标对模型预测准确性进行分析。对于 E_{MA} 、 E_{MAP} 和 E_{RMS} 3个指标来判断真实值与预测值的误差, 值越小则代表预测精度越高。同时用 R^2 指标来评估模型的拟合程度, $R^2 \rightarrow 1$ 时, 代表模型的拟合性越好, 反之, 若 $R^2 \rightarrow 0$, 则表明模型的数据拟合度越差。各预测指标计算公式如下:

$$E_{MA}(\hat{y}_i, y_i) = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i| \quad (11)$$

$$E_{MAP}(\hat{y}_i, y_i) = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{\hat{y}_i - y_i}{y_i} \right| \quad (12)$$

$$E_{RMS}(\hat{y}_i, y_i) = \sqrt{\frac{\sum_{i=1}^n (\hat{y}_i - y_i)^2}{n}} \quad (13)$$

$$R^2(\hat{y}_i, y_i) = 1 - \frac{\sum_{i=1}^n (\hat{y}_i - y_i)^2}{\sum_{i=1}^n (\bar{y} - y_i)^2} \quad (14)$$

式中: y_i 为真实值; $\hat{y}_i$ 为预测值; $\bar{y} = \frac{1}{n} \sum_{i=1}^n \hat{y}_i$; $i = 1, 2, \dots, n$; n 为预测值的个数。

下面对各个模型的准确性进行定量分析, 各模型预测评价指标如图9所示。通过4个评价指标的值可以定量看出 LSTM 的预测准确性最差, 这与前文论述

的单一 LSTM 模型不适合预测具有非稳定性和非线性特点的涌水量时间序列预测任务相符合。GA-BP 个别点预测效果较差, 导致整体的误差也较大, 稳定性不高。

通过对 LSTM 和 VMD-LSTM、RBM 和 VMD-RBM、DBN 和 VMD-DBN 3组消融实验, 可知加入 VMD 模块后, 评价指标 E_{MA} 分别降低了 68.78%、21.02%、14.62%; E_{MAP} 分别降低了 68.72%、22.64%、14.61%; E_{RMS} 分别降低了 67.97%、20.47%、11.63%; R^2 分别提高了 0.78、0.01、0.01。通过 LSTM 和 VMD-LSTM 这组消融实验, 说明对于预测不平稳的涌水量时间预测任务而言, LSTM 无法发挥其序列记忆的特点, 此时可以通过类似模态分解之类的算法进行平稳化处理之后, 再使用 LSTM 预测, 以期达到一个较好的预测效果。3组消融实验全都证明 VMD 去噪的有效性和必要性, 通过加入 VMD 模块可以有效地降低模型的整体误差, 提高预测的拟合度和准确性。

通过 VMD-DBN 与对照组 GA-BP、VMD-LSTM、VMD-RBM 的评价指标进行对比研究, 计算得出评价指标 E_{MA} 分别降低了 14.38%、41.51%、9.33%; E_{MAP} 分别降低了 17.39%、42.42%、7.32%; E_{RMS} 分别降低了 65.34%、39.31%、9.34%; R^2 分别增加了 0.24、0.06、0.01。说明 VMD-DBN 的耦合效果强于 VMD-LSTM 和 VMD-RBM 模型, 更适合涌水量预测的工程任务




图 9 各模型预测 4 个评价指标对比

Fig.9 Comparison of 4 evaluation indicators for each model prediction

要求。

总体上, VMD-DBN 有最小的 E_{MA} 、 E_{MAP} 、 E_{RMS} 和最高的拟合度 R^2 , 对于涌水量时间序列的预测最为精准和稳定。

4 结论

a. 针对矿井涌水量的非稳定、非线性特点, 建立耦合 VMD、DBN 的涌水量智能化预测方法, 丰富了矿井涌水量预测方法, 为智慧矿山的安全监测提供一种新型的技术手段, 具有一定的理论价值和现实意义。

b. 利用某矿实测涌水量数据对 VMD-DBN 涌水量预测方法的精准性、稳定性进行测试, 统计学指标 E_{MA} 、 E_{MAP} 、 E_{RMS} 和 R^2 指示该方法较 GA-BP、LSTM、VMD-LSTM、RBM、VMD-RBM 和 DBN 等方法的稳定性和准确性更高。说明该方法对于涌水量随时间无明显变化规律、且具有较强震荡性和非平稳的工况具有相对明显的优势。

c. 通过 VMD-LSTM 和 LSTM、VMD-RBM 和 RBM、VMD-DBN 和 DBN 对比, VMD 分解对于预测精度和稳定性方面具有明显的提升。

d. 该模型只考虑涌水量时间序列的单一变量预测, 没有考虑多变量对预测结果的影响。下一步可以考虑加入其他对矿井涌水量有影响的变量, 如降雨量、气压、温度等, 将多变量输入多变量预测模型, 提高预测模型的通用性。

参考文献(References)

- [1] 虎维岳, 闫丽. 对矿井涌水量预测问题的分析与思考[J]. 煤炭科学技术, 2016, 44(1): 13-18.
HU Weiyue, YAN Li. Analysis and consideration on prediction problems of mine water inflow volume[J]. Coal Science and Technology, 2016, 44(1): 13-18.
- [2] 范立民, 孙魁, 李成, 等. 榆神矿区煤矿防治水的几点思考[J]. 煤田地质与勘探, 2021, 49(1): 182-188.
FAN Limin, SUN Kui, LI Cheng, et al. Thoughts on mine water control and treatment in Yushen mining area[J]. Coal Geology & Exploration, 2021, 49(1): 182-188.
- [3] 虎维岳. 浅埋煤层回采中顶板含水层涌水量的时空动态预测技术[J]. 煤田地质与勘探, 2016, 44(5): 91-96.
HU Weiyue. Water inflows prediction technique of water inflow from roof aquifer during extraction of shallow seam[J]. Coal Geology & Exploration, 2016, 44(5): 91-96.
- [4] 杨建, 王皓, 梁向阳, 等. 鄂尔多斯盆地北部深埋煤层工作面涌水量预测方法[J]. 煤田地质与勘探, 2021, 49(4): 185-191.
YANG Jian, WANG Hao, LIANG Xiangyang, et al. Water inflow forecasting method of deep buried coal working face in northern Ordos Basin, China[J]. Coal Geology & Exploration, 2021, 49(4): 185-191.
- [5] 陈韶知, 刘树才, 杨国勇. 矿井涌水量预测方法的发展[J]. 工程地球物理学报, 2009, 6(1): 68-72.
CHEN Mingzhi, LIU Shucui, YANG Guoyong. The development of mining water inflow predict method[J]. Chinese Journal of Engineering Geophysics, 2009, 6(1): 68-72.
- [6] 马青山, 骆祖江. 解析法和数值法在矿井涌水量预测中的比较[J]. 矿业安全与环保, 2015, 42(4): 63-66.
MA Qingshan, LUO Zuijiang. Comparison of analytical method and numerical method in mine water inflow prediction[J]. Min-

- ing Safety & Environmental Protection, 2015, 42(4): 63–66.
- [7] 戴岩柯, 崔世新, 张坤. 水均衡法和数值模拟法在矿坑深部涌水量预测中的比较: 以西石门铁矿为例[J]. 地下水, 2010, 32(1): 24–26.
DAI Yanke, CUI Shixin, ZHANG Kun. Comparisons water balance to value simulation in the forecast of from the depth inflow of the mine pit: Take an iron-ore in Xishimen as an example[J]. Groundwater, 2010, 32(1): 24–26.
- [8] 张子祥. 甘肃核桃峪煤矿矿井涌水量的计算与分析[J]. 中国煤炭地质, 2015, 27(2): 32–36.
ZHANG Zixiang. Estimation and analysis of mine water inflow in Hetaoyu Coal Mine, Gansu[J]. Coal Geology of China, 2015, 27(2): 32–36.
- [9] 王家乐, 王施智, 黄倩. 基于相关分析法的煤矿涌水量预测[J]. 陕西煤炭, 2021, 40(2): 99–102.
WANG Jiale, WANG Shizhi, HUANG Qian. Prediction of coal mine water inflow based on correlation analysis method[J]. Shaanxi Coal, 2021, 40(2): 99–102.
- [10] 苏培东, 赵熠, 邱鹏, 等. 花岗岩蚀变带隧道涌水量预测研究[J]. 地下空间与工程学报, 2023, 19(1): 291–301.
SU Peidong, ZHAO Yi, QIU Peng, et al. Prediction of tunnel water intrush volume in granite alteration zone[J]. Chinese Journal of Underground Space and Engineering, 2023, 19(1): 291–301.
- [11] 邢金莎. 基于深度学习的矿井水文参数分析与预测[D]. 西安: 西安科技大学, 2021.
XING Jinsha. Mine hydrological parameter analysis and prediction based on deep learning[D]. Xi'an: Xi'an University of Science and Technology, 2021.
- [12] 齐晓峰, 邵良杉, 邢雨艳. 基于EMD的矿井涌水量ARMA预测模型[J]. 辽宁工程技术大学学报(自然科学版), 2020, 39(6): 509–513.
QI Xiaofeng, SHAO Liangshan, XING Yuyan. ARMA prediction model of mine water inflow based on EMD[J]. Journal of Liaoning Technical University (Natural Science), 2020, 39(6): 509–513.
- [13] 安欣, 贾进章. 矿井涌水量时间序列ARIMA预测模型[J]. 辽宁工程技术大学学报(自然科学版), 2015, 34(7): 785–790.
AN Xin, JIA Jinzhang. Time series prediction of mine water inflow of ARIMA model[J]. Journal of Liaoning Technical University (Natural Science), 2015, 34(7): 785–790.
- [14] 孟璐. 基于人工神经网络的矿井涌水量预测[J]. 煤炭与化工, 2020, 43(4): 65–68.
MENG Lu. Mine water volume prediction based on artificial neural networks[J]. Coal and Chemical Industry, 2020, 43(4): 65–68.
- [15] 乔美英, 程鹏飞, 刘震震. 基于GA-SVM的矿井涌水量预测[J]. 煤田地质与勘探, 2017, 45(6): 117–122.
QIAO Meiyong, CHENG Pengfei, LIU Zhenzhen. Mine water inflow prediction based on GA-SVM[J]. Coal Geology & Exploration, 2017, 45(6): 117–122.
- [16] 黄永刚, 李龙. 基于随机森林算法的矿井涌水量预测[J]. 煤炭技术, 2017, 36(1): 220–221.
HUANG Yonggang, LI Long. Mine water inflow forecasting based on random forest algorithm[J]. Coal Technology, 2017, 36(1): 220–221.
- [17] LI Zhanli, GAO Tianyu, GUO Cheng, et al. A gated recurrent unit network model for predicting open channel flow in coal mines based on attention mechanisms[J]. IEEE Access, 2020, 8: 119819–119828.
- [18] 罗奕, 向新, 王勇. 矿井明渠流量测定方法[J]. 煤田地质与勘探, 2006, 34(1): 56–57.
LUO Yi, XIANG Xin, WANG Yong. Technological method to measure the canal sewage discharge in coal mine[J]. Coal Geology & Exploration, 2006, 34(1): 56–57.
- [19] 降海荣, 赵宝峰, 康艳旗, 等. 基于深度置信网络的矿井涌水量预测研究[J]. 矿业研究与开发, 2023, 43(2): 143–148.
JIANG Hairong, ZHAO Baofeng, KANG Yanqi, et al. Prediction of mine water inflow based on deep belief network[J]. Mining Research and Development, 2023, 43(2): 143–148.
- [20] HUANG N E, SHEN Zheng, LONG S R, et al. The empirical mode decomposition and the Hilbert spectrum for nonlinear and non-stationary time series analysis[J]. Proceedings: Mathematical, Physical and Engineering Sciences, 1998, 454(1971): 903–995.
- [21] DRAGOMIRETSKIY K, ZOSSO D. Variational mode decomposition[J]. IEEE Transactions on Signal Processing, 2014, 62(3): 531–544.
- [22] KUREMOTO T, KIMURA S, KOBAYASHI K, et al. Time series forecasting using a deep belief network with restricted Boltzmann machines[J]. Neurocomputing, 2014, 137: 47–56.
- [23] CHENG Yong, ZHOU Xiangyu, WAN Shaohua, et al. Deep belief network for meteorological time series prediction in the Internet of things[J]. IEEE Internet of Things Journal, 2019, 6(3): 4369–4376.
- [24] 侍建国, 张亦飞. 拉依达准则在处理区域水文数据异常值中的应用[J]. 海河水利, 2016(5): 49–51.
SHI Jianguo, ZHANG Yifei. Application of Lajda's criterion in dealing with regional hydrological data outliers[J]. Haihe Water Resources, 2016(5): 49–51.
- [25] 李秉晨, 于惠钧, 丁华轩, 等. 基于CEEMD和LSTM-ARIMA的短期风速预测[J]. 中国测试, 2022, 48(2): 163–168.
LI Bingchen, YU Huijun, DING Huaxuan, et al. Short-term wind speed prediction based on CEEMD and LSTM-ARIMA[J]. China Measurement & Test, 2022, 48(2): 163–168.
- [26] IM K S, PESARAN M H, SHIN Y. Testing for unit roots in heterogeneous panels[J]. Journal of Econometrics, 2003, 115(1): 53–74.
- [27] 靳德武, 李超峰, 刘英锋, 等. 黄陇煤田煤层顶板水害特征及其防控技术[J]. 煤田地质与勘探, 2023, 51(1): 205–213.
JIN Dewu, LI Chaofeng, LIU Yingfeng, et al. Characteristics of roof water hazard of coal seam in Huanglong Coalfield and key technologies for prevention and control[J]. Coal Geology & Exploration, 2023, 51(1): 205–213.
- [28] 施龙青, 王雅茹, 邱梅, 等. 时间序列模型在工作面涌水量预测中的应用[J]. 煤田地质与勘探, 2020, 48(3): 108–115.
SHI Longqing, WANG Yaru, QIU Mei, et al. Application of time series model in water inflow prediction of working face[J]. Coal Geology & Exploration, 2020, 48(3): 108–115.
- [29] VANITHA V, SOPHIA J G, RESMI R, et al. Artificial intelligence-based wind forecasting using variational mode decomposition[J]. Computational Intelligence, 2020, 37(3): 1034–1046.

(责任编辑 周建军)