

基于半监督神经网络的铜矿矿坑涌水量精准估计研究

苏 航* 张奋明 余 莉 黎华平 孙双龙 李 奇*

(云南省有色地质局三〇八队, 云南 昆明 650200)

摘 要 为改善铜矿矿坑涌水量估计效果,为矿山安全生产提供有力支持,研究基于半监督神经网络的铜矿矿坑涌水量精准估计方法。构建基于半监督动态深度融合神经网络的涌水量估计模型,以有、无标注矿坑涌水量数据为模型输入,作滑动窗口处理后,在特征提取网络中进行位置编码,通过注意力机制模块提取出对涌水量估计更有价值的信息。采用 t 分布随机邻域嵌入方法降低包含位置信息的有、无标注涌水量数据空间分布差异后,通过堆叠自动编码器逐层学习原始输入数据,准确提取已标注涌水量数据隐层特征,作为特征回归网络输入,经过门控循环神经网络处理后,输出铜矿矿坑涌水量精准估计。结果表明,该方法可实现金平县龙脖河铜矿区矿坑涌水量的精准估计, RMSE、MAE、MAPE 指标分别为 0.017 86、0.012 95、0.206 46, R^2 指标为 0.978 02,涌水量误差介于 0.1~0.5 m³/h 之间,铜矿矿坑涌水量估计精度较高。

关键词 半监督;涌水量;滑动窗口;注意力机制;自动编码器;门控循环神经网络

中图分类号:TD163 文献标志码:A 文章编号:1000-8098(2025)02-0102-05 DOI:10.20244/j.cnki.fjsk.202502102

Research on Accurate Estimation of Water Inflow in Copper Mine Pit Based on Semi Supervised Neural Network

Su Hang* Zhang Fenming Yu Li Li Huaping Sun Shuanglong Li Qi*

(Team 308 of Yunnan Nonferrous Metals Geological Bureau, Kunming, Yunnan 650200)

Abstract In order to improve the estimation effect of water inflow in copper mines and provide strong support for mine safety production, an accurate estimation method of water inflow in copper mines based on semi-supervised neural network is studied. A water inflow estimation model based on semi-supervised dynamic deep fusion neural network is constructed. The data of mine inflow with and without labels are taken as the input of the model, and after sliding window processing, the position of the data is encoded in the feature extraction network, and more valuable data for water inflow estimation are extracted through the attention mechanism module. T -distribution random neighborhood embedding method is used to reduce the spatial distribution difference of labeled and unlabeled water inflow data containing position information. The original input data is learned layer by layer by stacking automatic encoder, and the hidden layer features of labeled water inflow data are accurately extracted as the input of feature regression network. After being processed by gated cyclic neural network, the accurate estimation results of water inflow in copper mines are output. The results show that this method can accurately estimate the water inflow in Longbohe copper mine area of Jinping County, with RMSE, MAE and MAPE indexes of 0.017 86, 0.012 95 and 0.206 46 respectively, R^2 index of 0.978 02, and the error of water inflow is between 0.1-0.5 m³/h, so the accuracy of accurate estimation of water inflow in copper mine is relatively high.

Key words semi supervised; water inflow; sliding window; attention mechanism; autoencoder; gated recurrent neural network

铜矿是一种重要的金属资源,矿坑涌水在铜矿开采过程中普遍存在^[1],涌水量定义为地下水通过矿坑周围的岩石裂隙、断层等渗入到矿坑中的质量。矿坑涌水量受多种因素影响^[2-3],如地质条件、气候条件、开采深度等,这些因素之间存在复杂的相互作用关系,使得涌水量的预测变得困难。采取有效措施实现铜矿矿坑涌水量的精准估计对确保矿山安全和高效生产至关重要^[4-6]。

王虎^[7]通过收集和处理大量铜矿水文地质数据,并经过复杂计算和分析完成涌水量的确定,在一定程度上增加了研究的难度和时间成本。罗奇斌等^[8]采

用数值模拟法通过构建数学模型分析陕北头道河则、二道河则沟域的地下水运动情况,预测矿坑涌水量,虽然该方法能够较好地处理复杂地质和气候因素,但计算成本较高,且模型参数难以确定。尹会永等^[9]将 BP 神经网络作为涌水量预测模型,并利用遗传算法、麻雀搜索算法对模型参数进行两次寻优,提高涌水量预测精度,该方法主要依赖标注数据训练模型,很难获得足够标注数据。另外,该方法在处理复杂地质和气候因素时,可能无法充分考虑各因素间的相互作用,导致预测误差较大。Xu 等^[10]构建生成对抗网络,通过自动发现数据中的模式、结构和关联对地下储油洞涌水量进行估计,无需标注数据指导模型训练,更关注于数据本身结构,而不是特定任务或目标。这可能导致模型在处理新的、未见过的数据时泛化能力有限。

收稿日期:2025-01-29

基金项目:云南省有色地质局“百名地质技术人才培养工程(2022042)。

* 通信作者, E-mail: Su520308@163.com; 86081514@qq.com。

半监督神经网络结合了监督学习和非监督学习的优点^[11],能够有效利用有限的标注数据和大量的未标注数据进行训练,可有效提高预测模型性能和泛化能力。因此,本试验基于半监督神经网络的铜矿矿坑涌水量精准估计方法,以适应矿坑开挖和地下水位的动态变化,为矿山安全生产提供有力支持。

1 铜矿矿坑涌水量精准估计方法设计

1.1 自编码器 自编码器是典型的无监督学习网络^[12-13],基本思想是通过将网络原始输入信息向低维特征空间的映射,完成数据结构和特征的有效学习,这个映射过程定义为编码阶段。将编码阶段输出结果再映射回原始数据空间,获得网络原始输入信息的过程定义为解码。自编码器基本结构,见图1。




图1 自编码器基本结构

从图1可看出,自编码器输入部分节点数量高于隐含层,目的是为了实现维数约减,即通过学习一个低维、压缩的表示,以捕获网络原始输入信息的主要特征。数据编码过程,见式(1)。

$$h=f(wx+b) \quad (1)$$

式中: x 为原始输入信息; h 为压缩处理结果; w 为输入、隐含层之间的连接权值; b 为偏置量; f 为激活函数。

解码阶段通过将获得的低维特征表示映射回原始数据空间,可获得 x 的重构结果,该过程描述方示,见式(2)。

$$x'=f(w'h+b') \quad (2)$$

式中: x' 为解码结果; w' 为隐含单元与输出部分之间的连接权值; b' 为偏置量。

本试验设计的自编码器输出、输入部分具有相同数量的节点,目的是使输出尽可能接近输入,通过损失函数量化输出和输入之间的差异。损失函数 $L(x, x')$,见式(3)。

$$\{w, b, w', b'\} = \arg \min L(x, x') = \|x - x'\| \quad (3)$$

自编码器以 $\text{Loss}(x, x')$ 最低为优化目标,确保 x 更接近 x' ,利用训练后的隐层节点,即可学习到网络原始输入信息的低维表示。隐含节点数量决定了网络输入信息低维特征学习效果的优劣。隐层节点数量确定式,见式(4)。

$$n_1 = \log_2 n \quad (4)$$

式中: n_1 为隐层节点总数; n 为输入层节点总数。

1.2 注意力机制 注意力机制能够在处理信息时聚焦于重要部分,忽视不相关部分^[14]。在神经网络中,注意力机制通过为隐层节点赋予差异权重增强重要信息,从而提高模型处理信息的效率和能力。注意力机制结构图,见图2。图2中 a_i 为注意力机制根据当前上下文信息,赋予各个隐层节点的权重,可反映各节点对网络最终输出 y 的贡献程度。




图2 注意力机制结构图

隐层节点权重 a_i 的计算公式,见式(5)和式(6)。

$$a_i = \exp(e_i) / \sum_{j=1}^T \exp(e_j) \quad (5)$$

$$e_i = w' \tanh(wh_i + b) \quad (6)$$

式中: e_i 为在 t 时间点下,根据自编码器隐层输出 h_i 确定的节点权重。

注意力关注值^[15]计算式,见式(7)。

$$a_i = \exp(e_i) / \sum_{j=1}^T \exp(e_j) \quad (7)$$

式中: a_i 为注意力函数,通过注意力函数可计算查询 q 与关键字 k 之间的匹配程度,再根据其对值 v 作加权求和处理。处理机制,见式(8)。

$$x_v = \sum_{i=1}^T a_i h_i \quad (8)$$

式中: x_v 为注意力机制处理结果, T 为输入信息维度。

1.3 基于半监督动态深度融合神经网络的铜矿矿坑涌水量估计模型 实际应用中,收集大量带有准确标签的矿坑涌水量数据困难且昂贵。无标签的数据(即没有直接涌水量记录的数据)相对易获取。本试验构建半监督动态深度融合神经网络(SS-DDFNN)模型,通过将自编码器这种典型的无监督学习网络和有监督学习的门控循环神经网络结合,旨在利用有限标注数据和大量未标注数据提高模型对铜矿矿坑涌水量估计性能。

SS-DDFNN模型结构,见图3。从图3可看出,该模型采取半监督方式对铜矿矿坑涌水量数据进行特征学习,按照3:2融合有、无标注数据,确保模型在预训练过程中既能从标注数据中学习得到与铜矿矿坑涌水量相关的特征,又能从未标注数据中学习得到原始输入信息的分布。定义标注数据损失函数的目的是使重构后的输入尽可能与原始输入一致,实现重构偏差最小化。这意味着模型不仅需要实现输入数据

的准确重构,还需要精准估计与铜矿矿坑涌水量相关的输出。定义无标注数据损失函数则只以最小化重构偏差为最终目的,在缺乏标注信息的情况下,无法实现铜矿矿坑涌水量估计的有效监督。通过对有、无标注数据损失函数进行同时优化,确定模型参数,以使模型可从标注数据中学习铜矿矿坑涌水量信息,同时从未标注数据中学习更一般的特征。




图3 基于SS-DDFNN的铜矿矿坑涌水量精准估计模型结构图

SS-DDFNN 模型由特征提取网络和特征回归网络构成,特征提取网络通过将输入到模型中的铜矿矿坑涌水量数据转换成更高层次、隐层特征表示,完成关键信息捕获及和复杂模式的学习。有、无标注的铜矿矿坑涌水量数据通过滑动窗口处理后,可创建包含多个时间点的数据序列, \$t\$ 时间点一个滑动窗口下的铜矿矿坑涌水量数据表示为 \$X=[x_t, x_{t-1}, x_{t-k+1}, \dots, x_{t-k}]\$, 其中 \$k\$ 为滑动窗口长度。对其进行位置编码,并将编码处理结果放回到 \$X\$ 中,即可使模型理解每个数据点在序列中的具体位置。位置编码计算式,见式(9)和式(10)。

$$P'_{i,2j} = \sin\left(\frac{i}{10\,000^{\frac{2j}{d}}}\right) + \sin\left(\frac{t}{10\,000^{\frac{2j}{d}}}\right) \quad (9)$$

$$P'_{i,2j+1} = \sin\left(\frac{i}{10\,000^{\frac{2j}{d}}}\right) + \sin\left(\frac{t}{10\,000^{\frac{2j}{d}}}\right) \quad (10)$$

式中: \$i\$ 表示铜矿矿坑涌水量数据在序列中位置, \$1 \leq i \leq k\$; \$j\$ 表示数据维度, \$1 \leq j \leq d\$。

在此基础上,通过式(5)确定各时刻铜矿矿坑涌水量数据的注意力权重,并基于式(7)为其提供具有差异性注意力关注值 \$A_i\$,以使模型能够将注意力聚焦在可实现矿坑涌水量精准估计的重要信息上,并忽略那些不重要信息。注意力机制输出数据 \$x_v\$ 中融入了位

置信息,将其按比例划分即可得到已标注铜矿矿坑涌水量监测数据样本 \$x_l\$、无标注铜矿矿坑涌水量监测数据样本 \$x_u\$。对 \$x_l\$、\$x_u\$ 进行 \$t\$ 分布随机邻域嵌入 (\$t\$-SNE) 空间相似性计算,并通过条件概率分布描述数据点之间的相似度,通过尽可能减小原始数据空间、特征空间的概率分布差异,即寻求最低 \$t\$-SNE 损失以实现输入数据结构特征的有效学习。\$t\$-SNE 损失函数,见式(11)~式(13)。

$$L = \sum_m \sum_n p_{mn} \log(p_{mn}/q_{mn}) \quad (11)$$

$$p_{mn} = \exp\left(\frac{-\|x_m - x_n\|^2}{2\delta^2}\right) / \sum_{k \neq l} \exp\left(\frac{-\|x_k - x_l\|^2}{2\delta^2}\right) \quad (12)$$

$$q_{mn} = \exp(1 + \|y_m - y_n\|^2)^{-1} / \sum_{k \neq l} \exp(1 + \|y_k - y_l\|^2)^{-1} \quad (13)$$

式中: \$p_{mn}\$、\$\delta^2\$ 分别为原始数据空间下的条件概率分布及高斯分布方差; \$q_{mn}\$ 为特征空间下的条件概率分布。

通过堆叠编码器对 \$x_l\$、\$x_u\$ 特征进行学习,获得用 \$h_1, h_2, \dots, h_n\$ 表示的隐层处理结果, \$h^n\$ 表示编号为 \$n\$ 的隐层提取的特征。通过对 \$h_1, h_2, \dots, h_n\$ 进行解码,即可实现 \$x_l\$、\$x_u\$ 的重构,得到 \$x'_l\$、\$x'_u\$,同时输出铜矿矿坑涌水量估计变量 \$\hat{y}\$。为降低模型深度增加而产生的信息损失问题,用损失函数使模型训练误差降至最低,并不断修正模型参数 \$\theta = \{w, b, w', b'\}\$,损失计算式,见式(14)。

$$J(\theta) = \frac{\sum_{i=1}^{N_l} \|x'_{ui} - x_{ui}\|^2}{N_u} + \frac{\sum_{i=1}^{N_l} \|x'_{li} - x_{li}\|^2}{N_l} + \frac{\sum_{i=1}^{N_l} \|\hat{y}'_{ui} - x_{ui}\|^2}{N_l} + \sum_m \sum_n p_{mn} \log(p_{mn}/q_{mn}) \quad (14)$$

式中: \$\frac{\sum_{i=1}^{N_l} \|x'_{ui} - x_{ui}\|^2}{N_u}\$ 和 \$\frac{\sum_{i=1}^{N_l} \|x'_{li} - x_{li}\|^2}{N_l}\$ 对应重构 \$x_u\$、\$x_l\$ 损失; \$\frac{\sum_{i=1}^{N_l} \|\hat{y}'_{ui} - x_{ui}\|^2}{N_l}\$ 对应铜矿矿坑涌水量估计损失;

\$\sum_m \sum_n p_{mn} \log(p_{mn}/q_{mn})\$ 对应 \$t\$-SNE 损失; \$N_l\$、\$N_u\$ 分别为 \$x_l\$、\$x_u\$ 数据总量。

为防止上述模型发生过拟合,采用 L1 正则化方法修改模型的损失函数来限制模型参数的规模,从而避免模型在训练数据上表现过好但在测试数据上泛化能力差。L1 正则化,也称为 Lasso 正则化,通过在损失函数中添加模型参数的绝对值之和 (即 L1 范数) 来实现。正则化方式倾向于产生稀疏的权重矩阵,即许多权重会被推向零,有助于特征选择,因为模型会倾向于忽略对预测结果贡献不大的特征。L1 正则化的损失函数,见式(15)。

$$J'(\theta) = J(\theta) + \lambda \sum_i |\omega_i| \quad (15)$$

式中: λ 表示正则化系数; ω 表示模型权重。

SS-DDFNN 模型的后半部分为特征回归网络, 基于门控循环神经网络 (GRU) 进行设计, 将提取到已标注数据 x_i 的隐层特征 h_{li} 作为输入, 实现铜矿矿坑涌水量的精准估计。利用式 (15) 对 h_{li} 进行处理, 获得门控值, 反映了对应特征对铜矿矿坑涌水量估计的重要程度。门控值计算式, 见式 (16)。

$$g_i = \sigma(W_{gi} \cdot h_{li} + b_{gi}) \tag{16}$$

式中: 激活函数 σ 为 Sigmoid 函数; W_{gi} 、 b_{gi} 分别为连接权值、偏置量, 下同。

通过对特征 h_{li} 进行映射, 可得到铜矿矿坑涌水量估计的候选值 y_i 。 y_i 计算式, 见式 (17)。

$$y_i = \tanh(W_{oi} \cdot h_{li} + b_{oi}) \tag{17}$$

每个特征的门控值 g_i 与其对应的铜矿矿坑涌水量估计的候选值 y_i 相乘, 得到该特征的加权估计值。再对其进行加和, 即可实现铜矿矿坑涌水量的精准估计, 输出 $\hat{y}_i$ 。 $\hat{y}_i$ 计算式, 见式 (18)。

$$\hat{y}_i = \sum_{i=1}^m g_i \cdot y_i = \sum_{i=1}^m \sigma(W_{gi} \cdot h_{li} + b_{gi}) \cdot \tanh(W_{oi} \cdot h_{li} + b_{oi}) \tag{18}$$

2 试验分析

以金平县龙脖河铜矿区为试验对象, 通过对该矿区进行地质勘探和水文地质调查, 收集该矿区地质构造、岩性、地下水流动性、水位等数据, 并利用安装在矿区周边的气象站及各种监测设备采集该矿区 2021 年 6 月至 2022 年 8 月期间降水量、开采深度、开采面积等数据, 见表 1。

表 1 试验数据集

项目	数据结构	数据量
地质构造、岩性数据	表格形式, 包含 ID、位置、岩性类型、地质构造类型、备注等字段	5 213
地下水流动性、水位数据	时间序列数据, 包含时间戳、地下水流动性(多方向速度)、水位等测量值	6 834
气象站检测设备数据	时间序列数据, 包含时间戳、降水量、开采深度、开采面积等测量值	7 541

完成试验数据集的构建后, 对数据集进行清洗、编码等处理, 剔除可能包含错误或异常的数据点, 并实现非数值型数据向数值型的转换。以 3 : 2 比例选择有、无标注数据, 建立训练样本集。将最后 5 日监测数据作为测试样本, 剩余数据作为训练样本。估计金平县龙脖河铜矿矿坑涌水量, 验证其性能优越性。

SS-DDFNN 模型性能直接决定金平县龙脖河铜矿矿坑涌水量估计精度, 设定模型参数, 见表 2。

表 2 模型参数设置

序号	网络参数	参数设置
1	自编码器编码阶段激活函数	ReLU
2	注意力机制中查询、关键字、值的维度	64
3	注意力机制多头注意力中的头数	8
4	GRU 网络隐藏层节点数	128
5	学习率	0.001
6	批次处理规模	30
7	迭代次数	100

表 2 中学习率及批次处理的参数是根据试验获得的, 此时模型的收敛性最好。将基于堆叠自编码器的估计方法、基于门控循环神经网络的估计方法作为对比方法, 并使其模型参数与研究方法保持一致, 应用 3 种方法对训练样本进行学习, 通过对比分析不同时刻下矿坑涌水量估计结果差异, 验证研究方法在矿坑涌水量估计上的优越性, 结果见图 4。




图 4 不同方法下的涌水量估计结果对比

从图 4 可看出, 不同时间下的矿坑涌水量呈现波动性变化规律, 对比方法涌水量估计结果均偏离实际曲线, 基于门控循环神经网络的估计方法使用监督学习方式对样本进行训练, 通过标注数据指导模型的学习过程, 能够更准确地学习数据的特征表示, 但由于无法直接利用无标注数据进行监督训练, 导致学习效果不佳。基于堆叠自编码器的估计方法在处理时间序列数据或需要捕捉数据之间顺序关系时, 可能无法有效学习到数据之间的时间依赖特性, 这是该方法估计结果存在较大偏差的主要原因。研究方法利用堆叠自动编码器对输入数据进行特征学习, 然后将学习到的特征表示作为门控循环神经网络的初始参数, 在提高模型训练效率的同时, 实现了各个时刻矿坑涌水量的准确估计, 估计曲线与实际曲线不仅保持一致走势规律, 且二者极度贴合, 误差极小。实验结果表明, 研究方法在金平县龙脖河铜矿矿坑涌水量估计上表现出显著优势。

选取均方根误差 (RMSE)、拟合优度系数 (R^2)、平均绝对误差 (MAE)、平均绝对百分比误差 (MAPE)

作为涌水量估计模型性能的评价指标,通过对比 3 种方法下的各指标差异,进一步验证研究方法的性能优势,结果见表 3。

表 3 不同方法性能评价

评价指标	研究方法	基于堆叠自编码器的估计方法	基于门控循环神经网络的估计方法
R^2	0.978 02	0.917 14	0.945 60
RSME	0.017 86	0.035 17	0.026 01
MAE	0.012 95	0.027 14	0.018 48
MAPE	0.206 46	0.262 98	0.227 01

由表 3 可知,应用研究方法对金平县龙脖河铜矿矿坑涌水量进行估计, RMSE、MAE、MAPE 指标均取得最小值,分别为 0.017 86、0.012 95、0.206 46,表明涌水量估计结果与实际值之间误差最小,估计精度最高。 R^2 指标达到最大值,即 0.978 02,更接近于 1,说明研究方法能够很好地拟合实际数据,准确性高。基于门控循环神经网络的估计方法指标优于基于堆叠自编码器的估计方法。

将测试样本输入到研究方法所用 SS-DDFNN 模型中预测矿坑涌水量,部分时刻矿坑涌水量估计结果,见表 4。

表 4 矿坑涌水量估计结果

时间/h	实际值/(m ³ /h)	估计值/(m ³ /h)
1	120	118.5
6	125	124.85
10	130	129.8
15	137	136.6
20	140	139.7
30	150	150.2
40	157	157.3
50	162	162.1
80	171	170.8
100	183	182.6
120	188	187.7

由表 4 可知,研究方法可实现金平县龙脖河铜矿矿坑涌水量的估计。以 6 h 开始,估计结果与实际涌水量的最大误差为 0.5 m³/h,最小误差为 0.1 m³/h。研究方法在不同时刻的估计结果均保持了一定的稳定性和一致性。表明研究方法在处理时间序列数据时具有较好的鲁棒性,能够应对各种复杂的矿坑涌水量变化情况,这对于长期稳定的矿山生产来说非常重要。

3 结论

1. 本试验在基于 SS-DDFNN 的半监督学习框架下开展铜矿矿坑涌水量估计研究,展现出了更高的预测精度和稳定性。这一优势主要得益于对未标记数据的充分利用,增强了模型对复杂地质和水文条件的适应能力。

2. 随着深度学习技术的不断发展,半监督神经网络在铜矿矿坑涌水量预测领域的应用将进一步拓展。未来研究可关注模型优化、数据增强及多源数据融合等方面,以提高预测精度和泛化能力,为矿山安全生产和水资源管理提供更加科学、高效的技术支持。

参考文献:

[1] 王志强. 铜山铜矿水文地质特征及矿坑涌水量预测研究[J]. 地下水, 2023, 45(3): 49-51.

[2] 李建林, 王路扬, 李松营, 等. 基于灰色-多步马尔科夫模型的矿井涌水量预测[J]. 河南理工大学学报(自然科学版), 2023, 42(5): 66-71.

[3] 梁满玉, 尹尚先, 姚辉, 等. 基于 DRN-BiLSTM 模型的矿井涌水量预测[J]. 煤矿安全, 2023, 54(5): 56-62.

[4] 李建林, 高培强, 王心义, 等. 基于混沌-广义回归神经网络的矿井涌水量预测[J]. 煤炭科学技术, 2022, 50(4): 149-155.

[5] 修艳敏, 张明燕, 顾端阳. 矿坑涌水量预测计算探采对比研究[J]. 中国矿业, 2021, 30(S1): 344-347.

[6] 赵研, 郭嘉琳, 施洋, 等. 基于 GMS 的抚顺西露天矿地下水涌水量模拟[J]. 环境工程, 2021, 39(1): 75-79, 129.

[7] 王虎. 西藏铁格隆南铜矿水文地质条件特征及矿坑涌水量计算分析[J]. 地下水, 2023, 45(2): 30-32, 37.

[8] 罗奇斌, 赵宝峰, 毛旭阁, 等. 基于数值模拟方法的煤矿开采涌水量预测分析[J]. 西北大学学报(自然科学版), 2022, 52(6): 1100-1110.

[9] 尹会永, 周鑫龙, 郎宁, 等. 基于 SSA 优化的 GA-BP 神经网络煤层底板突水预测模型与应用[J]. 煤田地质与勘探, 2021, 49(6): 175-185.

[10] XU Z H, BU Z H, GAO B, et al. Sensitivity Analysis and Prediction Method for Water Inflow of Underground Oil Storage Caverns in Fractured Porous Media[J]. International journal of geomechanics, 2021, 21(2): 1-14.

[11] 郭小萍, 种佳林, 李元. 基于半监督动态深度融合神经网络的软测量[J]. 计算机应用研究, 2024, 41(2): 521-526.

[12] 郑淋文, 周金治, 黄静. 深度稀疏自编码器在 ECG 特征提取中的应用[J]. 计算机工程与应用, 2021, 57(11): 156-161.

[13] 林焱辉, 李春波. 基于变分自编码器的多维退化数据生成方法[J]. 北京航空航天大学学报, 2023, 49(10): 2617-2627.

[14] 陈伟, 任鹏, 田子建, 等. 基于注意力机制的无监督矿井人员跟踪[J]. 煤炭学报, 2021, 46(S1): 601-608.

[15] 段超, 张婧, 何彬, 等. 融合注意力机制的深度混合推荐算法[J]. 计算机应用研究, 2021, 38(9): 2624-2627, 2634.

