



移动扫码阅读

DOI: 10.13347/j.cnki.mkaq.20230988

矿井地质与水害防治

连会青, 李启兴, 王瑞, 等. 基于深度学习的 LSTM-GRU 复合模型矿井涌水量预测方法研究[J]. 煤矿安全, 2024, 55(9): 166–172.

LIAN Huiqing, LI Qixing, WANG Rui, et al. Research on mine water inflow prediction method of LSTM-GRU composite model based on deep learning[J]. Safety in Coal Mines, 2024, 55(9): 166–172.

基于深度学习的 LSTM-GRU 复合模型 矿井涌水量预测方法研究

连会青, 李启兴, 王 瑞, 夏向学, 张 庆, 黄亚坤, 任正瑞, 康 佳
(华北科技学院 河北省矿井灾害防治重点实验室, 河北 三河 065201)

摘 要: 为了解决矿井涌水预测问题, 引入深度学习理论, 将长短期记忆网络(LSTM)和门控循环单元(GRU)进行结合, 选取矿井涌水量为研究对象, 建立一种 LSTM-GRU 的矿井涌水预测模型。以陕西某矿的矿井涌水量为样本数据, 采用 7 : 3 的比例将数据集划分为训练集和测试集, 选择模型训练效果较好的梯度下降算法确定网络模型参数和正则化参数, 为了证明 LSTM-GRU 模型的预测精度, 同时将结果分别与传统的 ARIMA 模型和 LSTM 模型预测矿井涌水所得到的预测结果进行对比。结果表明: LSTM-GRU 复合模型的平均绝对百分比误差(RMSE)为 70.51, 均方根误差(MAE)为 53.4, 平均绝对误差(MAPE)为 2.80%, 可决系数(R^2)为 0.86, 具有较高的预测精度和可靠性, 预测效果优于传统的 ARIMA 模型和 LSTM 模型。

关键词: 矿井防治水; 矿井涌水量预测; LSTM-GRU 网络模型; ARIMA 模型; LSTM 模型

中图分类号: TD745

文献标志码: A

文章编号: 1003-496X(2024)09-0166-07

Research on mine water inflow prediction method of LSTM-GRU composite model based on deep learning

LIAN Huiqing, LI Qixing, WANG Rui, XIA Xiangxue, ZHANG Qing, HUANG Yakun, REN Zhengrui, KANG Jia

(Key Laboratory of Mine Disaster Prevention and Control of Hebei Province, North China Institute of Science and Technology, Sanhe 065201, China)

Abstract: In order to solve the problem of mine water surge prediction, we introduce deep learning theory, combine long short-term memory network (LSTM) and gated circulation unit (GRU), select mine water surge as the research object, and establish a mine water surge prediction model based on LSTM-GRU. Taking the mine water inflow of a mine in Shaanxi Province as sample data, the data set was divided into a training set and a test set using a 7 : 3 ratio, and the gradient descent algorithm with good model training effect was selected to determine the network model parameters and regularization parameters. In order to prove the prediction accuracy of the LSTM-GRU model, the prediction results were compared with those obtained by the traditional ARIMA model and the LSTM model to predict mine water gusher, respectively. The results show that: the mean absolute percentage error (RMSE), root mean square error (MAE), mean absolute error (MAPE) and coefficient of determination (R^2) of the LSTM-GRU composite model are 70.51, 53.4, 2.80% and 0.86, indicating that the model has high prediction accuracy and reliability. The prediction effect is better than the traditional ARIMA model and LSTM model.

Key words: mine water control; mine water flow prediction; LSTM-GRU network model; ARIMA model; LSTM model

收稿日期: 2023-07-04

修回日期: 2023-08-02

责任编辑: 庚馨杰

基金项目: 国家自然科学基金资助项目(51774136, 51974126); 中央高校基本科研业务费资助项目(3142022003, 3142014018); 中央高校青年教师基金资助项目(3142021004)

作者简介: 连会青(1975—), 女, 山西忻州人, 教授, 博士, 从事矿井水害防治方面的教学和研究工作。E-mail: 2366884370@qq.com

矿井涌水是指在采掘过程中,地质构造发生变化,导致地下水涌入矿井内部,涌水量会在短时间内出现大幅度变化,从而引发一系列灾害事故。为了避免矿井涌水造成的损失,需要提前进行涌水量预测预警^[1]。

在煤矿生产过程中,形成了多种涌水量预测的方法,主要分为 2 大类:一类是以概率统计和综合分析为主的统计分析方法;另一类是以非线性数理模型研究的模型与公式为主的方法。1985 年, SINGH 等^[2]第 1 次详细介绍了矿井涌水量预测的解析公式,并给出了各个公式的有效条件;1995 年,杨永国等^[3]首次提出了多变量时间序列分析方法,建立了矿井降雨量与涌水量的相关模型,并将其用于矿井涌水量的预测;张奔等^[4]选取灰色 GM(1, 1)模型借助 MATLAB 软件编程,使用分源预测等方法得到矿井年最大涌水量的时间序列;来永伟等^[5]利用非稳定流降深法预测的矿井涌水量比较稳定,非稳定流解析法的结果则更直观、实用;段东伟等^[6]分别采用水文地质综合比拟法、单宽流量法和大井法对矿井工作面涌水量进行了动态预测,将这 3 种方法对比分析,结果表明,水文地质综合比拟法的预测结果最准确;罗奇斌^[7]使用 MODFLOW 软件建立了 1 个非稳态地下水流的三维数值模型,并预测了使用 2 种不同的提取方法,即综合提取法和分层提取法,研究区域内矿井涌水量的变化情况,选择改变采空区空间步长以预测矿井涌水量;杨晟^[8]利用 GMS 地下水数值模拟软件,预测了煤层开采过程中的涌水量;曲兴玥等^[9]运用 2 类时间序列模型(ARIMA)分析了矿区时间和月最大涌水量的对应函数关系,并通过乘法分解法对其中的影响因素进行提取,结果表明,矿井涌水量的预测精度得到了提升;庞凯等^[10]以含水层厚度、岩性差异和含水层水力特征作为富水性评价的指标,利用 AHP-熵权组合赋权法作为指标的确权方法,研究根据修正系数的导高计算方法,根据导水裂隙进入含水层的高度值插值生成顶板冒裂稳定性分区图,并且和富水性分区图进行耦合叠加,对分区内矿井涌水的风险性进行预测。

目前,我国在预测模型的研究方面取得了一定的成果^[11-21],但是对于矿井涌水量预测方法的研究还停留在传统的时间序列和机器学习方法上,如支持向量机、决策树和人工神经网络,以理解为不含任何隐藏层的模型,即浅层机器学习模型。因此,引入了最新的深度学习算法,基于长短时

记忆神经网络,将其与门控循环单元神经网络相结合,建立 LSTM-GRU 的矿井涌水量预测模型。

1 研究方法

LSTM-GRU 复合模型是 1 种神经网络模型^[22],复合是长短期记忆模型(LSTM)和门控循环单元模型(GRU)的结合体。LSTM-GRU 模型相对于 LSTM 和 GRU 模型具有更快的训练速度、更高的准确性和更好的泛化能力。LSTM-GRU 网络结构图如图 1 所示。




图 1 LSTM-GRU 网络结构图

Fig.1 LSTM-GRU network structure

LSTM 和 GRU 模型结合使用可以最大限度地利用 2 种模型的优点,提高模型的鲁棒性、泛化性能和训练速度。为了提高矿井涌水量预测的准确性,提出了 1 种将 LSTM 模型和 GRU 模型组合建立的方法。这种方法可以充分发挥 2 种模型的优点,同时弥补单个模型在预测过程中的不足,从而提高预测性能。通过多个模型的组合预测,可以有效地结合各个模型的优点,进一步提高预测精度。最后将 LSTM-GRU 模型的预测结果与 LSTM 模型的预测结果进行对比分析,进而解析组合模型的精准度和适用性。

选取了平均绝对百分比误差(RMSE)、均方根误差(MAE)、平均绝对误差(MAPE)、可决系数(R^2)这 4 个指标来综合评估 LSTM-GRU 模型的性能和优劣程度。

2 矿井涌水量情况

矿井涌水量是指在单位时间内涌入矿井的水量总和。陕西某矿经过采掘工作的不断进行，矿井涌水量总体呈逐步增加的趋势。尤其是从 2012 年以来，随着二盘区、三盘区开采的逐渐展开，井下涌水量增长速度显著加快。矿井涌水量变化曲线图如图 2 所示。




图 2 矿井涌水量变化曲线图

Fig.2 Variation curve of mine water inflow

通过对矿井涌水变化的分析得出变化特征，并将其划分为 4 个阶段：①2017 年 1 月—2017 年 5 月，该时期在二、三盘区交替采场采动的过程中，矿井涌水量呈现跳跃性上升；②2017 年 6 月—2018 年 10 月，受白垩系洛河组含水层影响，矿井最大涌水量为 2 079 m³/h；③2018 年 11 月—2019 年 6 月，伴随着二盘区开采的逐步完成，三盘区两侧的开采范围都在不断扩大，同时，矿区的涌水量也在逐步减少，在这一时期，涌水的变化趋势与二盘地区开采完毕后涌水量的变化趋势较为相似；④2019 年 7 月—2020 年 10 月，四盘区 401 采场的涌水开始显现，并随时间推移而增大，矿井涌水量最大达到了 2 023 m³/h。

矿井在建设及生产过程中共出现大、小涌水事件 12 次。最大涌水发生在 2017 年 6 月 8 日，涌水量为 2 079 m³/h，主要充水水源为白垩系洛河组含水层，对矿井生产有一定影响。矿井主要涌水情况见表 1。

3 结果与讨论

3.1 LSTM-GRU 模型的矿井涌水量预测

在机器学习模型中，要将数据集划分为 2 类：一类是训练集，另一类是测试集；使用训练集数据对模型进行训练，以获得最佳参数，然后在测试

表 1 矿井涌水情况统计表

Table 1 Statistical table of mine water gushing

编号	日期	涌水水源	涌水通道	涌水量/(m³·h)		
				初期	最大	稳定
1	2003-06-09	洛河组含水层	裂隙	67.9	67.9	62.9
2	2003-06-20	洛河组含水层	裂隙	67.6	67.6	62.0
3	2005-04-13	洛河组含水层	小断层	80.0	80.0	79.6
4	2006-05-08	白垩系含水层组	导水裂缝带	35.0	112.0	12.0
5	2007-05-08	白垩系含水层组	导水裂缝带	62.0	162.0	152.0
6	2010-06-10	白垩系含水层组	导水裂缝带	216.0	289.0	282.0
7	2011-12-29	白垩系含水层组	导水裂缝带	258.0	525.0	375.0
8	2012-12-26	白垩系洛河组含水层	导水裂缝带	747.0	840.0	733.0
9	2013-10-16	白垩系洛河组含水层	导水裂缝带	810.0	925.0	809.0
10	2013-12-25	白垩系洛河组含水层	顶板高冒	1 044.0	1 301.0	1 018.0
11	2015-10-23	白垩系洛河组含水层	导水裂缝带	846.0	932.0	872.0
12	2017-06-08	白垩系洛河组含水层	导水裂缝带	1 782.0	2 079.0	1 244.0

集上验证模型的泛化能力^[23]。其中，训练集和测试集的划分比例为 7: 3，一共 167 条数据。将 2007 年 1 月—2016 年 8 月涌水量数据划分为训练集用来训练模型，之后 2016 年 9 月—2020 年 10 月的涌水量数据用来检验模型的泛化能力。

采用程序自寻优法寻找最优参数，从而确定合适的参数。通过对 LSTM-GRU 模型进行训练，发现在 LSTM 与 GRU 网络的隐含层数目均为 1 层时，LSTM 隐含层神经元数目设定为 10 个，GRU 隐含层神经元个数设置为 5 个时效果最优。

为了避免神经网络中出现简单的线性组合，通常会在神经网络的各隐含层以及输出层使用非线性的激活函数。在深度学习中，选择适合的激活函数种类是非常重要的，常用的激活函数包括 sigmoid 函数、双曲正切函数 Tanh 和 ReLU 函数，这些函数都需要满足单调连续并可导的要求。激活函数具有一定的判别门限和包含足够多的梯度信息的特征。

在 LSTM 与 GRU 这 2 种神经网络中，TANH 与 SIGMOID 是最常见的 2 种激活函数。因为 TANH 函数的数值介于 [-1,1] 之间，而且离 0 越近，导数就越大，因此可以快速地在逆向传递过程中进行梯度更新，同时还可以解决“原点对称”问题。最后，选取了 TANH 作为该模型的激活函数。根据模型的训练和优化，确定丢弃阈值为 0.2。

建立的模型主要采用随机梯度下降法，计算速度比传统批量梯度下降法更快，同时，也能更

快地收敛到局部最优解。可以在每次更新时随机选择样本，使其不容易陷入局部最小值，有助于找到全局最优解；与批量梯度下降法不同，随机梯度下降法可以支持在线学习。这意味着可以在不断获取新数据的同时，持续更新模型的系数，以适应不断变化的数据。

学习率数值的大小对模型的收敛速度有影响，但过大的学习率可能会导致模型不稳定而影响训练结果。当学习率设置过高时，步长会变得太大，导致模型在更新参数时出现抖动，最终无法达到收敛的效果；如果学习率设置过小，模型的收敛

速度会变得非常缓慢；相反，如果学习率设置得太大，则可能导致模型无法收敛。因此，在选择学习率时需要权衡速度和稳定性的因素，以达到最佳的训练效果。

由于学习率选取对模型训练效果的影响，使用 ADAM 算法进行梯度优化。通过 ADAM 优化算法不断地调整模型参数，经过多次实验，将初始学习率设置为 0.005 时，每迭代 10 次学习率调整为原来的 20%，迭代 100 次后损失值趋于稳定值，效果达到最优。LSTM-GRU 网络模型参数见表 2。

表 2 LSTM-GRU 网络模型参数表

Table 2 LSTM-GRU network model parameters table

参数	设定	意义
Hidden_Layers	1	LSTM和GRU隐含层个数均为1
LSTM Units	10	LSTM隐含层神经元的数目
GRU Units	5	GRU隐含层神经元的数目
Dropout	0.2	抛弃阈值作用机理主要是采用随机概率，对模型训练过程中的部分神经元采取隐藏处理方式
batch_size	8	单批次输入数据量
activation	tanh	激活函数，根据不同数据、网络层有不同的推荐
optimizer	Adam	Adam优化器是一种对随机梯度下降法的扩展
learning_rate	0.005	学习率，用来调整梯度下降速率的关键超参数
loss function	MSE	损失函数用来计算真实值和预测值差距用来评估模型预测性能
epochs	100	更新迭代次数，在训练模型时候需要大量试验来确定最优参数

建立 LSTM-GRU 训练模型对预测的数据集，将真实值与预测值进行对比。原数据和 LSTM-GRU 模型预测数据图如图 3 所示，其中红色实线为矿井真实涌水量，蓝色实线为 LSTM-GRU 模型的预测值；LSTM-GRU 模型预测结果的相对误差图如图 4 所示。




图 3 原数据和 LSTM-GRU 模型预测数据图
Fig.3 Prediction data of raw data and LSTM-GRU model

由图 3 可知：LSTM-GRU 模型对矿井涌水量预测的结果与实际涌水量变化趋势契合度很高，大部分预测值与真实值差距不大，只在转折点处




图 4 LSTM-GRU 模型预测结果的相对误差图
Fig.4 Relative error diagram of LSTM-GRU model prediction results

的预测和个别峰值的预测有一定偏差，但是偏差不大。拟合曲线基本围绕真实数据曲线周围小范围上下波动，而且预测值的变化趋势与真实涌水量的变化趋势也基本保持一致。

由图 4 可知：90% 以上矿井涌水量预测值的相对误差在 6% 以内，极个别样本的预测值偏差较大，平均绝对百分比误差 MAPE 仅为 2.8%。平均绝

对误差较小,说明 LSTM-GRU 模型的预测精度较高。

3.2 不同模型预测结果综合对比分析

为进一步验证 LSTM-GRU 预测模型的有效性及其精度,将其与 ARIMA 模型和 LSTM 模型进行对比,把 3 个模型的矿井涌水量预测值进行汇总,并绘制出与真实值对比结果图,不同模型的矿井涌水量预测结果如图 5 所示。




图 5 不同模型的矿井涌水量预测结果

Fig.5 Prediction results of mine water inflow with different models

由图 5 可知:LSTM-GRU 模型与其他 2 个模型相比,其预测值与真实值的整体变化趋势最相似,预测曲线更接近原始序列,总体拟合情况最好,且单个样本的预测数据与原始数据的差值较小。说明 LSTM-GRU 模型的预测值与原始序列拟合效果更好。

通过与 ARIMA 模型、LSTM 模型进行对比可知,LSTM-GRU 组合模型对矿井涌水量的预测效果优于其他 2 种模型,说明建立的组合模型的预测精度是最高的。同时将这 3 个模型的 4 个评价指标进行分类统计,各模型的评价指标结果见表 3。为了更直观地横向对比指标结果,将各模型的评价结果进行分类绘制柱状图。不同模型的评估指标对比图如图 6 所示。

表 3 各模型的评价指标结果

Table 3 Results of evaluation indicators of each model

预测模型	RMSE/%	MAE/%	MAPE/%	R^2
ARIMA	87.00	82.14	4.67	0.74
LSTM	86.56	62.59	3.32	0.78
LSTM-GRU	70.51	53.40	2.80	0.86

由图 6 可知:LSTM 与 ARIMA 相比较 2 个模型的 RMSE 和 R^2 指标相差较小,但是在 MAE 和




图 6 不同模型的评估指标对比图

Fig.6 Comparison of evaluation indicators of different models

RMSE 这 2 个指标上,LSTM 分别比 ARIMA 下降了 19.55%、1.35%,因此 LSTM 模型预测效果小优于 ARIMA 模型。同时将 LSTM-GRU 模型分别与 ARIMA 模型和 LSTM 模型进行比较,在 RMSE、MAE、MAPE 这 3 个指标上,LSTM-GRU 模型比 ARIMA 模型分别下降 16.49%、28.74%、1.87%,LSTM-GRU 模型比 LSTM 模型分别下降 16.05%、9.19%、0.52%;且 LSTM-GRU 模型的 R^2 分别高于 ARIMA 模型和 LSTM 模型 0.12 和 0.08,说明将 LSTM 模型和 GRU 模型组合后取得了比单一模型更好的效果,一定程度上说明了在矿井涌水量的预测问题上对 LSTM 模型与 GRU 模型进行组合具有可行性。

综合预测结果对比图和各模型评价指标的对比,利用 LSTM-GRU 模型预测矿井涌水量,其预测结果与实际情况的变化趋势吻合较好。结果表明,LSTM-GRU 模型具有更高的预测准确率,显示出了预测涌水量变化趋势的最佳效果。

4 结 语

1)针对矿井涌水量数据具有非线性、不平稳的特点,建立 1 种深度学习的 LSTM-GRU 复合模型矿井涌水量预测方法,为进一步提高矿井涌水量预测精度提供了思路。

2)LSTM-GRU 模型的 RMSE、MAE 和 MAPE 的值均小于 ARIMA 模型和 LSTM 模型, R^2 大于 ARIMA 模型和 LSTM 模型,说明 LSTM-GRU 模

型的预测效果较好。

3)通过 LSTM-GRU 复合模型与 LSTM 模型、ARIMA 模型对比, LSTM-GRU 复合模型对于预测精度和准确性方面具有明显的提升。

参考文献(References):

- [1] 武强. 我国矿井水防控与资源化利用的研究进展、问题和展望[J]. 煤炭学报, 2014, 39(5): 795-805.
WU Qiang. Progress, problems and prospects of prevention and control technology of mine water and reutilization in China[J]. Journal of China Coal Society, 2014, 39(5): 795-805.
- [2] SINGH R N, ATKINS A S. Application of idealised analytical techniques for prediction of mine water inflow[J]. International Journal of Rock Mechanics & Mining Sciences, 1985, 2(2): 131-138.
- [3] 杨永国, 韩宝平, 谢克俊, 等. 用多变量时间序列相关模型预测矿井涌水量[J]. 煤田地质与勘探, 1995(6): 38-42.
YANG Yongguo, HAN Baoping, XIE Kejun, et al. To forecast the water yield of coal mine applying the time series interrelated model with multivariation[J]. Coal Geology & Exploration, 1995(6): 38-42.
- [4] 张奔, 谢小平. 矿井涌水原因分析及涌水量预测研究[J]. 煤炭技术, 2021, 40(7): 109-113.
ZHANG Ben, XIE Xiaoping. Analysis of causing water inflow in mine and research of water inflow prediction[J]. Coal Technology, 2021, 40(7): 109-113.
- [5] 来永伟, 孔庆虎, 李志慧. 非稳定流定降深法在矿井涌水量预测中的应用[J]. 中国煤炭地质, 2018, 30(S2): 50-52.
LAI Yongwei, KONG Qinghu, LI Zhihui. Application of unsteady flow fixed drawdown method in mine inflow growth prediction[J]. Coal Geology of China, 2018, 30(S2): 50-52.
- [6] 段东伟, 丁湘, 蒲治国, 等. 基于充水条件比拟的工作面涌水量预计方法[J]. 煤矿安全, 2019, 50(5): 209-213.
DUAN Dongwei, DING Xiang, PU Zhiguo, et al. Prediction methods of water inflow in coal face based on comparison of water-filled conditions[J]. Safety in Coal Mines, 2019, 50(5): 209-213.
- [7] 罗奇斌, 赵宝峰, 毛旭阁, 等. 基于数值模拟方法的煤矿开采涌水量预测分析[J]. 西北大学学报(自然科学版), 2022, 52(6): 1100-1110.
LUO Qibin, ZHAO Baofeng, MAO Xuge, et al. Prediction and analysis of mine water inflow based on numerical simulation method[J]. Journal of Northwest University (Natural Science Edition), 2022, 52(6): 1100-1110.
- [8] 杨晟. 新疆克尔碱矿区煤层顶板突水风险评价及涌水量模拟预测研究[D]. 济南: 山东大学, 2020.
- [9] 曲兴玥, 于小鸽, 施龙青. 基于两类时间序列模型预测矿井最大涌水量[J]. 煤炭技术, 2019, 38(8): 100-102.
QU Xingyue, YU Xiaoge, SHI Longqing. Prediction of maximum mine inflow based on two kinds of time-series models[J]. Coal Technology, 2019, 38(8): 100-102.
- [10] 庞凯, 武强, 曾一凡. 含水层与多烧变岩含水水体互层下煤层顶板突(涌)水风险性预测[J]. 煤炭工程, 2022, 54(12): 135-141.
PANG Kai, WU Qiang, ZENG Yifan. Prediction of roof water intrush risk under the complex condition of inter-bedded aquifer and multi burnt rock aquifers[J]. Coal Engineering, 2022, 54(12): 135-141.
- [11] 杨海涛, 王华朋, 牛瑾琳, 等. 融合 LSTM-GRU 网络的语音逻辑访问攻击检测[J]. 数据采集与处理, 2022, 37(2): 396-404.
YANG Haitao, WANG Huapeng, NIU Jinlin, et al. Logical access attack audio detection based on LSTM-GRU[J]. Journal of Data Acquisition and Processing, 2022, 37(2): 396-404.
- [12] 高翱, 李国玉, 撒奥洋, 等. 基于 Adam 算法优化 GRU 神经网络的短期负荷预测模型[J]. 电子设计工程, 2022, 30(9): 180-183.
GAO Ao, LI Guoyu, HAN Aoyang, et al. Short-term load forecasting model based on Adam algorithm to optimize GRU neural network[J]. Electronic Design Engineering, 2022, 30(9): 180-183.
- [13] 刘年平. 煤矿安全生产风险预警研究[D]. 重庆: 重庆大学, 2012.
- [14] VISIN F, KASTNER K, CHO K, et al. ReNet: A recurrent neural network based alternative to convolutional networks[J]. ArXiv e-Prints, 2015: arXiv: 1505.00393.
- [15] 靳德武, 刘英锋, 冯宏, 等. 煤层底板突水监测预警系统的开发及应用[J]. 煤炭科学技术, 2011, 39(11): 14-17.
JIN Dewu, LIU Yingfeng, FENG Hong, et al. Development and application of monitoring and early warning system to seam floor water intrush[J]. Coal Science and Technology, 2011, 39(11): 14-17.
- [16] 焦保国. 矿井突水灾害预警系统的设计与实现[J]. 煤矿机电, 2016(6): 1-4.
JIAO Baoguo. Design and implementation of mine water intrush disaster early warning system[J]. Colliery Mechanical & Electrical Technology, 2016(6): 1-4.

- [17] 华攸金, 李希建. 基于可拓理论的煤矿安全风险预警与评估[J]. 煤炭工程, 2020, 52(1): 163-168.
HUA Youjin, LI Xijian. Coal mine safety risk early warning and assessment based on extension theory[J]. Coal Engineering, 2020, 52(1): 163-168.
- [18] 隋海波, 程久龙. 矿井工作面底板突水安全预警系统构建研究[J]. 矿业安全与环保, 2009, 36(1): 58-60.
SUI Haibo, CHENG Jiulong. Study on construction of early warning system of floor water inrush in mine working face[J]. Mining Safety & Environmental Protection, 2009, 36(1): 58-60.
- [19] 王博辉. 矿井水害预警方法研究及实现 [D]. 西安: 西安科技大学, 2012.
- [20] 张明. 煤矿安全预警管理及系统研究 [D]. 太原: 太原理工大学, 2004.
- [21] 蔡明锋, 程久龙, 隋海波, 等. 矿井工作面水害安全预警系统构建[J]. 煤矿安全, 2009, 40(9): 50-53.
CAI Mingfeng, CHENG Jiulong, SUI Haibo, et al. Construction of early warning system of water disaster in coal mine working face[J]. Safety in Coal Mines, 2009, 40(9): 50-53.
- [22] 吴晓建, 危一华, 王爱春, 等. 基于融合 Dropout 与注意力机制的 LSTM-GRU 车辆轨迹预测[J]. 湖南大学学报(自然科学版), 2023, 50(4): 65-75.
WU Xiaojian, WEI Yihua, WANG Aichun, et al. Vehicle trajectory prediction based on LSTM-GRU integrating dropout and attention mechanism[J]. Journal of Hunan University (Natural Sciences), 2023, 50(4): 65-75.
- [23] 程希. 基于机器学习的 Web 攻击检测系统及算法安全性研究 [D]. 南京: 南京邮电大学, 2021.