



移动扫码阅读

李建林,高培强,王心义,等.基于混沌-广义回归神经网络的矿井涌水量预测[J].煤炭科学技术,2022,50(4):149-155.

LI Jianlin, GAO Peiqiang, WANG Xinyi, et al. Prediction of mine water inflow based on Chaos- Generalized Regression Neural Network[J]. Coal Science and Technology, 2022, 50(4): 149-155.

基于混沌-广义回归神经网络的矿井涌水量预测

李建林^{1,2},高培强¹,王心义^{1,2},赵帅鹏¹

(1.河南理工大学 资源环境学院,河南 焦作 454000;2.煤炭安全生产与清洁高效利用省部共建协同创新中心,河南 焦作 454000)

摘要:针对矿井涌水量预测研究中存在的相关影响因素考虑较少、模型预测精度不高和适用性不强的问题,建立了混沌理论与广义回归神经网络耦合的新的预测模型(Chaos-GRNN模型)。从理论上分析了矿井水文系统产生混沌现象的机理;由混沌理论得到涌水量序列相空间重构后的嵌入维数、时间延迟和最大 Lyapunov 指数,以此确定 GRNN 的输入层神经元个数、取值和预测时长;采用交叉验证法获得 GRNN 的光滑因子,建立 Chaos-GRNN 模型;对平煤十二矿涌水量(2014 年 1 月至 2015 年 12 月)进行模型验证。结果表明:矿井水文系统演化过程的循环迭代是产生混沌的根本原因,其表象特征为演化过程的不可逆性、非平稳性和演化结果的多样性;平煤十二矿涌水量时间序列具有混沌特征,其嵌入维数 $m=7$,即涌水量的影响因素为 7 个,GRNN 输入层神经元个数为 7;时间延迟 τ 为 13 个月,由此确定了 GRNN 输入层神经元的取值;最大 Lyapunov 指数为 0.053 0,确定了 GRNN 预测时长为 19 个月;Chaos-GRNN 模型预测精度达到了 94.98%。该预测模型利用混沌理论量化了广义回归神经网络的输入层和预测时长,充分考虑了矿井涌水量的影响因素,提高了预测精度和适用性。

关键词:混沌理论;相空间重构;广义回归神经网络;输入层神经元;涌水量预测

中图分类号:TD745

文献标志码:A

文章编号:0253-2336(2022)04-0149-06

Prediction of mine water inflow based on Chaos- Generalized Regression Neural Network

LI Jianlin^{1,2}, GAO Peiqiang¹, WANG Xinyi^{1,2}, ZHAO Shuaipeng¹

(1. Institute of Resources & Environment, Henan Polytechnic University, Jiaozuo 454000, China;

2. State Collaborative Innovation Center of Coal Work Safety and Clean-efficiency Utilization, Jiaozuo 454000, China)

Abstract: A new prediction model (Chaos-GRNN model) coupled with chaos theory and generalized regression neural network was established to solve the problems of less consideration of relevant influencing factors, low model prediction accuracy and poor applicability in mine water inflow prediction research. The mechanism of chaotic phenomenon in mine hydrological system was theoretically analyzed; the embedding dimension, time delay and maximum Lyapunov exponent of the water inflow time series were calculated by chaos theory, so as to determine the number of neurons in the input layer of GRNN. The number and the value of input layer neurons, and the prediction duration of the model were determined by the m dimensions' sequence. The smoothing factor of GRNN was obtained by cross-validation method. Finally, the Chaos-GRNN model was established. As an example, the water inflow from January 2014 to December 2015 of Pingdingshan Coal Mine No.12 was predicted. The results show that: the cyclic iteration of mine hydrological system evolution process was the fundamental cause of chaos, and its representation features are irreversibility, nonstationarity and diversity of evolution results; the water inflow time series of Pingdingshan Coal Mine No.12 has chaotic characteristics, its embedding dimension $M=7$, that is, the influencing factors of water inflow are 7, and the number of neurons in the input layer of GRNN is 7; the time delay $\tau=13$ months, which determines the value of neurons in the input layer of GRNN; the maximum Lyapunov index is 0.053 0, and the prediction time of GRNN is 19 months; the prediction accuracy of the Chaos-GRNN model was 94.98%. Chaos-GRNN model used chaos theory to quantify the number and the value of input layer neurons, and prediction duration of the model. This model fully considered the influencing factors of mine water inflow, improved

收稿日期:2021-10-05

责任编辑:黄小雨

DOI:10.13199/j.cnki.est.2020-0772

基金项目:国家自然科学基金资助项目(41672240,41573095);河南省自然科学基金资助项目(182300410155)

作者简介:李建林(1973—),男,甘肃天水人,教授,博士。E-mail:lijianlin@hpu.edu.cn

both prediction accuracy and the applicability of model.

Key words: Chaos Theory; phase space reconstruction; Generalized Regression Neural Network; input layer neuron; prediction of water inflow

0 引言

矿井涌水量是指在单位时间内,矿山建设和生产过程中涌入井巷中的总水量。准确预测涌水量对于矿山安全生产具有重要作用^[1]。地表水体(大气降水、河流等)、开采条件(开采深度和规模、煤层围岩出露条件、上覆地层透水性等)、地质构造等因素都会对矿井涌水造成直接或间接的影响。学者们针对矿井涌水量的预测从确定性方法逐渐发展到非确定性随机预测,研究方法不断更新^[2-4]。但受水文地质条件复杂性的影响,确定性方法(解析法、水均衡法等)的计算结果往往会出现较大误差^[5];非确定性随机预测方法(水文地质比拟法、模糊数学模型、灰色系统理论、BP神经网络等)主要受限于实测资料的积累程度,而且这类方法对开采条件下矿井充水因素的动态变化考虑不够^[6]。整体而言,目前涌水量预测存在的主要问题是影响涌水量的因素认识不够、不能找出起决定作用的因素;或已找到起决定作用的因素,但这些因素的资料不全或数据难以获取,导致建模及预测过程简化。

混沌理论(Chaos Theory)可以让时间序列中隐藏的丰富的动力学信息得以恢复^[7],是研究复杂系统的有效工具。我国将其应用到矿井涌水量预测的研究始于1996年,经过20多年的发展,取得了一定的成果^[8-10]:①很多矿井的涌水量时间序列具有混沌特性;这在理论和实践中都得到了验证;②利用全域法、局域法、加权一阶局域法等进行涌水量短期预测,取得了较好结果。但与混沌理论在其他领域的研究相比,进展较为缓慢。直到2016年,才有学者将混沌理论与BP神经网络相结合,建立了新的涌水量预测模型^[11]。目前,基于混沌理论的涌水量预测的研究成果仅能实现对涌水量的短期预测,对煤矿安全生产和矿井水资源的利用意义不大。

人工神经网络(ANN)在时间序列模拟与预测上具有独特的优势。广义回归神经网络(GRNN)是一种径向基神经网络,它具有模型结构简单、调整参数少、学习速度快和预测准确性高的优点,适用于解决非线性问题。王雪冬等^[12]将涌水量的3个主要影响因素作为输入神经元,建立了GRNN的涌水量预测模型,预测效果较好。利用GRNN进行涌水量预测时,输入层神经元的个数及其取值(即涌水影

响因素的选择及其取值)是决定模型精度的关键。而往往有些影响因素的数据难以量化,或在众多影响因素中难以确定起关键作用的因素,导致GRNN模型具有较大的主观性和局限性。

混沌理论认为,一维的时间序列中蕴藏着大量的多维的相关因素的信息,而相关因素的个数和取值可通过相空间重构获得^[13]。鉴于此,本研究将混沌理论与GRNN结合在一起,利用涌水量时间序列相空间重构来确定GRNN输入层神经元的个数及其取值(减少单一GRNN模型的主观性和局限性),建立混沌-广义回归神经网络(Chaos-GRNN)模型,以实现矿井涌水量更有效的预测。

1 Chaos-GRNN 预测模型研究方法

1.1 相空间重构

相空间重构中,延迟时间 τ 和嵌入维数 m 选取十分关键。采用自相关函数法确定延迟时间 τ 。与复自相关法、重构展开法和互信息量法相比,该方法具有对时间序列要求低、计算简单的优势^[14];采用Cao方法确定嵌入维数 m ,该方法具有主观参数少(仅有1个主观参数 τ)、信号区分能力强、计算效率高的优点^[15]。

延迟时间 τ 和嵌入维数 m 确定后,进行涌水量时间序列 $X = \{x_1, x_2, \dots, x_n\}$ 的相空间重构,得到 m 维的向量序列 Y_i 为

$$Y_i = \{x_i, x_{i+\tau}, x_{i+(m-1)\tau}\} \quad (1)$$

其中: $i=1, 2, \dots, M, M=n-(m-1)\tau$ 。

1.2 最大 Lyapunov 指数

最大 Lyapunov 指数 $\lambda_{\max}$ 为系统是否具有混沌特征的辨识参数(若 $\lambda_{\max} > 0$,则系统具有混沌特征),也可以确定重构序列的预测步长 T ($T=1/\lambda_{\max}$)^[10]。计算 $\lambda_{\max}$ 的方法主要有定义法、Wolf法、Jacobian法、 p -范数法等;相比较而言,Wolf法运算更为简单^[14],本研究采用该方法计算 $\lambda_{\max}$ 。

以上方法在相关文献中有详细介绍^[14-15],此处不再赘述。

1.3 广义回归神经网络

GRNN的理论基础为概率统计中的最大似然原理:现实中发生的事件往往是概率最大的那个事件,即计算非独立输出变量 y 相对于独立输入变量 x 的非线性回归,得到具有最大概率的 y ^[16-17]。当给定

随机变量 x 的一个观测值为 x_0 时,随机变量 y 的估计值 $\hat{y}$ 为

$$\hat{y}(x_0) = \frac{\sum_{i=1}^n y_i e^{-d(x_0, x_i)}}{\sum_{i=1}^n e^{-d(x_0, x_i)}} \quad (2)$$

式中: $d(x_0, x_i) = (x_0 - x_i)^T (x_0 - x_i) / 2\sigma^2$, x_i, y_i 分别为随机变量 x 和 y 的样本观测值; n 为样本容量; σ 光滑因子(正态分布标准差)。

GRNN 由输入层、模式层、加和层和输出层组成^[18](图1)。




图1 GRNN 结构

Fig.1 Structural diagram of GRNN

1.4 Chaos-GRNN 模型

充分发挥混沌理论和 GRNN 各自的优势,将其有机地结合在一起,建立涌水量 Chaos-GRNN 预测模型,具体步骤如下:

1) 计算时间序列 $\{x_1, x_2, \dots, x_n\}$ 的延迟时间 τ 、嵌入维数 m 和最大 Lyapunov 指数 $\lambda_{\max}$ 。 m 为矿井涌水量影响因素的个数,并将其作为 Chaos-GRNN 模型的输入、模式层神经元的个数;输入神经元的取值由式(1)确定。 $T=1/\lambda_{\max}$ 确定 GRNN 模型的预测步长。

2) 将重构好的向量序列 Y_i 分成训练数据和验证数据两类(验证数据的个数为 $T-1$)。针对训练数据,基于 Matlab 神经网络工具箱,采用交叉验证的方法对 newgrnn() 函数的最佳 Spread 参数值进行寻优,得到光滑因子 σ 。然后,将训练好的输入层、模式层数据和优化参数相结合,构建 Chaos-GRNN 模型。

3) 导入验证数据 $(Y_j, Y_{j+1}, \dots, Y_{j+T-2})$, 进行模型验证。导出结果为: $Y_{j+T-1} = (x_{j+T-1}, x_{j+T-1+\tau}, \dots, x_{j+T-1+(m-1)\tau})$, 则 $x_{j+T-1+(m-1)\tau}$ 为 $j+T-1+(m-1)\tau$ 时刻的涌水量的预测值(验证过程须假设此时刻之前的涌水量已知)。

4) 预测下一时刻的涌水量。为保持预测长度为 T , 在导入数据中去掉 Y_j , 增加 Y_{j+T-1} 进行模拟。

由于上一时刻之前的涌水量已知,为提高预测精度,用实测涌水量代替预测值进行预测。导出结果为 $Y_{j+T} = (x_{j+T}, x_{j+T+\tau}, \dots, x_{j+T+(m-1)\tau})$, 则 $x_{j+T+(m-1)\tau}$ 为该时刻的涌水量的预测值。

5) 重复步骤4), 即可得到一个时期内的涌水量预测结果。

6) 预测结果用相对误差 (E_{AP})、平均相对误差 (E_{MAP}) 和精度 (P_p) 来量化:

$$E_{AP} = \left| \frac{x_k - \hat{x}_k}{x_k} \right|, k = 1, 2, \dots, n \quad (3)$$

$$E_{MAP} = \frac{1}{n} \sum_{k=1}^n \left| \frac{x_k - \hat{x}_k}{x_k} \right| \quad (4)$$

$$P_p = (1 - E_{MAP}) \times 100\% \quad (5)$$

式中: x_k 为实测值; $\hat{x}_k$ 为预测值。

2 研究区概况及数据来源

2.1 研究区及充水水源概述

平煤十二矿位于平顶山矿区东部,主采煤层为二组煤,二₁煤层底板灰岩水和采空区积水对煤矿安全生产的威胁较大;矿井正常涌水量为 129 m³/h, 矿井涌水量相对较小,但三水平生产以后,随着开采深度的增加和地质、构造条件的变化,矿井水害防治工作逐渐引起重视。涌水量直接来源为先期开采的采空区积水、煤层顶板砂岩水、煤层底板灰岩水,间接水源为大气降水和地表水。

2.2 涌水量数据来源及特征

根据 497 个月的涌水量实测数据(1976 年 2 月至 2015 年 12 月)进行建模和验证(图2)。选取 1976 年 2 月至 2012 年 12 月涌水量数据进行时间序列的相空间重构,并确定涌水量影响因素的个数;选取 2012 年 7 月至 2013 年 12 月涌水量数据进行 Chaos-GRNN 建模;2014 年 1 月至 2015 年 12 月的涌水量数据进行模型验证。




图2 平煤十二矿涌水量趋势

Fig.2 Monthly mine discharge curve of Coal Mine No.12

3 涌水量结果预测

3.1 相空间重构

利用自相关函数法求得涌水量时间序列的延迟时间 $\tau = 13$ 个月(图3);利用Cao方法求得其嵌入维数 $m = 7$ (图4),图4中 $E_1(m)$ 为嵌入维数公式中相同维数下距离变化均值的比值。利用公式(6)和式(7)计算得到 Lyapunov 指数 $\lambda = 0.053$ 。




图3 延迟时间 τ 与自相关系数 $C(\tau)$ 的关系

Fig.3 Relationship between time delay and autocorrelation coefficient




图4 嵌入维数 m 与 $E_1(m)$ 的关系

Fig.4 Relationship between m and $E_1(m)$

嵌入维数 $m = 7$, 表示矿井涌水量影响因素为 7 个, 以此确定 Chaos-GRNN 模型的输入层神经元的个数为 7。 $\lambda > 0$, 表明该时间序列具有混沌特征。 $T = 1/\lambda_{\max} = 18.86 \approx 19$, 即 Chaos-GRNN 模型的预测时长为 19 个月。

对平煤十二矿的涌水量时间序列进行重构, 得到一个时间延迟为 13 个月的 7 维向量空间 Y :

$$Y = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_{377} \\ Y_{378} \\ \vdots \\ Y_{401} \end{pmatrix} = \begin{pmatrix} x_1 & x_{14} & x_{27} & x_{40} & x_{53} & x_{66} & x_{79} \\ x_2 & x_{15} & x_{28} & x_{41} & x_{54} & x_{67} & x_{80} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ x_{377} & x_{390} & x_{403} & x_{416} & x_{429} & x_{442} & x_{455} \\ x_{378} & x_{391} & x_{404} & x_{417} & x_{430} & x_{443} & x_{456} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ x_{401} & x_{414} & x_{427} & x_{440} & x_{453} & x_{466} & x_{479} \end{pmatrix} \quad (6)$$

要利用 2014 年 1 月至 2015 年 12 月的涌水量数据 $\{x_{456}, x_{457}, \dots, x_{479}\}$ 对模型进行验证, 即: ① $x_1, x_2, \dots, x_{455}$ 已知, 为实测涌水量; ② 假设 $x_{456}, x_{457}, \dots, x_{479}$ 未知, 须利用所建模型预测; ③ 在式(6)中 $Y_{378} \sim Y_{401}$ 最后一列数未知, 所以须选取 Y_{378} 之前的向量进行训练。

3.2 涌水量预测

1) 预测 x_{456} 。选取 $Y_{360} \sim Y_{377}$ 共 18 个向量作为样本, 进行数据训练, 输出层输出 $\hat{Y}_{378}$:

$$\hat{Y}_{378} = (\hat{x}_{378}, \hat{x}_{391}, \hat{x}_{404}, \hat{x}_{417}, \hat{x}_{430}, \hat{x}_{443}, \hat{x}_{456}) \quad (7)$$

在式(7)中, $\hat{x}_{456}$ 即为 x_{456} 的预测值。

2) 预测 x_{457} 。为提高预测精度, 在式(7)中, 保留 $\hat{x}_{456}$, 其他值用实测值代替预测值, 记为 Y'_{378} :

$$Y'_{378} = (x_{378}, x_{391}, x_{404}, x_{417}, x_{430}, x_{443}, x_{456}) \quad (8)$$

选取 $(Y_{361}, Y_{362}, \dots, Y_{377}, Y'_{378})^T$ 共 18 个向量

作为样本, 进行训练, 输出 $\hat{Y}_{379}$:

$$\hat{Y}_{379} = (\hat{x}_{379}, \hat{x}_{392}, \hat{x}_{405}, \hat{x}_{418}, \hat{x}_{431}, \hat{x}_{444}, \hat{x}_{457}) \quad (9)$$

在式(9)中, $\hat{x}_{457}$ 即为 x_{457} 的预测值。

3) 重复以上步骤, 可得 $x_{458}, x_{459}, \dots, x_{479}$ 的预测值, 即平煤十二矿 2014 年 1 月至 2015 年 12 月的矿井涌水量的预测值(表 1)。

4) 预测过程中, 设光滑因子初值为 0.1, 步长为 0.1, 终值为 2, 通过循环交叉验证选定每次预测的最佳值(表 1)。

利用式(3)一式(5)对预测结果进行评估。由表 1 可以看出, Chaos-GRNN 模型预测值的最大误差为 12.98%, 最小误差为 0.001%, 平均误差为 5.02%, 预测精度达到了 94.98%。

4 讨 论

4.1 矿井水文系统产生混沌的机理

如果将矿井涌水作为研究主体, 把矿井涌水及其各影响因素视为一个整体, 则可称之为矿井水文系统。该系统具有明显的循环特征: 随着开采深度和开采面积等的增加, 矿井涌水量也随之增加; 矿井水文系统各要素通过自身的调节以适应这种改变, 逐步达到相对稳定的状态; 此时, 矿井水文系统完成一次演化过程。随着开采深度和开采面积等再一次改变并达到一定程度后, 矿井水文系统各要素也再次随之变化, 进入下一次循环(图 5)。

表 1 Chaos-GRNN 模型预测结果
Table 1 Chaos-GRNN model prediction results

日期(年-月)	实测值/ ($\text{m}^3 \cdot \text{h}^{-1}$)	σ	预测值/ ($\text{m}^3 \cdot \text{h}^{-1}$)	$E_{\text{AP}}/\%$	日期(年-月)	实测值/ ($\text{m}^3 \cdot \text{h}^{-1}$)	σ	预测值/ ($\text{m}^3 \cdot \text{h}^{-1}$)	$E_{\text{AP}}/\%$
2014-01	115	0.7	114.997	0.003	2015-01	99	0.4	111.417	12.541
2014-02	115	0.2	114.993	0.006	2015-02	99	0.3	112.850	13.989
2014-03	115	0.3	114.996	0.004	2015-03	100	0.5	112.795	12.795
2014-04	115	0.6	114.999	0.001	2015-04	102	0.1	111.994	9.798
2014-05	114	0.1	114.997	0.873	2015-05	115	0.6	112.573	2.111
2014-06	114	0.4	114.996	0.873	2015-06	113	0.4	112.722	0.246
2014-07	114	0.4	114.996	0.874	2015-07	114	0.8	112.972	0.902
2014-08	100	0.8	111.883	11.883	2015-08	112.3	0.9	112.972	0.598
2014-09	100	0.8	111.847	11.847	2015-09	112.2	0.7	112.943	0.662
2014-10	99	0.6	111.849	12.979	2015-10	112.2	0.1	112.945	0.664
2014-11	99	0.3	111.792	12.922	2015-11	112.1	0.6	113.075	0.870
2014-12	99	0.5	111.792	12.912	2015-12	112.3	0.9	112.543	0.216

该循环是在上一次循环结果的基础上进行的,所以可用迭代来描述;而迭代是系统形成混沌的主要机制。所以,矿井水文系统的演化过程具有混沌特征;演化过程的不可逆性、非平稳性和演化结果的多样性都是混沌特征的表现^[9]。




图 5 矿井水文系统演化过程

Fig.5 Evolution process of mine hydrological system

4.2 混沌理论和人工神经网络的优势

目前,涌水量预测存在的主要问题是影响涌水量主控因素的资料不全或难以量化。而按照混沌理论,嵌入维数 m 等于矿井涌水量影响因素的个数;各影响因素的取值即为重构后相空间的列向量 Y_i 。所以通过混沌理论可量化涌水量的主控因素。但 Y_i 的取值依旧是涌水量,而并非各影响因素的真正取值,

所以,这种量化不是完全的量化。这也导致了混沌理论的应用受阻。2013 年至今,利用混沌理论进行矿井涌水量预测基本处于停滞状态。

处理数据恰好是人工神经网络(ANN)的优势:ANN 通过强大的对样本的自适应、自学习功能,可以完成对输入神经元的有效输出,从而达到预测的目的;但由于 ANN 对涌水量影响因素选择的主观性、局限性,ANN 模型也未得到广泛的重视。

因此,混沌理论与 ANN 有机地结合在一起(相空间重构确定输入神经元的个数、取值,及预测时长),解决了影响因素选择的主观性、局限性问题;同时,也加深了人们对混沌理论更深入的理解,应该会对混沌理论发展和应用有所促进。

4.3 Chaos-GRNN 模型的适用性

1) 只要矿井水文系统具有混沌特征,理论上就可以对涌水量序列进行相空间重构,进而建立涌水量预测的 Chaos-GRNN 模型(图 6)。由矿井水文系统产生的机理和已有的研究表明,矿井水文系统具备了成为混沌系统的条件^[7-9,19-21]。




图 6 Chaos-GRNN 模型结构

Fig.6 Structural diagram of Chaos-GRNN model

2)在进行相空间重构和 GRNN 建模时,需要涌水量序列较长(至少连续 3~5 a 的涌水量观测值),才能保证建模的效果;而我国生产矿井都有专门的涌水量观测和处理的部门(一般在地测科),这些数据很容易获得。所以,Chaos-GRNN 模型具有很好的适用性。

3)目前,判断一个复杂系统是否具有混沌特征,常用的方法是最大 Lyapunov 指数法(该值大于 0 即说明系统具有混沌特征)。但如果计算得到的最大 Lyapunov 指数小于或等于 0,说明该涌水量不具有混沌特征或混沌特征不明显,建议采用其他方法进行涌水量的预测。

5 结 论

1)矿井水文系统具有循环迭代特征,具备了产生混沌现象的条件。

2)根据混沌理论和广义回归神经网络特有的优势,建立了涌水量预测的 Chaos-GRNN 模型。该模型利用相空间重构确定了矿井涌水量影响因素的数目及其取值,该值与 GRNN 输入层神经元的个数和取值相对应,模型预测时长由最大 Lyapunov 指数决定。

3)对平煤十二矿建立了涌水量预测的 Chaos-GRNN 模型,模型克服了以往模型对涌水量影响因素考虑不够和难以量化的缺点,预测精度达到了 94.98%。

参考文献(References):

- [1] 张耀辉,熊祖强,李西凡,等.复杂水文地质条件下矿井水害综合防治技术研究[J].煤炭科学技术,2021,49(3):167-174.
ZHANG Yaohui, XIONG Zuqiang, LI Xifan, *et al.* Study on technology of mine water disaster prevention and control in underground mine under complex hydrogeological conditions[J]. Coal Science and Technology, 2021, 49(3): 167-174.
- [2] 李建林,常晓峰,王 燕. 矿井涌水量的中长期混沌预测[J]. 河南理工大学学报,2017,36(5):23-28.
LI Jianlin, CHANG Xiaofeng, WANG Yan. Medium and long-term chaotic prediction of mine water consumption [J]. Journal of Henan Polytechnic University, 2017, 36(5): 23-28.
- [3] 贺晓浪,蒲治国,丁 湘,等. 矿井涌水量预测方法的改进及结果准确性判定[J]. 煤炭科学技术,2020,48(8):229-236.
HE Xiaolang, PU Zhiguo, DING Xiang, *et al.* Improved methods for prediction of mine water inflow and determination of accuracy of results[J]. Coal Science and Technology, 2020, 48(8): 229-236.
- [4] 陈韶知,刘树才,杨国勇.矿井涌水量预测方法的发展[J].工程地球物理学报,2009,6(1):68-72.
CHEN Mingzhi, LIU Shucan, YANG Guoyong. The development of prediction method for the inflow rate of mine water[J]. Chinese Journal of Engineering Geophysics, 2009, 6(1): 68-72.
- [5] 朱宗奎,黄鑫磊. 基于 Visual MODFLOW 的煤层底板突水量预测研究[J].煤炭科学技术,2020,48(8):157-163.
ZHU Zongkui, HUANG Xinlei. Study on water inrush quantity prediction from coal seam floor based on Visual MODFLOW [J]. Coal Science and Technology, 2020, 48(8): 157-163.
- [6] 贺晓浪,蒲治国,丁 湘,等. 矿井涌水量预测方法的改进及结果准确性判定[J].煤炭科学技术,2020,48(8):229-236.
HE Xiaolang, PU Zhiguo, DING Xiang, *et al.* Improved methods for prediction of mine water inflow and determination of accuracy of results [J]. Coal Science and Technology, 2020, 48(8): 229-236.
- [7] 汤 琳,杨永国. 混沌时间序列分析及应用研究[J]. 武汉理工大学学报,2010,32(19):189-192.
TANG Lin, YANG Yongguo. Chaotic time series analysis and its application research[J]. Journal of Wuhan University of Technology, 2010, 32(19): 189-192.
- [8] 唐依民. 矿区地下水系统及其特征分析[J]. 湖南地质,1996,15(2):93-98.
TANG Yimin. Underground water system in mining areas and their properties[J]. Hunan Geology, 1996, 15(2): 93-98.
- [9] 唐依民,肖 江. 矿区地下水系统演化过程中混沌性态形成的条件及机理[J]. 煤炭学报,2006,31(1):45-49.
TANG Yimin, XIAO Jiang. Condition and mechanism about chaos formation in the evolution process of groundwater system of mining area[J]. Journal of China Coal Society, 2006, 31(1): 45-49.
- [10] 汪 伟,罗周全,王益伟,等. 基于混沌理论的矿井涌水量预测研究[J]. 中国安全科学学报,2013,23(4):52-57.
WANG Wei, LUO Zhouquan, WANG Yiwei, *et al.* Research into mine water inflow forecast based on chaotic theory [J]. China Safety Science Journal, 2013, 23(4): 52-57.
- [11] 邓 高,杨 珊,江时雨,等. 相空间重构和混沌遗传神经网络融合的矿井涌水量研究[J]. 世界科技研究与发展,2016,38(5):973-978.
DENG Gao, YANG Shan, JIANG Shiyu, *et al.* Study on mine water consumption by phase space reconstruction and chaotic genetic neural network fusion[J]. World Science and Technology Research and Development, 2016, 38(5): 973-978.
- [12] 王雪冬,董 慧. 基于广义回归神经网络的矿井涌水量预测[J]. 中国安全生产科学技术,2014,10(11):90-93.
WANG Xuedong, DONG Hui. Prediction of mine water inflow based on generalized regression neural network [J]. China Safety Production Science and Technology, 2014, 10(11): 90-93.
- [13] 吕金虎,陆君安,陈士华. 混沌时间序列分析及其应用[M]. 武汉:武汉大学出版社,2002.
- [14] 张淑清,贾 健,高 敏,等. 混沌时间序列重构相空间参数选取[J]. 物理学报,2010,59(3):1576-1582.
ZHANG Shuqing, JIA Jian, GAO Min, *et al.* Research on phase space parameters selection of chaotic time series reconstruction [J]. Acta Physica Sinica, 2010, 59(3): 1576-1582.
- [15] 孟 力,毕叶平. 相空间重构文献综述可视化分析[J]. 系统仿真学报,2017,29(12):3167-3175.
MENG Li, BI Yeping. Visualization analysis of literature review of phase space reconstruction [J]. Journal of System Simulation, 2017, 29(12): 3167-3175.

- 2017,29(12):3167-3175.
- [16] 李军红,刘锁清,董森,等. 广义回归神经网络对脱硫效率的预测[J]. 自动化技术与应用,2018,37(10):34-37.
LI Junhong, LIU Suoqing, DONG Sen, *et al.* Prediction of desulfurization efficiency by generalized regression neural network [J]. Automation Technology and Applications, 2018, 37(10):34-37.
- [17] 郝建浩,唐德善,尹 笋,等. 基于广义回归神经网络模型的径流预测研究[J]. 水电能源科学,2016,34(12):49-52.
HAO Jianhao, TANG Deshan, YIN Sun, *et al.* Research on runoff prediction based on general regression neural network model[J]. Hydropower Science, 2016, 34(12):49-52.
- [18] 郝丽娜,粟晓玲,黄巧玲. 基于小波广义回归神经网络耦合模型的月径流预测[J]. 水利发电学报,2016,35(5):47-54.
HAO Lina, SU Xiaoling, HUANG Qiaoling. Monthly runoff prediction based on wavelet generalized regression neural network coupled model [J]. Journal of Hydraulic Engineering, 2016, 35(5):47-54.
- [19] 黄存捍,冯 涛,王卫军,等. 基于分形和支持向量机矿井涌水量的预测[J]. 煤炭学报,2010,35(5):806-810.
HUANG Cunhan, FENG Tao, WANG Weijun, *et al.* Mine water inrush prediction based on fractal and support vector machines [J]. Journal of China Coal Society, 2010, 35(5):806-810.
- [20] 黄存捍,陈魁奎,李振华,等. 基于相空间重构和支持向量机的矿井涌水量预测[J]. 河南理工大学学报(自然科学版), 2016, 35(2):202-205.
HUANG Cunhan, CHEN Kuikui, LI Zhenhua, *et al.* Mine water inrush prediction based on phase space reconstruction and support vectormachines [J]. Journal of Henan Polytechnic University (Natural Science), 2016, 35(2):202-205.
- [21] 汪吉林,姜 波. 矿井构造系统的混沌时间序列分析[J]. 煤田地质与勘探,2005,33(4):21-24.
WANG Jilin, JIANG Bo. Analytic method about chaos time-series in mine geologic structure [J]. Coal Geology & Exploration, 2005, 33(4):21-24.