

侯恩科,徐林啸,荣统瑞.彬长大佛寺矿井涌水量时序预测[J].西安科技大学学报,2024,44(3):490-500.

HOU Enke, XU Linxiao, RONG Tongrui. Time series prediction of mine water inflow from Binchang Dafosi mine[J]. Journal of Xi'an University of Science and Technology, 2024, 44(3): 490-500.

彬长大佛寺矿井涌水量时序预测

侯恩科^{1,2}, 徐林啸^{1,2}, 荣统瑞³

(1. 西安科技大学 地质与环境学院, 陕西 西安 710054;

2. 陕西省煤炭绿色开发地质保障重点实验室, 陕西 西安 710054;

3. 青海盐湖工业股份有限公司, 青海 格尔木 816000)

摘要:为提高矿井涌水量预测精度,解决矿井涌水量预测无法及时响应动态变化的问题,构建一种基于模态分解和深度学习的矿井涌水量多因素时间序列组合预测模型。使用变分模态分解和灰色关联分析筛选主控因素,通过双向长短期记忆网络和卷积长短期记忆网络对高、低频模态分量进行预测。结果表明:对比不同时序预测模型,变分模态分解可以有效捕捉时序数据中的长期依赖关系,提供了更加准确的长期时序数据预测能力;经过鲸鱼优化、贝叶斯优化算法对不同频率模态分量的处理,有效降低了高频部分的无序性、复杂性并优化了较为线性、缓慢的低频部分;验证了矿井涌水量时序预测中的变分模态深度学习组合模型的有效性和适用性,预测精度满足生产需求。该理论丰富了矿井涌水量时序预测方法,对煤矿水害预防具有一定的理论意义。

关键词:模态分解;深度学习;时间序列;多因素序列降维;矿井涌水量预测

中图分类号:TD 742

文献标志码:A

文章编号:1672-9315(2024)03-0490-11

DOI:10.13800/j.cnki.xakjdx.2024.0309

开放科学(资源服务)标识码(OSID):



Time series prediction of mine water inflow from Binchang Dafosi mine

HOU Enke^{1,2}, XU Linxiao^{1,2}, RONG Tongrui³

(1. College of Geology and Environment, Xi'an University of Science and Technology, Xi'an 710054, China;

2. Shaanxi Provincial Key Laboratory of Geological Support for Coal Green Exploitation,

Xi'an University of Science and Technology, Xi'an 710054, China;

3. Qinghai Salt Lake Industry Co., Ltd., Golmud 816000, China)

Abstract: To enhance the accuracy of mine water inflow predictions and address the current inability of these forecasts so as to respond promptly to dynamic changes, a multifactorial time-series combination forecast model for mine water inflow was developed, based on modal decomposition and deep learning. The model employs variational modal decomposition and grey relational analysis to select the main controlling factors, and predicts high and low frequency modal components through bidirectional long short-term memory networks and convolutional long short-term memory networks. The results that: compared to different time series prediction models, variational modal decomposition can effectively capture long-

收稿日期:2023-10-15

基金项目:国家自然科学基金项目(42177174)

通信作者:侯恩科,男,陕西扶风人,教授,博士生导师, E-mail:584156788@qq.com

term dependencies in time series data, thus exhibiting a more accurate long-term time series prediction capability; after processing different frequency modal components with whale optimization and Bayesian optimization algorithms, the disorder and complexity of the high-frequency part were effectively reduced, and the more linear and slow low-frequency part was optimized; through error assessment, the effectiveness and applicability of the variational modal deep learning combination model in mine water inflow time series prediction were verified, and its predictive accuracy meets production requirements. The model has better predictive performance and higher accuracy in the field of mine water inflow prediction, and one more method of mine water inflow time series prediction has been added, a theoretical significance for the prevention of water hazards in coal mines.

Key words: modal decomposition; depth learning; time series; multi-factor series dimensionality reduction; mine water inflow prediction

0 引言

准确预测涌水量对矿井排水能力设计、改造和水害防治具有重要意义。目前矿井涌水量预测方法主要有水文地质比拟法^[1]、回归分析法^[2]、模糊数学法^[3]、灰色理论法^[4]、人工神经网络^[5]、数值模拟法^[6]、大井法^[7]和时间序列分析法^[8]。随着智慧矿山的不断发展和深度学习在人工智能领域发展逐渐成熟^[9-10],且时间序列预测在处理矿井涌水量大量监测数据方面具有较大优势,深度学习算法被应用于矿井涌水量时序预测方法研究^[11-12]。

刘黎明首次将时间序列的多层送阶预报方法用于矿区地下水动态预测^[13];杨永国等运用多变量时间序列分析方法,建立了矿井涌水量与降雨量之间的相关模型^[14];汤琳等利用非线性时间序列分析揭示了矿井涌水的非线性特征,为矿井涌水量预测提供了新方法^[15];陈玉华等通过对矿井涌水量时间序列资料的分析,分析了矿井涌水量时间序列的混沌特征^[16];曲兴玥等通过时间序列乘法分解模型对涌水量序列的趋势-循环因子、季节变动、不规则变动进行提取,对青龙煤矿月最大涌水量进行预测^[17];田罡豪等基于R/S分析法对矿井涌水量时间序列进行了分形刻画,结合灰色预测理论对某矿井涌水量进行了定量预测,时间序列具有长程相关性,且持续性极强^[18];刘慧等针对随时间无明显变化规律的涌水量序列,提出了变分模态分解和深度置信网络相结合的高效时间序列预测模型^[19];侯恩科等以小庄煤矿矿井涌水量数据进行试验,将CEEMDAN-BO-BiGRU预测结果与其他多种预测模型结果进行对比分析^[20],为

涌水量的短时预测提供了一种新思路。

1 模型原理

1.1 变分模态分解

变分模态分解是一种在经验模态分解的基础上改进的分解算法,是一种用于信号处理的方法,旨在将非线性和非平稳信号分解成多个固有模态函数,以实现降重。通过引入时间和频率域的正则化约束,逐步提取信号中不同频率的分量,并对每个分量进行去噪和降重处理,得到一组干净、精细且易于分析的信号模态。这些模态可以应用于信号识别、分类、压缩和重构等任务,提高信号处理效率和准确性^[21]。

1.2 贝叶斯优化算法

贝叶斯优化算法是用于参数调优的优化方法,通过建立概率模型来估计目标函数的行为,并根据这个模型进行迭代优化,以找到全局最优解^[22]。贝叶斯优化算法基于先验知识构建了一个高斯过程模型,用于描述目标函数在参数空间中的分布情况。通过选择下一个采样点来进行优化迭代,在未探索的区域寻找可能的最优解,利用基于已有数据中的最优解进行搜索。这样可以平衡全局搜索和局部搜索之间的权衡,提高搜索效率。在每次迭代中贝叶斯优化算法会根据当前的高斯过程模型,计算出一个目标函数的改进度量,用于选择下一个采样点。评估目标函数在采样点处的值,更新高斯过程模型的参数,随着迭代的进行,模型会不断地收敛于最优解(图1)。

1.3 双向长短期记忆网络

双向长短期记忆网络由前向长短期记忆网络和后向长短期记忆网络共同组成,前向长短期记

忆网络处理时间序列的历史信息,后向长短期记忆网络处理时间序列的未来信息,可对时序数据的正向和逆向信息进行同时处理(图2),能够挖掘矿井涌水量数据中所包含的时序信息^[23]。




图1 贝叶斯优化算法流程

Fig. 1 Flow of Bayesian optimization algorithm




图2 双向长短期记忆网络流程

Fig. 2 Flow of bi-directional long short-term memory network

1.4 鲸鱼优化算法

鲸鱼优化算法是一种模拟座头鲸狩猎行为元启发式优化算法。算法中每个座头鲸的位置代表一个潜在解,不断更新鲸鱼的位置,最终获得全局最优解(图3)。

组合模型中鲸鱼优化算法对卷积长短期记忆网络模型参数优化实质上是通过鲸鱼优化算法的迭代更新寻找最优的网络参数^[24],模拟鲸鱼捕猎、攻击及搜索猎物的方式进行优化。




图3 鲸鱼优化算法流程

Fig. 3 Flow of whale optimization algorithm

1.5 卷积长短期记忆网络

卷积神经网络作为深度学习的一种重要算法,在数据处理方面具有较大优势,但卷积神经网络在处理时间相关性强的数据时,表现出较差的泛化能力^[25];卷积长短期记忆网络结合了卷积神经网络和长短期记忆网络的优点,模型的第一部分是由卷积层和最大值组成的卷积神经网络部分池化层,对原始数据进行预处理并输入至卷积神经网络卷积层,利用卷积核自适应提取生命特征,将卷积核权重与局部序列进行卷积运算得到初步的特征矩阵。使用池化层的池化操作对提取的特征进行数据降维,避免模型过拟合,保留数据主要特征;池化后连接一个长短期记忆网络层,提取相关向量由卷积神经网络构造一个长期的时间序列作为长短期记忆网络的输入数据;卷积层通过数据展平的方式将数据压缩成一个长高宽通道的一维数组,可以添加直接密集层(图4)。

1.6 灰色关联与主成分分析

灰色关联分析是一种根据历史数据与目标的隐含关联性去量化两者相关性的方法。针对矿井涌水量的众多影响因素,采用灰色关联分析筛选出主控因素,剔除关联度不高的因素,降低这些因素对矿井涌水量预测的影响^[26]。

主成分分析可以对多个指标通过线性变化转换为线性无关的综合指标,各综合指标即为主成分,根据主成分累计贡献率选取贡献率大的主成分代替原指标实现对数据的降维^[27-28]。

1.7 模态分解和深度学习组合模型

通过中心频率法确定变分模态分解数量,将矿井涌水量时序数据分解为高频模态分量和低频模态分量;通过灰色关联分析对多元因素序列进行预处理,筛选出众多影响因素中的主控因素,并将主控因素序列通过变分模态分解为各主控因素

序列分量;所得主控因素各分量序列做主成分分析,去除相关程度较低的分量序列,最终将其余分量汇总作为各预测模型的多元因素输入;利用贝叶斯优化双向长短期记忆神经网络模型对较复

杂、无序以及非线性的高频部分进行预测,利用鲸鱼优化卷积长短期记忆网络模型对较为线性的低频部分进行预测;整理各部分预测值,得到矿井涌水量的最终预测值(图5)。




图4 卷积长短期记忆神经网络模型流程

Fig. 4 Flow of the convolutional long-short-term memory neural network model




图5 组合模型流程

Fig. 5 Flow of the composite model

2 模型应用

2.1 预测数据选取

选取陕西彬长矿区大佛寺矿井2013年1月至2022年12月共计120组矿井涌水量月监测数据作为矿井涌水量时间序列。根据前人对大佛寺矿井影响因素的研究^[29],将影响矿井涌水量的多元因素序列初步选取开采深度、煤层厚度、含水层厚度、隔水层厚度、月采煤量、月降雨量、采空区面积和开拓延伸长度8个具有代表性且易于量化表达

的影响因素,将数据的前90组序列作为训练集,后30组时序数据作为测试集(图6)。

2.2 矿井涌水量数据时序分解

为提高模型预测精度,采用变分模态分解算法分解矿井涌水量时序数据,为防止数据过分解或欠分解,通过中心频率法确定模态数量,分别设置模态数量为3,4,5,6,7,8,得到不同模态数量下每一个模态分量的中心频率。

当模态数量 ≤ 6 时,分量间的中心频率差值相对较大且随着模态数量的增加而逐渐减小;当模态数量为7时,模态分量7和模态分量8的中心频率分别为0.072 1,0.071 0,与其他几个模态分量之间的倍数关系相比,模态分量7和模态分量8的中心频率相对较小,可认为模态数量分解为7时数据被过度分解(表1)。各子序列呈现一定的周期性和规律性,可有效表征矿井涌水量时间序列的非线性特征,使得采用深度学习对实现高精度预测变为可能。其中高频分量部分的模态分量1、模态分量2、模态分量3和模态分量4显示了矿井涌水量时间序列的震荡频率,低频分量部分的模态分量5和模态分量6是矿井涌水量时间序列的趋势项,显示出矿井涌水量的长期走势特点(图7)。

2.3 多元因素序列降维

通过灰色关联分析得到各影响因素与矿井涌水量之间的关联度(图8),8个影响因素的关联度




图6 原始序列数据划分结果

Fig. 6 Partition results of original sequence data




图7 矿井涌水量数据时序分解结果

Fig. 7 Results of time series decomposition of mine water inflow data

表 1 不同模态数量下模态分量的中心频率
Table 1 Center frequency of modal components
with different number of modes

模态数量	3	4	5	6	7	8
模态分量 1	0.198 8	0.454 7	0.381 8	0.443 9	0.450 0	0.459 9
模态分量 2	0.041 9	0.218 1	0.210 7	0.301 6	0.317 1	0.377 2
模态分量 3	0.000 4	0.042 2	0.117 9	0.179 8	0.209 8	0.289 5
模态分量 4		0.000 3	0.036 3	0.107 1	0.137 0	0.198 7
模态分量 5			0.000 3	0.033 3	0.072 1	0.132 5
模态分量 6				0.000 2	0.033 1	0.071 0
模态分量 7					0.000 2	0.033 0
模态分量 8						0.000 2

均高于 0.6,当关联度大于 0.8 时,认为关联性很好,因此初步选取关联度在 0.8 以上的影响因素作为主控因素。开采深度和月降雨量、煤层厚度和采空区面积、含水层厚度和隔水层厚度的关联度较为接近,说明这 3 组因素对矿井涌水量的影响效果相一致,只需保留关联度较高的因素即可。

确定将开采深度、煤层厚度、含水层厚度和开拓延伸长度共 4 个因素作为模型的主控因素序列。筛选出主控因素后,利用中心频率法对 4 个主控因素序列进行分解后分别得到 5,7,8,3 个模态分量,

将分解后的各主控因素序列的模态分量分别和矿井涌水量做主成分分析,完成数据降维(表 2)。当主成分贡献率累计值达到 85% 以上,能够保证降维后的主控因素序列包含充分的原始信息。为了更充分地保证信息量,在 85% 的基础上选取贡献率达到 90% 的主成分进行后续的模式分量汇总。因此,分别选取前 4,3,3,1 个主成分,并将各主成分进行再次重构得到新的主控因素序列作为后续模型的因素输入层(图 9)。




图 8 灰色关联分析结果
Fig. 8 Results of grey correlation analysis

表 2 主成分分析结果
Table 2 Results of principal component analysis

主控因素	特征值贡献率							
	模态分量 1	模态分量 2	模态分量 3	模态分量 4	模态分量 5	模态分量 6	模态分量 7	模态分量 8
开采深度	42.93	75.37	89.15	96.84	100			
煤层厚度	44.87	77.69	91.49	95.16	97.25	98.85	100	
含水层厚度	62.53	88.79	95.06	96.89	98.04	99.02	99.61	100
开拓延伸长度	99.52	99.84	100					

2.4 模型超参数确定

为提升预测性能,利用贝叶斯优化算法分别对各高频分量在双向长短期记忆网络预测模型的隐藏层神经元个数、初始学习率、训练周期和步长各超参数进行优化及确定,并将时间滑动窗口设置为 10,批处理大小设置为 16(表 3);采用鲸鱼优化算法分别对各低频分量在卷积长短期记忆网络预测模型,初始学习率、训练周期和步长各超参数进行优化及确定,并将时间滑动窗口设置为 10,池化层神经元个数设置为 2,卷积核个数设置为 64,卷积核尺寸设置为 3(表 4)。

表 3 贝叶斯优化算法结果

高频分量	神经元个数	初始学习率	训练周期	步长
模态分量 1	177	0.004 3	198	12
模态分量 2	189	0.021 1	165	9
模态分量 3	90	0.090 5	99	6
模态分量 4	36	0.049 5	177	3

表 4 鲸鱼优化算法结果

低频分量	神经元个数	训练周期	步长
模态分量 5	0.010 0	909.87	623.30
模态分量 6	0.005 7	544.95	824.86




图9 主控因素重构序列

Fig. 9 Reconstitution sequence of the master factors




图10 各模态分量预测值与实际值对比

Fig. 10 Comparison of predicted values and actual values of each modal component

3 矿井涌水量预测结果分析

3.1 分量模型预测结果分析

通过对各高、低频分量分别构建贝叶斯优化双向长短期记忆网络模型和鲸鱼优化卷积长短期记忆网络模型,并经过反复训练后得出各模态分量模型的预测结果(图10)。各分量模型预测结果曲线与实际曲线在总体上较为贴合,绝对误差总体上在0~50 m³/h(表5)。

表5 各模态分量模型预测结果绝对误差特征

Table 5 Absolute error characteristics of prediction results of each modal component model

模态分量	绝对误差/(m ³ ·h ⁻¹)		
	最小值	最大值	平均值
模态分量1	0.029 1	15.955 9	6.446 7
模态分量2	0.887 4	48.273 7	11.167 0
模态分量3	2.372 4	20.730 3	9.907 1
模态分量4	0.641 6	17.838 0	9.547 1
模态分量5	0.522 4	24.137 5	10.975 7
模态分量6	0.645 1	12.076 1	3.852 3

3.2 变分模态分解时序分解有效性分析

为验证变分模态分解时序分解组合模型方法的有效性,将模态分解和深度学习组合模型与各类时序模型的预测结果进行对比分析(图11)。组合模型的预测结果与实测值的拟合度明显高于另

外 6 组模型。其中没有经过时序分解的单一预测模型错峰、错谷、延时的问题较为突出,而与经验模态分解方法相组合的预测模型只是在一定程度上缓解了单一模型出现的问题,经过变分模态分解的组合预测模型能够较为理想的预测坡、峰、谷等特征序列(表 6),模型预测效果提升较为显著。

经过变分模态分解的预测模型相较于经过经验模态分解的预测模型,预测精度下降的较为明显,说明利用变分模态分解将原始非平稳数据分解为多组平稳性较强的子序列,降低了数据的非

平稳性和复杂度,从而提高了模型的预测精度。模态分解深度学习组合模型与模态贝叶斯双向长短期模型和模态鲸鱼卷积长短期模型相比,预测精度平均绝对误差、均方误差、均方根误差、平均绝对百分比误差分别降低了 7.086 0,354.307 6,6.038 1 m^3/h 、1.407 9% 和 13.190 6,1301.270 6,18.334 3 m^3/h 、2.764 3%,模型的预测性能得到有效提升,说明了多元因素序列降维方法的有效性,验证了组合模型在矿井涌水量时序预测方面的适用性。




图 11 时序分解有效性模型预测结果对比

Fig. 11 Comparison of prediction results of time series decomposition validity models

表 6 时序分解有效性模型预测精度指标对比

Table 6 Comparison of prediction accuracy index of time series decomposition validity model

预测模型	平均绝对误差/ ($\text{m}^3 \cdot \text{h}^{-1}$)	均方误差/ ($\text{m}^3 \cdot \text{h}^{-1}$)	均方根误差/ ($\text{m}^3 \cdot \text{h}^{-1}$)	平均绝对百分比误差/%
模态分解深度学习组合模型	20.572 1	692.746 7	26.320 1	5.108 5
模态贝叶斯双向长短期模型	27.658 1	1 047.054 2	32.358 2	6.516 5
模态鲸鱼卷积长短期模型	33.762 7	1 994.017 3	44.654 4	7.872 9
经验贝叶斯双向长短期模型	56.985 8	4 765.758 7	69.034 5	12.872 9
经验鲸鱼卷积长短期模型	87.502 8	11 848.831 1	108.852 3	20.143 9
贝叶斯双向长短期模型	92.492 7	12 051.018 7	109.777 1	20.398 3
鲸鱼卷积长短期模型	121.402 0	26 769.547 1	163.614 0	22.238 0

3.3 组合模型预测结果对比分析

为验证变分模态与深度学习组合时序模型在矿井涌水量预测方面的精确度,分别选取模态双向门控循环网络模型、模态门控循环网络模型、模态长短期记忆网络模型、模态极端梯度树模型、模态反向传播网络模型、模态支持向量机模型与模态分解深度学习组合模型进行对比。经过变分模态分解预测与实测曲线的大致趋势基本相同,曲线贴合程度相对较高,没有明显的错峰、错谷和延时的问题,说明变分模态分解算法的优势(图 12)。

在波峰、波谷、极值以及拐点处的拟合效果均明显优于其余对比模型,说明了模型对高、低频分量分别构建相应预测模型的必要性,与变分模态极端梯度提升树模型预测精度进行对比(表 7),预测指标平均绝对误差、均方误差、均方根误差和平均绝对百分比误差分别下降了 19.606,1 775.564,23.362 m^3/h 、4.011 3%,预测精度提升较为显著,验证了组合模型在矿井涌水量预测方面的适用性和优越性。




图 12 各组合模型预测结果对比

Fig. 12 Comparison of prediction results of different combined models

表 7 各组合模型预测精度指标对比

Table 7 Comparison of prediction accuracy indexes of each combined model

预测模型	平均绝对误差/ ($\text{m}^3 \cdot \text{h}^{-1}$)	均方误差/ ($\text{m}^3 \cdot \text{h}^{-1}$)	均方根误差/ ($\text{m}^3 \cdot \text{h}^{-1}$)	平均绝对百 分比误差/%
模态分解深度学习组合模型	20.572 1	692.746 7	26.320 1	5.108 5
模态双向门控循环网络模型	63.094 9	4 599.635 5	67.820 6	13.601 6
模态门控循环网络模型	54.000 5	3 776.396 7	61.452 4	12.802 0
模态长短期记忆网络模型	65.606 4	6 543.984 3	80.894 9	13.461 3
模态极端梯度树模型	40.178 5	2 468.311 0	49.682 1	9.119 9
模态反向传播网络模型	47.075 6	3 074.103 4	55.444 6	10.899 1
模态支持向量机模型	80.991 3	10 524.471 2	102.588 8	16.226 2

4 结 论

1)模态分解深度学习组合模型对比模态贝叶斯双向长短期模型和模态鲸鱼卷积长短期模型预测精度平均绝对误差、均方误差、均方根误差、平均绝对百分比误差分别降低了 7.086 0,354.307 6,6.038 1 m^3/h 、1.407 9%和 13.190 6,1 301.270 6,18.334 3 m^3/h 、2.764 3%,降低了数据的复杂性,优化了序列非平稳性,成功解决了时序预测中出现的错峰、错谷和延时问题。验证了变分模态分解在矿井涌水量时序预测上的有效性。

2)模态分解深度学习组合模型与对比模型中预测效果最好的模态极端梯度树模型,预测指标平均绝对误差、均方误差、均方根误差和平均绝对百分比误差分别下降了 19.606,1 775.564,23.362 m^3/h 、4.011 3%,预测精度提升显著,验证了不同频率下分别优化的组合模型在矿井涌水量预测方面对比单因素短时时序预测的适用与优越性。

参考文献(References):

[1] 苗霖田,贺晓浪,张建军,等. 矿井涌水量的时间序列分析-水文地质比拟法预测[J]. 中国煤炭,2017,43(3):32-35.
MIAO Lintian, HE Xiaolang, ZHANG Jianjun, et al. Time series analysis-hydrogeological analogy method for mine water inflow prediction[J]. China Coal, 2017, 43(3):32-35.

[2] 李建林,高培强,王心义,等. 基于混沌-广义回归神经网络的矿井涌水量预测[J]. 煤炭科学技术,2022,50(4):149-155.
LI Jianlin, GAO Peiqiang, WANG Xinyi, et al. Prediction of mine water inflow based on Chaosge-Geralized Regression Neural Network[J]. Coal Science and Technology, 2022, 50(4):149-155.

[3] 苗阶,刘帅,刘超. 模糊数学在预测大孤山铁矿深部涌水量中的应用[J]. 地质找矿论丛,2014,29(2):295-298.
MIAO Jie, LIU Shuai, LIU Chao. Application of fuzzy mathematics to forecasting upwelling volume of water to

- depth of Dagushan iron mine[J]. Contributions to Geology and Mineral Resources Research, 2014, 29(2): 295-298.
- [4] 范军平,程国志. 基于灰色理论的矿井涌水量预测研究[J]. 能源与环保, 2017, 39(8): 178-181.
FAN Junping, CHENG Guozhi. Prediction of mine water inflow based on gray theory[J]. China Energy and Environmental Protection, 2017, 39(8): 178-181.
- [5] 邓高,杨珊,江时雨. 相空间重构和混沌遗传神经网络融合的矿井涌水量预测研究[J]. 世界科技研究与发展, 2016, 38(5): 973-978.
DENG Gao, YANG Shan, JIANG Shiyu. Mine water inflow prediction research based on phase space reconstruction and Chaotic Genetic Neural Network [J]. World Sci-Tech R&D, 2016, 38(5): 973-978.
- [6] 马青山,骆祖江. 矿井涌水量预测三维数值模拟[J]. 西安科技大学学报, 2015, 35(2): 236-241.
MA Qingshan, LUO Zujang. Three-dimensional numerical simulation for predicting mine water inflow[J]. Journal of Xi'an University of Science and Technology, 2015, 35(2): 236-241.
- [7] 张子祥,李文鑫. 矿井涌水量预测方法的比较研究——以甘肃大庄煤矿为例[J]. 西北地质, 2022, 55(3): 355-360.
ZHANG Zixiang, LI Wenxin. Comparative study on prediction methods of mine water inflow: A case study of Dazhuang coal mine in Gansu province [J]. Northwestern Geology, 2022, 55(3): 355-360.
- [8] 齐晓峰,邵良杉,邢雨艳. 基于 EMD 的矿井涌水量 ARMA 预测模型[J]. 辽宁工程技术大学学报(自然科学版), 2020, 39(6): 509-513.
QI Xiaofeng, SHAO Liangshan, XING Yuyan. ARMA prediction model of mine water inflow based on EMD [J]. Journal of Liaoning Technical University (Natural Science) 2020, 39(6): 509-513.
- [9] 张淑清,李君,姜安琦,等. 基于 FPA-VMD 和 BiLSTM 神经网络的新型两阶段短期电力负荷预测[J]. 电网技术, 2022, 46(8): 3269-3279.
ZHANG Shuqing, LI Jun, JIANG Anqi, et al. A novel two-stage model based on FPA-VMD and BiLSTM neural network for short-term power load forecasting [J]. Power System Technology, 2022, 46(8): 3269-3279.
- [10] 丁同,傅晓锦,刘明旺. 基于 GA-VMD-BiLSTM 算法的风电功率预测[J]. 扬州大学学报(自然科学版), 2022, 25(4): 44-49.
DING Tong, FU Xiaojin, LIU Mingwang. Research on wind power prediction based on GA-VMD-BiLSTM algorithm [J]. Journal of Yangzhou University (Natural Science Edition), 2022, 25(4): 44-49.
- [11] 黄欢. 矿井涌水量预测方法及发展趋势[J]. 煤炭科学技术, 2016, 44(S1): 127-130.
HUANG Huan. Prediction method of mine water inflow and its development [J]. Coal Science and Technology, 2016, 44(S1): 127-130.
- [12] 王晓蕾. 煤矿开采矿井涌水量预测方法现状及发展趋势[J]. 科学技术与工程, 2020, 20(30): 12255-12267.
WANG Xiaolei. Present situation and development trend of coal mine discharge forecast method [J]. Science Technology and Engineering, 2020, 20(30): 12255-12267.
- [13] 刘黎明. 时间序列多层递阶预报方法的应用[J]. 工科数学, 1995, 11(1): 25-29.
LIU Liming. Apply of time series multi-layer recursion prediction [J]. Journal of Mathematics for Technology, 1995, 11(1): 25-29.
- [14] 杨永国,韩宝平,谢克俊,等. 用多变量时间序列相关模型预测矿井涌水量[J]. 煤田地质与勘探, 1995, (6): 38-42.
YANG Yongguo, HAN Baoping, XIE Kejun, et al. To forecast the water yield of coal mine applying the time series interrelated model with multivariation [J]. Coal Geology & Exploration, 1995, (6): 38-42.
- [15] 汤琳,杨永国,徐忠杰. 非线性时间序列分析及其在矿井涌水预测中的应用研究[J]. 工程勘察, 2007, 35(5): 28-30, 72.
TANG Lin, YANG Yongguo, XU Zhongjie. Study of non-linear time series analysis and its use on mine water inrush prediction [J]. Geotechnical Investigation & Surveying, 2007, 35(5): 28-30, 72.
- [16] 陈玉华,杨永国,彭高辉. 矿井涌水量混沌时间序列分析与预测[J]. 煤田地质与勘探, 2008, 36(4): 34-36.
CHEN Yuhua, YANG Yongguo, PENG Gaohui. Chaotic time series analysis and prediction for minewater inflow [J]. Coal Geology & Exploration, 2008, 36(4): 34-36.
- [17] 曲兴羽,于小鸽,施龙青. 基于两类时间序列模型预测矿井最大涌水量[J]. 煤炭技术, 2019, 38(8): 100-102.
QU Xingyue, YU Xiaoge, SHI Longqing. Prediction of maximum mine inflow based on two kinds of time-series models [J]. Coal Technology, 2019, 38(8): 100-102.
- [18] 田罡豪,崔中良,胡体才,等. 基于 R/S 分析法的矿井涌水量时间序列分析及定量预测[J]. 化工矿物与加工, 2021, 50(10): 1-5, 9.
TIAN Ganghao, CUI Zhongliang, HU Ticai, et al. Time

- series analysis and quantitative prediction of mine water inflow based on R/S analysis[J]. *Industrial Minerals & Processing*, 2021, 50(10): 1-5, 9.
- [19] 刘慧, 刘桂芹, 宁殿艳, 等. 基于 VMD-DBN 的矿井涌水量预测方法[J]. *煤田地质与勘探*, 2023, 51(6): 13-21.
- LIU Hui, LIU Guiqin, NING Dianyan, et al. Mine water inrush prediction method based on VMD-DBN model[J]. *Coal Geology & Exploration*, 2023, 51(6): 13-21.
- [20] 侯恩科, 夏冰冰, 吴章涛, 等. 基于 CEEMDAN-BO-BiGRU 的矿井涌水量预测研究[J]. *科学技术与工程*, 2023, 23(28): 12012-12019.
- HOU Enke, XIA Bingbing, WU Zhangtao, et al. Mine water inflow prediction based on CEEMDAN-BO-BiGRU[J]. *Science Technology and Engineering*, 2023, 23(28): 12012-12019.
- [21] DRAGOMIRETSKIY K, ZOSSO D. Variational mode decomposition[J]. *IEEE Transactions on Signal Processing*, 2014, 62(3): 531-544.
- [22] SHAHRIARI B, SWERSKY K, Wang Z Y, et al. Taking the human out of the loop: A review of Bayesian optimization[J]. *Proceedings of the IEEE*, 2016, 104(1): 148-175.
- [23] 梁满玉, 尹尚先, 姚辉, 等. 基于 DRN-BiLSTM 模型的矿井涌水量预测[J]. *煤矿安全*, 2023, 54(5): 56-62.
- LIANG Manyu, YIN Shangxian, YAO Hui, et al. Mine water inflow prediction based on DRN-BiLSTM model[J]. *Safety in Coal Mines*, 2023, 54(5): 56-62.
- [24] 赵力, 史贤俊, 秦玉峰. 基于多策略融合改进鲸鱼算法的诊断策略优化方法[J]. *舰船电子工程*, 2023, 43(10): 186-193, 199.
- ZHAO Li, SHI Xianjun, QIN Yufeng. Diagnostic strategy optimization method based on multi-strategy fusion improved whale algorithm[J]. *Ship Electronic Engineering*, 2023, 43(10): 186-193, 199.
- [25] 赵江平, 张雪莹, 侯刚. 基于多源信息融合和 WOA-CNN-LSTM 的外脚手架隐患分类预警研究[J]. *安全与环境学报*, 2024, 24(3): 933-942.
- ZHAO Jiangping, ZHANG Xueying, HOU Gang. Classification and early warning research of scaffolding hidden trouble based on multi-source information fusion and WOA-CNN-LSTM[J]. *Journal of Safety and Environment*, 2024, 24(3): 933-942.
- [26] 郝天轩, 李鹏飞. 基于灰色关联分析-GA-BP 模型预测煤层瓦斯含量[J]. *中国矿业*, 2016, 25(11): 116-120.
- HAO Tianxuan, LI Pengfei. Prediction of gas content based on gray correlation analysis-GA-BP neural network[J]. *China Mining Magazine*, 2016, 25(11): 116-120.
- [27] 魏国营, 裴蒙. 基于 PCA-AHPSO-SVR 的煤层瓦斯含量预测研究[J]. *中国安全生产科学技术*, 2019, 15(3): 69-74.
- WEI Guoying, PEI Meng. Prediction of coal seam gas content based on PCA-AHPSO-SVR[J]. *Journal of Safety Science and Technology*, 2019, 15(3): 69-74.
- [28] 张宪峰, 魏久传, 张延飞, 等. 基于主成分分析与 BP 神经网络的矿井涌水量预测研究[J]. *煤炭技术*, 2018, 37(6): 201-203.
- ZHANG Xianfeng, WEI Jiuchuan, ZHANG Yanfei, et al. Principal component analysis and BP neural network of mine water inflow prediction research[J]. *Coal Technology*, 2018, 37(6): 201-203.
- [29] 武谋达, 王建辉, 侯恩科, 等. 大佛寺煤矿顶板涌水规律及影响因素[J]. *西安科技大学学报*, 2018, 38(4): 636-642.
- WU Mouda, WANG Jianhui, HOU Enke, et al. Roof water bursting rules and influential factors of Dafosi coal mine[J]. *Journal of Xi'an University of Science and Technology*, 2018, 38(4): 636-642.

(责任编辑:李克永)