

文章编号:1009-6094(2024)08-2994-11

改进多变量时序模型的 露天涌水量预测*

王孝东¹,杨懿杰¹,吕玉琪¹,
刘 唱¹,陈炫中¹,谢 博²,杜青文²

(1 昆明理工大学国土资源工程学院,昆明 650093;

2 昆明理工大学公共安全与应急管理学院,昆明 650093)

摘 要:露天矿坑涌水量变化影响着边坡的稳定性、工程进度和设备使用寿命,在矿山汛期,涌水量的突增给矿山带来巨大的安全隐患。为了做好涌水量突增安全防范,对于汛期涌水量的精准预测成为矿山安全生产的一大难题。针对这一问题,提出了一种基于改进蜣螂优化算法(Sparrow Initialization Dung Beetle Optimizer, SIDBO)优化变分模态分解(Variational Mode Decomposition, VMD)-双向长短周期神经网络(Bi-directional Long Short-Term Memory, BiLSTM)时序模型预测露天矿坑涌水量的方法。对于难以确定 VMD 参数的问题,利用改进蜣螂优化算法寻找最优 VMD 核心参数组合。SIDBO 算法首先基于 t 分布的差分策略优化勘探阶段,使用最优解和第二解中位搜寻策略增强全局最优解搜索能力,最后采用麻雀优化算法优化开发阶段。结果表明,与 VMD-SIDBO-LSTM 等模型相比较, SIDBO-VMD-SIDBO-BiLSTM 模型预测精度更高,均方根误差(R_{MSE})、平均绝对误差(M_{AE})、平均绝对百分比误差(M_{APE})、 R^2 分别为 5.96、4.96、0.41%、0.98,并将该模型与传统地质方法——水均衡法在实际工程实例中进行对比,该时序模型相对于水均衡法对于矿坑汛期涌水量预测精度提升了 3.8%,为露天矿汛期涌水量预测提供了新的技术与思路。

关键词:安全工程;算法优化;时序预测;变分模态分解(VMD);深度学习

中图分类号:X936 **文献标志码:**A

DOI: 10.13637/j.issn.1009-6094.2024.0773

0 引 言

露天矿坑涌水量是指通过大气降雨、地下涌水及地表径流等方式汇集至露天矿坑中的积水量。露天矿坑涌水的主要灾害表现为破坏边坡的稳定性,减缓矿山工程的推进速度,降低设备效率和使用寿命,影响工作人员的生命安全和矿山开采工作的

展开。

对于矿坑涌水量预测的研究,1950年,Darcy首次提出了达西定律^[1],标志着水文地质研究进入定量阶段,此阶段假设水流是稳定的,常使用经验公式预测。1970年左右,对矿坑涌水量预测的研究进入非稳定流阶段,此阶段考虑到水流在非稳定条件下的影响,使用水动力学方程组和地下水流模型来模拟矿坑周围地下水位的变化,并据此推断涌水量。1975—1980年,研究进入数值解阶段,通过在计算机上求解水文地质方程来预测涌水量,包括有限元法、有限差分法或边界元法等。1980年后,研究进入新型方法阶段,对矿区涌水进行系统性研究,并考虑到时空动态变化等因素来预测涌水量。

根据各阶段所用方法,将矿区涌水量预测分为两种:确定性预测,包括水均衡法、大井法、比拟法等传统地质预测法;非确定性预测,包括神经网络、线性回归、灰色理论等方法。邵立达^[2]对齐大山铁矿运用比拟法、大井法计算矿区涌水量,将两种计算结果进行比较得出适用于该矿的预测方法。畅秀俊^[3]采用比拟法计算地下水流入量,并依据气象站资料计算矿坑大气降水流入量,最终对Kolwezi铜钴矿矿坑涌水量做出预测。2014年,Bahrami等^[4]首次提出了一个二维数值模型的有限元分析法,通过数据分析及现场验证表明SEEP/W数值模拟在露天矿场不同开采水平涌水量预测中具有较高的可靠性。2000年,周翔等^[5]首次采用反向传播(Back Propagation, BP)神经网络对黑旺铁矿涌水量进行预测,由于BP神经网络不具备数据长时依赖和序列关联能力,其预测精度仍有待提高。何保等^[6]采用非线性回归法和比拟法对元宝山露天煤矿涌水量做了预测分析,为该矿区提供了安全生产依据。

此前对于露天矿坑涌水量预测更偏重于矿坑所处地区地质环境,考虑其地下涌水量,但露天矿坑涌水量汛期受大气降雨、地表径流影响更为直接,涌水量具有很强的周期性与趋势性。传统地质方法简单易行,但需要大量的人力、时间对该地区地质条件进行准确测量和分析,不适用于地质条件复杂的矿区;计算机数值法等需要大量的水文数据作为基础,且对模型参数选择和校正要求较高;神经网络预测法多为BP回归拟合,并未考虑时间发展变化,导致预测精度较低,而双向长短周期神经网络(Bi-directional Long Short-Term Memory, BiLSTM)相对于BP而言,具备良好的灵活性、泛化能力和时间序列依赖性,更适用于预测汛期突发性降雨涌水量。针

* 收稿日期:2024-05-16

作者简介:王孝东,副教授,博士,从事机器学习、智能矿山研究,1955171912@qq.com。

基金项目:昆明理工大学引进人才科研启动基金项目(KKSY201721032)

2994

对这一特点,本文提出采用时序模型预测露天矿坑涌水量的方法,建立 SIDBO - VMD - SIDBO - BiLSTM 预测模型。采用改进蜣螂优化算法 (Sparrow Initialization Dung Beetle Optimizer, SIDBO) 以最小样本熵^[7]为目标优化变分模态分解 (Variational Mode Decomposition, VMD)^[8],将 VMD 分解得到的本征模态函数 (Intrinsic Mode Function, IMF) 分量代入 SIDBO 优化后的 BiLSTM^[9]进行特征提取预测,再将预测分量进行累加求和,得到预测结果。最后,将模型与 BiLSTM、GRU、LSTM、VMD - BiLSTM、VMD - GRU、VMD - LSTM、VMD - SIDBO - GRU、VMD - SIDBO - LSTM 八个模型进行对比,为露天矿坑涌水量预测提供新的技术手段。

1 改进蜣螂优化算法 (SIDBO)

1.1 DBO 算法

蜣螂优化算法 (Dung Beetle Optimizer, DBO) 是 Xue 等^[10]提出的一种新型群体智能优化算法,灵感来自蜣螂的生物行为。在该算法中,滚球蜣螂、育雏球、小蜣螂和小偷蜣螂群体行为代表着不同的算子运行规律。

1.2 基于 t 分布的差分策略

在算法勘探阶段中,强调算法的随机性,使之可勘探到更多未知解空间,因此,提出了一种以 t 分布为步距系数的差分策略,优化滚球蜣螂阶段,提高对全局最优解的搜索能力。公式为

$$P_{i,j}^{\text{new}} = P_{i,j} + t_{10} (P_{A,j} - P_{B,j}) \quad (1)$$

式中 $P_{i,j}^{\text{new}}$ 为当前 t 次迭代过程中第 i 个搜寻者在第 j 维的新位置; t_{10} 为自由度为 10 的 t 分布随机数; $P_{A,j}$ 为第 A 个搜寻者在第 j 维的位置; $P_{B,j}$ 为第 B 个搜寻者在第 j 维的位置。

1.3 中位搜寻策略

提出了一种基于最优解和第二优解的中位搜寻策略,对于全局最优解来说,不一定存在于已知最优解处,已知最优解可能为局部最优解,此时需要对最优解处进行再次的开发。因此,提出了一种基于中位搜寻的策略,帮助算法迅速跳出局部最优解,提升解的质量。公式为

$$P_{i,j}^{\text{new}} = \frac{P_{\text{best}} + P_{\text{second}}}{2} \times l \quad (2)$$

$$l = 1 - t/T \quad (3)$$

式中 P_{best} 为第 t 次迭代时的最优解; P_{second} 为第 t 次迭代时的第二优解; l 为从 1 线性衰减为 0 的衰减系数; T 为最大迭代次数。

1.4 麻雀开发策略

为了进一步提高算法开发能力,引入了麻雀优化算法 (Sparrow Search Algorithm, SSA)^[11] 的加入者思想,其位置更新公式为

$$P_{i,j}^{\text{new}} = Q \exp [(P_{\text{worst}} - P_{i,j}) / i^2] \quad (4)$$

式中 Q 表示遵循正态分布的随机数; P_{worst} 为当前全局最差的位置。

1.5 SIDBO 性能测试

为了更好地验证 SIDBO 算法性能,选取高引算法——鲸鱼优化算法 (Whale Optimization Algorithm, WOA)^[12]、白鲸优化算法 (Beluga Whale Optimization, BWO)^[13]、DBO、灰狼优化算法 (Grey Wolf Optimizer, GWO)^[14]、粒子群算法 (Particle Swarm Optimization, PSO)^[15]、哈里斯鹰算法 (Harris Hawks Optimization, HHO)^[16] 和优秀改进蜣螂优化算法 QHDBO^[17]、IDBO^[18] 与本文 SIDBO 算法进行测试函数比较。

算法参数设置为:种群 30、迭代次数 500。为了避免单次试验造成的误差,在维度为 500 的情景下分别运行 20 次获取平均迭代曲线。

1.5.1 各测试函数基本信息及结果

表 1 中包含了 6 种测试函数, $F_1 \sim F_3$ 为单峰测试函数, $F_4 \sim F_6$ 为多峰函数。单峰函数在函数边界内具有一个全局最优解,用于检测算法的寻优速度;多峰函数在函数边界内具有多个局部最优解,用于检测算法寻优精度。

表 1 各测试函数信息

Table 1 Information of each test function

函数名称	区间	函数最小值
F_1 (Sphere Function)	$[-100, 100]$	$f(x)_{\min} = 0$
F_2 (Schwefel's Problem 2.22)	$[-10, 10]$	$f(x)_{\min} = 0$
F_3 (Schwefel's Problem 1.2)	$[-100, 100]$	$f(x)_{\min} = 0$
F_4 (Ackley's Function)	$[-32, 32]$	$f(x)_{\min} = 0$
F_5 (Generalized Penalized Function 1)	$[-50, 50]$	$f(x)_{\min} = 0$
F_6 (Generalized Penalized Function 2)	$[-50, 50]$	$f(x)_{\min} = 0$

各算法在 $F_1 \sim F_6$ 测试函数上的迭代曲线见图 1。

1.5.2 测试结果分析

从图 1 可以看出:在 $F_1 \sim F_3$ 单峰函数测试上, SIDBO 相比其他 8 种算法收敛速度更快,且能迅速收敛至最优值 0,其性能明显优于其余算法;在 $F_4 \sim F_6$ 多峰测试函数中, SIDBO 相比其他算法收敛速度




图1 各算法迭代曲线图

Fig.1 Iteration curves graph for each algorithm

快且精度较高, F_5 和 F_6 函数中, SIDBO 未收敛至最优值, 但收敛速度和精度优于其他算法。

通过6个测试函数得到, 所提出的 SIDBO 性能均高于原 DBO 优化算法, 且在处理高维复杂问题时有着良好的处理速度及寻优能力, 有效提高了时序

模型的预测性能。

2 涌水量时序模型建立

2.1 数据来源及预处理

所用露天矿涌水量数据为来源于云南某矿山

2021—2022 年的 720 个数据,所用降雨量、气温、气压、湿度等数据来源于中国气象局。

(1)异常值处理^[19]。在数据收集过程中,存在一定的误差,导致某些数值远远偏离正常值。采用 3σ 原则去除异常值,计算过程如下。

$$\sigma = \sqrt{\frac{\sum_{i=1}^d (x_i - \bar{x})^2}{d-1}} \quad (5)$$

$$|x_i - \bar{x}| > 3\sigma \quad (6)$$

设原始数据为 $\{x_1, x_2, x_3, \dots, x_d\}$, d 为数据个数,平均值为 $\bar{x}$ 。计算 x_i 的标准差记为 σ ,再计算 x_i 与 $\bar{x}$ 的绝对差,当其值大于 3σ 时,认为是异常值。

(2)缺失值处理。对于少部分缺失值数据,采用线性插值进行处理,公式如下。

$$\frac{f(t_2) - f(t_0)}{t_2 - t_0} = \frac{f(t_1) - f(t_0)}{t_1 - t_0} \quad (7)$$

式中 t_0, t_2 时刻值为 $f(t_0), f(t_2)$, t_1 时刻缺失值为 $f(t_1)$ 。

处理后涌水量、降雨量、气温、气压历史曲线图见图 2。

2.2 SIDBO 参数优化

2.2.1 VMD 分解参数

在使用 VMD 分解矿坑涌水量数据时,需预先设

置惩罚因子 α 和模态分解个数 k ,但因为数据受到天气因素、湿度等因素影响,振动信号复杂多变, k 和 α 难以确定。当 k 过大时,可能会捕捉到一些无关的噪声或高频成分;而当 k 过小时,无法捕捉到信号的全部信息,分解结果也不准确。当 α 过小时,分解结果稀疏;当 α 过大时,可能会导致丢失一些细节信息,使分解结果过于模糊。前人大多以多次试验来确定 k 和 α ,但此方法存在一定误差,使得结果并非最优解。

因此,本文提出采用改进蜚螂优化算法 (SIDBO) 以数据最小样本熵为目标函数,对 (k, α) 组合进行寻优。

2.2.2 最小样本熵

对于 VMD,目前主要通过样本熵、包络熵、信息熵和排列熵四种方法进行优化。

最小包络熵对于非平稳信号和非线性信号具有较好的适应性,但对于包络较为平缓的信号,可能会得到较低的熵值。最小信息熵可以评估信号的信息量和随机性,对于具有不同分布和概率密度的信号都适用,但无法提供信号的动态特征,对于信号的非线性特征无法很好地反映。最小排列熵可以评估时间序列的非线性动力学特征,对于非平稳信号和非




图 2 矿区历史数据图

Fig. 2 Historical data map of mining area

线性信号具有较好的适应性,但无法提供信号的详细信息,只能提供整体特征。

因此,选择最小样本熵为寻优目标函数,其优势在于:能提供时间序列的整体特征,可用于评估时间序列的随机性和复杂度,且对于具有不同长度和采样频率的时间序列都适用,不受噪声和干扰的影响。公式如下。

$$B^m(r) = \frac{1}{N-m} \sum_{i=1}^{N-m} B_i^m(r) \quad (8)$$

式中 $B^m(r)$ 为所有 i 对应的 $B_i^m(r)$ 的平均值; N 为数据个数; m 为模式维数; r 为相似容限阈值; i 为 $[1, N-m]$ 之间 $B_i^m(r)$ 的索引值; $B_i^m(r)$ 为 $N-m$ 个子序列模板的匹配概率,即近似数量与总数量的比值,此时总数量为 $N-m-1$ 。

将维数加 1 变为 $m+1$, 重复以上步骤, 得到 $A^m(r)$, 得出样本熵公式为

$$\text{SampEn}(m, r) = \ln B^m(r) - \ln A^m(r) \quad (9)$$

式中 $\text{SampEn}(m, r)$ 为样本熵值; $A^m(r)$ 为两个序列匹配 $m+1$ 个点的概率。

2.2.3 VMD 优化

确定了以 SIDBO 为寻优算法、最小样本熵为目标函数, 参数设置如下: 下边界为 (100, 3), 上边界为 (10000, 20), 即得 $k \in [3, 20]$, $\alpha \in [100, 1000]$; 维度为 2, 迭代次数为 100, 种群规模为 30。

采用 DBO 和 SIDBO 对最小样本熵进行对比寻优, 见图 3。

由图 3 可知, SIDBO 具有更优秀的求解精度, 在对样本数据求解最小样本熵时, 获得更精确的样本熵值。通过样本熵值可计算最佳 (k, α) 组合值, $k=5$, $\alpha=2413$ 。

2.3 VMD 分解

将最优参组合代入 VMD, 对 VMD 进行参数设




图3 最小样本熵求解图

Fig.3 Diagram of the minimum sample entropy solution

置: 中心频率参数为 1, 容差为 10^{-7} , 直流分量为 0, 噪声容限为 0。将参数代入 VMD 得出如图 4 所示的模式分解图。

2.4 SIDBO-BiLSTM 模型预测

将分解得到的 $\text{IMF}_1 \sim \text{IMF}_5$ 以及降雨量、湿度等数据代入 SIDBO-BiLSTM 进行多变量预测, 将数据后 72 个数据划分为测试集。

SIDBO 参数设置如下: 种群数量为 20, 最大迭代次数为 500。采用 SIDBO 优化 BiLSTM 的三个参数: 隐藏单元数目、训练周期、初始学习率。将预测出的数据与测试集进行对比, 并建立了 BiLSTM、LSTM、GRU、VMD-BiLSTM、VMD-LSTM、VMD-GRU、VMD*-BiLSTM、VMD*-LSTM、VMD*-GRU (VMD* 表示已对神经网络进行超参数优化) 9 个模型作为对比, 见图 5。

通过图 5(a) 可以看出, 单一的神经网络仅能预测曲线的大致方向, 且预测精度一般。在图 5(b) 中, 对神经网络模型进行变分模态分解后, 相比于图 5(a) 性能得到了巨大的提升, 添加了涌水量 $1285 \text{ m}^3/\text{h}$ 的分隔面, 发现 350 d 时, 涌水量有明显的增幅, 表明此时正值汛期, 三个模型中, 只有 VMD-BiLSTM 预测更为精准, 对于汛期涌水量激增有更高的敏感性, 在图 5(c) 中, 采用了 SIDBO 算法对神经网络超参数进行优化, 相比于图 5(b), 进一步提升了模型的性能, 同样在汛期, 添加了涌水量为 $1300 \text{ m}^3/\text{h}$ 的分隔面, 发现 VMD*-BiLSTM 相比于其他模型对于汛期涌水量预测有了更高的精度。采用平均绝对百分比误差^[20]、平均绝对误差、均方根误差、 R^2 对模型进行评价。

平均绝对误差 (M_{AE}) 公式为

$$M_{\text{AE}} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (10)$$




图4 VMD 分解

Fig.4 VMD decomposition




图 5 不同模型预测对比图

Fig. 5 Comparison chart of different model predictions

式中 y_i 是真实值; $\hat{y}_i$ 表示预测值。

均方根误差 (R_{MSE}) 公式为

$$R_{MSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (11)$$

平均绝对百分比误差 (M_{APE}) 公式为

$$M_{APE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{\hat{y}_i - y_i}{y_i} \right| \quad (12)$$

R^2 公式为

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (13)$$

式中 $\bar{y}$ 表示真实值的平均值。

各模型预测评价指标见图 6。

通过 4 个评价指标的值可以定量看出,GRU 的预测精度最低,对 BiLSTM、GRU 加入 VMD 模态分解后,相比原来模型评价指标 R_{MSE} 分别降低了 49.79%、48.47%, M_{AE} 分别降低了 50.58%、51.44%, M_{APE} 分别降低了 50.76%、51.65%, R^2 分别提高了 0.472 4、0.471 4。通过这两组对比试验可知,在加入了 VMD 分解后,数据得到了有效的去噪,使得神经网络提取到了更多的有效特征,大幅提升了模型预测精度和数据拟合度。

通过对 VMD-GRU、VMD-BiLSTM 采用 SIDBO 进行超参数优化得到 VMD-SIDBO-GRU、VMD-SIDBO-BiLSTM 模型,对比分析可知, R_{MSE} 分别降低了 67.29%、57.48%, M_{AE} 分别降低了 67.33%、58.33%, M_{APE} 分别降低了 67.54%、58.54%, R^2 分别增加了 0.08、0.10。这表明 SIDBO 在进行超参数寻优时,具有良好的跳出局部最优解性能,经过超参数优化后神经网络模型性能得到了一定的提升,明显提升了预测的精度。

对 VMD-SIDBO-BiLSTM、VMD-SIDBO-GRU、VMD-SIDBO-LSTM 三个模型进行对比,从 4 个评价指标中看出,VMD-SIDBO-BiLSTM 对于露天矿坑涌水预测性能最优。BiLSTM 通过两层 LSTM 的堆叠,双向结构使得网络能够更好地学习数据特征,能够在每个时间步骤上更全面地捕捉序列中的模式和特征。相比于 LSTM 和 GRU 预测模型, BiLSTM 对于本文数据有更好的预测效果。

3 工程实例

基于云南某露天矿地质实例,采用传统地质方法(水均衡法)和本文建立的时序模型预测法对该矿区 2022 年测试集中最大降雨量日进行涌水量预测对比。

3.1 矿区水文地质

矿区地层、岩组见图 7(a) 和 (b)。该矿区含水层主要包含岩溶裂隙水、裂隙水、孔隙水三种,划分依据为 GB/T 12719—91《矿区水文地质工程地质勘探规范》。地层富水等级划分依据来源于实测泉水流量及钻孔单位涌水量^[21]。在查明了矿区不同地质岩性、富水性、补径条件的基础上,采用水均衡法对 750 开采平台进行涌水量预测。

在图 7(a) 中:该矿区岩溶裂隙水含水层为 Pt_3x_3 ³;该矿区裂隙水含水层为 Pt_3x_1 ¹、 Pt_3x_2 ²、 Pt_3x_4 ⁴ ~




图6 评价指标柱状图

Fig. 6 Histogram of evaluation indicators




图7 矿区地质地形图

Fig. 7 Geological topographic map of the mining area

Pt₃x. 6 及侵入岩体 $\gamma\beta\text{mS}_3$ 、Qv、 $\gamma\pi\text{K}_2$ 、 $\eta\gamma\text{K}_1$ 等;该矿区孔隙水含水层为人工填土 Qh^s, 主要分布于南部, 3000

由黏土、花岗岩碎块、变质岩等组成,富水性中等,钻孔单位涌水量为 0.537 L/(s·m)。具体见表 2,表 2 中空白处代表未实际测量。

3.2 水均衡法

按照图 7(b) 中剖面线剖开,矿坑涌水量来源简单示意图见图 8。

$$Q_0 = Q_1 + Q_2 + Q_3 + Q_4 + Q_5 - Q_6 \quad (14)$$

式中 Q_0 为 750 开采平台涌水量, m³/h; Q_1 为矿坑涌水量直接补给, m³/h; Q_2 为矿坑涌水量入渗补给, m³/h; Q_3 为水塘 A 对矿坑涌水量补给, m³/h; Q_4 为沟流对矿坑涌水量补给, m³/h; Q_5 为矿坑区域含水层补给, m³/h; Q_6 为排水沟排出水量, m³/h。

3.2.1 降雨量补给

矿坑半径 r_1 为 774.22 m, 坑底半径 r_2 为 104.56 m。大气降雨对矿坑补给表现在两个方面: 直接补

给 Q_1 和入渗补给 Q_2 ^[22]。直接补给入渗系数 λ_1 取 1.00, 补给矿坑底部面积为 πr_2^2 。入渗补给入渗系数 λ_2 通过矿区地下水监测数据和气象资料计算为 0.27~0.32, 为了更好地反映汛期降雨量, 取最大入渗系数 0.32。降水入渗补给面积为矿坑侧面补给面积(即开采露出的面积 S 与矿坑底部面积之差 $S - \pi r_2^2$)。在矿区 2022 年汛期测试集中, 单日最大降雨量为 27.1 mm。




图 8 矿坑涌水来源示意图
Fig. 8 Schematic diagram of source of gushing water in the mine

$$Q = \lambda FP \tag{15}$$
式中 Q 为降雨补给量, m^3/h ; λ 为降水入渗系数; F 为接受降雨入渗地表面积, m^2 ; P 为当日降雨量, mm 。

计算结果如表 3 所示, 空白处代表无此项。

3.2.2 A 水塘补给

水塘一侧的渗漏补给量可以用达西公式计算。

$$Q_3 = KSI \tag{16}$$

式中 Q_3 为 A 水塘的渗漏补给量, m^3/h ; K 为含水层渗透系数, m/h ; S 为 A 水塘与含水层接触面积, m^2 ; I 为水力梯度。Pt₃x.³ 地层 K 为 0.042 7 m/h, A 水塘与含水层接触面积 S 为 4 532.61 m^2 , 水力梯度 I 为 0.207 5, A 水塘当日平均水位为 1 266 m。补给涌水量计算结果如表 4 所示, ∇H 为 A 水塘和开采平台水位差值, L 为 A 水塘至矿坑之间的距离。

3.2.3 其余补给与排出

根据该矿历史记录数据, 沟流最大补给量为 18.72 m^3/h 。矿区地质资料显示, 该矿坑区域含水层主要为二云片岩和大理岩, 岩石之间孔隙体积即为含水层含水量, 孔隙度取值为 10%, 矿坑区域含

表 2 矿区水文地质特征参数

Table 2 Hydrogeological characteristic parameters of mining area

含水层类型	含水层	岩性	富水性	泉数量	泉流量/($\text{L} \cdot \text{s}^{-1}$)
孔隙水	Qh ^s	变质岩、花岗岩碎块、黏土	中等	0	0
裂隙水	Pt ₃ x. ⁶	二云片岩	弱	24	0.02~0.456
	Pt ₃ x. ⁵	二云石英片岩	弱		0.002~0.45
	Pt ₃ x. ⁴	二云片岩、绿泥片岩	弱		0.002~0.45
	Pt ₃ x. ²	二云片岩	弱	2	0.081~0.249
	Pt ₃ x. ¹	绿泥片岩	弱	3	0.005~0.287
	$\eta\gamma K_1$	中粗粒似斑状二云二长花岗岩	中等	4	0.20~1.13
	$\gamma\pi K_2$	花岗斑岩	弱	1	0.120
	$\eta\gamma^a S_3$	浅灰色片麻状中细粒二云二长花岗岩	弱	45	0.024~0.901
	$\gamma\beta m S_3$	云母花岗岩	弱	0	0
	Qv	长英岩体	弱	0	0
岩溶裂隙水	Pt ₃ x. ³	大理岩与二云片岩互层	中等	14	0.006~0.712

表 3 水均衡法降雨量补给计算

Table 3 Calculation of rainfall recharge by water equalization method

补给方式	λ	F/m^2	$P/(\text{m} \cdot \text{h}^{-1})$	$Q_1/(\text{m}^3 \cdot \text{h}^{-1})$	$Q_2/(\text{m}^3 \cdot \text{h}^{-1})$
直接补给	1	34 328.97	0.001 1	37.76	
入渗补给	0.32	1 847 839.18	0.001 1		650.43

表4 A水塘水量补给计算

Table 4 Calculation of water recharge to A reservoir

$K/$ ($\text{m} \cdot \text{h}^{-1}$)	$S/$ m^2	$\nabla H/$ m	$L/$ m	I	$Q_3/$ ($\text{m}^3 \cdot \text{h}^{-1}$)
0.042 7	4 532.61	516	2 486	0.207 5	40.226

水层对矿坑补给量取值为 $593.901 \text{ m}^3/\text{h}$ 。该矿区存在两条排水沟,最大排出量为 $108 \text{ m}^3/\text{h}$ 。

3.2.4 水均衡法计算结果

水均衡法预测涌水量见表5。

3.3 时序预测法

根据建立的时间序列模型对汛期最大日降雨量进行预测。2022年该矿区测试集中最大日降雨量为 27.1 mm ,如图9所示,该日矿井记录涌水量为 $1\,310.59 \text{ m}^3/\text{h}$,预测值为 $1\,301.48 \text{ m}^3/\text{h}$ 。计算结果见表6。

露天矿坑涌水量与矿区所处地质环境和降雨量有关,但针对文中所述矿区,地质环境对于短期涌水量变化影响甚微,因此,重点关注降雨量、湿度等气象因素与涌水量之间的时间序列研究。由表6可知,时间序列预测方法相对于传统地质方法——水均衡法,对于矿山汛期涌水量激增具有更高的预测性,预测精度提升了 3.8% ,为该矿区汛期涌水量预测提供了新的思路。

4 结论

本文针对露天矿坑涌水量预测问题,提出了一种基于SIDBO优化VMD核心参数,并结合SIDBO优化双向长短期记忆神经网络参数的模型。通过试验得出以下结论。

(1)改进蜣螂优化算法SIDBO在单峰及多峰测试函数上迭代速度与求解精度均高于原算法DBO,且在多个测试函数中表现优于其他算法,有效提高了预测精度。

(2)通过对比验证得出,加入了VMD分解和SIDBO参数优化,对于预测精度和稳定性方面具有明显的提升。建立了基于SIDBO-VMD-SIDBO-BiLSTM的露天矿坑涌水量预测时序模型, R_{MSE} 、 M_{AE} 、 M_{APE} 、 R^2 分别为 5.96 、 4.96 、 0.41% 、 0.98 。

(3)将建立的时序预测模型运用于云南某露天矿坑涌水量预测中,将思路转为对该矿区降雨量-涌水量时间序列预测研究,在汛期矿坑涌水量预测中,时序模型法相比于水均衡法预测精度提升了 3.8% 。

表5 水均衡法预测计算

Table 5 Prediction calculation of water balance method

补给量/ ($\text{m}^3 \cdot \text{h}^{-1}$)					排泄量 Q_6 /涌水量 Q_0 / ($\text{m}^3 \cdot \text{h}^{-1}$) ($\text{m}^3 \cdot \text{h}^{-1}$)	
Q_1	Q_2	Q_3	Q_4	Q_5		
37.76	650.43	40.226	18.72	593.901	108	1 233.037

表6 水均衡法与时序法涌水量对比

Table 6 Comparison of water inflow between water balance method and time series method

预测方法	水均衡法	时序法	真实数据
汛期涌水量/($\text{m}^3 \cdot \text{h}^{-1}$)	1 233.037	1 301.48	1 310.59




图9 时序模型涌水量预测

Fig. 9 Water inflow prediction of time series model

3.8% ,对于露天矿坑涌水预测提供了新的技术手段。

参考文献 (References):

- [1] LI R, ZHANG Y C, WU J H, et al. Discontinuous finite volume element method for Darcy flows in fractured porous media [J]. Journal of Computational and Applied Mathematics, 2020, 381: 113025.
- [2] 邵立达. 齐大山铁矿露天开采涌水量计算及水质评价 [D]. 长春: 吉林大学, 2013.
SHAO L D. The forecast of water inflow during open pit mining and water quality evaluation in Qidashan iron mine [D]. Changchun: Jilin University, 2013.
- [3] 畅秀俊. Kolwezi 铜钴矿露天采场矿坑涌水量预测及治水方案分析 [J]. 地下水, 2013, 35(3): 83-84.
CHANG X J. Water inflow prediction and water control scheme analysis of Kolwezi open-pit stope [J]. Ground Water, 2013, 35(3): 83-84.

- [4] BAHRAMI S, ARDEJANI F D, ASLANI S, et al. Numerical modelling of the groundwater inflow to an advancing open pit mine: Kolahdarvazeh pit, Central Iran [J]. *Environmental Monitoring and Assessment*, 2014, 186(12): 8573–8585.
- [5] 周翔, 朱学愚, 文成玉, 等. 基于遗传学习算法和 BP 算法的神经网络在矿坑涌水量计算中的应用[J]. *水利学报*, 2000(12): 59–63.
ZHOU X, ZHU X Y, WEN C Y, et al. Application of ANN to predict the drainage in mine [J]. *Journal of Hydraulic Engineering*, 2000(12): 59–63.
- [6] 何保, 李振南, 赵世杰. 基于多元非线性回归分析的露天煤矿涌水量预测[J]. *煤炭科学技术*, 2018, 46(5): 125–129.
HE B, LI Z N, ZHAO S J. Prediction on water inflow of surface mine based on multi-element nonlinear regression analysis [J]. *Coal Science and Technology*, 2018, 46(5): 125–129.
- [7] 赵晓军. 时间序列的相关性及复杂性研究[D]. 北京: 北京交通大学, 2015.
ZHAO X J. The correlation and complexity analysis of time series [D]. Beijing: Beijing Jiaotong University, 2015.
- [8] 刘长良, 武英杰, 甄成刚. 基于变分模态分解和模糊 C 均值聚类的滚动轴承故障诊断[J]. *中国电机工程学报*, 2015, 35(13): 3358–3365.
LIU C L, WU Y J, ZHEN C G. Rolling bearing fault diagnosis based on variational mode decomposition and fuzzy C means clustering [J]. *Proceedings of the CSEE*, 2015, 35(13): 3358–3365.
- [9] 赵志宏, 李晴, 杨绍普, 等. 基于 BiLSTM 与注意力机制的剩余使用寿命预测研究[J]. *振动与冲击*, 2022, 41(6): 44–50, 196.
ZHAO Z H, LI Q, YANG S P, et al. Remaining useful life prediction based on BiLSTM and attention mechanism [J]. *Journal of Vibration and Shock*, 2022, 41(6): 44–50, 196.
- [10] XUE J K, SHEN B. Dung beetle optimizer: a new meta-heuristic algorithm for global optimization [J]. *The Journal of Supercomputing*, 2023, 79(7): 7305–7336.
- [11] 薛建凯. 一种新型的群智能优化技术的研究与应用 [D]. 上海: 东华大学, 2020.
XUE J K. Research and application of a novel swarm intelligence optimization technique [D]. Shanghai: Donghua University, 2020.
- [12] MIRJALILI S, LEWIS A. The whale optimization algorithm [J]. *Advances in Engineering Software*, 2016, 95: 51–67.
- [13] GUAN Y, LÜ M, LI S, et al. Optimized sensor placement of water supply network based on multi-objective white whale optimization algorithm [J]. *Water*, 2023, 15(15): 2677.
- [14] MIRJALILI S, MIRJALILI S M, LEWIS A. Grey wolf optimizer [J]. *Advances in Engineering Software*, 2014, 69: 46–61.
- [15] 张舒, 代涵, 史秀志, 等. 基于 PSO–RF 的建筑安全文明施工费费率预测 [J]. *安全与环境学报*, 2022, 22(2): 844–850.
ZHANG S, DAI H, SHI X Z, et al. Prediction of fee rate for safe and civilized construction cost based on PSO–RF [J]. *Journal of Safety and Environment*, 2022, 22(2): 844–850.
- [16] HEIDARI A. A, MIRJALILI S, FARIS H, et al. Harris hawks optimization: algorithm and applications [J]. *Future Generation Computer Systems*, 2019, 97: 849–872.
- [17] ZHU F, LI G S, TANG H, et al. Dung beetle optimization algorithm based on quantum computing and multi-strategy fusion for solving engineering problems [J]. *Expert Systems with Applications*, 2024, 236: 121219.
- [18] 李斌, 高鹏, 郭自强. 改进蜣螂算法优化 LSTM 的光伏阵列故障诊断[J/OL]. *电力系统及其自动化学报*: 1–10 [2024–07–05]. <https://doi.org/10.19635/j.cnki.csu-epsa.001317>.
LI B, GAO P, GUO Z Q. Improved dung beetle optimizer to optimize LSTM for photovoltaic array fault diagnosis [J/OL]. *Proceedings of the CSU–EPSA*: 1–10 [2024–07–05]. <https://doi.org/10.19635/j.cnki.csu-epsa.001317>.
- [19] 刘慧, 刘桂芹, 宁殿艳, 等. 基于 VMD–DBN 的矿井涌水量预测方法 [J]. *煤田地质与勘探*, 2023, 51(6): 13–21.
LIU H, LIU G Q, NING D Y, et al. Mine water inrush prediction method based on VMD–DBN model [J]. *Coal Geology & Exploration*, 2023, 51(6): 13–21.
- [20] 侯恩科, 姚星, 车晓阳, 等. 基于 KPCA–APSO–ELM 的矿井涌水水源识别 [J]. *安全与环境学报*, 2022, 22(1): 64–71.
HOU E K, YAO X, CHE X Y, et al. Identification method of mine water inrush sources based on KPCA–APSO–ELM [J]. *Journal of Safety and Environment*, 2022, 22(1): 64–71.

2022, 22(1): 64–71.

- [21] 李亮. 云南文山都龙矿区矿坑涌水量预测方法对比研究[D]. 昆明: 昆明理工大学, 2020.

LI L. Comparative study on prediction methods of mine water inflow in Dulong mining area, Wenshan, Yunnan [D]. Kunming: Kunming University of Science and Technology, 2020.

- [22] 王其虎, 叶义成, 刘艳章, 等. 矿坑涌水对大气降水的响应分析及预测[J]. 安全与环境学报, 2012, 12(1): 182–186.

WANG Q H, YE Y C, LIU Y Z, et al. Response analysis and forecasting of the pit-water due to the rainfall[J]. Journal of Safety and Environment, 2012, 12(1): 182–186.

Prediction of open air water inflow based on improved multivariate time series model

WANG Xiaodong¹, YANG Yijie¹, LÜ Yuqi¹, LIU Chang¹, CHEN Xuanzhong¹, XIE Bo², DU Qingwen²

(1 School of Land and Resource Engineering, Kunming University of Science and Technology, Kunming 650093, China;

2 School of Public Safety and Emergency Management, Kunming University of Science and Technology, Kunming 650093, China)

Abstract: Changes in the amount of water surging from open pits affect the stability of slopes, the rate of decline of the project and the service life of the equipment. During the flood season of the mine, the sudden increase in the amount of water surging poses a huge safety hazard to the mine. Therefore, in order to do a good job in the surge of water safety precautions, the accurate prediction of the flood season surge of water has become a major problem of mine safety production. To address this problem, this paper proposes a method based on the Sparrow Initialization Dung Beetle Optimizer (SIDBO) algorithm to optimize the Variational Mode Decomposition (VMD)-Bi-directional Long Short-Term Memory (BiLSTM) time series model to predict the water inflow of open pit. BiLSTM temporal modeling method for predicting water influx in open pits. For the problem of difficult to determine VMD parameters, an improved dung beetle optimization algorithm is used to find the optimal VMD core parameter combinations. The SIDBO algorithm first optimizes its exploration phase based on the t-distributed difference strategy, enhances its global optimal solution searching capability using

the optimal solution and the second solution median searching strategy, and finally optimizes its development phase using the sparrow optimization algorithm. The BiLSTM is optimized by SIDBO, and SIDBO optimizes its three parameters: the optimal number of hidden units, the optimal training period, and the optimal initial learning rate. The optimized VMD decomposition components and the mine rainfall data are brought into the super-parameter-optimized BiLSTM to make predictions, and finally the predictions are accumulated and summed up. The results show that the SIDBO-VMD-SIDBO-BiLSTM model has higher prediction accuracy compared with other models such as VMD-SIDBO-LSTM. The four indexes of Root Mean Squared Error (R_{MSE}), Mean Absolute Error (M_{AE}), Mean Absolute Percentage Error (M_{APE}), and R^2 are 5.96, 4.96, 0.41%, and 0.98, respectively. Comparing this model with the traditional geological method-water equalization method in the actual engineering examples, this time series model can improve the accuracy of water influx prediction for the flood season of the pit by 3.8%, providing a new technical method and idea for the prediction of flood season of the open pit mine and supporting safety production.

Key words: safety engineering; algorithm optimization; time series prediction; Variational Modal Decomposition (VMD); deep learning