



移动阅读

刘 譞, 姬亚东, 朱开鹏, 等. 煤层顶板涌水量 TCN-LSTM-SVM 时间序列预测模型构建与应用[J]. 煤田地质与勘探, 2025, 53(6): 201–211. doi: 10.12363/issn.1001-1986.25.03.0198

LIU Xuan, JI Yadong, ZHU Kaipeng, et al. Construction and application of a TCN-LSTM-SVM-based time series prediction model for water inflow in coal seam roofs[J]. Coal Geology & Exploration, 2025, 53(6): 201–211. doi: 10.12363/issn.1001-1986.25.03.0198

煤层顶板涌水量 TCN-LSTM-SVM 时间序列预测模型 构建与应用

刘 譞^{1,2,3,4}, 姬亚东^{1,2,3,4,*}, 朱开鹏^{2,3,4}, 赵春虎^{1,2,3,4}, 李 凯^{2,3,4}, 李超峰^{2,3,4},
袁晨瀚^{2,3,4}, 李盼盼^{2,3,4}, 闫鹏珍^{1,2,3,4}

1. 煤炭科学研究总院, 北京 100013; 2. 中煤科工西安研究院(集团)有限公司, 陕西 西安 710077; 3. 煤矿灾害防控全国重点实验室, 陕西 西安 710077; 4. 陕西省煤矿水害防治技术重点实验室, 陕西 西安 710077

摘要: 【背景】矿井涌水量的准确预测对于煤矿水害防治、安全高效生产起着重要的作用。【方法】为构建适用于西部受巨厚砂岩含水层水害威胁矿井的涌水量预测模型, 以受该种水害严重影响的陕西彬长矿区某典型矿井为研究对象, 基于工作面回采进尺与涌水量数据之间的相关关系, 选取其作为矿井涌水量时间序列预测的特征变量, 提出基于时域卷积网络(temporal convolutional networks, TCN)的长短期记忆网络(long-short term memory, LSTM)-支持向量机(support vector machines, SVM)矿井工作面涌水量耦合预测模型, 即 TCN-LSTM-SVM 模型。该模型首先通过 TCN 框架对原数据进行处理, 提取回采进尺与涌水量之间的依赖关系和动态特征, 随后将提取特征输出到后续的 LSTM-SVM 组合模型, 以进一步捕捉回采进尺与涌水量之间的时序关系和特征。【结果】模型训练与预测结果显示: TCN-LSTM-SVM 耦合模型的训练集、验证集和测试集的平均绝对误差(E_{MA})为 56.02~129.89 m³/h, 平均绝对百分比误差(E_{MAP})为 3%~7%, 均方根误差(E_{RMS})为 82.60~162.61 m³/h, 决定系数(R^2)为 0.81~0.98, 预测结果较 BP 神经网络、随机森林(RF)、Transformer 等常用预测模型的准确度更高, 并且避免了其中多数模型在验证集和测试集中出现的误差过大的情况。研究发现, 该耦合模型既具备 TCN 模型的并行处理优势和多尺度特征提取能力, 同时也具备 LSTM-SVM 组合模型优秀的预测性能和泛化能力, 针对研究矿井的工作面涌水量预测与以往模型相比具有一定的优越性和适用性。【结论】研究成果为矿区相似地质条件的矿井涌水量预测提供了新的方法, 对该矿地质条件类似的工作面涌水量预测以及防治水工作有一定的现实意义。

关键词: 矿井水害; 煤层顶板; 涌水量预测; 时域卷积网络; 长短期记忆网络; 支持向量机; 陕西彬长矿区

中图分类号: TD745 文献标志码: A 文章编号: 1001-1986(2025)06-0201-11

Construction and application of a TCN-LSTM-SVM-based time series prediction model for water inflow in coal seam roofs

LIU Xuan^{1,2,3,4}, JI Yadong^{1,2,3,4,*}, ZHU Kaipeng^{2,3,4}, ZHAO Chunhu^{1,2,3,4}, LI Kai^{2,3,4}, LI Chaofeng^{2,3,4},
YUAN Chenhan^{2,3,4}, LI Panpan^{2,3,4}, YAN Pengzhen^{1,2,3,4}

1. China Coal Research Institute, Beijing 100013, China; 2. CCTEG Xi'an Research Institute (Group) Co., Ltd., Xi'an 710077, China; 3. State Key Laboratory of Coal Mine Disaster Prevention and Control, Xi'an 710077, China; 4. Shaanxi Key Laboratory of

收稿日期: 2025-03-18 接收日期: 2025-05-07

基金项目: 国家自然科学基金面上项目(52474278); 天地科技股份有限公司科技创新创业资金专项项目(2023-TD-MS016)

第一作者: 刘 譞, 2001 年生, 男, 陕西金台人, 硕士研究生。E-mail: 2608401617@qq.com

*通信作者: 姬亚东, 1976 年生, 男, 陕西米脂人, 博士, 研究员, 硕士生导师。E-mail: Jiyadong@cctegxian.com

© Editorial Office of Coal Geology & Exploration. OA under CC BY-NC-ND

Prevention and Control Technology for Coal Mine Water Hazard, Xi'an 710077, China

Abstract: [Background] The accurate prediction of mine water inflow plays a significant role in the prevention and control of water hazards and the safe and efficient production in coal mines. [Methods] To construct a prediction model of water inflow in mines under threat of water hazards from extremely thick sandstones aquifer in West China, this study investigated a typical mine (also referred to as the studied mine) severely affected by such water hazards in the Binchang mining area of Shaanxi Province. The correlation between the mining footage and water inflow of the mining face was selected as the characteristic variable for the time series prediction of mine water inflow. Accordingly, this study proposed a prediction model for water inflow along the mining face in the studied mine based on the temporal convolutional network (TCN), long short-term memory (LSTM), and support vector machine (SVM)—the TCN-LSTM-SVM model. First, by raw data processing using the TCN framework, this model extracted the dependency between mining footage and water inflow and its dynamic characteristics. Subsequently, the extracted characteristics were output to the LSTM-SVM model to further capture the time series relationship between mining footage and water inflow and its characteristics. [Results] The training and prediction results indicate that the TCN-LSTM-SVM model yielded mean absolute errors (E_{MA}) ranging from 56.02 m³/h to 129.89 m³/h, mean absolute percentage errors (E_{MAP}) from 3 % to 7 %, root mean square errors (E_{RMS}) from 82.60 m³/h to 162.61 m³/h, and coefficients of determination (R^2) from 0.81 to 0.98 based on the training, validation, and test sets. This model exhibited more accurate prediction results compared to the commonly used prediction models like backpropagation neural network (BPNN), random forest (RF), and Transformer while avoiding excessive errors produced by most of these models on the validation and test sets. The results indicate that the TCN-LSTM-SVM model integrated the parallel processing advantages and multi-scale feature extraction capacity of the TCN model while also enjoying the excellent prediction performance and generalization capability of the LSTM-SVM model. Compared to previously developed models, the TCN-LSTM-SVM model demonstrated certain superiority and applicability in the prediction of water inflow along the mining face in the studied mine. [Conclusions] The results of this study provide a new approach to water inflow prediction for mines with similar geological conditions to those in the Binchang mining area. Therefore, this study holds practical implications for water inflow prediction and water prevention and control in mining faces with similar geological conditions to those in the studied mine.

Keywords: mine water hazard; coal seam roof; water inflow prediction; temporal convolutional network; long short-term memory (LSTM) network; support vector machine (SVM); Binchang mining area in Shaanxi

我国的能源禀赋特征决定了煤炭资源在我国能源安全保障中的重要作用,当前阶段煤炭仍然是我国的主体能源^[1-3]。但煤炭资源生产会导致煤层上覆岩层破坏并伴随大量矿井水的产生^[4-6],在陕西彬长、甘肃宁正等矿区受上覆白垩系洛河组巨厚砂岩含水层水害影响更为强烈,矿井涌水量巨大。以彬长矿区某煤矿为例(后文称为研究矿井),研究矿井属西部黄陇侏罗纪煤田,区内煤层厚度较大(一般超过 5 m),上覆白垩系洛河组巨厚砂岩含水层,该含水层厚度一般超过 300 m,最厚可达 600 m,可释放出大量地下水,且该矿采用综放开采工艺,对上覆岩层扰动强烈,导致其矿井涌水量普遍较大,单个工作面涌水量可达 2 000 m³/h 以上,严重威胁矿井生产^[7-9],同时也对当地自然环境造成了一定破坏,如生态环境破坏、地下水位下降与水质恶化等。

通过预测矿井工作面涌水量,可对工作面后续涌水情况有一定了解,矿井涌水量的大小决定了煤矿开采针对矿井水治理投入成本的大小,而准确预测矿井与工作面涌水量是煤矿降低生产成本、安全高效生产的重要工作之一^[10-11]。国内学者利用解析法^[11]、数值法^[12]、灰色系统法^[13]以及多种综合方法^[14],对矿井涌水量预测进行了研究。其中解析法预测矿井涌水量具有较强

的科学性和逻辑性,但需要获得精确的地质参数,前期工作难度太大,且数据误差可能导致预测准确率降低^[15];数值法能够了解地下水进入矿井的动态变化过程,但模型建立复杂、计算量大且耗时长;灰色系统预测矿井涌水量的适用性强,计算简单,但对数据的质量要求较高且长期预测的精度较差。

近年来,随着计算机技术的发展,学者通过机器学习或深度学习预测矿井涌水量的方法逐渐成熟^[16-19],该方法可通过对涌水量样本数据进行训练并提取其中的非线性关系,预测精度高,在大数据场景下表现优异。侯恩科等^[20]通过模态分解深度学习组合模型等对彬长矿区大佛寺煤矿的涌水量进行了预测,发现进行优化后的组合模型比单因素时序模型在矿井涌水量预测上具有更好的适用性与优越性。王飞等^[21]通过变分模态分解对原数据进行处理,并通过贝叶斯算法优化的双向长短期记忆网络模型对彬长矿区文家坡煤矿的矿井涌水量进行预测,验证了该模型的有效性。丁莹莹等^[22]通过提取矿井涌水多因素特征变量,采用 SSA-CG-Attention 多因素矿井工作面涌水量预测模型,对彬长矿区亭南煤矿 207 工作面涌水量进行了预测,发现该模型预测结果更加准确稳定。Shi Junwei 等^[23]通过融合

基于自注意力机制的 Transformer 算法和捕获数据长期依赖关系的 LSTM 算法的时间序列预测模型, 对黑龙江某矿井的矿井涌水量进行了预测, 发现该模型具有较好的预测精度。但研究矿井作为受煤层顶板巨厚砂岩含水层水害影响的典型矿井, 矿井涌水条件复杂, 常规神经网络或上述时间序列模型对该矿涌水量数据的拟合结果误差极大, 因此亟需一种适用于该煤矿的涌水量预测模型。

基于国内学者研究成果^[24-28], 笔者结合研究矿井 3406 工作面回采进尺以及涌水量数据, 提出一种 TCN-LSTM-SVM 耦合模型, 区别于通过统计大量地质资料和数据及构建复杂模型的传统涌水量预测方法, 该耦合模型仅需提取回采进尺与涌水量的数据特征并进行时间序列预测, 跳出回归预测模型、数值模拟或数值分析模型预测矿井涌水量需要大量基础地质资料和数据缺陷, 预测成本低且准确度较高。通过该模型对研究矿井 3406 工作面涌水量进行较准确的预测, 以期对矿井防治水工作提供依据。

1 基本原理

1.1 TCN 框架

时域卷积网络 (temporal convolutional network, TCN) 是一种专为处理时间序列数据设计的深度学习模型, 广泛应用于时间序列预测、多序列分类等问题^[29], 可有效地对煤矿工作面未来涌水量或相似地质条件的工作面涌水量进行预测。TCN 引入了因果卷积和扩展卷积, 即结合了卷积神经网络 (convolutional neural network, CNN) 的特点可以有效捕捉时间序列数据的长时间依赖关系, 进而替代传统处理序列数据的循环神经网络 (recurrent neural network, RNN), 以克服他们在处理长序列时可能存在的梯度消失和梯度爆炸等问题^[30]。其主要有以下 3 个核心结构。

1) 因果卷积

因果卷积表示在序列处理中, 输出序列中的元素仅依赖于当前时间步以及之前的时间步, 而不会使用后续或未来的特征信息, 即对于输入序列 $x = [x_1, x_2, \dots, x_t]$, 输出序列 y_t 仅依赖于 $[x_1, x_2, \dots, x_t]$, 而不会依赖于 $[x_{t+1}, x_{t+2}, \dots]$, 这确保了模型的输出只依赖于过去的输入, 且保持原来的时间顺序, 这样的结构称为“因果性”^[31](图 1)。对于使用机器学习方法预测涌水量而言, 训练模型可实现依赖当前时间步之前输入的涌水量数据, 而不是通过“窥视”未来的涌水量数据来预测当前的涌水量。采用因果卷积可有效地确保序列处理和训练时的时间顺序, 避免后续涌水量数据对当前训练的影响, 使训练过程具有较好的稳定性。




图 1 因果卷积

Fig.1 Causal convolution

2) 扩展卷积

扩展卷积通过在卷积核之间增加空洞, 可在不增加参数数量的情况下扩大卷积层的感受野, 从而捕获更长的时间依赖关系(图 2)。扩展卷积的公式^[32]如下。

$$y(t) = \sum_{i=0}^{k-1} W_{ki} x(t-id) \quad (1)$$

通过调整扩展率 d 的大小, 可以使模型在涌水量数据的多个时间尺度上进行特征提取, 既可以捕捉到涌水量在短期内的变化, 也能识别出长期的涌水量变化趋势和周期变化趋势。




图 2 扩展卷积

Fig.2 Dilated convolution

3) 残差连接

TCN 具有多个残差连接层, 其训练过程中通常使用残差连接层来跳过中间层, 不仅可加速模型的训练过程, 同时缓解梯度消失、梯度爆炸等问题(图 3)。残差连接层可将输入信息与卷积输出信息直接相加, 确保在网络层数较深时信息也能有效传递。残差连接的公式^[30]如下。




图 3 残差连接

Fig.3 Residual connection

$$r = \text{ReLU}[\text{Conv}(x)] + x \quad (2)$$

本文模型中利用 TCN 的并行计算及特征提取能力, 用其做前置网络对回采进尺和涌水量数据进行预处理, 并提取数据的多尺度特征, 然后将这些特征输入后续框架, 以进一步捕捉回采进尺与涌水量之间复杂的时序依

赖关系和动态特征。

1.2 LSTM 框架

LSTM 是上述提到的 RNN 的一种改进模型, 其引入了输入门、遗忘门和输出门等门结构以及细胞状态等机制^[33](图 4)。




图 4 LSTM 框架

Fig.4 LSTM framework

1) 遗忘门

遗忘门根据上一步的输出和当前新的输入决定遗忘无用信息: 将输入和上一步的输出整合为一个单独的向量, 通过 σ 激活函数点乘在细胞状态上。遗忘门的计算公式如下。

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \quad (3)$$

2) 输入门

输入门是决定有用特征或信息被选取进入细胞状态的控制单位。其通过 $\tanh$ 激活函数提取现有向量的有用信息, 后通过 σ 激活函数决定有用信息进入细胞状态中的数量。输入门的计算公式如下。

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad (4)$$

$$\tilde{C}_t = \tanh(W_C[h_{t-1}, x_t] + b_C) \quad (5)$$

3) 细胞状态

细胞状态可将经过遗忘门的信息和经过输入门新增的信息相加得到新的细胞状态, 细胞状态的计算公式如下。

$$C_t = C_{t-1}f_t + \tilde{C}_ti_t \quad (6)$$

4) 输出门

通过输出门可整合细胞状态与 σ 激活函数确定的输出部分相乘得到最后的输出信息或特征, 输出门的计算公式如下。

$$O_t = \sigma(W_O[h_{t-1}, x_t] + b_O) \quad (7)$$

$$h_t = O_t \tanh(C_t) \quad (8)$$

这些机制可以改善 RNN 训练时权重影响过大以及梯度消失等问题, LSTM 单元可以长时间保存有用的数据, 比传统的 RNN 能更好地捕获长期依赖关系, 但 LSTM 需要大量数据进行训练以防止过拟合问题, 且相比传统的 RNN, 因引入了门结构和长期记忆机制导致其计算复杂度更高。

1.3 SVM 框架

SVM 回归是一种基于支持向量机的回归方法, 目前关于支持向量机方法的运用已较为成熟, 其通过构建一个最优决策面, 使离该决策面最近样本点的函数间隔最大化, 得到的具有“最大间隔”的决策面就是 SVM 最优解。对于输入的新样本, SVM 可通过训练的最优决策面进行预测。该方法对于非线性数据具有较好的泛化能力和鲁棒性。

2 模型构建及评价指标

2.1 耦合 TCN-LSTM-SVM 框架

针对 LSTM 需要数据多及计算时间长的缺点和 SVM 较好的泛化能力的优点, 本研究提出通过集成 2 种模型的方法集成训练 LSTM 与 SVM, 根据 2 个模型运行的误差对两模型加权得到一个组合模型, 以提升 2 个模型整体的预测性能和泛化能力。

如图 5 所示, 首先将整个输入数据集按照开采的时间顺序以 7 : 2 : 1 的比例划分为训练集、验证集和测

试集, 即 3406 工作面共开采 594 d, 选取从开始回采到第 416 天的涌水量数据为训练集, 第 417 天到第 535 天的涌水量数据为验证集, 第 536 天到第 594 天的涌水量数据为测试集。首先设置一个超参数选取范围, 超参数即模型运行前可自行设置, 并控制模型性能的参数, 如学习率、网络层数及隐藏层数等。给定超参数, 将训练集数据分别在 LSTM 和 SVM 模型上进行训练, 得到模型 M_{LSTM} 和 M_{SVM} 。随后采用验证集数据在训练的 2 个模型上进行测试, 多次迭代后找到最佳超参数模型, 同时记录验证集在 2 个模型上与真实值的误差 E_{LSTM} 和 E_{SVM} 。对不同训练模型的误差进行判断, 若 2 个模型

之间误差相差较大, 则选择误差小的模型为最优模型; 若 2 个模型之间误差小于一定的阈值 θ 且满足 2 个模型误差的相对差值比小于 θ , 则可通过误差 E_{LSTM} 和 E_{SVM} 来决定权重, 并对 2 个模型进行权重组合, θ 的判别公式和权重的计算公式如下。

$$\frac{|E_{LSTM} - E_{SVM}|}{\max(E_{LSTM}, E_{SVM})} < \theta \quad (9)$$

$$W_{LSTM} = \frac{E_{SVM}}{E_{LSTM} + E_{SVM}} \quad (10)$$

$$W_{SVM} = \frac{E_{LSTM}}{E_{LSTM} + E_{SVM}} \quad (11)$$




图5 LSTM-SVM 组合模型

Fig.5 LSTM-SVM combined model

经过测试集后可以得到测试集上的预测值分别为 y_{LSTM} 和 y_{SVM} , 则模型集成后的预测结果为 $y = W_{LSTM} \cdot y_{LSTM} + W_{SVM} \cdot y_{SVM}$ 。

在此基础上, 将 TCN 框架作为前置网络模型与 LSTM-SVM 组合模型连接起来一起处理时序数据, 最终得到 TCN-LSTM-SVM 耦合模型。该模型将 TCN 当作前置网络, 将输出的回采进尺和涌水量时序数据进行初步处理, 提取出其中的关键特征, 然后将这些特征输入 LSTM-SVM 组合模型中, 以进一步捕捉复杂的回采进尺和涌水量时序关系和动态特征。耦合 3 种框架的模型既具备 TCN 模型的并行计算处理优势和对多尺度特征的提取能力, 同时也利用 LSTM-SVM 组合模型优秀的预测性能和泛化能力, 使得其在处理长依赖关系和复杂动态变化的时序数据时表现得更出色。

2.2 模型评价指标

为量化评价各模型的性能和准确程度, 本次训练采用平均绝对误差 E_{MA} 、平均绝对百分比误差 E_{MAP} 、均方根误差 E_{RMS} 、决定系数 R^2 来进行量化评价。其中, E_{MA} 、 E_{MAP} 及 E_{RMS} 值越接近 0, 则表明模型的性能越好, 准确程度越高; R^2 越接近 1, 则表明模型的性能越好, 准确程度越高。上述 4 个量化评价指标计算公式如下。

$$E_{MA} = \sum_{j=1}^m \frac{|x_j - y_j|}{m} \quad (12)$$

$$E_{MAP} = \frac{100\%}{m} \sum_{j=1}^m \frac{|x_j - y_j|}{x_j} \quad (13)$$

$$E_{RMS} = \sqrt{\frac{1}{m} \sum_{j=1}^m (x_j - y_j)^2} \quad (14)$$

$$R^2 = 1 - \frac{\sum_{j=1}^m (x_j - y_j)^2}{\sum_{j=1}^m (x_j - \bar{x})^2} \quad (15)$$

3 涌水量预测实践分析及对比

3.1 研究矿井概况

研究矿井是我国西部地区受煤层顶板巨厚砂岩含水层水害严重威胁的典型矿井, 目前主采侏罗系延安组 4 煤, 研究矿井区域内的含、隔水层从上到下分布见表 1。

煤层上覆含水层为侏罗系延安组、直罗组砂岩含水层, 白垩系宜君组、洛河组和华池组砂岩-砾岩含水层, 主要充水含水层为洛河组巨厚砂岩含水层, 平均厚

表 1 研究煤矿含、隔水层分布

Table 1 Distributions of aquifers and aquicludes in the studied mine

含隔水层及岩性	厚度/m
第四系全新统冲、洪积含水层	0~20.00
第四系中更新统黄土含水层	67.00~190.00
新近系小章沟组红土隔水层段	40.00~116.52
白垩系华池组泥岩隔水层	0~605.00
白垩系洛河组砂砾岩含水层	75.00~581.00
白垩系宜君组砾岩含水层	0~76.00
侏罗系安定组泥岩、泥灰岩隔水层	0~110.56
侏罗系直罗组粗砂岩含水层	10.00~86.00
侏罗系中统延安组及煤层顶板含水层	0~153.36
侏罗系延安组4号煤层系	0~18.00
侏罗系富县组泥岩隔水层	0~82.00

度为 400.4 m, 富水性较强, 经实测导水裂隙带发育至洛河组内部, 导致该矿矿井涌水量较大。经统计, 自研究矿井 2019 年投产至 2023 年 8 月, 矿井涌水量呈阶梯式上升, 稳定于 5 500 m³/h 左右, 目前回采的 3406 工作面涌水量可达 2 500 m³/h 以上, 工作面回采进尺与涌水量统计如图 6 所示。因此, 准确地预测工作面涌水量对于该矿进行资源合理调配、降低煤炭生产成本以及保证工作面安全生产具有重要的意义。




图 6 研究矿井 3406 工作面回采进尺与涌水量关系

Fig.6 Relationship between mining footage and water inflow of mining face 3406 in the studied mine

3.2 各模型预测结果对比

将 TCN-LSTM-SVM 耦合模型与传统预测模型 BP 神经网络、RF、Transformer 以及耦合模型中的单一模型在原始涌水量数据集上进行训练、验证及测试, 结果如图 7、图 8 所示, 因为各模型的训练集拟合结果相近, 故除 TCN-LSTM-SVM 模型的训练集结果外, 其余模型的训练集结果不再展示。

对比耦合模型 TCN-LSTM-SVM 的训练集与 BP 神经网络、RF、Transformer 等模型的训练集拟合结果, 可以看出各模型训练集拟合程度均较高, 其中 TCN-




图 7 TCN-LSTM-SVM 耦合模型的拟合结果


Fig.7 Fitting results of the TCN-LSTM-SVM coupling model

LSTM-SVM 耦合模型训练集拟合程度最好。从各模型评价指标结果(表 2)也可以看出, 各模型训练集中 TCN-LSTM-SVM 模型的 E_{MA} 和 E_{RMS} 最小, 分别为 56.02、82.60 m³/h, 该模型 R^2 最大, 为 0.98, 表明该模型的训练集拟合效果最好; Transformer 模型的 E_{MA} 和 E_{RMS} 最大, 分别为 135.08、172.35 m³/h, 且其 R^2 最小为 0.91。各项训练集数据也反映出各模型训练集拟合程度均较高, 且 TCN-LSTM-SVM 的训练集拟合程度最好, 这与训练集拟合结果是一致的。



对比 TCN-LSTM-SVM 耦合模型与 BP、RF 等模型的验证集、测试集拟合结果(图 7、图 8)以及各项评价指标结果(表 2), 可以明显看到, 除 TCN-LSTM-SVM 耦合模型拟合结果较好外, 其余所有模型的拟合结果均

较差,其中 TCN-LSTM-SVM 模型的误差最小,验证集的 E_{MA} 、 E_{MAP} 和 E_{RMS} 分别为 $129.89 \text{ m}^3/\text{h}$ 、 0.07 和 $162.61 \text{ m}^3/\text{h}$,测试集的 E_{MA} 、 E_{MAP} 和 E_{RMS} 分别为 $68.66 \text{ m}^3/\text{h}$ 、 0.03 和 $85.74 \text{ m}^3/\text{h}$,且该模型验证集和测试



集的决定系数 R^2 分别为 0.86 和 0.81 。除该模型外,其余模型不论验证集和测试集的各项误差评价指标均较大,且除 LSTM-SVM 模型验证集和测试集的 R^2 为正值,其余模型验证集和测试集的 R^2 出现了负值的情况,代





(a) BP 模型




(b) RF 模型



(c) LSTM-SVM 模型



(d) TCN 模型






图 8 不同模型的验证集和测试集的拟合结果
Fig.8 Fitting results of varying models based on the same validation and test sets

表 2 各模型评价指标统计结果
Table 2 Statistics of the assessment metrics of various models

样本	参数	TCN-LSTM-SVM	BP	Transformer	RF	LSTM-SVM	TCN	TCN-LSTM
训练集	$E_{MA}/(m^3 \cdot h^{-1})$	56.02	85.45	135.08	58.32	92.23	105.49	119.44
	$E_{MAP}/\%$							
	$E_{RMS}/(m^3 \cdot h^{-1})$	82.60	121.03	172.35	82.44	164.49	137.98	224.87
	R^2	0.98	0.95	0.91	0.97	0.94	0.94	0.95
验证集	$E_{MA}/(m^3 \cdot h^{-1})$	129.89	459.77	247.10	317.71	213.22	295.68	381.00
	$E_{MAP}/\%$	7	22	13	16	11	15	18
	$E_{RMS}/(m^3 \cdot h^{-1})$	162.61	576.77	322.70	396.15	281.96	368.34	473.77
	R^2	0.86	-0.37	0.46	0.16	0.59	0.34	0
测试集	$E_{MA}/(m^3 \cdot h^{-1})$	68.66	1 078.54	169.08	504.20	153.26	394.56	751.89
	$E_{MAP}/\%$	3	43	7	20	7	16	30
	$E_{RMS}/(m^3 \cdot h^{-1})$	85.74	1 109.47	198.94	535.01	165.58	420.03	771.37
	R^2	0.81	-5.49	-0.23	-8.32	0.15	-2.60	-15.36

表各模型拟合结果的预测误差极大,即模型并不适用于研究矿井涌水量预测。而耦合模型的基础模型 LSTM-SVM 模型在经过 TCN 模块对其优化后,各项评价误差不仅大幅度下降, R^2 也有明显提升,这表明 TCN-LSTM-SVM 模型对于研究矿井涌水量的预测具有较强的适用性。该模型的建立,对于该矿的矿井涌水量智能预测与矿井防治水工作有一定的指导意义。

4 结论

- (1) TCN-LSTM-SVM 耦合模型可用于研究矿井的工作面涌水量时间序列预测,不仅拥有较强的并行计算与特征提取能力,且具有较强的预测性能与泛化能力。相比其余常用的预测模型误差大幅度降低,决定系数 R^2 也有明显的提升,表现出了优越的拟合性能。
- (2) TCN-LSTM-SVM 耦合模型对于研究矿井的

3406 工作面涌水量预测具有较强的准确性和适用性,跳出了传统回归模型需要收集大量数据的缺陷,为该矿防治水与涌水量预测提供了新方法,具有一定的指导意义。

(3) 该模型仅考虑了回采进尺与涌水量数据之间的关系,未来将在彬长矿区其他矿井进一步收集矿井涌水量数据并引入新参数或新指标以深入研究,使该模型在矿区进行推广应用,进一步提升模型的可推广性。

符号注释:

b_c 、 b_f 、 b_i 、 b_o 为偏置值; $\text{Conv}(x)$ 为卷积层的输出; C_t 为 t 时刻的细胞状态; C_{t-1} 为上一时刻的细胞状态; $\tilde{C}_t$ 为隐藏的细胞状态; $C_{t-1}f_t$ 为 C_{t-1} 时刻被遗忘的信息数; $\tilde{C}_ti_t$ 为 $\tilde{C}_t$ 被保留的信息数; d 为扩展率; f_t 为遗忘门控单元; $h_1, h_2, \dots, h_n$ 为不同时刻的输出状态; h_t 为当前时刻的输出状态; h_{t-1} 为上一时刻的输出状态; i 为卷积核数; i_t 为输入门控单元; k 为卷积核的大小; m 为时序数据总数; n 为门结构数; O_t 为 t 时刻的输出; W_c 为细胞状态的权重; W_f 为遗忘门中连接输入与隐藏层神经元的权重; W_i 为输入门中连接输入与隐藏层神经元的权重; W_{ki} 为第 i 个卷积核的权重; W_{LSTM} 为模型耦合时 LSTM 模型的权重; W_o 为输出门中连接输入与隐藏层神经元的权重; W_{SVM} 为模型耦合时 SVM 模型的权重; ReLU 为残差连接的激活函数; r 为输出残差; t 为时序数据的时间步; $\tanh$ 为 LSTM 输入的激活函数; x 为残差连接的输入; $\bar{x}$ 为涌水量真实值的均值; x_j 为涌水量真实值; $x_1, x_2, \dots, x_t, \dots, x_n$ 为不同时刻新的输入; x_t 为当前时刻新的输入; $x(t-id)$ 为过去的的数据; y_j 为涌水量预测值; $y(t)$ 为输出数据; σ 为神经网络的 Sigmoid 激活函数。

利益冲突声明/Conflict of Interests

所有作者声明不存在利益冲突。

All authors disclose no relevant conflict of interests.

参考文献(References)

- [1] 王双明, 申艳军, 宋世杰, 等. “双碳”目标下煤炭能源地位变化与绿色低碳开发[J]. 煤炭学报, 2023, 48(7): 2599–2612.
WANG Shuangming, SHEN Yanjun, SONG Shijie, et al. Change of coal energy status and green and low-carbon development under the “dual carbon” goal[J]. Journal of China Coal Society, 2023, 48(7): 2599–2612.
- [2] 杨建, 蒲悦. 我国西部矿井涌水分布特征及充水模式研究[J/OL]. 煤炭科学技术, 2025: 1–13 [2025-01-16] [2025-03-18]. <https://kns.cnki.net/KCMS/detail/detail.aspx?filename=MTKJ20241219002&dbname=CJFD&dbcode=CJFQ>.
YANG Jian, PU Yue. Research on the distribution characteristics and water filling modes of mine water inflow in western mining

- areas of China[J/OL]. Coal Science and Technology, 2025: 1–13 [2025-01-16] [2025-03-18]. <https://kns.cnki.net/KCMS/detail/detail.aspx?filename=MTKJ20241219002&dbname=CJFD&dbcode=CJFQ>.
- [3] 孙文洁, 李文杰, 宁殿艳, 等. 我国煤矿水害事故现状、预测及防治建议[J]. 煤田地质与勘探, 2023, 51(12): 185–194.
SUN Wenjie, LI Wenjie, NING Dianyan, et al. Current states, prediction and prevention suggestions for water hazard accidents in China's coal mines[J]. Coal Geology & Exploration, 2023, 51(12): 185–194.
- [4] 顾大钊, 李井峰, 曹志国, 等. 我国煤矿矿井水保护利用发展战略与工程科技[J]. 煤炭学报, 2021, 46(10): 3079–3089.
GU Dazhao, LI Jingfeng, CAO Zhiguo, et al. Technology and engineering development strategy of water protection and utilization of coal mine in China[J]. Journal of China Coal Society, 2021, 46(10): 3079–3089.
- [5] 韦华鹏, 罗奇斌, 康卫东, 等. 基于不同开采方式的煤矿涌水量预测及其环境影响分析[J]. 水文地质工程地质, 2023, 50(1): 21–31.
WEI Huapeng, LUO Qibin, KANG Weidong, et al. Prediction of coal mine water inflow by different mining methods and environment impact analyses[J]. Hydrogeology & Engineering Geology, 2023, 50(1): 21–31.
- [6] 周振方, 董书宁, 董阳, 等. 蒙陕接壤区典型煤层开采顶板周期性变形破坏及涌水响应特征[J]. 煤田地质与勘探, 2024, 52(8): 101–110.
ZHOU Zhenfang, DONG Shuning, DONG Yang, et al. Periodic roof deformation and failure and associated water inflow characteristics during the mining of typical coal seams in the Inner Mongolia-Shaanxi contiguous area[J]. Coal Geology & Exploration, 2024, 52(8): 101–110.
- [7] 李超峰, 刘业献, 张金魁, 等. 基于双 Packer 抽水试验的洛河组水文地质特征垂向变异性研究[J]. 煤田地质与勘探, 2023, 51(11): 55–64.
LI Chaofeng, LIU Yexian, ZHANG Jinkui, et al. Vertical variability of hydrogeological characteristics of Luohe Formation by double packer system pumping test[J]. Coal Geology & Exploration, 2023, 51(11): 55–64.
- [8] 冯龙飞, 王双明, 王海, 等. 彬长矿区典型顶板水害矿井洛河组砂岩微观孔隙特征研究[J]. 煤炭科学技术, 2023, 51(8): 208–218.
FENG Longfei, WANG Shuangming, WANG Hai, et al. Micro pore characteristics of Luohe aquifer sandstone in Binchang mining area typical roof water hazard mines[J]. Coal Science and Technology, 2023, 51(8): 208–218.
- [9] 郭小铭. 彬长矿区洛河组沉积控水及开采扰动流场响应特征研究[D]. 北京: 煤炭科学研究总院, 2022: 13–14.
GUO Xiaoming. Sedimentary controlling groundwater in Luohe Formation and the water flow field response regularity after mining disturbance in Binchang mining area[D]. Beijing: China Coal Research Institute, 2022: 13–14.
- [10] 周全超, 王丹丹, 党志伟, 等. 矿井涌水量预测方法及对比分析: 以新疆东沟煤矿为例[J]. 煤炭科学技术, 2024, 52(增刊 1): 211–220.

- ZHOU Quanchao, WANG Dandan, DANG Zhiwei, et al. Research and comparative analysis of mine water inflow prediction method: A case study of Donggou coal mine in Xinjiang[J]. Coal Science and Technology, 2024, 52(Sup.1): 211–220.
- [11] 周全超, 刘玲, 李继升, 等. 基于多种解析法和数值法求解巨厚砂岩水文地质参数[J]. 煤炭科学技术, 2024, 52(增刊 1): 174–182.
- ZHOU Quanchao, LIU Ling, LI Jisheng, et al. Solving hydrogeological parameters of thick sandstone based on various analytical and numerical methods[J]. Coal Science and Technology, 2024, 52(Sup.1): 174–182.
- [12] 胡兵, 刘会月, 李媛, 等. Modflow 中关键参数取值对矿井涌水量预测的影响研究[J]. 煤炭工程, 2024, 56(10): 247–253.
- HU Bing, LIU Huiyue, LI Yuan, et al. Influence of key parameter values in Modflow on mine water inflow prediction[J]. Coal Engineering, 2024, 56(10): 247–253.
- [13] 李建林, 王路扬, 李松营, 等. 基于灰色-多步马尔科夫模型的矿井涌水量预测[J]. 河南理工大学学报(自然科学版), 2023, 42(5): 66–71.
- LI Jianlin, WANG Luyang, LI Songying, et al. Forecast of mine water inflow based on grey-multi-step Markov model[J]. Journal of Henan Polytechnic University (Natural Science), 2023, 42(5): 66–71.
- [14] 朱奎奎, 黄鑫磊. 基于 Visual MODFLOW 的煤层底板突水量预测研究[J]. 煤炭科学技术, 2020, 48(8): 157–163.
- ZHU Zongkui, HUANG Xinlei. Study on water intrush quantity prediction from coal seam floor based on Visual MODFLOW[J]. Coal Science and Technology, 2020, 48(8): 157–163.
- [15] 徐智敏, 陈天赐, 陈歌, 等. 煤层采动顶板水文地质参数演化与矿井涌水量动态计算方法[J]. 煤炭学报, 2023, 48(2): 833–845.
- XU Zhimin, CHEN Tianci, CHEN Ge, et al. Hydrogeological parameter evolution of coal seam roof and dynamic calculation method of mine water inflow[J]. Journal of China Coal Society, 2023, 48(2): 833–845.
- [16] 董书宁. 人工智能技术在煤矿水害防治智能化发展中的应用[J]. 煤矿安全, 2023, 54(5): 1–12.
- DONG Shuning. Application of artificial intelligence technology in intelligent development of coal mine water disaster prevention and control[J]. Safety in Coal Mines, 2023, 54(5): 1–12.
- [17] 姚辉, 尹慧超, 梁满玉, 等. 机器学习方法在矿井水防治理论体系研究中的应用思考[J]. 煤田地质与勘探, 2024, 52(5): 107–117.
- YAO Hui, YIN Huichao, LIANG Manyu, et al. Some reflections on the application of machine learning to research into the theoretical system of mine water prevention and control[J]. Coal Geology & Exploration, 2024, 52(5): 107–117.
- [18] 李建林, 高培强, 王心义, 等. 基于混沌-广义回归神经网络的矿井涌水量预测[J]. 煤炭科学技术, 2022, 50(4): 149–155.
- LI Jianlin, GAO Peiqiang, WANG Xinyi, et al. Prediction of mine water inflow based on chaos-generalized regression neural network[J]. Coal Science and Technology, 2022, 50(4): 149–155.
- [19] 侯恩科, 夏冰冰, 吴章涛, 等. 基于 CEEMDAN-BO-BiGRU 的矿井涌水量预测研究[J]. 科学技术与工程, 2023, 23(28): 12012–12019.
- HOU Enke, XIA Bingbing, WU Zhangtao, et al. Mine water inflow prediction based on CEEMDAN-BO-BiGRU[J]. Science Technology and Engineering, 2023, 23(28): 12012–12019.
- [20] 侯恩科, 徐林啸, 荣统瑞, 彬长大佛寺矿井涌水量时序预测[J]. 西安科技大学学报, 2024, 44(3): 490–500.
- HOU Enke, XU Linxiao, RONG Tongrui. Time series prediction of mine water inflow from Binchang Dafosi mine[J]. Journal of Xi'an University of Science and Technology, 2024, 44(3): 490–500.
- [21] 王飞, 荣统瑞, 侯恩科, 等. 基于 VMD-BiLSTM 组合模型的矿井涌水量时间序列预测方法研究[J]. 矿业研究与开发, 2024, 44(3): 143–151.
- WANG Fei, RONG Tongrui, HOU Enke, et al. Research on time series prediction method of mine water inflow based on VMD-BiLSTM combined model[J]. Mining Research and Development, 2024, 44(3): 143–151.
- [22] 丁莹莹, 尹尚先, 连会青, 等. 基于 SSA-CG-Attention 模型的多因素采煤工作面涌水量预测[J]. 煤田地质与勘探, 2024, 52(4): 111–119.
- DING Yingying, YIN Shangxian, LIAN Huiqing, et al. Prediction of mine water inflow along mining faces using the SSA-CG-Attention multifactor model[J]. Coal Geology & Exploration, 2024, 52(4): 111–119.
- [23] SHI Junwei, WANG Shiqi, QU Pengfei, et al. Time series prediction model using LSTM-Transformer neural network for mine water inflow[J]. Scientific Reports, 2024, 14: 18284.
- [24] 杨鑫源, 范传光, 叶佳锐, 等. 基于 TCN-Attention 模型的电力负荷短期概率预测方法[J]. 供用电, 2025, 42(4): 91–98.
- YANG Xinyuan, FAN Chuanguang, YE Jiarui, et al. A short-term probability prediction method of power load based on TCN-Attention model[J]. Distribution & Utilization, 2025, 42(4): 91–98.
- [25] 李士哲, 张天宇, 谢家乐. 基于电池老化趋势重构与 TCN-GRU-Attention 网络的 SOH 估计[J]. 电力科学与工程, 2025, 41(3): 38–45.
- LI Shizhe, ZHANG Tianyu, XIE Jiale. SOH estimation based on battery aging trend reconstruction and TCN-GRU-Attention network[J]. Electric Power Science and Engineering, 2025, 41(3): 38–45.
- [26] 陆睿, 尹尚先, 王玉国, 等. 基于 GMS 的深部煤层开采工作面涌水量预测[J]. 煤矿安全, 2025, 56(1): 164–170.
- LU Rui, YIN Shangxian, WANG Yuguo, et al. Prediction of water inflow in deep coal seam mining face based on GMS[J]. Safety in Coal Mines, 2025, 56(1): 164–170.
- [27] 张琴琴, 刘文强, 陈之鸿, 等. 基于 LSTM-SVM 模型的河流流量预测[J]. 天津师范大学学报(自然科学版), 2023, 43(6): 45–52.
- ZHANG Qinqin, LIU Wenqiang, CHEN Zhihong, et al. Forecasting of river flow based on LSTM-SVM model[J]. Journal of Tianjin Normal University (Natural Science Edition), 2023, 43(6): 45–52.
- [28] 王发麟, 俞威. 基于 TCN-LSTM 神经网络的线缆性能衰退预测方法[J]. 科学技术与工程, 2023, 23(35): 15109–15116.
- WANG Falin, YU Wei. Prediction method research of cable performance degradation state for complex mechatronic products based on TCN-LSTM[J]. Science Technology and Engineering, 2023, 23(35): 15109–15116.

- [29] 赵玉, 陈丽霞, 梁梦姣. 基于 LSTM-TCN 模型的降雨型滑坡时间概率预测及气象预警建模[J]. 地质科技通报, 2024, 43(2): 201-214.
ZHAO Yu, CHEN Lixia, LIANG Mengjiao. Temporal probability prediction and meteorological early warning modeling of rainfall-induced landslide based on LSTM-TCN model[J]. Bulletin of Geological Science and Technology, 2024, 43(2): 201-214.
- [30] 王超, 赵永良, 王杰, 等. 基于 TCN-LSTM-SE 神经网络的低压有源配电网电压控制方法研究[J]. 供用电, 2025, 42(4): 48-58.
WANG Chao, ZHAO Yongliang, WANG Jie, et al. Research on voltage control method of low voltage active distribution network based on TCN-LSTM-SE neural network[J]. Distribution & Utilization, 2025, 42(4): 48-58.
- [31] 苏连成, 朱娇娇, 李英伟. 基于时间卷积网络残差校正的短期风电功率预测[J]. 太阳能学报, 2023, 44(7): 427-435.
SU Liancheng, ZHU Jiaojiao, LI Yingwei. Short-term wind power prediction based on temporal convolutional network residual correction model[J]. Acta Energiae Solaris Sinica, 2023, 44(7): 427-435.
- [32] 王舒雨, 李豪, 马刚, 等. 基于 TCN 和 DLinear 的光伏发电功率多步预测模型[J]. 电力建设, 2025, 46(4): 173-184.
WANG Shuyu, LI Hao, MA Gang, et al. Multistep prediction model for photovoltaic power generation based on time convolution and DLinear[J]. Electric Power Construction, 2025, 46(4): 173-184.
- [33] 闫昭阳, 朱景宝, 刘赫奕, 等. CEEMDAN-LSTM 框架下的天然地震与矿震区分技术研究[J]. 煤炭学报, 2024, 49(增刊 2): 731-745.
YAN Zhaoyang, ZHU Jingbao, LIU Heyi, et al. CEEMDAN-LSTM framework for distinguishing natural and mining-induced seismicity[J]. Journal of China Coal Society, 2024, 49(Sup.2): 731-745.

(责任编辑 周建军)