



西北农林科技大学

硕士学位论文

基于深度学习 Self-Attention 的矿井涌水量预测模型研究

培 养 单 位 水利与建筑工程学院

专业学位类别 土木水利

专业学位领域 水利工程

论 文 作 者 姚东泽

指 导 教 师 陈实 讲师

合作指导教师 牟林 研究员

2024 年 6 月

Dissertation Submitted to Northwest A&F University
in Partial Fulfillment of the Requirements
for the Professional Degree of
Master of Civil and Hydraulic Engineering

Research on mine water inflow prediction model based on deep learning Self-Attention

Colleges: College of Water Resources and Architectural Engineering

Major: Hydraulic Engineering

Candidate: Yao Dongze

Supervisor: Chen Shi

Co- Supervisor: Mou Lin

June, 2024

分类号：TD80

UDC：556

密级：公开

学校代码：10712

研究生学号：2021055831

西北农林科技大学硕士学位论文

基于深度学习 Self-Attention 的矿井涌水量预测模型研究

论文作者：姚东泽

指导教师：陈实

答辩委员会：

西北农林科技大学 水利与建筑工程学院 张智韬 教授（主席）

西北农林科技大学 水利与建筑工程学院 向友珍 副教授

西北农林科技大学 水利与建筑工程学院 柳礼相 高级工程师

西北农林科技大学 水利与建筑工程学院 栗现文 副教授

西北农林科技大学 水利与建筑工程学院 陈俊英 教授

答辩日期：2024 年 05 月 21 日

本研究得到国家自然科学基金青年科学基金 (编号: 42330506)

煤矿水资源保护与利用国家重点实验室开放基金 (批准号:

GJNY-20-113-16)

摘要

煤矿生产中, 矿井涌水会带来一系列的安全问题和生产问题。准确的矿井涌水量预测能够为矿方制定煤矿安全策略、为地下水资源管理提供建议。传统的矿井涌水量预测方法包括了确定性模型和不确定性模型。其中确定性模型存在计算成本高、数据获取难度较大、建模复杂度高等问题, 非确定性模型存在适用性较差、精度较低等问题。机器学习的时间序列预测方法有改善传统模型缺陷的潜力, 在其他时间序列预测领域应用较为成熟。本文提出了一种基于 Self-Attention (自注意力机制) 的时间序列预测方法, 和一种基于自适应噪声完全集成经验模态分解 (CEEMDAN) 的多模型预测框架, 用于矿井涌水量的预测。提出的时间序列模型结合了前沿的深度学习预测技术, 提出的多模型预测框架能够融合多种模型优势, 解决更复杂问题。本文将提出的方法与框架应用于扎尼河露天矿矿井涌水量预测。

扎尼河露天矿在矿区北侧修建了地下水隔水帷幕工程。帷幕的建设改变了矿区水文地质条件, 使矿井水流入量突然变少, 对机器学习模型的预测造成了困难。通过将一种基于 Self-Attention 的时间序列预测方法应用于扎尼河露天矿矿井涌水量的预测中, 验证了模型和方法的适用性, 论文的主要研究成果如下:

(1) 通过改进 Transformer 中的 Self-Attention 模块, 提出了 Self-Attention 的矿井涌水量预测模型, 并用于研究区矿井涌水量预测。结果发现, Self-Attention 在趋势预测方面表现出色, 评估指标和测试集效果均好于对比模型, 在高频率序列的方面不如传统的门控循环神经网络 (LSTM)、门控循环神经网络 (GRU) 或支持向量机 (SVM) 模型。在时间序列预测方面表现出尚未发现的潜力。

(2) 本研究提出了基于 CEEMDAN 多模型的预测框架, 该框架能够融合多种模型的优势。通过结合 Self-Attention 模型、LSTM 模型、GRU 模型, 用于研究区矿井涌水量预测。与单一模型相比, 本文提出的多模型预测框架的平均绝对误差 (MAE) 提高了 26.12%, 均方根误差 (RMSE) 提高了 33.47%。

(3) 将本文提出的多模型预测框架与 Self-Attention 预测模型用于矿区的地下水位预测中, 结果得到了预期的效果。本文提出的预测框架在评估指标上优于单一模型以及 LSTM-GRU、TCN-GRU 和 CNN-MLP-LSTM 的多模型预测方法。

关键词: 矿井涌水量预测; 自注意力机制; CEEMDAN; LSTM; 时间序列预测

ABSTRACT

In coal mining operations, mine water inflow presents a series of safety and production challenges. Accurate prediction of mine water inflow can help formulate safety strategies for mining operations and provide recommendations for groundwater resource management. Traditional methods for predicting mine water inflow include deterministic and non-deterministic models. Deterministic models often suffer from high computational costs, difficulties in data acquisition, and complex modeling processes. Non-deterministic models, on the other hand, tend to have poor applicability and low accuracy. Machine learning-based time series prediction methods have the potential to address the shortcomings of traditional models and have been widely applied in other time series prediction fields. This paper proposes a time series prediction method based on the Self-Attention mechanism and a multi-model prediction framework based on Complete Ensemble Empirical Mode Decomposition with Adaptive Noise (CEEMDAN) for predicting mine water inflow. The proposed time series model integrates advanced deep learning prediction techniques, and the multi-model prediction framework leverages the advantages of various models to tackle more complex problems. The proposed methods and framework are applied to predict the mine water inflow of the Zhanni River open-pit mine.

The Zhanni River open-pit mine constructed an underground water barrier curtain on the north side of the mining area. The construction of this curtain altered the hydrogeological conditions of the mining area, leading to a sudden decrease in mine water inflow, which posed challenges for machine learning model predictions. By applying a time series prediction method based on Self-Attention to predict the mine water inflow of the Zhanni River open-pit mine, the suitability of the model and method was validated. The main research findings are as follows:

(1) By improving the Self-Attention module in the Transformer, a Self-Attention-based mine water inflow prediction model was proposed and applied to the prediction of mine water inflow in the study area. The results indicated that Self-Attention performed excellently in trend prediction, with evaluation metrics and test set results surpassing those of comparison models. However, in high-frequency sequences, it was outperformed by traditional models such as Long Short-Term Memory (LSTM), Gated Recurrent Unit (GRU), or Support Vector Machine (SVM). This demonstrates the potential of Self-Attention in time series prediction.

(2) This study proposed a CEEMDAN-based multi-model prediction framework capable of integrating the strengths of various models. By combining the Self-Attention model, LSTM

model, and GRU model for mine water inflow prediction in the study area, the proposed multi-model prediction framework improved the Mean Absolute Error (MAE) by 26.12% and the Root Mean Square Error (RMSE) by 33.47% compared to single models.

(3) The proposed multi-model prediction framework and Self-Attention prediction model were also applied to predict groundwater levels in the mining area, achieving the expected results. The proposed prediction framework outperformed single models as well as other multi-model prediction methods such as LSTM-GRU, TCN-GRU, and CNN-MLP-LSTM in evaluation metrics.

KEY WORDS: Mine water inflow prediction; self-attention mechanism; CEEMDAN; LSTM; time series prediction

目 录

第一章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	2
1.2.1 时间序列预测研究现状.....	2
1.2.2 矿井涌水量预测方法现状.....	3
1.2.3 机器学习方法现状.....	5
1.2.4 深度学习方法在矿井涌水量预测方面的应用	6
1.2.5 存在的问题.....	7
1.3 研究内容与技术路线.....	8
1.3.1 研究内容	8
1.3.2 技术路线.....	9
1.4 章节安排.....	9
第二章 研究方法概述	11
2.1 分解方法及原理.....	11
2.1.1 CEEMDAN 算法原理.....	11
2.1.2 变分模态分解.....	12
2.2 机器学习及深度学习方法介绍	12
2.2.1 长短期记忆网络(LSTM)	12
2.2.2 门控循环神经网络(GRU)	13
2.2.3 Self-Attention.....	14
2.2.4 支持向量机(SVM)	15
2.3 多模型预测框架介绍.....	16
2.4 评估指标.....	17
第三章 研究背景与研究区概况	19
3.1 研究区概况.....	19
3.1.1 研究区位置概况.....	19
3.1.2 矿井涌水概况.....	20
3.1.3 隔水帷幕概况.....	21
3.1.4 隔水帷幕对矿井涌水量预测的影响.....	22
3.1.5 地形地貌.....	22
3.1.6 水文气象.....	22
3.2 水文地质条件.....	23
3.3 实验设计.....	23
3.4 本章小结.....	24

第四章 单一模型预测矿井涌水量	25
4.1 数据分析	25
4.1.1 数据划分	25
4.1.2 数据分解方法介绍	27
4.1.3 数据分解	28
4.2 单一模型预测	29
4.2.1 模型选择	29
4.2.2 模型输入	30
4.2.3 单一模型预测结果分析	31
4.3 本章小结	33
第五章 多模型预测框架预测矿井涌水量	35
5.1 趋势分量的预测	35
5.1.1 数据输入	35
5.1.2 实验结果分析	36
5.2 多模型预测结果分析	38
5.2.1 数据输入	38
5.3 Self-Attention 结构分析	41
5.4 与其他多模型预测方法比较	42
5.5 多模型框架重构及模型选择	43
5.6 分解方法的选择	43
5.6.1 经验模态分解(EMD)	44
5.6.2 集成经验模态分解(EEMD)	45
5.6.3 互补集合经验模态分解(CEEMD)和自适应噪声集合经验模态分解(CEEMDAN)	45
5.6.4 变分模态分解(VMD)	46
5.7 本章小结	46
第六章 多模型预测框架预测水位数据	47
6.1 研究区地下水位数据介绍	47
6.2 地下水位监测井数据预测结果分析	50
6.2.1 N1 水位监测井预测结果	51
6.2.2 N4 水位监测井预测结果	52
6.2.3 Q4 水位监测井预测结果	53
6.2.4 观 13-2 水位监测井预测结果	54
6.2.5 Z4 水位监测井预测结果	55
6.3 本章小结	56
第七章 结论及展望	57
7.1 结论	57
7.2 创新点	58

7.3 不足及展望.....	58
参考文献.....	60

第一章 绪论

1.1 研究背景与意义

煤炭作为主要能源之一，在我国能源结构中扮演着重要角色。然而，煤矿开采过程中常常面临着矿井涌水的威胁，这不仅对矿山生产造成直接影响，开采活动往往会导致地下水位大幅下降，这可能会对植被产生不利影响，进而影响整个生态系统的稳定性（彭苏萍和毕银丽 2023; 武强等 2024; 顾大钊等 2016; 戴振学 1993; 王广才等 2002; 尹尚先等 2023; 卞正富等 2023; 毕银丽等 2024; 曹瑜等 2019; 董书宁等 2024; 张许良等 2003）。因此，对于矿井涌水量的准确预测与管理显得尤为迫切与重要。本论文旨在探讨矿井涌水量的预测方法，并就其对煤矿安全管理和生态环境维护的重要性进行深入研究与分析。

由于受地质条件、岩石渗透性、地下水位和降水等多种因素的影响，矿井涌水量的预测面临着极大的挑战。矿井涌水量预测涉及物理模型和数据驱动模型两大类方法。动态模型建立在对矿井涌水形成过程的理解和相关物理过程的数学表达或参数化基础上。在地下水动力学中，常用于矿井涌水量预测的方法包括解析法和数值方法。解析法相对较易应用，但在面对复杂条件和不规则情况时，其预测结果可能存在较大误差。相比之下，数值模拟可以结合计算机通过数学方程的求解，解决复杂条件下问题的理想方法。然而，数值模型的建立需要依赖许多对地质结构的假设，这些假设基于对地质情况的详细描述。此外，随着煤层开采深度的增加，需要控制的因素数量也相应增加，而获取地质特征的难度也在增加。实际情况中，改变进水量过程十分复杂，需要各种专业知识和实践能力的支持。

以往的研究主要集中在大井法和数值模拟方法上。数值模拟方法通过解决偏微分方程获得了出色的结果，从而实现了更加精确和科学准确的预测。然而，这种方法依赖于复杂地质数据以定义边界条件。地质数据的获取面临着巨大的挑战，随着采矿作业的进行，某些地质条件可能会发生变化，从而增加了数据获取的难度并降低了数据的可用性，进而进一步影响了模型的准确性。传统模型在处理复杂的地质和水文条件时受到数据获取困难的限制，但一些数据驱动模型已经出现，成为应对这一挑战的潜在解决方案。

近年来，机器学习方法在时间序列预测领域得到了广泛应用，在各个领域取得了显著的成功。长短期记忆网络（LSTM）、门控循环单元神经网络（GRU）、卷积神经网络（CNN）和反向传播神经网络（BPNN）等常见的深度学习模型擅长于从数据中提取潜在信息并捕获信息之间的时间依赖性。它们对数据维度表现出相对较高的容忍度。

许多研究表明,即使是一维输入,只要序列包含足够的信息,这些模型仍然可以获得鲁棒的预测结果,这是基于传统物理模型无法达到的能力。

2017年,Vaswani等人介绍了用于机器翻译的Transformer模型架构,其特点是Self-Attention机制,引起了研究人员的极大关注。它允许根据输入数据的特征将不同的注意力分配到序列中的各个位置,避免RNN遇到的梯度消失问题。即使是时间序列预测中稳健的LSTM架构也可能容易受到梯度消失的影响,这使得在发生数据突变时为序列片段分配更多权重变得困难,从而降低预测准确性。在时间序列预测中利用自注意力有可能解决梯度消失问题。虽然Self-Attention主要应用于翻译领域,但它的编码器以序列形式接收输入,而不仅仅是用于翻译的句子,这表明它在时间序列预测中的应用潜力。然而,先前的研究很少探讨将Self-Attention应用于时间序列分析的可行性。

在复杂的水文地质条件下,矿井涌水时间序列表现出高度的非平稳性和复杂性,对传统的预测模型提出了挑战。分解方法,例如小波分解、经验模态分解(EMD)、集成EMD(EEMD)、自适应噪声完全集成经验模态分解(CEEMDAN)和变分模态分解(VMD)可以降低序列的复杂度,本文选择利用CEEMDAN对数据进行处理,降低数据的复杂度。在涉及VMD、EMD或其他分解方法的研究中,研究人员经常忽视分解数据之间的区别。不同频率的数据分量具有独特的特性;例如,低频数据捕获原始数据的潜在趋势,而高频数据可能会给拟合带来挑战。此外,各种预测模型擅长预测不同的数据类型。利用多个模型来预测分解的数据可以利用每个模型的优势,从而改善最终的预测结果。总之,本文提出了一种组合预测方法,利用CEEMDAN分解数据并集成自注意力、LSTM和SVM模型的预测能力。

1.2 国内外研究现状

1.2.1 时间序列预测研究现状

随着大数据和人工智能时代的兴起,人们得以通过人工智能技术获取并利用各种数据,从中提取出有价值的信息和知识。在这个背景下,时间序列数据作为复杂数据的典型代表备受关注,其建模与预测一直是研究的热点。在大数据环境下,时间序列往往具有不稳定性、不确定性和非线性等特点,这给时间序列数据的处理和预测带来了巨大的难度。利用深度学习提高时间序列预测性能已成为当前研究的重要方向。深度学习的引入为时间序列分析提供了全新的思路和方法,通过深度神经网络的构建和训练,可以更好地捕捉时间序列中的复杂特征,从而提升预测的准确性和稳定性。

在统计模型中,ARIMA(自回归积分移动平均模型)是非常著名的时间序列预测模型。例如,Fara et al.(2021)文章主要比较了ARIMA和ANN模型在太阳能预测中的效果,并提出了通过GMDH模型优化的方法来计算光伏能源产量。也有学者将ARIMA与深度学习方法结合,提出了一种改进的基于深度学习的太阳能光伏电池最大功率点

跟踪（MPPT）方法，通过考虑各种基于时间序列的环境输入来建模，从而实现了太阳能光伏电池的稳健跟踪和动态响应（Agrawal et al. 2022）。支持向量机（SVM）和ARIMA都是用于建模和预测时间序列数据的方法，SVM通常用于非线性数据的分类和回归问题，而ARIMA则更适用于线性和平稳的时间序列数据。在过去，研究人员将SVM引入时间序列预测领域，以克服ARIMA对线性假设的限制，提高对非线性数据的建模能力（Cui et al. 2005a; Cui et al. 2005b; Thiessen et al. 2003）。Ye and Wang（2004）利用最小二乘支持向量机（LS-SVM）进行混沌时间序列的单步和多步预测，相比传统神经网络，LS-SVM具有更高的泛化性能。传统的时间序列预测方法如ARIMA和SVM已经在许多领域得到广泛应用，但它们对数据的线性假设和对数据间复杂非线性关系的局限性可能导致在某些情况下的预测性能不佳。神经网络的非线性建模能力和对复杂数据模式的灵活适应性使其成为一种有力的预测工具，尤其在处理具有高度非线性关系的数据和大规模数据集时表现出色。神经网络具有足够的表达能力，可以以任意所需的精度来逼近任何波莱尔可测函数，无论这些函数是从一个有限维空间到另一个有限维空间的映射关系（Hornik et al. 1989）。换句话说，只要神经网络的结构足够复杂，并且具有足够数量的神经元和层次结构，它就能够学习并表示各种复杂的函数关系，从而实现对数据的高精度逼近。在时间序列预测中，已有许多学者使用，例如，Zhang and Berardi（2001）研究了神经网络组合方法以改进传统的“单一模型的时间序列预测性能，提出了两种结合神经网络的一般方法，并在英镑和美元汇率预测中进行了验证，结果表明，采用不同神经网络结构的集成模型能够稳定地优于单个最佳的网络。

时间序列数据分析和预测在大数据和人工智能时代具有重要意义。机器学习方法的引入为时间序列预测带来了全新的思路和方法，使得对复杂、非线性时间序列数据的建模和预测变得更加高效和准确。

1.2.2 矿井涌水量预测方法现状

矿井涌水量预测是矿山生产，评估潜在的安全风险，以及有效规划和采取措施来减少涌水对矿井生产和人员安全造成的影响的必要工作。前人对矿井涌水量预测工作已经做出了大量研究，并且将矿井涌水量预测方法分成了确定性模型方法和不确定性方法（陈酩知等 2009）。确定性方法包括了解析法和数值模拟方法，不确定性方法有水文地质比拟法、相关分析法、时间序列法、灰色理论法等。

（1）水文地质比拟法

水文地质比拟法是一种经验预测方法，旨在通过参考具有相似地质条件的矿井数据来估算矿井涌水量。该方法主要关注地质特征和生产参数之间的相关性，而非具体的物理机制，从而建立经验模型以预测涌水状况。其核心优势在于能够快速、灵活地预

测新矿井或新采区的涌水量，广泛应用于矿业工程和水文地质领域（徐龙和葛晓光 1995）。

刘琼（2023）分析了矿山水文地质条件，通过比拟法和解析法对矿山矿井涌水量进行了预测。刘述友等（2023）利用数值法与水文地质比拟法对马城铁矿地下水流场进行研究，通过分析地质特征、水文地质参数和地下水径流条件，建立三维模型并预测涌水量，结果表明两种方法在涌水量预测中具有较高的可信度，可为矿山开采安全提供可靠依据。

（2）回归分析法

回归分析法基于相关性原理，通过分析变量间相关关系的规律性，建立矿井涌水量与其影响因素的内在联系，以预测矿井涌水量，可根据因果关系采用线性或非线性多元回归分析（李孝朋等 2016）。樊发旺等（2024）通过典型工作面生产数据进行矿井涌水量与生产因素相关性分析，确定开采面积、原煤产量、采掘长度等生产因素作为预测变量，利用多元相关计算建立回归方程预测涌水量，评价结果显示高预测精度，具有较高的参考价值。

（3）模糊数学法

模糊数学法是一种处理不确定性和模糊性问题的数学方法，它允许变量具有不确定的、模糊的值，并提供了一种处理这种不确定性的数学框架（牛肖铮等 2013）。可以用来解决一些模糊问题，即界限和隶属关系不明确的问题（孟俊等 2009）。戴柳珍等（2020）利用模糊数学法综合评价了瓮福磷矿区矿井水水质，有效考虑了主要污染指标和数据的有效信息量，采用等级量化加权平均原则评判水质类别，对各矿井水质进行排序并提出了水环境保护建议。

（4）灰色理论法

灰色理论法是将一个随机变量看成一定范围内变化的灰色的量（姬亚东 2019；Mierzwiaak 2019），其随机变化过程是在一定范围内变化的，起变化过程是与时间相关的。李天宇等（2017）以大井法和比拟法为基础，采用灰色理论建立GM（1，1）模型，对研究区域进行模型的实验，实验发现对矿井涌水量的预测效果较好，为矿山进一步建设和开采提供了可靠的技术资料。张萌等（2020）分析了大井法和灰色理论方法在矿井涌水量预测上的应用，结果发现结合两种方法，可以提高预测的精度。（叶永芳和陈娟 2015）将灰色理论方法与最小二乘法结合，求出了研究区内的矿井涌水量值。

（5）数值模拟法

数值模拟法通过计算机求解偏微分方程，以求得一个近似解。罗庆（2021）以祁东煤矿南部采区6163工作面为对象，结合地质资料和水文地质条件，利用解析法和数值法预测了工作面的涌水量，探讨了不同情况下的涌水量变化规律。翟俊杰（2023）通过实地调研和数值模拟，深入分析了煤矿地下水系统的变化，特别关注了含水层水文

地质特征及断层的水文地质控制规律，并利用Visual Modflow建立了地下水渗流数值模型，预测了工作面推采过程中的涌水量动态变化特征。景婷婷（2023）使用数值模拟法和大井法对矿区矿井涌水量进行预测和分析，发现随着采掘强度增加，涌水量也增加，但在采掘强度稳定后，涌水量略有下降；此外，与数值模拟相比，大井法计算得到的涌水量误差更大。

（6）大井法

大井法使用较为简单，并且应用广泛，将工作面看作一口“大井”，将大井的矿井涌水量看作工作面的矿井涌水量（刘云艳 2023）。张子祥和李文鑫（2022）采用大井法、廊道法和比拟法计算大庄煤矿涌水量，并进行了误差分析，建议在涌水量预测中考虑实测影响半径和补给模数法公式，提出了更精确的涌水量预测方法。王玉合（2022）结合实测资料，采用大井法和比拟法计算涌水量，确定了该矿井正常涌水量的最终采用值，并为矿井防治水工作提供了参考依据。孙刚友等（2023）将大井法与数值模拟法进行了对比，并且将两种方法进行结合。张博成和孙常民（2023）将水文地质比拟法和大井法用于预测涌水量，并对预测方法进行了对比分析。

1.2.3 机器学习方法现状

随着计算机技术的不断发展和获取数据的方式逐渐多样化，机器学习方法在时间序列预测领域展获得了广泛的应用。时间序列预测作为一种重要的数据分析方法，在金融、气象、交通等领域中具有广泛的应用前景。传统的时间序列预测方法往往受限于模型的复杂性和对数据特征的静态假设，难以捕捉数据中的非线性关系的变化。而机器学习方法则通过利用大数据和强大的计算能力，能够更好地发现数据之间的复杂关系，并实现更精准的预测。在时间序列预测中，机器学习方法可以分为监督学习和无监督学习两大类。监督学习方法通过训练数据集中的输入与输出之间的关系，构建预测模型，例如人工神经网络（ANN）、决策树、支持向量机（SVM）等算法的应用。这些方法能够从历史数据中学习规律和趋势，并基于学习到的模式对未来数据进行预测。而无监督学习方法则不需要事先标记的输出数据，主要通过聚类、降维等技术来挖掘数据的内在结构和模式，例如聚类分析、主成分分析等方法。

下文本文对常见的机器学习方法以及其在水文方面的应用进行介绍。

人工神经网络（ANN）通常是一种监督学习方法，其中的训练过程需要标记的输入和输出数据来调整网络参数，以最小化预测输出与实际输出之间的误差（Agatonovic-Kustrin and Beresford 2000）。Che Nordin et al.（2021）系统性地探讨了包括神经网络（ANN）在内的多种机器学习方法在地下水质量建模和预测中的应用，发现ANN在处理大量数据集和准确预测方面表现更优。Rakhshandehroo et al.（2012）利用ANN进行

了地下水位预测，比较了四种不同神经网络结构的预测效果，结果表明人工神经网络可成功用于地下水位预测。

支持向量机（SVM）作为一种受欢迎的方法被广泛应用于水位、风电、洪水和金融等领域的预测任务中（Mosavi et al. 2018）。Ortiz-García et al.（2014）研究了支持向量机（SVM）在日降水预测中的表现，通过考虑大量新颖的预测变量并分析其重要性，与其他神经计算方法和经典算法进行比较，证明了SVM方法的出色性能。Jajarmizadeh et al.（2015）比较了土壤水评估模型（SWAT）和支持向量机（SVM）在伊朗南部干旱地区月流量预测方面的结果，结果表明SVM模型在预测该干旱地区月流量方面表现良好。Granata et al.（2016）通过比较研究了基于SVM的降雨径流建模方法在意大利北部两个实验流域的应用情况，结果表现良好，显示 SVM在城市水文领域具有巨大潜力。

随机森林（RF）是一种回归技术，是决策树算法的一种改进，用来处理分类和预测问题（Breiman 2001; Guo et al. 2011）。Li et al.（2016）在中国鄱阳湖应用了随机森林模型，并与ANN、SVM和线性模型进行比较，在考虑时间滞后和前期水位的情况下进行了三种不同的场景模拟，结果表明随机森林模型在每日预测方面表现最佳，可为水资源管理和决策提供信息或模拟场景。Wang et al.（2018）提出了一种基于随机森林的预测地下水位的方法，该算法在预测地下水位变化方面表现出优越性，尤其在训练时间和参数优化复杂性方面相较于其他方法具有优势。

大量的水文学领域工作者在研究中使用了机器学习方法，并取得了好的成果。随着机器学习技术的不断演进和改进，未来还可以预期更多新型算法和模型的涌现，进一步提升时间序列预测在水文学领域的应用效果和精度。这将为水资源管理、环境保护和灾害预警等领域提供更加可靠和准确的决策支持。

1.2.4 深度学习在矿井涌水量预测方面的应用

水文系统的本质上是存在一定的异质性，即系统内部存在着空间和时间上的非均匀性和多样性（Marcais and de Dreuzay 2017）。水文系统中的各个部分并不完全相同，它们可能在地质结构、土壤类型、降水分布、地形等方面存在差异，导致水文过程在不同地区或不同时期表现出不同的特征和行为。这种异质性使得对水文系统进行建模和预测变得复杂，需要考虑和处理不同尺度上的变化和不确定性。深度学习技术成为一种有前景的解决方案，其能够通过强大的特征学习能力和对非线性关系的灵活建模，更好地适应水文系统中多样性和动态性的特征（Sahiner et al. 2019）。

深度学习是机器学习的一个子领域，常见的深度学习方法包括了卷积神经网络（CNN）、循环神经网络（RNN）和生成对抗网络（GAN）等深度学习模型已经在计算机视觉、自然语言处理和时间序列预测等多个领域实现了突破性进展（Haskins et al. 2020; Heaton et al. 2017; Ma et al. 2019）。

卷积神经网络（CNN）通常用于处理具有空间结构的数据。CNN包含卷积层、激活层和池化层，通过多个卷积核从输入中提取复杂的特征，并通过激活函数引入非线性，最后通过池化层减小输入大小同时保持位置信息（Zhou and Chellappa 1988）。de Vitry et al.（2019）通过深度卷积神经网络（DCNN）检测洪水并提供定性的洪水水平趋势信息，为城市洪水风险评估和规划提供了一种廉价且高度可扩展的替代方法。

递归神经网络（RNN）和长短期记忆网络（LSTM）是另两种在深度学习中常用的神经网络架构，特别适用于处理时间序列数据（Hochreiter and Schmidhuber 1997）。由于水文数据具有时序性和动态性，RNN和LSTM能够很好地捕捉数据之间的时间依赖关系，从而提高水文预测的准确性和稳定性（Xiang and Demir 2020）。因此，在水文领域中，RNN和LSTM等循环神经网络架构为解决时间序列数据分析和预测问题提供了有效的工具和方法。Kratzert et al.（2018）利用LSTM网络进行降雨径流建模，通过测试241个来自CAMELS数据集的流域，与传统模型相比较，并展示了LSTM作为区域水文模型的潜力。

Kumar et al.（2019）利用RNN和LSTM等深度学习模型，基于长序列原始数据进行月降雨预测，结果表明这些模型在印度不同均质区域的表现良好，为水文学和相关领域的时间序列分析提供了参考。Qin et al.（2019）利用TensorFlow框架构建了自回归模型和LSTM模型，对水文时间序列进行预测，结果显示模型的预测效果达到预期，并提出了解决现有结果局限性的方案。Zuo et al.（2020）将变分模态分解（VMD）和集合经验模态分解（EEMD）与LSTM结合，用于水流流量预测。

除此之外，深度学习方法也在煤矿行业有一定的应用。Huang et al.（2018）利用CNN和深度学习技术开发了一种识别地下矿井微震事件震源位置的方法，通过交叉小波变换提取地震波信息，并利用深度学习网络自动学习特征，实现了准确的微震源识别。Yang et al.（2023）提出了基于差分法（DIFF）和时域卷积神经网络（TCN）的DIFF-TCN和DIFF-LSTM模型进行矿井涌水量预测，探索了深度学习数据驱动模型在矿井涌水量预测的应用。Fang（2022）利用CNN构建了煤矿突水水源识别模型，有效提高了识别准确率，为煤矿突水预防和控制提供了可靠的早期预警和识别手段。Yin et al.（2023）提出了一种创新的数据驱动方法，利用现场三维微震监测数据来预测矿业突水，通过机器学习和深度学习模型分析微震事件，使用长短时记忆（LSTM）+绝对误差（AE）、隔离森林（iForest）和LSTM+iForest模型来检测异常，能够准确预测突发性水突事件。

本研究将深度学习和机器学习方法应用于煤矿领域，通过解决煤矿矿井涌水量预测的问题，为深度学习方法在煤矿领域的应用提供了新的思路和视角。

1.2.5 存在的问题

通过分析传统矿井涌水量预测方法的应用进展，发现存在以下主要问题：

(1) 传统的确定性模型发展较为成熟, 预测精度较高, 但在复杂场景的应用中建模精度要求较高, 数据完整性要求较高, 计算成本较高。

(2) 传统的非确定性模型在地质条件不复杂的煤矿中应用效果较好, 但适用性较差, 精度较差。

(3) 单一模型预测效果不稳定, 局限性较大, 对非平稳数据的预测效果较差, 因此有必要探究组合模型在适用性和精度上的潜力。

(4) 机器学习和深度学习方法在其他领域使用较为成熟, 但在矿井涌水量预测方面应用较少, 有必要进一步研究机器学习、深度学习模型在该领域的适用性。

1.3 研究内容与技术路线

1.3.1 研究内容

基于对国内外研究现状的分析, 结合矿井涌水量预测存在的问题, 本文旨在探究提出的Self-Attention模型和多模型预测框架在矿井涌水量预测中的性能表现。本文使用提出的模型和框架, 以扎尼河煤矿的2015-2019年的矿井涌水量数据为例, 对矿井涌水量数据进行预测, 并比较不同的模型, 评估不同模型和方法的性能。研究内容如下:

(1) 构建Self-Attention时间序列预测模型

将Transformer中的Self-attention模块提取, 构建一个基于Self-attention的时间序列预测模型, 对矿井涌水量数据进行预测。与传统机器学习模型进行对比, 验证模型的性能, 发掘模型预测潜力。对比模型包括: SVR支持向量机; LSTM长短期记忆网络; GRU门控循环网络。

(2) CEEMDAN对单一预测模型的影响分析

通过比较使用CEEMDAN与不使用CEEMDAN的单一模型预测, 验证CEEMDAN对单一预测模型性能的改善程度。

(3) 构建多模型预测框架

提出了一种基于CEEMDAN的多模型的预测框架, 通过多模型预测框架将多个不同的单一模型进行结合, 使预测结果能够拥有多个模型的优势。

(4) 多模型预测框架在地下水位预测的应用

将多模型预测框架推广到煤矿地下水位的预测, 对比其他单一模型和多模型预测方法, 进一步挖掘多模型预测框架的预测能力。

选定平均绝对误差(MAE)、均方根误差(RMSE)、均方百分比误差(MAPE) 3个误差指标进行预报精度评价与模型择优。

1.3.2 技术路线




图 1-1 技术路线图

Fig. 1-1 Technology roadmap

1.4 章节安排

本文共分为八章。继本章节之后，第二章对基本理论方法和对比模型进行了介绍，包括了本文提出的Self-Attention方法和常见的时间序列预测模型。此外，本章节对多模型预测框架的运行逻辑进行了介绍，以引导读者进一步了解。最后介绍了本文所使用的评估指标。

第三章对实验背景进行了描述，主要对研究区的隔水帷幕进行了介绍，并进一步分析了隔水帷幕对矿井涌水量的影响。简述了研究区的地理概况、水文气象概况。最后对研究的整个安排进行了介绍，旨在使读者更好的理解后续的实验章节。

第四章是实验的第一部分，使用单一模型对矿井涌水量进行预测。该章节介绍了数据的划分方法，模型的输入，以及分解方法的使用。之后是具体的实验结果及分析讨论，初步的验证了Self-Attention的预测性能。

第五章是多模型预测框架在矿井涌水量的预测。首先对Self-Attention的趋势预测性能进行了验证，进一步的使用了多模型预测框架使其与多种模型进行融合。通过预测结果来展示多模型预测框架的预测性能。

第六章是结合扎尼河露天矿矿井涌水量预测的结果对模型、框架的结构进行进一步的分析讨论。为了使读者能够更好的使用该模型，以及未来研究中能继承的优势，模型在不同场景下的使用可能性，都需要结合模型的框架结构本身进行进一步的讨论。此外对于技术细节，例如参数选择、分解方法的选择进行了进一步的讨论。

第七节本文将多模型的预测方法使用在了本研究区的地下水位预测上。本文的目的是进一步拓展模型和框架是使用范围，并进一步讨论未来在其他地方使用该模型的可能。

第八章总结了研究结果，对多模型预测框架和Self-Attention预测模型进行概括性的总结，并且对本研究的局限性进行分析以及对未来机器学习方法在矿井涌水量的研究的展望。

第二章 研究方法概述

2.1 分解方法及原理

2.1.1 CEEMDAN 算法原理

本研究采用CEEMDAN (Complete Ensemble Empirical Mode Decomposition with Adaptive Noise) 方法对矿井涌水数据进行分解, 主要有两个原因: 1) CEEMDAN可以将非平稳序列分解为多个不同频率的序列, 从而提高预测精度。2) 通过应用不同的模型来预测分解的本征模态函数 (IMF), 可以在预测结果中结合多个模型的优点。

CEEMDAN是Torres提出的经验模态分解(EMD)的改进, 是对最初由Huang等人(1996)提出的EMD分解方法的改进。EMD能够将复杂的原始信号分解为表示为IMF的各种频率分量。CEEMDAN通过引入自适应白噪声序列解决了EMD中的模式混合问题。详细分解过程如下:

Step 1: 向信号 $s(t)$ 添加N次均值为零的高斯白噪声, 生成N个序列, 记为 $s_i(t)$, 其中 $i = 1, 2, 3 \dots N$ 。

$$s_i(t) = s(t) + \beta \delta_i(t) \quad (2-1)$$

其中 β 表示高斯白噪声的系数, $\delta_i(t)$ 表示第 i 次迭代时产生的高斯白噪声。

Step 2: 对 $s_i(t)$ 应用 EMD 以获得所有的 IMF s。计算这些 IMF 的平均值以获得CEEMDAN 分解的 IMF_1 。

$$IMF_1(t) = \frac{1}{N} \sum_{i=1}^N IMF_1^i(t) \quad (2-2)$$

$$r_1(t) = s(t) - IMF_1(t) \quad (2-3)$$

其中 IMF_1 表示 CEEMDAN 的第一个 IMF 分量, $r_1(t)$ 表示初始分解期间产生的残差信号。

Step 3: 添加噪声, 进一步分解。

$$IMF_j(t) = \frac{1}{N} \sum_{i=1}^N E_1(r_{j-1}(t) + \varepsilon_{j-1} E_{j-1}(\delta^i(t))) \quad (2-4)$$

$$r_j(t) = r_{j-1}(t) - IMF_j(t) \quad (2-5)$$

其中 $IMF_j(t)$ 表示CEEMDAN分解后的第J个IMF分量, E 表示EMD分解后的IMF分量。 ε 是残差信号的系数, $r_{j-1}(t)$ 表示第j个残差信号产生。

Step 4: 重复上述步骤, 直到残差信号成为单调函数, 表明无法进一步分解。原始信号 $S(t)$ 表示如下:

$$s(t) = \sum_{j=1}^J IMF_j(t) + r_j(t) \quad (2-6)$$

2.1.2 变分模态分解

VMD在处理平稳性较差的非线性数据时,往往能够取得好的效果。在数据的稳定性较差时,数据中波动幅度较小的信息很难被模型学习并用来预测,使用VMD将数据分解为不同的本征模态函数(intrinsic mode function, IMF)分量,分解方法如下:

1) 对每个 u_k 通过希尔伯特变换得到单边频谱及解析信号,将解析信号及其预估中心频率 $e^{-j\omega_k t}$ 项混合,把频谱变换到基带上,利用高斯平滑估算已解调信号的带宽,并构建变分约束问题如下:

$$\begin{cases} \min_{\{u_k\}, \{\omega_k\}} \left\{ \sum_k \left\| \partial(t) \left[\left(\delta(t) + \frac{j}{\pi t} \right) * u_k(t) \right] e^{-j\omega_k t} \right\|_2^2 \right\} \\ \text{s.t. } \sum u_k = f(t) \end{cases} \quad (2-7)$$

2) 使用拉格朗日算子 λ 和二次惩罚因子 α ,将变分约束问题转变为非约束问题,求解变分问题最优解:

$$L(\{u_k\}, \{\omega_k\}, \lambda) =$$

$$\alpha \sum_k \left\| \partial(t) \left[\left(\delta(t) + \frac{j}{\pi t} \right) * u_k(t) \right] e^{-j\omega_k t} \right\|_2^2 + \left\| f(t) - \sum_k u_k \right\|_2^2 + \left\langle \lambda(t), f(t) - \sum_k u_k \right\rangle \quad (2-8)$$

3) 通过交替方向乘子法实现对 $\hat{u}_k$ 及 w_k 的交替更新,完成VMD分解。

$$\begin{aligned} \hat{u}_k^{n+1}(\omega) &= \frac{\hat{f}(\omega) - \sum_{i \neq k} \hat{u}_i(\omega) + \frac{\hat{\lambda}(\omega)}{2}}{1 + 2\alpha(\omega - \omega_k)^2} \\ \omega_k^{n+1} &= \frac{\int_0^\infty \omega |\hat{u}_k^{n+1}(\omega)|^2 d\omega}{\int_0^\infty |\hat{u}_k^{n+1}(\omega)|^2 d\omega} \end{aligned} \quad (2-9)$$

式中: $\hat{f}(\omega)$ 、 $\hat{u}_k(\omega)$ 和 $\hat{\lambda}(\omega)$ 分别为 $f(t)$ 、 $u_k(t)$ 和 $\lambda(t)$ 的傅里叶变换, ω 为频率, n 为迭代的次数。

2.2 机器学习及深度学习方法介绍

2.2.1 长短期记忆网络(LSTM)

长短期记忆网络(Long Short-Term Memory, LSTM)是一种经过改进的循环神经网络(Recurrent Neural Network, RNN),它通过增加控制信息传递的门控单元来解决RNN在处理长序列数据时常见的梯度消失或爆炸问题。LSTM在RNN的基本结构之上引入了三个主要的门:遗忘门、输入门和输出门。每个门的设计都有特定的功能,以确保数据在网络中的传递和存储更加有效。LSTM的遗忘门负责控制之前的记忆是否被遗

忘或保留。它通过学习可以避免不必要的旧信息向后传播，同时保留关键的信息，从而提高模型对长序列的处理能力。输入门的功能是控制新的数据进入记忆单元的程度，这有助于确保网络在学习时关注重要的部分。输出门则决定从记忆单元传递到下一层或下一时刻的输出内容。这种结构使得LSTM可以更有效地处理具有长时依赖性的序列数据。通过这种门控机制，LSTM可以在较长的时间序列中保存信息，使其在应用于自然语言处理、时序预测、信号处理等领域时具有显著优势。遗忘门、输入门和输出门的协调工作，使LSTM在保持稳定训练的同时，能够更好地处理复杂的序列模式。LSTM内部计算公式如下：

$$f_t = \sigma(W_{fx}x_t + W_{fh}h_{t-1} + b_f) \quad (2-10)$$

$$i_t = \sigma(W_{ix}x_t + W_{ih}h_{t-1} + b_i) \quad (2-11)$$

$$g_t = \tanh(W_{gx}x_t + W_{gh}h_{t-1} + b_g) \quad (2-12)$$

$$O_t = \sigma(W_{ox}x_t + W_{oh}h_{t-1} + b_o) \quad (2-13)$$

$$C_t = g_t i_t + C_{t-1} f_t \quad (2-14)$$

$$h_t = \tanh(C_t) O_t \quad (2-15)$$

式中： W 为权值； b 为偏置； σ 为sigmoid函数。每个时刻的输入变量包含上一时刻的单元状态；上一时刻的中间状态；以及当前时刻的输入；中间变量包括遗忘门的输出；输入输出门的输出和，以及输入节点的输出；输出变量包括单元状态和中间状态。




图 2-1 LSTM 结构图

Fig. 2-1 LSTM structure diagram

2.2.2 门控循环神经网络（GRU）

与LSTM相比，GRU结构相对简单，但仍然包含了门控机制以控制信息的传递。GRU主要有两个门控单元：重置门和更新门。重置门用于决定如何将新输入与过去的记忆结合在一起，这一过程涉及将过去的记忆清空或者保留一部分，从而有效处理序列中的变化。更新门用于控制过去的记忆在多大程度上影响当前的状态，也可以理解

为控制记忆的更新程度。通过这两个门的配合，GRU在保持对历史信息的记忆与适应新输入之间达到了平衡。由于其结构简单，GRU通常比LSTM具有更少的参数，因此计算效率更高。在某些应用场景下，GRU可以提供与LSTM相似的性能，但在计算开销和训练时间方面可能更加优化。GRU在处理时序数据、自然语言处理和其他循环神经网络常用的应用领域中，同样展现了强大的适应能力和性能。总体而言，GRU和LSTM的设计目标都是在循环神经网络的基础上，通过门控机制控制信息的传递，以便更有效地处理长序列数据。GRU的简单结构和较少的参数量使其成为某些应用中的首选，但LSTM可能在处理非常复杂的序列模式时具有优势。




图 2-2 GRU 结构图

Fig. 2-2 GRU structure diagram

2.2.3 Self-Attention

自注意力机制（Self-Attention）是注意力机制中的一种变形，是近年来在深度学习和自然语言处理领域取得突破性进展的关键技术之一。自注意力机制的核心思想是通过计算输入序列中的元素之间的相关性，来确定这些元素在计算中的重要性，从而优化模型并做出更为准确的判断。自注意力机制不再依赖于多维数据的输入，可以从自身序列中提取关键信息，Vaswani等人将自注意力机制代替了循环神经网络，成功的提出了Transformer模型。在一维序列数据的处理上，不但具备类似长短期记忆网络（LSTM）对历史特征的学习和记忆能力，还拥有对重要特征提取并赋予权重的能力，在一维时间序列的预测上有巨大的潜力。

自注意力机制中的注意力的计算公式和注意力机制相同，区别在于自注意力机制的Q，K，V都同源，公式如下：

$$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}})V \quad (2-16)$$

其中， Q ， K ， V 分别表示“查询”、“键”和“值”； d_k 是缩放因子，表示 K 的维度。




图 2-3 Self-Attention 结构图

Fig. 2-3 Self-Attention structure diagram

本文通过改进了transformer翻译算法中的自注意力机制，用输入的序列窗口数据组成的向量代替原本的词向量，结构如图2-3，计算过程如下：

- 1) 将输入数据转化为嵌入向量。
- 2) 通过嵌入向量计算出 Q, K, V 三个向量。
- 3) 通过 QK 计算出相关性。
- 4) 为了保证梯度的稳定性，需要进行缩放，将 QK 除以 $\sqrt{d_k}$ 。
- 5) 使用Softmax激活函数。
- 6) Softmax点乘Value的 v ，得到每个输入向量的评分 v 。
- 7) 输出 Z ， $Z = \Sigma v$ 。

这时的输出 Z 包含了序列中其他元素赋予了注意力权重之后的值，通过这种计算将历史数据的重要信息保留下来。

2.2.4 支持向量机（SVM）

支持向量机（Support Vector Machine）是一种广泛使用的机器学习算法，主要用于分类和回归问题（Vapnik 1963）。其基本思想是通过构建一个最佳的超平面，将数据划分成不同的类别，或者在回归问题中预测连续的输出。SVM的核心概念包括最大化分类间隔和使用核方法处理非线性问题。SVM在处理非线性数据时非常灵活，这得益于核方法（Kernel Methods）。通过选择合适的核函数，SVM可以在不显著增加计算复杂性的情况下处理复杂的非线性数据。

SVM 方法的基本思想是将输入特征变换到高维空间，其中两个类可以通过高维表面（称为超平面）线性分离。给定一个包含 N 个样本的训练数据集 $\{x_n\}_{n=1}^N$ ，其中 $x \in \mathbb{R}^L$ ， x 为输入特征向量，输出特征向量 $\{y_n\}_{n=1}^N$ ，其中 $y_n \in \{-1, 1\}$ ，SVM回归模型定义为：

$$y_n = w \cdot \phi(x_n) + b, \quad n = 1, 2, \dots, N$$

其中 $\phi(x_n)$ 是一个非线性映射函数，用于将原始输入向量变换到目标特征空间。 w 和 b 分别为权重向量和偏执量，求解方法为：

$$\begin{cases} \min \frac{1}{2} \|w\|^2 + C \cdot \sum_{i=1}^N (\xi_i + \xi_i^*) \\ \text{subject to: } w \cdot \phi(x_i) + b_i - y_i \leq \varepsilon + \xi_i^* \\ y_i - w \cdot \phi(x_i) - b_i \leq \varepsilon + \xi_i \end{cases} \quad (2-17)$$

式中： ξ_i 和 ξ_i^* 是正松弛变量，表示具有误差容限的第 i 个样本的训练误差 ε 。 C 是控制模型经验风险的参数。

2.3 多模型预测框架介绍




图 2-4 CEEMDAN 多模型预测框架

Fig. 2-4 CEEMDAN multi-model prediction framework

本文提出的多模型框架通过CEEMDAN发挥了多种模型的优势。图2-4展示了本文提出的多模型预测框架的工作流程。CEEMDAN将原始数据分解为多个IMF。采用适当的模型来预测每个IMF，从而得出结合了多个模型优势的预测。模型选择策略基于不同模型对不同频率分量的不同预测能力。首先，使用VMD将原始序列分解为不同频率的分量。随后，应用各种模型进行预测，以确定每个组件最合适的模型。考虑到低频和高频IMF的不同变化范围，以及与MAE和RMSE量纲的问题，本文选择MAPE作为评估指标。最终MAPE结果用于CEEMDAN组件中的模型选择。

本研究利用4.1节中介绍的矿井涌水数据作为实验的输入。数据最初表现稳定，随后防水帷幕施工完成后矿井涌水量突然减少。本文将数据按照7:3的比例分为训练集和测试集，确保大部分趋势下降阶段都在测试集中。这种安排有助于更好地探索Self-Attention模型在处理趋势突变的序列方面的潜力。用于组合的多模型包括Self-Attention模型、LSTM模型、GRU模型和SVM模型。选择LSTM和GRU模型是因为它们广泛应用于各种时间序列预测问题中，并且许多研究人员提出了基于这些模型的改良版本并投入研究。SVM模型虽然比较传统，并且随着深度学习网络的发展逐渐被其他深度学习模型所取代，但它具有两个独特的优点：1）不存在梯度消失问题，2）即使在数据有限的情况下也有良好的预测性能。选择它们可以确保更好的代表性。

2.4 评估指标

目前，评估机器学习模型预测准确性的常用指标包括均方根误差（RMSE）、平均绝对误差（MAE）和平均绝对百分比误差（MAPE），如表2-1所示。公式如下，

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m (\hat{y}_{test,i} - y_{test,i})^2} \quad (2-18)$$

$$MAE = \frac{1}{m} \sum_{i=1}^m |\hat{y}_{test,i} - y_{test,i}| \quad (2-19)$$

$$MAPE = \frac{1}{m} \sum_{i=1}^m \frac{|\hat{y}_{test,i} - y_{test,i}|}{y_{test,i}} \quad (2-10)$$

其中 m 是测试集中的样本数； $\hat{y}_{test,i}$ 是测试集中第*i*个样本的预测值； $y_{test,i}$ 为测试集中第*i*个样本的测量值； $\bar{y}_{test,i}$ 是测试集中测量值的平均值。

表 2-1 评估指标

Table 2-1 Evaluation indicators

评估指标	指标全称	描述
RMSE	Mean Absolute Error	表示预测值与实际值之间的平均差异。
MAE	Root Mean Square Error	预测误差平方平均值的平方根。
MAPE	Mean Absolute Percentage Error	表示预测值与实际值之间的平均百分比差异。

第三章 研究背景与研究区概况

本研究提出的多模型预测框架不同于改良的深度学习预测模型,在时间序列领域,大量的新模型基于旧模型进行改良,大多数改良模型仅仅是在评估指标的数值上优于其他模型。本研究提出的模型框架可以将各种先进的模型进行融合,它能使预测结果拥有多种模型的优势。本文将其应用于一个特殊的研究区域—扎尼河露天矿。该研究区使用了罕见的截水帷幕方案对地下水进行阻截,该方法对矿井涌水量以及地下水位的影响较大,导致矿井涌水量预测难度较大。本章节着重对研究区的特点以及预测框架的特点进行介绍,引导读者了解模型的特点及应用。

3.1 研究区概况

3.1.1 研究区位置概况

研究区位于中国内蒙古呼伦贝尔草原地区,大兴安岭以西。属温带大陆性草原气候。研究区南北长7公里,东西宽5.5公里,面积38.5平方公里。

扎尼河矿区最大的特点其高达10万立方米的日矿井涌水量。扎泥河露天煤矿自2010年开工以来,地下水位已下降50多米。造成这一现象的主要原因是其独特的地理位置,该矿区北部、西部和东部分别是海拉尔河、扎尼河和顺河,如图三条季节性河流的地下水补给使得扎尼河矿区有大量的矿井水涌出。




图 3-1 扎尼河露天矿与三条河流位置图

Fig. 3-1 Location map of Zani Open-Pit Mine and three rivers

根据调查,研究区植被主要分为湿地草甸植被、草原植被和沼泽植被三大类。湿地草甸植被主要包括扎泥河湿地和海拉尔河灌丛中的高海拔阶地上的低洼湿地草甸,这类植被在湿润的环境下生长繁茂。草原植被则以草甸草地为主,广泛分布在研究区的低山丘陵和河流阶地,展现了草原特有的生态特征。沼泽植被则多见于海拉尔河湿

地和扎泥河湿地，既包括木本沼泽区，也包括草本沼泽区。其中，木本沼泽的外围有成片的山茱萸和灌木植被。有些地区有沙地植被，其中针叶草、羊草、艾草和柳树是主要物种。图3-2中蓝色部分为防水幕工程，有效截留地下水补给。




Fig. 3-2 Overview map of the study area

3.1.2 矿井涌水概况

研究区总体地势南高北低，南部为低山丘陵区，地表均被草原植被覆盖，地貌单元属冲积平原。露天煤矿开采生产时需将地下水位疏降至煤层底板以下，自露天矿投产以来，采用疏干井方式进行疏排水，施工疏干井数量累计已达100余口，每天排水量高达十几万立方米，远大于初步设计中预计的 $4.7 \times 10^4 \text{m}^3/\text{d}$ 。经分析，疏排水动态补给量主要由北侧海拉尔河补给。继续采用疏排降水方案，将会给露天煤矿生产带来一系列的问题：（1）长时间大流量疏排水，引起区域地下水位下降，目前疏降中心3km范围内地下水位出现不同程度的下降，由此造成了海拉尔河湿地植被枯死、周边井泉干枯，土地沙漠化等现象，同时造成周边居民生活用水困难；（2）每年大量疏排地下水造成水资源的极大浪费，矿坑水排放造成周边河流水质变差；（3）巨大疏排水量易造成水土流失，给矿坑边坡维护带来较大困难；（4）巨额的疏排水费用、矿坑水处理费用增加了露天矿生产成本，降低了经济效益。

为解决上述问题，拟采用防渗墙帷幕截流的方式从根本上减少矿坑疏排水量，从而有利于保护生态环境和地下水资源，维护煤矿正常生产与安全，提高煤矿经济效益。

3.1.3 隔水帷幕概况

隔水帷幕的主要功能是通过截断地下水渗流通道，减少矿坑的疏排水量。在露天煤矿中，隔水帷幕被广泛应用，阻隔地下水，同时保护生态环境。隔水帷幕尤其适用于含水层埋藏较浅、富水性强、透水性好的地区。在这些地区，矿坑通常面临较大的地下水补给量，因此需要有效的截水措施。帷幕的设计必须考虑工程地质和水文地质条件，确保能够有效截断地下水的补给。

隔水帷幕的历史可以追溯到20世纪60年代，当时中国在水利水电工程坝基防渗处理中首次采用帷幕注浆技术，成功切断区域地下水流。自此之后，这项技术在地下深部矿山、隧道和其他地下工程中得到了广泛应用，成为处理复杂地质和水文条件的有效手段。隔水帷幕的主要益处在于能够形成相对隔水层，减少帷幕内外的水力联系。这不仅降低了矿井的排水成本，还保护了地下水资源，减少了由地下水引发的次生地质灾害的风险。

考虑到扎尼河露天矿的工程地质、水文地质条件，以及地下水的补给情况，本文将隔水帷幕的放置在朝向地下水水流的方向，这样更有利于拦截地下水的渗流。并且为了有效的隔水，隔水帷幕的末端需要放置在隔水地层中，整个隔水帷幕需要连续和完整。在本研究区中，隔水帷幕采用弧线形隔水帷幕，这样更好的应对煤矿北部、西部和东部的河流地下水补给，如图3-3所示。弧线形隔水帷幕建造难度大，但由于几何特性，稳定性较高，并且能够准确地朝向地下水流的补给方向。建设时需要考虑多方面因素，例如地下水补给的流向、地形的厚度情况、地质构造情况、边坡安全情况、保证煤炭开采的安全和效率以及地表设施和设备分布情况。但建设后对地下水阻截能力较强，能够有效减少矿井涌水对煤矿生产和煤矿周边生态带来的损害。




图 3-3 煤矿隔水帷幕布置示意图

Fig. 3-3 Layout diagram of water-barrier curtains in the coal mine

3.1.4 隔水帷幕对矿井涌水量预测的影响

在帷幕建成之前,矿井涌水量高达10万立方米,矿方认为主要来源于西边,北边和东边三条季节性河流的地下水补给。在2015年进行了一段长为400米的试验工程后,确定帷幕能够对地下水流场进行干扰。并且建设帷幕后矿井涌水量出现了一定的下降,因此能够确定地下水补给是主要的影响因素。在2013到2019年间,地下水水位呈现逐年下降趋势,长期的矿井排水会导致地下水流失,水头压力下降,进一步导致矿井排水下降。随着帷幕工程的建设进度增加,矿井涌水量逐渐下降,并且下降速度越来越大。由此可见,隔水帷幕的干扰对矿井涌水的变化产生了明显的影响。这种人为的影响为矿井涌水预测增加了难度,也为模型构建提出了挑战。本文也因此使用此案例,对模型的预测性能进行进一步的研究。

3.1.5 地形地貌

扎尼河露天矿位于大兴安岭西坡和呼伦贝尔大草原东缘,整个区域呈现出盆地状,地势特征为四周较高而中部较低。地形地貌上,扎尼河煤田西区属于中国北方兴蒙古黑地槽金成矿地质条件及矿床地质特征中的兴安地槽东北段北带边缘,地表覆盖草原植被。矿区内的海拔高度在635至693米之间。地貌方面,该区域主要属于冲积平原类型,这种地貌特征反映了长期的地质过程和水流沉积作用。在基础设施方面,扎尼河露天矿的北部具备较好的交通和电力供应条件。308国道贯穿该区域,沿着近东西方向延伸。此外,三条高压输电线路(敏雁线、汇海线和西海线,电压等级为220KV)和三条地下光缆也与308国道平行分布。这些基础设施为露天矿的开采和运输提供了重要支持,也确保了电力和通信的有效供应。综合来看,扎尼河露天矿所在区域的地质、地形和基础设施条件为矿区的开发与运营提供了重要的支持与保障。

3.1.6 水文气象

扎尼河露天矿所在地区的水文气象条件具有显著的季节性特征。地表水系主要由河流组成,包括一条非季节性河流和三条季节性河流。主要河流是海拉尔河,宽度在53至139米之间,流向由北东至南西。此外,三条季节性河流分别为海拉尔河、顺河和扎尼河,流量在490至439立方米/小时,流向由南至北,最终汇入海拉尔河。该地区的水分蒸发量远高于降雨量。年平均气温为-3.1摄氏度,最低气温可以达到-43.1摄氏度,而最高气温则可达35.32摄氏度。风速方面,年平均风速为2.5米/秒,但最大风速可以达到27米/秒。风向在不同季节有明显差异,结冻期也在这个时间段,冻结深度通常超过3米,并存在岛状永久冻土层。这些气象和水文特征对扎尼河露天矿的作业和环境保护产生显著影响。

3.2 水文地质条件

1、含水层

第四系孔隙潜水含水层主要位于矿区的北部，厚度从南到北逐渐增加，平均厚度为6.5米，最大厚度可达21.76米，总分布面积约2.96平方公里。

伊敏组地层9煤组裂隙含水层是由煤层裂隙形成的。底板标高从391.91米到573.32米不等，稳定水位标高在601.95米至633.52米之间。由于煤层中裂隙和地质断层的存在，导致地下水流通活跃，部分钻孔在钻进煤层时，泥浆漏失严重。承压水的水头从南向北递减，平均水力坡度为2.1%。含水层厚度平均为33.44米，最大厚度48.29米，最小厚度为6.2米。

伊敏组地层8煤组裂隙含水层与7煤组的含水条件、储水构造和含水层底板相似，但相对厚度较薄，隔水性较差。

2、隔水层

9煤含水岩组顶部隔水层主要由泥岩、碳质泥岩和砂质泥岩组成，厚度最大可达253.37米，最小为3.98米，平均厚度74.1米。隔水层的分布稳定，隔水性较好，但地质构造应力可能导致裂隙的产生，影响隔水效果。

10煤含水岩组顶部隔水层主要由泥岩、碳质泥岩，夹细砂岩透镜体构成。隔水层厚度最大9.91米，最小1.56米，平均厚度3.92米。分布相对稳定，但隔水性较差，主要因为断层引起水力联通。由于断层和地应力的变化，7煤组与8煤组之间的隔水效果可能不稳定，存在水力联通的风险。此外，隔水层的厚度和承压水水头的变化受到地质构造和断层的影响，表明该地区的水文地质条件较为复杂，这对露天矿的开采和地下水管理带来了困难。

3.3 实验设计

本研究的主要贡献是提出了基于Self-Attention的矿井涌水量预测模型，以及多模型的预测框架。实验的设计将围绕验证Self-Attention模型和多模型预测框架展开，并且进一步的对模型和框架的适用性进行讨论。

第一部分的目标是验证Self-Attention在预测中的性能。本文直接将Self-Attention与LSTM、GRU和SVM模型进行比较。并且本文与结合了CEEMDAN的预测结果进行了对比。对比模型选择的主要原因是LSTM、GRU和SVM都是机器学习领域广为人知的模型。其有好的时间序列预测性能和代表性，并且有大量的研究者已经对其性能进行了验证。是用CEEMDAN作为对比实验的目的，是由于CEEMDAN方法作为本研究所提多模型预测框架的重要组成部分，对其本身的性能也需要进行验证。

在第二部分中，本文进一步深入研究Self-Attention对低频分量的预测性能。Self-Attention本身源于transformer，在翻译领域有着成熟的运用，但时间序列预测数据是使用还是一个空缺。本研究发现，它特殊的结构（更多分析见第六章）对于长序列时间序列数据的趋势预测能力较传统模型较强。为了进一步分析其在趋势序列的预测能力，本文设计了实验对CEEMDAN分解后的趋势项进行了预测。

第三部分使用了本文提出的多模型预测框架以及对比的多模型预测框架。对于模型框架使用的具体介绍见2.3节。本文使用了第一部分中表现结果最好的组合和其他多模型预测方法进行了对比，一方面为了验证单模型预测方法和多模型预测框架在预测效果上的区别，一方面为了和其他学者提出的多模型预测方法进行对比，进一步论述本研究提出模型的先进性。

第四部分使用本文提出的多模型预测框架与Self-Attention预测模型对地下水位进行了预测。选择了矿区的5个地下水位监测井数据，这些数据与矿井涌水量有相同的特点，在隔水帷幕的主要工程阶段开始后，数据的趋势发生明显的变化。该实验的目的是为了验证模型在其他数据上的表现，进一步探讨模型在更多类型时间序列预测数据上使用的可行性。

3.4 本章小结

本章节对实验数据及研究区域进行了介绍。首先介绍了研究区域的特点，基本的地理情况、水文气象条件。最重要的是研究区的矿井涌水情况和隔水帷幕建设情况，隔水帷幕的建设使煤矿涌水量骤降，对预测带来困难。

随后进一步分析了地理、气象条件对矿井涌水量的影响，由于本矿区实验条件特殊，又对矿井涌水量的变化趋势进行了分析。解释了造成研究区涌水量过高的原因。最后，本文对实验设计进行了介绍，并将实验设计思路进行了汇总，详细的阐述了实验设计的意义，更好的帮助读者了解实验的具体流程。

第四章 单一模型预测矿井涌水量

本章节首先对数据的特点进行了介绍，并且对数据的划分、分解进行了解释。并初步使用了单一模型对矿井涌水量进行了预测，探究单一模型的预测特点，挖掘本文提出的Self-Attention的预测潜力。

4.1 数据分析

4.1.1 数据划分

在矿山生产中，建立具有分布非均质结构和参数的复杂物理模型是非常困难的。与基于过程的模型不同，深度学习模型是一种“黑箱”模型，其参数的物理含义与传统模型有所不同。深度学习模型的优势在于可以直接从数据中学习数据变化的特征，而无需考虑物理参数的精确含义。因此，本文在研究中没有涉及其他地质数据，而是侧重于利用深度学习模型从矿井涌水量数据中提取特征和模式，以实现准确预测。

图4-1为扎尼河露天矿2012年至2020年矿井涌水量数据，数据在2019年前整体呈缓慢下降趋势，2019年帷幕进入主要建设阶段，矿井涌水量下降速度增加。在预测之前本文对矿井涌水量的变化进行分析。本文考虑了帷幕建设进度和降雨量的影响因素，如图4-2，本文绘制了2013年到2018年海拉尔河的降水数据，整体呈现下降趋势。如图4-3，红色线段为2015年进行的长为400米的试验工程，工程验证了截水帷幕的效果，确定了帷幕有能力对地下水流场进行干扰。截水帷幕建成后矿井涌水量出现了一定程度的下降，能够确定地下水补给是影响矿井涌水的一个重要因素。图4-1是2012年到2020年的矿井涌水量，在2019年以前，矿井涌水量以一个稳定的速率在变化，2019年1月之后，矿井涌水量明显的剧烈下降。2019年1月，工程进行了主要的建设阶段，随着工程继续，矿井涌水量的下降速度增加（曲线斜率增大）。综上所述，本文认为在2019年以前矿井涌水量的匀速下降是由于当地降雨减少和地下水水位下降导致的。2019年之后的剧烈变化，是隔水帷幕工程占主导地位。

截水帷幕的建设在对2019年后的矿井涌水量变化产生了剧烈的影响，本文认为这是一种突发事件，这种突发的事件对于传统预测模型来说具有挑战，但在工程中，预料之外的情形往往是需要关注的。为了进一步研究机器学习模型对突发情况的应对能力，本文在实验中使用了该研究区域的矿井涌水量数据。本文收集了扎泥河露天煤矿2015年至2019年1810天的每日矿井涌水数据。

数据集按7: 3的比例分为训练集和测试集，作为模型的输入。本文的测试集涵盖了施工的主要部分，训练集仅有17%的数据拥有施工的信息。这样的划分可以保证模型

在训练时无法获得施工信息，在测试集预测时可以充分的反映模型应对突发情况的能力。




图 4-1 矿井涌水量 2012 年 1 月至 2020 年 1 月趋势变化曲线（蓝色虚线为隔水帷幕工程主要建设开始时刻）

Fig. 4-1 Trend of mine water inflow from January 2012 to January 2020 (blue dotted line indicates the start of major water-barrier curtain construction)




图 4-2 矿区 2014 至 2018 降雨量曲线图

Fig. 4-2 Rainfall curve in the mining area from 2014 to 2018




图 4-3 矿区隔水帷幕试验阶段（红色线段部分）

Fig. 4-3 Test phase of the water-barrier curtain in the mining area (red segment)

4.1.2 数据分解方法介绍

（1）小波变换（Wavelet Transform）

小波变换是一种时间-频率分析方法，能够在时间和频率上同时提供信息。它将信号分解成不同尺度（或频率）的小波函数，从而可以检测信号中的瞬态特征和频率变化。小波变换具有多分辨率特性，能够有效处理非平稳信号，并在许多领域中被广泛应用，如信号处理、图像处理和数据压缩等。

（2）经验模态分解（EMD）

EMD是一种基于数据自适应的信号分解方法，可以将信号分解成一系列本征模态函数（IMF），每个IMF代表了信号中的一个固有振动模式。通过迭代的方式，EMD将信号分解成趋势和振荡的组合，适用于处理非线性和非平稳信号，如地震信号和生物信号等。

（3）变分模态分解（VMD）

VMD是一种基于优化理论的信号分解方法，通过最小化信号与基函数之间的距离来得到信号的分解结果。VMD具有良好的收敛性和稳定性，能够有效地处理非线性和非平稳信号，并且对噪声具有一定的鲁棒性。

（4）集合经验模态分解（CEEMDAN）

CEEMDAN是对EMD的改进版本，引入了自适应噪声调整技术，通过多次重复提取IMF并取平均的方式来减小噪声的影响。CEEMDAN能够更好地处理噪声干扰和模态混叠等问题，提高了信号分解的稳定性和准确性。

（5）支持向量机分解（SVM Decomposition, SVMD）

SVMD是一种利用支持向量机（SVM）进行信号分解的方法，通过将信号投影到高维特征空间，并利用SVM的非线性分类能力来分离信号的不同成分。SVMD具有较强的非线性拟合能力，适用于处理复杂的信号结构和高维数据。

4.1.3 数据分解

当进行矿井涌水量预测时，数据的复杂性和不稳定性为模型预测增加了难度。这些数据通常具有非线性和非平稳性质，意味着它们可能呈现出不规则的变化模式和突发的波动。为了更好地理解和预测这种复杂性，本文需要使用适当的技术来处理原始数据。一些分解方法，例如CEEMDAN是一种针对非线性和非平稳时间序列数据的处理方法。它通过将原始数据分解为多个固有模态函数（IMFs），每个IMF代表了数据中的一个特定频率序列或模式。这种分解过程允许我们捕捉数据中的局部变化和复杂动态，使得我们能够更好地理解数据的内在结构和变化规律。在矿井涌水量预测中，CEEMDAN的应用对于提高预测模型的准确性和可靠性至关重要。通过将原始数据分解为多个频率序列，我们能够更好地捕捉数据的非线性特征和短期变化，从而提高了预测模型对于复杂数据模式的识别能力。这种预处理方法不仅提高了预测模型的性能，还使得模型更加稳健，能够更好地适应数据中的波动和变化。图4-4是通过CEEMDAN分解后的数据，其特点是具有高频、中频、低频的IMFs，其中低频的IMFs包含了数据的趋势。

在时间序列预测中，趋势的预测至关重要，一些工程问题中，通常很关注整体趋势的变化。例如在矿井涌水预测中，趋势预测可以帮助矿井管理者预测未来涌水量的变化趋势，从而及时采取必要的安全措施。如果发现涌水量呈现上升趋势，管理者可以提前做好防范措施，以减少事故风险；了解涌水量的趋势有助于矿井规划者进行有效的资源规划。如果发现涌水量预计将增加，可能需要调整生产计划或增加水资源管理投入，以保证生产的顺利进行；趋势预测有助于降低成本和提高效率。通过预测涌水量的趋势，矿井管理者可以优化设备维护计划、调整供水和排水系统，并合理分配人力资源，从而降低因涌水引起的生产中断和维修成本；预测涌水量趋势也有助于减少对环境的负面影响。如果预测到涌水量将增加，管理者可以采取措​​施来防止或减轻对周围环境的负面影响，如加强水质监测、采取环境修复措施等。




图 4-4 矿井涌水量数据经 CEEMDAN 分解后结果呈现

Fig. 4-4 Result of decomposition of mine water inflow data using CEEMDAN

4.2 单一模型预测

在尝试使用本文所提出的多模型预测框架之前，首先我们要进行单一模型性能的测试，进而研究多模型预测方案相比传统方案的优势。

4.2.1 模型选择

在研究中，本文将采用单一模型预测的方法，以评估各个模型在矿井涌水量预测任务中的表现。这些单一模型包括Self-Attention模型、LSTM模型、GRU模型和SVM模型。Self-Attention模型是一种在自然语言处理领域广泛应用的模型，其在处理长距离依赖关系和全局信息捕捉方面具有优势。在矿井涌水量预测中，考虑到涌水量可能受到多个因素的影响并具有时间序列的特点，Self-Attention模型能够有效地捕捉不同时间点之间的关联信息。LSTM（长短期记忆网络）是一种经典的循环神经网络，适用于处理时间序列数据并具有记忆单元，能够有效地捕捉数据中的长期依赖关系。在矿井涌水量预测中，LSTM模型能够有效地学习和记忆数据中的周期性和趋势，从而提高预测的准确性。GRU（门控循环单元）是LSTM的一种变体，相比于LSTM具有更简单的结构和更少的参数，训练速度更快。在矿井涌水量预测中，GRU模型可以作为一种快速而有效的基准模型，用于比较其他模型的性能。SVM（支持向量机）是一种经典的机器

学习算法，当数据样本较小时具有优势。在矿井涌水量预测中，SVM模型能够有效地处理数据中的非线性关系，提供一种与神经网络模型不同的建模思路。

4.2.2 模型输入




图 4-5 矿井涌水量变化情况及防水幕施工过程

Fig. 4-5 Variation of mine water inflow and construction process of water-barrier curtains

图4-5展示了研究期间矿井涌水量变化情况及防水幕施工过程。步骤A为防水幕墙施工的测试阶段，步骤B和步骤C为幕墙的正式施工阶段。步骤A对应于图4-1中的红色部分，而步骤B和C分别对应于图4-1中的绿色和蓝色部分。每阶段帷幕施工都会造成一定程度的矿井涌水量减少。绿色虚线描绘了实验的训练集和测试集之间的划分。值得注意的是，防水幕的施工过程没有作为模型的输入，这对预测提出了重大挑战。在整个原始数据中，93.16%的幕布构建发生在测试集中，导致模型在训练阶段无法学习这部分过程。在测试集中，本文可以清楚地观察到帷幕结构导致矿井水流入量大幅减少——这是模型没有意识到的“突发事件”。这可用于研究模型对不可预见事件的敏感性。

除了对单一模型进行实验外，我们还将探究CEEMDAN与每个模型结合的效果，以验证CEEMDAN对预测结果的改善。CEEMDAN作为一种数据预处理技术，具有能够提取数据中局部特征和复杂动态的能力，因此与各个模型结合后可能会进一步提高预测的准确性和稳健性。这一部分的实验设计将有助于我们全面理解CEEMDAN对矿井涌水量预测的影响，并为后续的多模型融合框架提供更加准确和可靠的基础。同时，通过与单一模型的对比，我们还可以更清晰地评估CEEMDAN在提升预测性能方面的具体作用和优势。

4.2.3 单一模型预测结果分析




图 4-6 单一模型以及使用 CEEMDAN 的单一模型使用后的测试集结果

Fig. 4-6 Test set results of single models and single models using CEEMDAN

图4-6为单一模型的测试集预测结果。本文将 Self-Attention、LSTM、GRU 和 SVM 模型与 CEEMDAN 结合起来进行预测，并将结果与没有使用 CEEMDAN 的情况进行比较。预测后的评估指标如图4-7和表4-1所示。

分析图4-6，总体来看，矿井涌水量的测试集预测难度较大，使用CEEMDAN后的预测效果均有改善。尤其在SVM的预测结果处，不使用CEEMDAN的情况下，SVM的预测结果偏差极大。对于Self-Attention，GRU以及LSTM的细节处预测改善效果较好，但趋势的预测效果较差。在图4-6a) 可以看出，Self-Attention的趋势预测效果较好，但细节预测效果较差，曲线接近平滑。

从图4-7中可以明显看出，使用 CEEMDAN 的模型在结果中表现出不同程度的改进。表现最好的模型是本文提出的Self-Attention模型。然而，结合图4-6可以看出，Self-Attention模型在使用CEEMDAN后并没有学习到矿井涌水量的细节变化。关于这个现象，本文在后面的章节进行着重分析。




图 4-7 单一模型预测结果 RMSE 和 MAE 柱状图

Fig. 4-7 Bar graph of RMSE and MAE for single model prediction results

表 4-1 单一模型预测结果评估指标

Table 4-1 Evaluation metrics for single model prediction results

	CEE-SVM	SVM	CEE-GRU	GRU	CEE-LSTM	LSTM	CEE-SA	SA
MAE (m³/d)	20768.49	30019.49	8003.74	10651.68	6069.70	10082.33	2863.66	4914.96
RMSE (m³/d)	36980.29	38429.84	9134.31	11990.93	9307.72	13394.57	3896.55	5894.50
MAPE	0.31	0.37	0.15	0.17	0.08	0.13	0.03	0.05




图 4-8 测试集结果的可视化

Fig. 4-8 Visualization of test set results

图4-8显示了预测后CEE-SA、CEE-LSTM、CEE-GRU和CEE-SVM在测试集上的曲线。与原始数据相比，除CEE-SA外，所有曲线的预测都相对保守，未能有效预测矿井

涌水量的持续减少。另一方面,CEE-SA 表现出卓越的性能,与原始数据的偏差最小。然而,值得注意的是,虽然 CEE-SA 在趋势预测方面表现出色,但在捕捉更精细的细节方面却表现不佳(从图中的放大视图可以明显看出)。初步假设表明,Self-Attention 模型在预测 CEEMDAN 分解的低频分量方面表现良好,但难以捕获高频分量中包含的详细信息。

4.3 本章小结

本章节对实验的第一部分,即单一模型的预测结果进行了分析。首先介绍了数据的具体情况,隔水帷幕对矿井涌水量的变化造成了影响。并且进一步解释数据划分、分解的意义和思路。在模型选择部分,本文介绍了采用的单一模型,包括Self-Attention、LSTM、GRU和SVM,并分析了它们各自的特点和选择原因。对单一模型预测的实验结果进行了分析,包括对使用CEEMDAN的模型与不使用CEEMDAN的模型进行比较,并提供了评估指标和可视化结果。所有的模型在评估指标上都相比不使用CEEMDAN得到了改善。尤其使用了CEEMDAN的Self-Attention模型在趋势预测方面表现突出,然而在捕捉细节方面却有所不足。为了进一步研究本文提出的Self-Attention模型的预测潜力,本文设计了随后章节的实验进行研究。

第五章 多模型预测框架预测矿井涌水量

本章节将进一步挖掘Self-Attention的预测潜力，并将其与本文提出的多模型预测框架结合，对矿井涌水量进行预测。本文所提出的多模型预测框架，不仅仅是对前人的模型进行改良，它能够结合多种模型的优势，解决实际问题。在本研究中，矿井涌水量在2019年后剧烈下降，是一种难以预测的突发情况。在挖掘Self-Attention的预测性能时，我们发现它对于分解后趋势项的预测效果要好于传统模型，初步猜测这得益于它的Encoder-Decoder编码结构，与传统的循环神经网络不同。但是，Self-Attention模型的预测能力也有劣势，也因此我们提出了一种多模型的预测框架来克服这种劣势。框架能够将Self-Attention与成熟的循环神经网络结合，更好的改善矿井涌水量的预测效果。

5.1 趋势分量的预测

5.1.1 数据输入

本章节实验使用了研究区矿井涌水量数据分解后的趋势分量，使用CEEMDAN将矿井涌水量数据分解，分解后的IMF-7、IMF-8、IMF-9分量为趋势分量。此外还选择了分解后频率最高的IMF-1分量，目的是为了向读者展示Self-Attention在高频分量预测能力较差的缺点。图5-1为分解后的趋势分量，这些分量频率较低，包含了数据中趋势变化的信息。






图 5-1 矿井涌水量分解后的趋势分量 IMF-7、IMF-8 和 IMF-9

Fig. 5-1 Trend components IMF -7, IMF -8, and IMF -9 after decomposition of mine

5.2.2 实验结果分析

在上一章的实验中,我们注意到Self-Attention对于趋势分量的预测表现良好,为了进一步分析Self-Attention在趋势分量的预测能力,本文设计了实验对分解后分量的趋势分量进行预测。




图 5-2 IMF-7、IMF-8、IMF-9 和 IMF-1 测试集预测的可视化

Fig. 5-2 Visualization of test set predictions for IMF-7, IMF -8, IMF -9, and IMF-1

图5-2a、b、c和d分别说明了不同模型在预测IMF-7、IMF-8、IMF-9和IMF-1分量方面的性能。在图5-2a表示IMF-7的测试集的预测结果，预测趋势效果最好的是Self-Attention模型，它在测试集的预测曲线与真实值曲线几乎重叠。LSTM和GRU随着时间推后，误差累积越来越大，并不能好的拟合出曲线的下降趋势，SVM的预测效果较差。图5-2b表示IMF-8的测试集的预测结果，结合图5-1b可以看出，训练集和测试集都有较大幅度的数据波动，在训练集有充分的数据使模型学习数据波动的信息。然而在测试集数据的峰值处（图中黑色方框部分），各个模型在峰值的预测效果有一定的差距。Self-Attention模型预测效果较接近，但略高于真实值，原因可能是在训练集给予了模型在峰值预测较多的权重。与预期相符和的是LSTM、GRU和LSTM模型的预测较为保守。在测试集最后部分，SVM一如既往的预测出了错误的趋势。LSTM、GRU、Self-Attention的预测结果与5-2a类似。图5-2c表示IMF-9的测试集的预测结果。很明显除了Self-Attention之外都表现出较差的预测结果，原因结合图5-1c可以看出，在训练集部分的数据较为平坦，但测试集部分出现了突变，故对传统的机器学习模型来说，预测到突然的变化难度较大。此外，在图5-2a和5-2b中，曲线在峰值和曲线末端有明显的向中心收敛的趋势，自注意力模型的预测是例外。其他三个模型的预测显得相对保守。图5-2d显示了高频IMF-1分量上的自注意力结果，我们做这一组是为了补充在研究时发现的Self-Attention的缺陷，很明显，对于高频分量，Self-Attention并不能好的预测。

从结构上猜测造成这一现象的原因，Self-Attention模型的参数量主要由其注意力矩阵的大小所决定。对于一个Self-Attention层，参数量与输入序列的长度成正比。在传统的翻译任务中，参数量由词向量的长度和维度决定，在计算attention矩阵时，参数量是词向量长度的平方。在我们的矿井涌水量问题中，取决于输入序列的长度，输入序列

的长度越长,参数量越多。而在传统的LSTM或GRU网络中,参数量由输入维度和隐藏层的数量决定,在我们的一维序列预测中,输入维度为1,然而隐藏层的数量相比attention矩阵的长宽肯定是非常小的(实际模型运行中,Self-Attention模型的运行时间要远大于LSTM、GRU或SVM)。简而言之,在输入序列长度较长时,Self-Attention模型的参数量可能会更多;而在输入序列长度相对较短、但是隐藏状态维度较大时,LSTM模型的参数量可能会更多。Self-Attention的权重矩阵有较多的参数量,能够顾全训练集中较远序列的信息。而LSTM、GRU网络的参数较少并且模型本身存在的一定的梯度消失的问题,很难对历史信息进行好的保留。

综上所述,实验结果符合我们的预期。常用的时间序列预测模型(例如LSTM、GRU和SVM)在数据剧烈变化的情况下暴露出其局限性。Self-Attention模型在预测低频分量的趋势序列方面表现良好,但在高频分量的预测性能较差。模型总是有优点和他的局限性,没有哪个参数和框架是通用的,Self-Attention能够好的预测趋势分量,相反的他对于细节信息的捕获较差。

5.2 多模型预测结果分析

当本文发掘到Self-Attention在趋势预测方面的潜力之后,我们计划将其优势与其他模型结合,提出了多模型的预测框架。该框架具体运行流程见2.3节。本文提出框架通过CEEMDAN将原始数据分解成多个子序列,使用不同的模型预测适合的序列,达到将多种模型优势结合的效果。框架筛选合适模型时的选择依据,是不同模型对不同频率序列的预测效果。用频率作为选择依据是因为,不同频率序列对应了原始数据的趋势信息或细节信息,而我们在实验中发现,不同的模型对于不同频率的序列预测效果不同,例如在5.1节发现了Self-Attention适合预测趋势序列,SVM适合预测高频率序列。

5.2.1 数据输入

本文使用VMD将原始数据分解为19个IMF,排除零频率和相同频率的IMF,剩下14个IMF。然后通过各种模型对这14个IMF进行预测,并对结果进行比较。表5-1显示了1000Hz采样率下每个IMF的频率以及每个模型预测的MAPE评估指标。为了便于分析,将表5-1的结果可视化为图5-3中的曲线图。

表 5-1 VMD 提取的 14 个序列的频率和 MAPE

Table 5-1 Frequencies and MAPE for 14 sequences extracted by VMD

	Frequency (Hz)	SA	LSTM	GRU	SVM
IMF-2	12.81	1.61	1.97	1.66	3.77
IMF-3	34.54	1.4	1.86	1.52	2.88
IMF-4	65.74	2.06	1.28	1.56	2.51
IMF-5	96.38	1.1	0.62	1.64	2.21
IMF-7	109.19	1.21	0.73	0.98	1.86
IMF-9	142.62	1.91	0.86	1.34	1.77
IMF-10	191.64	3.89	1.89	2.3	2.1
IMF-11	250.14	2.56	1.51	1.76	1.34
IMF-12	317.55	3.23	1.58	2.29	1.23
IMF-13	350.55	4.86	2.48	2.92	1.52
IMF-14	392.76	2.57	0.74	0.89	0.25
IMF-17	427.86	2.37	1.34	1.65	0.47
IMF-18	489.14	1.6	1.6	0.76	0.24
IMF-19	498.05	3.61	2.29	1.79	1.01

表 5-2 CEEMDAN 分量频率和相应的预测模型

Table 5-2 CEEMDAN component frequencies and corresponding prediction models

	分量	频率	模型	RMSE	MAE	MAPE
CEEMDAN	IMF-1	254.56	SVM	1764.11	2766.14	0.02
	IMF-2	119.82	LSTM			
	IMF-3	49.14	LSTM			
	IMF-4	29.27	LSTM			
	IMF-5	12.70	LSTM			
	IMF-6	3.31	SA			
	IMF-7	1.66	SA			
	IMF-8	1.1	SA			
	IMF-9	0	SA			




图 5-3 预测不同频率 IMF 的不同模型的 MAPE 折线图

Fig. 5-3 Line graph of MAPE for different models for different IMF frequencies

在图5-3中，可以看出不同频率下每个模型的预测效果（MAPE越低越好）。其中Self-Attention在低频部分略好，这与我们在5.1节的预期一致，对高频率序列的预测效果不如其他模型。在50Hz到200Hz之间，LSTM和GRU的表现要好于其他模型。当频率来到高频区间时，SVM的预测效果表现更出色。本文将224Hz作为一个分水岭，区别不同频率序列对应其合适的模型。本文将结果总结成表5-2可以清晰的看出CEEMDAN分解后的序列所选择的模型。




图 5-4 多模型测试集预测的可视化

Fig. 5-4 Visualization of multi-model test set predictions

表 5-3 多模型和 CEE-X 模型的比较结果

Table 5-3 Comparison results between multi-model and CEE-X model

	Proposed	CEE-SA	CEE-LSTM	CEE-GRU	CEE-SVM
RMSE(m ³ /d)	1764.11	2863.66	6069.7	8003.74	20768.49
MAE(m ³ /d)	2766.14	3896.55	9307.72	9134.31	36980.29
MAPE	0.02	0.03	0.08	0.15	0.3

我们计算CEEMDAN第一部分分解结果的频率，然后采用适合不同频率的模型进行预测。表5-1概述了频率模型配对。表5-2和图5-3分别显示了多模型预测框架的预测指标和测试集结果的可视化。本文提出的集合预测方法的评估指标是最有利的。此外，图5-4说明了测试集的结果，它不仅巧妙地捕捉了下降趋势，而且还成功预测了细微的数据变化。准确的趋势预测归因于Self-Attention对于捕捉长序列数据趋势的熟练程度，而精确的细节预测则归因于将不同的频率分量分配给合适的模型进行预测。发挥多种模型优势的结果是单一模型无法达到的。

5.3 Self-Attention 结构分析




图 5-4 LSTM 与 Self-Attention 结构对比

Fig. 5-4 Comparison of LSTM and self-attention structures

本文深入研究了LSTM和GRU网络在预测序列趋势变化方面的结构局限性。作为一种独特的的循环神经网络类型，LSTM和GRU的引入旨在解决传统RNN中存在的梯度消失问题。以LSTM为例，图5-4a说明了数据从左到右输入模型、更新权重信息的过程。随着数据的增加，早期信息（例如X1，X2）对权重的影响逐渐减弱，特别是在处理长输入序列时，使得保留历史信息变得具有挑战性。这导致模型在面对数据突变时表现不佳，这是之前研究中观察到的问题。

相比之下, Self-Attention采用编码器-解码器架构,如图5-4b所示,能够并行输入和输出时序数据(其中注意力权重在图中用 α 表示)。通过执行2.2节中描述的Softmax计算, Self-Attention考虑 X_n 与所有元素之间的依赖关系,为某些元素分配更多权重,创建“Attention”。 α 之和为1,这意味着模型在处理某个位置时会同时考虑整个上下文,而不是选择性地关注数据的子集。在本研究的背景下,在探索矿井水流入数据特征时,自注意力可以为变化的数据分配更多的权重。大量研究发现,注意力机制擅长关注序列相关任务中的关键信息。综上所述, Self-Attention通过并行机制处理整个序列,为不同的数据元素分配不同的权重。相比之下,像LSTM和GRU这样的网络需要顺序处理输入数据,从而导致梯度消失的问题。因此, Self-Attention在预测数据的总体趋势方面表现出色,但对微小波动的预测能力可能有限。

5.4 与其他多模型预测方法比较




图 5-5 不同多模型方法对比结果

Fig. 5-5 Comparison of results from different multi-model methods

表 5-4 多模型预测结果的呈现

Table 5-4 Prediction results for n1 water monitoring well

	Proposed	LSTM-GRU	TCN-GRU	CNN-MLP-LSTM
MAE (m^3/d)	1764.11	6004.63	10883.09	10340.35
RMSE (m^3/d)	2766.14	8696.56	16109.48	14819.82
MAPE	0.02	0.08	0.14	0.13

为了更好地证明本文提出的模型的优越性,本文与代表性的多模型进行了比较。所选模型包括LSTM-GRU、TCN-GRU和CNN-MLP-LSTM:

(1) 在时间序列预测领域，LSTM和GRU是应用最广泛的深度学习模型。一些研究人员使用各种技术将它们合并，与单个模型相比，性能得到了增强。在本研究中，本文使用加权LSTM-GRU组合模型作为比较模型，具有更好的泛化性。

(2) 时序卷积网络（TCN）模型在时间序列预测领域也得到广泛应用。它通过一维卷积和因果卷积等技术有效地捕获长期依赖性和序列结构。本文采用了多位学者使用的TCN-GRU模型，该模型性能更好，并且可以与优秀的GRU网络结合。

(3) 多层感知器（MLP）是一种经典的前馈神经网络，在预测领域表现良好。在本研究中，本文使用了CNN-MLP-LSTM相结合的模型进行比较。

图5-5展示了各种模型之间的测试集比较（“Propose”表示本文提出的多模型预测模型）。本文提出的模型在以剧烈趋势变化为特征的后半部分中明显优于其他模型。这归功于Self-Attention模型在低频趋势分量上的优越预测性能。表5-4列出了上述模型的评估指标的比较。总之，与其他多个模型相比，本文提出的模型表现出了更好的性能。最佳的预测性能需要合适的模型和数据。本文提出的多模型方法允许替换特定模型，理论上可以解决更广泛的场景。

5.5 多模型框架重构及模型选择

多模型预测框架有利于整合不同模型的优势。在这项研究中，Self-Attention的纳入在改善预测结果方面发挥了关键作用，特别是在处理具有重大趋势变化的数据方面表现出色。虽然Self-Attention对于高频数据效果不及传统时间序列模型，但通过结合LSTM、GRU和SVM可以解决这个问题。由此可见，模型特点的互补性至关重要。读者在使用此模型框架时，应优先选择有特点的模型，尽可能用其他模型的优势弥补该模型的劣势。

随着深度学习技术的发展，大量广泛应用于地下水案例的深度学习和机器学习模型，如ARIMA、SVM、LSTM、GRU、人工神经网络（ANN）及其增强版本等代表性模型。这些模型与各种数据处理方法相结合，产生了一系列具有不同特点的模型。本文提出的框架与不同的时间序列模型兼容。本文选择了LSTM、GRU和SVM的组合，因为这些是广为人知，比较有代表性的模型。他们各自代表了深度学习和传统的机器学习在时间序列预测上的应用。选择它们是因为它们具有广泛的用途，并且在一定程度上充当各自领域的代表性模型。

5.6 分解方法的选择

本研究使用了CEEMDAN作为多模型预测框架的分解方法，除此之外还有经验模态分解（EMD）、经验小波变换（EWT）、变分模态分解（VMD）。对于当前研究区

域, CEEMDAN是经过测试分析后最合适的分解方法, 但其他分解方法也值得讨论, 有在其他研究中使用的可能。

5.6.1 经验模态分解 (EMD)

经验模态分解 (Empirical Mode Decomposition, EMD) 是一种时频分析方法, 用于从复杂的信号中分解出本征模态函数 (Intrinsic Mode Functions, IMFs)。EMD主要用于分析非线性和非平稳信号, 广泛应用于信号处理、数据分析、语音识别、地震学等领域。EMD可以提取有价值的成分, 有助于获得信号必要的特征。因此, 人们对EMD进行了大量的理论和应用研究。其中, 集成经验模态分解 (EEMD)、互补集成经验模态分解 (CEEMD) 和带有自适应噪声的互补集成经验模态分解 (CEEMDAN) 是使用较多的。因此, 本文介绍这些方法的原理, 以及相对于 EMD 的相应优势, 以及选择 CEEMDAN的原因。

EMD将信号 分解为少量 IMF。过程如下:

- (1) 设 $k=0$, 求 $r_0(t) = f(t)$ 的所有极值。
- (2) 在 $r_k(t)$ 的最小值(最大值)之间进行插值以获得下(上)包络 $e_{min}(t)(e_{max}(t))$ 。
- (3) 平均包络线的计算公式为:

$$m(t) = (e_{min}(t) + e_{max}(t))/2 \quad (5-5)$$

- (4) IMF候选者的获得方式为:

$$d_{k+1}(t) = r_k(t) - m(t) \quad (5-6)$$

- (5) 对 $d_{k+1}(t)$ 重复步骤 (2) 到 (4), 直到 $m(t)$ 接近于零。那么 $d_{k+1}(t)$ 就是一个IMF, 记为 $c_{k+1}(t)$ 。

- (6) 计算余数:

$$r_{k+1}(t) = f(t) - c_{k+1}(t) \quad (5-7)$$

- (7) 将残差 $r_{k+1}(t)$ 取为 $f(t)$, 重复步骤(1)~(6)生成下一个IMF和残差, 直到最终的 $r(t)$ 满足预定义的停止准则。因此, 原始信号 $f(t)$ 可以用下式表示:

$$f(t) = \sum_{i=1}^n c_i(t) + R(t) \quad (5-8)$$

其中 $c_i(t)$ 是第 i 个IMF, $R(t)$ 是最终的残差。

信号极值的分布取决于相应单分量的 IA 和 IF。借鉴EMD的原理, EMD利用其在筛选和迭代过程中提取IMF。因此, 该方法不可避免地受到一些领域的限制, 例如频率分辨率和采样频率的影响。

EMD是一种无需先验知识或信号结构假设的信号分解方法。它根据信号自身的特性进行分解, 具有良好的自适应性。分解后得到的每个固有模态函数 (IMF) 代表了信号在时间-频率域上的局部特征, 因此能够更好地捕捉信号的局部变化。与其他频谱分析方法 (如小波变换) 相比, EMD无需复杂的参数调整, 只需设置停止准则的阈值即可。

然而, EMD也存在一些问题。存在模态混叠问题, 即不同频率成分在不同时间段混合在一起, 从而影响分解结果的准确性。此外, EMD的频率分辨率受筛选迭代次数和停止标准阈值的影响, 因此对于不同信号可能需要经验性地调整参数。同时, 为了获得准确的分解结果, EMD对信号的采样频率要求较高, 否则可能会导致误差增加和出现假分量。此外, EMD对噪声和局部极大值敏感, 这可能导致分解结果的不稳定性, 特别是在信号存在较强噪声或异常值的情况下。

5.6.2 集成经验模态分解 (EEMD)

集合经验模态分解 (EEMD) 是经验模态分解 (EMD) 的一种改进方法。它通过在信号中加入白噪声, 实现了在时频空间中更均匀的尺度分布。EEMD 的核心理念是, 白噪声可以提供一个均匀分布的参考网格, 从而自动关联信号中不同尺度的固有振荡。借助这种机制, EEMD 能够在整个信号中保持固有振荡的连续性。在 EEMD 中, 白噪声的加入非常关键。它为信号提供了参考框架, 使得提取固有模态时更加稳定和一致。白噪声的性质使其在整个时频空间中分布均匀, 从而能够有效地抑制由于间歇信号引起的模式混合问题。EMD 的提取方式基于极值分解, 选择每个时间段内出现频率最高的分量。这种方式可以避免由于信号的不连续性导致的模态混合现象。通过添加白噪声并对其进行多次 EMD 分解, 然后计算均值, EEMD 可以显著减小模态混合的风险。均值运算在 EEMD 中扮演重要角色, 它能够在信号的极值部分保留原始信号的特征, 而在没有极值的部分保持稳定, 从而确保信号的固有模态能够得到准确提取。通过这种方式, EEMD 改进了 EMD, 提供了更强的稳定性和鲁棒性。

集成经验模态分解原理如下:

(1) 信号 $f_i(t)$ 的产生方式为

$$f_i(t) = f(t) + \beta \omega^{(i)}(t) \quad (6-5)$$

其中 β 是添加白噪声的方差, $\omega^{(i)}(t)(i=1, \dots, i \text{ 是进行EMD的次数})$ 表示零均值单位方差白噪声 $N(0,1)$ 。

(2) 利用EMD对每个 $f_i(t)$ 进行完全分解, 得到IMFs $d_k^i(t)$ (k 是EMD的IMF个数)。

(3) 计算每个最终 IMF,

$$c_k(t) = \frac{1}{I} \sum_{i=1}^I d_k^i(t) \quad (6-6)$$

其中 $c_k(t)$ 是EEMD 的第 k 个IMF。

EEMD是对EMD的改进, 能够克服 EMD 的频率分辨率限制, 使得在合理的迭代次数下, 更好地分离信号的不同频率成分。

5.6.3 互补集合经验模态分解 (CEEMD) 和自适应噪声集合经验模态分解 (CEEMDAN)

EEMD添加白噪声可能会在 EEMD 分解结果重构的信号中引入残差。EEMD 中添加的白噪声残差可以通过带有正添加白噪声的系综 IMF 从数据和白噪声的混合中提取出来重新构建信号，与 EMD 迭代计算过程中产生的残差不同。为了抑制这种残留效应，CEEMD被提出了。

CEEMDAN相比EEMD的优点在于它引入了自适应噪声，在分解过程中可以更有效地去除残留信号。通过对每个残差引入不同实现的白噪声，并结合多次重复的分解过程，CEEMDAN能够提供更准确和稳健的分解结果，进而改善了信号重建的质量。此外，还可以根据信号特征调整噪声的幅度，从而更好地适应不同类型的信号，提高了分解的灵活性和适用性。

5.6.4 变分模态分解 (VMD)

VMD的原理在2.1节已经进行介绍，它的优点在于它能够自适应地确定信号的相关频段，并通过有效的分解方法将不同分量分离出来，使得分解结果具有较高的精度。VMD的计算过程相对简单且快速，具有较低的计算复杂度。然而，VMD的缺点在于它对信号的傅里叶频谱进行分段处理，因此受到傅里叶谱的限制，当信号的不同分量无法在频谱中明确分离时，VMD的分解效果可能不理想。VMD的参数K对分解的结果影响很大，通过调整K可以控制分解的细节程度和分量的数量，从而使VMD适应不同信号的特性。这种参数的调节性使得VMD可以根据需要对信号进行更精细或更粗糙的分解，提高了其适用性和灵活性，但增加了模型的参数复杂度。

5.7 本章小结

本章节研究了多模型预测框架对矿井涌水量的预测。首先，本文设计了实验对Self-Attention在趋势预测方面的预测性能进行了验证。实验结果表明，Self-Attention在预测低频趋势分量方面表现良好，但对于高频分量的预测效果较差。为了克服Self-Attention的局限性，本文进一步提出了多模型的预测框架，结合不同模型对不同频率序列的预测能力，取得了较好的预测效果。此外，本章节注重模型结构的解释和框架重现的讨论。首先对模型的结构进行了分析，向读者解释了Self-Attention相较传统时间序列预测模型的区别所在，分析了结构对结果进行的影响。并且进一步的将多模型预测框架与其他多模型预测方法进行了对比，展示了本文所提出多模型预测框架的独特性。为了方便读者重现或改进，对于模型框架的使用以及模型的选择进行了讨论。最后对与分解方法的选择进行了讨论。

在第五章本文分别对多模型预测框架的性能进行了验证,并在第六章结合预测结果和模型结构对其进行了分析,进一步的,本文将对多模型预测框架的适用范围进行拓展,用于地下水位的预测。本章节本文将所提出的多模型预测框架应用于地下水位预测的场景,并对其综合性能进行评估。

Fig. 6-1 Layout of monitoring wells for groundwater level in the mining area

47




图 6-2 Q4 地下水位监测井水位变化曲线

Fig. 6-2 Water level change curve of Q4 groundwater monitoring well




图 6-3 观 13-2 地下水位监测井水位变化曲线

Fig. 6-3 Water level change curve of Guan 13-2 groundwater monitoring well




图 6-4 N1 地下水位监测井水位变化曲线

Fig. 6-4 Water level change curve of N1 groundwater monitoring well




图 6-5 N4 地下水位监测井水位变化曲线

Fig. 6-5 Water level change curve of n4 groundwater monitoring well




图 6-6 Z4 地下水位监测井水位变化曲线

Fig. 6-6 Water level change curve of Z4 groundwater monitoring well

Q4, 观13-2, N1, N4, Z4五个水位监测井都是隔水帷幕内的水井, 随着隔水帷幕修建, 水位逐渐下降。整体来看, 五个地下水位监测井在前半段趋于稳定, 后半段逐渐下降, 根据每个井的水文地质条件不同, 在细节的变化上一致。综合看来, 五个地下水位监测井的数据有预测的价值, 可以进一步评估模型的适用性。

6.2 地下水位监测井数据预测结果分析

本节本文使用了本文所提出的模型框架(图表中用Proposed代替), 以及对比模型Self-Attention、LSTM、GRU、LSTM-GRU、TCN-LSTM、CNN-MLP-GRU七种模型进行对地下水位监测井数据进行预测, 在绘制测试集曲线图时, 考虑到模型线条过多, 可读性较差, 本文将图分成四组进行展示。评估指标依然使用第三章介绍的评估指标。数据分解方式使用CEEMDAN, 考虑到阅读的连贯性, 本文将CEEMDAN的分解结果放在本章节的末尾进行展示。数据划分依然使用训练集测试集7:3的划分方法。

6.2.1 N1 水位监测井预测结果

表 6-1 N1 水位监测井预测结果

Table 6-1 Prediction results for N1 water monitoring well

	Proposed	SA	LSTM	SVM	GRU	LSTM-GRU	TCN-LSTM	CNN-MLP-GRU
MAE (m)	0.18	0.39	1.35	3.2	1.09	0.98	0.71	0.85
RMSE (m)	0.22	0.42	1.56	3.43	1.33	1.1	0.79	0.97
MAPE	0.36	0.41	0.86	2.35	0.54	0.68	0.52	0.64




图 6-7 N1 水位监测井各模型之间测试集结果

Fig. 6-7 Test set results for different models for N1 water monitoring well

如图6-7,展示了各个模型预测N1水位监测井数据的测试集结果图。从图中可以看出,本文所提出的模型喝SA模型有更好的表现,其中使用了多模型预测框架的模型比SA模型的拟合结果更接近真实值。SA的预测趋势较好,但对细节的预测较差。其他传统模型,如LSTM、GRU、SVM模型对于趋势的预测较差,主要体现在下降趋势无法好的捕捉和预测。尤其SVM模型的预测结果较差,传统的机器学习方法对于突变数据的你和能力较差。CNN-MLP-GRU、TCN-LSTM、LSTM-GRU等其他多模型预测方法的预测结果相比单一模型均有改善。尤其CNN-MLP-LSTM模型的预测效果较好,多种模型的预测效果在趋势变化剧烈的情况下预测效果较好。表6-1是N1水位监测井的评估指标结果,可以看出,本文提出的模型预测效果好于其他模型,其次是本文提出的Self-Attention模型。与矿井涌水量预测结果相比,地下水位预测的结果符合预期。

6.2.2 N4 水位监测并预测结果

表 6-2 N4 水位监测并预测结果

Table 6-2 Prediction results for n4 water monitoring well

	Proposed	SA	LSTM	SVM	GRU	LSTM-GRU	TCN-LSTM	CNN-MLP-GRU
MAE (m)	0.09	0.25	0.93	2.1	0.85	0.67	0.71	0.58
RMSE (m)	0.14	0.24	1.12	2.75	0.4	0.7	0.55	0.44
MAPE	0.21	0.21	0.66	1.45	0.34	0.34	0.36	0.98




图 6-8 N4 水位监测并各模型之间测试集结果

Fig. 6-8 Test set results for different models for n4 water monitoring well

如图6-8,展示了各个模型预测N4水位监测井数据的测试集结果图。整体看来,相比N1水文监测井, N4水位监测井的预测结果较好。结合图6-8可以发现,训练集中存在下降趋势的序列,模型在训练过程中对下降的趋势能够有效的捕捉,在预测中有相对好的表现。但有与N1水位监测井预测结果相同的表现,单一的预测模型效果不如多模型的预测效果。本文提出的多模型预测框架预测结果最好,其他多模型预测框架也有较好的表现。TCN-LSTM模型与CNN-MLP-GRU模型的预测效果接近,能够体现出多模型预测结果的优势。LSTM-GRU模型也属于多模型的预测方法,但两个模型的结构接近,表现的效果不如其他多模型预测方法。表6-2展示了N4水位监测井的评估指标结果,本文所提出的模型表现优于其他模型,与N1水位监测井数据相比结果均有改善。总体看来,当数据变化趋势不够剧烈时,模型之间差距较小,但使用多模型方法的结果均好于单一模型的结果。

6. 2. 3 Q4 水位监测井预测结果

表 6-3 Q4 水位监测井预测结果

Table 6-3 Prediction results for q4 water monitoring well

	Proposed	SA	LSTM	SVM	GRU	LSTM-GRU	TCN-LSTM	CNN-MLP-GRU
MAE (m)	0.16	0.34	1.28	2.93	1.02	0.85	0.57	0.73
RMSE (m)	0.25	0.35	1.47	3.21	1.22	0.84	0.72	0.88
MAPE	0.31	0.35	0.81	2.15	0.48	0.61	0.56	0.53




图 6-9 Q4 水位监测井各模型之间测试集结果

Fig. 6-9 Test set results for different models for q4 water monitoring well

如图6-9，展示了各个模型预测Q4水位监测井数据的测试集结果图。Q4水位监测井的数据变化幅度较大，预测难度相比前者更大。从图6-9可以看出，与其他水位监测井的预测结果类似，本文所提出的模型预测效果好于其他模型。LSTM-GRU、LSTM、GRU三个模型的测试集预测结果接近，都未能好的捕捉到数据下降的趋势。SVM的预测效果最差，整体的预测趋势趋于水平。TCN-LSTM、CNN-MLP-GRU与本文提出的多模型预测方法的预测结果较好。表6-3展示了预测结果的评估指标，与预期相同，本文所提出的多模型预测框架的预测结果好于其他模型。

6.2.4 观 13-2 水位监测井预测结果

表 6-4 观 13-2 水位监测井预测结果

Table 6-4 Prediction results for guan 13-2 water monitoring well

	Proposed	SA	LSTM	SVM	GRU	LSTM-GRU	TCN-LSTM	CNN-MLP-GRU
MAE (m)	0.13	0.27	1.01	2.58	1.09	0.91	0.65	0.77
RMSE (m)	0.18	0.31	1.25	2.64	1.08	0.98	0.57	0.73
MAPE	0.26	0.29	0.33	1.79	0.41	0.51	0.38	0.44




图 6-10 观 13-2 水位监测井各模型之间测试集结果

Fig. 6-10 Test set results for different models for guan 13-2 water monitoring

结合图6-3，观13-2水位监测井的变化趋势在后半段较为平缓，并且在训练集中能够包含趋势下降的信息，在一定程度上降低了预测的难度。如图6-9，展示了各个模型预测观13-2水位监测井数据的测试集结果图，整体来看，各个模型的预测效果均表现良好，SVM的预测结果较差。本文所提出的多模型预测框架预测结果较好，优于其他模型。与N4水位监测井的预测结果类似，多模型预测框架都有较好的预测表现。表6-3展示了所有模型预测结果的评价指标，本文所提出的多模型预测框架的预测结果好于其他模型，多模型预测框架预测结果好于单一模型。

6.2.5 Z4 水位监测井预测结果

表 6-5 Z4 水位监测井预测结果

Table 6-5 Prediction results for z4 water monitoring well

	Proposed	SA	LSTM	SVM	GRU	LSTM-GRU	TCN-LSTM	CNN-MLP-GRU
MAE (m)	0.08	0.28	0.68	1.54	0.59	0.46	0.38	0.49
RMSE (m)	0.10	0.21	0.75	1.54	0.63	0.58	0.39	0.45
MAPE	0.18	0.20	0.48	1.12	0.26	0.35	0.27	0.29




图 6-11 Z4 水位监测井各模型之间测试集结果

Fig. 6-11 Test set results for different models for z4 water monitoring well

结合图6-6，Z4水位监测井的水位变化数据，在2019年5月之后的下降趋势较为规律，在训练集部分，模型能够有效的学习到数据的下降趋势。反映在图6-11的测试集结果图中，可以看出各个模型的预测结果较为准确。SVM的预测趋势与其他模型相差较大。LSTM-GRU模型、LSTM模型、GRU模型的结果接近。与其他水位监测井的预测结果相似，多模型预测方法的预测结果表现优于单一模型预测结果。表6-5显示了所有预测模型预测结果的评估指标，本文所提出的多模型预测框架预测效果好于其他模型。结合上述各个水位监测井水位数据的预测结果来看，多模型预测框架的预测效果较好，并且预测结果与矿井涌水量的预测结果基本一致，尤其本文所提出的多模型预测框架，在预测结果上有好的表现。

6.3 本章小结

本章节使用了本文所提出的多模型预测框架，对比模型Self-Attention、LSTM、GRU、LSTM-GRU、TCN-LSTM、CNN-MLP-GRU对地下水位监测井数据进行预测。通过对地下水位数据的预测，验证模型的适用性。选择的水位监测井数据有五组，分别是Q4，观13-2，N1，N4，Z4水位监测井数据。结果显示，本文所提出的多模型预测框架预测效果优于其他模型。由于多模型的预测方法结构更复杂，对数据的特点包容性更强，多模型的预测效果好于单一模型的预测效果。从地下水位数据预测的结果可以看出，本文所提出的模型，在时间序列预测问题上有一定的通用性。初步尝试在地下水位的突变数据预测上效果达到预期，有用于其他场景与时间序列数据的可能。

第七章 结论及展望

7.1 结论

矿井涌水是煤矿安全生产中的一个关键问题,准确预测矿井涌水量可以有效指导煤矿及相关管理部门制定合理的管理策略。矿井涌水数据波动大,预测困难,传统的预测方法存在一定的局限性。为了更好地应对矿井涌水量的各种波动,增强模型对矿井涌水量不确定变化的适应性,本研究结合了深度学习技术,提出了一种多模型预测框架以及一个基于Transformer改进的Self-Attention预测模型。通过在扎尼河露天矿进行矿井涌水量预测实验,验证了Self-Attention在矿井涌水量预测中的可行性。扎尼河露天矿的矿井涌水量情况复杂,趋势变化剧烈,难以预测。本研究将多模型预测方法与擅长预测数据趋势的Self-Attention模型相结合,验证了提出的多模型预测框架的性能。该框架改善了传统模型在预测趋势突变数据时的困难。此外,本研究还将该预测框架用于预测扎尼河露天矿的地下水位数据,探索了模型和框架在其他水文问题预测上的潜力。

(1) 通过改进Transformer中的Self-Attention模块,提出了Self-Attention的矿井涌水量预测模型并用于扎尼河露天矿矿井涌水量预测中。整体看来,Self-Attention因为结构不同,有与传统机器学习时间序列预测方法不同的优势。从预测CEEMDAN分解获得的低频分量的预测来看,Self-Attention在趋势预测方面表现出色。但在高频率序列的方面不如传统的LSTM、GRU或SVM模型。因此它在时间序列预测方面表现出尚未发现的潜力。

(2) 扎尼河露天矿在隔水帷幕修建之后,矿井涌水量变化剧烈,预测难度较大,传统的机器学习时间序列预测方法不能好的预测到变化的测试集数据。本研究提出了多模型的预测框架,通过CEEMDAN结合了擅长趋势预测的Self-Attention和多种机器学习模型,解决了单一模型精确度低的问题。与单一模型相比,本文提出的多模型预测框架的平均绝对误差(MAE)提高了26.12%,均方根误差(RMSE)提高了33.47%。

(3) 将本文提出的多模型预测框架与Self-Attention预测模型用于矿区的地下水位预测中,结果达到了预期的效果。本文提出的预测框架在评估指标上优于单一模型以及LSTM-GRU、TCN-GRU和CNN-MLP-LSTM的多模型预测方法。从地下水位数据预测的结果可以看出,本文所提出的模型,在时间序列预测问题上有一定的通用性。初步尝试在地下水位的突变数据预测上效果达到预期,有利于其他场景与时间序列数据的可能。

(4) 本文分析了Self-Attention模型的结构,将它的结构与传统的循环神经网络结构进行对比,为读者解释了为何Self-Attention的结构能够解决梯度消失的问题,为读者

在未来时间序列预测问题上选择模型提供了参考。没有完美的模型，Self-Attention的结构在顾及到整体的注意力权重时，对于细节变化的预测不如传统模型。

综上所述，本文提出了一种多模型的预测框架，以及一个基于Self-Attention的时间序列预测模型，并且在研究区进行了实验验证。Self-Attention模型在趋势突变数据的预测效果上好于传统模型，多模型的预测框架能够融合多种模型的优势。

7.2 创新点

(1) 提出了基于Self-Attention的矿井涌水量预测模型，该模型在趋势分量预测方面有较好的表现。

(2) 提出了基于CEEMDAN的多模型预测框架，该框架能够融合多个模型的优势。

7.3 不足及展望

(1) 尽管Self-Attention在捕捉低频趋势方面表现良好，但对于高频分量的预测效果仍有待提高。Self-Attention的模型结构能够考虑到更远的历史数据，但是对细节的捕捉还需要进一步的优化。

(2) 越来越多的深度学习模型被投入使用，许多模型的精度得到了提高，但模型的可解释性还需要完善。可解释性使研究人员能够深入了解模型是如何做出预测或决策的。这对于验证模型是否符合领域知识、发现模型的局限性以及优化模型都非常重要。在一些应用场景中，特别是需要向非专业人士解释模型结果的情况下，模型的可解释性可以帮助用户更好地理解模型的输出，从而更好地应用模型的结果。

(3) 输入数据的维度还有待提高。矿井涌水量受到多种因素的影响，包括地质、水文、气象等多方面因素。通过增加数据维度，可以收集更多关于这些影响因素的信息，使预测模型能够更全面地捕捉到涌水量的变化规律。增加数据维度可以提供更多的信息，有助于模型更好地解释数据的变化和预测结果。这样的可解释性对于矿井涌水量预测来说非常重要，可以帮助相关人员更好地理解预测结果，并做出相应的应对措施。并且增加数据维度可以提供更多的特征信息，有助于模型更好地理解数据的特征和模式。这样的特征提取可以使模型更有效地学习到数据的规律，从而提高了模型的泛化能力和预测性能。

(4) 参数优化方法与模型的结合。参数优化方法可以帮助模型找到最优的参数组合，从而提高模型的性能和效果。通过不断调整模型的参数，可以使模型更好地拟合数据，提高预测准确性和泛化能力。并且，通过合适的参数优化方法，可以避免模型过度拟合训练数据，提高模型的泛化能力，从而减少过拟合的风险。合适的参数优化方法可

以增强模型的鲁棒性，使模型对数据中的噪声和干扰具有更好的容忍性。通过调整参数，可以使模型更加稳健，从而提高模型在实际应用中的可靠性。

参考文献

- 毕银丽,武超,彭苏萍,田乐焯,张延旭.2024.西部煤矿区微生物修复促进植物水分高效利用策略[J].煤炭学报,49(02):1003-1010.
- 卞正富,雷少刚,王楠.2023.生态文明背景下的矿山生态修复模式[J].中国土地,(11):4-8.
- 曹瑜,严鹏飞,胡振琪,袁冬竹,孙杨杨.2019.赵固二矿采煤塌陷土地复垦适宜性评价[J].中国煤炭,45(02):122-129.
- 陈酩知,刘树才,杨国勇.2009.矿井涌水量预测方法的发展[J].工程地球物理学报,6(01):68-72.
- 戴柳珍,向刚,丁正芬,李阳.2020.基于模糊数学法在矿井水处理效果评价——以瓮福磷矿区为例[J].资源节约与环保,(10):115-117.
- 戴振学.1993.地表水—地下水联合模拟模型[J].勘察科学技术,(03):33-36.
- 翟俊杰.2023.东欢坨矿北二采区12煤底板涌水数值模拟研究[D].华北理工大学.
- 董书宁,樊敏,郭小铭,刘英锋,郭康,姬中奎,李超峰,薛小渊.2024.陕西省煤矿典型水灾隐患特征及治理技术[J].煤炭学报,49(02):902-916.
- 樊发旺,郭爱江,芦震,王鹏.2024.基于生产因素相关性分析的矿井涌水量预测[J].陕西煤炭,43(02):82-85.
- 顾大钊,颜永国,张勇,王恩志,曹志国.2016.煤矿地下水库煤柱动力响应与稳定性分析[J].煤炭学报,41(07):1589-1597.
- 景婷婷.2023.矿井涌水量动态预测研究及对比分析[J].山西化工,43(03):154-156.
- 李天宇,李维康,王敏.2017.基于灰色理论模型对焦家金矿带新城矿区矿井涌水量预测研究[J].地下水,39(04):9-12.
- 李孝朋,谢道雷,徐万鹏,张延飞,张宪峰,吴霞.2016.多元回归分析在矿井涌水量预测中的应用[J].煤炭技术,35(10):189-190.
- 刘琼.2023.比拟法和解析法在矿坑涌水量预测中的应用[J].中国资源综合利用,41(05):45-47.
- 刘述友,胡雪峰,杨智淇.2023.数值法与比拟法在矿坑涌水量预测中的应用[J].地下水,45(02):43-45.
- 刘云艳.2023.白音华四号矿厚煤层大采高分层开采矿井涌水规律研究[D].辽宁工程技术大学.
- 罗庆.2021.基于MODFLOW的矿井涌水量预测[D].安徽理工大学.
- 孟俊,杨海燕,张治国.2009.基于模糊数学法的矿井水质评价[C].中国煤炭学会矿井地质专业委员会2009年学术论坛,4.
- 牛肖铮,吕力行,林吉飞,李基隆.2013.基于模糊数学法的矿井通风系统评价方法研究[J].矿冶,22(02):19-23.
- 彭苏萍,毕银丽.2023.钱鸣高院士指导西部干旱半干旱煤矿区生态修复研究[J].采矿与安全工程学报,40(05):857-860.
- 孙刚友,胡清珍,康钦容,夏缘帝,袁威,张卫中.2023.基于大井法和地下水模型系统数值模拟方法的某矿坑涌水量预测对比分析[J].科学技术与工程,23(21):9024-9031.
- 王广才,李竟生,黄国刚,陈遂斋,刘贵平.2002.平顶山矿区十三矿地温场数值模拟研究[J].工程勘察,(01):18-21.
- 王玉合.2022.甘肃靖远煤电股份有限公司红会第一煤矿矿井涌水量计算与分析[J].甘肃科技,38(20):10-13.
- 武强,张守成,刘宏磊,曾一凡.2024.矿山环境正效应开发利用适宜性评价理论与方法[J].煤炭学报,49(01):114-130.
- 徐龙,葛晓光.1995.水文地质比拟法的系统处理模型[J].煤炭学报,(04):346-350.
- 叶永芳,陈娟.2015.基于灰色理论的矿井涌水量预测[J].江西煤炭科技,(01):109-111.
- 尹尚先,徐斌,尹慧超,曹敏,丁莹莹,梁满玉.2023.矿井水防治学科基本架构及内涵[J].煤炭科学技术,51(07):24-35.
- 张博成,孙常民.2023.水文地质极复杂型矿井盘区涌水量预测[J].中国煤炭,49(S2):107-112.

- 张萌,贾文凯,田凯.2020.大井法和灰色理论在矿井涌水量预测中的综合应用[J].内蒙古煤炭经济,(13):143-144.
- 张许良,张子戌,彭苏萍.2003.数量化理论在矿井突(涌)水水源判别中的应用[J].中国矿业大学学报,(03):42-45.
- 张子祥,李文鑫.2022.矿井涌水量预测方法的比较研究——以甘肃大庄煤矿为例[J].西北地质,55(03):355-360.
- Agatonovic-Kustrin S, Beresford R. 2000. Basic concepts of artificial neural network (ANN) modeling and its application in pharmaceutical research[J]. Journal Of Pharmaceutical And Biomedical Analysis, 22(5): 717-727.
- Agrawal P, Bansal H O, Gautam A R, Mahela O P, Khan B. 2022. Transformer-based time series prediction of the maximum power point for solar photovoltaic cells[J]. Energy Science & Engineering, 10(9): 3397-3410.
- Breiman L. 2001. Random forests[J]. Machine Learning, 45(1): 5-32.
- Che Nordin N F, Mohd N S, Koting S, Ismail Z, Sherif M, El-Shafie A. 2021. Groundwater quality forecasting modelling using artificial intelligence: A review[J]. Groundwater For Sustainable Development, 14: 100643.
- Cui W Z, Zhu C C, Bao W X, Liu J H. 2005a. Chaotic time series prediction using mean-field theory for support vector machine[J]. Chinese Physics, 14(5): 922-929.
- Cui W Z, Zhu C C, Bao W X, Liu J H. 2005b. Prediction of the chaotic time series using support vector machines for fuzzy rule-based modeling[J]. Acta Physica Sinica, 54(7): 3009-3018.
- de Vitry M M, Kramer S, Wegner J D, Leitao J P. 2019. Scalable flood level trend monitoring with surveillance cameras using a deep convolutional neural network[J]. Hydrology And Earth System Sciences, 23(11): 4621-4634.
- Fang B. 2022. Method for Quickly Identifying Mine Water Inrush Using Convolutional Neural Network in Coal Mine Safety Mining[J]. Wireless Personal Communications, 127(2): 945-962.
- Fara L, Diaconu A, Craciunescu D, Fara S. 2021. Forecasting of Energy Production for Photovoltaic Systems Based on ARIMA and ANN Advanced Models[J]. International Journal Of Photoenergy, 2021.
- Granata F, Gargano R, de Marinis G. 2016. Support Vector Regression for Rainfall-Runoff Modeling in Urban Drainage: A Comparison with the EPA's Storm Water Management Model[J]. Water, 8(3).
- Guo L, Chehata N, Mallet C, Boukir S. 2011. Relevance of airborne lidar and multispectral image data for urban scene classification using Random Forests[J]. Isprs Journal Of Photogrammetry And Remote Sensing, 66(1): 56-66.
- Haskins G, Kruger U, Yan P K. 2020. Deep learning in medical image registration: a survey[J]. Machine Vision And Applications, 31(1).
- Heaton J B, Polson N G, Witte J H. 2017. Deep learning for finance: deep portfolios[J]. Applied Stochastic Models In Business And Industry, 33(1): 3-12.
- Hochreiter S, Schmidhuber J. 1997. Long Short-Term Memory[J]. Neural Computation, 9(8): 1735-1780.
- Hornik K, Stinchcombe M, White H. 1989. Multilayer Feedforward Networks Are Universal Approximators[J]. Neural Networks, 2(5): 359-366.
- Huang L, Li J, Hao H, Li X. 2018. Micro-seismic event detection and location in underground mines by using Convolutional Neural Networks (CNN) and deep learning[J]. Tunnelling And Underground Space Technology, 81: 265-276.
- Jajarmizadeh M, Lafdani E K, Harun S, Ahmadi A. 2015. Application of SVM and SWAT models for monthly streamflow prediction, a case study in South of Iran[J]. Ksce Journal Of Civil Engineering, 19(1): 345-357.
- Kratzert F, Klotz D, Brenner C, Schulz K, Herrnegger M. 2018. Rainfall-runoff modelling using Long Short-Term Memory (LSTM) networks[J]. Hydrology And Earth System Sciences, 22(11): 6005-6022.

- Kumar D, Singh A, Samui P, Jha R K. 2019. Forecasting monthly precipitation using sequential modelling[J]. *Hydrological Sciences Journal*, 64(6): 690-700.
- Li B, Yang G, Wan R, Dai X, Zhang Y. 2016. Comparison of random forests and other statistical methods for the prediction of lake water level: a case study of the Poyang Lake in China[J]. *Hydrology Research*, 47: 69-83.
- Ma L, Liu Y, Zhang X, Ye Y, Yin G, Johnson B A. 2019. Deep learning in remote sensing applications: A meta-analysis and review[J]. *Isprs Journal Of Photogrammetry And Remote Sensing*, 152: 166-177.
- Marcais J, de Dreuzy J. 2017. Prospective Interest of Deep Learning for Hydrological Inference[J]. *Groundwater*, 55(5): 688-692.
- Mosavi A, Ozturk P, Chau K. 2018. Flood Prediction Using Machine Learning Models: Literature Review[J]. *Water*, 10(11).
- Ortiz-García E G, Salcedo-Sanz S, Casanova-Mateo C. 2014. Accurate precipitation prediction with support vector classifiers: A study including novel predictive variables and observational data[J]. *Atmospheric Research*, 139: 128-136.
- Qin J B, Liang J, Chen T, Lei X H, Kang A Q. 2019. Simulating and Predicting of Hydrological Time Series Based on TensorFlow Deep Learning[J]. *Polish Journal Of Environmental Studies*, 28(2): 795-802.
- Rakhshandehroo G R, Vaghefi M, Aghbolaghi M A. 2012. Forecasting Groundwater Level in Shiraz Plain Using Artificial Neural Networks[J]. *Arabian Journal For Science And Engineering*, 37(7): 1871-1883.
- Sahiner B, Pezeshk A, Hadjiiski L M, Wang X, Drukker K, Cha K H, Summers R M, Giger M L. 2019. Deep learning in medical imaging and radiation therapy[J]. *Medical Physics*, 46(1): e1-e36.
- Thiessen U, van Brakel R, de Weijer A P, Melssen W J, Buydens L. 2003. Using support vector machines for time series prediction[J]. *Chemometrics And Intelligent Laboratory Systems*, 69(1-2): 35-49.
- Vapnik V N. 1963. Pattern recognition using generalized portrait method[J]. *Automation And Remote Control*, 24(6): 774-780.
- Wang X H, Liu T L, Zheng X L, Peng H, Xin J, Zhang B. 2018. Short-term prediction of groundwater level using improved random forest regression with a combination of random features[J]. *Applied Water Science*, 8(5).
- Xiang Z, Demir I. 2020. Distributed long-term hourly streamflow predictions using deep learning - A case study for State of Iowa[J]. *Environmental Modelling & Software*, 131.
- Yang S, Lian H, Xu B, Thanh H V, Chen W, Yin H, Dai Z. 2023. Application of robust deep learning models to predict mine water inflow: Implication for groundwater environment management[J]. *Science Of The Total Environment*, 871: 162056.
- Ye M Y, Wang X D. 2004. Chaotic time series prediction using least squares support vector machines[J]. *Chinese Physics*, 13(4): 454-458.
- Yin H, Zhang G, Wu Q, Yin S, Soltanian M R, Thanh H V, Dai Z. 2023. A Deep Learning-Based Data-Driven Approach for Predicting Mining Water Inrush From Coal Seam Floor Using Microseismic Monitoring Data[J]. *Ieee Transactions On Geoscience And Remote Sensing*, 61.
- Zhang G P, Berardi V L. 2001. Time series forecasting with neural network ensembles: an application for exchange rate prediction[J]. *Journal Of The Operational Research Society*, 52(6): 652-664.
- Zhou, Chellappa. 1988. Computation of optical flow using a neural network[C]: *IEEE 1988 International Conference On Neural Networks*, 71-78.
- Zuo G G, Luo J G, Wang N, Lian Y N, He X X. 2020. Decomposition ensemble model based on variational mode decomposition and long short-term memory for streamflow forecasting[J]. *Journal Of Hydrology*, 585.