

基于深度置信网络的矿井涌水量预测研究^{*}

降海荣, 赵宝峰, 康艳旗, 王劲文

(太原理工大学 矿业工程学院, 山西 太原 030024)

摘要:在矿井开采过程中,准确预测矿井涌水量对于矿井防治水及高效、安全生产具有重要意义。针对矿井涌水量影响因素复杂导致预测精度不高的问题,提出一种基于深度置信网络(DBN)间接预测矿井涌水量的方法。针对不同的盘区建立相应的DBN涌水量预测模型,对矿井各个盘区水仓提取涌水量数据,之后分别导入DBN预测模型进行预测,得到各个盘区的涌水量,进而得出矿井总体涌水量,同时将结果分别与BP、ELM神经网络以及DBN直接预测矿井涌水所得到的预测结果进行对比。试验结果表明,DBN间接预测的预测精度最高,其平均绝对百分误差仅有5.85%,运行时长也大幅缩短,说明DBN间接预测矿井涌水量模型具有更好的预测效果。研究结果为矿井涌水量的准确预测提供了一种新的方法。

关键词:矿井涌水量;DBN;预测;深度学习;BP神经网络

中图分类号:TD744 **文献标识码:**A

文章编号:1005-2763(2023)02-0143-06

0 引言

随着我国矿井开采强度、深度以及规模的日益增大,矿井排水在矿井的安全生产过程中占有越来越突出的地位,如果处理不当,极易发生淹巷淹井事故,对人员和矿井造成严重后果^[1]。因此,涌水量的准确预测对于矿井能否实现安全生产至关重要,同时也能够根据预测的涌水量对排水控制进行提前规划,实现峰值转移,从而降低排水系统运行成本^[2]。

在矿井的开采过程中,形成了多种涌水量预测的方法,齐晓峰等^[3]使用适用于处理非平稳信号的EMD算法与ARMA结合建立了涌水预测模型,得到较为理想的预测效果。李建林等^[4]建立了中长期混沌矿井涌水量预测模型,首先对矿井涌水量使用混沌理论进行特征识别,之后建立预测模型,预测出接下来6个月每月的涌水量。高瑞忠等^[5]通过钻孔和物探断面勘测等数据,构建矿区井田三维地质模型,使

用集水廊道法和大井法实现涌水量的静态预测,使用数值模拟法描述矿区地下水在开采过程中的运动规律。王春刚等^[6]分别采用多种方法对涌水量进行预测,经过最终的对比分析,对于基建阶段使用廊道法进行涌水量预测,对于矿井生产阶段使用大井法和数值法,对于工作面使用动静结合法,实现对该矿井不同阶段的涌水量预测。李占利等^[7]提出一种GEEMD与GRU相结合的矿井涌水量预测模型,首先通过GEEMD对原始数据进行分解,使各个分量包含不同的特征,再使用适合处理时序数据的GRU进行处理,结果表明,该模型能够提高涌水预测模型的精度和适用性,取得了较好的预测效果。上述方法对于矿井涌水量的预测研究起到了积极的作用,但是仍存在一定的局限性:EMD模型存在端点效应,会影响预测精度;混沌理论对初值的选择具有敏感依赖性,对初始条件要求较高;构建矿区井田三维地质模型以及多种方法结合进行预测,适用性较差,往往只能针对某一矿井;而GRU层节点个数的选择由于目前没有具体的计算标准,导致模型优化较为困难。

随着近年来深度学习的飞速发展,越来越多的学者使用深度学习算法并结合自身行业内容进行预测研究,深度置信网络(DBN)作为其中具有代表性的一种算法,具有强大的自组织学习能力,可以通过模拟人脑神经元来实现对复杂非线性问题的处理,在大量数据分析以及多特征提取方面存在优势。DBN目前已经成功应用于多个行业^[8],Ahmed S S等^[9]基于DBN构建了一套股票价格预测模型,取得了良好的效果。雷蕾等^[10]基于DBN实现了对变风量空调送风量的有效预测。马婉贞等^[11]将DBN应用于风速预测以提高天气预报的准确度,获得了较高的预测精度。D S de O Santos Jr等^[12]应用DBN实现了太阳辐照度的预测。冯兆熙等^[13]使用

^{*} 收稿日期:2022-05-06

基金项目:国家自然科学基金面上项目(61572347)。

作者简介:降海荣(1996—),男,山西忻州人,硕士研究生,主要从事煤矿机电及智能化方面的研究,E-mail:jhrong12@163.com。

通信作者:赵宝峰(1977—),男,山西大同人,博士,副教授,研究方向为煤矿机电和煤矿通信技术,E-mail:zhaobaofeng@tyut.edu.cn。

DBN 构建了滚动轴承剩余使用寿命的预测模型, 试验验证表明, 相较于其他两种深度学习算法, DBN 能够大幅降低预测误差, 准确性更高。袁桂丽等^[14]通过使用 DBN 实现了短期风电功率预测, 并使用云南某风电场的实际数据进行验证, 结果表明该方法具有较高的预测精度。

本文将 DBN 应用于矿井涌水量预测, 充分利用 DBN 的优势对涌水量数据中隐含的各类影响因素进行特征提取, 提高预测精度。对于地质条件、开采状况等影响因素, DBN 可根据涌水数据对隐含层节点数、节点之间的权值以及偏置等参数进行更新优化, 实现对不同影响因素的特征提取, 从而使得隐含层中的各个节点包含不同的影响因素。而不同盘区之间的水文地质条件、开采程度等涌水量影响因素都会有差异, 为了减小特征提取的难度, 本文提出一种基于 DBN 间接预测矿井涌水量的方法, 首先分别对矿井的各盘区建立相应的 DBN 预测模型进行涌水量预测, 进而根据各盘区的涌水量得到矿井总体的涌水量。

1 DBN 预测模型

DBN 由 Hilton 于 2006 年提出, 其结构由多个受限玻尔兹曼机(RBM)和一个 BP 神经网络构成。

1.1 受限玻尔兹曼机

RBM 包括两层结构, 如图 1 所示, 分别为可见层(visible layer)和隐含层(hidden layer), 是一个二分图, 层间存在全连接, 层内不存在连接。




图 1 RBM 运行原理

由图 1 可知, 可见层的神经元个数用 m 来表示, 隐含层的神经元个数用 n 来表示, 两层间的权值用 W 表示, 可见层的神经元偏置用 a 来表示, 隐含层的神经元偏置用 b 来表示。能量函数表示为:

$$E(v, h) = - \sum_{i=1}^m v_i a_i - \sum_{j=1}^n h_j b_j - \sum_{i=1}^m \sum_{j=1}^n w_{ij} v_i h_j \quad (1)$$

式中, v 为可见层的状态向量; h 为隐含层的状态向量; i 表示第 i 个可见层; v_i 表示其状态; a_i 表示其偏置; j 表示第 j 个隐含层; h_j 表示其状态; b_j 表示其偏置; w_{ij} 为两层之间的连接权值。

第一个 RBM 的可见层输入涌水量数据, 可见层的输出为隐含层的输入, 之后隐含层作为下一层 RBM 的可见层进行输入, 完成 RBM 的堆叠。能量函数代表着 RBM 的稳定状态, 通过对 RBM 进行训练, 调整其内部的参数使能量函数逐步趋于稳定, 最终使 RBM 达到最稳定的状态。

可见层和隐含层的联合概率分布定义为:

$$p(v, h) = \frac{1}{Z} \exp(E(v, h)) \quad (2)$$

其中, Z 为归一化因子, 其定义为:

$$Z = \sum_v \sum_h \exp(-E(v, h)) \quad (3)$$

RBM 由于层间全连接, 而层内无连接, 因此当数据输入到可见层时, 可见层会决定隐含层各神经元的状态, 并且此时隐含层各神经元的激活状态条件独立, 则隐含层中某个单元的概率为:

$$p(h_j = 1 | v) = \sigma \left(\sum_{i=1}^n v_i w_{ij} + b_j \right) \quad (4)$$

式中, σ 为激活函数, 表示 sigmoid 函数。

相同的, 隐含层状态完全确定时, 可见层神经元的激活状态也条件独立, 其公式为:

$$p(v_j = 1 | h) = \sigma \left(\sum_{i=1}^m h_i w_{ij} + a_i \right) \quad (5)$$

1.2 深度置信网络原理

DBN 通过先使用多个 RBM 进行堆叠训练, 获得较好的初始参数值后, 再传输给 BP 神经网络, 从而有效避免了预测结果陷入局部极小值的情况, 大幅度提高预测精度。经典 DBN 的结构如图 2 所示, 为图示方便, 图中画出两层 RBM, 实际应用当中可根据需要进行增减, 该模型训练过程分为两步:




图 2 DBN 运行流程

(1) 首先对各层 RBM 进行无监督的单独训练,使自身层内的参数最优,确保能够保留尽可能多的特征信息;

(2) 各层 RBM 训练好之后,最后一层 RBM 将特征向量传输给 BP 神经网络,BP 神经网络对输入的数据进行有监督的训练,获取误差后反向传输给各层进行参数的更新,实现 DBN 各层的参数优化。

第一步相当于找到模型最优解的区域,搭建出主体的模型结构,而第二步微调的目的是在最优解区域中进一步筛选出最优解^[15]。

2 DBN 涌水预测模型及验证

2.1 DBN 涌水量预测模型

图 3 所示为 DBN 涌水量预测模型流程。首先通过传感器采集数据,之后将采集的数据进行预处理,剔除掉其中的异常数据后进行归一化,而后将数据集划分成样本数据和验证数据,样本数据用来进行模型训练,之后通过验证数据不断地对隐含层节点、权值以及偏置等参数进行更新,训练出满足精度要求的 DBN 预测模型。再使用训练好的 DBN 模型对涌水量进行预测,得到涌水量预测值。其中隐含层节点可根据式(6)进行选择:

$$N = \sqrt{m+n} + a \quad (6)$$

式中, m 为输入节点数目; n 为输出节点数目; a 为 0 到 10 之间的数。

经过多次对比试验结果,本预测模型层数选择为两层隐含层时结果最优,3 个盘区的两个隐含层节点数分别为 32、16、28、8、30、12。




图 3 基于 DBN 的涌水量预测模型

2.2 数据来源

本文选用某煤矿在 2021 年 1 月中旬到 2 月中

旬的涌水量数据进行训练,该矿包含 3 个盘区,分别对 3 个盘区水仓以及中央水仓每小时记录一次涌水量数据,并对 2021 年 2 月 16 日的数据每小时进行一次记录,作为实测数据。获取数据之后,首先分别对各盘区的涌水量数据进行预处理,剔除掉其中的异常数据之后,每组分别得到 720 个训练样本,依次输入到 DBN 预测模型中对 2 月 16 日的涌水量进行预测,并与实测值进行比较。

2.3 DBN 和 BP、ELM 神经网络对比

将各盘区涌水量数据分别导入 BP 以及 ELM 神经网络进行预测,以验证 DBN 模型对各盘区涌水量预测的效果是否更好。BP 和 ELM 预测模型精度较高,与 DBN 优化运行时长近似,是具有足够可比性且应用较多的预测模型。

将一盘区的涌水量数据分别导入到 BP、ELM 和 DBN 预测模型中进行预测,将预测值与实测数据进行比较,如图 4 所示。由图 4 可以看出,DBN 预测模型对一盘区的涌水预测效果较好。




图 4 BP、ELM 和 DBN 对一盘区涌水预测效果对比

同样的,将二盘区的涌水量数据分别导入到BP、ELM和DBN预测模型中进行预测,并与实测数据进行比较,如图5所示。由图5可以看出,DBN预测模型的预测效果更佳。




图5 BP、ELM和DBN对二盘区涌水预测效果对比

最后,将三盘区的涌水量数据分别导入各预测模型并与实测数据进行比较,如图6所示。由图6可以看出,DBN预测模型的预测效果最好。

为了更直观地体现评估效果,采用根均方差(RMSE)、平均绝对误差(MAE)、平均绝对百分误差(MAPE)来进一步评估3种预测模型的预测效果。

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (t - p)^2} \quad (7)$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |t - p| \quad (8)$$

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{t - p}{t} \right| \quad (9)$$

式中, t 为实测值, p 为预测值, n 为24。




图6 BP、ELM和DBN对三盘区涌水预测效果对比

$RMSE$ 是精确度的度量,用来比较特定数据集在不同模型下的预测误差,值越低代表预测效果越好。 MAE 表示预测值与实测值之间距离的平均值,值越大表示误差越大。 $MAPE$ 是衡量预测准确性的统计指标,值越小预测效果越好。表1为各盘区3种预测模型的 $RMSE$ 值、 MAE 值和 $MAPE$ 值,由表1可更直观地看出,DBN预测模型较BP和ELM神经网络预测效果更好。

表1 各盘区3种预测模型的预测效果

盘区	预测模型	$RMSE$	MAE	$MAPE/\%$
一盘区	BP	28.22	24.36	14.10
一盘区	ELM	24.24	16.37	9.74
一盘区	DBN	13.17	10.81	6.56
二盘区	BP	12.87	10.61	17.98
二盘区	ELM	8.29	6.20	10.53
二盘区	DBN	4.46	3.88	6.72
三盘区	BP	5.99	5.18	14.07
三盘区	ELM	4.79	3.57	9.45
三盘区	DBN	2.94	2.39	6.21

2.4 DBN 间接预测和直接预测对比

该矿中央水仓的来水即为 3 个盘区水仓的排水,因此,将 3 个盘区水仓的涌水量相加也就是矿井的总涌水量。然而不同盘区的地质条件以及开采程度等影响因素都不相同,如果直接使用总体涌水量数据进行预测,由于其包含各个盘区涌水量的影响因素,会导致差异性较大,特征提取的难度增加,因此直接使用算法预测矿井总体的涌水量仍会存在较高的误差^[16]。而要想实现相同或者相近的精度效果,就需要更多的隐含层以及节点数,但是隐含层选择过多,不仅计算时间增长,还容易出现“过拟合”现象。

相较于直接预测矿井总体涌水量,间接预测相当于对隐含各盘区不同地质条件等特征的涌水量数据进行了提前划分,实现化繁为简,能够有效降低预测模型的复杂程度,提高预测精度的同时大幅节省计算时间。为对比预测效果,本文再次使用 DBN 对总涌水量进行直接预测,直接预测模型包含 3 层隐含层,节点数分别为 30, 13, 9。直接预测和间接预测对比结果见图 7 和表 2。




图 7 DBN 直接预测和间接预测效果对比

表 2 DBN 两种预测方法对比

预测方法	RMSE	MAE	MAPE/%	运行时长/s
直接预测	35.37	31.58	12.52	1.41
间接预测	17.53	15.00	5.85	0.45

由图 7 和表 2 可以看出,间接预测较直接预测精度有大幅度的提升,其平均绝对百分误差仅 5.85%,运行时长也大幅缩短,说明使用 DBN 进行涌水量间接预测的方法能够较好地实现矿井涌水量的预测。

3 结论

(1) 提出一种基于 DBN 实现间接预测矿井涌水量的方法,通过对矿井的各盘区分别建立相应的 DBN 涌水预测模型,获取各盘区的涌水量,从而得到矿井总体涌水量。

(2) 使用某煤矿在 2021 年 1 月中旬到 2 月中旬的涌水量数据对模型进行训练,分别对 3 个盘区的涌水量数据进行归一化、DBN 预测模型层数选择、节点数选择等一系列处理,对各盘区构建出相应的最优 DBN 涌水预测模型,最终得到 3 个盘区的预测值。

(3) 通过与 BP 及 ELM 神经网络进行对比后得出,DBN 预测模型在各盘区的涌水预测中精度更高。相较于使用 DBN 直接预测矿井总体涌水量,DBN 间接预测具有更高的精度,更加适用于矿井总体涌水量的预测。

参考文献(References):

- [1] 曾一凡,梅傲霜,武强,等.基于水化学场机器学习分析与水动力场反向示踪模拟耦合的矿井涌(突)水水源综合判识技术[J].煤炭学报,2022(3):1-14.
- [2] 韩秀琪.矿井多水平接力排水系统优化控制[J].工矿自动化,2020,46(9):109-112.
- [3] 齐晓峰,邵良杉,邢雨艳.基于 EMD 的矿井涌水量 ARMA 预测模型[J].辽宁工程技术大学学报(自然科学版),2020,39(6):509-513.
- [4] 李建林,常晓峰,王燕.矿井涌水量的中长期混沌预测[J].河南理工大学学报(自然科学版),2017,36(5):23-28.
- [5] 高瑞忠,姬腾达,于婵,等.基于钻探—物探数据融合的矿井涌水量预测及效果评估[J].煤矿安全,2021,52(8):66-74.
- [6] 王春刚,方刚,刘洋.榆横北区巴拉素井田不同时期矿井涌水量预测[J].煤矿安全,2020,51(6):212-217+222.
- [7] 李占利,邢金莎,靳红梅,等.基于 CEEMD-GRU 模型的矿井涌水量预测[J].北京工业大学学报,2021,47(8):904-911.
- [8] 刘方园,王水花,张煜东.深度置信网络模型及应用研究综述[J].计算机工程与应用,2018,54(1):11-18+47.
- [9] AHMED S S, KANKAR M, NAIK N, et al. Hybrid ARIMA-deep belief network model using PSO for stock price prediction [J]. International Journal of Swarm Intelligence,2022,7(1):66-81.
- [10] 雷蕾,王宁,郑皓,等.基于深度置信神经网络的变风量空调送风量的预测[J].流体机械,2021,49(3):85-90.
- [11] 马婉贞,钱育蓉,范迎迎.基于 WRF 数值模式的 DBN 风速预测模型研究[J].计算机仿真,2018,35(3):332-336.

- [12] D S de O. Santos Jr, P S G de Mattos Neto, J F L de Oliveira, et al. Solar Irradiance Forecasting Using Dynamic Ensemble Selection[J]. Applied Sciences, 2022, 12(7): 3510.
- [13] 冯兆熙, 邱度金, 孔令驹, 等. 基于深度置信网络的轴承剩余使用寿命预测[J]. 电子测量与仪器学报, 2021, 35(10): 124-129.
- [14] 袁桂丽, 吴振民, 刘骅骐, 等. 基于深度置信网络的短期风电功率预测[J]. 太阳能学报, 2022, 43(2): 451-457.
- [15] 张雨. 基于深度学习的井下瓦斯浓度预测系统设计与实现[D]. 徐州: 中国矿业大学, 2019.
- [16] 王晓蕾. 煤矿开采矿井涌水量预测方法现状及发展趋势[J]. 科学技术与工程, 2020, 20(30): 12255-12267.

Prediction of Mine Water Inflow Based on Deep Belief Network

JIANG Hairong, ZHAO Baofeng, KANG Yanqi, WANG Shaowen

(College of Mining Engineering, Taiyuan University of Technology, Taiyuan, Shanxi 030024, China)

Abstract: In the process of mine mining, accurate prediction of mine water inflow is of great significance for mine water control, as well as efficient and safe production. Aiming at the problem of low prediction accuracy caused by complex influencing factors of mine water inflow, a method of indirect prediction of mine water inflow based on deep belief network (DBN) was proposed. The corresponding DBN water inflow prediction model was established for different panels, and the water inflow data was extracted from the water storage of each panel of the mine. Then, the DBN prediction model was introduced to predict the water inflow of each panel, and the total water inflow of the mine was obtained. At the same time, the results were compared with the prediction results obtained by BP, ELM neural network and DBN direct prediction of mine water inflow. The test results show that the prediction accuracy of DBN indirect prediction is the highest, the average absolute percentage error is only 5.85%, and the running time is also greatly shortened, indicating that the DBN indirect prediction model of mine water inflow has a better prediction effect. The research results can provide a new method for the accurate prediction of mine water inflow.

Key words: Mine water inflow, DBN, Prediction, Deep learning, BP neural network