



胡友彪(1963—),男,江苏泰州人,教授,博士生导师;1984 年本科、1990 年硕士研究生毕业于中国矿业大学水文地质工程地质专业,在太原理工大学、安徽理工大学从事水资源评价与开发管理、矿井水害防治、矿山生态环境评价与恢复治理、环境地质等领域教学、科研工作 30 余年。曾担任安徽理工大学地球与环境学院院长、校科技部副部长兼学术出版中心主任等职,学术兼职有:中国地质学会理事,中国煤炭工业技术委员会防治水专家委员会委员,中国煤炭学会土地复垦与生态修复专业委员会委员,中国地质教育研究会委员,矿业高校环境学科教材编审委员会副主任,安徽省地质学会常务理事,安徽省矿井水害防治专业委员会副秘书长,安徽省环境科学学会理事,淮南市环境科学学会理事长等,现为安徽理工大学矿井水害综合防治煤炭行业工程研究中心主任。发表论文 40 余篇,出版著作(教材)5 部,主持国家重点研发项目课题、国家自然科学基金项目、安徽省自然科学基金项目及企业委托项目多项,获省部级科技成果一等奖 2 项、二等奖 2 项、三等奖 2 项,优秀论文奖 2 项。

文章编号:1008-3731(2022)04-0052-09

基于粒子群优化随机森林的煤矿涌(突)水 水源机器学习识别技术

胡友彪^{1,2}, 琚棋定¹

(1. 安徽理工大学 地球与环境学院,安徽 淮南 232001; 2. 矿井水害综合防治煤炭行业工程研究中心,安徽 淮南 232001)

摘 要: 随着华北型煤田不断向深部开采,突水水源的威胁日益严重,涌(突)水事故不时发生。从宿南矿区的 3 种含水层中提取了 120 个水样,基于 6 个地下水常规离子数据,划分了 100 个训练集和 20 个测试集,采用粒子群算法对随机森林的参数进行优化,并结合随机森林建立了水源判别模型。研究表明,单一随机森林的测试集综合准确率为 85%,粒子群优化的随机森林模型(PSO-RF)测试集水源判别综合精确度为 95%。PSO-RF 判别模型远高于传统的单一 RF 模型。因此,提出 PSO-RF 水源判别模型以提高识别精度有助于矿井水害精准预防与控制。

关键词: 煤矿水害; 随机森林; 粒子群优化算法; 机器学习; 宿南矿区

中图分类号: TD742

文献标志码: A

Machine learning recognition technology of coal mine water inflow (outburst) source
based on particle swarm optimization random forest

HU You-biao^{1,2}, JU Qi-ding¹

(1. School of Earth and Environment, Anhui University of Technology, Huainan 232001, China; 2. Coal Industry Engineering Research Center for Comprehensive Prevention and Control of Mine Water Disasters, Huainan 232001, China)

Abstract: With the continuous deep mining of North China type coalfields, the threat of water inrush sources is becoming increasingly serious, and water inrush accidents occur from time to time. 120 water samples were extracted from three aquifers in Sunan mining area. Based on six conventional ion data of groundwater, 100 training sets and 20 test sets were divided. Particle swarm optimization algorithm was used to optimize the parameters of random forest, and a water source discrimination model was established in combination with random forest. The results show that the comprehensive accuracy of the test set of single random forest is 85%, and the comprehensive accuracy of water

收稿日期: 2022-03-10; DOI: 10.19896/j.cnki.mtkj.2022.04.006

作者简介: 胡友彪(1963—),男,江苏泰州人,教授,博士生导师,1984 年本科、1990 年硕士研究生毕业于中国矿业大学水文地质工程地质专业,现从事水资源评价与开发管理、矿井水害防治、矿山生态环境评价与恢复治理、环境地质等领域教学、科研工作。

引用格式: 胡友彪,琚棋定. 基于粒子群优化随机森林的煤矿涌(突)水水源机器学习识别技术[J]. 煤炭科技, 2022, 43(4): 52-60.

HU You-biao, JU Qi-ding. Machine learning recognition technology of coal mine water inflow (outburst) source based on particle swarm optimization random forest[J]. Coal Science & Technology Magazine, 2022, 43(4): 52-60.

source discrimination of the test set of particle swarm optimization random forest model (PSO-RF) is 95%. The PSO-RF discriminant model is much higher than the traditional single RF model. Therefore, the PSO-RF water source discrimination model is proposed to improve the recognition accuracy, which is conducive to the precise prevention and control of mine water disasters.

Keywords: coal mine water disaster; random forest; particle swarm optimization algorithm; machine learning; sunan mining area

CLC number: TD742

Document identification: A

煤炭是全球储量最大的化石燃料,在大多数国家的供电系统中占主导地位,是全球能源的重要组成部分^[1-3]。2017 年全球煤炭消费量相当于 37.5 亿 t 石油,在未来几十年,煤炭仍是一个重要的经济增长推动者和能源来源^[4-5]。随着开采深度的增加,华北型煤田多处煤矿矿深接近 1 000 m,导致涌(突)水灾害发生频率也在增大,对我国煤矿生产安全构成严重威胁,也给煤炭行业造成巨大损失。由于开采深度的不同,受潜在涌(突)水水源影响的类型也不同^[6-8]。因此,在巷道涌水或淋水前,如何准确快速识别突水水源类型,是预防和控制矿井水害发生的关键,也为水资源管理、当地生态系统可持续性和社会经济的发展提供了有价值的决策支持。

很多学者提出了多种识别矿山涌(突)水源的方法,如利用水化学特征、水动力特征、水温、水位动态观测、地质分析和物探结果^[9-11],由于煤矿各含水层具有不同的水化学和物理特征,通过测试含水层的水化学数据可以反映地下水的基本特征,因此基于水化学信息可以准确快速地识别突水水源。目前,确定矿山突水水源的方法主要包括水文地球化学同位素分析和多元统计分析^[12-17]。相关研究表明,随着煤矿开采的发展,深层石灰岩水的主要来源是顶板砂岩地下水的横向补给,并且深层石灰岩地下水的混合比例与地下水的年龄呈正相关,与温度呈负相关,结合铀和温度数据,黄平华教授采用多元素混合质量平衡计算方法建立了煤层底板多层石灰岩混合水源的动态识别模型^[18]。近年来,一些定量和半定量的方法被广泛应用于突水水源识别,通常是与多元统计数据相结合,如灰色相关分析方法、灰色聚类方法、模糊综合评价、人工神经网络识别技术、逐步判别分析和支持向量机等方法,并在相应煤矿水源判别领域取得了显著效果^[19-21]。此外,随着计算机人工智能技术在预测和分类领域的广泛应用,人工智能机器学习水源判别技术逐渐成为趋势,如支持向量机(Support Vector Machine)、卷积神经网络(Convolutional Neural Networks)、随机森林、BP 神经网络和自组织映射神经网络(Self-organizing map)等机器学习算法,克服了在识别过程中人为因

素导致的误差,提高了突水水源判别的精度和效率^[22-24]。然而这些方法在单独进行判别时具有一定的局限性,如同位素混合水源判别成本较高,实际应用中需要考虑经济性等因素;一些线性回归模型具有过拟合导致分类精度低、不适应数据量大的情形;多元统计方法对于不同水源的变量数据差异较小时容易产生误判;一些机器学习的自组织学习能力强,可客观评价结果,但对于训练样本要求高,若机器学习的参数没有得到准确优化,参数变化会导致结果的不稳定性。因而应用机器学习对涌(突)水源进行识别时,应从经济性、数据自身特征、人为因素和机器算法参数优化的角度出发,以找到合适的判别模型。

以宿南矿区为研究区,收集矿区 5 个煤矿的第四系松散含水层、二叠系煤系砂岩含水层和石炭系灰岩含水层的水样数据,应用粒子群优化的随机森林方法建立水源判别模型,并对 20 个涌突水水源样本进行了测试,以验证模型精度。相比传统的随机森林分类方法,使用粒子群优化算法对其参数进行优化,减少了随机森林重复操作选取参数的繁琐步骤,也降低了人为因素的误差,提高了判别效率和精度。

1 研究区概况

宿南矿区位于安徽省北部,在宿州市、淮北市和蚌埠市交界处,海拔 +23.5 ~ +24.5 m,年平均降雨量为 750 ~ 900 mm,最高气温 40.2 °C,最低气温为 -14 °C,年平均气温 14 °C ~ 15 °C;春秋季节多东北风,夏季多东南风,冬季多西北风。矿区内有 5 个煤矿,分别为祁东、祁南、桃园、钱营孜和邹庄煤矿。矿内新生界松散层厚 76.65 ~ 251.30 m,平均厚 216.16 m,其厚度变化受古地形控制,大致自北向南、从东向西逐渐增厚。根据区域水文地质资料与钻探取心、测井资料进行分析对比,按其岩性组合特征,自上而下划分为第四系松散含水层、二叠系煤系砂岩含水层和石炭系灰岩含水层,宿南矿区水样点位置如图 1 所示。




图 1 宿南矿区水样点位置示意

Fig. 1 Location of water sample points
in Sunan mining area

2 研究区地下水形成机制分析

2.1 水化学描述统计

通过对 120 个水样的成分进行描述性统计分析,结果见表 1。

表 1 离子变量描述性统计

Tab. 1 Descriptive statistics of ion variables

类别	参数	$K^+ + Na^+$	Ca^{2+}	Mg^{2+}	Cl^-	SO_4^{2-}	HCO_3^-
第四系松散水	最小值	109.43	40.38	29.94	74.89	458.11	228.52
	最大值	998.66	309.68	209.88	347.08	2188.89	474.89
	均值	322.55	143.35	86.20	227.77	761.04	355.58
	标准差	164.75	61.66	38.76	40.63	459.74	49.04
	变异系数	0.51	0.43	0.45	0.18	0.60	0.14
二叠系砂岩水	最小值	394.15	2.87	0.88	42.07	3.29	221.02
	最大值	1505.97	122.63	67.63	604.47	2845.39	2321.80
	均值	972.70	20.95	9.90	216.95	870.90	1160.25
	标准差	288.31	25.19	11.66	113.24	1092.34	790.29
	变异系数	0.30	1.20	1.18	0.52	1.25	0.68
石炭系灰岩水	最小值	216.68	4.37	1.95	152.45	2.47	374.08
	最大值	694.05	115.65	54.17	326.14	514.91	1303.63
	均值	538.35	21.26	13.75	263.95	90.58	954.50
	标准差	148.51	26.52	12.64	41.42	132.60	346.72
	变异系数	0.28	1.25	0.92	0.16	1.46	0.36

由表 1 可以看出,松散水中阳离子含量大小依次为 $K^+ + Na^+ > Ca^{2+} > Mg^{2+}$,阴离子含量依次为 $SO_4^{2-} > HCO_3^- > Cl^-$;砂岩水中阳离子含量依次为 $K^+ + Na^+ > Ca^{2+} > Mg^{2+}$,阴离子含量依次为 $SO_4^{2-} > HCO_3^- > Cl^-$;灰岩水中阳离子含量依次为 $K^+ + Na^+ > Ca^{2+} > Mg^{2+}$,阴离子含量依次为 $HCO_3^- > Cl^-$

$> SO_4^{2-}$ 。 Ca^{2+} 、 Mg^{2+} 和 SO_4^{2-} 含量随深度增加有升高的趋势,其他离子则随深度增加呈降低趋势。总体上,地下水成分变异系数小,空间离散程度低,离子含量波动性小。

2.2 相关性分析

Spearman 相关性可以对地下水成分变化类似性和来源一致性进行解释。利用 Origin 软件绘制所有地下水样的 Spearman 相关系数热图(图 2)。

由图 2 可以看出, Ca^{2+} 与 Mg^{2+} 显著性相关,表明两者来源一致, SO_4^{2-} 与 Ca^{2+} 、 Mg^{2+} 呈正相关,相关系数分别为 0.66 和 0.43,显示了研究区地下水成分形成可能与硫酸盐矿物溶解有关。 HCO_3^- 与 $K^+ + Na^+$ 呈正相关,相关系数为 0.38,表明发生了碳酸氢盐溶解作用。 Ca^{2+} 、 Mg^{2+} 与 $K^+ + Na^+$ 呈显著负相关,相关系数分别为 -0.6 和 -0.73,表明地下水存在阳离子交替吸附作用。 SO_4^{2-} 与 HCO_3^- 呈显著负相关,相关系数为 -0.82,说明地下水中可能发生脱硫酸作用。地下水中多种矿物溶解和化学反应的作用程度不同,导致地下不同含水层存在显著差异性。

2.3 水化学相

宿南矿区各含水层 Piper 三线图如图 3 所示。不同深度的地下水中的离子变化差异较大。第四系松散水中,阳离子以无主导型和 $Na^+ + K^+$ 为主导型两种情况,阴离子以无主导型和 SO_4^{2-} 型为主,其水化学类型为 $SO_4 - Na$ 型为主。

二叠系煤系砂岩水中,阳离子以 $Na^+ + K^+$ 为主导型,阴离子以 SO_4^{2-} 为主导、无主导和 HCO_3^- 主导型 3 种情况,其水化学类型主要为 $SO_4 \cdot HCO_3 - Na$ 型。石炭系太原组灰岩水,阳离子也以 $Na^+ + K^+$ 为主导型,阴离子则为无主导和 HCO_3^- 主导型 2 种情况,其水化学类型主要为 $HCO_3 - Na$ 型。

随着深度的增加,阳离子含量呈现出以部分 $Na^+ + K^+$ 为主导向全部以 $Na^+ + K^+$ 主导的趋势。根据各含水层的水化学类型可以判断出砂岩水与松散水、灰岩水相近,初步显示煤系水来源于松散水和灰岩水的补给。

3 粒子群优化随机森林的判别模型

3.1 随机森林(RF)分类理论

随机森林(Random Forest)是一个分类器,由各个树结构分类器 $\{h(X, \theta_k) | k = 1, 2, \dots\}$ 组成,其中 θ_k 为 I. I. D 的随机向量,也是在输入 X 时每棵树为




图 2 Spearman 相关系数热图

Fig. 2 Spearman correlation coefficient heat map




图 3 Piper 三线图

Fig. 3 Piper three line diagram

最受青睐类的投票^[3]。随机森林分类算法如图 4 所示。




图 4 随机森林分类算法示意

Fig. 4 Schematic diagram of random forest classification algorithm

总之,最终的分类结果是通过随机森林中作为分类器的树 $h_1(X)$, $h_2(X)$, $\dots$, $h_N(X)$ 进行投票,随机以向量 Y, X 的分布得到训练子集。边际函数的定义如式(1):

$$mg(X, Y) = av_N I(h_N(X) = Y) - \max_{j \neq Y} av_N I(h_N(X) = j) \quad (1)$$

式中, $I(\cdot)$ 为指标函数; $av_N(\cdot)$ 为平均值; 边际衡量的是 X, Y 对正确阶级的平均票数超过任何其他阶级的平均票数的程度。边际越大,对分类就越准备。用方程式描述了随机森林分类器的泛化误差。

$$PE^* = P_{X,Y}(mg(X, Y) < 0) \quad (2)$$

式(2)阐明了 $\{h(X, \theta_k) | k = 1, 2, \dots\}$ 遵循大数规则, N 的值对于模型足够大,分类器就有足够的树。同时,证明了泛化误差的上限是收敛的,因为随机向量 $\theta, \dots, PE^*$ 由公式(3)确定。

$$P_{X,Y}(P_\theta(h(X, \theta) = Y - \max_{j \neq Y} P_\theta(h(X, \theta) = j) < 0) \quad (3)$$

$$\bar{\varepsilon} \leq \frac{\rho(1-s^2)}{s^2} \quad (4)$$

式中, $\bar{\varepsilon}$ 为泛化误差的上限; ρ 为树之间的平均相关系数; s 为决策树的平均分类性能。

式(4)表明,平均相关系数越大,泛化误差的上限就越大。同样,平均分类量越大,泛化误差的上限就越大。也就是说,分类性能受到 2 个因素的影响,一个是树木的整体性能,另一个是树木之间的多样性。

作为一种集成学习算法,该分类器由于每棵树的良好性能和适当的树数量,具有更好的整体性能。

此外,随机森林空间的覆盖能力取决于树间的差异^[32-33]。为了实现树之间的差异,采用了 2 种方法:①生成多个训练数据子集;②结构上,在每个节点上,通过随机选择生长具有随机特征的树,然后对一小组输入变量按最大大小进行分割,不需要修剪。综上所述,在应用时应确定 n_{tree} 和 m_{try} 的 2 个参数去识别双变量自相关过程的异常模式。

建立 RF 模型的步骤如下所示。①基于 Bootstrap 方法在训练集中采样获取多个训练子集。②根据每个训练数据子集生成每棵对应的树。首先,从原始特征集中随机选择特征;其次,当将具有选定随机特征的树在每个节点上生长到最大值,不进行修剪。注意在这个过程中,特征子集的容量通常是恒定的。③通过测试数据集对 RF 分类器的性能进行测试,从每棵树中得到分类结果。④最终的分类将是分类结果中投票最多的结果。

3.2 粒子群优化(PSO)算法

粒子群优化算法是受鸟类自然捕食行为启发,为了寻找最优解决,从而被提出。本研究通过引入 PSO 算法,同时对 RF 的 2 个参数树的个数(n_{tree})和树的层数(m_{try})进行优化。通过 PSO 优化 RF 的 2 个关键参数的步骤如下。

(1) 对总体进行初始化解,并将 n_{tree} 和 m_{try} 的范围分别设置为 $[200, 800]$ 和 $[2, 10]$ 。

(2) 在建立 RF 模型后,计算适应度值。

(3) 刷新粒子的速度和位置,并很快计算出新的适应度值。

(4) 通过比较 g_{best} 值,对局部最佳(用 p_{best} 表示)和全局最佳进行刷新。

(5) 迭代循环直到达到最大迭代次数或目标函数的最优值时才能完成。否则返回到步骤(3)。

(6) 作为 RF 模型的最佳参数,通过寻找 PSO 和 m_{try} 的最优粒子,得到 n_{tree} 的最优组合。

总之,PSO 算法的一个基本变体的工作属性是一个候选解(称为粒子)的总体(称为群)。这些粒子位置的改变方式可以在搜索空间中用几个简单的公式来证明。粒子是基于包括它们自己的规则驱动的以及整个搜索空间中最显著的位置。此外,当达到改进的位置时,群的运动也由它们引导。接下来,这个过程将重复,直到最终发现一个令人满意的解决方案。迭代循环直到达到最大迭代次数或目标函数的最优值时才能结束。最后,通过寻找最优粒子得到 n_{tree} 和 m_{try} 的最优值作为 RF 模型的最优参数。

3.3 建立粒子群优化的随机森林(PSO-RF)模型

RF 模型的 2 个关键参数(m_{try} 和 n_{tree}) 不仅会影响识别精度,而且对识别效率也有一定的影响。本研究采用具有一个目标的标准 PSO 作为优化方法,对将其作为一个组成部分的 2 个关键参数进行优化。因此,建议使用 PSO-RF 来识别双变量自相关过程中的异常模式,PSO-RF 模型中 2 个关键参数优化的 PSO 程序的流程如图 5 所示。




图 5 PSO-RF 判别模型流程

Fig. 5 Pso-RF discrimination model flow


图 5 中,在模块 I 提取统计特征之前,通过蒙特卡罗模拟生成 3 种水源数据集,将所提取的特征向量作为数据集的来源,利用 1 个特殊的比例将特征向量分为 2 个不同的部分,包括训练和测试数据集。对于模块 II,PSO 算法对 RF 的 2 个关键参数(n_{tree} 和 m_{try}) 进行优化,获得最优组合。更具体地说,应用训练和测试数据集来比较 RF 模型的性能,从而在 n_{tree} 和 m_{try} 的不同组合中选择最优的模型。然后,利用这 2 个关键参数的最优组合,通过模块 III 的数据集的训练和验证,建立 PSO-RF 模型。最终,作为分类器的 PSO-RF 模型识别 3 种涌(突)水源,并通过测试数据集得到混淆矩阵中显示的识别精度。

4 实验结果与讨论


4.1 单一随机森林判别

在 RF 中,需要定义 2 个参数:森林中树的数量(k)以及分裂节点的随机变量数量(m)。为了使模型的精度最大化,有必要对参数 m 、 k 的组合进行优化。当 k 定义值较小时,RF 误差不可控,模型性不

能达到最优识别;相反,如果参数 k 太大,计算时间和所需的内存也会相应增加。通过重复操作,发现当 $k=90$ 时,各分类的 OOB 误差均趋于稳定,模型不存在过拟合的趋势。RF 模型训练样本与测试样本预测结果如图 6 所示,每个离子变量对生成的 RF 模型重要性如图 7 所示。



(a) 训练集预测结果(正确率97%)



(b) 测试集预测结果(正确率85%)

图 6 RF 模型训练样本与测试样本预测结果

Fig. 6 Prediction results of RF model training samples and test samples

OOB 错误率随树的数量 k 的变化而发生变化。当 $k=90$ 时,模型的错误率稳定;当 $m=4$ 时,错误率较低,约为 0.09。这表明,当 RF 模型应用于训练样本和测试样本判别时,模型的准确率分别为 97% 和 85%。

每个变量的重要性程度通过 2 种方法进行测量,分别是基尼指数的平均下降和 OOB 精度的平均下降。根据基尼指数, K^+ 、 Na^+ 的重要性最高,其次是 Mg^{2+} 和 SO_4^{2-} , Ca^{2+} 、 HCO_3^- 和 Cl^- 的重要性最低;OOB 的精度下降同基尼指数一致,说明 Ca^{2+} 、

HCO_3^- 和 Cl^- 对涌突水判别影响较小。




图 7 RF 模型误差分析

Fig. 7 Error analysis of RF model

4.2 PSO 优化效果

采用基于一个目标的标准粒子群优化方法,对射流的 2 个关键参数进行了优化。需要声明 PSO 的参数值如下: 将学习因子 C_1 和 C_2 均设置为 2,种群更新次数和种群规模分别设置为 50 和 5,粒子速度的 2 个分量分别被限制在 $[0, 3]$ 和 $[-10, -1]$ 中,最大边界和最小边界限制在 $[0, 10]$ 和 $[-1, 1]$ 中。此外,实验重复 100 次,获得本节 RF 的 n_{tree} 和 m_{try} 最优组合。PSO 的结果,即适应度值,通过模型在验证数据集上的平均 RA 进行评估。

4.3 PSO-RF 判别结果

将 100 个训练样本,20 个测试样本代入 PSO-RF 模型中运行,得出训练集的判别准确率为 98%,测试集的判别准确率为 95%,其中太灰水和四含水的判别准确率为 100%,二叠系误判了 2 个水样,准确率为 91.4%。对比单一 RF 判别模型,经过粒子群优化参数的随机森林模型判别准确率较高,具有更优的性能,不需要重复操作去寻找最优的 n_{tree} 和 m_{try} 参数,大大缩短了判别所用的时间,也提高了判别的精度。PSO-RF 模型训练样本与测试样本预测结果如图 8 所示,粒子群收敛曲线及误差分析如图

9 所示。




图 8 PSO-RF 模型训练样本与测试样本预测结果

Fig. 8 Prediction results of PSO-RF model training samples and test samples




图 9 粒子群收敛曲线及误差分析

Fig. 9 Particle swarm convergence curve and error analysis

图 9 中的 PSO-RF 模型显示了最佳粒子的适应度,得出 $n_{\text{tree}} = 7, m_{\text{try}} = 3$ 的结果。在 n_{tree} 和 m_{try} 的多个组合中,仅通过一步即可达到适应度函数的等值,

说明了 RF 作为分类器具有稳定的分类性能。

5 结论

提出了一种水源判别应用模型 PSO-RF,该模型融合多种离子变量来表示分类模式,并通过 PSO 优化的随机森林对模式进行分类,以识别双变量自相关过程中的不同特征。

(1) RF 模型应用于训练样本和测试样本判别时,模型的准确率分别为 97% 和 85%;采用 PSO-RF 模型对其判别时,准确度分别为 98% 和 95%,经过 PSO 参数优化后,识别精度明显提高。

(2) PSO-RF 模型经过粒子群算法自动优化 n_{tree} 和 m_{try} 参数,减少了 RF 模型确定超优参数的繁琐重复操作环节,提高了水源判别的效率。

(3) 研究区离子间具有不同程度的自相关性,而 PSO-RF 模型对相关性强度的离子变量,仍具有一定程度的识别能力。

参考文献(References):

- [1] 桑树勋,袁亮,刘世奇,等.碳中和地质技术及其煤炭低碳化应用前景[J].煤炭学报,2022,47(3):1-23.
SANG Shu-xun, YUAN Liang, LIU Shi-qi, et al. Geological technology for carbon neutrality and its application prospect for low carbon coal exploitation and utilization[J]. Journal of China Coal Society, 2022(3): 1-23.
- [2] 刘峰,郭林峰,赵路正.双碳背景下煤炭安全区间与绿色低碳技术路径[J].煤炭学报,2022,47(1):1-15.
LIU Feng, GUO Lin-feng, ZHAO Lu-zheng. Research on coal safety range and green low-carbon technology path under the dual-carbon background[J]. Journal of China Coal Society, 2022, 47(1): 1-15.
- [3] DONG S, ZHENG L, TANG S, et al. A Scientometric Analysis of Trends in Coal Mine Water Inrush Prevention and Control for the Period 2000—2019[J]. Mine Water and the Environment, 2020, 39(1): 3-12.
- [4] 李浩荡,赵永峰,尤文顺,等.新发展格局下国家能源集团煤炭产业高质量发展研究[J].中国煤炭,2021,47(1):46-51.
LI Hao-dang, ZHAO Yong-feng, YOU Wen-shun, et al. Research on high-quality development of the coal industry in China Energy Investment Group under the new development pattern[J]. China Coal, 2021, 47(1): 46-51.
- [5] 吴吟.保障国家能源安全 推进煤炭工业高质量发展[J].中国煤炭,2020,46(7):1-3.
WU Yin. Ensuring national energy security and promoting high-quality development of coal industry[J]. China Coal, 2020, 46(7): 1-3.
- [6] BI Y, WU J, ZHAI X, et al. Application of Partial Least Squares-Discriminate Analysis Model Based on Water Chemical Compositions in Identifying Water Inrush Sources from Multiple Aquifers in Mines[J]. Geofluids, 2021, 2021: 1-17.
- [7] WANG D, JU Q, WANG Y, et al. Source identification of mine water inrush based on the exponential whitenization function and the grey situation decision model[J]. Energy Exploration & Exploitation, 2022: 014459872210856.
- [8] JU Q, HU Y. Source identification of mine water inrush based on principal component analysis and grey situation decision[J]. Environmental Earth Sciences, 2021, 80(4): 157.
- [9] 张淑莹,胡友彪,琚棋定.基于水化学特征分析判别朱集煤矿井突水水源[J].矿业安全与环保,2018,45(6):53-56.
ZHANG Shu-ying, HU You-biao, JU Qi-ding. Distinguishing the sources of water inrush in Zhuji Coal Mine by hydrochemical characteristics[J]. Mining Safety & Environmental Protection, 2018, 45(6): 53-56.
- [10] 马雷,钱家忠,赵卫东.基于GIS和水质水温的矿井突水水源快速判别[J].煤田地质与勘探,2014,42(2):49-53.
MA Lei, QIAN Jia-zhong, ZHAO Wei-dong. An approach for quickly identifying water-inrush source of mine based on GIS and groundwater chemistry and temperature[J]. Coal Geology & Exploration, 2014, 42(2): 49-53.
- [11] 董东林,孙文洁,朱兆昌,等.基于GIS-BN技术的范各庄煤矿12底板突水态势评价[J].煤炭学报,2012,37(6):999-1004.
DONG Dong-lin, SUN Wen-jie, ZHU Zhao-chang, et al. Water inrush situation evaluation of coal 12 floor in Fanggezhuang Mine based on GIS-BN Technology[J]. Journal of China Coal Society, 2012, 37(6): 999-1004.
- [12] QU Shen, WANG Guang-cai, SHI Zhe-ming, et al. Using stable isotopes(δD , $\delta^{18}O$, $\delta^{34}S$ and $87Sr/86Sr$) to identify sources of water in abandoned mines in the Fengfeng coal mining district, northern China[J]. Hydrogeology Journal, 2018, 26(5): 1443-1453.
- [13] 赵伟,刘启蒙,柴辉婵,等.基于Fisher判别法和质心距理论的突水水源识别[J].科学技术与工程,2020,20(9):3552-3556.
ZHAO Wei, LIU Qi-meng, CHAI Hui-chan, et al. Identification of water inrush source based on Fisher discriminant method and centroid distance theory, 2020, 20(9): 3552-3556.
- [14] 姜子豪,胡友彪,琚棋定,等.矿井突水水源判别方法[J].工矿自动化,2020,46(4):28-33.
JIANG Zi-hao, HU You-biao, JU Qi-ding, et al. A discrimination method of mine water inrush source[J]. Industry and Mine Automation, 2020, 46(4): 28-33.
- [15] 琚棋定,胡友彪,张淑莹.基于主成分分析与贝叶斯判别法的矿井突水水源识别方法研究[J].煤炭工程,2018,50(12):90-94.
JU Qiding, HU Youbiao, Zhang Shuying. Mine water inrush source identification method based on principal component analysis and Bayesian discriminant[J]. Coal Engineering, 2018, 50(12): 90-94.
- [16] 张淑莹,胡友彪,邢世平.基于独立性权—灰色关联度理论的

- 突水水源判别 [J]. 水文地质工程地质, 2018, 45(6): 36-41, 62.
- ZHANG SHU-ying, HU You-biao, XING Shi-ping. Discrimination of the mine water inrush source based on principal component analyses - theory of gray relational degree [J]. Hydrogeology and Engineering Geology, 2018, 45(6): 36-41, 62.
- [17] 郭瑞, 王永申, 许刚. 不连沟煤矿充水水源水化学特征分析及突水水源判别模型研究及应用 [J]. 煤炭科技, 2018(3): 128-131.
- GUO Rui, WANG Yong-shen, XU Gang. Chemical characteristics analysis of water - filled source water in Buliangou Coal Mine and research and application of water source water source discrimination model [J].
- [18] HUANG P, HU Y, GAO H, et al. Dynamic identification and radium-radon response mechanism of floor mixed water source in high ground temperature coal mine [J]. Journal of Hydrology, 2021, 603: 126942.
- [19] 郭元. 辛置井田多含水层水岩作用机理及突水水源判别技术研究 [D]. 北京: 中国矿业大学(北京), 2019.
- [20] 王晓明, 周小平, 刘咏, 等. 基于水化学信息的顾北煤矿最佳突涌水水源判别模型 [J]. 安全与环境工程, 2013, 20(5): 122-125.
- WANG Xiao-ming, ZHOU Xiao-ping, LIU Yong, et al. Optimum Discrimination Model of Water - inrush Source Based on Water Chemical Information in Gubei Coal Mine [J]. Safety and Environmental Engineering, 2013, 20(5): 122-125.
- [21] 罗斌, 齐跃明, 白向挺. 基于 H 支持向量机和灰色关联分析突水水源判别 [J]. 煤炭科学技术, 2013, 41(S2): 367-369.
- LUO Bin, QI Yue-ming, BAI Xiang-ting. Identification of Water Inrush Source Based on H support vector machine and grey correlation analysis [J]. Coal Science and Technology,
- [22] 曾一凡, 梅傲霜, 武强, 等. 基于水化学场机器学习分析与水动力场反向示踪模拟耦合的矿井涌(突)水水源综合判识技术 [J]. 煤炭学报: 1-14 [2022-03-26].
- ZENG Yi-fan, MEI Ao-shuang, WU Qiang, et al. Comprehensive identification technology of mine gushing water source based on the coupling of machine learning analysis of hydrochemical field and reverse tracing simulation of hydrodynamic field [J]. 煤炭学报: 1-14 [2022-03-26].
- [23] 董东林, 陈昱吟, 倪林根, 等. 基于 WOA-ELM 算法的矿井突水水源快速判别模型 [J]. 煤炭学报, 2021, 46(3): 984-993.
- DONG Dong-lin, CHEN Yu-yin, NI Lingen, et al. Fast discrimination model of Mine Water Inrush Source Based on WOA elm algorithm [J].
- [24] 吴兆立. 基于蜻蜓算法和最小二乘支持向量机的矿井突水水源判别 [J]. 中国矿业, 2021, 30(2): 91-94.
- WU Zhao-li. Identification of mine water inrush source based on dragonfly algorithm and least squares support vector machine [J]. China Mining Magazine, 2021, 30(2): 91-94.
- [25] 郝谦, 武雄, 穆文平, 等. 基于随机森林模型判别矿井涌(突)水水源 [J]. 科学技术与工程, 2020, 20(16): 6411-6418.
- HAO Qian, WU Xiong, MU Wen-ping, et al. Groundwater Source Determination of Mine Inflow or Inrush Using a Random Forest Model [J]. Science Technology and Engineering, 2020, 20(16): 6411-6418.
- [26] 王甜甜, 靳德武, 刘基, 等. 动态权—集对分析模型在矿井突水水源识别中的应用 [J]. 煤炭学报, 2019, 44(9): 2840-2850.
- WANG Tiao-tao, JIN De-wu, LIU Ji, et al. Application of dynamic weight - set pair analysis model in mine water inrush discrimination
- [27] 杨勇, 岳建华, 李晶, 等. LIF 和 CNN 的矿井突水水源类型判别 [J]. 光谱学与光谱分析, 2019, 39(8): 2425-2430.
- YANG Yong, YUE Jian-hua, LI Jing, et al. Online Discrimination Model for Mine Water Inrush Source Based CNN and Fluorescence Spectrum [J]. Spectroscopy and Spectral Analysis, 2019, 39(8): 2425-2430.
- [28] 曲兴玥, 施龙青. 基于 Matlab 因子分析及距离判别模型的矿井突水水源识别 [J]. 煤炭科学技术, 2018, 46(8): 178-182.
- QU Xing-yue, SHI Long-qing. Discrimination on mine water inrush source based on Matlab factor analysis and Distance Distinguished Model Coal Science and Technology
- [29] 徐星, 田坤云, 郑吉玉. 基于遗传 BP 神经网络模型的矿井突水水源判别 [J]. 工业安全与环保, 2017, 43(11): 21-24.
- XU Xing, TIAN Kun-yun, ZHENG Ji-yu. Discriminating Mine Water Inrush Source Based on Genetic BP Neural Network Model [J]. Industrial Safety and Environmental Protection, 2017, 43(11): 21-24.
- [30] 张玉, 郭伟峰. 基于分形滤波的 SOFM 在矿井突水水源判别中的应用 [J]. 华北水利水电学院学报, 2012, 33(5): 99-102.
- ZHANG Yu, GUO Wei-feng. Application of SOFM Based on the Fractal Filter to the Identification of the Mine Water Inrush [J]. Journal of North China Institute of Water Conservancy and Hydroelectric Power, 2012, 33(5): 99-102.
- [31] WAN Y wei, ZHU B. Abnormal patterns recognition in bivariate autocorrelated process using optimized random forest and multi-feature extraction [J]. ISA Transactions, 2021, 109: 102-112.
- [32] LUO W, YUAN D, JIN D, et al. Optimal Control of Slurry Pressure during Shield Tunnelling Based on Random Forest and Particle Swarm Optimization [J]. Computer Modeling in Engineering & Sciences, 2021, 128(1): 109-127.
- [33] 郭瑞, 王永申, 许刚. 不连沟煤矿充水水源水化学特征分析及突水水源判别模型研究及应用 [J]. 煤炭科技, 2018(3): 128-131.
- GUO Rui, WANG Yong-shen, XU Gang. Chemical characteristics analysis of water - filled source water in Buliangou Coal Mine and research and application of water source water source discrimination model [J]. Coal Science & Technology Magazine, 2018(3): 128-131.