

分类号: TP183

密 级:

学 号: 19208049018



西安科技大学
XI' AN UNIVERSITY OF SCIENCE AND TECHNOLOGY

硕士学位论文

Thesis for Master's Degree

基于机器学习的煤矿涌水量预测方法研究

申请人姓名: 李娜

指导教师: 秋兴国

学科门类: 工学

学科名称: 计算机科学与技术

研究方向: 大数据与智能信息处理

2022 年 6 月

论文题目：基于机器学习的煤矿涌水量预测方法研究


学科名称：计算机科学与技术

硕士生：李娜

(签名)

指导教师：秋兴国

(签名)



摘要

煤矿涌水量是煤矿安全监测的关键指标，准确预测煤矿涌水量对保障煤矿安全生产、防排水系统设防以及预防水害事故发生具有重要意义。机器学习方法因其具有强大的非线性处理能力而被应用于煤矿涌水量预测中，论文结合不同地质构造下的煤矿涌水量特性，分别提出了基于 MSGWO-SVR 的煤矿涌水量预测模型和基于 CNN-GCN-BiLSTM 的煤矿涌水量预测模型，并通过算例分析，验证了所提模型用于煤矿涌水量预测的可行性。论文主要研究内容如下：

(1) 对于地质构造简单的煤矿，煤矿涌水量主要受含水层水压影响，水压与涌水量之间具有强烈的非线性关系，传统方法难以准确表征水压与涌水量之间的潜在变化规律。针对以上问题，提出了一种基于混合策略改进灰狼算法优化支持向量回归的煤矿涌水量预测模型 (MSGWO-SVR)。首先，为了增强传统灰狼优化算法种群质量和跳出局部极值的能力，将精英反向学习机制、非线性收敛因子和高斯变异策略引入传统灰狼优化算法，得到 MSGWO 算法；其次，利用 MSGWO 对 SVR 的惩罚因子和核参数进行寻优，以提高 SVR 模型的自学习能力和非线性拟合能力；最后，根据最优参数组合建立煤矿涌水量预测模型。实验结果显示，与传统预测模型以及 SVR 和 GWO-SVR 模型相比，论文所提出的 MSGWO-SVR 模型预测准确性和稳定性均有明显提高，表明 MSGWO-SVR 模型可以实现超参数的自动寻优，从而准确预测处于简单地质构造下的煤矿涌水量。

(2) 对于地质构造复杂的煤矿，煤矿涌水量受断层落差、煤层倾角等诸多因素影响，各因素之间存在明显的协同作用，浅层模型对数据间的关联特征信息挖掘不够充分，难以实现精准预测。针对以上问题，提出了一种基于图卷积神经网络和双向长短期记忆神经网络的煤矿涌水量预测模型 (CNN-GCN-BiLSTM)。首先，为了获得原始数据的有效表征，采用二维卷积 (2D-CNN) 神经网络层提取数据深层特征；其次，为了深入挖掘输入变量间的潜在信息，构建以涌水量影响因素为节点、皮尔逊相关系数为边的无向图，利用图卷积 (GCN) 神经网络提取数据空间特征；最后，使用双向长短期记忆 (BiLSTM) 神经网络对提取的特征信息所构成的序列数据进行双向序列特征学习，并

通过全连接层输出涌水量预测值。实验结果显示，与 7 种经典模型和基线模型相比，论文所提出的 CNN-GCN-BiLSTM 模型预测准确率最高，表明 CNN-GCN-BiLSTM 模型更适合于解决复杂地质构造下的煤矿涌水量预测问题。

关 键 词：煤矿涌水；涌水量预测；机器学习；灰狼优化算法；图卷积神经网络

研究类型：应用研究

**Subject : Research on prediction method of coal mine water inflow
based on machine learning**

Specialty : Computer Science and Technology

Name : LiNa (Signature)

Instructor : Qiu Xingguo (Signature)



ABSTRACT

The quantity of water inflow in coal mine is the key index of Coal Mine Safety Monitoring, and it is of great significance to ensure safe coal mine production, prevent drainage systems from being set up and prevent water damage accidents. This paper combines the characteristics of coal mine water surges under different geological formations and proposes a prediction model based on MSGWO-SVR and a prediction model based on CNN-GCN-BiLSTM for prediction of quantity of water inflow in coal mine, and through case analysis verified the feasibility of the proposed model used for prediction of the quantity of coal mine water inflow. The main research elements of the thesis are as follows:

(1) For coal mines with simple geological formations, the quantity of coal mine water inflow is mainly affected by the water pressure in the aquifer, and there is a strong non-linear relationship between water pressure and water influx, which makes it difficult for traditional methods to accurately characterise the internal change law between water pressure and quantity of mine water influx. In response to above issues, a model for predicting coal mine water inflow based on a hybrid strategy to improve the grey wolf algorithm to optimise support vector regression is proposed (MSGWO-SVR). Firstly, in order to enhance the population quality and the ability to jump out of local extremum of the traditional grey wolf optimisation algorithm, the elite opposition based learning mechanism, nonlinear convergence factor and Gaussian mutation strategy are introduced into the traditional gray wolf optimization algorithm and obtain MSGWO algorithm; secondly, the penalty factor and kernel parameters of the SVR are optimised using MSGWO in order to improve the self-learning ability and non-linear fitting ability of the SVR model; finally, according to the optimal combination of parameters to establish the prediction model of coal mine water

inflow. The experimental results show that compared with traditional forecasting models and the SVR and GWO-SVR models, the MSGWO-SVR model proposed in this paper has significantly improved the prediction accuracy and stability, which indicates that the MSGWO-SVR model can realize the automatic optimization of the hyperparameters, so as to accurately predict the value of coal mine water inflow under simple geological formations.

(2) For coal mines with complex geological formations, the quantity of coal mine water inflow is affected by many factors, such as fault drop, coal seam inclination and so on, there are obvious synergistic effects between various factors, the shallow model is difficult to accurately mine the correlation among data, which leads to large errors of prediction results. In response to above issues, a prediction model of coal mine water inflow based on graphical convolutional neural network and bi-directional long short-term memory neural network is proposed (CNN-GCN-BiLSTM). Firstly, in order to obtain the effective representation of the original data, the two-dimensional convolutional (2D-CNN) neural network is used to extract the deep features of the data; secondly, in order to mine the underlying information between the input variables, an undirected graph was constructed with the influencing factors of coal mine water inflow as nodes and Pearson correlation coefficients as edges, and the spatial features of the data were extracted using the graph convolution (GCN) neural network; finally, bi-directional long short-term memory (BiLSTM) neural network is used to perform bi-directional sequence feature learning on the sequence data composed of the extracted feature information, and output the predicted value of water inflow through the fully connected layers. The experimental results show that the CNN-GCN-BiLSTM model proposed in this paper has the highest prediction accuracy compared to the seven classical models and the baseline model, which indicates that the CNN-GCN-BiLSTM model is more suitable for solving the problem of predicting coal mine water influx under complex geological structures.

Key words : Coal mine water inflow; Water inflow prediction; Machine learning; Gray wolf optimization algorithm; Graph convolutional neural network

Thesis : Applied Research

目 录

1 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 煤矿涌水量预测方法研究现状.....	2
1.2.2 传统灰狼优化算法研究现状.....	3
1.2.3 图卷积神经网络研究现状.....	5
1.3 论文主要研究内容.....	6
1.4 论文组织结构.....	7
2 相关理论基础	8
2.1 煤矿涌水量影响因素分析	8
2.2 灰狼优化算法.....	9
2.2.1 算法基本思想.....	9
2.2.2 算法基本流程.....	11
2.2.3 算法影响因素分析.....	13
2.3 支持向量回归.....	13
2.3.1 模型基本原理.....	13
2.3.2 模型性能分析.....	15
2.4 卷积神经网络.....	16
2.4.1 卷积层.....	16
2.4.2 池化层.....	17
2.4.3 全连接层.....	18
2.4.4 激活函数.....	18
2.5 图卷积神经网络.....	19
2.6 长短期记忆神经网络.....	21
2.6.1 长短期记忆神经网络.....	21
2.6.2 双向长短期记忆神经网络.....	23
2.7 本章小结.....	23
3 基于 MSGWO-SVR 的煤矿涌水量预测模型.....	25
3.1 MSGWO 优化算法	25
3.1.1 精英反向学习策略.....	25
3.1.2 收敛因子非线性调整策略.....	26
3.1.3 高斯变异策略.....	27
3.2 MSGWO 优化算法基本流程	27
3.3 MSGWO 优化算法仿真实验	29

3.3.1 算法评价指标和测试函数.....	29
3.3.2 实验环境和参数设置.....	30
3.3.3 仿真实验结果与分析.....	31
3.4 基于 MSGWO-SVR 的煤矿涌水量预测模型	37
3.4.1 MSGWO-SVR 算法基本流程	37
3.4.2 MSGWO-SVR 模型框架	38
3.5 算例分析.....	39
3.5.1 实验环境.....	39
3.5.2 实验数据	39
3.5.3 模型评价指标.....	39
3.5.4 数据预处理.....	40
3.5.5 模型参数设置.....	40
3.5.6 实验结果与分析.....	40
3.6 本章小结.....	43
4 基于 CNN-GCN-BiLSTM 的煤矿涌水量预测模型	45
4.1 CNN-GCN-BiLSTM 模型框架	45
4.2 CNN-GCN-BiLSTM 模型网络结构	46
4.2.1 CNN 层的网络结构设计	46
4.2.2 GCN 层的网络结构设计	47
4.2.3 BiLSTM 层的网络结构设计	48
4.2.4 Adam 优化器	49
4.3 CNN-GCN-BiLSTM 模型训练预测过程	50
4.3.1 CNN-GCN-BiLSTM 模型训练过程.....	50
4.3.2 CNN-GCN-BiLSTM 模型预测过程.....	51
4.4 算例分析.....	52
4.4.1 实验环境.....	52
4.4.2 实验数据	52
4.4.3 模型评价指标.....	52
4.4.4 数据预处理.....	53
4.4.5 模型参数设置.....	53
4.4.6 实验结果与分析.....	53
4.5 本章小节.....	56
5 总结与展望.....	57
5.1 总结.....	57
5.2 展望.....	58
参考文献.....	59

1 绪论

1.1 研究背景及意义

2021 年,我国原煤产量高达到 40.7 亿吨,同比增长 4.7%。尽管处在能源结构调整、碳达峰和碳中和的大背景下,煤炭仍然是我国的主体能源。综合考虑我国能源特点,在今后很长一段时间内,煤炭仍会发挥其兜底保障作用,促进社会 and 经济发展^[1]。

煤矿安全生产工作一直都受到国家的高度重视。在我国煤矿灾害事故中,煤矿水害已成为我国第二大矿井生产灾害。2021 年,我国共发生水害事故 4 起,与 2020 年相比,2021 年水害事故数减少 3 起,但是死亡人数却增加了 23 人,占当年全国煤矿事故死亡总人数的 27.0%。2000 年到 2021 年我国煤矿水害事故数和死亡人数统计结果如图 1.1 所示,通过图 1.1 可以看出,在 2000 年至 2021 年期间,虽然我国煤矿水害事故数呈下降趋势,但是每年仍有较为严重的水害事故发生。




图 1.1 2000 年到 2021 年我国煤矿水害事故数和死亡人数统计图

煤矿水害是指在煤矿开采过程中煤矿涌水量超过煤矿自身排水能力导致人身和财产造成危害的现象,煤矿水害事故的发生会给煤矿企业和井下员工造成非常严重的恶性影响。煤矿涌水量是指单位时期内涌入煤矿的总水量,一般用 m^3/h 和 m^3/min 表示。在煤矿水害事故发生前后煤矿涌水量会有明显变化,煤矿涌水量是煤矿水害防治工作的重要参照指标,而预测煤矿涌水量则是预防煤矿水害发生的一项基础性工作。

在煤矿实际开采过程中,若能准确预测煤矿涌水量,煤矿企业不但可以在涌水量变化初期采取相应的防治和控制措施,从而降低煤矿水害事故发生几率,确保煤炭开采作业的安全进行,而且还可以通过煤矿涌水量分析煤矿水害事故发生原因,从而寻找煤矿涌水量变化规律,避免类似事故再次发生。

目前,如何准确预测煤矿涌水量,防止煤矿突水事故发生,已成为日益关注的热点研究问题之一。但是,煤矿涌水量系统是一个复杂的非线性动力学系统,导致煤矿涌水量预测研究的难度大大增加。因此,寻求一种合理有效的煤矿涌水量预测方法对于未来煤矿企业防治水工作以及大规模安全开采具有重要的实际应用价值。

1.2 国内外研究现状

1.2.1 煤矿涌水量预测方法研究现状

选择合理有效的预测方法是准确预测煤矿涌水量的前提条件。近些年,国内外研究学者对煤矿涌水量预测这一课题做了大量的研究,从多种角度提出了不同的预测方法。分析现有的预测方法,对于煤矿涌水量预测问题的研究具有非常重要的参考价值。

(1) 基于数学模型的方法

早期的煤矿涌水量预测方法大多都是基于数学模型所建立的确定性分析方法,主要有解析法、数值法以及水均衡法。其中,解析法原理简单、使用方便,但只适用于水文地质条件较为简单的煤矿;利用数值法所求得的涌水量为近似解,而且数值法对矿井水文地质参数的要求极高。所以,数值法仅适用于水文地质参数记录较为详细且对预测精度要求较低的煤矿;水均衡法是根据地下水动力平衡原理所提出的,水均衡法主要适用于水均衡条件简单的煤矿。由于煤矿涌水量成因复杂,单一方法无法准确表述煤矿涌水量变化规律。因此,在实际应用过程中,通常会将多个单一方法的预测结果进行分析比较,从而得到较为可靠的涌水量预测结果。例如,Chen 等人^[2]分别使用数值模拟法和大井法对南山煤矿涌水量进行了预测,发现数值模拟法可以克服大井法参数不易确定的问题;胡雅琴等人^[3]首先分析了祁南煤矿的水文地质条件,然后将数值法和解析法的预测结果进行相互补充,从而得到了该矿的涌水量;戴岩柯等人^[4]以西石门铁矿深基坑为例,分别采用水平衡法和数值模拟法对西石门铁矿深基坑涌水量进行了预测。

在煤矿实际开采过程中,煤矿涌水量具有复杂、不确定以及高耦合等特性。因此,使用确定性分析方法对煤矿涌水量进行预测时,预测精度较低。此外,确定性分析方法过于依赖煤矿含水层的水文地质参数,预测方法使用条件较为严苛。

(2) 基于回归分析的方法

随着数理统计学的发展,许多学者利用回归分析法对煤矿涌水量进行预测。李孝朋等人^[5]将多元回归分析法应用于煤矿涌水量预测,通过多元回归分析法建立了煤矿涌水量和涌水量影响因素间的非线性回归拟合方程式,利用该方程式对涌水量进行了预测;段俭君等人^[6]首先利用 SPSS 软件分析了煤矿涌水量和涌水量影响因素之间的关系,然后通过相关分析法建立了多元回归方程,从而实现了矿井涌水量预测;王家乐等人^[7]在

分析煤矿水文地质条件的基础上,根据煤矿涌水量与煤产量、工作面推进距离以及开采面积之间的相关关系建立了回归方程,最后利用该回归方程对煤矿涌水量进行了预测;姚辉等人^[7]建立了两种不同的回归模型用来预测煤矿涌水量。首先通过 ARIMA 模型利用历史涌水量数据建立了回归模型;其次基于煤矿涌水量影响因素建立了回归模型。发现在两种回归模型中,考虑涌水量影响因素的回归模型预测结果更为准确。

回归分析法的出现减少了煤矿涌水量预测方法对水文地质参数的依赖。但是,回归分析法无法准确确定煤矿涌水量影响因素与涌水量之间复杂的映射关系,从而导致预测精度低于预期,并且该方法泛化能力较差。

(3) 基于机器学习的方法

近年来,机器学习因其极强的自学习能力和非线性拟合能力^[9]也被应用于煤矿涌水量预测。刘国辉等人^[9]为了准确、快速地预测涌水量,建立了基于 SVR 的煤矿涌水量预测模型;凌成鹏等人^[10]以降水量作为模型输入变量,煤矿涌水量作为模型输出变量,建立了基于 BP 神经网络的煤矿涌水量预测模型;张宪峰等人^[12]考虑到影响煤矿涌水的因素众多,首先利用主成分分析法降低输入数据维度,然后通过 BP 神经网络对煤矿涌水量进行预测,该方法预测误差更小,为矿井涌水量预测提高了一种新思路;孟璐^[13]选取煤矿开采面积、开采深度、降水量以及水位作为煤矿涌水量的主要影响因素,将煤矿涌水量主要影响因素作为模型输入特征,构建了以 BP 神经网络为核心的煤矿涌水量预测模型;窦贤明等人^[14]为了解决传统 BP 神经网络的缺点,利用遗传算法来优化 BP 神经网络的超参数,并以刘桥二矿实测数据为例,进行了算例验证。相比传统 BP 神经网络,利用智能优化算法改进后的 BP 神经网络模型预测精度更高。

机器学习算法具有较强的特征学习能力以及非线性拟合能力,可以准确地挖掘和表征煤矿涌水量变化规律。但是,机器学习算法也有一定局限性,主要体现在以下两方面:其一,机器学习算法的学习效果和泛化性能依赖于超参数的选择,传统的参数优化方法主要有随机搜索法和网格搜索法,此种方法计算量大,非常耗时,并且寻优结果易陷入局部最优;其二,复杂地质构造下的煤矿涌水量由多种影响因素共同引起,这些影响因素之间还会相互作用、相互影响。目前,基于机器学习的煤矿涌水量预测模型大多都是浅层模型,浅层模型对数据的挖掘深度不够,不能深入地分析数据之间的潜在变化规律,在预测复杂地质构造下的煤矿涌水量时会产生较大的误差。

1.2.2 传统灰狼优化算法研究现状

全局优化旨在找到问题的最优解,在科学技术领域存在许多全局优化问题,如路径规划、资源分配以及机器学习和神经网络超参数寻优等。元启发式算法因其在处理非线性参数优化问题时具有良好的表现而被广泛应用于求解全局优化问题。从上世纪九十年

代开始,国内外众多科研工作者先后提出了很多不同的元启发式算法,元启发式算法大致分为以下三类:基于进化算法(Evolutionary Algorithm,EA)的元启发式算法、基于物理定律的元启发式算法以及基于群体智能(Swarm Intelligence,SI)的元启发式算法。

基于进化算法(Evolutionary Algorithm,EA)的元启发式算法主要包括遗传算法(Genetic Algorithm,GA)^[15]、演化算法(Evolutionary Strategies,ES)^[16]、差分进化算法(Differential Evolution,DE)^[17]和生物地理学优化算法(Biogeography-based optimization,BBO)^[18]等。

在基于物理定律的元启发式算法中,具有代表性的算法有引力搜索算法(Gravitational Search Algorithm,GSA)^[19]、热交换优化算法(Thermal Exchange Optimizatio,TEO)^[20]、正弦余弦算法(Sine Cosine Algorithm,SCA)^[21]和瞬态搜索优化算法(Transient Search Optimization,TSO)^[22]等。

基于群体智能的元启发式算法中主要包括粒子群优化算法(Particle Swarm Optimization,PSO)^[23]、人工鱼群算法(Artificial Fish Swarms Algorithm,AFSA)^[24]、蚁群算法(Ant Colony Optimization,ACO)^[25]、人工蜂群算法(Artificial Bee Colony,ABC)^[26]、布谷鸟搜索(Cuckoo Search,CS)^[27]、鲸鱼优化算法(Whale Optimization Algorithm,WOA)^[28]和果蝇优化算法(Fruit Fly Optimization Algorithm,FOA)^[29]等。

在元启发式算法中,基于群体智能的元启发式算法是受自然界中各种生物体(如鱼、蚂蚁、蜜蜂等)的社会互动和生活方式激发而提出的一种全局优化算法。这种优化算法易于理解、寻优效果好且收敛速度快,被认为是解决实际优化问题最有效的一种方法^[30]。

2014年,Mirjalili等人提出了一种新的群智能优化算法——灰狼优化算法(Grey Wolf Optimizer,GWO)^[31],灰狼优化算法具有参数依赖性低、寻优精度高等优点。目前,GWO算法在许多领域得到了广泛的应用。Tikhamarine等人^[32]为了提高SVR在月经流量预测中的精度,利用GWO算法对SVR参数进行寻优,提出了基于WSVR-GWO的月经流量预测模型;Nayak等人^[33]提出使用GWO算法对变化天气条件下光伏组件的参数进行估计,与PSO算法相比,GWO算法寻优性能更好;Qin等人^[34]为了准确估算电动公交车的能耗,首先利用GWO算法对所提模型的超参数进行寻优,然后根据最优参数建立基于GWO-SVR的预测模型,该模型性能优于GA-BP以及利用网格搜索优化的SVR模型;黄波等人^[35]提出一种基于灰狼算法优化深度置信网络的医院网络异常流量识别方法,该方法提高了医院网络异常流量识别精度;Chandar等人^[36]考虑到Elman神经网络超参数选择具有不确定性,为了解决这一问题,采用灰狼优化算法对Elman超参数进行寻优,根据最优参数建立了基于GWO-ENN的股票价格预测模型。该模型可以准确预测股票价格,并且优于其他基准模型。

与其他智能优化算法一样,在处理复杂的高维问题时,灰狼优化算法也存在着一些无法避免的缺陷,例如,种群缺乏多样性、局部和全局搜索能力不平衡以及过早收敛等问题。目前,国内外大量研究学者从不同角度对传统灰狼优化算法进行了改进。

为了弥补灰狼优化算法初始化种群缺少多样性这一不足。陈长倩等人^[36]引入高斯分布曲线对种群进行初始化以获得更好的性能;徐辰华等人^[38]使用 Cat 混沌映射提高了灰狼优化算法的初始解质量;Kohli 等人^[39]通过对 10 种不同混沌映射的研究发现,适当的混沌映射可以增强灰狼优化算法寻优性能。

为了保持灰狼优化算法局部开发能力和全局探索能力之间的平衡。谈发明等人^[40]利用非线性递减的收敛因子来协调灰狼优化算法的开发和探索能力;李阳等人^[41]为了提高算法寻优成功率,将线性减小的收敛因子改成分段可调节的收敛因子;徐辰华等人^[42]引入正弦函数平衡传统灰狼优化算法的全局探索能力和局部开发能力。

为了降低灰狼优化算法迭代后期陷入局部最优的风险。龙文等人^[43]基于差分进化和粒子群优化算法,提出了一种新的种群个体位置更新方式,增强了算法寻优能力;莫艳红等人^[44]将莱维飞行策略应用于灰狼优化算法,以降低算法后期陷入局部最优的风险;黄晨晨等人^[45]为了防止传统灰狼算法出现早熟现象,利用随机蛙跳算法中最差位置改变机制帮助灰狼优化算法跳出局部最优;Jia 等人^[46]引入加权策略,动态地给优势狼分配权值,从而保证种群可以跳出局部最优解;Gao 等人^[47]提出了一种具有可变权重的灰狼优化算法——VW-GWO,提高了算法寻优精度。

综上所述,灰狼优化算法在处理简单问题时具有参数依赖性低、模型原理简单以及寻优性能好等优点。但是在处理复杂问题时,传统灰狼优化算法也存在不足,通过分析现有的改进算法,可以发现目前所提出的改进算法主要是从种群初始化、收敛因子以及狼群位置这三个方面对灰狼优化算法进行调整。相比传统灰狼优化算法,这些改进算法虽然在一定程度上提升了灰狼优化算法的寻优性能,但是灰狼优化算法仍存在较大的改进空间。

1.2.3 图卷积神经网络研究现状

众所周知,卷积神经网络非常擅长结构化数据。但是,在日常生活中除了有结构化数据,还存在着大量的非结构化数据,比如社会网络信息、交通网络信息、地理结构信息等。为了处理此类数据,图神经网络(Graph Neural Network,GNN)^[48]应运而生,图神经网络是一种能对非结构化数据或者图结构化数据进行深度学习的方法。图卷积神经网络(Graph Convolutional Network, GCN)是 GNN 的一个重要分支,2013 年,Bruna 等人提出了第一个图卷积神经网络^[49]。

图卷积神经网络与卷积神经网络一样,都可以用来处理数据。不同的是,图卷积神

经网络的处理对象是图结构化数据。图卷积神经网络在处理图结构化数据时可以同时考虑节点的特征信息以及节点间的结构信息,从而实现节点预测、节点分类和边预测等众多任务。近些年,图卷积神经网络在很多领域都取得了优异的成绩。例如,Gonzalez 等人^[50]将节点结构信息和特征信息作为输入,将食物分子的抗癌可能性作为模型输出,提出了一种基于图卷积神经网络的抗癌食物分子预测模型;刘臣等人^[51]为了预测在线知识社区中用户之间的行为,首先构建了以用户为节点、用户回答为边的图结构化数据,然后提出了基于图卷积神经网络的预测模型。与其他预测方法相比,基于图卷积网络的预测模型预测结果最好;Yu 等人^[52]考虑到目前交通流量预测模型缺少挖掘数据的时空相关性,为了提高交通流量预测准确率,建立基于图卷积神经网络模型的交通流量预测模型。

由于传统模型(如支持向量机、随机森林等)只将数据特征信息作为模型输入,而图卷积神经网络可以同时利用节点的邻接矩阵和特征矩阵来强调节点相关性。因此,图卷积神经网络对数据相关性的挖掘能力要远远优于传统模型。

1.3 论文主要研究内容

在课题国内外研究现状基础上,论文对不同地质构造下的煤矿涌水量预测问题进行了深入研究,论文主要研究内容如下:

(1) 针对简单地质构造下的煤矿涌水量主要受含水层水压影响,传统预测方法难以准确表征水压与涌水量之间的强非线性映射关系的问题,提出了一种基于混合策略改进灰狼算法优化支持向量机的煤矿涌水量预测模型(MSGWO-SVR)。首先,将精英反向学习机制、非线性收敛因子以及高斯变异策略引入传统灰狼优化算法,提出了基于混合策略改进的灰狼优化算法(MSGWO),从而有效避免传统灰狼优化算法收敛精度低、易陷入局部极值等问题;其次,利用 MSGWO 算法对支持向量机(SVR)模型的惩罚因子 C 和核参数 μ 进行寻优,从而提高 SVR 模型的自学习能力和非线性拟合能力;最后,根据最优参数组合建立基于 MSGWO-SVR 的煤矿涌水量预测模型。为了验证模型有效性,以山东省兖州矿业集团下属 A 矿为例,利用 MSGWO-SVR 模型对煤矿涌水量进行预测,并将其预测结果与传统预测模型(Adaboost、XGboost、RF、KNN 和 LSTM)以及 SVR 和 GWO-SVR 模型的预测结果进行对比。

(2) 针对复杂地质构造下的煤矿涌水量影响因素多,因素之间存在复杂的耦合关系,浅层模型对数据挖掘深度不够,难以实现精准预测的问题,提出了一种基于图卷积神经网络和双向长短期记忆神经网络的煤矿涌水量预测模型(CNN-GCN-BiLSTM)。首先,为了获得原始数据的有效表征,采用二维卷积神经网络(2D-CNN)提取数据局部特征;其次,为了深入挖掘输入变量间的关联关系,构建以涌水量影响因素为节点、皮尔逊相

关系数为边的图数据,利用图卷积神经网络(GCN)提取数据空间特征;最后,通过双向长短时记忆神经网络(BiLSTM)对提取到的特征信息所构成的序列数据进行双向特征学习,通过全连接层输出煤矿涌水量预测值。为了验证模型有效性,以山东省兖州矿业集团下属 B 矿为例,利用 CNN-GCN-BiLSTM 模型对煤矿涌水量进行预测,并将其预测结果与传统预测模型(Adaboost、XGboost、RF、KNN 和 SVR)以及基准模型(CNN-LSTM 和 CNN-GCN-LSTM)的预测结果进行对比。

1.4 论文组织结构

本论文共有五章,各章节所包含内容如下:

第一章为绪论。首先阐明了选题背景和意义;其次分别介绍了煤矿涌水量预测方法、传统灰狼优化算法以及图卷积神经网络的国内外研究现状,并对国内外研究现状所存在的问题进行了评述;最后阐述了论文主要研究内容和论文组织结构安排。

第二章为相关理论基础。首先分析了处于不同地质构造下的煤矿涌水量影响因素;其次描述了传统灰狼优化算法的基本原理和主要步骤,并给出了算法流程图。此外,还分析了影响传统灰狼优化算法性能的因素;最后对 SVR 模型、CNN 网络、GCN 网络以及 LSTM 网络的基本原理进行了简单介绍,为后序章节提供了理论支撑。

第三章为基于 MSGWO-SVR 的煤矿涌水量预测模型。首先详细描述了 MSGWO 算法的改进策略和基本流程;接着在 6 个测试函数上进行了仿真实验,验证了 MSGWO 算法的有效性;然后建立了基于 MSGWO-SVR 的煤矿涌水量预测模型,并对该模型框架和流程进行了介绍;最后基于煤矿真实涌水数据集进行了对比实验,对本章所提的 MSGWO-SVR 模型性能进行了验证和分析。

第四章为基于 CNN-GCN-BiLSTM 的煤矿涌水量预测模型。首先介绍了模型框架;接着详细阐述了模型中核心层的网络结构;然后描述了模型的训练和预测过程,并给出了相应的流程图;最后基于煤矿真实涌水数据集进行了对比实验,对本章所提的 CNN-GCN-BiLSTM 模型性能进行了验证和分析。

第五章为总结与展望。主要对论文主要研究内容和成果进行了客观的自我总结,并提出了今后需要继续优化和改进的地方。

2 相关理论基础

本章将对论文研究内容所涉及的技术和理论进行介绍,主要包括煤矿涌水量影响因素、灰狼优化算法(Grey Wolf Optimizer,GWO)、支持向量回归机(Support Vector Regression,SVR)、卷积神经网络(Convolutional Neural Networks,CNN)、图卷积神经网络(Graph Convolutional Neural Network,GCN)、长短期记忆神经网络(Long Short-Term Memory,LSTM)以及双向长短期记忆神经网络(Bi-directional Long Short-Term Memory,BiLSTM),为后续建立煤矿涌水量预测模型提供了理论支撑。

2.1 煤矿涌水量影响因素分析

煤矿涌水量是煤矿正常开采的重要指标之一。在煤矿建井和生产时,相关人员应该查明煤矿水文地质类型和预计开采矿井涌水量,根据涌水量的变化情况采取具有针对性的措施。

在煤矿实际开采过程中,煤矿涌水量成因复杂,影响涌水量的因素会因煤矿所处地区的地质构造不同而不同。在实际开采过程中,不同煤矿的地理位置及地质条件不同,导致其地质构造相差较大,论文将煤矿所处地区的地质构造分为简单地质构造和复杂地质构造。其中,简单地质构造是指煤矿所处区域内的岩层和煤层的走向起伏变化小、煤层倾角小且接近水平、断层稀少且褶皱规则;复杂地质构造是指煤矿所处区域内的岩层和煤层的走向起伏变化大、倾斜角度大、断层较多且褶皱和断裂十分发育。

分析煤矿涌水量影响因素是准确预测涌水量的前提条件。通过研究已有理论,如“下三带”理论^[53]、原位张裂理论和零位破坏理论^[54]、薄板模型理论^[55-56]、“强渗通道”说^[57]、“岩水应力关系”说^[58]以及KS关键层理论^[59],下面将对这两种地质构造下的煤矿涌水量影响因素进行分析。

当煤矿所处地区属于简单地质构造时,含水层水压是决定煤矿涌水量大小的最基础、最主要的因素。水压是煤矿涌水的动力来源,煤矿含水层水压增大会导致岩层有效应力减小,岩层强度会降低且容易被破坏^[60],在含水层厚度确定的情况下,水压的大小与煤矿涌水量的多少成正比。

当煤矿所处地区属于复杂地质构造时,煤矿在开采过程中会遇到裂隙、断层等现象。此时,煤矿涌水量不仅仅受水压影响,还会受地质构造和开采活动的影响,具体包括工作面推进距离、导水裂隙带发育高度、煤层倾角以及断层落差。其中,采煤工作面推进距离的变化会导致煤层所处的地质结构发生变化,从而会影响涌水量的大小;导水裂隙带是岩体垮落带和裂隙带的统称,煤层在开采之后会受采动影响而发生变形,严重时煤

层将被破坏，从而会形成垮落带、裂隙带以及下沉带^[61]。导水裂隙带会使岩层透水性变大，而且裂隙带的存在直接为涌水提供了导水通道。无论在开采的哪个阶段，导水裂隙带对涌水量都起着至关重要的作用；煤层倾角即煤层层面与水平面的夹角，煤层倾角会直接影响破坏带深度，从而影响煤层涌水量大小，孙少华等人通过数值模拟实验得出当煤层倾角在 0~12 度时，破坏带深度增长率为 0.13，当煤层倾角在 12~30 度时，破坏带深度增长率会增加到 0.28^[62]；断层在矿井中分布位置多，且规模不等、大小不一。断层是一个天然的导水通道，它可以破坏煤层的稳定性，导致各含水层之间发生联系。此外，在煤矿实际开采过程中，断层与其他影响因素会相互作用，从而增大其他因素对涌水的影响程度，文献[63]通过实验分析表明，落差大、形态起伏明显的断层比落差小的断层更容易引起突水事故的发生。

2.2 灰狼优化算法

2.2.1 算法基本思想

灰狼优化算法是基于自然界中灰狼的捕猎行为以及社会等级提出的一种群智能优化算法。

在自然界中，灰狼是一种喜欢群居并且处于食物链顶端的动物。每个灰狼种群通常由四类灰狼组成，分别是 α 狼、 β 狼、 γ 狼以及 ω 狼，种群中每一类灰狼都有着其特定的作用。其中， α 狼是狼群中的主要领导者（决策者），狼群中的一些重要的事情由 α 狼决定，如狩猎、休息时间和地点等； β 狼是 α 狼的接班人，在灰狼群日常活动中， β 狼需要服从和协助 α 狼； γ 狼主要负责监视领地边界并在种群有危险时及时通知其他成员， γ 狼需要服从于 α 狼和 β 狼； ω 狼只需要跟随其他社会等级的狼。 ω 狼看起来在灰狼群体中没有太大的作用，但是 ω 狼是平衡种群内部关系的关键组成部分。灰狼群的社会等级具体如图 2.1 所示。




图 2.1 灰狼的社会等级制度

灰狼严格细致的社会等级保证了它们在捕猎时具有较高成功率。灰狼的狩猎过程可

以描述为：当狼群发现猎物之后，会一直追随并紧跟猎物，狼群到达猎物附近后，迫使猎物停止逃跑，然后狼群会对猎物发起攻击，至此狩猎行为完成。在实现灰狼优化算法时，需要对灰狼的社会等级和狩猎行为进行建模，其中，狩猎行为又被细分为包围猎物、打猎以及攻击猎物。

(1) 社会等级

整个狼群的最适合解决方案为 α 狼，然后是 β 狼和 γ 狼，其余的候选解决方案属于 ω 狼。灰狼优化算法在迭代过程中， ω 狼主要根据 α 狼、 β 狼以及 γ 狼的位置来更新自身位置，从而准确找到猎物。

(2) 包围猎物

狩猎机制的第一阶段是包围猎物，包围猎物这一行为对应的数学模型如公式(2.1)~公式(2.5)所示。

$$X(t+1) = X_p(t) - A \cdot D \quad (2.1)$$

$$D = C \cdot X_p(t) - X(t) \quad (2.2)$$

$$A = 2 \cdot a \cdot r_1 - a \quad (2.3)$$

$$C = 2 \cdot r_2 \quad (2.4)$$

$$a = 2 - \frac{2t}{t_{\max}} \quad (2.5)$$

式中， t ——当前迭代次数； $t_{\max}$ ——最大迭代次数； $\cdot$ ——hadamard 乘积； $X_p(t)$ ——猎物的当前位置； $X(t)$ ——灰狼的当前位置； A 和 C ——控制参数； D ——包围步长； r_1, r_2 —— $[0, 1]$ 中的随机数； a ——收敛因子。

(3) 打猎

灰狼在狩猎过程中无法预先知道猎物位置。因此，狼群需要通过 α 狼、 β 狼以及 γ 狼这三头优势狼的位置来更新自身位置，从而保证整个狼群最终都能够到达猎物所在位置。灰狼位置更新过程如图 2.2 所示，位置更新数学模型如公式(2.6)~公式(2.8)所示。

$$\begin{cases} D_\alpha = C_1 X_\alpha(t) - X(t) \\ D_\beta = C_2 X_\beta(t) - X(t) \\ D_\gamma = C_3 X_\gamma(t) - X(t) \end{cases} \quad (2.6)$$

$$\begin{cases} X_1 = X_\alpha - A_1 D_\alpha \\ X_2 = X_\beta - A_2 D_\beta \\ X_3 = X_\gamma - A_3 D_\gamma \end{cases} \quad (2.7)$$

$$X(t+1) = \frac{1}{3}(X_1 + X_2 + X_3) \quad (2.8)$$

式中, $D_i (i = \alpha, \beta, \gamma)$ ——当前灰狼和 α 狼、 β 狼以及 γ 狼的距离; A 和 C ——控制参数; $X(t+1)$ ——当前灰狼 X 下一时刻的位置。




图 2.2 GWO 算法中灰狼位置更新示意图

(4) 攻击

当猎物停止移动时,灰狼将通过攻击行为来完成狩猎工作。在灰狼优化算法中,参数 A 决定着灰狼是远离猎物还是攻击猎物,当 $|A| > 1$ 时,为了寻找更优质的猎物,狼群会扩大搜索范围;当 $|A| < 1$ 时,灰狼会在所确定的搜索范围内进行更为精准的寻找,从而确定猎物的准确位置,并对其发起攻击。

2.2.2 算法基本流程

灰狼优化算法在寻优初期需要产生一定数量的种群个体,然后从中选取三头适应度值最优的灰狼,将其定为 α 狼、 β 狼以及 γ 狼,种群中剩余的灰狼则为 ω 狼。在寻优过程中, ω 狼则需要根据 α 狼、 β 狼和 γ 狼的位置不断更新调整自身位置,最终到达最优猎物的位置。

灰狼优化算法具体步骤如下:

Step1: 初始化灰狼种群数 N 以及最大迭代次数 t ;

Step2: 初始化参数 A 、 C 和 a ,并令 $t = 0$;

- Step3: 计算种群所有个体适应度, 并选出最优解 X_α 、优解 X_β 和次优解 X_γ ;
- Step4: 根据公式(2.6)~公式(2.8)更新狼群位置;
- Step5: 根据公式(2.3)~公式(2.5)更新参数 A 、 C 和 a 的值;
- Step6: 计算种群所有个体适应度, 并更新 X_α 、 X_β 和 X_γ 的值;
- Step7: 迭代次数 $t + 1$;
- Step8: 判断算法当前迭代次数是否到达最大迭代次数, 若达到则进行下一步; 否则回到 Step4, 算法继续进行寻优;
- Step9: 输出最优解 X 。
- 灰狼优化算法流程图如图 2.3 所示。




图 2.3 传统灰狼优化算法流程图

2.2.3 算法影响因素分析

灰狼优化算法具有原理简单、参数依赖性低以及寻优精度高等优点。但是,在处理复杂的高维度问题时灰狼优化算法性能会有所下降,算法会出现种群缺乏多样性、局部和全局搜索能力不平衡以及过早收敛等问题。导致传统灰狼优化算法出现上述问题的原因主要有以下几点:

(1) 种群初始化

合适的初始化种群对于算法寻优准确性以及算法收敛速度至关重要。在灰狼优化算法的初始化种群中,如果初始化的优势狼刚好位于猎物附近,那么狼群就能以较快的速度逼近猎物并将更多的精力用于寻找猎物的精准位置。但是,在传统灰狼优化算法中,初始化种群是随机生成的,这种初始化方法效果较差,难以保证种群质量。

(2) 收敛因子

在寻优过程中,灰狼优化算法主要利用全局探索和局部开发这两个阶段来寻找问题的全局最优解。算法在全局探索阶段需要确定猎物搜索范围,如果搜索范围过小,则会导致算法错失全局最优解,最终的寻优结果会停滞在局部最优解附近;算法在局部开发阶段则需要在有限搜索范围内精确确定问题的最终解,如果此阶段时间过长,则会导致算法收敛时间产生不必要的增加。因此,保持全局探索能力和局部开发能力的适当平衡是提高灰狼优化算法性能的关键。

在灰狼优化算法中主要通过收敛因子 a 来平衡算法的全局探索能力和局部开发能力。在算法迭代过程中,收敛因子 a 从2线性减小到0,但是,在实际应用中,线性减小的收敛因子 a 无法满足复杂问题的寻优过程。

(3) α 狼、 β 狼以及 γ 狼位置

在传统灰狼优化算法中,灰狼主要根据 α 狼、 β 狼和 γ 狼的位置来调整自身位置。如果在算法迭代后期, α 狼、 β 狼和 γ 狼陷入局部最优,那么会使算法出现早熟收敛的现象,导致算法最终无法得到问题的最优解,只能搜索到较优解或次优解。

2.3 支持向量回归

1995年,Vapnik提出了支持向量机(SVM)^[64]。根据处理的问题不同,支持向量机又被具体分为支持向量分类(SVC)和支持向量回归(SVR)两种类型。论文所研究的煤矿涌水量预测问题属于回归问题,因此,接下来针对SVR进行详细介绍。

2.3.1 模型基本原理

设有一训练集 $\{x, y\} = \{(x_1, y_1), \dots, (x_i, y_i)\}$,其中, x_i, y_i 分别为模型的输入数据和输

出数据, 利用 SVR 模型可以对输入数据和输出数据之间的关系进行描述, SVR 模型定义如公式(2.9)所示。

$$f(x) = w^T \beta(x) + b \quad (2.9)$$

式中, $\beta(\cdot)$ ——非线性映射函数; w ——权值; b ——偏置量。

为了判断预测结果 $f(x)$ 和实际结果 y 的误差, 引入不敏感损失函数, 函数如公式(2.10)所示。

$$L(f(x), y, \varepsilon) = \begin{cases} 0, & |y - f(x)| \leq \varepsilon \\ |y - f(x)|, & |y - f(x)| > \varepsilon \end{cases} \quad (2.10)$$

式中, $f(x)$ ——预测值; y ——真实值; ε ——损失函数。

若预测结果 $f(x)$ 和实际结果 y 之间的误差绝对值不超过 ε , 则认为不敏感损失为 0 并接收该不敏感损失。

权值 w 和 b 最小化有利于 SVR 模型的训练。因此, 利用最小化结构风险函数对公式(2.10)中的 w 和 b 进行求解, 求解公式如公式(2.11)所示。

$$\begin{cases} \min \frac{1}{2} \|w\|^2 \\ \begin{cases} y_i - w\beta(x_i) - b \leq \varepsilon \\ w\beta(x_i) + b - y_i \leq \varepsilon \end{cases} \end{cases} \quad (i = 1, 2, \dots, n) \quad (2.11)$$

如果无法满足上述约束条件, 则引入松弛变量 ξ_i, ξ_i^* , 具体如公式(2.12)所示。

$$\begin{cases} \min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) \\ \begin{cases} y_i - w\beta(x_i) - b \leq \varepsilon + \xi_i \\ w\beta(x_i) + b - y_i \leq \varepsilon + \xi_i^*, (i = 1, 2, \dots, n) \\ \xi_i \geq 0, \xi_i^* \geq 0 \end{cases} \end{cases} \quad (2.12)$$

式中, ξ_i, ξ_i^* ——松弛变量; C ——惩罚因子。

利用拉格朗日函数将最优化问题变换成对偶形式, 与此同时引入核函数。这一过程过程如公式(2.13)和公式(2.14)所示。

$$\left\{ \begin{array}{l} \max_{a, a^*} \left[-\frac{1}{2} \sum_{i,j=1}^n (a_i - a_i^*) (a_j - a_j^*) K(x_i, x_j) - \varepsilon \sum_{i=1}^n (a_i + a_i^*) + \sum_{i=1}^n y_i (a_i - a_i^*) \right] \\ s.t. \left\{ \begin{array}{l} \sum_{i=1}^n (a_i - a_i^*) = 0 \\ a_i, a_i^* \in [0, C] \end{array} \right. \end{array} \right. \quad (2.13)$$

$$K(x_i, x_j) = \beta(x_i) \beta(x_j) \quad (2.14)$$

式中, a_i, a_j, a_i^*, a_j^* ——拉格朗日乘子; $K(\cdot)$ ——核函数。

最终, SVR 模型可以用公式(2.15)所示的回归函数表示。

$$f(x) = \sum_{i=1}^n (a_i - a_i^*) K(x_i, x_j) + b \quad (2.15)$$

2.3.2 模型性能分析

利用 SVR 模型预测煤矿涌水量的基本思想是通过一组非线性传递函数将影响涌水量变化的数据映射到更高维的特征空间, 然后在该空间利用所构建的线性回归函数对涌水量进行预测。这一过程的实现主要依靠于 SVR 模型中的核函数, 因此, 核函数的选择直接影响着 SVR 模型的泛化能力和预测精度, 是确保 SVR 模型性能的关键。

目前, 常用的核函数有线性核函数、多项式核函数和高斯径向基函数(RBF)。其中, RBF 核函数具有参数依赖性低以及可以将样本映射到更高维特征空间等优点。因此, 论文在利用 SVR 模型进行煤矿涌水量预测时, 选择 RBF 作为 SVR 模型的核函数。RBF 函数如公式(2.16)所示。

$$K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|}{2\mu^2}\right) \quad (2.16)$$

式中, μ ——高斯核函数的宽度系数。

SVR 模型的性能取决于其体系结构, 在将模型的最佳超参数提供给模型之前, 无法获得模型的最优性能。当利用 RBF 核函数训练 SVR 模型时, 惩罚因子 C 以及高斯核函数的宽度系数 μ 对 SVR 模型性能影响最大。惩罚因子 C 用于平衡模型复杂程度和训练误差, 惩罚因子 C 较大会导致模型过度拟合数据, 使得模型具有较差的泛化能力; 宽度系数 μ 反应了训练数据样本的分布情况, μ 越大, 训练数据中单个样本的影响范围就越大。目前, SVR 模型超参数的选取通常依赖于随机搜索法或网格搜索法, 此种方法不仅费时费力而且所求得的参数易陷入局部最优。

2.4 卷积神经网络

卷积神经网络是一种常用的深度学习模型。卷积神经网络主要由输入层、隐藏层以及输出层组成，其中隐藏层主要包括卷积层、池化层以及全连接层^[65]。典型的卷积神经网络结构如图 2.4 所示。




图 2.4 卷积神经网络结构图

2.4.1 卷积层

通常，卷积神经网络中包含一个或多个卷积层。在卷积层中主要利用卷积核对原始输入数据进行卷积操作，从而提取原始数据的局部特征。一个卷积核只能提取到输入数据的一种局部特征。通过对输入数据应用不同的卷积核，在卷积操作之后就可以得到原始数据的多种局部特征。卷积过程如图 2.5 所示，卷积操作如公式(2.17)所示。

$$\mathbf{C} = \sigma(\mathbf{W}\mathbf{X} + b) \quad (2.17)$$

式中， $\mathbf{C}$ ——提取特征； $\sigma(\cdot)$ ——Relu($\cdot$)激活函数； $\mathbf{W}$ ——权重矩阵； $\mathbf{X}$ ——输入矩阵； b ——偏置量。




图 2.5 卷积操作示意图

卷积层最主要的两个特性为局部感知和权值共享。

(1) 局部感知

局部感知是指在卷积神经网络中每层的神经元节点不与上一层的所有神经元节点

相连，而只与部分神经元节点相连。采用局部感知可以有效地减少网络参数个数，从而可以加快网络学习速度，同时降低模型过拟合风险。

(2) 权值共享

为了更好地提取数据特征，通常会在卷积层中会设置多个卷积核。但是，卷积核数目的增多会导致网络计算量增大。因此，在卷积神经网络中规定在对数据同一特征进行提取时，所有卷积核的参数保持一致。采用权值共享可以减少模型参数量，降低模型复杂程度。

2.4.2 池化层

池化层(Pooling)也被称为下采样层，实际上它是一种形式的降采样，通常添加在卷积层之后。添加池化层主要有两个作用，首先，池化层在保留主要数据特征的同时减少网络参数；其次，池化层的存在可以减少卷积层对位置的过度敏感性，使得特征的绝对位置不再重要，关注特征的相对位置即可。因此，添加池化层可以有效降低网络在学习过程中的计算成本，防止模型出现过拟合现象，同时可以使数据具有一定的不变性。

池化层在保持原有特征的基础上最大限度地将数组的维数变小。目前，常用的两种池化方式为：最大池化(Max Pooling)和平均池化(Average Pooling)，其中使用最大池化得到的特征矩阵由池化窗口内的最大值组成；而使用平均池化得到的特征矩阵则是由池化窗口内所有特征值的平均值组成的。一般如果不做特定选择，池化方式默认选择最大池化。这两种方法的池化过程如图 2.6 所示。




图 2.6 池化过程示意图

2.4.3 全连接层

全连接层(Fully Connected Layers,FC)主要用于将卷积层和池化层学习到的高级特征进行整合并得到最终输出。全连接层一般位于卷积神经网络的尾部,全连接层的存在可以有效提高数据拟合精度,减少由于特征不同位置对分类预测结果所带来的影响,进一步增强了整个网络的鲁棒性。

2.4.4 激活函数

激活函数对神经网络的性能起着至关重要的作用,如果神经网络中没有添加激活函数,那么神经网络就变成了线性模型,网络输出只是输入的线性组合。激活函数的存在可以建立网络输入和输出之间的非线性关系,让网络具备处理非线性问题的能力。

目前,常用的激活函数是 Sigmoid 函数、Tanh 函数以及 ReLu 函数。Sigmoid 函数表达式如公式(2.18)所示,函数曲线如图 2.7 所示。

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2.18)$$




图 2.7 Sigmoid 激活函数

从图 2.7 可以看出,Sigmoid 激活函数输出在 $[0,1]$ 区间内,函数导数恒小于 1。目前,Sigmoid 激活函数在实际应用中使用较少,主要是因为 Sigmoid 激活函数存在以下三个缺点:其一,当输入趋近于无穷大或是无穷小时,Sigmoid 函数导数会趋近于 0。因此,神经网络在反向传播梯度时会产生梯度消失或梯度爆炸问题;其二,由于 Sigmoid 不是一个以 0 为中心对称的函数。因此,Sigmoid 函数收敛速度比较缓慢;其三,Sigmoid 函数涉及指数运算,因此,计算量较大。

Tanh 激活函数如公式(2.19)所示,函数曲线如图 2.8 所示。

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2.19)$$




图 2.8 Tanh 激活函数

从图 2.8 可以看出, Tanh 激活函数输出在 $[-1,1]$ 区间内, 而且 Tanh 是一个关于 0 点中心对称的函数。因此, Tanh 激活函数性能会优于 Sigmoid 激活函数。但是, 使用 Tanh 激活函数仍然会出现梯度消失或梯度爆炸问题。此外, Tanh 激活函数也存在指数运算, 使用 Tanh 函数计算量也较大。

目前, 卷积神经网络中常用的激活函数是 ReLu 函数, ReLu 激活函数如公式(2.20)所示, 函数曲线如图 2.9 所示。

$$f(x) = \max(0, x) \quad (2.20)$$




图 2.9 ReLu 激活函数

从图 2.9 可以看出, 当输入大于 0 时, ReLu 激活函数的导数恒为 1。因此, ReLu 函数可以有效缓解梯度消失或梯度爆炸问题。此外, ReLu 函数具有线性以及非饱和特性, 这使得 ReLu 激活函数的收敛速度快于 Sigmoid 激活函数和 Tanh 激活函数。

2.5 图卷积神经网络

在日常生活中, 除了存在简单的结构化数据, 还存在着大量的非结构化数据(图数据)。卷积神经网络可以很好地处理结构化数据。但是, 由于非结构化数据存在不规则

的数据拓扑结构。因此，卷积神经网络无法直接对非结构化数据进行特征提取。为了解决这一问题，提出了图卷积神经网络^[66]，典型的图卷积神经网络结构如图 2.10 所示。




图 2.10 图卷积神经网络结构图

图卷积神经网络是一种可以捕捉非欧式结构数据空间相关性的有效方法。图卷积神经网络在挖掘数据特征时不仅可以考虑节点自身的信息，而且还可以考虑节点之间结构信息。

图 G 由边集合 E 和顶点集合 V 组成，记作 $G=(E,V)$ 。图 G 的邻接矩阵 $\mathbf{A}$ 是节点间的关系组成，图 G 的特征矩阵 $\mathbf{F}$ 由节点特征组成。矩阵 $\mathbf{A}$ 和 $\mathbf{F}$ 便是图卷积神经网络的输入矩阵，输入之后进行相关的卷积操作。图卷积操作如公式(2.21)和公式(2.22)所示。

$$\hat{\mathbf{A}} = \mathbf{A} + \mathbf{I} \quad (2.21)$$

$$\mathbf{H}^{i+1} = f(\mathbf{H}^i, \mathbf{A}) = \sigma \left(\hat{\mathbf{D}}^{-\frac{1}{2}} \hat{\mathbf{A}} \hat{\mathbf{D}}^{-\frac{1}{2}} \mathbf{H}^i \mathbf{W}^i \right) \quad (2.22)$$

式中， $\mathbf{H}^i$ ——第 i 层的特征矩阵， $\mathbf{H}^0 = \mathbf{F}$ ； $\mathbf{A}$ ——无向图的邻接矩阵； $\mathbf{I}$ ——单位矩阵； $\hat{\mathbf{D}}$ ——度矩阵； $\mathbf{W}^i$ ——权重矩阵； $\sigma(\cdot)$ 函数—— $\text{Relu}(\cdot)$ 激活函数。

图卷积神经网络的卷积层数越多，每个节点的感受野就越大，图卷积神经网络能够提取到的数据特征信息就越多。多层图卷积神经网络示意图如图 2.11 所示，通过图 2.11 可以看出，原本节点 1 只能获取邻接节点 2、3 和 4 的节点信息，在进行 2 次图卷积操作之后，实现了所有节点的信息交换。




图 2.11 多层图卷积神经网络示意图

2.6 长短期记忆神经网络

神经网络的出现为许多复杂问题提供了解决方法和思路。但是，传统的前馈神经网络无法很好地处理序列和时间序列问题，循环神经网络的出现解决了这一问题。随着对循环神经网络的深入研究，长短期记忆神经网络和双向长短期记忆神经网络的诞生解决了简单循环神经网络在处理长序列数据时出现的梯度消失和梯度爆炸问题。

2.6.1 长短期记忆神经网络

传统的神经网络无法很好地处理前后输入数据具有关联关系的问题，为了能够很好地处理此类问题。在 1982 年，Saratha Sathasivam 提出了循环神经网络^[67]。典型的循环神经网络结构如图 2.12 所示，在图 2.12 中， X_t 、 Y_t 和 A 分别为输入、输出以及当前网络状态。




图 2.12 循环神经网络结构图

循环神经网络循环神经网络解决了传统神经网络的不足，它可以将上一时刻（序列）

的输入信息持久化保存, 并利用其对当前时刻(序列)的输出产生影响。循环神经网络在处理时序数据时展现出了优越的学习能力。但是, 当循环神经网络处理较长的时序数据时, 循环神经网络会受到梯度消失或梯度爆炸问题的困扰, 从而限制了循环神经网络学习数据的长期依赖关系。

为了克服循环神经网络的不足, 1997 年, 由 Hochreiter 和 Schmidhuber 提出了长短期记忆神经网络^[68]。长短期记忆神经网络是一种特殊的循环神经网络, 它能够学习长期依赖关系。具体地说, 长短期记忆神经网络就是在循环神经网络中添加了一个关键的记忆单元, 长短期记忆神经网络可以通过记忆单元存储有用的信息并减少学习错误。典型的长短期记忆神经网络结构如图 2.13 所示。




图 2.13 长短期记忆神经网络结构图

长短期记忆神经网络之所以能够记忆长短期的信息, 是因为它由三个“门”组成: 输入门、遗忘门以及输出门。“门”的结构的存在可以去除和增加信息到神经元的能力。长短期记忆神经网络工作步骤如公式(2.23)~公式(2.28)所示。

$$I(t) = \sigma(\mathbf{W}_i[h(t-1), X(t)] + b_i) \quad (2.23)$$

$$F(t) = \sigma(\mathbf{W}_f[h(t-1), X(t)] + b_f) \quad (2.24)$$

$$O(t) = \sigma(\mathbf{W}_o[h(t-1), X(t)] + b_o) \quad (2.25)$$

$$\hat{I}(t) = \tanh[(\mathbf{W}_i h(t-1), X(t)) + b_i] \quad (2.26)$$

$$C(t) = F(t) \cdot C(t-1) + I(t) \cdot \hat{I}(t) \quad (2.27)$$

$$h(t) = O(t) \cdot \tanh(C(t)) \quad (2.28)$$

式中, $\mathbf{W}$ ——权重矩阵; b ——偏向量; $\sigma(\cdot)$ ——sigmoid($\cdot$)激活函数, 用于更新或者遗忘数据; $\tanh(\cdot)$ ——双曲正切激活函数。

2.6.2 双向长短期记忆神经网络

双向长短期记忆神经网络是对长短期记忆神经网络的改进。双向长短期记忆神经网络的基本思想是每一个输入序列正向和反向都经过一次长短期记忆神经网络, 这样的双向结构可以提供给输出层输入序列每个结点完整的过去和未来的上下文信息, 从而可以保留更多的数据特征。双向长短期记忆神经网络由前向 LSTM 层和后向 LSTM 层组成, 其中前向 LSTM 层和后向 LSTM 层的工作步骤和标准的 LSTM 一致。典型的双向长短期记忆神经网络结构如图 2.14 所示。




图 2.14 双向长短期记忆神经网络结构图

在图 2.14 中, 前向 LSTM 依次输入样本数据 $X = \{X_1, X_2, \dots, X_n\}$, 输出向量集合 $O_L = \{h_{L1}, h_{L2}, \dots, h_{Ln}\}$; 后向 LSTM 依次输入样本数据 $X = \{X_n, X_{n-1}, \dots, X_1\}$, 输出向量集合 $O_R = \{h_{Rn}, h_{Rn-1}, \dots, h_{R1}\}$, 拼接 h_{Ln} 和 h_{Rn} 得到最终的特征向量 $O = \{[h_{L1}, h_{R1}], [h_{L2}, h_{R2}], [h_{L3}, h_{R3}], \dots, [h_{Ln}, h_{Rn}]\} = \{h_1, h_2, \dots, h_n\}$ 。

2.7 本章小结

本章主要介绍了煤矿涌水量影响因素以及论文中所用到基本理论。首先分别介绍了复杂地质构造和简单地质构造下影响煤矿涌水量的影响; 然后介绍了传统灰狼优化算法算法的基本原理和主要步骤, 并给出了算法流程图, 分析了影响灰狼优化算法性能的因

素。可以看出，在处理复杂的高维问题时，传统灰狼优化算法也会存在不足；随后介绍了支持向量回归模型的基本原理以及核函数的选择，并对影响模型性能的参数进行了分析；接着详细介绍了卷积神经网络中核心层的基本原理以及常用激活函数的优缺点；然后介绍了图卷积神经网络的网络结构，讨论了多层图卷积神经网络在处理数据时的优势。可以看出，图卷积神经网络擅长处理非结构化数据；最后对长短期记忆神经网络和双向长短期记忆神经网络的网络结构进行了介绍。

3 基于 MSGWO-SVR 的煤矿涌水量预测模型

对于地质构造简单的煤矿,水压是煤矿日常生产工作过程中主要监测的数据。煤矿含水层水压是涌水水源的初始动力条件,因此,水压能直接有效地反应出煤矿涌水量大小。考虑到含水层水压与涌水量之间呈现非线性关系,本文选择支持向量回归机(SVR)作为基础预测模型,通过 SVR 建立煤矿含水层水压与煤矿涌水量之间的非线性函数映射关系,针对 SVR 模型参数选定具有盲目性,利用混合策略改进的灰狼优化(MSGWO)算法对 SVR 模型的超参数进行寻优,根据最优参数组合构建基于混合策略改进灰狼算法优化支持向量回归的煤矿涌水量预测模型(MSGWO-SVR)。该模型避免了人为设定参数的局限性,从而可以充分发挥 SVR 模型优异的非线性拟合能力。

3.1 MSGWO 优化算法

灰狼优化算法可以有效地逼近优化问题的最优值,灰狼优化算法具有原理简单、参数依赖性低以及易实现等优点。但是,在处理复杂问题时,传统灰狼优化算法存在易陷入局部极值、种群缺乏多样性以及探索和开发能力不平衡等问题。针对传统灰狼优化算法存在的缺陷,本文提出了一种基于混合策略改进的灰狼优化算法(Mixed Strategy Improved Grey Wolf Optimization,MSGWO)。MSGWO 算法主要从以下三个方面对传统灰狼优化算法进行了改进:首先利用精英反向学习策略完成种群初始化,以增强种群的多样性和质量;然后采用非线性收敛因子来平衡算法的全局探索能力和局部开发能力,同时提高算法的收敛速度;最后利用高斯变异策略保证算法在迭代后期具有跳出局部最优的能力,避免算法出现早熟收敛的现象。接下来的小节将详细介绍 MSGWO 算法的改进策略。

3.1.1 精英反向学习策略

传统灰狼优化算法的初始化种群是随机产生的,通过随机方式所产生的初始化种群缺乏多样性,并且无法保证种群质量。为了降低随机初始化种群对算法的计算复杂度和搜索性能的影响,在灰狼优化算法种群初始化阶段引入了精英反向学习机制。

反向学习(Elite Opposition Based Learning,OBL)^[69]是一种计算智能方案,在 2005 年由 Rahnamayan 等人提出。反向学习的基本思想是同时考虑问题候选解决方案及其相反的解决方案。精英反向学习策略(Elite Opposition Based Learning,EOBL)则是在反向学习的基础上引入了精英个体。假设在 D 维搜索空间存在一精英个体 $E_i = (E_{i1}, E_{i2}, \dots, E_{in})$,则该精英个体的发向解为 $E'_i = (E'_{i1}, E'_{i2}, \dots, E'_{in})$,精英反向解计算方式如公式(3.1)~公式(3.4)所示。

$$E'_i = \eta(da_i + db_i) - E_i, \eta \in [0, 1] \quad (3.1)$$

$$da_i = \min(E_i) \quad (3.2)$$

$$db_i = \max(E_i) \quad (3.3)$$

$$E_i \in [a_i, b_i] \quad (3.4)$$

式中, η ——服从均匀分布的随机数; da_i, db_i ——搜索空间的边界。

精英个体也存在跳出边界 $[a_i, b_i]$ 的可能, 因此需要对越界值进行处理, 处理方式如公式(3.5)所示。

$$E'_i = \text{rand}(a_i, b_i) \quad (3.5)$$

当 $E_i < a_i$ 或 $E_i < b_i$, 公式(3.5)成立。

式中, $\text{rand}(\cdot)$ ——区间 $[a_i, b_i]$ 上的一个随机数。

在 MSGWO 算法中, 利用精英反向学习机制产生初始化种群的具体过程为: 首先, 计算随机初始化种群中每个个体适应度值, 选择适应度值较优的个体组成精英种群; 然后, 利用精英种群生成精英反向种群; 最后, 将精英反向种群个体适应度与当前种群个体适应度进行比较, 从中选择出适应度值较优的个体构成新种群, 进行下一次迭代。

3.1.2 收敛因子非线性调整策略


收敛因子 a 是灰狼优化算法中一个非常重要的参数。它有助于优化算法从全局探索向局部开发过渡, 也有助于保持优化算法在全局探索能力和局部开发能力之间的平衡。在传统灰狼优化算法中, 收敛因子 a 是从 2 线性下降到 0 的。线性下降的收敛因子普适性较差, 无法适应不同种类的优化问题, 而且还会导致算法出现收敛速度较慢的问题。

基于以上分析, 为了维持灰狼优化算法全局探索能力和局部开发能力之间的适当平衡, 把指数函数引入收敛因子更新公式中, 提出了收敛因子非线性调整策略。改进后的收敛因子更新公式如公式(3.6)所示。

$$a = a_{\text{init}} - (a_{\text{init}} - a_{\text{final}}) \left(\frac{t}{t_{\text{max}}} \right)^3 \quad (3.6)$$

式中, a_{init} ——参数初始值; a_{final} ——参数最终值; t ——当前迭代次数; t_{max} ——最大迭代次数。

为了更直观地看到改进后收敛因子 a 的变化情况, 改进前后收敛因子 a 的变化对比如图 3.1 所示。

图 3.1 收敛因子 a 的变化曲线

从图 3.1 可以看出,改进之后的收敛因子 a 在算法迭代过程中是非线性下降,并且在不同迭代阶段具有不同的下降速度。在算法迭代前期,为了保证狼群有足够时间扩大搜索范围,收敛因子 a 的下降速度较慢。到了算法迭代后期,收敛因子 a 的下降速度逐渐加快,这样可以让狼群快速确定猎物的准确位置,同时加快算法的收敛速度。

3.1.3 高斯变异策略

在传统灰狼优化算法中,狼群主要根据 α 狼、 β 狼以及 γ 狼的位置来调整自身位置,从而寻找猎物。在算法后期迭代中,灰狼会聚集在优势狼附近,导致种群多样性变差,如果优势狼在迭代后期陷入了局部最优,那么算法将会有陷入局部极值的风险。

为了解决迭代后期种群多样性差导致算法易陷入局部最优这一问题,将高斯变异^[70]引入狼群位置更新公式中,规定当种群中个体最优适应度值连续 5 代未发生变化时,则对该个体状态进行高斯变异操作。高斯变异定义如公式(3.7)所示。

$$X_i' = X_i + X_i \times N(0, 1) \quad (3.7)$$

式中, X_i ——优势狼的原有状态; $N(0, 1)$ ——服从均值为 0, 方差为 1 的高斯分布的随机向量。

3.2 MSGWO 优化算法基本流程

综上所述,本文提出了一种基于混合策略改进的灰狼优化算法,算法流程图如图 3.2 所示。




图 3.2 MSGWO 算法流程图

MSGWO 算法具体步骤如下:

Step1: 随机初始化灰狼种群, 种群数为 N ; 初始化算法参数 A 、 C 和 a ; 初始化最

大迭代次数 t ，并令 $t=0$ ；

Step2: 根据公式(3.1)~公式(3.4)利用精英反向学习初始化种群；

Step3: 通过计算从种群中选出三头适应度值最优的狼，将其设为最优解 X_α 、优解 X_β 和次优解 X_γ ，若算法的最优适应度值连续 5 代未发生变化，则根据公式(3.7)对最优个体进行高斯变异操作；

Step4: 根据公式(3.6)、公式(2.3)和公式(2.4)依次更新参数 a 、 A 和 C 的值；

Step5: 根据公式(2.6)~公式(2.8)更新狼群位置；

Step6: 迭代次数 $t+1$ ；

Step7: 判断算法当前迭代次数是否达到最大迭代次数，若满足该条件，则进行下一步骤。否则回到 Step3；

Step8: 输出最优解 X 。

3.3 MSGWO 优化算法仿真实验

为了全面衡量 MSGWO 算法性能，本文分别在维度为 2 和 30 时，利用 MSGWO、标准灰狼算法(GWO)、标准粒子群算法(PSO)、标准人工蜂群算法(ABC)、差分进化算法(DE)以及模拟退火算法(SA)对 6 个经典测试函数进行寻优。此外，由于群智能优化算法存在一定的随机性和偶然性，为了保证仿真实验结果的准确性和有效性，在仿真对比实验中，优化算法在每个测试函数上单独运行 30 次。

3.3.1 算法评价指标和测试函数

评价指标可以反应算法性能的好坏，如果选择的评价指标不合理，那么可能会得出错误的结论。根据测试函数以及优化算法的特点，在仿真对比实验中设有以下 4 个评价指标：最优值、最差值、平均值和收敛速度。

(1) 最优值

最优值表示在 30 次寻优结果中取最优结果，最优值计算如公式(3.8)所示。

$$\text{Best} = \min(y_1, y_2, \dots, y_{30}) \quad (3.8)$$

式中，Best——结果最优值； y ——寻优结果。

(2) 最差值

最差值表示在 30 次寻优结果中取最差结果，最差值计算如公式(3.9)所示。

$$\text{Worst} = \max(y_1, y_2, \dots, y_{30}) \quad (3.9)$$

式中，Worst——结果最差值。

(3) 平均值

平均值表示取 30 次寻优结果的平均值，平均值计算如公式(3.10)所示。

$$\text{mean} = \frac{1}{30} \sum_{i=1}^{30} y_i \quad (3.10)$$

式中，mean——结果平均值。

(4) 收敛速度

算法的收敛速度为在目标范围内搜索到测试函数最优值的速度。

仿真实验选取的 6 个测试函数如表 3.1 所示。

表 3.1 基准函数

函数	公式	理论最优值	维度 D
F1	$F_1(x) = \sum_{i=1}^N x_i^2, x_i \in [-100, 100]$	0	2/30
F2	$F_2(x) = \sum_{i=1}^N x_i + \prod_{i=1}^N x_i , x_i \in [-10, 10]$	0	2/30
F3	$F_3(x) = \max\{ x_i , 1 \leq i \leq N\}, x_i \in [-100, 100]$	0	2/30
F4	$F_4(x) = \sum_{i=1}^{N-1} i x_i^4 + \text{random}[0, 1), x_i \in [-1.28, 1.28]$	0	2/30
F5	$F_5(x) = \sum_{i=1}^N [x_i^2 - 10 \cos(2\pi x_i) + 10], x_i \in [-5.12, 5.12]$	0	2/30
F6	$F_6(x) = -20 \exp\left(-0.2 \sqrt{\frac{1}{N} \sum_{i=1}^N x_i^2}\right) - \exp\left(\frac{1}{N} \sum_{i=1}^N \cos 2\pi x_i\right) + 20 + e, x_i \in [-32, 32]$	0	2/30

在表 3.1 中，F1~F4 函数为单峰测试函数，F5 和 F6 函数为对称的非线性多峰函数。不同几何特性的测试函数可以更全面验证 MSGWO 算法性能。单峰函数在搜索空间内有且仅有一个全局最优解，所以可以利用单峰函数验证优化算法的寻优和收敛能力；与单峰函数不同，多峰函数在搜索空间里有一个全局最优解的同时还有多个局部最优解，因此，可以通过多峰函数来验证算法跳出局部最优的能力。

3.3.2 实验环境和参数设置

本实验硬件环境为 Intel(R) Core(TM)i7-7500U CPU @2.70GHz 2.90 GHz 处理器和 8.0GB 内存空间；软件环境为 Windows10(64 位)操作系统；编程语言为 Python3.8。


仿真对比实验中各优化算法参数设置如下：6 种优化算法初始化种群数量以及迭代

次数完全相同, 种群数为 50, 迭代次数均为 500; PSO 算法的加速常数 $c_1 = c_2 = 2$, 惯性因子 $w = 0.9$; ABC 算法中侦查蜂所占比例为 60%; DE 算法的交叉概率为 0.8, 缩放因子为 0.85; SA 算法的交叉概率为 0.8, 变异概率为 0.05, 初始温度为 1000。


3.3.3 仿真实验结果与分析

(1) 测试函数维度为 2


首先, 为了直观的看出测试函数维度为 2 时, 不同优化算法的收敛速度, 通过可视化绘图记录了 6 种群智能优化算法对 6 种测试函数寻优过程中算法历史最优适应度值的变化情况, 结果如图 3.3 所示。在图 3.3 中, 横轴为迭代次数, 纵轴为算法的历史最优适应度值, 优化算法的收敛速度快慢与适应度曲线斜率大小成正比, 收敛速度越快, 则曲线斜率越大。此外, 6 种测试函数的理论最优值均为 0, 因此算法适应度值越低, 寻优效果越好。由图 3.3 可以看出, 在处理维度为 2 的 6 个测试函数时, 相较于其他 5 种优化算法, MSGWO 算法的收敛精度最高, 并且在目标范围内的收敛速度最快。




(a) F1 函数收敛曲线图



(b) F2 函数收敛曲线图



(c) F3 函数收敛曲线图



(d) F4 函数收敛曲线图




图 3.3 D=2 时优化算法收敛曲线图

其次,为了更好的了解不同优化算法寻优能力之间的差异,分别统计了 6 种优化算法针对每种测试函数单独运行 30 次后的 3 种算法评价指标,即最优适应度值、最差适应度值以及适应度平均值,统计结果如表 3.2 所示。在表 3.2 中,3 种算法评价指标的数值越小表示优化算法的寻优精度越高,表中使用粗体字对每种测试函数下的 3 种评价指标的最佳值进行了标记。


当测试函数维度为 2 时,根据单峰函数 F1~F4 的寻优结果,将 6 种优化算法根据寻优误差从小到大进行排序: $MSGWO < GWO < DE < SA < ABC < PSO$,可以看出传统的 GWO 算法在处理低维单峰函数时寻优精度要高于传统的 PSO、ABC、SA 以及 DE 算法,由此说明传统灰狼优化算法在处理低维单峰函数时本身具有较强的寻优能力。相较于未改进的 GWO 算法,本文所提出的 MSGWO 算法在处理低维单峰函数时具有更高的寻优精度,且 MSGWO 算法可以收敛到 F1~F3 函数的理论最优值 0,由此可以表明文中所提出的改进策略可以增强传统灰狼优化算法的寻优能力。根据多峰函数 F5 和 F6 的寻优结果,将 6 种优化算法根据寻优误差从小到大进行排序: $MSGWO = GWO = SA = DE < ABC < PSO$,可以看出在处理低维多峰函数时,PSO 算法的寻优误差最大,MSGWO 算法、GWO 算法、SA 算法以及 DE 算法的寻优误差一致,小于 PSO 算法和 ABC 算法。

表 3.2 D=2 时不同群智能优化算法性能对比结果


测试函数	算法	最优值	最差值	平均值
F1	PSO	2.35E-09	2.14E-06	4.21E-07
	ABC	9.46E-19	6.26E-16	8.34E-17
	SA	1.44E-31	3.17E-29	1.22E-29
	DE	1.88E-71	2.73E-69	7.76E-70
	GWO	1.20E-322	2.21E-263	1.88E-264
	MSGWO	0	0	0
F2	PSO	8.81E-05	3.00E-03	1.29E-03
	ABC	9.71E-11	2.95E-09	1.66E-09
	SA	1.05E-27	2.44E-27	1.80E-27
	DE	8.06E-37	3.54E-35	1.28E-35
	GWO	1.56E-156	2.23E-136	2.10E-137
	MSGWO	0	0	0
F3	PSO	7.14E-05	1.70E-03	5.44E-04
	ABC	1.33E-08	2.85E-07	1.10E-07
	SA	5.74E-28	1.04E-27	9.95E-28
	DE	2.59E-33	3.67E-32	1.82E-32
	GWO	1.56E-149	1.52E-122	1.56E-123
	MSGWO	0	0	0
F4	PSO	6.40E-04	4.50E-03	1.87E-03
	ABC	2.18E-05	1.30E-03	6.38E-04
	SA	1.26E-04	7.51E-05	1.50E-04
	DE	2.06E-04	9.10E-04	4.59E-04
	GWO	2.63E-05	6.51E-04	2.07E-04
	MSGWO	4.15E-06	7.90E-04	1.60E-05
F5	PSO	1.46E-05	2.30E-04	1.06E-04
	ABC	2.01E-11	2.05E-07	3.66E-08
	SA	0	0	0
	DE	0	0	0
	GWO	0	0	0
	MSGWO	0	0	0
F6	PSO	5.05E-04	7.78E-03	2.71E-03
	ABC	1.24E-04	6.04E-03	2.44E-03
	SA	4.44E-16	4.44E-16	4.44E-16
	ED	4.44E-16	4.44E-16	4.44E-16
	GWO	4.44E-16	4.44E-16	4.44E-16
	MSGWO	4.44E-16	4.44E-16	4.44E-16

(2) 测试函数维度为 30


首先, 为了直观的看出测试函数维度为 30 时, 不同优化算法的收敛速度, 通过可视化绘图记录了 6 种群智能优化算法对不同测试函数寻优过程中算法历史最优适应度值, 迭代过程中, 算法适应度值变化情况如图 3.4 所示。由图 3.4 可以看出, 在处理维度为 30 的测试函数时, MSGWO 算法相较于其他 5 种优化算法具有更快的收敛速度, 同时 MSGWO 算法的曲线位置始终位于其他算法曲线的下方, 由此说明 MSGWO 算法的寻优精度高于其他 5 种优化算法。此外, 通过算法的收敛曲线图可以看出, 在处理高维函数时, PSO 算法、ABC 算法、SA 算法、DE 算法以及 GWO 算法均不同程度地陷入了局部极值, 而 MSGWO 算法则具有跳出局部最优的能力。




(a) F1 函数收敛曲线图



(b) F2 函数收敛曲线图



(c) F3 函数收敛曲线图



(d) F4 函数收敛曲线图




图 3.4 D=30 时优化算法收敛曲线图

其次,为了更好的了解不同优化算法寻优能力之间的差异,分别统计了测试函数维度为 30 时,6 种优化算法单独运行 30 次后的 3 种算法评价指标,即最优适应度值、最差适应度值以及适应度平均值,统计结果如表 3.3 所示。

当测试函数维度为 30 时,根据单峰函数 F1~F4 的寻优结果中,将 6 种优化算法根据寻优误差从小到大进行排序:MSGWO<GWO<SA<PSO<ABC<DE,可以看出在处理高维单峰函数时,相较于其他 5 种优化算法,MSGWO 算法的寻优精度最高、寻优误差最小。根据多峰函数 F5 的寻优结果,将 6 种优化算法根据寻优误差从小到大进行排序:MSGWO<GWO<SA<PSO<ABC<DE。根据多峰函数 F6 的寻优结果,将 6 种优化算法根据寻优误差从小到大进行排序:MSGWO<PSO<GWO<SA<ABC<DE。综合多峰函数 F5 和 F6 函数的寻优结果可以看出,相较于其他 5 种优化算法,MSGWO 算法在处理高维多峰函数时具有较高的寻优精度和较强的稳定性。

综上所述,本文利用精英反向学习增强灰狼初始化种群多样性、通过非线性收敛因子平衡算法探索能力和开发能力之间的平衡关系、引入高斯变异策略提高灰狼种群活力,这三种改进策略的综合使用保证了无论是处理低维简单问题还是高维复杂问题,MSGWO 算法均具有明显的竞争优势。

表 3.3 D=30 时不同群智能优化算法性能对比结果

测试函数	算法	最优值	最差值	平均值
F1	PSO	0.83	2.05	1.38
	ABC	8.15	2.68E+01	1.56E+01
	SA	2.53E-10	1.65E-08	3.67E-09
	DE	1.69E+04	2.07E+04	1.93E+04
	GWO	3.96E-35	2.56E-33	9.66E-34
	MSGWO	2.65E-307	1.65E-262	1.65E-263
F2	PSO	1.53E+01	7.81E+02	2.21E+02
	ABC	2.86E+17	1.92E+24	2.90E+23
	SA	3.27E-05	1.39E-04	7.64E-05
	DE	3.32E+28	1.10E+33	2.34E+32
	GWO	2.66E-19	5.91E-18	1.21E-18
	MSGWO	4.84E-175	1.01E-166	9.15E-168
F3	PSO	1.79	4.40	2.41
	ABC	4.13E+01	6.42E+01	5.54E+01
	SA	3.46E-02	5.99E-02	4.82E-02
	DE	7.89E+01	8.97E+01	8.54E+01
	GWO	2.67E-09	3.19E-08	1.46E-08
	MSGWO	5.90E-114	1.34E-91	1.34E-92
F4	PSO	4.65E+06	7.52E+8	5.58E+07
	ABC	3.24E+11	5.48E+12	1.57E+12
	SA	8.43E-03	7.89E-02	2.51E-02
	DE	5.04E+08	9.90E+08	7.75E+08
	GWO	2.74E-02	1.86E-01	8.25E-02
	MSGWO	2.59E-05	1.26E-04	1.01E-04
F5	PSO	1.72E+02	2.49E+02	2.19E+02
	ABC	2.80E+02	3.31E+02	3.06E+02
	SA	2.38E-04	3.98	2.00
	DE	1.58E+04	2.28E+04	1.93E+04
	GWO	2.48E-14	8.66	1.59
	MSGWO	0	0	0
F6	PSO	1.65	1.97	1.81
	ABC	2.12E+01	2.22E+01	2.16E+01
	SA	2.16E+01	2.20E+01	2.15E+01
	DE	2.22E+01	2.32E+01	2.23E+01
	GWO	2.11E+01	2.19E+01	2.15E+01
	MSGWO	0.78	1.01	0.88

3.4 基于 MSGWO-SVR 的煤矿涌水量预测模型

3.4.1 MSGWO-SVR 算法基本流程

SVR 的拓扑结构简单、学习能力和拟合能力强，并且擅长处理复杂的非线性高维问题。但是，通过 2.3.2 节的分析可知 SVR 模型性能主要依赖于惩罚因子 C 以及核参数 μ ，这两个参数的大小直接影响着 SVR 模型预测准确性。针对这一问题，利用 3.1 节提出的 MSGWO 算法寻优 SVR 模型参数，提出 MSGWO-SVR 算法。

MSGWO-SVR 算法的优化过程主要包含以下两个步：第一步首先通过 MSGWO 算法在参数取值范围内，搜索到 SVR 模型的最优参数组合 (C, μ) ；第二步利用求得的最优参数组合 (C, μ) 构建 MSGWO-SVR 算法。

MSGWO-SVR 算法的具体步骤如下：

Step1：将采集到的数据进行预处理并按照 2:8 的比例划分为测试集和训练集；

Step2：初始化灰狼种群数 N 、参数 A 、 C 和 a 以及最大迭代次数 t ，并令 $t=0$ 。设置支持惩罚因子 C 和 RBF 函数参数 μ 的取值范围，其下界值和上界值分别为 0.01 和 200；

Step3：将预测煤矿涌水量的均方根误差(RMSE)设置为算法的目标函数；

Step4：根据公式(3.1)~公式(3.4)利用精英反向学习初始化种群；

Step5：通过计算从种群中选出三头适应度值最优的狼，将其设为最优解 X_α 、优解 X_β 和次优解 X_γ ，若算法的最优适应度值连续 5 代未发生变化，则根据公式(3.7)对最优个体进行高斯变异操作

Step6：根据公式(3.6)、公式(2.3)和公式(2.4)依次更新参数 a 、 A 和 C 的值；

Step7：根据公式(2.6)~公式(2.8)更新狼群位置；

Step8：迭代次数 $t+1$ ；

Step9：判断算法寻优过程的终端条件是否满足，终端条件为预定的最大迭代次数，若满足该条件，则进行下一步骤。否则回到 Step3；

Step10：输出最优参数 C 和 μ 以及模型实际输出值，算法结束。

MSGWO-SVR 算法流程示意图如图 3.5 所示。




图 3.5 MSGWO-SVR 算法流程图

3.4.2 MSGWO-SVR 模型框架

将 3.4.1 节提出的 MSGWO-SVR 算法应用于简单地质构造下的煤矿涌水量预测问题, 构建基于 MSGWO-SVR 的煤矿涌水量预测模型, 该模型选择含水层水压作为模型的特征值, 工作面涌水量作为模型的目标值。MSGWO-SVR 模型框架如图 3.6 所示。




图 3.6 MSGWO-SVR 模型框架示意图

如图 3.6 所示, MSGWO-SVR 模型主要包括四个部分: 第一个部分是收集数据, 并将样本数据按照 2:8 的比例划分为测试集和训练集; 第二个部分是数据预处理, 对原始数据进行归一化操作; 第三个部分是训练模型, 在训练集上利用 MSGWO 对 SVR 模型参数进行寻优; 第四个部分是模型预测, 根据最优参数组合建立 MSGWO-SVR 预测模型, 利用含水层水压对涌水量进行预测。

3.5 算例分析

3.5.1 实验环境

本实验硬件环境为 Intel(R) Core(TM)i7-7500U CPU @2.70GHz 2.90 GHz 处理器和 8.0GB 内存空间; 软件环境为 Windows10(64 位)操作系统; 编程语言为 Python3.8。

3.5.2 实验数据

本章实验数据采集于山东省兖州矿业集团下属 A 矿, 共采集 62 组数据, 其中 80% 的数据作为训练集数据, 20% 作为测试集数据。每组数据包括该工作面含水层水压和涌水量, 含水层水压作为模型的输入数据, 涌水量作为模型的输出数据, 模型根据工作面含水层水压对这一工作面涌水量进行预测。

3.5.3 模型评价指标

煤矿涌水量预测属于回归问题。模型性能的好坏, 主要是根据模型预测值与实际观测值之间的误差进行评估。因此, 选择平均绝对误差(Mean Absolute Error, MAE)和均方根误差(Root Mean Squared Error, RMSE)作为 MSGWO-SVR 模型的评价指标。在煤矿涌

水量预测中,模型的评价指标 RMSE 和 MAE 值越小,说明模型输出的煤矿涌水量预测值与煤矿涌水量实际值越吻合,模型性能越好。RMSE 计算方法如公式(3.11)所示,MAE 计算方法如公式(3.12)所示。

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (O_i - P_i)^2} \quad (3.11)$$

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |(O_i - P_i)| \quad (3.12)$$

式中, O_i ——实际值; P_i ——模型预测值; N ——样本个数。

3.5.4 数据预处理

在实验中含水层水压与涌水量之间存在不同的量纲和量纲单位。因此,利用归一化处理将数据值映射到[0,1]范围内,从而消除由于数据量纲和量纲单位不同给模型性能带来的影响,本实验数据归一化过程如公式(3.13)所示。

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (3.13)$$

式中, x' ——归一化后的值; $x_{\max}$ ——最大值; $x_{\min}$ ——最小值。

3.5.5 模型参数设置

实验中算法参数设置如下:灰狼初始种群数为 30,种群搜索空间维度为 2,算法最大迭代次数为 50,SVR 关键参数惩罚因子 C 的寻优范围为[1,200],核参数 μ 的寻优范围为[0.01,1]。

3.5.6 实验结果与分析

本文将煤矿含水层水压作为 MSGWO-SVR 模型的输入,煤矿涌水量作为 MSGWO-SVR 的输出,建立了基于 MSGWO-SVR 模型的煤矿涌水量预测模型。在训练过程中,MSGWO-SVR 的适应度函数为 RMSE。MSGWO-SVR 的适应度值变化曲线如图 3.8 所示,从图 3.8 可以看出,适应度值在迭代前期下降速度极快,经过 10 次迭代后适应度值趋于稳定,由此可以说明 MSGWO-SVR 模型在训练集上收敛且未出现过拟合现象。




图 3.8 MSGWO-SVR 适应度曲线图

MSGWO-SVR 模型预测结果如图 3.9 所示。从图 3.9 可以看出模型涌水量预测值曲线和涌水量实际曲线变化趋势相同，表明 MSGWO-SVR 模型具有较好的拟合能力。




图 3.9 MSGWO-SVR 模型预测结果

为了验证利用 MSGWO 算法对 SVR 模型关键参数进行寻优可以提高模型预测精度，在相同的数据集和实验环境下，利用 SVR 和 GWO-SVR 对煤矿涌水量进行了预测，并将 SVR 和 GWO-SVR 模型预测结果与 MSGWO-SVR 模型预测结果进行对比。3 个预测模型的评价指标对比结果如表 3.4 所示。为了更加直观的观察不同模型的性能差异，统计了 3 个模型在测试集上的预测误差，统计结果如表 3.4 所示，并且将 3 个模型预测值和实际值进行了可视化对比，对比结果如图 3.10 所示，

表 3.4 不同模型预测性能评价指标对比

模型	RMSE/%	MAE/%
SVR	4.93	12.01
GWO-SVR	3.25	8.41
MSGWO-SVR	2.15	6.03

通过表 3.4 可以看到，相较于其他两种预测模型，MSGWO-SVR 模型的平均绝对误

差和均方根误差最小, MSGWO-SVR 模型的 MAE 和 RMSE 分别为 6.03%和 2.15%。相较于 SVR 模型, MSGWO-SVR 模型的 MAE 降低了 5.98% , RMSE 降低了 2.78%; 相较于 GWO-SVR 模型,MSGWO-SVR 模型的 MAE 降低了 2.38% ,RMSE 降低了 1.1%。

表 3.5 不同模型对 12 个测试样本的预测结果

样本 编号	实际涌水量 /m ³ /h	SVR		GWO-SVR		MSGWO-SVR	
		预测值 /m ³ /h	绝对误差 / m ³ /h	预测值 /m ³ /h	绝对误差 / m ³ /h	预测值 /m ³ /h	绝对误差 / m ³ /h
1	74.31	67.47	6.84	68.43	5.88	68.95	5.36
2	105.35	75.46	29.89	86.86	18.49	94.46	10.89
3	92.64	74.88	17.76	80.73	11.91	84.22	8.42
4	64.09	57.65	6.44	58.65	5.44	59.85	4.24
5	20.22	26.64	6.42	24.09	3.87	22.69	2.47
6	21.41	27.15	5.74	24.88	3.47	23.63	2.22
7	47.32	44.03	3.29	44.10	3.20	45.26	2.06
8	54.88	49.39	5.19	51.34	3.54	51.13	3.74
9	116.84	74.20	42.64	89.68	27.16	100.96	15.88
10	70.12	63.78	6.34	64.11	6.01	64.67	5.45
11	29.26	31.34	2.08	30.50	1.24	30.05	0.79
12	89.36	73.08	16.08	76.64	12.72	78.66	10.70




图 3.10 不同模型预测值与实际值对比图

通过图 3.10 和表 3.5 可以看出, 与 SVR 和 GWO-SVR 模型相比, 经过 MSGWO 算法优化之后的 SVR 模型预测曲线更加贴近涌水量实际曲线, 证明了利用 MSGWO 算法优化 SVR 模型参数的必要性。此外, 通过实验结果可以看出, 单一 SVR 模型在预测较大涌水量时, 预测结果误差非常大。但是, GWO-SVR 和 MSGWO-SVR 模型在预测较

大涌水量时,预测误差均有所减小。由此可以说明,利用智能优化算法优化 SVR 模型可以解决单一 SVR 模型预测结果不稳定这一问题。

为了进一步验证 MSGWO-SVR 模型的有效性,在相同实验条件和相同数据集下,选取了 5 个常用于煤矿涌水量预测的模型与其进行对比实验。5 个传统预测模型分别为 AdaBoost、XGBoost、最邻近结点算法(K-NearestNeighbor,KNN)、随机森林(Random Forest,RF)以及长短期记忆神经网络(LSTM)。为了了解不同模型的预测性能,采用平均绝对误差(MAE)和均方根误差(RMSE)对 AdaBoost、XGBoost、KNN、RF 以及 LSTM 模型性能进行评估,各模型预测性能评价指标对比结果如表 3.6 所示。

表 3.6 各模型预测性能评价指标对比

模型	RMSE/%	MAE/%
AdaBoost	27.92	33.6
RF	25.09	31.6
XGBoost	17.06	12.48
KNN	16.71	11.23
LSTM	5.44	9.79
MSGWO-SVR	2.15	6.03

由表 3.6 可知,MSGWO-SVR 模型的 MAE 和 RMSE 评价指标均小于其他 5 种传统预测模型,评价指标表明 MSGWO-SVR 模型拟合能力更好,煤矿涌水量预测结果更精确,准确率更高。

综上所述,本文所提出的基于 MSGWO-SVR 的煤矿涌水量预测模型可以较好地反映含水层水压与涌水量之间的非线性映射关系,在预测简单地质构造下的煤矿涌水量时,该模型具有较强的自学习能力以及较高的稳定性。

3.6 本章小结

本章主要介绍了基于 MSGWO-SVR 的煤矿涌水量预测模型。首先,详细介绍了基于混合策略改进的灰狼优化算法(MSGWO),并给出了 MSGWO 算法流程图;其次,分别在维度为 2 和 30 的 6 个测试函数上,将 MSGWO 算法与传统灰狼优化算法(GWO)、粒子群优化算法(PSO)、人工蜂群优化算法(ABC)、模拟退火算法(SA)以及差分进化算法(DE)进行了仿真对比实验,实验验证了 MSGWO 算法的有效性;然后,利用 MSGWO 算法给 SVR 模型提供最优参数(惩罚系数 C 和核参数 μ),根据最优参数组合构建了基于 MSGWO-SVR 的煤矿涌水量预测模型,该模型利用煤矿工作面含水层水压对工作面涌水量进行预测;最后,将 MSGWO-SVR 模型应用于山东省兖州矿业集团下属 A 矿涌水实例中,实验结果显示,相较于传统预测模型(Adaboost、XGboost、RF、KNN 和

LSTM 模型)以及单一 SVR 模型和 GWO-SVR 模型, MSGWO-SVR 模型具有更高的预测精度和较强的稳定性, 表明 MSGWO 可为 SVR 模型提供最优参数, 使得 MSGWO-SVR 模型可以更好地反应含水层水压与涌水量之间的非线性映射关系, 模型预测结果可以为处于简单地质构造下的煤矿企业防治水策略制定和调整提供重要的参考依据。

4 基于 CNN-GCN-BiLSTM 的煤矿涌水量预测模型

对于地质构造复杂的煤矿而言,在实际开采中会遇到断层、裂隙带等现象。因此,复杂地质构造下的煤矿涌水量不仅仅受含水层水压影响,还会受到裂隙带发育高度、断层落差以及煤层倾角等诸多因素影响。此外,每个影响因素的变化会对煤矿涌水量造成不同程度的影响,各因素之间也会相互关联、相互作用。为了提高复杂地质构造下的煤矿涌水量预测精度,本文从挖掘关键因素以及有效提取不同因素间的关联特征信息出发,提出了一种基于图卷积神经网络和双向长短期记忆神经网络的煤矿涌水量预测模型(CNN-GCN-BiLSTM),选择相关的影响因素作为输入特征,对煤矿涌水量进行预测。该模型不仅能够利用数据自身特征信息,还能挖掘数据之间潜在的结构信息,从而充分捕捉序列数据内在规律,使得涌水量预测值更加接近真实值。

4.1 CNN-GCN-BiLSTM 模型框架

基于 CNN-GCN-BiLSTM 的煤矿涌水量预测模型由三部分组成:输入层、隐藏层和输出层。其中,隐藏层由卷积神经网络层(Convolutional Neural Networks, CNN)、图卷积神经网络层(Graph Convolutional Neural Network, GCN)和双向长短期记忆神经网络层(Bi-directional Long Short-Term Memory, BiLSTM)组成。CNN-GCN-BiLSTM 模型结构图如图 4.1 所示。




图 4.1 CNN-GCN-BiLSTM 模型结构

如图 4.1 所示, CNN-GCN-BiLSTM 模型预测流程为: 首先, 通过输入层对煤矿开采过程中监测到的涌水量时序数据进行预处理; 然后, 利用 CNN 提取数据的深层非线性特征, 通过 GCN 挖掘数据的空间特征; 最后, 利用 BiLSTM 对提取到的特征信息进行上下文学习, 通过全连接层输出涌水量预测值。此外, 模型采用 Adam 优化器对模型参数不断调整以优化预测结果。模型各层具体结构将在下面小节中进行详细介绍。

4.2 CNN-GCN-BiLSTM 模型网络结构

4.2.1 CNN 层的网络结构设计

CNN 可以通过卷积和池化操作自动提取输入数据的局部特征, 数据局部特征可以更加有效地表达原始数据所包含的信息。CNN 在提取数据局部特征时, 卷积核起着关键性的作用。为了获取数据不同的局部特征, 一个卷积层通常会设置多个维度相同、大小不同的卷积核, 但是卷积核大小不能超过单个样本数据大小。

考虑到处于复杂地质构造下的煤矿涌水量受多种因素影响, 原始数据特征无法有效反应实际涌水量。因此, 本文利用二维卷积神经网络(Two-dimensional Convolutional Neural Networks, 2D-CNN)提取数据的深层特征, 从而提高模型性能。为了获取数据不同的局部特征, 在卷积层设有 3 个卷积核, 大小分别为 1×3 、 1×5 和 1×7 , 步长为 1。模型中 CNN 的具体结构如图 4.1 所示, 卷积操作之后, 将 3 个卷积核提取的不同特征矩阵 F_1 、 F_2 和 F_3 拼接, 得到最后的特征向量 F 。卷积操作如公式(4.1)所示。

$$C = \sigma(WX + b) \quad (4.1)$$

式中, C ——提取特征; $\sigma(\cdot)$ ——Relu($\cdot$)激活函数; W ——权重矩阵; X ——输入矩阵; b ——偏置量。




图 4.2 2D-CNN 网络结构

4.2.2 GCN 层的网络结构设计

GCN 可以处理图结构化数据, 图 $G=(E,V)$ 由边集合 E 和顶点集合 V 组成, GCN 利用节点特征信息以及节点间结构信息, 提取数据的空间特征, 从而实现节点预测、节点分类和边预测等众多任务。

复杂地质构造下的煤矿涌水量影响因素种类多, 影响因素与涌水量之间具有较强的非线性关系, 而且因素之间还存在关联关系。为了更好地分析因素数据特征, 提高预测精度, 以涌水量影响因素为节点、皮尔逊相关系数为边, 将煤矿监测的涌水量数据建模成图结构化数据, 然后利用 GCN 提取数据的空间特征。模型中 GCN 具体结构如图 4.3 所示。




图 4.3 GCN 网络结构

在 GCN 层, 首先使用皮尔逊相关系数(Pearson)来衡量煤矿涌水量影响因素间的关联性。Pearson 计算公式如公式(4.2)所示。

$$R_{ij} = \frac{\text{cov}(x_i, x_j)}{\sigma x_i \sigma x_j} \quad (4.2)$$

式中, R_{ij} ——因素 i 和因素 j 的相关系数; $\text{cov}(x_i, x_j)$ ——协方差; σx ——标准差。

煤矿涌水量影响因素间相关程度的高低与其相关系数绝对值大小成正比。相关系数 R_{ij} 的取值范围为 $[-1, 1]$, 当两个因素完全负相关时, $R_{ij} = -1$; 当两个因素完全正相关时, $R_{ij} = 1$; 当两个因素完全没关系时, $R_{ij} = 0$ 。通过计算 R_{ij} , 可得到相关系数矩阵 R 。

然后,以影响因素为节点,相关系数为边,建立无向图。该图数据可用特征矩阵 $\mathbf{H}$ (CNN 神经网络层输出的特征向量 $\mathbf{F}$) 和邻接矩阵 $\mathbf{A}$ (相关系数矩阵 $\mathbf{R}$) 表示, $\mathbf{F}$ 和 $\mathbf{R}$ 为 GCN 层的输入。GCN 层与层之间的传播方式如公式(4.3)和公式(4.4)所示。

$$\hat{\mathbf{A}} = \mathbf{A} + \mathbf{I} \quad (4.3)$$

$$\mathbf{H}^{i+1} = f(\mathbf{H}^i, \mathbf{A}) = \sigma\left(\hat{\mathbf{D}}^{-\frac{1}{2}} \hat{\mathbf{A}} \hat{\mathbf{D}}^{-\frac{1}{2}} \mathbf{H}^i \mathbf{W}^i\right) \quad (4.4)$$

式中, $\mathbf{H}^i$ ——第 i 层的特征矩阵, $\mathbf{H}^0 = \mathbf{F}$; $\mathbf{A}$ ——无向图的邻接矩阵; $\mathbf{I}$ ——单位矩阵; $\hat{\mathbf{D}}$ ——度矩阵; $\mathbf{W}^i$ ——权重矩阵; $\sigma(\cdot)$ 函数——Relu($\cdot$) 激活函数。

当 GCN 层数为三层时,模型可以获得更多的特征信息,同时模型具有较好的性能。因此,本文在 CNN-GCN-BiLSTM 模型中的设置 GCN 层数为 3。虽然 GCN 层数越多,提取到的特征信息越多,但是,网络参数数量也会随着模型深度增加而变多,从而导致模型存在过拟合的风险。为了防止模型出现过拟合,在第一层 GCN 和第二层 GCN 后添加了 Dropout 层。经过多次实验,模型中 Dropout 值取 0.4。网络添加 Dropout 层之后效果如图 4.4 所示。




图 4.4 添加 Dropout 层的效果示意图

在图 4.4 中,左侧正常的神经网络在添加 Dropout 层之后就会变成右侧所示的网络结构。可以看到,在加入 Dropout 层之后网络会随机删除一些神经元,从而减少网络中每一次神经元的连接个数,实现特征增强并有效地减少模型过度拟合的风险。

4.2.3 BiLSTM 层的网络结构设计

煤矿涌水是一个动态过程,涌水量和涌水量影响因素都会随着时间不断变化,所以采集到的涌水量数据属于时间序列数据。因此,利用 BiLSTM 神经网络对 CNN 神经网络层和 GCN 神经网络层提取到的特征信息构成的时序数据进行双向序列特征学习,充

分挖掘有限样本数据的长期依赖特征，并利用提取到的特征信息学习影响因素与煤矿涌水量之间的内在规律，最后通过全连接层输出煤矿涌水量预测值。BiLSTM 层网络结构如图 4.5 所示。




图 4.5 BiLSTM 层网络结构

4.2.4 Adam 优化器

神经网络学习的最终目标是找到合适的参数，使得损失函数的值尽可能小。解决此问题的过程称为优化，用于解决此问题的算法称为优化器。模型网络参数的更新和计算主要依靠于优化器，使用优化器可以实现模型性能最优化。目前，常用的优化器主要包括：梯度下降优化算法、动量优化算法以及自适应学习率优化算法。

(1) 梯度下降优化算法

梯度下降法的基本思想是沿着梯度的方向不断逼近最优值。根据每次计算样本数量的不同，将梯度下降法分为批处理梯度下降法、随机梯度下降和小批处理梯度下降法。随机梯度法主要有两个缺点，一方面，当样本数据很大时，学习时间较长；另一方面，在处理非凸函数时，利用梯度下降法会出现在局部最优值中循环而无法跳出的情况。

(2) 动量优化算法

动量优化算法将动量项融入到梯度下降法中，在动量优化方法中梯度不仅由当前训练数据决定，而且还受历史训练数据的梯度决定，因此，使用动量优化方法可以加快梯度下降。但是，该方法也存在陷入局部最优的风险。

(3) 自适应学习率优化算法

自适应学习率优化算法很好地解决了传统优化算法在更新模型学习率时没有考虑

不同参数需要对应不同的学习率这一问题。目前，常用的自适应学习率优化算法主要有 AdaGrad 算法，RMSProp 算法以及 Adam 算法。

综合考虑各种优化器的优缺点，本文在 CNN-GCN-BiLSTM 模型中使用 Adam 优化器对参数进行优化。Adam 是 2014 年由 Kingma 学者所提出的优化算法^[70]，它结合了适应性梯度法(AdaGrad)和均方根传播法(RMSProp)的优点。

4.3 CNN-GCN-BiLSTM 模型训练预测过程

本文提出了一种基于 CNN-GCN-BiLSTM 的煤矿涌水量预测模型。模型训练预测过程为：首先对原始数据预处理，并划分训练集和测试集；然后将训练集数据输入 CNN-GCN-BiLSTM 模型，模型开始训练；最后将测试集数据输入训练好的模型，完成对煤矿涌水量的预测。模型具体训练和预测过程将在下面小节进行介绍。

4.3.1 CNN-GCN-BiLSTM 模型训练过程

CNN-GCN-BiLSTM 模型训练过程如图 4.6 所示。




图 4.6 GCN-BiLSTM 训练过程示意图

CNN-GCN-BiLSTM 模型训练的主要步骤如下:

Step1: 输入训练集数据;

Step2: 输入数据预处理, 由于数据具有不同的量纲, 之间存在较大差距, 为了更好地训练模型, 对输入数据进行归一化等操作;

Step3: 网络初始化, 初始化 CNN-GCN-BiLSTM 模型各层的权值和偏差;

Step4: CNN 层计算, CNN 提取数据的局部特征, 将三个卷积核得到的不同特征张量进行拼接得到最终的特征矩阵;

Step5: GCN 层计算, GCN 提取数据的空间特征;

Step6: BiLSTM 层计算, BiLSTM 挖掘有限样本数据的长期依赖特征, 并利用提取到的数据特征来学习样本序列数据内部变化规律;

Step7: 通过全连接层输出涌水量预测值;

Step8: 计算涌水量预测值与涌水量实际值之间的误差;

Step9: 判断预测过程的终端条件是否满足, 成功终端的条件是完成预定的循环次数或是预测误差低于所设定的阈值。如果满足其中一个条件, 则模型训练完成。否则, 继续进行下一步骤;

Step10: 误差反向传播, 将计算的误差反向传播, 更新各层的权重和偏差, 返回到 Step4 继续网络训练。

4.3.2 CNN-GCN-BiLSTM 模型预测过程

CNN-GCN-BiLSTM 模型预测过程如图 4.7 所示。




图 4.7 CNN-GCN-BiLSTM 预测过程示意图

CNN-GCN-BiLSTM 模型预测的主要步骤如下:

Step1: 输入测试集数据;

Step2: 输入数据预处理, 由于数据具有不同的量纲, 之间存在较大差距, 为了更好地训练模型, 对输入数据进行归一化等操作;

Step3: 将归一化之后的数据输入训练好的 CNN-GCN-BiLSTM 模型, 得到输出值;

Step4: 将模型输出值进行反归一化操作, 输出涌水量预测值。

4.4 算例分析

4.4.1 实验环境

本实验硬件环境为 Intel(R) Core(TM)i7-7500U CPU @2.70GHz 2.90 GHz 处理器和 8.0GB 内存空间; 软件环境为 Windows10(64 位)操作系统; 编程语言为 Python3.8。

4.4.2 实验数据

从 2.1 节可知, 当煤矿所处地区地质构造属于复杂地质构造时, 煤矿涌水量主要受工作面推进距离、水压、隔水层厚度、含水层厚度、导水裂隙带发育高度、煤层倾角和断层落差共同影响。因此, 本实验选择这 7 种影响因素作为输入特征, 对煤矿涌水量进行预测。

本章实验数据采集于山东省兖州矿业集团下属 B 矿, 共采集数据 600 组, 其中 80% 的数据作为训练集数据, 20% 作为测试集数据。每组数据包含 7 种涌水量影响因素以及涌水量, 其中 7 种影响因素为模型输入数据, 涌水量为预测模型的输出。

4.4.3 模型评价指标

CNN-GCN-BiLSTM 模型用来对煤矿涌水量进行预测, 涌水量预测值与涌水量实际值之间的误差越小, 表明模型性能越好。因此, 选取均方根误差(Root Mean Squard Error, RMSE)和平均绝对误差(Mean Absolute Error, MAE)作为预测模型的评价指标。通过评价指标 MAE 和 RMSE 的大小来反应模型预测性能的好坏。

RMSE 计算方法如公式(4.5)所示, MAE 计算方法如公式(4.6)所示。

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (O_i - P_i)^2} \quad (4.5)$$

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |O_i - P_i| \quad (4.6)$$

式中, O_i ——实际值; P_i ——模型预测值; N ——样本个数。

4.4.4 数据预处理

由于含水层厚度为非数值类型数据，因此，对含水层厚度特征进行标签编码，薄层灰岩为 1，厚层灰岩为 0，将非数值类型数据转换成数值型数据，用于模型计算。

此外，由于影响煤矿涌水量的因素多而杂，且各煤矿涌水量影响因素之间的量纲和量纲单位均不相同。因此，需要对样本数据进行归一化处理，从而减少因数据量纲和量纲单位不同给模型预测结果带来的影响。数据归一化过程如公式(4.7)所示。

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (4.7)$$

式中， x' ——归一化后的值； $x_{\max}$ ——最大值； $x_{\min}$ ——最小值。

4.4.5 模型参数设置

CNN-GCN-BiLSTM 模型的超参数设置在一定程度上影响模型对煤矿涌水量预测精度。经过反复试验，确定了相对较优的超参数，CNN-GCN-BiLSTM 模型的超参数设置如下：CNN 层数为 1，卷积核个数为 3，卷积核大小分别为 1×3 、 1×5 和 1×7 ，步长为 1；GCN 层数为 3，在第一层 GCN 和第二层 GCN 之后添加 Dropout 层，Dropout 值取 0.4；模型训练次数(Epochs)为 5000，批处理大小(Batch_size)为 2，学习率(Loss)为 0.001。

4.4.6 实验结果与分析

CNN-GCN-BiLSTM 模型首先在训练集数据上进行训练，模型损失函数为均方根误差(RMSE)。在训练过程中，模型利用反向传播的误差信息进行迭代权重更新，不断优化各层参数，直到模型收敛。模型在训练过程中损失值(Loss)变化情况如图 4.8 所示。




图 4.8 CNN-GCN-BiLSTM 模型迭代损失函数图

由图 4.8 可以看出，在模型迭代初期，损失值保持着较快的下降速度，随着模型迭

代次数的增加, 损失值慢慢趋于稳定。由此可以说明, CNN-GCN-BiLSTM 模型在整个训练集上收敛, 并没有出现过拟合现象。

模型训练完成之后, 利用训练好的 CNN-GCN-BiLSTM 模型对测试集样本进行预测。模型涌水量预测值与涌水量实际值对比结果如图 4.9 所示。通过图 4.9 可以看出, CNN-GCN-BiLSTM 模型输出的涌水量预测值与涌水量实际值变化趋势一致且误差较小, 说明 CNN-GCN-BiLSTM 预测模型具有较强的学习能力, 能够对处于复杂地质构造下的煤矿涌水量进行准确预测。




图 4.9 CNN-GCN-BiLSTM 模型涌水量预测值和实际值对比图

为了验证 CNN-GCN-BiLSTM 模型的优越性, 在相同实验条件和相同数据集下, 选取了 5 个常用于煤矿涌水量预测的模型与其进行对比实验。5 个传统预测模型分别为 AdaBoost、XGBoost、最邻近结点算法(K-NearestNeighbor,KNN)、随机森林(Random Forest,RF)以及支持向量回归(SVR)。

AdaBoost: AdaBoost 具有优越的泛化能力, 而且不易出现过拟合现象。在对比实验中 XGBoost 参数设置如下, 学习率为 1.3, 迭代次数为 350。

XGBoost: XGBoost 具有原理简单、计算速度快以及精度高等优点。在对比实验中, XGBoost 的参数设置如下: 学习率为 0.04, 每棵树的随机抽样比为 0.8, 收缩步长为 0.2, 迭代次数为 2400, 树的最大深度为 6。

KNN: KNN 适用于非线性序列数据。在对比实验中, KNN 参数设置如下: k 为 1, 距离参数 p 为 1。

RF: RF 具有学习速度快、过拟合少、对噪声具有鲁棒性、无需过多参数调整即可达到良好效果的优点。在对比实验中, RF 参数设置如下: 决策树数量为 2400。

SVR: SVR 是机器学习中最重要算法之一, 它可以非常有效地处理带有少量标签的高维异构数据集。在对比实验中, 使用 RBF 核函数用于构建 SVR 模型。

不同预测模型性能评价指标对比结果如表 4.1 所示。

表 4.1 不同模型预测性能评价指标对比

模型	RMSE/%	MAE/%
XGboost	7.23	25.65
RF	8.73	29.07
KNN	10.18	28.13
Adaboost	2.65	14.4
SVR	2.96	15.17
CNN-GCN-BiLSTM	2.42	6.85

MAE 和 RMSE 指标越小，代表模型性能越好。通过表 4.2 可以看出，CNN-GCN-BiLSTM 模型的评价指标 MAE 和 RMSE 最小，CNN-GCN-BiLSTM 模型的 MAE 和 RMSE 分别为 6.85%和 2.42%。其中，RMSE 指标相比 XGboost、RF、KNN、Adaboost 和 SVR 这 5 种模型分别降低了 4.81、6.31、7.76、0.23、0.54 个百分点；MAE 指标相比 XGboost、RF、KNN、Adaboost 和 SVR 这 5 种模型分别降低了 18.8、22.22、21.28、7.55、8.32 个百分点。由此可见，CNN-GCN-BiLSTM 模型预测准确率高于 XGboost、RF、KNN、Adaboost 以及 SVR 单模型，表明基于同一数据集，深层模型可以更好地挖掘数据信息，从而保证模型预测精度高于浅层预测模型。

为了进一步分析提取数据空间特征以及双向序列特征对预测结果的影响程度，以 LSTM 作为基础模型，构建了 CNN-LSTM 和 CNN-GCN-LSTM 作为对比模型。为了保证对比实验结果准确，对比模型与 CNN-GCN-BiLSTM 模型中各网络参数保持一致。各模型性能指标如表 4.2 所示。

表 4.2 不同模型预测性能评价指标对比

模型	RMSE/%	MAE/%
CNN-LSTM	5.99	13.6
CNN-GCN-LSTM	2.71	8.39
CNN-GCN-BiLSTM	2.42	6.85

通过表 4.2 可以看出，在三种模型中，CNN-GCN-BiLSTM 模型的 RMSE 和 MAE 指标相比 CNN-LSTM 模型下降了 3.57 和 6.75 个百分点，这是由于 GCN 可以有效地提取数据的空间特征信息；CNN-GCN-BiLSTM 模型的 RMSE 指标和 MAE 指标相比 CNN-GCN-LSTM 模型下降了 0.29 和 1.54 个百分点，这是因为 BiLSTM 具有对特征信息的时序相关性和历史信息的记忆能力。综上所述，基于 CNN-GCN-BiLSTM 的煤矿煤

矿涌水量预测模型从时序数据中自动获取的高级数据特征能够很好地反映煤矿涌水量与影响因素之间的映射关系，模型具有较高的预测精度。

为了清晰地观察 CNN-LSTM、CNN-GCN-LSTM 和 CNN-GCN-BiLSTM 模型对煤矿涌水量预测的性能差异，图 4.10 展示了这三个模型对测试集中前 40 个样本的涌水量预测值与涌水量实际值对比情况，由图 4.10 可以看出，虽然这三种模型的涌水量预测值与实际值大致吻合，但是 CNN-GCN-BiLSTM 模型的涌水量预测值更加贴近涌水量实际值。




图 4.10 煤矿涌水量预测值与涌水量实际值对比图

4.5 本章小节

本章提出了一种基于 CNN-GCN-BiLSTM 的煤矿涌水量预测模型。首先介绍了 CNN-GCN-BiLSTM 模型的整体框架；接着详细阐述了 CNN-GCN-BiLSTM 模型各层的网络结构以及模型所选择的优化器；然后介绍了 CNN-GCN-BiLSTM 模型训练和预测过程的详细步骤，并给出了过程流程图；最后结合山东省兖州矿业集团下属 B 矿的实测涌水量数据对模型进行了实验验证，并与传统预测模型（Adaboost、XGboost、RF、KNN 和 SVR 模型）以及 CNN-LSTM 和 CNN-GCN-LSTM 这 7 种模型预测结果进行了对比。实验结果显示，CNN-GCN-BiLSTM 模型误差最小，精度最高，更适用于复杂地质构造下的煤矿涌水量预测。综上所述，基于 CNN-GCN-BiLSTM 的煤矿涌水量预测模型充分考虑了多种影响因素对涌水量的影响，模型从数据中自动学习到的高级数据特征能够很好地表征煤矿涌水量与影响要素之间的映射关系，从而得到较高的预测准确率，为复杂地质构造下的煤矿涌水量预测提供了新思路。

5 总结与展望

5.1 总结

一直以来,煤矿安全生产备受关注,而煤矿涌水量是煤矿安全生产过程中一个非常重要的参考指标,如果煤矿涌水量预测误差较大,工作人员则无法及时地在突水事故发生前做出有效的预防措施。准确预测煤矿涌水量对煤矿安全生产有着重要的现实意义。为了提高煤矿涌水量预测精度,论文综合考虑不同地质构造下的煤矿涌水量特性,分别构建了基于 MSGWO-SVR 的煤矿涌水量预测模型和基于 CNN-GCN-BiLSTM 的煤矿涌水量预测模型。论文的重点研究内容总结如下:

(1) 对于处于简单地质构造下的煤矿,其涌水量主要受含水层水压的影响。考虑到水压与涌水量之间存在复杂的映射关系,提出了一种基于混合策略改进灰狼算法优化支持向量机的煤矿涌水量预测模型——MSGWO-SVR,以解决简单地质构造下的含水层水压与煤矿涌水量之间非线性变化规律无法准确表征的问题。首先,为了克服传统灰狼优化算法的不足,提出了基于混合策略改进的灰狼优化算法(MSGWO)。在 MSGWO 算法中,利用精英反向学习机制增强种群的多样性和质量、引入非线性收敛因子平衡算法的全局探索能力和局部开发能力、通过高斯变异策略保证算法在迭代后期具有跳出局部最优的能力。对 6 个测试函数进行仿真实验,结果表明,与其他 5 种优化算法相比 MSGWO 算法具有明显优势;其次,为了避免 SVR 模型参数的选定对模型预测结果产生影响,利用 MSGWO 优化 SVR 模型的关键影响参数(惩罚因子 C 和核参数 μ);最后,基于最优参数组合构建基于 MSGWO-SVR 的煤矿涌水量预测模型。基于山东省兖州矿业集团下属 A 煤矿的实测数据的算例分析结果显示,与 Adaboost、XGboost、RF、LSTM、SVR 和 GWO-SVR 模型相比,MSGWO-SVR 模型的 MAE 和 RMSE 值最小,分别为 6.03%和 2.15%,表明该模型的预测结果更可靠,更适用于简单地质构造下的煤矿涌水量预测。

(2) 对于处于复杂地质构造下的煤矿,其涌水量受导水裂隙带发育高度、煤层倾角和断层落差等诸多因素共同影响。考虑到各因素变化会对涌水量造成不同程度的影响,且因素间存在复杂的耦合关系,提出了一种基于图卷积神经网络和双向长短期记忆神经网络的煤矿涌水量预测模型——CNN-GCN-BiLSTM,以解决浅层模型难以准确挖掘因素间的关联关系导致涌水量预测精度低的问题。首先,利用 2D-CNN 神经网络的卷积层提取包含涌水量影响因素相关性信息的输入数据在高维空间的特征向量;接着,为了更好地分析涌水量影响因素间的关联关系,以影响因素为节点、皮尔逊相关系数为边,将煤矿监测的涌水量数据建模成图结构化数据,通过 GCN 神经网络层挖掘各涌水量影响

因素间的空间特征；然后，将提取到的特征信息构造成序列特征向量输入 BiLSTM 神经网络层，利用 BiLSTM 对序列数据进行双向序列特征学习；最后，通过全连接层输出煤矿涌水量预测值。基于山东省兖州矿业集团下属 B 煤矿的实测数据的算例分析结果显示，与 Adaboost、XGboost、RF、KNN、SVR、CNN-LSTM 和 CNN-GCN-LSTM 模型相比，CNN-GCN-BiLSTM 模型的 RMSE 和 MAE 值最小，分别为 2.42% 和 6.85%，表明提取各影响因素之间的空间特征和数据之间天然的关联特征可以提高复杂地质构造下的煤矿涌水量预测准确率。

5.2 展望

论文提出了两种煤矿涌水量预测模型——MSGWO-SVR 和 CNN-GCN-BiLSTM。虽然通过算例分析验证了所提模型在煤矿涌水量预测问题中的有效性和可靠性，但是仍存在许多不足，考虑可以改进的方向如下：

（1）由于条件有限，论文仅利用山东省兖州矿业集团下属煤矿的实测数据对模型性能进行了验证，虽然实验结果显示论文所提模型在预测精度方面达到了预期效果。但是，今后需要考虑不同煤矿的实测数据以验证所提模型的泛化能力。

（2）煤矿涌水是一个非常复杂过程。论文通过研究涌水机理相关理论，对简单地质构造下的煤矿涌水量影响因素和复杂地质构造下的煤矿涌水量影响因素进行了分析，并在此基础上建立了相应的预测模型。但是，今后还需要在大量数据基础上进行更为完善的实验验证。

（3）论文只将所提模型应用于煤矿涌水量预测，后续可以考虑将预测模型应用于其他领域，如电力负荷预测、天气预测等，提高所提模型的应用范围。

参考文献

- [1] 汤家轩,刘具,梁跃强,程坤,张镔.“十四五”时期我国煤炭工业发展思考[J].中国煤炭,2021,47(10):6-10.
- [2] Chen S L, Xu K, Yu S B, Li B, Cao B, Shen J J.Comparsion Study on Two Methods of Water Inflow Prediction of Coal Mining [J].Advanced Materials Research, 2015,1093: 1379-1382.
- [3] 胡雅琴,任红蕾.利用数值法和解析法对祁南煤矿矿坑涌水量进行预测分析[J].地下水,2021,43(5):9-11.
- [4] 戴岩柯,崔世新,张坤.水均衡法和数值模拟法在矿坑深部涌水量预测中的比较——以西石门铁矿为例[J].地下水,2010,32(1):24-26.
- [5] 李孝朋,谢道雷,徐万鹏,张延飞,张宪峰,吴霞.多元回归分析在矿井涌水量预测中的应用[J].煤炭技术,2016,35(10):189-190.
- [6] 段俭君,徐会军,王子河.相关分析法在矿井涌水量预测中的应用[J].煤炭科学技术,2013,41(6):114-116.
- [7] 王家乐,王施智,黄倩.基于相关分析法的煤矿涌水量预测[J].陕西煤炭,2021,40(2):99-102.
- [8] 姚辉,张润畦,蒋知廷,刘鑫.矿井涌水量回归模型预测方法研究[J].华北科技学院学报,2021,18(3):24-31.
- [9] Deng Y,Cao C,Chen S.Research on correlation analysis and prediction model of agricultural climate factors based on machine learning [J].MATEC Web of Conferences,2021,336(7): 1-7.
- [10] 刘国辉,侯征,王天意,宋洪伟.一种新型的地下含水层涌水量预测模型[J].地球物理学进展,2012,27(3):1268-1273.
- [11] 凌成鹏,孙亚军,杨兰和,姜素,邵飞燕.基于BP神经网络的孔隙充水矿井涌水量预测[J].水文地质工程地质,2007,34(5):55-58.
- [12] 张宪峰,魏久传,张延飞,吴霞,李孝朋.基于主成分分析与BP神经网络的矿井涌水量预测研究[J].煤炭技术,2018,37(6):201-203.
- [13] 孟璐.基于人工神经网络的矿井涌水量预测[J].煤炭与化工,2020,43(4):65-68.
- [14] 窦贤明,杨永国,徐伟伟,靖凤伟.基于遗传算法和BP神经网络的矿井涌水量预测[J].中国煤炭地质,2009,21(10):37-38.
- [15] Shuaihan T. An Improved genetic algorithm for solving TSP[J]. Journal of Physics: Conference Series,2021,1952(4): 1-5.

- [16]潘正君,康立山.演化算法[M].北京:北京清华大学出版社,1998.
- [17]Carlo M D, Vasile M, Minisci E.Adaptive multi-population inflationary differential evolution [J]. Soft Computing, 2020,24(5): 3861-3891.
- [18]Simon D.Biogeography-based optimization[J].IEEE Trans on Evolutionary Computation, 2008,12(6): 702-713.
- [19]Rashedi E, Nezamabadi-Pour H, Saryazdi S. GSA: a gravitational search algorithm[J]. Information sciences,2009,179(13): 2232-2248.
- [20]Kaveh A, Dadras A. A novel meta-heuristic optimization algorithm: Thermal exchange optimization[J].Advances in Engineering Software, 2017,110: 69-84.
- [21]Mirjalili S. SCA: a sine cosine algorithm for solving optimization problems[J]. Knowledge-based systems, 2016,96:120-133.
- [22]Qais M H, Hasanien H M, Alghuwainem S. Transient search optimization: A new meta-heuristic optimization algorithm[J].Applied Intelligence, 2020, 50(11): 3926-3941.
- [23]赵乃刚,邓景顺.粒子群优化算法综述[J].科技创新导报,2015,12(26):216-217.
- [24]李晓磊.一种新型的智能优化方法-人工鱼群算法[D],浙江:浙江大学,2003.
- [25]Dorigo M, V Maniezzo, Colormi A. Ant sytem: Optimization by a colony of cooperating agents [J]. IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics), 2002, 26(1):29-41.
- [26]Karaboga D, Basturk B. A powerful and efficient algorithm for numerical function optimization: artificial bee colony (ABC) algorithm[J]. Journal of global optimization, 2007, 39(3): 459-471.
- [27]Guerrero-Luis M, Valdez F, Castillo O. A Review on the Cuckoo Search Algorithm[J]. 2021, 940: 113-124.
- [28]Mirjalili, Seyedali, Lewis, Andrew.The Whale Optimization Algorithm[J].Advances in engineering software, 2016,95: 51-67.
- [29]Xing B, Gao W J. Fruit Fly Optimization Algorithm [J].Springer International Publishing,2014,62: 167-170.
- [30]李雅丽,王淑琴,陈倩茹,王小钢.若干新型群智能优化算法的对比研究[J].计算机工程与应用,2020,56(22):1-12.
- [31]Sm A,Smm B,Al A.Grey Wolf Optimizer[J]. Advances in Engineering Software, 2014, 69(7): 46-61.
- [32]Tikhamarine Y, Souag-Gamane D, Kisi O.A new intelligent method for monthly

- streamflow prediction: hybrid wavelet support vector regression based on grey wolf optimizer (WSVR–GWO)[J]. Arabian Journal of Geosciences,2019,12(17): 1-20.
- [33]Nayak B, Mohapatra A, Mohanty K B. Parameter estimation of single diode PV module based on GWO algorithm[J]. Renewable Energy Focus, 2019, 30: 1-12.
- [34]Qin W,Wang L H,Liu Y H,Xu C.Energy Consumption Estimation of the Electric Bus Based on Grey Wolf Optimization Algorithm and Support Vector Machine Regression[J]. Sustainability,2021,13(9) :4689-4689.
- [35]黄波,杨正,王超.基于灰狼算法优化 DBN 的医院网络异常流量识别[J].微型电脑应用,2022,38(1):34-36.
- [36]Chandar S K.Grey Wolf optimization-Elman neural network model for stock price prediction[J].Soft Computing,2021,25(1): 649–658.
- [37]陈长倩,慕晓冬,牛犇,王立志.结合高斯分布的改进二进制灰狼优化算法[J].计算机工程与应用,2019,55(13):145-150.
- [38]徐辰华,李成县,喻昕,黄清宝.基于 Cat 混沌与高斯变异的改进灰狼优化算法[J].计算机工程与应用,2017,53(4):1-9.
- [39]Kohli M,Arora S.Chaotic grey wolf optimization algorithm for constrained optimization problems-ScienceDirect[J].Journal of Computational Design and Engineering,2018,5(4): 458-472.
- [40]谈发明,赵俊杰,王琪.一种改进非线性收敛方式的灰狼优化算法研究[J].微电子学与计算机,2019,36(5):89-95.
- [41]李阳,李维刚,赵云涛,刘翱.基于莱维飞行和随机游动策略的灰狼算法[J].计算机科学,2020,47(8):291-296.
- [42]徐辰华,骆珠光,吴冠宏,刘斌.基于正弦因子和量子局部搜索的灰狼优化算法[J].计算机工程与应用,2021,57(24):83-89.
- [43]龙文,蔡绍洪,焦建军,伍铁斌.一种改进的灰狼优化算法[J].电子学报,2019,47(1):169-175.
- [44]莫艳红,聂慧,刘振丙,杨辉华.基于莱维飞行的灰狼优化算法[J].微电子学与计算机,2019,36(4):78-83.
- [45]黄晨晨,魏霞,黄德启,叶家豪.求解高维复杂函数的混合蛙跳–灰狼优化算法[J].控制理论与应用,2020,37(7):1655-1666.
- [46]Jia S Y,Sun S B,Wang J, Xu F. Research Based on The Improved Grey Wolf Optimization Algorithm[J]. Journal of Physics: Conference Series, 2021,1883(1):1-6.

- [47] Gao Z M, Zhao J. An Improved Grey Wolf Optimization Algorithm with Variable Weights[J]. Computational Intelligence and Neuroscience, 2019, 2019: 1-13.
- [48] Scarselli F, Gori M, Tsoi A C, Hagenbuchner M, Monfardini G. The Graph Neural Network Model[J]. IEEE Transactions on Neural Networks, 2009, 20(1): 61-80.
- [49] Bruna J, Zaremba W, Szlam A, et al. Spectral Networks and Locally Connected Networks on Graphs[J]. Computer Science, 2013.
- [50] Gonzalez G, Gong S, Laponogov I, Bronstein M, Veselkov K. Predicting anticancer hyperfoods with graph convolutional networks[J]. Human Genomics, 2021, 15(1): 33-33.
- [51] 刘臣, 李秋, 郝宇辰. 基于图卷积神经网络的在线社区行为预测[J]. 计算机技术与发展, 2021, 31(4): 28-33.
- [52] Yu B, Lee Y, Sohn K. Forecasting road traffic speeds by considering area-wide spatio-temporal dependencies based on a graph convolutional neural network (GCN)[J]. Transportation Research Part C, 2020, 114(C): 189-204.
- [53] 张彦青. “下三带”理论对承压水上采煤底板突水的预测研究[J]. 山西煤炭, 2014, 34(4): 50-52.
- [54] 张金才, 刘天泉, 张玉卓. 裂隙岩体渗透特征的研究[J]. 煤炭学报, 1997(5): 35-39.
- [55] 于辉. 基于薄板理论的首采工作面基本顶来压步距数值研究[J]. 科学技术与工程, 2018, 18(21): 195-199.
- [56] 刘鸿泉, 王作宇. 采场底板承压水运动[J]. 河北煤炭, 1992(4): 196-201.
- [57] 王作宇, 刘鸿泉, 王培彝, 于树春. 承压水上采煤学科理论与实践[J]. 煤炭学报, 1994(1): 40-48.
- [58] 王成绪. 底板突水的数值计算方法研究[J]. 煤田地质与勘探, 1997(S1): 45-47.
- [59] 钱鸣高, 缪协兴. 岩层控制中的关键层理论研究[J]. 煤炭学报, 1996, 21(3): 2-7.
- [60] 赵伟冬. 含水层水压对底板断层突水危险性的影响[J]. 内蒙古煤炭经济, 2018(4): 138-144.
- [61] 严由吉. 深埋煤层采动覆岩导水裂隙带发育高度研究[D]. 西安: 西安科技大学, 2021.
- [62] 孙少华, 苏礼, 苏志毅. 煤层倾角对底板破坏带深度的影响[J]. 煤, 2017, 26(8): 29-32.
- [63] 刘亮东. 综采工作面覆岩断层采动活化致灾机理研究[D]. 西安: 西安科技大学, 2020.
- [64] 刘方园, 王水花, 张煜东. 支持向量机模型与应用综述[J]. 计算机系统应用, 2018, 27(4): 1-9.
- [65] Choi R Y, Coyner A S, Kalpathy-Cramer J, Chiang M F, Campbell J P. Introduction to Machine Learning, Neural Networks, and Deep Learning[J]. Translational Vision Science & Technology, 2020, 9(2): 14-14.

- [66]Zhao L, Song Y, Zhang C, Liu Y,Li H. T-gcn: A temporal graph convolutional network for traffic prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 21(9): 3848-3858.
- [67]Al-Smadi M,Qawasmeh O,Al-Ayyoub M,Jararweh Y,Gupta B.Deep Recurrent Neural Network vs. Support Vector Machine for Aspect-Based Sentiment Analysis of Arabic Hotels' Reviews[J]. Journal of Computational ence, 2018, 27: 386-393.
- [68]Hochreiter S, Schmidhuber J.Long Short-Term Memory[J]. Neural Computation,1997, 9(8): 1735-1780.
- [69]Wang N, Zhao L, Wang L, Hei X H,Zhao L. A review of opposition-based learning from 2005 to 2012[J]. Engineering Applications of Artificial Intelligence: The International Journal of Intelligent Real-Time Automation, 2014, 29(3): 1-12.
- [70]李彦苍,吴悦.基于高斯变异的蚁狮算法及其在组合优化中的应用[J].中国科技论文,2022,17(3):295-304.
- [71]唐思豪,滕召胜,孙彪,胡清,潘喜福. ADAM改进BP神经网络与动态称重应用[J]. 电子测量与仪器学报, 2021,35(4):127-135.