

基于机器学习的隧址区地面塌陷易发性与 隧道涌水量预测方法及应用研究



重庆大学硕士学位论文 (专业学位)

学生姓名：郝晋渝

指导教师：王桂林 教授

专业学位类别：土木水利

研究方向：岩土工程

答辩委员会主席：郑光俊 正高级工程师

授位时间： 2023 年 6 月

Research on Prediction Method and Application of Ground Collapse Susceptibility in Tunnel Site and Tunnel Water Inflow Based on Machine Learning



A Dissertation Submitted to Chongqing University
In Partial Fulfillment of the Requirement for the
Professional Degree

By

Hao Jinyu

Supervised by Prof. Wang Guilin

June, 2023

摘 要

我国的隧道建设规模大、数量多,所处的地质环境复杂,地貌形态多样,常常面临着穿越岩溶区、构造断层带及软弱层等复杂环境,因此也导致了隧道建设过程中灾害的频发,其中隧址区地面塌陷及隧道突涌水的问题日益突出,导致原有生态环境系统的平衡被打破。隧址区地面塌陷严重危及人民的正常生产生活与安全,突涌水问题直接影响隧道的修建,因此,开展隧址区地面塌陷易发性预测和隧道涌水量预测,对地面塌陷易发性空间分布特征进行分析,对涌水量大小及区间进行预测,为防治提供科学依据,具有重要的理论意义和工程价值。

本文依托国家重点研发计划课题“基于地质云的地质灾害基础信息提取与大数据分析挖掘”(2018YFC1505501),根据收集到的实际工程案例,以隧址区地面塌陷和隧道涌水量为研究对象,分别搭建地面塌陷地理信息数据库和涌水量数据库,分析地面塌陷和涌水量的分布特征,对两种隧道灾害的影响因素进行大数据挖掘和提取,分别建立基于耦合优化的随机森林地面塌陷易发性预测方法和基于CatBoost-可靠度联合的隧道涌水量预测方法,并应用于实际工程之中。本文的主要研究内容和成果如下:

1.搭建隧址区地面塌陷灾害与隧道突涌水灾害数据库,对灾害在各变量上的分布特征以及相关性进行分析。收集地面塌陷样本点 327 个,并选取 18 个影响因子,使用 ArcGIS 实现数据提取及数据可视化,对塌陷与影响因子的空间分布特征进行统计分析。结果表明 87.32%的塌陷点分布于距隧道距离不足 1km 的位置,且大部分地面塌陷处于富含灰岩的地层,含水性为强富水且地貌形态平坦的地方;将隧道埋深(H)、地下水位(h)、RQD 值和产水特性(W)视为随机变量,利用多种大数据分析方法对预测目标和变量的分布及相关性进行分析和可视化描述。结果显示隧道涌水量(WI)主要集中于 0~150m³/h 的范围内,和产水特性(W)的最大信息系数(MIC)为 0.31,具有较高程度的非线性相关性,而与隧道埋深(H)和 RQD 值的非线性相关性较为一般。经过数据清洗后的隧道涌水量样本点缩减了 97 个,使用四分位距法(IQR)检测,无数据异常。

2.提出一种基于因子及参数耦合优化的机器学习方法,并应用于实际隧道区域地面塌陷的易发性预测。该方法通过地理探测器(GeoDetector)探索地面塌陷的空间分异性以及 18 个影响因子对该分异性的解释程度,实现因子优化,又引入贝叶斯优化理论对随机森林(RF)算法进行超参数优化,融合两种优化方法来反复构建模型,从而获取因子及参数耦合优化后的最佳模型。该模型的预测精度和准确率分别为 0.935 和 0.964,对比未优化模型分别提高了 26.7%和 17.8%,验证了该方法的优越

性。使用该模型对整个研究区进行地面塌陷预测,对每个网格单元点输出塌陷概率,基于塌陷概率来划分地面塌陷易发性等级。结果表明极高易发区的面积占比仅为 5.25%,却有 79.15%的地面塌陷灾害,塌陷频率比(FR)高达 15.03,预测结果符合实际,可以为类似工程灾害提供有效参考。

3.提出一种基于机器学习和可靠度联合的隧道涌水量预测方法,并应用于实际隧道突涌水工程案例。该方法通过建立一个基于 Optuna 优化的 CatBoost 回归器 (Optuna-CBR)来输出隧道涌水量预测值,实现 1000 次迭代计算下的超参数优化过程可视化,并通过多个评价指标进行验证。Optuna-CBR 模型在训练集上的平均绝对百分比误差(MAPE)为 5.43%,均方根误差(RMSE)为 5.45,而决定系数 R^2 为 0.98,测试集上的 MAPE 为 8.58%, RMSE 为 11.24, R^2 为 0.95,对比未优化的 CBR 模型及传统线性回归(LR)模型有较大提升,该模型的预测能力强,拟合性能好。根据隧道涌水量分级标准构建功能函数,选取基于 Hermite 多项式展开的随机响应面法作为可靠度分析方法,并使用拉丁超立方抽样进行样本抽取,从而实现 10^6 次蒙特卡洛模拟。计算结果表明,基于可靠度概率分级的隧道涌水量级别有 50.79%的概率隶属于 III_2 级,有 41.66%的概率隶属于 IV 级,而隶属于 V 级的概率只有 7.43%,隶属于 III_1 的概率仅有 0.12%。同时还计算了 90%、95%及 99%置信水平下的涌水量置信区间,确立了本案例中隧道预测涌水量的标准值为 $268.8 \text{ m}^3/\text{h}$ 。

关键词: 机器学习; 耦合优化方法; 易发性预测; 可靠度; 涌水量预测

Abstract

The construction of tunnels in our country is characterized by large scale, numerous projects, complex geological environments, and diverse landforms. These tunnels often encounter challenging conditions such as karst areas, fault zones, and weak layers, leading to frequent occurrence of disasters during the construction process. Among these issues, ground collapse in tunnel site areas and sudden inflow of water into tunnels have become increasingly prominent, disrupting the balance of the original ecological system. Ground collapse in tunnel site areas poses a severe threat to people's normal production, life, and safety, while water inflow directly affects tunnel construction. Therefore, it is of great theoretical significance and engineering value to conduct prediction of ground collapse susceptibility in tunnel site areas and forecast the water inflow volume, analyze the spatial distribution characteristics of ground collapse susceptibility, and predict the magnitude and range of water inflow, in order to provide scientific basis for prevention and control.

This paper relies on the national key research and development program project "Extraction of Geological Hazard Basic Information and Big Data Analysis and Mining Based on Geological Cloud" (2018YFC1505501). Based on collected actual engineering cases, we focus on the ground collapse in tunnel site areas and water inflow volume in tunnels as research objects. We establish a geographic information database for ground collapse and a database for water inflow volume, analyze the distribution characteristics of ground collapse and water inflow, and conduct big data mining and extraction of the influencing factors of these two tunnel disasters. We respectively establish a ground collapse susceptibility prediction method based on coupled optimization and random forest, as well as a tunnel water inflow volume prediction method based on CatBoost-reliability fusion. These methods are then applied to practical engineering. The main research contents and results of this paper are as follows:

1. Establishing databases for ground collapse disasters in tunnel site areas and sudden inflow of water into tunnels, and analyzing the distribution characteristics and correlations of these disasters in various variables. A total of 327 ground collapse sample points were collected, and 18 influencing factors were selected. Data extraction and visualization were performed using ArcGIS to statistically analyze the spatial distribution characteristics of collapses and influencing factors. The results showed that 87.32% of

the collapse points were distributed within a distance of less than 1 km from the tunnel, and most of the ground collapses occurred in areas rich in limestone, with strong water abundance and flat landforms. Tunnel depth (H), groundwater level (h), RQD value, and water production characteristics (W) were treated as random variables. Various big data analysis methods were used to analyze and visually describe the distribution and correlations between the prediction targets and variables. The results showed that the tunnel water inflow volume (WI) was mainly concentrated within the range of 0-150 m³/h, and the maximum information coefficient (MIC) between water production characteristics (W) and tunnel water inflow volume (WI) was 0.31, indicating a high degree of non-linear correlation. The non-linear correlation with tunnel depth (H) and RQD value was relatively moderate. After data cleaning, 97 tunnel water inflow volume sample points were reduced, and data anomalies were detected using the interquartile range method (IQR), resulting in no abnormal data.

2. Proposing a machine learning method based on coupled optimization of factors and parameters, and applying it to the susceptibility prediction of ground collapse in actual tunnel areas. This method utilizes the Geographic Detector (GeoDetector) to explore the spatial heterogeneity of ground collapse and the explanatory power of the 18 influencing factors. It achieves factor optimization by introducing Bayesian optimization theory to optimize the hyperparameters of the Random Forest (RF) algorithm. The two optimization methods are combined to iteratively build models and obtain the best model with coupled optimization of factors and parameters. The predictive accuracy and precision of the model are 0.935 and 0.964, respectively, which are improved by 26.7% and 17.8% compared to the non-optimized model, demonstrating the superiority of this method. Using this model, ground collapse prediction is conducted for the entire study area, and the collapse probability is output for each grid cell. The susceptibility level of ground collapse is classified based on the collapse probability. The results show that the area proportion of extremely high susceptibility zones is only 5.25%, but they account for 79.15% of ground collapse disasters, with a high collapse frequency ratio (FR) of 15.03. The predicted results align with reality and can provide effective reference for similar engineering disasters.

3. Proposing a tunnel water inflow volume prediction method that combines machine learning and reliability analysis, and apply it to an actual tunnel water inflow engineering case. This method involves building an Optuna-optimized CatBoost regressor (Optuna-

CBR) to output predictions of tunnel water inflow volume. The hyperparameter optimization process is visualized with 1000 iterations, and the model is validated using multiple evaluation metrics. The Optuna-CBR model achieves an average mean absolute percentage error (MAPE) of 5.43% and root mean square error (RMSE) of 5.45 on the training set, with a coefficient of determination (R^2) of 0.98. On the test set, the MAPE is 8.58%, RMSE is 11.24, and R^2 is 0.95. Compared to the non-optimized CBR model and traditional linear regression (LR) model, significant improvements are observed, indicating strong prediction capability and good fitting performance of the proposed model. Based on the classification criteria for tunnel water inflow volume, a functional function is constructed. The reliability analysis method selected is the stochastic response surface method based on Hermite polynomial expansion. Latin hypercube sampling is used for sample extraction, enabling 10^6 Monte Carlo simulations. The calculation results show that there is a 50.79% probability of the tunnel water inflow volume belonging to grade III₂, a 41.66% probability of belonging to grade IV, a 7.43% probability of belonging to grade V, and only a 0.12% probability of belonging to grade III₁, based on the reliability probability-based classification of tunnel water inflow volume. Additionally, confidence intervals for water inflow volume are calculated at 90%, 95%, and 99% confidence levels. The standard value of predicted water inflow volume in this case is determined to be 268.8 m³/h.

Key words: Machine learning; Coupling optimization method; Susceptibility prediction; Reliability analysis; Water inflow prediction

目 录

1 绪论.....	1
1.1 选题背景及研究意义.....	1
1.2 国内外研究现状.....	3
1.2.1 地面塌陷易发性预测方法研究现状.....	3
1.2.2 隧道涌水量预测方法研究现状.....	6
1.3 研究内容及技术路线.....	8
1.3.1 研究内容.....	8
1.3.2 技术路线.....	9
2 机器学习与 CatBoost-可靠度预测方法原理.....	11
2.1 引言.....	11
2.2 机器学习基本原理.....	11
2.2.1 随机森林算法.....	11
2.2.2 CatBoost 算法.....	13
2.2.3 K 折交叉验证.....	15
2.3 基于因子及参数耦合优化的随机森林预测方法.....	16
2.4 可靠度基本理论.....	17
2.4.1 可靠度原理.....	17
2.4.2 随机响应面法.....	20
2.4.3 蒙特卡洛法.....	23
2.5 CatBoost-可靠度联合预测方法.....	24
2.6 本章小结.....	25
3 基于耦合优化的随机森林隧址区地面塌陷易发性预测.....	27
3.1 引言.....	27
3.2 隧址区地面塌陷地理信息数据库搭建.....	27
3.2.1 研究区概况.....	28
3.2.2 影响因子选取及分布特征分析.....	33
3.3 基于因子及参数耦合优化的 RFC 预测模型.....	62
3.3.1 地理探测器原理.....	63
3.3.2 贝叶斯优化理论.....	63
3.3.3 模型质量评价指标.....	65
3.3.4 模型建立及验证.....	67
3.4 隧址区地面塌陷易发性预测.....	73
3.5 本章小结.....	75
4 基于 CatBoost-可靠度联合的隧道涌水量预测.....	77

4.1 引言.....	77
4.2 隧道涌水案例数据预处理	77
4.2.1 预测指标选取及统计特征分析.....	77
4.2.2 样本数据清洗.....	82
4.3 Optuna-CBR 涌水量预测模型	88
4.3.1 模型质量评价指标.....	88
4.3.2 模型建立及验证.....	89
4.4 隧道涌水量级别和预测区间可靠度分析	99
4.4.1 基本随机变量标准正态化.....	99
4.4.2 Hermite 随机多项式展开.....	103
4.4.3 涌水量分级概率及预测区间确定.....	104
4.5 本章小结.....	108
5 结论与展望.....	111
5.1 主要结论.....	111
5.2 不足与展望.....	112
参考文献.....	113

图索引

图 1.1 中梁山地区部分隧道分布 ^[7]	2
图 1.2 地面塌陷现场调研	2
图 1.3 隧道突涌水现场调研	2
图 1.4 本文技术路线	10
图 2.1 集成学习原理	12
图 2.2 Bagging 策略原理	13
图 2.3 Boosting 策略原理	14
图 2.4 K 折交叉验证原理	16
图 2.5 二维定义域和极限状态	19
图 2.6 拉丁超立方抽样原理	23
图 3.1 研究区位置	28
图 3.2 塌陷点分布	30
图 3.3 塌陷规模统计: (a)塌陷直径统计; (b)塌陷深度统计	30
图 3.4 不同致塌机制的占比	33
图 3.5 中梁山区域部分隧道的影响	34
图 3.6 地层岩性分布图层和塌陷分布统计特征	36
图 3.7 地层岩性占比	37
图 3.8 距断层距离分布图层和塌陷分布统计特征	38
图 3.9 覆盖层厚度分布图层和塌陷分布统计特征	39
图 3.10 高程分布图层和塌陷分布统计特征	41
图 3.11 坡度分布图层和塌陷分布统计特征	42
图 3.12 坡向分布图层和塌陷分布统计特征	44
图 3.13 坡向与塌陷分布雷达图	44
图 3.14 坡位分布图层和塌陷分布统计特征	46
图 3.15 平面曲率分布图层和塌陷分布统计特征	47
图 3.16 剖面曲率分布图层和塌陷分布统计特征	48
图 3.17 微地貌分布图层和塌陷分布统计特征	50
图 3.18 地表切割深度分布图层和塌陷分布统计特征	51
图 3.19 高程变异系数分布图层和塌陷分布统计特征	53

图 3.20 TWI 分布图层和塌陷分布统计特征.....	54
图 3.21 地层含水性分布图层和塌陷分布统计特征	56
图 3.22 SPI 分布图层和塌陷分布统计特征	57
图 3.23 TRI 分布图层和塌陷分布统计特征.....	59
图 3.24 距隧道距离分布图层和塌陷分布统计特征	60
图 3.25 土地利用类型分布图层和塌陷分布统计特征	62
图 3.26 隧址区地面塌陷 RFC 预测模型的技术路线.....	68
图 3.27 影响因子 q 值排序	69
图 3.28 全部 RFC 模型的预测精度	71
图 3.29 两种 RFC 模型的 ROC 曲线	73
图 3.30 地面塌陷易发性分区和塌陷分布统计特征	74
图 4.1 样本数据统计特征	79
图 4.2 最大信息数热力图	80
图 4.3 不同涌水量级别下 H 和 RQD 的核密度估计	81
图 4.4 不同涌水量级别下 W 和 h 的核密度估计	81
图 4.5 H 分布特征及异常值检测	83
图 4.6 h 分布特征及异常值检测	83
图 4.7 RQD 分布特征及异常值检测.....	84
图 4.8 W 分布特征及异常值检测	85
图 4.9 SOMGN 原理	86
图 4.10 SMOGN 后异常值检测.....	87
图 4.11 异常值剔除后	87
图 4.12 隧道涌水量 CatBoost-可靠度预测模型的技术路线	90
图 4.13 超参数重要性排序	92
图 4.14 优化过程中的超参数交互信息: (a)列采样等级和迭代数; (b)列采样等级和学习率; (c)迭代数和学习率	93
图 4.15 超参数搜索的演变过程	94
图 4.16 超参数优化历史	95
图 4.17 不同预测模型在测试集和训练集上的预测结果: (a)Optuna-CBR 模型; (b)CBR 模型; (c)LR 模型	97
图 4.18 不同预测模型在测试集上的预测结果: (a)Optuna-CBR 模型; (b)CBR 模型; (c)LR 模型.....	99

图 4. 19 H 标准正态化后: (a)直方图; (b)q-q 图	101
图 4. 20 h 标准正态化后: (a)直方图; (b)q-q 图	101
图 4. 21 RQD 标准正态化后: (a)直方图; (b)q-q 图	102
图 4. 22 W 标准正态化后: (a)直方图; (b)q-q 图	102
图 4. 23 隧道涌水量分布和累积分布函数曲线	107

表索引


表 2.1 两种策略的区别	14
表 2.2 常见随机变量分布及多项式类型	21
表 2.3 5 维 5 阶待定系数	21
表 3.1 20%的塌陷点空间信息	31
表 3.2 地层岩性类别及分布特征统计	35
表 3.3 距断层距离类别及分布特征统计	37
表 3.4 覆盖层厚度类别及分布特征统计	39
表 3.5 高程类别及分布特征统计	40
表 3.6 坡度类别及分布特征统计	42
表 3.7 坡向类别及分布特征统计	43
表 3.8 坡位类别及分布特征统计	45
表 3.9 平面曲率类别及分布特征统计	47
表 3.10 剖面曲率类别及分布特征统计	48
表 3.11 微地貌类别及分布特征统计	49
表 3.12 地表切割深度类别及分布特征统计	51
表 3.13 高程变异系数类别及分布特征统计	52
表 3.14 TWI 类别及分布特征统计	54
表 3.15 地层含水性类别及分布特征统计	55
表 3.16 SPI 类别及分布特征统计	57
表 3.17 TRI 类别及分布特征统计	58
表 3.18 距隧道距离类别及分布特征统计	60
表 3.19 土地利用类型类别及分布特征统计	61
表 3.20 混淆矩阵	65
表 3.21 因子及参数耦合优化结果	70
表 3.22 两种 RFC 模型预测能力对比	72
表 3.23 地面塌陷易发性预测结果	73
表 3.24 地面塌陷易发性等级空间熵	75
表 4.1 样本数据统计特征	79
表 4.2 处理更新后样本数据统计特征	87

表 4.3 Optuna 优化后的 CBR 模型超参数	95
表 4.4 不同预测模型的质量评价结果	96
表 4.5 随机变量正态性检验	100
表 4.6 标准正态化后变量分布检验结果	103
表 4.7 待定系数的解	104
表 4.8 隧道涌水量亚级分级 ^[93,142]	105
表 4.9 隧道涌水量分级概率	106
表 4.10 不同置信水平下的涌水量预测区间	107
表 4.11 涌水量可靠度计算结果特征统计	108

1 绪 论

1.1 选题背景及研究意义

隧道建设是我国基础建设的重点对象之一，是提高交通运输效率和促进经济发展的控制性工程。自改革开放以来，我国大力发展隧道工程建设，在隧道设计理念和工法技术上取得了重大突破，建成了一系列重大且具有代表性的宏伟隧道工程。近 10 年来，公路隧道里占公路总里程的比例从 0.133%发展到了 0.378%，截至 2019 年底，我国的公路隧道总数达到了 19067 条，总里程 18966.6km，与十年前的总里程相比增长了 381.14%。在铁路隧道的建设中，截至 2020 年底，投入运营的铁路隧道共计 16798 条，总里程约为 19630km，规划中的铁路隧道约 6354 条，总里程约为 16255km^[1]。近年来随着“西部大开发”战略和“一带一路”发展建设等推动，西部山区隧道建设受到越来越多的重视和关注^[2-3]。然而我国西部山区地形复杂，地貌繁多，具有众多复杂地质情况，决定了西部隧道必然是一批具有“大埋深、长洞线、高应力、强岩溶、高水压、构造复杂、灾害频发”等显著特点的隧道工程^[4-5]。这就意味着隧道施工安全问题成为隧道工程建设中必须面临的挑战，根据已建成的岩溶山区隧道经验，突水突泥、塌方、大变形和地面塌陷已成为隧道建设的主要灾害。据调查统计，在 160 个岩溶地质条件下建成的隧道所遭受的直接损害中，突水突泥在所有灾害中占比高达 74.5%^[6]，严重危害了生产建设安全。而地下水抽取导致了区域地下水位下降，发生地面塌陷，间接损害了隧址区周边房屋和农田以及人民的生命财产安全。例如重庆作为西部大开发的重要战略支点，大量开展隧道建设，其中“四山”地区不可避免地出现地面塌陷急剧增长的现象，如中梁山地区近年来已建隧道 16 条，在建隧道 3 条，规划隧道 10 条，隧址区地下水排泄总量超过 10 万 m³/d，截至 2017 年底诱发地面塌陷超过 280 处^[7]，对当地人民的正常生产生活造成了极大损害。图 1.1 为中梁山地区部分隧道分布，图 1.2 和 1.3 分别为现场调研时地面塌陷及突涌水的照片。



- | | | | | | |
|-------------|------------|----------|-------------|--------------|----------|
| 1 新北碚2#隧道 | 5 龙凤、新龙凤隧道 | 9 土主隧道 | 13 轨1号线隧道 | 17 渝遂高速大学城隧道 | 21 华岩隧道 |
| 2 北碚2#隧道 | 6 渝武高速北碚隧道 | 10 新兰渝隧道 | 14 双碑公路隧道 | 18 襄渝铁路隧道 | 22 华福隧道 |
| 3 绕城高速施家梁隧道 | 7 轨道6号线隧道 | 11 渝怀线隧道 | 15 西永隧道 | 19 成渝高速公路隧道 | 23 西凤岭隧道 |
| 4 兰渝铁路龙凤隧道 | 8 歇马隧道 | 12 井口隧道 | 16 成渝客运专线隧道 | 20 歌乐山隧道 | |

图 1.1 中梁山地区部分隧道分布^[7]

Fig.1.1 Distribution of some tunnels in Zhongliangshan



图 1.2 地面塌陷现场照片

Fig.1.2 Site photos of ground collapse site



图 1.3 隧道突涌水现场照片（左图来自文献[7]）

Fig.1.3 Site photos of tunnel water inflow

对于隧道建设中的地面塌陷和突涌水灾害，其危害性体现在以下几个方面：

（1）危害建筑结构，威胁人员生命安全。隧道涌水易造成衬砌的腐蚀剥落，干扰隧道内电力，软化道床基底等，在涌水量大时，裹挟泥沙，对结构造成直接破坏，大量积水导致人员可能无法快速撤离等。地面塌陷导致房屋底下产生溶腔溶穴，造成基底失稳或房屋倾斜，对隧址区周边居民的正常生活和安全造成极大威胁。

（2）具有突发性和难控制性。不论是突涌水还是地面塌陷都具有强突发性，发生时间和地点难以预测，且不好控制。在隧道施工期需要耗费大量财力和人力做好突涌水的预防工作，而对于地面塌陷预测也需要大量投入，开展地质雷达等手段的勘探工作进行预防，但由于其发生的时间极短且规模数量不一，导致防治工作依然难以开展。

（3）破坏生态系统平衡。隧道建设抽取大量地下水，地下水位大幅下降，地下水系统遭到破坏，地下生态系统的平衡被打破。不论是隧道抽排水还是突涌水，都会有一部分通过地表渗流及岩溶管道的方式回补至地下，在这一过程中水质受到污染，而排大于补，地下水资源走向贫乏甚至枯竭，从而诱发地面塌陷。

由于隧址区地面塌陷和隧道突涌水灾害的频发，对隧道工程建设的干扰性、阻碍性强，危害性大，再加上灾害的突发性强，现有的防治手段多为被动补救而非主动预防，因此如何对隧道灾害进行有效预测成为了热点和难点，建立合理准确的隧道灾害预测方法具有重要意义。由于当前已建隧道数量庞大，累积了巨大体量的可供参考的数据，因此从隧道案例中挖掘有效数据，建立基于大数据的预测方法成为了隧道灾害预测的手段之一。随着计算机硬件发展和人工智能算法的更新迭代，机器学习方法已经普遍应用于工程建设，机器学习模型具有预测准确率高、计算速度快的优势，但仍存在一些有待提升的地方。本文拟建立因子及参数耦合优化的机器学习预测方法和机器学习-可靠度联合预测方法分别对隧址区地面塌陷易发性和隧道涌水量进行预测，通过隧道灾害的现状研究，在前人的研究基础上建立方法，通过理论研究、工程案例收集来搭建案例数据库，然后建立预测模型，开展预测工作，进一步提高机器学习模型的预测准确率，解决机器学习中缺乏不确定性分析等不足，为复杂地质环境下的隧道施工安全和隧址区地面塌陷有效预警提供一定的科学依据。

1.2 国内外研究现状

1.2.1 地面塌陷易发性预测方法研究现状

地面塌陷作为隧址区常见的地质灾害具有突发性强、破坏性高的特点，专家学

者对地面塌陷主要采取数值建模的方式分析其塌陷机理和塌陷模式，目前主要的塌陷理论有潜蚀论、真空吸蚀论等，并结合地质因子和水文因子对地面塌陷进行预测预警，而机器学习方法同样越来越广泛地被应用于地面塌陷易发性预测。

地面塌陷易发性预测需要选取影响因子，通常从塌陷机理层面展开分析和选取，而同为地质灾害的滑坡易发性研究在影响因子选取上也能提供借鉴意义。地面塌陷是一种多机制的地质灾害，康彦仁^[8]总结了不同力学效应导致的不同塌陷模式，共有 8 种基本致塌模式。王滨和贺可强^[9]根据地下洞室平衡拱理论建立起临界土洞的极限平衡高度公式，从而实现对地面塌陷的预测。贾龙等^[10]通过 FLAC3D 来模拟土洞的演化，通过“等沉面”和“塑性区”来判断土洞的稳定性以及土洞所能发育的最大程度。吴庆华等^[11]采用物理模型试验来还原覆盖层为砂土的地面塌陷发育过程，并研究了黏土对塌陷的阻隔，从而实现了塌陷机理的定量化研究。张海坦等^[12]对重庆市歌乐山区域地面塌陷发育特征进行研究，为易发性影响因子的选取提供了参考。高培德和王林峰^[13]由极限平衡理论提出覆盖型塌陷土体的稳定性计算方法和塌陷范围的计算方法。薛明明^[14]等通过数值模拟方法研究降雨速率变化对土洞塑性区分布的影响，结果表明土洞大小和降雨速率对覆盖层土体有较程度的影响。Zhao 等^[15]建立了隐伏溶洞的数值模型，他的研究表明，地下水的饱和和扩大了溶洞，并在岩溶塌陷中发挥了重要作用。Wei 等^[16]使用由九个因素组成的层次结构 AHP 建立了岩溶塌陷的易发性模型，易发性分析结果表明，覆盖层厚度和塌陷发育是最敏感的参数。吴远斌等^[17]认为隧道施工对地下水位的疏排有影响，疏水的不同阶段对应了不同的诱发因素。强壮^[18]用有限元对岩土地面塌陷机理进行研究，得到不同覆盖层厚度和降雨条件下的塌陷发育规律。陈学军等^[19]基于大量的塌陷案例提出 6 个地面塌陷影响因子，通过熵权法计算它们的权重并建立预测模型。Wei 等^[20]发现 Karst 地质结构和岩溶发育水平高度决定了塌陷发生与否。Mariano Di Napoli 等^[21]建立了一个由 400 个滑坡点和 11 个因素组成的数据库。Zhou^[22]等在滑坡易发性研究中提出因子优化，并比较了两种不同的结果。Paola Reichenbach 等^[23]总结了基于统计的滑坡易发性模型，并使用数据库的统计信息建立了易发性的最佳地形分区，并且强调收集地理信息有助于建立高质量的模型。Calista Monia 等^[24]基于地形、水文、岩性和地貌学，使用两个特定的数值模拟软件评估了滑坡的分布及其潜在易发区域，并使用地理信息系统绘制易发图。Taheri Kamal 等^[25]将化学离子作为影响因子，为地面塌陷易发性预测指标选取开拓了新思路。孙德亮等^[26]对滑坡因子分类标准进行优化，采用滑坡点属性来构造因子层，来提高滑坡预测模型的精度和准确率。薛蒙蒙^[27]构建了 19 个评价因子来对山区滑坡易发性进行建模，其中地质构造因子和水文因子与地面塌陷影响因子的选取有

一定共性。Titti Giacomo 等^[28]将滑坡易发性的尺度提高,联合不同国家地区的开源滑坡清单建立易发性预测及验证。

对于预测模型的选择,专家学者进行了大量研究。Wu 等^[29]使用层次分析法选择了 8 个评价因子来预测山东泰来盆地地面塌陷的易发性。Yao 等^[30]使用基于层次分析法的模糊综合评价方法来评估岩溶现状并预测其塌陷。Hu 等^[31]利用层次分析法(AHP)和逻辑回归(LR)模型对武汉市岩溶塌陷危险区进行了评价,LR 模型比 AHP 模型更准确。白永学等^[32]为了研究隧道盾构施工诱发地面塌陷导致的变形曲线影响,采用了最小二乘支持向量机来建立预测模型。Ding 等^[33]使用模糊层次分析法(FAHP)和灰色关联分析法(GRA)建立了岩溶塌陷风险评估模型。Deng 等^[34]结合 GIS 使用了 6 个因素来评估岩溶区域的风险,然后在不考虑地下水对岩溶塌陷的影响的情况下进行了二次评估。Subedi Praveen 等^[35]比较了基于层次分析法和逻辑回归法的塌陷易发性区划分方法。AlSanea Dalal 和 Abdullah Waleed^[36]选择了 8 个因素,并通过 AHP 评估了灰岩区域地面塌陷易发性。Yong Je Kim 等^[37]使用 7 个关键因素来计算地面塌陷易发性指数(SSI)。Sun 等^[38]使用贝叶斯优化算法来评估滑坡的易发性。谢静峰等^[39]利用基于遗传算法优化的极限学习机开展地面塌陷易发性预测。V. Vakhshoori 和 M. Zare^[40]使用证据权重(WofE)、模糊逻辑法和频率比(FR)建立滑坡易发性图,并比较了三种方法的预测结果,结果表明频率比优于证据权重和模糊逻辑。Taheri 等^[41]开展了基于层次分析法和塌陷易发性指数的易发性评价,研究区存在由低到高的塌陷风险,在对塌陷的研究中^[42],他利用地面塌陷样本、若干条件因子和四种不同的统计方法建立了几种易发性模型。Salles 等^[43]利用地质数据、场地视觉分析等对不同等级易发性的区域进行分类。Zhang 等^[44]基于模糊数学原理和层次分析法开发了一个地面塌陷易发性评估系统。Rosdi 等^[45]使用 AHP 方法评估了灰岩地面塌陷的易发性。Kim Yong Je 等^[46]对碳酸盐岩性地层的塌陷空间概率分布建立了预测模型,并得到了良好的验证结果。Li 等^[47]研究了不同数据模式及与环境因素的联系对塌陷的影响,并提出了 20 种不同耦合条件下的预测模型来对比验证,来寻求最优预测水平的耦合预测模型。Li 等^[48]通过 44 个地面塌陷数据,利用 3S 技术获取 14 个致塌因子来开展预测。Mansour Zaagane 等^[49]通过频率比、多元线性回归和信息价值模型来建立滑坡易发性。Sumit Das 等^[50]还将 AHP 方法应用于洪水灾害制图。Zhou 等^[51]采用 SHAP 和 XGBOOST 方法建立了滑坡易发性评价模型。

上述方法可以有效地预测地面塌陷,但也存在一些不足:数值分析可以建立有效的塌陷模型,充实塌陷机理理论研究,但无法实现地面塌陷防治所需的预测预警模型或易发性分区模型。大数据分析及建模能够实现这一点,但传统的数据分析方

法局限性较大,例如在证据权重法中,每个影响因素的权重完全由作者或专家决定,受主观判断的影响很大。而 AHP 法在选择影响因素方面存在局限性,由于主准则层和次准则层的构造,当影响因素过多时,AHP 法就会变得非常繁琐。因此构建机器学习预测模型是较好的选择,但目前的机器学习预测模型的优化方法较为单一,对于预测精度的提高仍有上升的空间。

1.2.2 隧道涌水量预测方法研究现状

隧道突涌水常发生于隧道施工过程中,尤其是在地下水位较高,降雨频繁且雨量大的地区。其具有突发性强、破坏力巨大的特点。目前专家学者们主要采用数值分析手段建立数值模型,考虑多因素对隧道涌水的影响,对地下水渗流场进行分析计算,设计最优隔水岩层厚度,同时也结合机器学习方法,开展大数据建模,输出隧道涌水量点预测结果,对隧道涌水量预测结果进行量化分析以及建立隧道涌水风险评价体系。

隧道涌水量的机器学习预测方法同样需要对预测指标进行选取,专家学者对隧道涌水机理和因素展开了研究,为预测指标的选取提供了参考,其中对机理的研究通常采用数值模型或经验公式。林传年等^[52]对不同含水地质构造的岩溶区进行划分,提出相应较合理的隧道涌水量预测方法,基于隧道所处完整水文地质单元的岩溶水补径排条件,提出综合考虑垂向分带和水平分带影响的涌水量估算概念模型。李鹏飞等^[53]总结了隧道涌水量预测的 3 种主要方法并讨论了围岩渗透系数等 6 个因素对隧道涌水量的影响,研究认为隧道涌水量随围岩渗透系数的增大线性增大,随地下水位高度的升高存在一个先减小后增大的过程,同样的开挖面积条件下圆形隧道的涌水量最小。李铮等^[54]使用 Visual-MODFLOW 软件进行数值建模分析,考虑注浆圈和初衬渗透系数对隧道涌水的影响。刘常昊等^[55]提出了一种基于地质雷达的隧道富水段涌水量预测方法,引入隧道富水区域结构模型参数,建立基于地下水动力学的隧道涌水量预测公式。王璐^[56]基于 105 个隧道涌水灾害样本构建了由 8 个指标组成的隧道涌水致灾因子,涉及了地质构造和水文地质等宏观因素。傅鹤林等^[57]考虑了支护结构内缘承担的水头,构建数值模型并分析相关参数,提高涌水量预测的精度。Jin 等^[58]采用三种经验公式对岩溶隧道涌水量进行计算,通过变更设计方案来减小隧道开挖对周边地下水环境的影响。魏兴萍等^[59]采用地下水动力法和古德曼经验公式计算涌水量,从而分析隧道修建对水体渗漏的影响。王飞等^[60]为了提高隧道涌水预测的准确度,由岩性、地形、地质构造和水文条件等宏观因素选取了 7 个子因素作为隧道富水程度的预测指标。K. H. Holmøy 和 B. Nilsen^[61]基于对挪威某项目 6 条隧道的详细研究,通过将涌水量与 8 个地质影响因素进

行联合分析并验证假设。Wang 等^[62]提出了基于球坐标转换的半理论半经验涌水量预测公式。

在机器学习算法的选择和优化上,前人也做了一些研究。周玲等^[63]以遗传算法、粒子群算法和最小二乘法等多种单项预测模型为基础,构建了隧道涌水量的优化组合预测模型。肖建于等^[64]将模糊证据理论应用于煤层底板的突水状态判别,并生成突水基本概率。李建林等^[65]将混沌理论与广义回归神经网络模型相结合,考虑矿井突涌水产生混沌现象的机理,构建神经网络模型,实现涌水量预测。Ma 等^[66]采用基于粒子群优化的改进灰色模型对断层涌水量进行预测。Feng 等^[67]从地质因素、水文条件和工程环境 3 个方面提取出 9 个预测指标,并采用 AHP 结合 BP 神经网络来建立了山岭隧道涌水量综合预测模型。Wang 等^[68]提出了一种基于改进直觉模糊理论的方法,引入正态分布对传统属性综合评价模型进行优化,选取不同影响因素来构建多层次的突涌水风险评价体系。Kang 等^[69]使用模糊聚类方法并结合 7 种常见离子含量来对地下水类型进行划分,建立了基于隧道开挖期间监测数据的涌水量预测模型。魏晓悦等^[70]构建了由 13 个预测指标组成的评价体系,利用主成分分析法对突水风险预测指标提取主成分并降维,将剩余预测指标用于改进 RBF 神经网络评价模型,实现铁路隧道风险评价。毛正君等^[71]使用递阶层次结构模型来确定突涌水风险等级,并认为裂隙水隧道突涌水风险的主控因素之一。胡迪勇^[72]通过数值方法对隧道围岩、埋深、空间尺寸等对隧道稳定性的影响进行分析,而后采用 AHP 来评价隧道突涌水危险性。欧光照^[73]建立了基于自主采样法的 SVM-BPNN 涌水量预测模型,通过六种不同机器学习模型的对比分析来验证模型质量,并对工程案例展开涌水量的点预测与区间预测。王连国和宋扬^[74]使用遗传算法改进人工神经网络,在对煤层底板突水的预测中考虑了水源、水压、隔水层、断层等因素。Mohsen Golian 等^[75]介绍了一种使用 GMS 软件的 MODFLOW 代码预测隧道掘进机(TBM)开挖时的涌水量的方法。H.S. Xie 等^[76]利用有限差分软件 FLAC3D 建立了数值模型并进行了计算,并讨论了隧道半径、衬砌厚度、衬砌渗透系数等影响因子。仇文岗等^[77]提出了一种基于随机森林的预测模型,并结合 4 种常见的超参数优化算法预测 TBM 掘进速度。Fu 等^[78]进行了考虑开挖扰动和地应力对围岩渗透系数影响的隧道突水分析。Li 等^[79]建立高斯过程回归模型(GPR),结果表明高斯过程在隧道涌水量预测分析中的表现优于支持向量机(SVM)和人工神经网络(ANN)。Nguyen Ngoc-Hien 等^[80]使用一个包含 6 个输入变量的 424 个样本的数据集来构建 CatBoost 模型,以用于预测含偏高岭土的水泥基砂浆的抗压强度。Grbčić Luka 等^[81]建立了基于环境特征预测大肠杆菌和肠球菌的 CatBoost 模型,与其他评估算法相比预测效果较好。Kaiser Maria 等^[82]使用基于树的分类器对雨洪和

山洪易发区进行区域尺度预测,分别建立了随机森林(RF)、梯度提升决策树(GBDT)和 CatBoost 模型(CB),而 CB 模型的预测性能最佳。Lee Seunghye 等^[83]建立 CatBoost 算法进行钢管混凝土柱强度预测,计算出与实验结果高度接近的预测结果。孔瑞瑶等^[84]构建 CatBoost 水深反演模型,与传统水深反演模型及 Boosting 中的 XGBoost 和 LightGBM 模型的反演精度进行比较,试验结果表明准确性最高,效果更佳。陈点点^[85]等采用带交叉验证的网格搜索法分别对 CatBoost 和随机森林 2 种机器学习模型进行超参数调优,确定模型最优参数配置,并对比不同模型反演精度,确定最优模型。

以上研究主要着重于对隧道涌水量大小的预测,然而由于知识的不完备性、实地调查信息取值的不准确性等因素,预测模型中的参数或变量是具有不确定性的,通常服从某种分布,因此部分学者还结合可靠度分析方法对隧道突涌水灾害中的概率问题展开了研究。王遇国^[86]结合可靠度理论来研究岩溶构造隔水防突岩层破坏突水风险问题。鲁海峰和姚多喜^[87]总结隔水底板的两种不同失效模式,从而构建两种功能函数来计算隔水底板的失效概率。Karl Yau 等^[88]利用 Matlab 生成随机分布的岩溶洞穴,来研究隧道中岩溶分布的不确定性,进而评估岩溶的空间变异性及其对隧道衬砌和涌水量的影响。Dall'Alba Valentin 等^[89]在不确定性分析阶段考虑了不同的水文地质场景,使用蒙特卡洛方法对岩溶隧道涌水量进行概率估计。Hao 等^[90]利用一种改进的属性识别方法展开岩溶隧道突水危险性评价的不确定性分析,利用蒙特卡洛模拟计算突涌水风险的概率分布。Shi 等^[91]结合蒙特卡洛法构建了随机确定性三维裂隙网络渗流模型,来预测隧道各里程段涌水量。

从上述研究可以看出,目前经验法及数值法对隧道涌水量的预测研究取得了很好的发展,能够进行一定的有效预测,但也存在一些不足:经验法和数值法通常基于已知的且较为简单的地质模型,但对于复杂的水文地质条件,则难以准确地预测涌水量。机器学习方法在隧道涌水量预测中得到了越来越多广泛的应用,相较于经验法或数值法,能够考虑复杂的地质条件(包括更多的地质水文因素),并且有着较好的预测效果,但鲜有考虑因预测模型中参数或变量的不确定性导致的预测结果的不确定性问题,缺乏对隧道涌水量预测结果更深层次的研究。

1.3 研究内容及技术路线

1.3.1 研究内容

本文基于上述研究现状中存在的不足及发展趋势,拟通过收集隧址区地面塌陷和隧道涌水量的案例数据,分别开展影响因素特征分析,建立机器学习预测模型,

通过因子及参数优化方法提升机器学习模型的预测精度和泛化性能，并应用于隧址区地面塌陷易发性预测。引入可靠度基本理论，选取随机响应面作为可靠度计算方法，对混沌多项式进行展开，构建显式功能函数，进行可靠度分析，进而确定隧道涌水量分级概率和不同置信水平下的预测区间。主要的研究内容有以下几个方面：

1.搭建隧址区地面塌陷灾害与隧道涌水量灾害数据库

该数据库包括灾害样本点和所携带的变量属性信息。收集地面塌陷样本点并选取 18 个影响因子，使用 ArcGIS 实现数据提取及数据可视化，并统计各子类别面积占比和塌陷占比，以频率直方图和塌陷频率比的形式对塌陷分布进行定量分析。收集隧道涌水量数据和 4 个随机变量，分别为隧道埋深(H)、地下水位(h)、RQD 值和产水特性(W)，利用散点图和最大信息系数等多种大数据分析方法对预测目标和变量的分布及相关性进行分析和可视化描述，使用 SMOGN 数据增强算法、异常值剔除的方法进行数据预处理。

2. 基于耦合优化的随机森林隧址区地面塌陷易发性预测

提出一种基于因子及参数耦合优化的机器学习方法，并应用于实际隧道诱发地面塌陷工程案例。通过地理探测器(GeoDetector)探索地面塌陷的空间分异性以及所有影响因子对该分异性的解释程度，以 q 值表示解释力，并基于 q 值排序实现因子优化。引入贝叶斯优化理论对随机森林(RF)算法进行超参数优化，融合两种优化方法来反复构建模型。模型的质量通过精度、准确率、ROC 曲线和 AUC 值进行评价，从而获取因子及参数耦合优化后的最佳模型。使用该模型对整个研究区进行地面塌陷预测，对每个网格单元点输出塌陷概率，基于塌陷概率来划分地面塌陷易发性等级，并以空间熵来判断易发性分级结果的空间稳定性及规律性。

3. 基于 CatBoost-可靠度联合的隧道涌水量预测

提出一种基于机器学习和可靠度联合的隧道涌水量预测方法，并应用于实际隧道突涌水工程案例。该方法通过建立一个基于 optuna 优化的 CatBoost 回归器模型(Optuna-CBR)来预测隧道涌水量，利用 python 的可视化模块对超参数优化特性进行分析，并通过常用的回归预测模型评价指标进行验证。根据隧道涌水量分级标准构建功能函数，并确立随机变量的维度和多项式阶数，通过 Hermite 混沌多项式展开来求解高维非线性隐式功能函数，使用拉丁超立方抽样进行样本抽取，开展 10^6 次蒙特卡洛模拟，计算得到隧道涌水量分级概率、置信区间和涌水量标准值。

1.3.2 技术路线

本文基于已有文献研究和资料收集，分别展开基于耦合优化的随机森林地面

塌陷易发性预测和基于 CatBoost-可靠度联合的隧道涌水量预测。搭建隧址区地面塌陷数据库,以地理探测器和贝叶斯优化库为工具,提出因子及参数耦合优化方法,对随机森林分类器(Random Forest Classifier,RFC)进行优化,与优化前的 RFC 模型做对比,展开模型质量评价,并实现塌陷与影响因子的分布可视化,然后使用优化后的 RFC 模型对研究区的地面塌陷易发性进行预测,对结果进行分区统计,计算塌陷频率比和空间熵。搭建隧道涌水量数据库,使用三种不同的机器学习预测模型实现隧道涌水量点预测,并展开模型质量评价,构建以混沌多项式展开为基础的随机响应面,结合蒙特卡洛模拟,对隧道涌水量预测进行可靠度分析,最后得到涌水量分级概率、预测区间和标准值。本文技术路线如图 1.4 所示。




图 1.4 本文技术路线

Fig.1.4 Technical route of this article

2 机器学习与 CatBoost-可靠度预测方法原理

2.1 引言

机器学习^[92]是一门通过计算手段,利用“经验”来提升系统性能的一种方法。在计算机系统里,“经验”是以数据的方式存在的,因此机器学习实质上是一种在计算机上从数据中学习并生成模型的方法。有了机器学习算法,输入经验数据,就能产生一个模型,而这个模型在面对新的场景时就会提供一个具有参考意义的判断。近年来由于计算机的飞速发展,大数据概念的提出和机器学习算法的不断革新,在工程分析中也有越来越多利用机器学习方法来解决工程问题的案例,尤其是用于解决工程中的非线性相关性问题,例如多变量条件下的地质灾害预测预警研究^[93-96],边坡稳定性分析以及可靠度分析等研究^[97-98]。本文拟将机器学习方法应用于隧址区地面塌陷易发性预测和隧道涌水量预测。

对于机器学习算法最重要的是拥有好的预测能力,以往的研究多集中于单一的优化方法,没有综合考虑算法本身和实际工程的需求和变化,对于预测精度的提高仍有上升的空间。另外将可靠度引入机器学习回归器的预测中,并结合概率分级和最大隶属度理论,可以更好地对预测结果进行拓展应用。例如,郑帅等^[99]构建了细菌觅食优化算法的最小二乘支持向量机模型,搭建分级指标和围岩级别的非线性映射关系,并对机器学习模型输出结果进行可靠度分析,并应用于隧道建设的动态设计。因此,本章将系统性地介绍随机森林算法和 CatBoost 算法原理,以及可靠度基本理论,然后展开因子及参数耦合优化的随机森林预测方法以及 CatBoost-可靠度联合预测方法研究,为后续工程案例的应用提供理论基础和手段。

2.2 机器学习基本原理

2.2.1 随机森林算法

随机森林(Random Forest,RF)算法由于其计算效率高、结构简单及预测效果好,近年来被广泛应用于岩土工程领域^[100-103]。随机森林是一种基于统计学理论的机器学习算法,属于集成学习的范畴^[104]。在机器学习的有监督学习算法中,期待的目标是得到一个在多方面性能都表现良好的模型,然而通常只能得到在某一部分表现较好的模型,即弱监督模型。而集成学习就是结合多个弱监督模型以期得到强监督模型的算法,其思想是即便某一弱监督模型产生了错误的预测,也能通过其他的弱监督模型纠正回来。也就是说集成学习并不是一个机器学习算法单元,而通过结

合多个弱学习器来构建预测模型。集成学习可以用于分类问题集成，回归问题集成，特征选取集成，异常点检测集成等，也被定义为强学习器。图 2.1 展示了集成学习的原理。




图 2.1 集成学习原理(修改自文献^[105])

Fig.2.1 Principles of Integrated Learning

决策树作为随机森林算法的基学习器，模型判别能力强，原理简单且有良好的可解释性，能够完成分类及回归任务，也能对输入参数进行特征重要度分析，这就决定了随机森林作为决策树的集成，也具有相应的优点。随机森林原理的核心是 Bootstrap Aggregating，即 Bagging 思想^[106]，并行训练多个基学习器，从训练集里进行抽样构建单个决策树的子训练集，决策树的每个节点代表样本集的特征，对每个决策树模型进行训练，最后结合所有决策树模型，产生预测结果。Bagging 策略原理如图 2.2 所示。

随机森林算法流程如下：

- (1) 从样本数据中随机取样，有放回地选取 n 个样本；
- (2) 随机选择 k 个特征，用选择的样本通过这些特征构建决策树，再根据基尼不纯度选择其中最好的一个特征；
- (3) 重复以上步骤 m 次，可生成 m 棵决策树，形成随机森林；
- (4) 对新的数据进行预测，经全部决策树决策，共同决定结果。对于分类问题，由每个决策树模型投票决定最终预测结果的所属类别，对于回归问题，取所有决策树模型的均值作为预测结果。




图 2.2 Bagging 策略原理

Fig.2.2 Bagging strategy principle

随机森林在 Bagging 的基础上，样本数据采样和特征选择采样均为随机且有放回的方式。传统决策树在特征选择上会在当前节点的特征集合中选择最优特征，但随机森林中，每个决策树节点随机选择特征集合的一个子集，并且特征子集之间相互独立，再在这个子集中选择最优特征。这种方式叫做 **Bootstrap sampling**，即自主采样法。这样得到的采样集与初始样本和其他的采样集是不同的，可以很好生成不同的基学习器，也就是单个决策树。单个决策树之间的差异度越大，最终的随机森林模型的泛化性能就越好，采样的随机性增大了决策树构建的偏差，使得单个决策树的预测性能因为随机扰动而下降，但随着决策树数量的增加，以及对于最终结果的选择是平均下来的，使随机森林的方差很小，模型收敛于一个较低的泛化误差值，不容易过拟合。

2.2.2 CatBoost 算法

CatBoost 算法和随机森林算法一样，同属于集成学习的范畴，只不过随机森林原理的核心是 Bagging 策略，而 CatBoost 基于 Boosting 策略^[107]。Boosting 的核心思想在于通过迭代多个基学习器，每一次迭代训练都关注于上一个基学习器没能解决的部分，调整数据分布，以此减小有监督学习中的训练误差。并且在迭代训练的过程中，计算每一个基学习器的错误率，然后赋予该基学习器权重。对于分类问题，在最后的集成环节进行加权投票，决定预测结果的所属类别；对于回归问题，取每个基学习器的加权平均作为最终预测结果。Boosting 策略原理如图 2.3 所示。

Boosting 策略的计算流程如下：

- (1) 基于训练集的初始权重训练出一个弱学习器 M_1 ；
- (2) 由 M_1 的错误率来更新训练样本的权重，赋予 M_1 中预测错误率高的训练样本更高的权重，以此训练 M_2 ；
- (3) 重复步骤 2，直至训练出 n 个弱学习器， n 为事先指定的数目；
- (4) 将 n 个弱学习器通过加权集成的方式得到最终的强学习器。




图 2.3 Boosting 策略原理

Fig.2.3 Boosting strategy principle

由于两种策略的核心思想不同，因此 Boosting 与 Bagging 主要存在数据样本、结果集成、训练顺序以及预期目标上的区别，如表 2.1 所示。

表 2.1 两种策略的区别

Table 2.1 Differences between the two strategies

区别	Bagging	Boosting
数据样本	随机采样	全部数据
结果集成	对全部结果平权投票或取均值	对每个结果加权投票或取加权平均
训练顺序	并行训练，互不干扰	串行训练，有先后顺序
预期目标	提高泛化性能，解决过拟合的问题	提高训练精度，解决欠拟合的问题

CatBoost 诞生于 XGBoost 和 LightBGM 等主流 Boosting 算法之后，但相比于前面两种，CatBoost 的优势在于：

- (1) 基学习器采用了对称决策树，避免过拟合；
- (2) 使用了组合类别特征，可以利用到特征之间的联系，丰富了特征维度；
- (3) 嵌入了自动将类别型特征处理为数值型特征的创新算法；
- (4) 解决了梯度偏差及预测偏移的问题，提高了算法的准确性和泛化能力。

该算法通过构建新的对称决策树来拟合模型梯度，但这容易存在由有偏的点态梯度估计引起的过拟合问题。也就是说，在每个步骤中使用的梯度都由当前模型中的相同数据点来估计，就会导致在特征空间任何域中的估计梯度分布与该域中真实梯度分布相比发生了偏移，从而导致过拟合。为了解决这个问题，CatBoost 做出了改进。设 F_i 为构建 i 棵树后的模型， $g^i(X_k, Y_k)$ 为构建 i 棵树后第 k 个训练样本上面的梯度值。为了使得 $g^i(X_k, Y_k)$ 无偏于模型 F_i ，需要在没有 X_k 参与的情况下对模型 F_i 进行训练。由于需要对所有训练样本计算无偏的估计梯度，因此对于每一个样本 X_k ，训练一个单独的模型 M_k ，且该模型从不使用基于该样本的估计梯度来获取更新。使用 M_k 来估计 X_k 上的梯度，并使用这个估计梯度对结果决策树进行评分。

2.2.3K 折交叉验证

用于机器学习建模的样本数较少时，当所有样本数据都被用于模型训练，会导致样本的某些特征会被学习器认为是模型本身的一部分，从而导致模型过拟合。K 折交叉验证^[108]可以有效地解决过拟合的问题，提高模型的泛化性，是机器学习模型优化方法之一。其具体步骤为：

- (1) 将全部样本数据划分为 K 个大小相等的子集，这些子集互不相交，并且尽可能与总集保持数据分布的一致性；
- (2) 将当前子集作为测试集，剩余子集作为验证集，让学习器进行训练和测试；
- (3) 遍历所有子集，即学习器经历 k 次训练和测试，得到共 k 个结果；
- (4) 将 k 次迭代训练得到的评估结果相加，除以子集总个数 k ，将得到的平均值作为模型最终的评估结果。

对于机器学习模型的超参数优化来说，K 折交叉验证可以较好地反映不同超参数的取值对模型精度的影响，通过不断调整超参数来找到模型最佳的交叉验证后的精度，以此确立最优超参数的取值。本文取 10 折交叉验证来调整模型性能，其原理示意图如下。




图 2.4 K 折交叉验证原理

Fig.2. 4 K-fold cross validation principle

2.3 基于因子及参数耦合优化的随机森林预测方法

机器学习预测方法的核心在于能否通过样本训练得到一个具有优秀预测能力的模型，有学者提出了多种优化方法^[109-111]，这些方法着重于对模型本身超参数的优化和对训练样本数据的优化，并且取得了较好的效果。超参数的取值很大程度直接影响了模型的预测性能。而对一个目标进行预测需要构建样本数据进行训练，其中就包含了与该预测目标存在理论相关性的影响因子，或称之为预测指标。样本数据的容量及组成影响预测模型的训练，进而影响模型的预测性能。如何将机器学习模型的预测能力最大化，使得预测结果最大程度地符合真实情况，是具有重要意义的。

基于前人的研究，本文提出一种因子及参数耦合优化的机器学习预测方法，探索不同的模型超参数和影响因子，旨在找到一个因子与参数的组合，使得机器学习模型的预测能力达到最佳。本方法的实现步骤为：

(1) 构建初始样本数据集。该数据集包括了目标预测值(Y)与影响因子($X_1, X_2, \dots, X_n$)的属性，当影响因子为数值型变量，其属性则为数值，当为类别型变量，其属性则为子类别。例如在后续的隧址区地面塌陷预测中，地层岩性就作为一个影响因子，而它的属性则为具体的某一地层；

(2) 考虑预测目标 and 影响因子的现实工程意义，选取合理的方法对影响因子进行可解释性的排序，根据排序结果依次剔除一个影响因子，例如当按照敏感性进行排序时，以敏感性从小到大的顺序依次剔除因子。从而构建总共 N 个样本数据集，第一个样本数据集拥有全部 n 个影响因子，然后剔除排序末尾的影响因子，第二个样本数据集拥有 n-1 个影响因子，以此类推，直到排序首端的因子单独构成第

N 个样本数据集；

(3) 选取机器学习模型待优化的超参数，依次输入步骤(2)的 N 个样本数据集，对每一个输入的样本数据集以一定且相同的比例划分训练集和测试集，进行模型训练。每一次对预测模型的训练都使用相同的优化方法进行超参数优化。重复此步骤直至遍历全部 N 个样本数据集，得到 N 组预测模型的最优超参数组合以及在该组合下训练模型在测试集上的预测精度；

(4) 取预测精度最大值对应的机器学习模型，该模型对应的影响因子和超参数组合就为因子及参数耦合优化的最终结果。选取该类预测模型对应的多个评价指标，使用测试集数据进行综合性的结果验证，对预测模型进行质量检验，最后使用该预测模型对实际工程案例进行应用。

2.4 可靠度基本理论

机器学习是一种基于数据驱动建立的模型，在实际工程应用中，机器学习模型的输入为工程中的各种参数，例如岩土体特性的各项参数指标，如泊松比，弹性模量，土体粘聚力和内摩擦角等，也包括地灾工程的各种地质参数指标，如富水程度，地层岩性，覆盖层厚度等。对应的，机器学习模型输出的结果有分类结果和回归结果，例如结构失效与否，滑坡与否或者滑坡位移量大小、隧道涌水量大小等。由于机器学习模型的训练数据十分庞大，通常将多个工程案例收集起来作为整体，以此构建预测模型，因此各种输入的参数在这一整体中具有各自的分布特征。所以在构建好预测模型之后，对某一个案例进行预测，其结果就具有不确定性，而这种不确定性就需要通过基于参数的分布特征来进行可靠度分析。另外这些输入参数和输出结果之间具有一定程度的非线性关系，但无法用传统的解析式来进行表达，而机器学习方法又基于黑箱理论，只知道模型的输入与输出，而无法确定显式关系式。

因此本文引入可靠度基本理论和随机响应面方法，既能通过量化指标对预测结果进行可靠度分析，又能构建输入与输出的显式表达关系式。

2.4.1 可靠度原理

可靠度概念最先用于建筑结构领域，工程结构在设计施工及使用维护中具有各种不利于结构安全性、适用性、耐久性的不确定因素^[112]，这些不确定性使工程师在判断结构是否可靠时不能仅仅用是或否的回答来衡量，而必须采用以概率作为表达形式的可靠度指标来表达，因此产生和发展了结构可靠度理论。而不确定性是指计算或预测结果的不确定，这种不确定性来自结构设计中的有关设计参数，包括结构上的作用效应或力学荷载，以及结构承受作用效应的能力，即抗力。通常将

影响结构可靠性的不确定性分为随机性、模糊性和知识的不完备性,因此这些参数都可以当作随机变量考虑。而随机变量的统计规律是可以得到和使用的,这些构成了计算结构可靠度分析的基本条件和内容。

(1) 功能函数

结构设计的基本目的是使所设计的结构在设计基准期内满足安全性、适用性和耐久性,也就是使结构具有足够的可靠性。结构在规定时间内和规定条件下完成预定功能的能力,称为结构的可靠性。结构在规定时间内和规定条件下完成预定功能的概率,称为结构的可靠度。

在结构可靠度分析中,根据结构的功能要求和相应的极限状态,可构建结构的功能函数。设随机变量 $X = (X_1, X_2, \dots, X_n)$ 为影响结构可靠度的 n 个基本随机变量, X 可以为材料属性、结构所受作用以及结构的几何特征等。设表示结构工作状态的结构功能函数为 $g(X)$,则有随机函数:

$$Z = g(X) = g(X_1, X_2, \dots, X_n) \quad (2.1)$$

该函数为结构的功能函数。

当 $Z > 0$ 时,结构处于可靠状态;

当 $Z = 0$ 时,结构处于极限状态;

当 $Z < 0$ 时,结构处于失效状态。

因此方程:

$$Z = g(X_1, X_2, \dots, X_n) = 0 \quad (2.2)$$

被称为结构的极限状态方程。它表示在 n 维基本随机变量空间中的 $n-1$ 维超曲面,即极限状态面。图 2.5 表示两个基本变量构成的 2 维极限状态曲面。




图 2.5 二维定义域和极限状态

Fig.2. 5 2D definition domain and limit state

(2) 可靠概率与失效概率

可靠概率 p_r 用于表示结构完成预定功能的概率,相反的,失效概率 p_f 用于表示结构不能完成预定功能的概率。结构的可靠和失效为互不相容事件,而它们的和事件是必然事件,即可以用以下关系表示:

$$p_r + p_f = 1 \quad (2.3)$$

可靠概率 p_r 和失效概率 p_f 都可以表示用于表示结构的可靠度,但在计算和表达中通常使用 p_f 来表示,即通过处理结构的不确定信息来计算结构的失效概率。由于结构功能函数 Z 为连续随机,设 Z 的概率密度函数为 $f_Z(z)$ 。由结构可靠度意义可得 p_f 的计算公式为:

$$p_f = P_r(Z < 0) = \int_{-\infty}^0 f_Z(z) dz \quad (2.4)$$

设 $f_X(x_1, x_2, \dots, x_n)$ 为基本随机变量 $X = (X_1, X_2, \dots, X_n)$ 的联合概率密度函数,联合累积分布函数 $F_X(x) = F_X(x_1, x_2, \dots, x_n)$,则结构的失效概率为:

$$\begin{aligned} p_f &= \int_{Z < 0} dF_X(x) = \int_{Z < 0} f_X(x) dx \\ &= \iint_{Z < 0} \dots \int f_X(x_1, x_2, \dots, x_n) dx_1 dx_2 \dots dx_n \end{aligned} \quad (2.5)$$

若随机变量 X 相互独立, X_i 的概率密度函数为 $f_{X_i}(x_i)$,则有:

$$p_f = \iint_{Z < 0} \dots \int f_{X_1}(x_1) f_{X_2}(x_2) \dots f_{X_n}(x_n) dx_1 dx_2 \dots dx_n \quad (2.6)$$

2.4.2 随机响应面法

(1) 随机响应面法原理

现有大部分的可靠度分析方法都是基于功能函数的解析式来实现的，但在某些复杂系统中，由于随机基本变量的输入与输出存在高度非线性关系，无法预先建立显式功能函数，导致可靠度分析模型无法确定。JC 等方法就不再适用了，此时引入响应面法。

响应面法的基本思想是对于隐式的或需要花费大量时间求解的功能函数或极限状态面，用一个相对容易处理的函数或曲面来代替，被称为响应面函数或者响应面。用响应面方法进行可靠度分析时，关键在于对函数取样点的拟合，当响应面函数的拟合情况较好时，就可以进行可靠度分析了。通常来说，随机变量的多项式形式为响应面函数的常用形式。

由于高次多项式在概念与计算上的复杂性，传统响应面法通常选取二次多项式，基本随机变量为 X 的响应面函数可表示为：

$$Z = g(X) \approx Z_r = \bar{g}(X) = a + \sum_{i=1}^n b_i X_i + \sum_{i=1}^n c_i X_i^2 + \sum_{1 \leq i < j \leq n} d_{ij} X_i X_j \quad (2.7)$$

式中 a, b_i, c_i, d_{ij} 均为待定系数, $i, j=1, 2, 3, \dots, n$ 。待定系数的个数为 $(n^2 + 3n)/2 + 1$ 。

用二次多项式表达的响应面函数存在的问题是较难做到在整个空间都很好地拟合真实功能函数，因此有时会用忽略交叉乘积项的非完全二次多项式，即：

$$Z = g(X) \approx Z_r = \bar{g}(X) = a + \sum_{i=1}^n b_i X_i + \sum_{i=1}^n c_i X_i^2 \quad (2.8)$$

待定系数个数变为 $2n + 1$ ，尽管在降低了求解待定系数的体量，提升了计算效率，但不论是非完全二次多项式还是完全二次多项式，对于实际工程中的基本随机变量，在响应面的构造上依然缺乏合理的数学计算依据。

随机响应面与传统响应面原理类似，是传统响应面方法的延伸。随机响应面能够解决非线性问题和更为复杂的隐式功能函数，其与传统响应面的区别在于用于构造响应面函数的基本随机变量的分布状态。随机响应面要求基本随机变量应当为标准正态分布，并且在传统响应面方法上引入 Hermite 随机多项式，建立输出响应量的代理模型，构建响应面的近似显式函数。

(2) 多项式混沌展开

多项式混沌展开 (Polynomial Chaos Expansions, PCE) 法主要基于混沌多项式 (Polynomial Chaos, PC) 理论，理论上当条件满足，能够精确描述任意分布形式的随机变量的随机性，是一种非常有效的基于随机展开的不确定性分析方法。表 2.2 列出了随机变量常见分布所对应的正交多项式类型。

表 2.2 常见随机变量分布及多项式类型

Table 2.2 Common random variable distributions and polynomial types

随机变量分布类型	正交多项式类型	区间
高斯分布	Hemite	$(-\infty, \infty)$
Gamma 分布	Laguerre	$[0, \infty)$
均匀分布	Jacobi	$[a, b]$
泊松分布	Charlier	$\{0, 1, 2, \dots\}$
二项分布	Krawtchouk	$\{0, 1, \dots, N\}$

Hermite 随机多项式具有推导简单易懂，在无穷区间上有正交性的特点，并且易于收敛。因此采用 Hermite 随机多项式来构建响应面近似显式函数。输出响应量 Y 与输入基本随机变量之间的近似显式函数可表示为：

$$\begin{aligned}
 Y = & a_0 \Gamma_0 + \sum_{i_1=1}^N a_{i_1} \Gamma_1(\xi_{i_1}) + \sum_{i_1=1}^N \sum_{i_2=1}^{i_1} a_{i_1, i_2} \Gamma_2(\xi_{i_1}, \xi_{i_2}) \\
 & + \sum_{i_1=1}^N \sum_{i_2=1}^{i_1} \sum_{i_3=1}^{i_2} a_{i_1, i_2, i_3} \Gamma_3(\xi_{i_1}, \xi_{i_2}, \xi_{i_3}) + \dots \\
 \Gamma_P = & (\xi_{i_1}, \xi_{i_2}, \dots, \xi_{i_p}) = (-1)^P e^{\frac{1}{2}\xi\xi^T} \frac{\partial^P}{\partial \xi_{i_1} \dots \partial \xi_{i_p}} e^{\frac{1}{2}\xi\xi^T}
 \end{aligned} \quad (2.9)$$

式中： $a = (a_0, a_{i_1}, a_{i_1, i_2}, \dots, a_{i_1, \dots, i_N})$ ——待定系数；

N——基本随机变量的个数；

$\xi = (\xi_{i_1}, \xi_{i_2}, \dots, \xi_{i_N})$ ——独立标准正态随机向量；

P——随机多项式展开的阶次；

$\Gamma_P = (\xi_{i_1}, \xi_{i_2}, \dots, \xi_{i_p})$ ——阶次为 P 的多维 Hermite 多项式。

因此对于 N 个基本随机变量的 P 阶 Hermite 多项式，待定系数 a 的个数 Nc 为：

$$N_c = \frac{(N+p)!}{N!p!} \quad (2.10)$$

由式 2.10 计算出前 5 维 5 阶所要求解的待定系数数量如表 2.3 所示。

表 2.3 5 维 5 阶待定系数

Table 2.3 5-dimensional 5-order undetermined coefficient

	p=1	p=2	p=3	p=4	p=5
n=1	2	3	4	5	6
n=2	3	6	10	15	21

	p=1	p=2	p=3	p=4	p=5
n=3	4	10	20	35	56
n=4	5	15	35	70	126
n=5	6	21	56	126	252

(3) 拉丁超立方抽样

随机响应面的构建需要对样本进行抽取,常用的方法有蒙特卡洛抽样方法。该方法首先根据随机变量的概率分布产生足够多的随机数,但在一个区间产生均匀随机数是通过数学递推实现的,因此产生的随机数并非完全独立,而是有一定相关性,被称为伪随机数。如果用蒙特卡洛抽样方法对一个服从正态分布的事件进行抽样,所取得的样本大部分都分布于 μ 附近。对于工程应用而言这是难以接受的,工程风险大多来自极端的工程条件或者风险事件,因此亟需一种能够用更少的抽样次数来覆盖整个事件分布的抽样方法。

拉丁超立方抽样(LHS)方法相比于蒙特卡洛抽样方法,迭代次数更少,输入重建的分布更加准确。拉丁超立方体抽样采用均匀采样的方法对变量进行采样,然后将这些变量的随机组合集用于目标函数的一次计算。LHS 法的关键是对输入概率分布进行分层,在累积概率尺度[0,1]上把累积曲线分成相等的区间。然后从每个区间中随机抽取样本,所抽取的样本就代表每个区间的值,因此可以使采集的样本均匀分布在待抽样区域。其抽样步骤如下:

- (1) 确定需要抽样的样本数为 N ;
- (2) 将[0,1]区间分为 N 等份;
- (3) 在 N 个区间 $[\frac{i}{N}, \frac{i+1}{N}]$ 之中随机抽取一个数,共 N 个数,随机取样依据的公式^[113]为:

$$f(\xi) = \frac{rand(0,1)}{N} + \frac{i-1}{N} \quad (2.11)$$

式中 $rand(1,1)$ 表示生成 0-1 个均匀分布的随机数, $\frac{rand(0,1)}{N}$ 表示缩放系数, $\frac{i-1}{N}$ 表示平移系数,通过缩放和平移可得第 i 个区间上的随机数;

- (4) 将这 N 个数的顺序打乱;
- (5) 这 N 个数为每个随机样本的概率,通过标准正态分布的反函数生成随机分布的值。等概率变换求取独立标准正态空间样本点的公式为:

$$\xi = \Phi^{-1}[f(\xi)] \quad (2.12)$$

式中 Φ^{-1} 为标准正态变量累积分布函数的逆函数。如图 2.6 所示,累计概率分

布函数被分别为 5 个区间，在每个区间内取出样本值，之后不再对该区间进行抽样，有效避免了样本聚集的问题。




图 2.6 拉丁超立方抽样原理

Fig.2. 6 Latin hypercube sampling principle

2.4.3 蒙特卡洛法

蒙特卡洛法 (Monte Carlo method)，也称统计模拟方法，在上世纪四十年代中期由于科学技术的发展和计算机的发明，而提出的一种以概率统计理论为指导的数值计算方法。蒙特卡洛法使用随机数来解决很多计算问题，其中就包括蒙特卡洛抽样产生的伪随机数，本文使用的是 LHS 抽样技术。蒙特卡洛法的基本原理是，用大量试验中发生的频率来估计事件发生的概率，当样本容量足够大时可以认为事件发生的概率即为其发生的频率。因此可以先对基本随机变量进行大量抽样，把所得的样本挨个代入功能函数进行求解，判断结构是否失效，最后求取结构的失效概率。

在前文提到，结构的功能函数可表示为 $Z = g(X)$ ， X 为基本随机变量，对 X 进行拉丁超立方抽样之后所得的样本 x 来计算功能函数。如果 $Z < 0$ ，则代表结构失效一次，假设总计算次数为 N ，其中把 $Z < 0$ 的次数记为 n_f ，则由大数定律中的 Bernoulli 定理可知，随机事件 $Z < 0$ 在 N 次独立试验中的频率 n_f/N 收敛于该事件的概率 p_f ，则失效概率 p_f 的估计值为：

$$\hat{p}_f = \frac{n_f}{N} \quad (2.13)$$

对于蒙特卡洛法来说,采样越多,得到的失效概率估计越接近真实值,但永远无法达到,也就是说得到的近似最优解是一种逼近式解。当一个工程体系的失效概率较小的时候,只能依靠增加试验次数来提高该方法的精度。该方法的关键在于随机抽样,本文利用拉丁超立方抽样将伪随机数转化成标准正态随机数,生成 Hermite 多项式,构建功能函数的随机响应面,在功能函数明确之后就可以使用蒙特卡洛法对其进行求解,这就是可靠度分析的全部步骤。

2.5 CatBoost-可靠度联合预测方法

岩土工程中常用数值模拟方法来建立单个数值模型,解决单个工程问题。其中由于岩土体参数的不确定性,因此常用到可靠度分析方法,来计算可靠概率或失效概率。但数值模型进行可靠度分析仍存在一些不足,首先,数值模型的计算效率较低,直接计算目标值及开展蒙特卡洛模拟需要耗费的时间成本太大。另外,数值模型中参与可靠度计算的随机变量多为建模所用的物理力学参数,然而实际工程中某些待预测或计算的目标受到多种因素的共同影响,例如某些地质因素,而这些因素无法输入至数值模型中,而机器学习模型恰好能克服这两点不足。机器学习模型的计算速度不言而喻,能急剧缩减计算所需的时间成本,并且机器学习模型的输入兼容性较强,并不局限于单个数值模型建立所需的岩土体物理力学参数,而是可以涵盖与预测目标具有相关性的各种变量。

可靠度分析的本质性目的在于对参数不确定性的分析,对于单个数值模型来说,通常将模型中的岩土体参数作为带有不确定性的随机变量,而对于机器学习这种基于大数据挖掘与分析的预测方法来说,是将大量的工程案例收集起来作为一个整体。由于研究尺度的增大,原本被认为是确定性因素的某些变量,在大数据预测和分析中也被视为具有某种分布特征的,带有不确定性的随机变量。

因此,综合以上陈述,基于前人的研究,本文提出一种机器学习-可靠度联合预测方法,该方法旨在实现对于目标值的高精度预测,以及对预测结果的可靠度分析。本方法的实现步骤为:

(1) 构建机器学习训练所需的样本数据,包括目标预测值(Y)与预测指标($X_1, X_2, \dots, X_n$),本方法中预测指标也可以称之为随机变量。由于后续需要对随机变量进行抽样,以此模拟变量的分布状态,因此随机变量的数据类型应为数值型,例如地下水位等;

(2) 建立机器学习预测模型,为了提高模型的预测精度和泛化性能,需要对预测模型进行优化提升。当随机变量的类型较多时,可以使用 2.3 节的耦合优化方法进行优化,当随机变量的类型较少,无需通过数据降维来提升模型精度时,仅对

模型超参数进行优化；

(3) 选取多个评价指标，使用测试集数据对机器学习模型进行结果验证。使用该预测模型对实际工程案例的目标值展开预测，得到预测结果，然后进行可靠度分析，分析方法有一次二阶矩法、蒙特卡洛法等，选择合理的方法展开可靠度分析。

(4) 根据实际工程问题构建功能函数，并根据概率密度函数对随机变量 $(X_1, X_2, \dots, X_n)$ 进行抽样并输出对应的 Y 值，以功能函数为判据展开可靠度分析，计算 Y 的失效概率或根据相关标准计算 Y 的分级概率。

2.6 本章小结

本章介绍了后续所要用到的机器学习方法及 CatBoost-可靠度联合预测方法的基本原理。机器学习预测模型的核心在于预测能力的好坏，即预测值是否能逼近或命中真实值。由此提出因子及参数耦合优化方法来提升模型性能。由于机器学习方法是基于大数据挖掘与分析的方法，参与模型训练的各种指标是服从一定分布的，因此对单个样本点的预测结果具有不确定性，所以引入可靠度基本理论，建立机器学习-可靠度联合预测方法，实现可靠度分析。后续将结合实际工程案例，将两个方法分别应用于隧址区地面塌陷易发性预测和隧道涌水量预测。

3 基于耦合优化的随机森林隧址区地面塌陷易发性预测

3.1 引言

由于隧址区地面塌陷频发,给工程推进和周围居民正常生活带来了极大阻碍和威胁,因此需要对地面塌陷灾害的易发性开展预测工作。为了最大程度地提高模型的预测能力,在前人的研究基础上,提出了基于因子及参数耦合优化的随机森林预测方法。

本章主要围绕该方法对重庆市中梁山地区隧址区地面塌陷易发性展开预测。首先搭建隧址区地面塌陷灾害数据库,收集地面塌陷样本点并选取具有理论相关的影响因子,使用 ArcGIS 实现数据提取及数据可视化,并统计各子类别面积占比和塌陷占比,以频率直方图和塌陷频率比的形式对塌陷分布进行定量分析。通过地理探测器(GeoDetector)探索地面塌陷的空间分异性以及所有影响因子对该分异性的解释程度,以 q 值表示解释力,并基于 q 值排序实现因子优化。引入贝叶斯优化理论对随机森林(RF)算法进行超参数优化,融合两种优化方法来反复构建模型。模型的质量通过精度、准确率、ROC 曲线和 AUC 值进行评价,从而获取因子及参数耦合优化后的最佳模型。使用该模型对整个研究区进行地面塌陷预测,对每个网格单元点输出塌陷概率,基于塌陷概率来划分地面塌陷易发性等级,并以空间熵来判断易发性分级结果的空间稳定性。

3.2 隧址区地面塌陷地理信息数据库搭建

地面塌陷作为一种常见的自然地质灾害与隧道诱发地质灾害,在我国多个省市均有分布。它具有破坏强度高、破坏时间短的特点,其规模大小不一,危及隧道、道路、房屋等各种工程结构,对人民生产生活造成严重不利影响。选择合理有效的方法评估地面塌陷的易发性,可以有效地帮助地方当局进行合理的工程建设规划,从而加强地面塌陷特征识别、监测和预警。

本文依托重庆市地质矿产勘查开发局南江地质队提供的地面塌陷案例及现场调查资料进行研究。据调查报告^[7],中梁山地区地质环境脆弱,岩溶发育强烈,水文地质条件复杂。近年来受铁路、公路和轨道等各类隧道工程建设的影响,地面塌陷频发,其中以长江——嘉陵江之间的区域为代表,分布有已建隧道 16 条,在建隧道 3 条,拟建隧道 10 条,现有隧道密度达 0.358 条/km,隧道建设密度和强度颇大,其建设所带来的地质环境破坏也十分强烈。截止 2017 年 12 月,该地区因隧道修建诱发的地面塌陷超过 280 处,根据已有资料分析,该地区塌陷具有以下特征:

- (1) 空间上呈现出规模越来越大, 影响范围越来越广;
- (2) 时间上呈现出逐年递增趋势, 破坏持续性长;
- (3) 分布上逐渐向学校、医院和居民区等社会易发性强的地区转移, 潜在威胁性越来越强;
- (4) 危害性越来越大, 其隐蔽性和突发性极易造成地区恐慌, 生态环境受到强烈破坏。

要建立有效的地面塌陷预测模型, 需要对庞大的地理信息数据进行整合、预处理和相关分析。因此本文收集了由南江地质队提供的重庆市中梁山地区的岩性分布数据、水文条件数据, 重庆市 30m 分辨率 DEM 数据, 以及 327 个塌陷点数据等, 用于提取预测模型训练所需的地理信息数据、水文信息数据、地质信息数据等, 结合 ArcGIS 地理信息系统搭建研究区地理信息数据库。

3.2.1 研究区概况

合理的研究区域划分影响预测模型的精度和数据处理效率, 本文根据地面塌陷的地形地貌分布特征研究, 结合重庆市卫图及高程图, 并考虑本案例的塌陷点分布, 确定了研究区范围, 如图 3.1 所示。




图 3.1 研究区位置

Fig.3.1 Location of the study area

研究区位于重庆市西北部中梁山区域，为一条狭长的梳状背斜，其中纵向长约为 53 千米，横向宽约为 6 千米，高程 157m-700m。背斜轴线约为 $N15^{\circ} \sim 40^{\circ} E$ ，两翼不对称，构造运动较为剧烈，有多条断裂带和褶皱。山体两侧坡度较为陡峭，角度在 35° 到 60° 之间。整座山体从北向南延伸，在南北方向，地势从高到低再到高。水和可溶性岩层的分布是地面塌陷发育的基本条件。研究区位于背斜构造上，呈条带状分布。考虑到地面塌陷与地形、地表水和地下水活动有关，研究区域的选择基于地形地貌和水文单元。研究区北边界被嘉陵江切割，南边界被长江切割，西边界和东边界为山脊。受南北走向背斜的控制，中梁山喀斯特区域为一个长的槽状盆地，导致研究区域呈长条带状。槽谷又是一个大的集水区，因此研究区域便成为一个大水文单元。区域内岩溶现象主要表现为凹陷、天坑、溶洞和地下河流。根据 1:200000 区域水文地质调查报告，研究区碳酸盐岩岩溶水集中在槽内，碎屑岩裂隙水分布在背斜翼。地下水主要由大气降雨补给，研究区域的年平均降雨量为 1200mm。研究区岩溶塌陷的平面形式主要为椭圆形和圆形，直径约为 2 至 10m，最大直径为 20m。漏斗形是一种常见的空间形式，深度大多在 2 至 5m 左右。根据该地区的交通规划，近年来中梁山隧道建设相对广泛。随着隧道的不断建设，地面塌陷也不断发生，形成了该地区的主要地质问题。

现场调查共发现 327 个塌陷点。地面塌陷的部分现场图如图 3.2 所示。图 3.3 显示了研究区域内地面塌陷点的规模统计。从图 3.3 可以看出，研究区的地面塌陷大多为中小型塌陷，发育程度不强。其中 20% 的塌陷点的空间信息如表 3.1 所示。




图 3.2 塌陷点分布

Fig.3. 2 Collapse point distribution




图 3.3 塌陷规模统计: (a)塌陷直径统计; (b)塌陷深度统计

Fig.3. 3 Collapse scale statistics: (a) collapse diameter statistics; (b) collapse depth statistics

上述调查结果表明,研究区域内存在汇水槽谷,降水补给非常丰富,但隧道开挖也破坏了地下水的原有平衡。整个山体的地下水运动非常强烈,现场调查也证实了该地区地面塌陷的频繁发生。

表 3.1 20%的塌陷点空间信息

Table 3.1 Spatial information of 20% collapse points

编号	经度	纬度	长度 (m)	宽度 (m)	深度 (m)	编号	经度	纬度	长度 (m)	宽度 (m)	深度 (m)
T001	106°24'52"	29°44'51"	8	8	None	T016	106°24'43"	29°44'9"	10	10	5
T002	106°24'57"	29°44'50"	3.5	3.5	2	T017	106°24'43"	29°44'7"	4	4	2.5
T003	106°24'49"	29°44'42"	2	1.5	0.6	T018	106°24'42"	29°44'3"	4.5	4.5	3
T004	106°24'53"	29°44'32"	1~2	1~2	2	T019	106°24'42"	29°44'2"	10	7	4
T005	106°24'56"	29°44'28"	2.5	2.5	2	T020	106°24'42"	29°44'1"	3.7	3.7	1
T006	106°24'54"	29°44'25"	2	2	1	T021	106°24'40"	29°44'08"	3.3	3.3	1.3
T007	106°24'54"	29°44'24"	5	4	0.7	T022	106°24'38"	29°44'2"	2	2	1.6
T008	106°24'48"	29°44'23"	7	7	2	T023	106°24'40"	29°44'3"	10	7	4
T009	106°24'51"	29°44'23"	4	4	2.5	T024	106°24'41"	29°43'50"	3.5	3.5	0.8
T010	106°24'52"	29°44'22"	4	3	3	T025	106°24'43"	29°43'51"	5.7	5.5	2.2
T011	106°24'51"	29°44'22"	7.5	4.5	0.5	T026	106°24'45"	29°43'51"	5	5	1.5
T012	106°24'50"	29°44'22"	9	8	5	T027	106°24'45"	29°43'46"	1	1	0.5
T013	106°24'51"	29°44'21"	3.5	3.5	1	T028	106°24'45"	29°43'39"	8	8	5
T014	106°24'46"	29°44'15"	1.5	1.5	2	T029	106°25'55"	29°44'33"	3	3	2.5
T015	106°24'44"	29°44'12"	7	5	2~3	T030	106°25'51"	29°44'23"	5	5	2

编号	经度	纬度	长度 (m)	宽度 (m)	深度 (m)	编号	经度	纬度	长度 (m)	宽度 (m)	深度 (m)
T031	106°25'50"	29°44'22"	3	3	2	T048	106°24'45"	29°38'55"	15	15	5
T032	106°25'49"	29°44'22"	5	5	1	T049	106°24'47"	29°40'22"	2.5	2.5	1.5
T033	106°25'43"	29°44'00"	5	5	3	T050	106°24'46"	29°38'54"	4	4	1.5
T034	106°25'42"	29°43'57"	4	4	2	T051	106°24'47"	29°38'54"	8	6	3.5
T035	106°24'20"	29°42'42"	3	2	1.3	T052	106°24'48"	29°38'53"	7.8	7.8	6
T036	106°24'36"	29°41'34"	3~4	3	2	T053	106°24'49"	29°38'52"	13	11	3
T037	106°24'55"	29°40'51"	3~4	3	2	T054	106°24'49"	29°38'52"	13	12	5
T038	106°24'56"	29°39'44"	2	2	1	T055	106°24'50"	29°38'51"	3	2	1
T039	106°24'51"	29°39'10"	2	2	2	T056	106°24'52"	29°38'51"	7.3	5.5	5
T040	106°24'54"	29°39'9"	4	4	3	T057	106°24'48"	29°38'49"	5	5	1
T041	106°24'54"	29°39'8"	8	8	5	T058	106°24'48"	29°38'48"	12.8	8	13
T042	106°25'5"	29°39'3"	1.5	1	0.8	T059	106°24'49"	29°38'48"	21	10	3
T043	106°25'2"	29°39'0"	2	2	1.5-2	T060	106°24'49"	29°38'47"	3	3	1
T044	106°25'2"	29°39'0"	2	2	1.5-2	T061	106°24'50"	29°38'47"	5	5	2.5
T045	106°24'52"	29°38'59"	7	4	3	T062	106°24'49"	29°38'47"	5	5	2.5
T046	106°24'45"	29°38'58"	3	3	1	T063	106°24'50"	29°38'47"	36	15.5	4.5
T047	106°24'45"	29°38'57"	7.5	7.5	2	T064	106°24'51"	29°38'47"	6	6	2

3.2.2 影响因子选取及分布特征分析

地面塌陷预测的主要手段有定性和定量的方法，定性方法通过塌陷发生的频率、规模大小、破坏程度等来决定塌陷易发性的等级，划分不同等级对应的易发性区域。但要实现较为准确的预测，必须选取定量化的评价指标以构建合理的机器学习模型。根据对地面塌陷机理的研究，塌陷的形成大多具备三个条件，物源条件、空间条件和水动力条件。物源条件是指从塌陷结构上讲，需要满足上覆土层为第四系松散土体，土体可以为自然沉积风化后的产物，也可以是人类活动所填筑的土体。空间条件是为了满足上覆土体垮塌之后的物质运移以及水的运移而存在的地下空腔，通常空间条件包括了土洞以及土洞以下的通道。水动力条件是塌陷形成的诱发条件，水动力对地面塌陷的影响主要体现在增加上覆土层的重量，使土层更容易垮塌，以及提供动力条件，破坏土洞结构的平衡性和稳定性。在本案例中，大量的隧道建设中不断抽水排水，引起地下水位下降，再加上研究区时常经历庞大的季节性降雨量，导致区域水动力活动异常丰富。同时文献[114-116]也对目前的地面塌陷机理进行了研究，致塌作用主要有潜蚀作用、真空吸蚀作用、降雨及地表水冲蚀作用及荷载与振动作用，文献[117]统计了中梁山地区不同力学致塌机制导致的塌陷数量。




图 3.4 不同致塌机制的占比

Fig.3. 4 Proportion of different collapse mechanisms

图 3.4 显示了中梁山地区的地面塌陷中，潜蚀作用和真空吸蚀作用导致的塌陷占大多数。潜蚀作用是指土层内部在地下水浸湿和动力作用的影响下，土颗粒被冲刷带到下部的过程。真空吸蚀作用是指在相对密闭的地下土洞中，由于地下水位大幅度下降，在地下水面与覆盖层底板之间形成低压“真空腔”或负压腔，覆盖层土

体受到的大气压强和土洞的低压无法平衡，导致覆盖层底板的土颗粒被吸蚀掏空，引起塌陷。四种力学致塌作用中，除了荷载与振动作用，其它均与水有关，潜蚀和真空吸蚀更是和地下水活动紧密相关，而中梁山区域密集的隧道建设大幅破坏了原有的地下水平衡，图 3.5 统计展示了中梁山部分隧道的影响特征。除此之外，隧道施工同样会引发荷载与振动作用，多方面诱发地面塌陷。




图 3.5 中梁山区域部分隧道的影响

Fig.3.5 Impact of some tunnels in Zhongliangshan area

通过上述对隧址区地面塌陷致塌条件和致塌机理的现状研究，本文将地面塌陷易发性的影响因素归纳为四个类别：①地质条件因子；②地形地貌因子；③水文因子；④人类活动。

一、地质条件因子

地面塌陷所处的地质背景通常起控制性作用，塌陷形成的基本条件包含塌陷物质来源和塌陷的运移通道，即覆盖层土体和下部岩溶发育管道，从地质特性和地质构造角度考虑，将地质条件因子进一步量化为地层岩性、距离断层距离和覆盖层厚度。

（1）地层岩性

地层岩性决定了岩土体的物质组分、软硬程度、裂隙发育程度，以及被风化的难易程度等，从而改变岩土体的应力状态和变形特性，这些自身特性直接或间接的影响了地面塌陷的易发性。资料^[7]显示岩溶发育程度往往和塌陷程度成正相关，可溶岩岩性较纯，连续厚度较大，出露分布较广，岩溶较易发育，地面塌陷的易发性更高，塌陷程度越烈。研究区内地层岩性类别及分布特征统计数据如表 3.2 所示。

图 3.6 为 ArcGIS 生成的地层岩性分布图层和塌陷分布特征统计。频率比法 (Frequency Ratio, FR) 常被应用于地质灾害分布特征的分析中, 能够反映影响因子的子类别与地质灾害的相关程度, 其计算公式如下:

$$FR = \frac{n_i/N}{s_i/S} \quad (3.1)$$

式中, n_i 为在某影响因子的第 i 个类别上发生灾害的数量, N 为灾害的总数量, s_i 为第 i 个类别的面积或网格单元数, S 为研究区的总面积或网格单元的总数量。在本研究中, n_i/N 就代表某影响因子第 i 个类别上的塌陷占比, s_i/S 代表了该类别的面积占比。FR 越大, 代表在相对较小的区域有较多地面塌陷, 反映了该类别对塌陷的发育是有利的, FR 越小, 反映该类别与塌陷发育的相关程度越低。

ArcGIS 作为一个集成地图制作、地图分析、数据编辑、数据管理、空间处理等等为一体的地理信息系统平台, 也拥有着强大的地理信息数据可视化的功能。本文将重庆市 30m 分辨率的 DEM 数据通过投影变换进行地理配准, 用掩膜提取来切割划分出研究区边界, 并将部分矢量数据转化为栅格数据, 再通过区域分析、提取分析、表面分析等空间分析手段, 生成各个影响因子图层, 但由于数据的多源性和差异性, 各个图层的网格单元大小和数量会有差异, 但在统计塌陷点属性时可以通过最邻近计算来将各个影响因素赋值给每个塌陷点。除此之外数据类型也分为离散和连续两种, 例如地层岩性就是离散数据, 而 DEM 提取的各种数据默认为连续。由于影响因子大多与自然因素相关, 并且地面塌陷作为自然和人为共同作用下的地质灾害, 因此选择使用自然断点法或等距离划分法将连续性数据划分区间, 成为离散型数据, 具体划分类别已统计于各个影响因子的数据表中。由于塌陷在很多地层岩性上并没有分布, 因此图 3.6 只显示了研究区内部分地层岩性占比和塌陷点在地层岩性上的分布占比, 以及各地层岩性上的塌陷频率比。

表 3.2 地层岩性类别及分布特征统计

Table 3.2 Statistics of stratum lithology categories and distribution characteristics

类别	地层岩性	网格数量	面积占比 (%)	塌陷数量	塌陷占比 (%)	FR
1	J1z	30343	7.48	0	0.00	0.00
2	J1zl	33395	8.23	0	0.00	0.00
3	J2s1	43829	10.81	0	0.00	0.00
4	J2x	37367	9.21	0	0.00	0.00
5	P2c	3938	0.97	0	0.00	0.00

类别	地层岩性	网格数量	面积占比 (%)	塌陷数量	塌陷占比 (%)	FR
6	T1d	41294	10.18	150	46.01	4.52
7	T1f1	6873	1.69	0	0.00	0.00
8	T1f2	15030	3.71	0	0.00	0.00
9	T1f3	21862	5.39	5	1.53	0.28
10	T1f4	10610	2.62	2	0.61	0.23
11	T1j1	13718	3.38	56	17.18	5.08
12	T1j2	36988	9.12	76	23.31	2.56
13	T1j3	14738	3.63	36	11.04	3.04
14	T2l	5146	1.27	1	0.31	0.24
15	T3xj1-5	67896	16.74	0	0.00	0.00
16	T3xj6	22500	5.55	0	0.00	0.00




图 3.6 地层岩性分布图层和塌陷分布统计特征

Fig.3. 6 Stratum lithology distribution layer and statistical characteristics of collapse distribution




图 3.7 地层岩性占比

Fig.3. 7 Proportion of formation lithology

图 3.7 为研究区地层岩性占比，可以看出 T3xj1-5、J2s1 和 T1d 的分布面积最大，但塌陷主要分布于 T1d、T1j1、T1j2 和 T1j3 地层，在 T1d 和 T1j1 上的塌陷数量和密度较大，分别塌陷了 150 处和 56 处，FR 值分别为 4.52 和 5.08。这些地层均为灰岩或泥质灰岩，厚度为中层至厚层，在其他地层岩性上的分布少或几乎没有，从地面塌陷机理角度分析，灰岩的确更加容易受风化剥蚀及化学侵蚀的作用。

(2) 距断层距离

地质构造也是地面塌陷的主控因素之一，构造作用使得岩层裂隙发育，一方面有利于地下水补给、排泄，为地下水运移提供了良好的条件，另一方面破碎的岩体同上部覆盖层的物质一起被运输至土洞，成为塌陷充填物。构造运动的产物之一是断层，研究区内有数条断层带，对塌陷的发育提供了有利的环境，因此选取距断层距离作为影响因子之一。距断层距离通过欧氏距离计算得到，将其等间距划分为 5 类，如表 3.3 所示。图 3.8 为距断层距离分布图层和塌陷分布特征统计。

表 3.3 距断层距离类别及分布特征统计

Table 3. 3 Statistics of distance categories and distribution characteristics from faults

类别	距断层距离 (m)	网格数量	面积占比 (%)	塌陷数量	塌陷占比 (%)	FR
1	<1000	160334	17.53	54	16.56	0.94
2	1000~2000	209948	22.96	53	16.26	0.71
3	2000~3000	228020	24.94	31	9.51	0.38
4	3000~4000	157881	17.27	81	24.85	1.44
5	>4000	158253	17.31	107	32.82	1.90




图 3.8 距断层距离分布图层和塌陷分布统计特征

Fig.3. 8 Statistical characteristics of distance distribution layer from fault and collapse distribution

地面塌陷在距断层距离的分布上并没有呈类线性特征，在五个类别上均有分布，并且在五个类别上的塌陷频率比(FR)相差不大，最高 FR 值为 1.9。分布规律上，在 3km 范围内距断层距离越小，FR 越大；在 3km 范围外距断层距离越小，FR 越小。可以推测本案例中，距断层距离为 3km 是判断该因素是否为主控因素之一的临界距离，该距离以内断层构造对地面塌陷的影响更强烈，该距离以外受其他因素影响更强烈。

(3) 覆盖层厚度

文献^[118-119]对塌陷机理的研究表明覆盖层厚度影响地面塌陷。不同的覆盖层厚度会影响到土洞的扩展及极限平衡状态的维持时间。从初始土洞至形成顶部即将塌陷的临界土洞，再从临界土洞的形成至地表土体的塌落形成塌坑这个过程中，覆盖层厚度越小，土体抗剪强度越小，在重力作用或负压作用下坍塌的周期越短，直至覆盖层土体全部垮塌，覆盖层厚度越大，抗剪强度越高，维持土洞极限平衡状态的周期就越长。将覆盖层厚度等间距划分为 5 类，如表 3.4 所示。图 3.9 为覆盖层厚度分布图层和塌陷分布特征统计。

表 3.4 覆盖层厚度类别及分布特征统计

Table 3.4 Statistics of overburden thickness categories and distribution characteristics

类别	覆盖层厚度 (m)	网格数量	面积占比 (%)	塌陷数量	塌陷占比 (%)	FR
1	<3	230981	14.22	37	11.35	0.80
2	3~4	378484	23.31	31	9.51	0.41
3	4~5	522388	32.17	70	21.47	0.67
4	5~6	349706	21.54	39	11.96	0.56
5	>6	142333	8.76	149	45.71	5.21




图 3.9 覆盖层厚度分布图层和塌陷分布统计特征

Fig.3.9 Statistical characteristics of overburden thickness distribution layer and collapse distribution

本案例中地面塌陷在覆盖层厚度>6m 的类别内分布最多, 45.71%的塌陷点分布于此, 但该类占整个区域的面积又是相对小的, 只占研究区的 8.76%, 因此在覆盖层>6m 时 FR 高达 5.21。而其他类别的 FR 就相对较低, 尽管该类别的土洞发育周期和塌陷进程较为漫长, 但就最终结果而言, 该类别对地面塌陷的影响是较大

的。

二、地形地貌因子

地形地貌影响地面塌陷的发育环境，不同的地形地貌条件使得塌陷具有不同的宏观特征，可以帮助分析是否有利于塌陷的形成。因此选取高程、坡度、坡向、坡位、平面曲率、剖面曲率、微地貌、地表切割深度、高程变异系数作为影响因子纳入易发性模型的建立。

(1) 高程

高程对地面塌陷的影响并不是直接的，但间接反映了塌陷的分布特性。主要体现在植被分布、地下水分布、人类工程活动和降雨量四个方面。高程不同，植被类型和覆盖率不同，岩土体受到的风化程度就不同，植被对水土保持发挥了不小作用。高程较低的地方，地下水含量往往越丰富，对塌陷的发生往往产生有利影响。而同时高程较低的地方，人类展开工程活动就越频繁，对地质环境和水文环境的改造就越发强烈。文献[120]表明，不同的高程和区域降雨量是密切相关的。考虑到上述间接影响，将高程纳入影响因子之一是有必要的。本案例将高程按自然断点法划分为5类，如表 3.5 所示。图 3.10 为高程分布图层和塌陷分布特征统计。

表 3.5 高程类别及分布特征统计
Table 3.5 Statistics of elevation categories and distribution characteristics

类别	高程 (m)	网格数量	面积占比 (%)	塌陷数量	塌陷占比 (%)	FR
1	<285	560819	16.12	0	0.00	0.00
2	285~369	745335	21.42	7	2.15	0.10
3	369~461	589645	16.95	4	1.23	0.07
4	461~551	1092568	31.40	286	87.73	2.79
5	>551	490646	14.10	29	8.90	0.63




图 3.10 高程分布图层和塌陷分布统计特征

Fig.3. 10 Statistical characteristics of elevation distribution layer and collapse distribution

研究区内高程分布相对均衡,每个类别的占比都相差不多,而地面塌陷却主要分布于 461~551m 这个区间内,FR 为 2.79,从图 3.10 中可以看出 461~551m 的高程范围在纵向上处于地势相对低洼处,地表水从南北两个方向均汇入此区间,在横向上又从该区间汇出,向东西两个方向排泄,同时该高程范围也是居民生活和生产建设的密集区。

(2) 坡度

坡度影响的是地表水的汇流以及该处发生地质灾害的类型。通常来说坡度越大的地方下滑力越大,地表水下渗后土体软化,粘聚力下降,发生滑坡的概率理论上大于地面塌陷的概率。并且由于临空面的存在,斜坡体的应力分布和变形特性不同于水平岩层,因此斜坡地形理论上不利于地下土洞稳定发展和形成。本文用度数表征地表倾斜程度。将坡度按自然断点法划分为 5 类,如表 3.6 所示。图 3.11 为坡度分布图层和塌陷分布特征统计。

表 3.6 坡度类别及分布特征统计

Table 3.6 Statistics of slope categories and distribution characteristics

类别	坡度 (°)	网格数量	面积占比 (%)	塌陷数量	塌陷占比 (%)	FR
1	<8.1	832674	24.01	268	82.21	3.42
2	8.1~15.0	922162	26.60	49	15.03	0.57
3	15.0~21.8	858820	24.77	6	1.84	0.07
4	21.8~30.1	595290	17.17	3	0.92	0.05
5	>30.1	258439	7.45	0	0.00	0.00




图 3.11 坡度分布图层和塌陷分布统计特征

Fig.3.11 Statistical characteristics of slope distribution layer and collapse distribution

研究区的坡度分布较为均衡，五个类别的坡度分布相差较小，绝大多数坡度小于 30.1° ，而塌陷在坡度 $<8.1^\circ$ 和 $8.1\sim15^\circ$ 上的分布较广，特别是在坡度 $<8.1^\circ$ 的区间内分布有 268 个塌陷点，FR 为 3.42。地面塌陷点的分布和上述理论分析认为的较为一致，即塌陷几乎分布于坡度很缓的平地，当坡度较大时，不利于地下土洞

的形成与发展，而更有可能发生滑坡地质灾害。

(3) 坡向

坡向对地面塌陷的影响也是间接的，坡向不同，地表受阳光照射时长不同，地表温度和辐射均有差异，因此对植被生长的影响就会产生差异。同时由于中梁山地区的地势较周边偏高，夏季地表温度高，昼夜温差大，不同的坡向温度差异大，岩土体不均匀受热，产生表面温差裂缝，从而间接影响地面塌陷的发生。坡向可从DEM中直接提取得到，共分为八个类别，每个类别的角度范围为 45° ，例如北的角度范围为 -337.5° 至 22.5° ，以此类推。坡向统计如表3.7所示。图3.12为坡向分布图层和塌陷分布特征统计。

表 3.7 坡向类别及分布特征统计
Table 3.7 Statistics of slope direction categories and distribution characteristics

类别	坡向	网格数量	面积占比 (%)	塌陷数量	塌陷占比 (%)	FR
1	北	292400	8.43	28	8.59	1.02
2	东北	384364	11.09	28	8.59	0.77
3	东	565412	16.31	30	9.20	0.56
4	东南	493118	14.22	71	21.78	1.53
5	南	320040	9.23	57	17.48	1.89
6	西南	398121	11.48	43	13.19	1.15
7	西	555295	16.01	39	11.96	0.75
8	西北	458635	13.23	30	9.20	0.70




图 3.12 坡向分布图层和塌陷分布统计特征

Fig.3.12 Statistical characteristics of slope distribution layer and collapse distribution




图 3.13 坡向与塌陷分布雷达图

Fig.3.13 Radar map of slope direction and collapse distribution

图 3.13 为坡向与塌陷的分布雷达图。研究区的坡向分布中，东西朝向的坡体分布相对较多，而塌陷在各个坡向均有分布，在东南和南朝向上的分布略高于其他朝向，FR 值分别为 1.53 和 1.89。从塌陷在坡向的总体分布上看，不同坡向类别对地面塌陷并没有明显的差异驱动关系，可以认为塌陷对坡向易发性较低。

(4) 坡位

坡位指地形纵剖面的位置，文献^[27]表明斜坡的坡位有不同的地质特性，因此不同坡位的地质特征和水文特征可能不同，尽管地面塌陷几乎发育在地形平缓的位置，但考虑到地质地貌因素的不确定性，仍将其纳入影响因子之一，后续通过因子优化来决定其是否参与进地面塌陷易发性模型。坡位可以直接在 ArcGIS 里由 Topographic Position Index 工具生成 TPI 指数，再由该指数分类为 6 个类别，如表 3.8 所示。图 3.14 为坡位分布图层和塌陷分布特征统计。

表 3.8 坡位类别及分布特征统计
Table 3.8 Statistics of slope classification and distribution characteristics

类别	坡位	网格数量	面积占比 (%)	塌陷数量	塌陷占比 (%)	FR
1	谷底	750	0.02	0	0.00	0.00
2	坡脚	10679	0.31	0	0.00	0.00
3	平地	588669	16.92	236	72.39	4.28
4	中坡	2863879	82.32	90	27.61	0.34
5	上坡	14347	0.41	0	0.00	0.00
6	山脊	689	0.02	0	0.00	0.00




图 3.14 坡位分布图层和塌陷分布统计特征

Fig.3. 14 Statistical characteristics of slope location distribution layer and collapse distribution

本案例中坡位的分布特征性比较强, 整个研究区几乎只有中坡和平地, 分别占比 82.32%和 16.92%, 而塌陷点在这两个类别的占比分别为 27.61%和 72.39%, 也就是说塌陷点大部分分布于小范围的平地。在平地的塌陷频率比为 4.28, 可以认为地面塌陷对坡位的敏感程度较高, 并且易发于平地。

(5) 平面曲率

平面曲率表示地表任意点所在等高线的弯曲变形程度。平面曲率的绝对值越小, 地形弯曲变形程度越小, 地质结构和地貌相对简单, 反之就越复杂。平面曲率一般影响土体变形和地表径流, 进而影响地面塌陷。按自然断点法将平面曲率分为 5 类, 如表 3.9 所示。图 3.15 平面曲率分布图层和塌陷分布特征统计。

表 3.9 平面曲率类别及分布特征统计

Table 3.9 Statistics of plane curvature categories and distribution characteristics

类别	平面曲率	网格数量	面积占比 (%)	塌陷数量	塌陷占比 (%)	FR
1	<-0.64	21344	6.41	6	1.84	0.29
2	$-0.64\sim-0.18$	77611	23.30	91	27.91	1.20
3	$-0.18\sim0.21$	127866	38.39	173	53.07	1.38
4	$0.21\sim0.7$	80076	24.04	50	15.34	0.64
5	>0.7	26167	7.86	6	1.84	0.23




图 3.15 平面曲率分布图层和塌陷分布统计特征

Fig.3.15 Statistical characteristics of planar curvature distribution layer and collapse distribution

地面塌陷在剖面曲率 $-0.18\sim0.21$ 的区间内分布有 173 个, 塌陷占比 53.07%, FR 值也相对其他类别较高, 为 1.38。该区间的地形弯曲程度和复杂程度都相对较小, 而平面曲率绝对值 >0.7 的类别几乎很少发生塌陷, 这也凸显了平面曲率影响塌陷发育的规律, 在 -0.18 至 0.21 区间内塌陷概率相对较大。

(6) 剖面曲率

剖面曲率表示地表在垂直方向上的弯曲变形程度。剖面曲率直观地反映了地

表径流的强度和方向,不同的剖面曲率通过径流间接改造了地表土体结构,从而影响地面塌陷的发育。剖面曲率同样可以归属为自然属性,由自然断点法分为5类,如表3.10所示。图3.16为剖面曲率分布图层和塌陷分布特征统计。

表 3.10 剖面曲率类别及分布特征统计

Table 3.10 Statistics of section curvature categories and distribution characteristics

类别	剖面曲率	网格数量	面积占比 (%)	塌陷数量	塌陷占比 (%)	FR
1	<-0.88	16103	4.83	0	0.00	0.00
2	$-0.88\sim-0.25$	68959	20.70	37	11.35	0.55
3	$-0.25\sim0.21$	130121	39.07	172	52.76	1.35
4	$0.21\sim0.88$	96853	29.08	114	34.97	1.20
5	>0.88	21028	6.31	3	0.92	0.15




图 3.16 剖面曲率分布图层和塌陷分布统计特征

Fig.3.16 Statistical characteristics of curvature distribution layer and collapse distribution in profile

剖面曲率与塌陷的数学统计分布特征相似于平面曲率,在 $-0.25\sim0.21$ 和

0.21~0.88 的两个类别中分别发育了 172 和 114 个塌陷, FR 分别为 1.35 和 1.20。反映了剖面曲率绝对值较小有利于塌陷发生, 垂直方向上的地表弯曲程度越大, 对地质灾害类型的改造就越远离地面塌陷这一类型, 例如在剖面曲率>0.88 这一类别下的塌陷占比仅有 0.92%。

(7) 微地貌

微地貌是规模相对比较微小的地貌形态, 也是最小的地貌形态单元, 通过对微地貌的观测, 可以进一步分析宏观地貌的形成过程。微地貌通常由风化作用形成, 岩石被风化成碎屑, 经过风力搬运和水力侵蚀、沉积, 形成各种形态的微地貌。微地貌通过反映周边植被发育、水系发育的程度来间接反映地面塌陷的发育程度。微地貌可由 Landform 工具提取生成, 共分为 8 类, 如表 3.11 所示。图 3.17 为微地貌分布图层和塌陷分布特征统计。

表 3.11 微地貌类别及分布特征统计

Table 3.11 Statistics on the types and distribution characteristics of microgeomorphology

类别	微地貌	网格数量	面积占比 (%)	塌陷数量	塌陷占比 (%)	FR
1	深切河谷	15396	0.44	0	0.00	0.00
2	U 形谷	845283	24.30	65	19.94	0.82
3	平原	403812	11.61	194	59.51	5.13
4	空旷斜坡	1406997	40.44	66	20.25	0.50
5	台地	776114	22.31	1	0.31	0.01
6	山谷中局部山脊	11	0.00	0	0.00	0.00
7	平原中坡处山脊	13	0.00	0	0.00	0.00
8	山峰	31387	0.90	0	0.00	0.00




图 3.17 微地貌分布图层和塌陷分布统计特征

Fig.3. 17 Statistical characteristics of microgeomorphic distribution layer and collapse distribution

由于塌陷在深切河谷、山谷中局部山脊、平原中坡处山脊和山峰没有分布，并且山谷中局部山脊、平原中坡处山脊这两个微地貌在整个研究区网格单元的占比几乎为 0，因此图 3.17 只展示了有着主要分布的几个微地貌。可以看出研究区内 U 型谷和空旷斜坡的面积占比最多，分别为 24.30% 和 40.44%，然而却有最多的塌陷分布于面积较小的平原微地貌，共有 193 个塌陷点，塌陷占比 59.51%，塌陷频率比为 5.13，因此可以认为塌陷对微地貌类型的敏感程度较高，并且平原有利于塌陷的发育形成。

(8) 地表切割深度

地表切割深度是指地面某点的邻域范围的平均高程与该邻域范围内的最小高程的差值。地表切割深度直接反映了地表被侵蚀切割的程度，间接反映了该处的地表径流强度，进而反映了地表形态被改造的程度，以及岩土体被侵蚀的程度，影响地面塌陷的发育进程。地表切割深度同样隶属于自然地质属性，由自然断点法分为 5 类，如表 3.12 所示。图 3.18 为地表切割深度分布图层和塌陷分布特征统计。

表 3.12 地表切割深度类别及分布特征统计

Table 3.12 Statistics of surface cutting depth categories and distribution characteristics

类别	地表切割深度 (m)	网格数量	面积占比 (%)	塌陷数量	塌陷占比 (%)	FR
1	<1.48	933592	26.78	280	85.89	3.21
2	1.48~2.82	1003680	28.79	38	11.66	0.40
3	2.82~4.24	843509	24.20	8	2.45	0.10
4	4.24~6.08	538867	15.46	0	0.00	0.00
5	>6.08	166244	4.77	0	0.00	0.00




图 3.18 地表切割深度分布图层和塌陷分布统计特征

Fig.3.18 Statistical characteristics of surface cutting depth distribution layer and collapse distribution

地面塌陷在地表切割深度上表现出了较强的易发性，有 85.89% 的共计 280 个塌陷点分布于地表切割深度为 <1.48m 的类别里，FR 值为 3.21。这和微地貌反映出来的塌陷发育规律是一致的，在平原地区，即地表切割较浅的区域分布了大量塌陷，而在深切河谷，即地表切割深度较大的区域，不利于地面塌陷的形成。图中可以看到本案例中当切割深度 >4.24m 已经没有塌陷发生了。

(9) 高程变异系数

高程变异系数是测度高程变异程度的相对统计量，用于比较平均数不同的两个或多个高程数据的变异程度，是标准差与其平均值之比。高程变异系数可以用来衡量地形的复杂度以及宏观区域高程的变化程度。高程变异系数不同，植被覆盖类型和覆盖面积也不同，即直接反映地表形态的突变程度，也间接反映水土流失程度和覆盖层结构的稳定程度。高程变异系数同地表切割深度一样反映垂直向的地表变化程度，由自然断点法分为 5 类，如表 3.13 所示。图 3.18 为高程变异系数分布图层和塌陷分布特征统计。

表 3.13 高程变异系数类别及分布特征统计

Table 3.13 Statistics on the categories and distribution characteristics of elevation variation coefficients

类别	高程变异系数	网格数量	面积占比 (%)	塌陷数量	塌陷占比 (%)	FR
1	<0.0026	1059131	30.39	304	93.25	3.07
2	0.0026~0.0052	1141284	32.74	21	6.44	0.20
3	0.0052~0.0079	868532	24.92	1	0.31	0.01
4	0.0079~0.0133	386787	11.10	0	0.00	0.00
5	>0.0133	29929	0.86	0	0.00	0.00




图 3.19 高程变异系数分布图层和塌陷分布统计特征

Fig.3.19 Statistical characteristics of elevation variation coefficient distribution layer and collapse distribution

高程变异系数反映的地面塌陷规律同地形切割深度,在的区间内发育有 304 个塌陷,然而并非因为此区间的面积占比大,表 3.14 显示高程变异系数为<0.0026、0.0026~0.0052 和 0.0052~0.0079 的面积占比分别为 30.39、32.74、24.92,相差不大,但 93.25%的塌陷点分布于第一个类别,因此推测塌陷对高程变异系数也具有较高的易发性,并且高程变异系数越低,地形在垂直向的变化越小,地形趋于平坦,越有利于塌陷形成。

三、水文因子

(1) 地形湿度指数(TWI)

地形湿度指数(Topographic wetness index, TWI)是指反映地形对地表径流流向和汇水量的指标。其反映了地形对地表径流的改造模式,通过该指标能量化分析地表汇水量增加的区域及积水区域,汇水量越大, TWI 越高。该指标在地形、降雨和径流的交互研究中具有重要意义, TWI 较高的地方,土壤含水量相对偏高,土体摩擦系数和粘聚力较小,土体性质更加不稳定,将其纳入地面塌陷影响因子之一是有必要的。地形湿度指数由 ArcGIS 的栅格计算器通过公式 3.2 计算得到:

$$TWI = \ln(A/\tan\beta) \quad (3.2)$$

式中 A 为单元累积汇水量, β 为局部坡度。

计算得到每个网格单元 TWI 值之后按照自然断点法分为 5 类, 如表 3.14 所示。图 3.20 为 TWI 分布图层和塌陷分布特征统计。

表 3. 14 TWI 类别及分布特征统计

Table 3. 14 TWI category and distribution characteristics statistics

类别	地形湿度指数	网格数量	面积占比 (%)	塌陷数量	塌陷占比 (%)	FR
1	<2	131248	39.48	40	12.27	0.31
2	2~3.6	115614	34.78	84	25.77	0.74
3	3.6~5.8	46261	13.92	73	22.39	1.61
4	5.8~8.8	29287	8.81	90	27.61	3.13
5	>8.8	9990	3.01	39	11.96	3.98




图 3. 20 TWI 分布图层和塌陷分布统计特征

Fig.3. 20 TWI distribution layer and collapse distribution statistical characteristics

TWI 与地面塌陷的交互规律较为显著,随着 TWI 的增大,FR 逐渐增大,地形湿度指数<2 的面积占比为 39.48%,但仅有 12.27%的塌陷分布于此范围。地形湿度指数为 5.8~8.8 和>8.8 的面积占比仅有 8.81%和 3.01%,FR 却达到 3.13 和 3.98。因此可以认为 TWI 越大,代表单元累积汇水量与局部坡度比值越大,地形越趋于局部集水区,对地面塌陷的发育和形成越有利。

(2) 地层含水性

地层含水性和岩溶发育程度密切相关。岩溶区域内地下水除了以潜水、承压水等方式储藏在地下,很大一部分也储存在岩体裂隙中。岩体裂隙为地下水体提供运移和物质交换的通道,地下水动力作用又过来扩张岩体裂隙。在岩溶裂隙富水程度高的地方,岩溶发育程度也相应高,覆盖层中孔隙水的水头高于岩溶水时,往往具有承压性,促进了土颗粒在水位波动和雨水下渗过程中被运移至岩溶通道中,加速了土洞的发育过程。根据重庆市地质矿产勘查开发局南江地质队曹聪等提供的水文资料,将地层含水性共分为 6 个类别,如表 3.15 所示。图 3.21 为地层含水性分布图层和塌陷分布特征统计。

表 3. 15 地层含水性类别及分布特征统计
Table 3. 15 Statistics of formation water content categories and distribution characteristics

类别	地层含水性	网格数量	面积占比 (%)	塌陷数量	塌陷占比 (%)	FR
1	中富水	78161	23.51	3	0.92	0.04
2	弱富水	11097	3.34	2	0.61	0.18
3	强富水	94566	28.45	320	98.16	3.45
4	贫乏	21106	6.35	0	0.00	0.00
5	较贫乏	118748	35.72	0	0.00	0.00
6	极贫乏	8732	2.63	1	0.31	0.12




图 3.21 地层含水性分布图层和塌陷分布统计特征

Fig.3. 21 Statistical characteristics of stratum water content distribution layer and collapse distribution

研究区的地层含水性和高程分布具有一定的相似性，这也间接印证了前文中提到的高程第 4 类别，即 461~551m 这一区间在地形上属于岩溶槽谷区，地层的含水性较高，相应的如图中所示，有 320 个地面塌陷点分布于强富水地层，塌陷占比为 98.16%，几乎涵盖了全部塌陷点，而强富水地层的面积占比仅为 28.45%。因此认为塌陷对地层含水性的敏感程度很高，并且含水性越高，越有利于地面塌陷的形成。

(3) 水流动力指数(SPI)

水流动力指数(Stream power index, SPI)用于衡量水流的三维空间强度，反映了水流的强度分布和速率。SPI 又被称为标准化降水指数，通常该指数越高，水流强度和流速越大。SPI 可以由 DEM 直接提取生成，用自然断点法将其分为 5 类，如表 3.16 所示。图 3.22 为 SPI 分布图层和塌陷分布特征统计。

表 3. 16 SPI 类别及分布特征统计

Table 3. 16 Statistics of SPI categories and distribution characteristics

类别	SPI	网格数量	面积占比 (%)	塌陷数量	塌陷占比 (%)	FR
1	<3.13	10306	3.10	36	11.08	3.58
2	3.13~4.62	38415	11.54	98	30.15	2.61
3	4.62~5.56	78502	23.59	131	40.31	1.71
4	5.56~6.65	114799	34.49	50	15.38	0.45
5	>6.65	90819	27.29	10	3.08	0.11




图 3. 22 SPI 分布图层和塌陷分布统计特征

Fig.3. 22 Statistical characteristics of SPI distribution layer and collapse distribution

从图 3.22 中看到随着 SPI 的增大, 塌陷频率比逐渐降低, 这似乎与通常的既有认知不相符合, 通常情况下水流的强度和大小越大, 致塌概率越高。但 SPI 指数越低的地方地势越平坦, 而 SPI>6.65 的地方几乎为研究区中的山脊处, 坡降较大, 水流流速和强度自然高, 但水体来不及浸润土体, 也就相对难以使土体变得松软, 难以削减土体的抗剪强度。而对于研究区的岩溶槽谷区, SPI 较小, 但集水蓄水能

力较强，有足够的时间软化覆盖层土体，因此致塌概率较高，例如水流动力指数 <3.13 和 3.13~4.62 的两个区间，FR 分别为 3.58 和 2.61。

(4) 地表粗糙度(TRI)

地表粗糙度(Topographic Roughness Index, TRI)是用于衡量地表凹凸程度的指标，同时也反映了地表受风化作用后被侵蚀的程度。不同的 TRI 影响了地表径流速，同时也影响了岩土体的抗风化能力，因此综合影响着地质灾害的发育程度。按照自然断点法将 TRI 分为 5 类，如表 3.17 所示。图 3.23 为 TRI 分布图层和塌陷分布特征统计。

表 3. 17 TRI 类别及分布特征统计
Table 3. 17 TRI category and distribution characteristics statistics

类别	TRI	网格数量	面积占比 (%)	塌陷数量	塌陷占比 (%)	FR
1	<1.03	188566	56.62	316	96.93	1.71
2	1.03~1.09	87985	26.42	10	3.07	0.12
3	1.09~1.17	39510	11.86	0	0.00	0.00
4	1.17~1.3	14035	4.21	0	0.00	0.00
5	>1.3	2968	0.89	0	0.00	0.00




图 3.23 TRI 分布图层和塌陷分布统计特征

Fig.3. 23 Statistical characteristics of TRI distribution layer and collapse distribution

地表粗糙度在研究区的分布规律为从小到大,分布面积逐渐减小,而塌陷占比和 FR 也随之减小,并且地面塌陷主要分布于 TRI<1.03 的范围内,塌陷数量为 112 个,所占比例为 96.93%,几乎涵盖了所有塌陷点,该类别的 FR 为 1.71。该分布可以解释为地表的凹凸程度越低,局部地形越趋于平缓,越有利于塌陷的形成。

四、人类活动

(1) 距隧道距离

隧道建设对中梁山地区的生态环境影响主要体现在地下水过量抽取导致水位大幅下降、工程设备污染及噪声、工程场地建设导致的植被破坏等,但对地面塌陷灾害最直接的影响在于过量抽取地下水,在水位下降的过程中土颗粒被带走,形成潜蚀作用,地下空腔气压下降,产生对覆盖层土体的吸蚀力,形成真空吸蚀作用,再有大量隧道工程设备及建筑材料的附加荷载及施工引起的振动,形成荷载与振动作用,综合诱发了中梁山地区的地面塌陷灾害。根据完整井抽水试验地下水位线变化,距离抽水点越近,水位下降梯度越大,因此考虑距隧道距离作为地面塌陷的影响因素之一。和距断层距离的提取方法一样,利用欧氏距离计算得到距隧道距离

数据，并按等间距分为 5 类，如表 3.18 所示。图 3.24 为距隧道距离分布图层和塌陷分布特征统计。

表 3. 18 距隧道距离类别及分布特征统计

Table 3. 18 Statistics of distance categories and distribution characteristics from tunnels

类别	距隧道距离 (m)	网格数量	面积占比 (%)	塌陷数量	塌陷占比 (%)	FR
1	<500	273444	29.90	135	41.41	1.38
2	500~1000	212000	23.18	149	45.71	1.97
3	1000~1500	138840	15.18	31	9.51	0.63
4	1500~2000	84019	9.19	5	1.53	0.17
5	>2000	206225	22.55	6	1.84	0.08




图 3. 24 距隧道距离分布图层和塌陷分布统计特征

Fig.3. 24 Statistical characteristics of distance distribution layer from tunnel and collapse distribution

由图可知据隧道距离的面积分布相差不大，但地面塌陷大多分布在距隧道距离不足 1km 的范围内，共计有 87.12%的塌陷点。在距隧道距离<500m 和 500~1000m

的区间内, 塌陷数量分别为 135 个和 149 个, 分别占比 41.41%和 45.71%, 塌陷频率比相较其他类别也偏高, 分别为 1.38 和 1.97。在本案例中, 距隧道距离 500m 范围外, FR 持续下降, 可以认为基本符合隧道工程建设影响地面塌陷的理论规律, 而在 500m 范围内, 推测有其他影响因素权重高于距隧道距离, 其他因素占主导作用。

(2) 土地利用类型

土地利用类型包括有水田、林地、城镇、公交建设用地等, 不同的土地利用类型对覆盖层及土洞发育的影响是不一样的。水田受到人为的蓄水灌溉, 土地松软, 林地受自然植被覆盖, 水土固结较好, 城镇和公交建设用地长期受到荷载作用。土地利用类型栅格数据的分辨率较低, 为 1km×1km 分辨率, 其共有 10 个类别, 如表 3.19 所示。图 3.25 为土地利用类型分布图层和其与塌陷分布特征统计。

表 3.19 土地利用类型类别及分布特征统计
Table 3.19 Statistics of land use types and distribution characteristics

类别	土地利用类型	网格数量	面积占比 (%)	塌陷数量	塌陷占比 (%)	FR
1	水田	32988	9.92	47	14.42	1.45
2	旱地	82415	24.79	58	17.79	0.72
3	有林地	130177	39.16	122	37.42	0.96
4	疏林地	23832	7.17	3	0.92	0.13
5	其他林地	1481	0.45	0	0.00	0.00
6	低覆盖度草地	1296	0.39	2	0.61	1.57
7	河渠	47	0.01	0	0.00	0.00
8	城镇	11078	3.33	0	0.00	0.00
9	农村居民点	21411	6.44	93	28.53	4.43
10	公交建设用地	27670	8.32	1	0.31	0.04




图 3.25 土地利用类型分布图层和塌陷分布统计特征

Fig.3.25 Statistical characteristics of land use type distribution layer and collapse distribution

在图 3.25 中没有展示研究区内面积较小以及塌陷没有分布的类别, 从图中可以发现土地利用类型中, 旱地和有林地面积占比较多, 分别为 24.79%和 39.16%, 其中塌陷数量分别为 58 个和 122 个, 塌陷占比为 17.79%和 37.42%。但在面积占比 6.44%的农村居民点却有 93 个塌陷, 塌陷占比为 28.53%, FR 为 4.43。因此认为人类活动对地面塌陷这一地质灾害具有一定程度的影响。

3.3 基于因子及参数耦合优化的 RFC 预测模型

随机森林算法可以用于回归模型和分类模型两种, 对于本案例而言, 在创建训练样本时, 目标预测值可用 0 和 1 进行表示, 即将地面塌陷的属性输入为 0 (代表未发生塌陷) 和 1 (代表已发生塌陷), 然后使用随机森林分类器 (RandomForestClassifier, RFC) 建立地面塌陷预测模型。初始 RFC 预测模型拥有默认的超参数, 需要对超参数进行优化, 寻找使预测性能表现最好的超参数组合。而本案例中共拥有 18 个影响因子, 这些影响因子对预测模型的预测性能的影响也需要通过量化计算来获得, 并非所有参与模型建立的因子都是有利于提高模型精度

的,其中可能存在噪声因子。因此本文建立一种因子及参数耦合优化的方法,以提高地面塌陷 RFC 预测模型的预测精度。

3.3.1 地理探测器原理

空间统计学包含了空间大数据的研究,空间分异性是指层内方差小于层间方差的地理现象^[121],而地理探测器是一种基于统计学来分析某一现象的影响因子的方法,该方法能够揭示分析对象的空间分异性。地理探测器(GeoDetector)基于以下假设:如果因变量受到自变量的重要影响,那么因变量与自变量的空间分布应当具有相似性。

在本案例中使用到的是地理探测器中的“分异及因子探测”这一探测器,用于探测目标预测结果(Y)与变量(X)的关系,即地面塌陷与影响因子的关系,该探测器能探索 Y 的空间分异性以及变量 X 对 Y 的空间分异性能达到何种程度的解释,并用 q 值来度量解释程度,公式如下:

$$q = 1 - \frac{\sum_{h=1}^L N_h \sigma_h^2}{N \sigma^2} = 1 - \frac{SSW}{SST} \quad (3.3)$$

$$SSW = \sum_{h=1}^L N_h \sigma_h^2, SST = N \sigma^2$$

式中h为影响因子 X 的分层,层是一种统计学概念,对应地理上的类或子区域,本案例中代表了影响因子的类别; N_h 为 h 的单元个数; N 为整个区域的单元个数; σ_h^2 为 h 的方差; σ^2 代表全部区域内 Y 值总方差; SSW 为层内方差之和; SST 为全区总方差。

q 的区间范围为[0,1], q 值越大表明地面塌陷的空间分异性越强,该影响因子对该空间分异性具有更高层次的解释,影响力更大, q 值越小表明该影响因子的解释程度更小,影响力更小。如果某个影响因子对地面塌陷空间分异性的 q 值为 1,说明该因子完全控制了塌陷的空间分布特征,如果 q 值为 0,说明该影响因子和塌陷并无关系。

3.3.2 贝叶斯优化理论

机器学习模型中有两种参数,一种是模型参数(model parameter),另一种是超参数(hyper parameter)。区分模型参数和超参数的可以看两者是否通过数据来进行调整,模型参数通常是由数据学习的过程中得到,超参数则不需要数据来驱动,而是在训练前或者训练中人为进行调整的参数。机器学习模型优化的目的是找到全局最优解或者局部的更优解,而其中对超参数的优化旨在寻找到使模型的性能在验证数据集上表现最好的超参数组合。本案例选取贝叶斯优化方法来对 RFC 超参

数进行优化。

(1) 高斯过程

贝叶斯优化由 J. Snoek^[122]提出, 基本思想为: 给定需要优化的目标函数, 该目标函数可以为广义函数, 只需指定输入和输出, 无需知道函数的内部结构和数学性质, 通过不断地添加样本点来更新目标函数的后验分布, 直到后验分布基本逼近于真实分布。简单来说就是一种类似于 Boosting 策略的思想, 考虑了上一个参数的信息分布, 并在此基础上调整下一个参数, 进行更好的拟合。高斯过程被用于拟合函数的分布, 输出目标函数的均值和方差。设函数的输入为 X , Y 为 X 在函数 f 上的映射, 假设 Y 服从正态分布, 通过已有样本点 X 的输入确定 Y 的分布, 随着已输入样本点的增加, 方差减小, 函数 f 趋于确定。

高斯过程^[123]可以用于非线性回归、非线性分类、参数寻优等, 在应用于预测方面时, 需要构建概率模型, 高斯过程表示为:

$$p(y_{N+1}|X_{N+1}, y_N) \quad (3.4)$$

式中, y 和 X 分别为自变量和因变量, N 表示变量所处的状态。因此高斯过程不仅仅考虑了 y 和 X 的关系, 同时考虑了 y_{N+1} 和 y_N 的关系。高斯过程的核心是高斯分布和随机过程, 因此假定 Y 服从联合正态分布, 以对 y_{N+1} 和 y_N 的关系作出解释, 对于 Y 的均值向量和协方差矩阵, 有:

$$\begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{bmatrix} \sim N(0, \begin{bmatrix} k(x_1, x_1) & k(x_1, x_2) & \dots & k(x_1, x_n) \\ k(x_2, x_1) & k(x_2, x_2) & \dots & k(x_2, x_n) \\ \dots & \dots & \dots & \dots \\ k(x_n, x_1) & k(x_n, x_2) & \dots & k(x_n, x_n) \end{bmatrix}) \quad (3.5)$$

式中 x_n 表示 x 所处的状态, x_1, x_2 为 x 所处的两个连续状态, 而协方差矩阵也叫做核矩阵, 这里定义 k 为核函数中的径向基函数, 公式如下:

$$k(x_1, x_2) = \sigma_f^2 \exp\left(\frac{-(x_1 - x_2)^2}{2l^2}\right) \quad (3.6)$$

式中 σ 和 l 为核函数的超参数, 可以人为对其作设置, $k(x_1, x_2)$ 表示两个连续时刻, 若要定义两个任意时刻的核函数, 则有:

$$k(s, t) = \sigma_f^2 \exp\left(\frac{-(s - t)^2}{2l^2}\right) \quad (3.7)$$

其中 s 和 t 表示任意两个时刻, $k(s, t)$ 为任意两个时刻的核函数, 它也决定了高斯过程的性质, 另外再定义 $m(x)$ 为均值函数, 由高斯过程的定义, 所需的均值函数和核函数一旦确定, 高斯过程也就确定了, 如下所示:

$$Y \sim GP(m(t), k(s, t)) \quad (3.8)$$

GP 意为 Gaussian Process, 代表高斯分布。确定了高斯过程, 就可以对函数进行拟合。

(2) 贝叶斯优化

贝叶斯优化是一种逼近理论,贝叶斯调参的优势有参数迭代次数少,耗时少,基于数据使用贝叶斯定理估计目标函数的后验分布,下一次的输入又基于上一次输入的后验分布,从而使结果更贴近真实的后验分布,而不是单纯穷举式地搜索。其优化的工作方式是通过目标函数形状的学习,并找到使结果向全局最大提升的参数。但贝叶斯优化容易在局部最优上探索,因此可能错失未采样区域内可能存在的更优解。优化概率函数可以很好解决这一问题,它表示目标函数值能比当前最优值大多少的概率,设 X 为待优化的超参数,概率优化函数公式^[124]如下:

$$POI(X) = P(f(X) \geq f(X^+) + \xi) = \Phi\left(\frac{\mu(x) - f(X^+) - \xi}{\sigma(x)}\right) \quad (3.9)$$

式中: $POI(X)$ ——优化概率函数;

$f(X)$ —— X 的目标函数值;

$f(X^+)$ ——当前最优目标函数值;

ξ ——权衡系数;

$\mu(x)$ ——目标函数均值;

$\sigma(x)$ ——目标函数方差;

上式中的 ξ 影响下一个采样点是从当前最优解中采样还是在未采样过的区域内采样,如果没有权衡系数,那么目标函数会倾向于在当前最优值的附近采样,而不会倾向于探索未采样的区域。而概率优化函数的最终目标是不断对新的 X 采样,由于 $f(X)$ 的计算复杂,为了确定最优的 X ,计算出 $POI(X)$ 的最大值即可,因此考虑采用最大优化概率函数值对应的 X 作为最终的优化结果。

3.3.3 模型质量评价指标

分类模型的评价指标选取是比较重要的,合理的评价指标体系能够衡量模型的真实预测水平,评价模型的优劣,从而对比和选择更好的预测模型。机器学习算法中的二分类模型常用混淆矩阵(Confuse Matrix)进行模型质量评价,如表 3.20 所示。

表 3.20 混淆矩阵
Table 3.20 Confusion matrix

实际样本	预测样本	
	正例	反例
正例	TP	FP
反例	FP	TN

在本案例中，正例代表了已发生塌陷，反例代表未发生塌陷。真正例(True positive, TP)指一个塌陷点被预测为塌陷，真反例(True negative, TN)指一个未发生塌陷点被正确预测为未塌陷，假正例(False positive, FP)指一个未发生塌陷点被错误预测为塌陷点，假反例(False negative, FN)指一个已发生塌陷点被错误预测为未塌陷。从而依靠混淆矩阵，还可以建立以下两个模型评价指标：

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN} \quad (3.10)$$

$$\text{Precision} = \frac{TP}{TP+FP} \quad (3.11)$$

式中，Accuracy代表了模型精度，其含义是在所有样本里预测正确的样本，即正例被预测为正例、反例被预测为反例占总预测样本的比值，Precision代表了准确率，其含义是在所有被预测为塌陷的样本中，实际的确发生了塌陷的样本占比。

由于很多机器学习模型对分类问题的预测结果是以概率形式输出的，因此如果要建立混淆矩阵，计算 Accuracy，就需要将概率转换成预测结果的类别，这就需要设置一个概率阈值，如果概率高于这个阈值，预测结果就属于类别 A，如果概率低于这个阈值，预测结果就属于 B。例如输出地面塌陷预测结果时，先得到的是该网格点的塌陷概率，阈值默认设定为 0.5，当概率>0.5 时，预测结果就输出为塌陷，当概率<0.5 时，预测结果就输出为未塌陷，从而建立起混淆矩阵。正因如此，概率阈值的设定在一定程度上影响了模型精度的计算，因此引入了受试者工作特性曲线(Receiver Operating Characteristic, ROC)。ROC 曲线也常用于分类模型的检验，特别是在样本不平衡时，ROC 曲线几乎不受影响，而样本不平衡指的是在对模型使用测试集进行检验时，可能会遇到负例比正例多得多的情况，例如本案例中未发生塌陷点就比已发生塌陷点的数量多很多，正负样本不平衡。ROC 曲线的横纵坐标分别为 FPR 和 TPR，计算公式如下：

$$\text{FPR} = \frac{FP}{TN+FP} \quad (3.12)$$

$$\text{TPR} = \frac{TP}{TP+FN} \quad (3.13)$$

FPR 统计了负例中有多少被错误预测正例，TPR 统计了有多少正例被正确预测为正例，FPR 只关注负样本，与正样本无关，而纵轴 TPR 只关注正样本，与负样本无关，这就可以合理解释为什么 ROC 曲线并不受样本不平衡的影响。ROC 曲线只能通过曲线的形状来定性判断模型的优劣，曲线越贴近左上角代表模型的质量越好。因此还引入了 ROC 曲线下面积(Area under the Curve of ROC, AUC)来定量评价模型的好坏，AUC 值越大代表模型越有效。当 AUC=1，代表该二分类模型是完美的，而当 AUC<0.5 时，该模型就没有意义，因为对一个二分类事件进行随

机预测的 AUC 值就约等于 0.5。

3.3.4 模型建立及验证

本案例通过因子及参数耦合优化来建立地面塌陷的最优预测模型，并生成研究区地面塌陷易发性分区图层。因子及参数耦合优化的核心思想主要是通过反复构建模型，计算模型的最优精度，来确立用于构建最优模型的超参数指标和影响因素指标。其实现步骤为：

（1）构建样本数据集。研究区共有塌陷点 327 个，从研究区内随机抽取 1962 个非塌陷点，非塌陷点和塌陷点以 6:1 的比例构建地面塌陷初始样本数据集，将 18 个影响因素的属性赋值到每个样本点里；

（2）利用地理探测器对 18 个影响因素进行对地面塌陷空间分异性的可解释程度排序， q 值代表解释力，根据基于 q 值大小的排序结果，以 q 值由小到大的次序依次剔除一个影响因素，从而构建总共 18 个样本数据集。例如第 1 个样本数据集拥有 18 个影响因素，然后剔除 q 值最小的影响因素，剩余 17 个影响因素来构建第 2 个样本数据集，以此类推，直到只剩由 q 值最大的影响因素单独构建第 18 个样本数据集；

（3）确立随机森林算法需要优化的超参数，依次输入上一步骤的 18 个样本数据集，对每一个输入的样本数据集以 3:1 的比例划分训练集和测试集，进行模型训练，对于每一次训练都采用贝叶斯超参数优化方法，寻找使目标函数最大的 RFC 超参数组合。重复此步骤直至遍历全部 18 个样本数据集，得到 18 组 RFC 最优超参数组合以及在该组合下训练模型的预测精度；

（4）取 18 组 RFC 模型预测精度中的最大值，该值对应的影响因素和超参数就为因子及参数耦合优化的最终结果，用该模型对本案例中研究区所有网格点进行地面塌陷预测，生成每个网格点的塌陷概率，将塌陷概率赋值到每个点的空间属性上，在 ArcGIS 中依据概率分布应用重分类将研究区划分为不同的易发性等级，生成地面塌陷易发性图层。

隧址区地面塌陷 RFC 预测模型的技术路线如图 3.26 所示：




图 3.26 隧址区地面塌陷 RFC 预测模型的技术路线

Fig.3. 26 Technical route of RFC prediction model for ground collapse in tunnel site area

本案例中由于研究区范围较大，纵长约 53km，横宽约为 6km，因此以 DEM 栅格单元的尺寸作为网格划分尺寸，每个网格 30m×30m，共划分有 330020 个网格单元，每个单元被赋予了 18 个影响因子的空间属性。然后按照步骤（1）构建初始样本数据集，共有 2230 行，首行是 18 个影响因子的名称（坡度、坡向、高程、坡位、距断层距离、地层含水性、距隧道距离、地层岩性、覆盖层厚度、TWI、TRI、平面曲率、剖面曲率、微地貌、地形切割深度、高程变异系数、SPI、土地利用类型），共有 19 列，前 18 列为影响因子的类别，第 19 列为塌陷与否（0 或 1）。因此实际参与地理探测器及预测模型运算的是一个 2289 行×19 列的矩阵。将初始样本数据集输入进地理探测器中，得到每个影响因子的 q 值，对 q 值排序后如图 3.27

所示。




图 3.27 影响因子 q 值排序

Fig.3. 27 Ranking of influence factor q values

从地理探测器的分析结果中可以看出,地层岩性、地层含水性、坡位、微地貌、坡度、高程变异系数、地形切割深度对地面塌陷空间分异性拥有较大程度的解释, q 值均 >0.2 ,意味着对塌陷的影响更大。由 4.2.2 节的分析结果可知地面塌陷在这 7 个影响因子上的分布,塌陷点大多分布于嘉陵江组地层和大冶组地层,并且几乎都发育在强富水性地层,在坡位与微地貌的分布中,显示大部分塌陷分布于平地,坡度处于 $<8.1^\circ$ 的范围内,地表切割深度不超过 1.48m,并且高程变异系数 <0.0026 。而坡向、平面曲率及剖面曲率对地面塌陷空间分异性的解释力最小, q 值 <0.03 ,意味着对塌陷的影响较小。依据 q 值排序结果,按照步骤(2)的方法构建共 18 个样本数据集,该方法的核心思想是对带有不同权重影响因子的预测模型,按照权重大小通过递归减少影响因子数量的方式来反复构建预测模型, q 值即是本案例中的

影响因子权重。

构建好 18 个样本数据集后，接下来用它们来分别建立 18 个 RFC 预测模型，在每一次的预测模型建立过程中都需要对随机森林超参数进行优化，从而实现每一次都能基于当前样本数据集训练出最佳的预测模型。本文主要参考文献[125]对 RFC 待优化的超参数进行选取，共有如下四个超参数：

n_estimators: 决策树数量;
max_depth: 最大树深度;
min_samples_split: 分割最小样本数;
max_features: 最大特征数。

在 python 中调用 bayes_opt，输入上述 4 个超参数优化的探索范围，定义目标函数为 10 折交叉验证的 AUC 均值，这里并不直接使用模型精度作为目标函数，而是以 AUC 值作为替代来消除样本不平衡对结果的影响。贝叶斯优化旨在迭代搜索超参数组合，使带 10 折验证的 AUC 值最大，从而得到基于当前样本数据集训练生成的模型最优超参数。重复执行步骤（3）直到遍历完 18 个样本数据集，训练生成 18 个 RFC 预测模型，共得到 18 组超参数优化结果，并由每一组训练好的模型对测试集进行预测精度评价，表 3.21 为因子及参数耦合优化的结果，图 3.28 展示了全部 RFC 模型的预测精度。

表 3.21 因子及参数耦合优化结果

Table 3.21 Factor and parameter coupling optimization results

影响因子 个数	n_estimators	max_depth	min_samples_split	max_features	预测精度
18	114	5.0	21.2	21.21	0.904
17	54	9.2	17.3	0.14	0.934
16	52	9.2	17.0	0.14	0.935
15	63	15.0	25.0	0.10	0.914
14	116	15.0	25.0	0.10	0.924
13	50	6.8	17.8	0.10	0.923
12	112	9.9	16.6	0.10	0.927
11	52	9.2	17.3	0.14	0.918
10	136	7.0	18.9	0.10	0.917
9	164	5.0	22.9	0.10	0.905
8	209	5.1	12.1	0.22	0.902

影响因子 个数	n_estimators	max_depth	min_samples_split	max_features	预测精度
7	194	5.3	24.9	0.56	0.899
6	73	5.5	24.5	0.45	0.898
5	10	5.3	24.9	0.71	0.898
4	196	6.8	24.0	0.33	0.898
3	201	5.0	25.0	0.93	0.893
2	29	14.5	23.8	0.41	0.854
1	10	6.7	23.1	0.43	0.853




图 3.28 全部 RFC 模型的预测精度

Fig.3.28 Prediction accuracy of all RFC models

图中横坐标为影响因子个数，影响因子依次被消除，被消除的次序就是各影响因子解释力 q 值由小到大的次序。

可以看出 18 个 RFC 模型的预测精度整体变化趋势是随着影响因子的减少而降低，当参与建模的影响因素只有一个时，预测精度最低。这是由于当有更多的影响因子参与地面塌陷预测模型的建立时，模型结构更为复杂，主控因素的变化更加多样，模型从输出到输出的过程即使是一个黑匣子，在其中也会有更加丰富的选择和周转。从局部上看，在剔除掉坡向和平面曲率后，预测精度上升了，说明这两个

影响因子对于地面塌陷的预测属于噪声因子。而在剔除剖面曲率后，预测精度经历了下降再上升的过程，直到只剩 12 个影响因子后，预测精度几乎保持单调下降的过程。这是由于影响因子并不是完全独立的，部分影响因子之间可能会互相影响，因此会出现单独剔除某个影响因子，预测精度反而下降的现象。

影响因子之间的相关性解释了预测精度的局部变化趋势，而在全局的预测精度上，去除了两个噪声因子之后，由所剩的 16 个影响因子构建的样本数据集训练得到的 RFC 模型预测精度最高，因子及参数耦合优化后的最优模型的预测精度为 0.935。最终参与研究区地面塌陷预测的影响因子有地层岩性、距断层距离、覆盖层厚度、高程、坡度、坡位、剖面曲率、微地貌、地表切割深度、高程变异系数、TWI、地层含水性、SPI、TRI、距隧道距离、土地利用类型。

对因子及参数耦合优化后的 RFC 模型进行模型质量评价，采用 4.3.2 节所选取的评价指标，并与未优化的初始 RFC 模型进行对比，两个模型的 ROC 曲线如图 3.29 所示。结果表明，耦合优化的 RFC 预测模型的 AUC 值为 0.977，表明该模型质量是优秀的，对地面塌陷预测正确的可能性很高，而未经优化的预测模型 AUC 值为 0.840，耦合优化后 AUC 值提高了 0.137。隧址区地面塌陷两种 RFC 预测模型的预测能力如表 3.22 所示，耦合优化的 RFC 模型的预测精度为 0.935，代表了对于验证集的全部预测中，有 93.5% 的样本点被正确预测，预测准确率为 0.964，代表了对验证集所有被预测为发生塌陷的样本点中，实际真正发生塌陷的数量占比为 96.4%，因此可以认为该模型的预测能力强，并且泛化性能好。而未优化的 RFC 模型预测精度仅为 0.738，准确率为 0.818。对比两个预测模型，耦合优化的 RFC 模型精度提高了 0.197，预测率提高了 0.146，证明了因子及参数耦合优化方法在机器学习预测模型性能上的提升是显著并有效的，对地面塌陷的预测具有可靠性，下面执行步骤（4），将该模型应用于本案例的整个研究区，以此生成研究区的地面塌陷易发性分区图层。

表 3.22 两种 RFC 模型预测能力对比

Table 3.22 Comparison of prediction capabilities between two RFC models

RFC 预测模型	精度	预测率
未优化的	0.738	0.818
耦合优化的	0.935	0.964




图 3.29 两种 RFC 模型的 ROC 曲线

Fig.3. 29 ROC curves of two RFC models

3.4 隧址区地面塌陷易发性预测

研究区内全部网格点的属性通过 ArcGIS 的提取分析功能进行汇总，剔除掉两个噪声因子的属性后，将其输入到耦合优化后的 RFC 模型，在训练好的模型中对研究区全部网格点展开地面塌陷预测，预测值的输出形式为塌陷概率，最终得到 330020 个网格点的塌陷概率。将预测结果导入 ArcGIS，赋予每一个网格对应的塌陷概率，即可得到整个研究区的地面塌陷概率分布图层，其分布区间为[0,0.837]。将该塌陷概率分布以自然断点法分为 4 个区间，每个区间对应一个易发性等级，得到研究区地面塌陷易发性的最终分级结果。地面塌陷易发性分级结果以及塌陷在各易发性等级的分布统计如表 3.23 所示。研究区地面塌陷易发性分区可视化以及易发性等级和塌陷分布特征统计如图 3.30 所示。

表 3.23 地面塌陷易发性预测结果

Table 3. 23 Prediction results of ground collapse susceptibility

易发性等级	塌陷概率	网格数量	面积占比 (%)	塌陷数量	塌陷占比 (%)	FR
极低易发	[0,0.069)	252698	76.63	3	0.95	0.01
低易发	[0.069,0.232)	41183	12.45	26	8.06	0.64
中易发	[0.232,0.461)	18766	5.67	39	11.85	2.10
高易发	[0.461,0.837]	17373	5.25	258	79.15	15.03




图 3.30 地面塌陷易发性分区和塌陷分布统计特征

Fig.3. 30 Susceptibility zoning and statistical characteristics of ground collapse distribution

统计结果显示, 极低易发性等级的面积占比最多, 为 76.63%, 但地面塌陷点只有 0.95%落在该区域内; 高易发性等级所占面积最少, 为 5.25%, 但却有 79.15%的塌陷点落在该区域内, 共计 258 个塌陷点。易发性等级从低到高所占面积是逐级递减的, 而对应的塌陷点占比以及塌陷频率比 FR 值却逐级升高, 尤其是高易发性区域内的塌陷频率比高达 15.03。本案例的易发性分区结果与地质灾害易发性的普遍规律相符合, 也与地面塌陷的实际情况相符, 即在面积分布较小的高易发性等级区域内, 塌陷发生的概率和实际塌陷的数量及密度远高于其他区域。

地质灾害的分析方法除了对空间分布进行统计和特征描述, 还可以应用信息熵来探索其空间规律性, 这便是信息熵的应用分支之一, 简称为空间熵。熵原本是物理学中用于度量能量守恒的指标, 后来为了探究信息传递时不同等级对象的信息交流过程, 常被用来作为一个系统的信息含量的量化指标, 从而将其用于模型优化或参数优化。熵被定义为从随机分布事件中所获得的信息, 因此也可以说熵的大小代表了该事件包含信息的大小。空间熵指的是不同类别的空间信息量的大小, 信息量越小, 说明完全掌握该空间的规律性所付出的代价就越小, 代表该类别的空间

稳定性越强，空间规律性越好。空间熵的计算公式如下：

$$E = -\sum_{i=1}^n P(x_i) \log_2 P(x_i) \quad (3.14)$$

$$\sum_{i=1}^n P(x_i) = 1 \quad (3.15)$$

式中， $P(x_i)$ 代表了 i 位置上的概率， n 为所划分的空间位置个数， E 则为空间熵值。 $P(x_i)$ 在本研究中代表了各易发性等级的面积占比， n 代表了易发性等级的个数，即极低易发、低易发、中易发、高易发四个。 E 即为空间熵值。地面塌陷易发性等级分区的秩序性和空间规律性可以通过空间熵来进行定量分析，空间熵越小，其所携带的空间信息量越小，说明塌陷的空间分布规律越好，具有较好的稳定性，空间熵越大，所携带的空间信息量越大，说明塌陷的空间分布规律越差，稳定性不佳，掌握塌陷的分布规律需要付出更大的代价。按式 3.14 计算得到地面塌陷各易发性等级携带空间信息量以及总空间熵值如表 3.24 所示。

表 3.24 地面塌陷易发性等级空间熵
Table 3.24 Ground collapse susceptibility hierarchical spatial entropy

	极低易发	低易发	中易发	高易发
信息量	0.294	0.374	0.235	0.223
空间熵	1.126			

结果表明，隧址区地面塌陷在 4 个等级上携带的空间信息量相差不大，每个等级的空间秩序性较好。基于塌陷概率分布的易发性分区在整个研究区的空间熵值为 1.126，数值较小，表明耦合优化的 RFC 模型预测结果具有很好的空间规律性及空间稳定性。综合以上评价及检验，认为耦合优化的 RFC 模型具有优秀的预测性能，预测结果和真实结果基本符合，预测精度高，预测效果好，能够为隧址区地面塌陷空间预警及灾害防治提供理论依据及技术支持。

3.5 本章小结

本章通过地面塌陷致塌条件和致塌机理的现状研究，总结了隧址区地面塌陷的影响因素为地质条件因子、地形地貌因子、水文因子和人类活动，结合研究区地面塌陷数据点搭建起地理信息数据库，建立了基于因子及参数耦合优化的 RFC 预测模型，对研究区隧址区地面塌陷易发性进行预测及评价，主要得到以下结论：

1. 选取了地层岩性、距断层距离、覆盖层厚度、高程、坡度、坡向、坡位、平面曲率、剖面曲率、微地貌、地表切割深度、高程变异系数、TWI、地层含水性、SPI、TRI、距隧道距离、土地利用类型共 18 个影响因子。其中地层岩性、地层含

水性、坡位、微地貌、坡度、高程变异系数、地形切割深度对地面塌陷空间分异性拥有较大程度的解释。地面塌陷大多分布于距隧道距离 1km 的范围内，坡位为平地，主要发育在嘉陵江组地层和大冶组地层，地层含水性为强富水，并且大部分塌陷分布在坡度处于 $<8.1^\circ$ 、地表切割深度不超过 1.48m 以及高程变异系数 <0.0026 的平原微地貌形态上。

2.建立因子及参数耦合优化的 RFC 预测模型，并使用混淆矩阵、ROC 曲线和 AUC 值进行验证评价。耦合优化的 RFC 模型预测精度为 0.935，预测准确率为 0.964，未优化的模型预测精度为 0.738，准确率为 0.818。对比两个预测模型，耦合优化的 RFC 模型精度提高了 26.7%，预测率提高了 17.8%，且 ROC 曲线更贴近左上角，AUC 值为 0.977，未经优化的预测模型 AUC 值为 0.840，对比之下 AUC 值提高了 16.3%。结果表明基于因子及参数耦合优化的 RFC 预测模型性能得到较大提升，预测能力强，拟合性能好。

3. 将上述模型应用于整个研究区的地面塌陷预测，输出每个网格点的塌陷概率，其分布区间为 $[0,0.837]$ ，以自然断点法划分易发性等级，共分为极低易发、低易发、中易发和高易发，对应的塌陷概率分别为 $[0,0.069)$ 、 $[0.069,0.232)$ 、 $[0.232,0.461)$ 、 $[0.461,0.837]$ 。高易发性等级的面积占比为 5.25%，对应的塌陷占比却为 79.15%，共计 258 个塌陷点，塌陷频率比 FR 值为 15.03。易发性等级从低到高的面积占比逐级递减，而对应的塌陷占比以及塌陷频率比逐级升高。通过空间熵计算得到每个易发性区域携带的空间信息量相差不大，整体空间熵为 1.126，表明地面塌陷易发性分区具有良好的空间规律性及空间稳定性。

4 基于 CatBoost-可靠度联合的隧道涌水量预测

4.1 引言

隧道突涌水是富水区隧道工程建设中的常见灾害，其危害主要体现在破坏隧道内结构、威胁人员生命安全等，易造成巨大生命财产损失，因此有必要对隧道涌水量规模进行预测，并依据预测结果提前做好防护和应对措施。由于预测模型输入参数具有不确定性，并且服从某种分布特征，为此本文提出基于 CatBoost-可靠度联合的隧道涌水量预测方法，对隧道涌水量的规模大小、概率分级和置信区间进行预测。

本章主要围绕该方法进行展开，收集隧道涌水量数据和 4 个随机变量，分别为隧道埋深(H)、地下水位(h)、RQD 值和产水特性(W)。值得注意的是在隧道或边坡工程单体模型当中，常常将 c 和 φ 等岩土体物理力学参数作为不确定性随机变量，但对于基于大数据的预测模型，将多个隧道案例视为一个整体，因此在单个隧道中本来被认为是确定性因素的隧道埋深，在大数据预测和分析中也被视作具有某种分布特征的，即具有不确定性的随机变量。收集并搭建隧道涌水量案例数据库，利用散点图和最大信息系数等多种大数据分析方法对预测目标和变量的分布及相关性进行分析和可视化描述，使用 SMOGN 数据增强算法、异常值剔除的方法进行数据预处理。通过建立一个基于 optuna 优化的 CatBoost 回归器模型(Optuna-CBR)来输出隧道涌水量预测值，实现大量迭代计算下的超参数优化过程可视化，并通过多个评价指标进行验证。将该模型的预测结果以及 4 个随机变量作为隧道涌水量可靠度计算的输入，根据隧道涌水量分级标准构建功能函数，使用基于 Hermite 随机多项式展开的随机响应面作为可靠度计算的代理模型，并使用拉丁超立方抽样进行数据抽取，实现 10^6 次蒙特卡洛模拟，进而得到隧道预测涌水量分级概率、置信区间和涌水量标准值。

4.2 隧道涌水案例数据预处理

4.2.1 预测指标选取及统计特征分析

根据文献[126]的研究，隧道涌水量预测中需要考虑有效参数，而非纳入所有能被考虑的参数，参与涌水量回归预测模型的参数过多可能导致结果的准确度下降。要建立对预测目标的机器学习模型，首先需要确定预测指标，针对隧道实际工况和所处水文地质环境来确立预测指标是有必要的。本文将文献[127]中 600 个隧

道涌水案例作为隧道涌水量预测方法研究的样本数据,选取隧道深度(H)、地下水位(h)、岩石质量指标(RQD)和产水特性(W)为作为预测指标,涌水量(WI)为目标预测值,建立隧道涌水量预测模型。隧道深度 H 越大,围岩压力就越大,相应的岩石裂缝更加不易扩展,导致渗透性和裂隙连通性的下降,从而对隧道涌水产生影响。随着地下水位 h 的升高,隧道所受的地下水压力也会随之增强,对地下水入渗隧道产生积极影响。 RQD 值通过围岩节理的数量和间距两个参数间接影响着隧道涌水,因此考虑 RQD 值作为隧道突涌水的有效参数之一。含水层的产水特性 W 可通过岩体渗流和涌水计算,围岩中的含水层具有不同的产水量和溶解度特性。例如薄砂岩和白云岩的产水量特征高于泥岩和页岩,而高溶解度的岩层产水量通常高于低溶解度岩层。由此确定预测指标为 $H[m]$ 、 $h[m]$ 、 $RQD[\%]$ 及 $W[m^3/h\ m]$,目标预测值为 $WI[m^3/h]$ 。

对原始的样本数据首先需要进行一些基础分析及预处理,目的在于通过数据分析确立变量的分布,并以数学统计和可视化的形式展示。图 4.1 为数据的特征分析图,展示了全部原始参数的分布特征,参数之间的相关性,以及 4 个随机变量和预测目标 WI 的相关性。其中拟合曲线很好地表达了参数的两两相关程度。相关性越高,拟合曲线越陡峭,相关性越低,拟合曲线越平缓。拟合曲线的走向表示了参数之间的正负相关性,向上倾斜代表了两个参数之间的正相关,向下倾斜代表的是负相关。表 4.1 为数据的统计学特征分析,统计了所有参数的平均值、标准差、最大值、最小值、上下四分位数及中位数。从图中可以看出 4 个随机变量之间具有一定的相关性,但相关性相对较低。而对于预测目标 WI ,与随机变量隧道深度 H 、地下水位 h 、岩石质量指标 RQD 都有较高的正相关性,而与岩石质量指标 RQD 却有着一定程度的负相关。




图 4.1 涌水量样本数据统计特征

Fig.4. 1 Statistical characteristics of water inflow sample data

表 4. 1 涌水量样本数据统计表

Table 4. 1 Statistical table of water inflow sample data

	H(m)	h(m)	RQD(%)	W(m ³ /h m)	WI(m ³ /h)
数量	600	600	600	600	600
平均值	88.843	50.515	48.191	5.730	83.030
标准差	68.947	56.241	20.307	3.967	34.086
最小值	15	0	4	1	40.5
25%	54	22	34	3.2	63.5
50%	66	33	45	4.65	72.35
75%	89	54	63	7	90.375
最大值	350	312	99	33.6	274.6

从图 4.1 中可以看出,涌水量 WI 与各随机变量之间的关系并非完全线性,并且图中无法定量展示出各因子对 WI 的影响程度,因此需要引入非线性量化指标来进一步说明参数之间的相关性。Reshef 等^[128]最早提出了最大信息系数(Maximal information coefficient, MIC) 的概念,其目的是较为综合地探索两个变量之间的线性或非线性关系程度。MIC 基本原理是利用互信息概念,将变量 x 和 y 离散于二维空间关系中,形成散点图,将二维空间划分为多个区间,查看散点在这些区间的分布情况,并以此求得联合概率分布,进而得到互信息,对最大的互信息值进行归一化,选择不同尺度下互信息的最大值作为 MIC 值,从而得到变量之间的影响关系程度。从图 4.2 中得到涌水量 WI 与 H 、 h 、RQD 以及 W 的 MIC 值分别为 0.16、0.23、0.14 和 0.31,可以看出 WI 与地下水位 h 和产水特性 W 具有最高程度的非线性相关性,而与隧道深度 H 和 RQD 的非线性相关性较为一般。




图 4.2 最大信息系数热力图

Fig.4. 2 Maximum information coefficient thermodynamic diagram

为了探索 4 个变量在不同涌水量等级下的分布规律,采用核密度估计图进行非参数估计。核密度估计(Kernel Density Estimation, KDE)用以基于有限的样本推断总体数据的分布,是一种基于数据本身来研究数据分布特征的方法。核密度估计即为样本数据的概率密度函数估计,根据该估计的结果就可以得到数据分布的一些性质,例如数据的聚集区域。根据文献[129]对隧道涌水量划分亚级的标准,本案例中涌水量只处于两个级别,分别为 III₂ 和 IV 级。图 4.3 和图 4.4 分别展示了 MIC

最大(W、h)和最小(H、RQD)的两组变量在不同涌水量级别下的核密度估计。




图 4.3 不同涌水量级别下 H 和 RQD 的核密度估计
Fig.4. 3 KDE of H and RQD under different water inflow levels




图 4.4 不同涌水量级别下 W 和 h 的核密度估计
Fig.4. 4 KDE of W and h under different water inflow levels

从图 4.3 和图 4.4 中可以看出当 WI 处于 III₂ 级时, KDE 图结果显示 H 和 RQD 的概率密度估计分布并不集中, W 集中分布于 0~10, 而 h 集中分布于 0~50m; 当 WI 处于 IV 级时, H 在 50~100m 的范围内概率密度估计最大, RQD 值在 40~60% 的范围内较大, 而 W 和 h 的概率密度估计分布平坦且分散。

4.2.2 样本数据清洗

在机器学习模型建立之前, 不能对直接获取的样本数据直接进行训练和建模, 数据清洗是发现和纠正样本数据可识别错误中的必要程序, 直接使用未经处理的数据有可能使模型结果产生偏差, 从而降低模型的准确性。数据清洗包括了检查数据的一致性、完整性, 处理数据空缺值、异常值及数据降维等。常用的手段有插值法、删除法和平均值替代法以及盖帽法等, 本文将对数据的异常值进行检测和处理, 由于隧道涌水案例的数据维度并不高, 因此不必做数据降维, 而本章使用的 CatBoost 算法本身对数据缺失处理和数据量纲差异方面都具有较强的兼容性, 因此本节主要针对原始样本异常值进行检测和处理。

在涌水量样本数据中有时会存在明显偏离正常值的个体异常样本, 数值远远偏离其余正常样本。其原因可能由地质因素中的异常或突变引起, 在整个隧道突涌水灾害中属于偶发现象, 对整体的预测并无帮助, 如果不做处理则会影响数据的分布, 对模型建立和数据统计分析来说都是不利的。异常值检测及处理就是为了检验数据的合理性, 对异常值进行纠偏或剔除。

箱线图是一种常用的异常值检测及可视化的工具, 可用于了解数据的分布, 也叫四分位距法(IQR, interquartile range), IQR 描述了从低到高排序的中间 50% 的数据。将数据从最低排到最高, 计算上四分位数 Q1、中位数 Q2 和下四分位数 Q3, IQR 为下四分位数和上四分位数的差值。因此定义大于上四分位数 1.5 倍 IQR 的值, 或者小于下四分位数 1.5 倍 IQR 的值, 为异常值。

图 4.5-图 4.8 为利用 python 中 seaborn 可视化库生成的异常值检测图, 展示了隧道涌水量的四个随机变量和预测目标 WI 的边缘箱线图, 中间为隧道深度、地下水位、岩石质量指标和产水特性分别与隧道涌水量 WI 生成的气泡图, 气泡的颜色映射了 4 个随机变量数值的大小, 气泡的大小映射了 WI 数值的大小, WI 越小, 气泡的面积越小。右侧为隧道涌水量检测的箱线图, 底部为各变量的箱线图。




图 4. 5 H 分布特征及异常值检测

Fig.4. 5 H distribution characteristics and abnormal value detection

从图中可以看到本案例中隧道埋深大多分布于 150m 的范围内，在 150~300m 的区间内少有少量分布。而 $H < 150\text{m}$ 这个区间内对应的涌水量大小多数在 $200\text{ m}^3/\text{h}$ 以下，当 H 处于 $[70, 200]\text{m}$ 这个区间内时，可以发现所对应的涌水量大小几乎不超过 $150\text{ m}^3/\text{h}$ 。从边缘箱线图中看出，隧道涌水量 WI 和隧道埋深 H 均有部分异常值，因此在对异常值进行处理之前无法直观判断和描述两个变量之间的分布规律。




图 4. 6 h 分布特征及异常值检测

Fig.4. 6 h distribution characteristics and abnormal value detection

本案例中地下水位集中于 0~70m 这一区间范围内, 从图 4.6 中可以看出气泡的分布十分密集, 而当地下水位 $>150\text{m}$ 时气泡密度下降, 说明地下水位在这一范围的分布较为稀疏。涌水量 WI 大部分处于 $150\text{ m}^3/\text{h}$ 以下, 当 $h<70\text{m}$ 时, 和 WI 的分布规律并不明显, 当 $h>70\text{m}$ 时, 随着地下水位的增大, 涌水量也呈增加的趋势。当 h 增大到 200m 以上时, WI 均增大至 $100\text{ m}^3/\text{h}$ 以上。因此在 $h>70\text{m}$ 的区间范围内, 气泡图直观表明了隧道涌水量随着地下水位的增大而增加。边缘箱线图表明了地下水位 h 也存在部分异常值, 需要对其进行预处理。




图 4.7 RQD 分布特征及异常值检测

Fig.4.7 RQD distribution characteristics and abnormal value detection

从图 4.7 中可以看出 RQD 值的分布规律性相对较好, 在 0~100%的区间内分布相对均匀, 因此 RQD 的边缘箱线图中并没有异常值出现。对于 RQD 值和 WI 的分布关系, 从气泡图中可以发现当 RQD 值处于 $[0,70]\%$ 这一区间范围内时, WI 少量分布了 $>150\text{ m}^3/\text{h}$ 的样本, 当 RQD 值 $>70\%$ 时, WI 均分布于 $150\text{ m}^3/\text{h}$ 以下, 但没有证据显示隧道涌水量随 RQD 的增加而减小, 两者之间不存在明确的非线性规律。




图 4.8 W 分布特征及异常值检测

Fig.4. 8 W distribution characteristics and abnormal value detection

产水特性 W 和隧道涌水量 WI 同样不存在明显的非线性关系,但可以从图 4.8 中看出随着 W 的增大, WI 的下限略有提高,即当产水特性增大时,最小隧道涌水量有小幅增加。并且从气泡图中可以看出,绝大部分二维样本点集中在 W 为 $[0,10]$ $\text{m}^3/\text{h m}$ 和 WI 为 $[0,150]$ $\text{m}^3/\text{h m}$ 的区间,当 $W > 10 \text{m}^3/\text{h m}$, 气泡密度越小,分布越稀疏,只有 6 个样本点的 $W > 20 \text{m}^3/\text{h m}$, 并且 WI 均在 $100 \text{m}^3/\text{h}$ 。从边缘箱线图中可以看到 W 也存在待处理的少量异常值。

可以看到除了岩石质量指标 RQD 值没有出现异常值外,其他变量的样本数据均有部分异常值,对于数据异常或离群值,通常可以采用剔除异常值的方式,但统计得 600 个样本数据共有 124 个异常值,如果全部剔除会大幅削减样本的数量,对模型的精度依然存在影响。事实上根据地质因素的偶发性和突变性,理论上地质因素的突变导致样本数据中的异常不应如此多,因此考虑为在每个变量的某一区间其样本数量相对较少,导致了该区间的数据被视为异常。现有的数据不平衡问题很多是基于分类问题研究上提出解决方案的,然后回归任务中的数据不平衡会更加复杂,因为变量是连续的,并且在有限的区间内变量存在一个初始值。除此之外,对于待解决的每一个不平衡数据,可能存在与该数据具有或不具有关联性的其他数据,又加深了计算的复杂度。事实上对于连续变量的回归模型,样本不平衡问题已被学者提出并研究过。Paula Branco 等^[130]提出了一种基于 SMOTE 算法改进的方法以解决不平衡回归问题。SMOTE 算法可以被描述为对于少数类样本 a , 从该样本最邻近的样本 b 中随机选取一个,然后在 a 与 b 之间的中点处新生成一个样

本。该方法的缺陷在于对于新样本的生成，少数类样本选择的 k 最邻近样本没有限制， a 和 b 的距离相差有近有远。而在这基础上，SOMGN 引入高斯噪声，只有当 a 和 b 相距足够近时，才允许新样本生成，而当相距较远时，高斯噪声介入，不生成新样本。这就使得对于不平衡数据的合成，加上了一定的限制条件，建立了一个决策边界，使得新合成的样本具有更高的泛化程度，建立的数据模型也更加可靠。SOMGN 算法的原理图如图 4.9 所示。




图 4.9 SOMGN 原理

Fig.4. 9 SOMGN principle

本文对样本数据中的 WI 进行 SOMGN 处理，对 WI 的少数类样本数据进行合成之后，数据量缩减为 532 个，由图 4.10 可以看到对于不平衡回归处理目标为涌水量 WI 时，新合成的样本的分布表现大体良好，对于目标 WI 以及变量 H 和 h，样本数据的分布相对合理，无异常值出现。变量 RQD 和 W 仍分别存在 1 个和 16 个异常值，按次序对两者进行异常值剔除，由于变量间的相关性影响，异常值剔除过程迭代了两次，最终剔除了 11 个岩石质量指标 RQD 的异常值和 17 个产水特性 W 的异常值。600 个样本经 SOMGN 不平衡回归处理和异常值剔除之后，最终数据为 503 个，如图 4.11 所示，其各变量的数据统计如表 4.2 所示。




图 4.10 SMOGN 后异常值检测

Fig.4.10 After SMOGN processing




图 4.11 异常值剔除后

Fig.4.11 After removing abnormal values

表 4.2 处理更新后样本数据统计特征

Table 4.2 Processing updated sample data statistical characteristics

	H(m)	h(m)	RQD(%)	W(m³/h m)	WI(m³/h)
数量	503.0	503.0	503.0	503.0	503.0
平均值	132.3	95.6	43.4	6.8	118.2
标准差	106.0	94.6	20.7	3.9	49.2

	H(m)	h(m)	RQD(%)	W(m ³ /h m)	WI(m ³ /h)
最小值	15.0	0.0	4.0	1.0	40.5
25%	54.0	25.0	30.0	3.7	70.9
50%	70.0	44.0	43.0	5.5	117.8
75%	223.5	178.5	56.0	9.2	154.3
最大值	350.0	312.0	93.0	17.4	262.8
IQR	169.5	153.5	26.0	5.5	83.4
下界	-200.3	-205.3	-9.0	-4.5	-54.1
上界	477.8	408.8	95.0	17.4	279.3

从表中可以看出数据异常值处理后的各变量所有数据都处于计算出的上下界内,并且极值大多靠近上界,说明样本的数据集中偏向整个分布的首部而非尾部,这在散点图里也能看出来。H 和 h 的中位数和均值相差较远,而 RQD、W 和 WI 的均值较为接近,说明前者的整体分布有较为严重的左偏态,后者的整体分布则相对均匀。

4.3 Optuna-CBR 涌水量预测模型

4.3.1 模型质量评价指标

机器学习模型需要预测结果进行质量评价,以验证模型的准确性。不论对分类预测模型还是本章所用的回归预测模型,都会考察模型的预测性能。首先模型的预测结果是否正确或接近正确,对于分类预测结果来说,只有是或不是两种结果,即判断分类结果的正确与否,对于回归预测结果,需要看模型计算结果是否足够接近真实值。其次对于回归预测模型,仅仅验证预测值和真实值的接近程度是不够的。需要探索线性拟合程度,即找出目标数据分布状态,如分布规律、单调性等。本案例选取 5 个回归模型统计指标对预测模型表现进行分析,分别为平均绝对值误差(MAE)、均方误差(MSE)、均方根误差(RMSE)、平均绝对百分比误差(MAPE)和决定系数(R^2)。公式 4.1-4.5 如下:

$$MAE = \frac{1}{m} \sum_{i=1}^m (|y_i - f(x_i)|) \quad (4.1)$$

$$MAPE = \frac{100\%}{m} \sum_{i=1}^m \left| \frac{y_i - f(x_i)}{y_i} \right| \quad (4.2)$$

$$MSE = \frac{1}{m} \sum_{i=1}^m (y_i - f(x_i))^2 \quad (4.3)$$

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m (y_i - f(x_i))^2} \quad (4.4)$$

$$R^2 = 1 - \frac{\text{MSE}(y_i, f(x_i))}{\frac{1}{m} \sum_{i=1}^m (y_i - \bar{y})^2} \quad (4.5)$$

式中, y_i 为真实值, $f(x_i)$ 为预测值, 而 $\bar{y}$ 代表了真实值的平均值, m 为样本数量。MAE 用于评估预测结果和真实数据集的接近程度, 其值越小说明拟合效果越好。MSE 计算的是拟合数据和原始数据对应样本点误差的平方和的均值, 其值越小说明拟合效果越好, 而 RMSE 为 MSE 的开方。MAPE 的取值范围为 $[0, +\infty)$, 越接近于 0 代表模型越完美。方差的信息量包含数据潜在的分布规律, R^2 的定义中, 分子为预测值与真实值差值的方差, 包含了数据模型中未被捕捉的信息量, 分母则包含了真实值的信息总量, 因此 R^2 代表的是已被捕捉的数据分布规律信息量占信息总量的比例。 R^2 的取值范围为 $[0, 1]$, 越接近 1, 说明模型的预测效果越好, 越接近于 0, 说明模型的预测效果越差。

4.3.2 模型建立及验证

CatBoost 算法分为分类模型和回归模型, 显然预测隧道涌水量是以回归任务为目标, 因此使用 CatBoostRegression(CBR)模型对样本数据展开训练与预测。由于随机变量服从一定的分布, 具有一定的不确定性, 因此需要对预测结果展开可靠度分析。基于 CatBoost-可靠度联合的隧道涌水量预测的步骤包括隧道涌水量数据库搭建、隧道涌水量点预测和可靠度分析。隧道涌水量 CBR 预测模型的技术路线如图 4.12 所示, 具体建模流程为:

(1) 隧道涌水量数据库搭建

收集机器学习建模需要的预测指标和目标预测值, 4.2.1 节详细介绍了选取隧道埋深、地下水位、RQD 值及产水特性的原因, 并对各变量的统计特性展开了分析。原始样本数据集存在地质扰动造成数据异常的现象, 但也有部分异常来自分布不均, 部分小样本数据较少, 对此采取 SMOGN 算法进行数据增强, 并在数据增强处理后再次检测异常值, 对其进行剔除。对更新后的数据集以 1: 4 的比例划分测试集和训练集。

(2) 隧道涌水量点预测

选取 CatBoost 算法对隧道涌水量展开点预测, 由于算法本身的超参数设置不同, 对于数据的探索和学习就可能倾向于不同的方向, 导致最后生成的模型良莠不齐, 因此选用 Optuna 优化框架对 CBR 模型进行超参数优化, 同时探索超参数的寻优过程, 并以可视化的方式呈现。以 MSE、RMSE、MAE、MAPE 和 R^2 对预测模型进行模型质量评价, 并以未优化的 CBR 模型和 LR 模型进行对比。

(3) 可靠度分析

由于随机变量分布具有非正态性,无法直接进行抽样,因此需要将变量标准正态化处理,由于处理后的随机变量直接应用于步骤(2)所建立的机器学习模型会导致模型失真,因此引入随机响应面法进行可靠度分析。隧道涌水量预测值与4个通过标准正态化的随机变量来对展开的 Hermite 多项式进行拟合,通过 MATLAB 求解待定系数,以构建随机响应面,通过 10^6 次蒙特卡洛模拟展开隧道涌水量预测的可靠度分析,最终得到隧道涌水量分级、3 个不同置信水平下的涌水量预测区间以及涌水量标准值。




图 4.12 隧道涌水量 CatBoost-可靠度预测模型的技术路线

Fig.4. 12 Technical route of CatBoost-reliability prediction model for tunnel water inflow

在 4.2 节已完成步骤(1)的实现,本节将建立 Optuna-CBR 预测模型。首先对预测模型进行超参数优化,实现超参数搜索过程可视化。CatBoost 模型待优化的超

参数主要有如下几个：

- iterations: 设置迭代数，限制树的数量；
- learning_rate: 优化时的学习率；
- l2_leaf_reg: 正则化项参数；
- colsample_bylevel: 列采样等级；
- depth: 树深度；
- min_data_in_leaf: 最小停止分裂值；
- one_hot_max_size: 最大独热编码；
- bagging_temperature: 定义 Bayesian 采样的设置。

超参数优化一般有手动调参、网格搜索寻优，手动调参就是人工不断试错的过程，很难得到最佳超参数且费时，网格搜索的不足在于由于是遍历超参数的所有组合，当需要优化的超参数数量较多，网格搜索的计算量就会呈指数型的上升，计算代价太大，网格搜索通常选择 3 至 4 个超参数进行优化，并不适用于 CatBoost 模型。

因此本文选择 Optuna 超参数优化框架实现超参数寻优。Optuna 最初诞生于 2019 年，其设计为对基于树的超参数搜索进行优化，例如 CatBoost 这样的基于树集成的机器学习算法。Optuna 使用 TPESampler (Tree-structured Parzen Estimator) 不断缩小超参数的搜索范围，直至一个能产生较好目标函数值的搜索范围，然后在该范围内继续搜索，确定超参数，这就是其采样规则，并且在超参数寻优的前期，通过剪枝规则终止效果较差的搜索范围。另外 Optuna 能实现超参数搜索的可视化，并且能获得各个超参数之间的交互信息，查看超参数寻优的历史过程等。CBR 模型的超参数优化需要定义一个损失函数，通常对于回归模型选择 RMSE 作为目标损失函数，即最优超参数组合使 RMSE 逼近最小。采用带十折交叉验证的 Optuna 优化进行寻优，将样本数据分为 10 份，其中 9 份作为训练集，1 份作为测试集，进行损失函数的计算，重复此步骤 10 次，每次选取不同的训练集，共得到 10 个不同的机器学习模型，最终结果取它们的平均值作为十折交叉验证的计算结果。

由此在 python 中定义目标函数，输入 CBR 模型的超参数及取值范围，以 10 折交叉验证的 RMSE 均值作为输出，对于超参数寻优的探索次数，次数过少会无法找到最佳超参数组合，次数过多对最终计算结果的影响不大，且较为费时，因此设置搜索次数为 1000 次。





图 4.13 超参数重要性排序

Fig.4.13 Hyperparametric importance ranking

图 4.13 为所选超参数对目标函数值的影响力，即超参数重要性，数值越大代表重要度越高，对计算结果的影响越强烈。其中列采样等级的重要度为 0.46，其次为迭代数和学习率，分别为 0.40 和 0.10，其他 5 个模型超参数对目标函数计算结果影响相对较小。为此图 4.14 展示了列采样等级、迭代数和学习率在超参数探索过程中的交互信息，等高线划分出来的不同颜色深浅的区域即为目标损失函数的迭代计算结果，颜色越深代表损失越大，RMSE 越小，模型性能越好，在这个过程中两个超参数的探索结果就是二维等高线图中点的空间属性。






图 4.14 优化过程中的超参数交互信息：(a)列采样等级和迭代数；(b)列采样等级和学习率；(c)迭代数和学习率

Fig.4. 14 Hyperparametric interaction information in optimization process: (a) `colsample_bylevel` and iterations; (b) `colsample_bylevel` and `learning_rate`; (c) iterations and `learning_rate`

从图中可以看出寻优过程中三个超参数都有各自的较优探索区，由于目标函数设置的是 RMSE，因此等高线数值越小越好，超参数越靠近深色区域越优，因此在迭代搜索的过程中大部分点都会分布于该区域附近。整个搜索过程中的 1000 个样本点分布最密集的区间就是较优搜索区，对于列采样等级而言，使目标函数较优的搜索区间约为 0.08~0.10；对于迭代数而言，最优搜索区间约为 600~800；对于学

习率而言，最优搜索区约为 0.04~0.08。图中的等高线分布情况反映了探索过程中超参数之间的两两交互情况，因为每个样本点都携带了三个信息，两个超参数信息和一个目标值信息，可以看出在等高线值较大时，分布有少许超参数样本点，因为在超参数优化的过程中不可避免地需要对未知区域展开探索，而不局限于局部最优，这样在不降低效率的同时也扩大了搜索范围。




图 4.15 超参数搜索的演变过程

Fig.4.15 Evolution of hyperparametric search

图 4.15 可以直观地看到在最佳超参数的搜索过程中，每个超参数在哪些区域被探索得最多，迭代搜索次数越大颜色越深，例如正则化项参数这一超参数，定义的范围为[0,1]，对于 RMSE 小于 14 的计算结果来说，大多对应了该参数为 0.6 至 0.8 的范围内，且迭代次数越大目标值越靠近 10，说明 optuna 优化框架根据先验结果缩小了搜索范围，使得超参数搜索区域趋于集中。

图 4.16 为参数优化历史，它能直观展示从 0 开始的迭代计算过程中目标函数值的整体下降过程以及局部的最小值，可以看出目标函数值大致呈阶梯式下降。




图 4.16 超参数优化历史

Fig.4.16 Hyperparametric optimization history

CBR 模型的超参数优化最终计算结果如表 4.3 所示，目标损失函数的返回结果 RMSE 逼近的最小值为 11.859。

表 4.3 Optuna 优化后的 CBR 模型超参数

Table 4.3 Hyperparameters of CBR model optimized by Optuna

模型超参数	值
iterations	757
learning_rate	0.573
l2_leaf_reg	0.274
colsample_bylevel	0.096
depth	10
min_data_in_leaf	5
one_hot_max_size	4
bagging_temperature	1.284

将经过 SMOGN 数据增强及异常值剔除后的全部 503 个涌水量数据以 4: 1 的比例划分训练集与测试集，抽样方式为打乱顺序后的随机抽样，得到训练集数据 402 个，测试集数据 101 个。将优化后的 8 个超参数输入 Optuna-CBR 模型，开始对训练集进行训练学习，完成后输入测试集数据，并输出模型训练结果。为了验证该模型的优越性，将同样的训练测试集输入未经优化的 CBR 模型和传统的线性回

归模型，分别得到预测结果，与 Optuna-CBR 模型进行对比分析。表 4.4 统计了三个模型的预测结果。

表 4.4 不同预测模型的质量评价结果
Table 4.4 Quality evaluation results of different prediction models

	MAE	MSE	RMSE	MAPE[%]	R ²
Optuna-CBR_train	5.45	47.12	6.86	5.43	0.98
Optuna-CBR_test	8.91	126.41	11.24	8.58	0.95
CBR_train	8.19	114.06	6.288	8.07	0.95
CBR_test	11.68	235.11	15.33	12.10	0.91
LR_train	16.16	451.73	21.25	15.25	0.80
LR_test	17.93	491.29	22.16	16.96	0.82

结果表明 Optuna-CBR 模型在各种误差上的表现均小于其他两个模型，在训练集上的平均绝对百分比误差只有 5.43%，均方根误差只有 5.45，而决定系数 R² 为 0.98，测试集上的平均绝对百分比误差为 8.58%，均方根误差为 11.24，决定系数 R² 为 0.95，可以有效说明该模型的拟合性能是优秀的。此时 Optuna-CBR 模型的 RMSE 与前文中超参数寻优定义的目标函数值计算结果不同，是由于两次抽样的训练集和数据集不同，但由于样本数据的分布是一致的，因此超参数优化结果适用于不同的训练测试集。

图 4.17 为不同预测模型在测试集和训练集上的预测结果，参考线代表着最理想，即预测值完全等于真实值。预测结果越靠近参考线代表预测越准确，越远离参考线代表预测效果越差。从整体结果上看，三个模型的结果分布大致贴合参考线，表明预测结果相对合理。其中 Optuna-CBR 模型直观上最贴合参考线，并且训练集和测试集的预测结果相对集中不分散，综合性能表现最佳，其决定系数 R² 在训练集及测试集上均为三个模型中的最大值，而 MAE 和 RMSE 均小于其他两个模型，说明其误差较小，预测性能最为良好。LR 模型在 3 个回归模型中表现最差，决定系数 R² 较低，并且图中数据点的离散程度大，预测产生的误差较大，说明该模型质量较差。未经优化的初始 CBR 模型性能尽管不及 Optuna-CBR 模型，但在训练集和测试集上决定系数较高，预测误差较小，说明 CatBoost 算法本身就具有较好的预测效果，是涌水量预测方面表现良好的模型。






图 4.17 不同预测模型在测试集和训练集上的预测结果：(a)Optuna-CBR 模型；(b)CBR 模型；(c)LR 模型

Fig.4.17 Prediction results of different prediction models on test sets and training sets: (a) Optuna-CBR model; (b) CBR model; (c) LR model

图 4.18 很好地展示了 3 个模型在测试集上的 101 个预测结果的整体分布，折线图分别为预测值和真实值，柱状图为两者的差值，柱越高表明对该样本点的预测误差越大。Optuna-CBR 模型的预测误差最高不超过 $50\text{m}^3/\text{h}$ ，大部分样本点误差都在 $25\text{m}^3/\text{h}$ 以内，少许样本点的预测误差高于这个区间。对于 Optuna-CBR 模型和未优化的初始 CBR 模型来说，预测结果和真实结果的吻合程度较高，误差较小，但图中 LR 模型的误差大，预测效果不佳，有部分样本点的预测误差超过了 $50\text{m}^3/\text{h}$ ，因此简单的线性回归并不能拟合真实的涌水量回归模型，也无法应用于实际工程。



(a)



(b)




图 4.18 不同预测模型在测试集上的预测结果: (a)Optuna-CBR 模型; (b)CBR 模型; (c)LR 模型

Fig.4. 18 Prediction results of different prediction models on the test set: (a) Optuna-CBR model; (b) CBR model; (c) LR model

4.4 隧道涌水量级别和预测区间可靠度分析

4.4.1 基本随机变量标准正态化

上节对原始数据进行了统计分析和一系列预处理，在超参数优化后建立了 Optuna-CBR 模型，并且验证了该模型的有效性。本节将选用随机响应面法来实现基于 Optuna-CBR 模型的隧道涌水量预测可靠度分析。

由于随机响应面确立的是基本随机变量与目标响应值的显式功能函数，采用的多项式形式是 Hermite 随机多项式，该多项式要求了基本随机变量需要服从标准正态分布，因此对于 503 个样本数据，需要对其进行标准正态化处理。事实上在 4.2 节对数据的特征统计分析中就能发现，变量的分布具有一定随机性，只是近似服从正态分布，因此首先对 4 个基本随机变量 H 、 h 、 RQD 和 W 的 503 个数据进行正态性检验。

本文对基本随机变量分布进行 Kolmogorov-Smirnov 检验 (K-S 检验)，该方法是基于累积分布函数的，通常用于确定两个样本数据的潜在概率分布是否存在显著差异，或者目标数据的潜在概率分布是否与假设分布存在显著差异。正态性检验

属于非参数检验，与参数检验不同的是它不要求数据的概率分布已知。调用 python 中的 K-S 检验，假设 4 个基本随机变量的分布服从正态分布，当 p 值大于 0.05 时接受原假设，数据服从正态分布，反之拒绝原假设，数据不服从正态分布。正态性检验的结果如表 4.5 所示。

表 4.5 随机变量正态性检验
Table 4.5 Test for normality of random variables

	偏态	峰度	p
H	0.849	-0.867	1.335e-26
h	0.935	-0.687	1.688e-34
RQD	0.246	-0.482	0.004
W	0.777	-0.473	1.018e-08

4 个基本随机变量的 p 值均小于 0.05，因此拒绝原假设，即数据不服从正态分布。因此对于非正态基本随机变量的输入，需要做正态化处理。常用的正态化处理方法有对数变换、平方根变换、倒数变换及 box-cox 方法等，但这些方法有各自的适用条件，如 box-cox 的优点是通过求变换参数 λ 来确定变换形式，是一种相对客观的求解方式，但不足在于无法保证改善正态性和方差齐性，比如该方法无法有效处理双峰数据。Scikit-Learn(sklearn)是基于 python 的机器学习工具包，是数据挖掘和预处理的强有力手段，在 sklearn 中导入分位数转换器(QuantileTransformer)这一工具包对非正态数据进行处理，该方法将数据转换为遵循均匀或正态分布，对于给定的数据集合，趋向于分散最高频数的值，并且能够有效减小边际效应。分位数转换器对于每个独立的变量，分别对其进行正态化转换，使用各变量的累积分布函数的估计来将原始值映射至均匀分布，然后使用关联的分位数函数将得到的值映射到高斯分布。低于或高于拟合范围的新数据及不可见数据的值将映射到高斯分布的边缘。

4 个基本随机变量标准正态化处理前后的频率分布直方图及 q-q 图如图 4.19-图 4.22 所示。




图 4.19 H 标准正态化后: (a)直方图; (b)q-q 图

Fig.4.19 After normalization of H standard: (a) histogram;(b)q-q diagram




图 4.20 h 标准正态化后: (a)直方图; (b)q-q 图

Fig.4.20 After normalization of h standard: (a) histogram;(b)q-q diagram




图 4.21 RQD 标准正态化后: (a)直方图; (b)q-q 图

Fig.4. 21 After normalization of RQD standard: (a) histogram;(b)q-q diagram




图 4.22 W 标准正态化后: (a)直方图; (b)q-q 图

Fig.4. 22 After normalization of W standard: (a) histogram;(b)q-q diagram

q-q 图中的纵坐标对应的是该数据的真实分位点,称为样本分位数点,横坐标为理论分位数点,如果变量服从正态分布,数据所有点的连线应当大致贴合于 $y=x$ 这条直线。从图中可以看到 4 个基本随机变量在分位数转换器变换后已基本服从标准正态分布,处理后的正态检验结果如表 4.6 所示。

表 4.6 标准正态化后变量分布检验结果

Table 4.6 Test results of variable distribution after standard normalization

	偏态	峰度	p
H	-0.173	2.579	0.386
h	-0.598	4.885	0.114
RQD	-0.001	1.832	0.549
W	-0.291	3.317	0.791

4.4.2 Hermite 随机多项式展开

响应面法是通过输入基本随机变量与对应的目标响应值来构建两者的拟合多项式,而随机响应面与普通响应面法的不同在于,随机响应面法的多项式是 Hermite 随机多项式,是一种可以扩展为高维高阶次的正交多项式,响应面法采用的是普通多项式。在 2.4.2 节对 Hermite 随机多项式做了基本介绍,对于本案例的 4 个基本随机变量,只需要确定多项式的阶次就可以求出完整表达式,对于 N 维 p 次的 Hermite 随机多项式,需要计算的待定系数数量为 $(N+p)!/(N!p!)$ 。例如当阶次等于 1,基本随机变量数量为 4 时,待定系数的数量为 5,四维一阶 Hermite 多项式为 $Y_{(4,1)}=b(1)+b(2)x_1+b(3)x_2+b(4)x_3+b(5)x_4$ 。

根据文献[131]的研究,阶次越高,多项式展开越复杂,随机响应面的构建越精密,在该文献对某一算例的研究中,分别使用了 10^4 次蒙特卡洛模拟与二阶、三阶、四阶随机响应面计算得到的失效概率进行对比,以蒙特卡洛模拟作为精确解,三阶和四阶随机响应面的计算结果更逼近于蒙特卡洛解,但对于高维基本随机变量来说,四阶 Hermite 多项式展开的项数和待定系数的数量要远大于三阶。因此本文选择阶次为 3,维数为 4,对 Hermite 多项式进行展开,共需求解 35 个待定系数 $b(n)$,多项式表达式如下:

$$\begin{aligned}
 Y_{(4,3)} = & b(1) + b(2)x_1 + b(3)x_2 + b(4)x_3 + b(5)x_4 + b(6)(x_1^2 - 1) + b(7)(x_2^2 - 1) + \\
 & b(8)(x_3^2 - 1) + b(9)(x_4^2 - 1) + b(10)(x_1x_2) + b(11)(x_1x_3) + b(12)(x_1x_4) + \\
 & b(13)(x_2x_3) + b(14)(x_2x_4) + b(15)(x_3x_4) + b(16)(x_1^3 - 3x_1) + \\
 & b(17)(x_2^3 - 3x_2) + b(18)(x_3^3 - 3x_3) + b(19)(x_4^3 - 3x_4) + \\
 & b(20)(x_1x_2^2 - x_1) + b(21)(x_1x_3^2 - x_1) + b(22)(x_1x_4^2 - x_1) + b(23)(x_2x_1^2 - x_2) + \\
 & b(24)(x_2x_3^2 - x_2) + b(25)(x_2x_4^2 - x_2) + b(26)(x_3x_1^2 - x_3) + b(27)(x_3x_2^2 - x_3) + \\
 & b(28)(x_3x_4^2 - x_3) + b(29)(x_4x_1^2 - x_4) + b(30)(x_4x_2^2 - x_4) + b(31)(x_4x_3^2 - x_4) + \\
 & b(32)(x_1x_2x_3) + b(33)(x_1x_2x_4) + b(34)(x_1x_3x_4) + b(35)(x_2x_3x_4)
 \end{aligned}$$

4.4.3 涌水量分级概率及预测区间确定

有了 Hermite 多项式表达式,就可以对响应面进行拟合,在用有限元模型求解可靠度的时候,通常会从模型中抽取一定数量的带有物理力学属性的网格点来进行可靠度计算,例如用于响应面的构建。通常把这个步骤称为“配点”,常用的方法有概率配点法等。机器学习-可靠度方法中的配点来自工程案例数据库,因为机器学习方法本身就是基于大数据分析的方法,可靠度计算中的样本点数据主要为基本随机变量和目标响应值,对应的则是机器学习模型中的输入和输出数据,因此在本模型中,将 H 、 h 、 RQD 和 W 作为基本随机变量(x_1, x_2, x_3, x_4),将 Optuna-CBR 模型输出的 WI 预测值作为目标响应值 Y ,利用 matlab 语言进行最小二乘拟合。

输入 503 个训练集的数据进行最小二乘拟合,计算得到 35 个待定系数的解:

表 4.7 待定系数的解

Table 4.7 Solution of undetermined coefficients

b	value	b	value	b	value
$b(1)$	102.534	$b(16)$	2.508	$b(31)$	-1.078
$b(2)$	-12.707	$b(17)$	-10.779	$b(32)$	1.135
$b(3)$	47.501	$b(18)$	1.126	$b(33)$	-2.188
$b(4)$	-6.154	$b(19)$	9.484	$b(34)$	4.676
$b(5)$	8.292	$b(20)$	9.188	$b(35)$	-0.695
$b(6)$	-1.677	$b(21)$	-7.295		
$b(7)$	0.170	$b(22)$	-14.267		
$b(8)$	-0.244	$b(23)$	0.512		
$b(9)$	-1.175	$b(24)$	7.389		
$b(10)$	11.529	$b(25)$	-3.702		
$b(11)$	7.371	$b(26)$	-1.794		
$b(12)$	-24.108	$b(27)$	4.925		
$b(13)$	-10.086	$b(28)$	-12.543		
$b(14)$	-1.620	$b(29)$	-1.340		
$b(15)$	3.954	$b(30)$	-5.076		

接下来利用蒙特卡洛模拟进行可靠度计算,设置采样数为 10^6 次的抽样计算,在此步骤中用拉丁超立方抽样法代替了直接抽样法。直接抽样法的优点在于抽样简单,但不足在于对于小样本来说抽取的样本点可能不具有代表性,并且产生的样本点并非完全独立,而是具有一定的相关性,因此产生的随机数也被称为伪随机数。拉丁超立方抽样是一种基于分层抽样的方法,即使是在变量分布的尾部也能采集

有效数量的样本，避免样本局部聚集，并且能够消除抽取样本之间的相关性，使抽样结果更加独立有效。

针对隧道突涌水风险分级问题，现有的相关文献^[129]和规范《铁路隧道风险评估及管理暂行规定》通过评价直接灾害和次生灾害带来的综合损失来对突涌水风险等级进行评定，综合损失包括了人员伤亡、经济损失、工期延误等，以及结合突涌水发生概率进行四色分级(低度、中度、高度、极高)。除了上述通过灾害后果等方式进行分级，文献^[129]根据案例统计和相关规范提出了岩溶隧道突涌水量亚级分级，如表 4.8 所示。亚级分级的提出应对了部分区间涌水量跨度过大的问题，下面将通过可靠度分析确定本案例的涌水量分级概率。

表 4.8 隧道涌水量亚级分级^[86,132]
Table 4.8 Subclass classification of tunnel water inflow

级别	I	II			III		IV	V
		II ₁	II ₂	II ₃	III ₁	III ₂		
涌水量 (m ³ /h)	≥10000	7000~ 10000	4000~ 7000	1000~ 4000	550~1000	100~550	10~100	≤10

通过 10^6 次蒙特卡洛模拟，由构建出来的随机响应面计算出对应的涌水量大小，并构建不同涌水量级别对应的功能函数。通常地，可靠度的功能函数是以某一界限作为判断结构或模型是否失效的二分类问题，此时功能函数为：

$$Z_k = g(X_1, X_2, \dots, X_n) - k \quad (4.6)$$

式中 k 为结构或模型失效的临界值，例如在计算边坡的可靠度概率时，通常以安全系数等于 1 作为临界值 k ，此时的失效概率为：

$$p_f = p(Z_k < 0) \quad (4.7)$$

式中 p 为某个限定条件下的概率，对应的可靠概率为：

$$p_r = p(Z_k \geq 0) \quad (4.8)$$

参考文献[132]中围岩分级可靠度的功能函数建立，设 $f_x(x_1, x_2, \dots, x_n)$ 为基本随机变量 $X = (X_1, X_2, \dots, X_n)$ 的联合概率密度函数，累积分布函数 $F_x(x)$ ，则以涌水量 k 为界限的可靠概率为：

$$\begin{aligned} p_r &= \int_{Z_k \geq 0} dF_x(x) = \int_{Z_k \geq 0} f_x(x) dx \\ &= \iint_{Z_k \geq 0} \dots \int f_x(x_1, x_2, \dots, x_n) dx_1 dx_2 \dots dx_n \end{aligned} \quad (4.9)$$

同样的以涌水量 j 为界限的可靠概率为:

$$\begin{aligned} p_r &= \int_{Z_j \geq 0} dF_x(x) = \int_{Z_j \geq 0} f_x(x) dx \\ &= \iint_{Z_j \geq 0} \dots \int f_x(x_1, x_2, \dots, x_n) dx_1 dx_2 \dots dx_n \end{aligned} \quad (4.10)$$

因此, 当涌水量处于 $k \sim j$ 之间时, 其可靠概率为:

$$P_{k \sim j} = P_k - P_j = P(Z_k \geq 0) - P(Z_j \geq 0)$$

以涌水量级别 IV 级为例, 基本随机变量为 (H, h, RQD, W) , $f(H, h, RQD, W)$ 为联合概率密度函数, 当涌水量级别为 IV 级, $WI \in (10, 100)$, 因此可以构建功能函数为:

$$\left. \begin{aligned} Z_{IV}^L &= g(H, h, RQD, W) - 10 \geq 0 \\ Z_{IV}^R &= g(H, h, RQD, W) - 100 < 0 \end{aligned} \right\} \quad (4.11)$$

根据功能函数可得:

$$\begin{aligned} P_r^{IV^L} &= P(Z_{IV}^L \geq 0) = \int_{Z_{IV}^L \geq 0} f(x) dcx = \\ &= \iint_{Z_{IV}^L \geq 0} \dots \int f(H, h, RQD, W) dH dh \dots dW \end{aligned} \quad (4.12)$$

$$\begin{aligned} P_r^{IV^R} &= P(Z_{IV}^R \geq 0) = \int_{Z_{IV}^R \geq 0} f(x) dcx = \\ &= \iint_{Z_{IV}^R \geq 0} \dots \int f(H, h, RQD, W) dH dh \dots dW \end{aligned} \quad (4.13)$$

式中 IV^L 为涌水量级别为 IV 级时的下限 $10 \text{ m}^3/\text{h}$, IV^R 为涌水量级别为 IV 级时的上限 $100 \text{ m}^3/\text{h}$ 。由此可得涌水量级别为 IV 级时的可靠概率为:

$$P_r^{IV} = P_r^{IV^L} - P_r^{IV^R} = P(Z_{IV}^L \geq 0) - P(Z_{IV}^R \geq 0) \quad (4.14)$$

同理可得涌水量级别隶属于其他等级的可靠概率。

构建好各涌水量级别的功能函数之后, 就可以对 10^6 次蒙特卡洛模拟结果进行可靠度概率分级, 其结果如表 4.9 所示:

表 4.9 隧道涌水量分级概率

Table 4.9 Classification probability of tunnel water inflow

概率	III ₁	III ₂	IV	V
P_r	0.0012	0.5079	0.4166	0.0743

统计分析得到基于蒙特卡洛模拟的可靠度计算结果中，只有极少点分布于表 4.9 中所示的 4 个级别以外，其可靠概率趋近于 0，因此可以忽略不计。可以看出基于可靠度概率分级的涌水量级别有 50.79%的概率隶属于 III₂ 级，有 41.66%的概率隶属于 IV 级，而隶属于 V 级的概率只有 7.43%，隶属于 III₁ 的概率仅有 0.12%。

进一步对可靠度概率分级下的涌水量预测值做直方图分布以及累积分布函数曲线，如图 4.23 所示。




图 4.23 隧道涌水量分布和累积分布函数曲线

Fig.4. 23 Tunnel water inflow distribution and cumulative distribution function curve

从直方图和累积分布函数曲线可以看到， 10^6 个抽样点的预测涌水量分布区间为[-1500,2000]，然而在区间两端的点极少，几乎可以忽略不计，大部分的点集中在中间的某一个区段，为了确定不同置信水平下的涌水量预测区间，本文取 90%、95%和 99%作为置信水平进行计算，结果如表 4.10 和表 4.11 所示。

表 4.10 不同置信水平下的涌水量预测区间

Table 4. 10 Prediction interval of water inflow under different confidence levels

置信水平	z 值	WI 置信区间 下限(m³/h)	WI 置信区间 上限(m³/h)
90%	1.645	-28.3	242.8
95%	1.96	-54.2	268.8
99%	2.576	-105.0	319.5

表 4.11 涌水量可靠度计算结果特征统计

Table 4.11 Characteristic statistics of water inflow reliability calculation results

	均值	标准差	标准值
WI(m ³ /h)	107.3	82.4	268.8

表 4.10 显示了不同置信水平下的预测涌水量范围，可以看出随着置信水平的增大，WI 的置信区间也随之增大，在 90%、95%和 99%的置信水平下，涌水量的置信区间上限分别为 242.8m³/h、268.8m³/h 和 319.5m³/h。涌水量置信区间的下限在三个不同置信水平下都为负值，而负值仅有数学意义，并无实际工程意义，因此对于实际工程来说，涌水量的下限可统一取为 0。表 4.11 中标准值的定义借鉴于规范《建筑结构荷载规范(GB50009-2012)》，荷载标准设计值是指结构在其使用期间正常情况下可能出现的最大荷载，按随机变量 95%保证率的统计特征值确定。因此涌水量标准值的意义为在 95%保证率下可能出现的最大涌水量，计算得到本案例中隧道预测涌水量的标准值为 268.8 m³/h，即在 95%的保证率下可能出现的最大涌水量为 268.8 m³/h。

4.5 本章小结

本章通过隧道突涌水案例的收集及涌水量有效参数的现状研究，将涌水量和 4 个预测指标用于搭建隧道涌水案例数据库，建立 Optuna-CBR 模型对隧道涌水量进行预测，并结合可靠度理论计算隧道量分级概率和置信区间，得到隧道涌水量标准值，主要得到以下研究成果：

1.对预测指标和涌水量进行统计特征分析，结果表明 WI 主要集中于 0~150m³/h 的范围内，与 H、h、RQD 以及 W 的 MIC 值分别为 0.16、0.23、0.14 和 0.31。说明 WI 与 W 具有较高程度的非线性相关性，而与 H 和 RQD 值的非线性相关性较为一般。利用 SMOGN 对样本不平衡的现象采取数据增强处理，以及异常值检测及剔除，经过数据清洗后的隧道涌水量样本点缩减为 503 个，使用四分位距法(IQR)生成箱线图进行检测，无异常数据。

2.建立了 Optuna-CBR 隧道涌水量预测模型，并通过多个评价指标进行验证，和未优化的 CBR 模型以及 LR 模型进行对比。结果显示 Optuna-CBR 预测模型训练集上的平均绝对误差(MAE)为 5.45，平均绝对百分比误差(MAPE)为 5.43%，均方根误差(RMSE)为 5.45，决定系数 R² 为 0.98，在测试集上的 MAE 为 8.91，MAPE 为 8.58%，RMSE 为 11.24，R² 为 0.95，对比未优化的 CBR 模型和 LR 模型有较大

提升。结果表明 Optuna-CBR 隧道涌水量预测模型的模型质量优秀,有较强的预测能力以及很好的泛化性能。

3.使用 CatBoost-可靠度联合预测方法进行隧道涌水量级别可靠度计算,根据分级标准得到隧道涌水量隶属某一级别的概率,并计算不同置信水平下的涌水量预测区间。计算结果表明,基于可靠度概率分级的隧道涌水量级别有 50.79%的概率隶属于 III₂ 级,有 41.66%的概率隶属于 IV 级,而隶属于 V 级的概率只有 7.43%,隶属于 III₁ 的概率仅有 0.12%。同时还计算了 90%、95%及 99%置信水平下的涌水量预测区间,分别为[0,242.8]、[0,268.8]和[0,319.5] m³/h,并确立了本案例中隧道预测涌水量的标准值为 268.8 m³/h。

5 结论与展望

5.1 主要结论

本文通过收集隧道灾害案例，分别建立了隧址区地面塌陷地理信息数据库和隧道涌水量案例数据库，并对影响因子或预测指标进行统计特征分析。以机器学习作为基础研究方法，分别结合因子及参数优化方法和可靠度分析方法，应用于工程实际中，并采用多种评价指标对预测模型进行检验。通过研究，本文得到以下主要结论：

①对隧址区地面塌陷空间分异性解释程度最大的 7 个影响因子为地层岩性、地层含水性、坡位、微地貌、坡度、高程变异系数、地形切割深度，解释程度最小的 3 个影响因子为坡向、平面曲率、剖面曲率。距隧道距离 1km 以内发育了大量地面塌陷，在 1km 以外，塌陷频率比随距离的增加而递减，而在距隧道距离 500m 以内，地面塌陷的发育受其他因素主导。结合频率比法(FR)分析地面塌陷分布特征，结果表明最有利于塌陷发育的因素有：坡位为平地、地层岩性为嘉陵江组地层和大冶组地层、地层含水性为强富水、坡度 $<8.1^{\circ}$ 、地表切割深度 $<1.48\text{m}$ 、高程变异系数 <0.0026 以及微地貌形态为平原。

②基于因子及参数耦合优化的 RFC 模型预测效果较好，相比于未优化的模型，预测精度、预测准确率以及 AUC 值分别提高了 26.7%、17.8%和 16.3%。表明因子及参数耦合优化方法能够给机器学习模型的预测能力和拟合性能带来较大程度的提升。

③将工程案例中的隧址区地面塌陷易发性等级划分为极低易发、低易发、中易发和高易发，统计结果表明有 79.15%的塌陷处于高易发性等级区域内，塌陷频比值(FR)高达 15.03，意味着在高易发区的塌陷密度更大，且随着易发性等级由高到低，FR 逐级递减，与地面塌陷实际分布相符。4 个易发性等级携带的空间信息量相差不大，整体空间熵为 1.126，表明地面塌陷易发性分区结果具有较好的空间规律性及稳定性。

④通过最大信息系数(MIC)来判断隧道涌水量与隧道埋深、地下水位、RQD 及产水特性的非线性相关程度，其中产水特性与隧道涌水量的非线性相关性程度最大，MIC 值为 0.31；RQD 与隧道涌水量的非线性相关程度最小，MIC 值为 0.14。使用数据清洗后的样本训练集建立 Optuna-CBR 隧道涌水量预测模型，相比于未优化的 CBR 模型和 LR 模型，预测值与实际值更接近，整体的预测误差更小，模型的泛化性能更好。

⑤对隧道涌水量预测结果进行可靠度分析，依据计算结果得到本案例中隧道

涌水量预测值处于 III₁、III₂、IV、V 这 4 个级别的概率分别为 0.12%、50.79%、41.66%和 7.43%。在 90%、95%及 99%的置信水平下,隧道涌水量预测区间分别为 [0,242.8]、[0,268.8]和[0,319.5] m³/h。本案例中隧道涌水量预测的标准值为 268.8 m³/h。表明 CatBoost-可靠度联合预测方法能够基于变量的整体分布,对预测结果的不确定性展开进一步分析。相比于确定性预测方法,该方法更能反映涌水量预测结果的分布状态,以分级概率和预测区间的形式定量化描述了预测结果的不确定性,更符合实际,使预测结果具有更好的参考价值。

5.2 不足与展望

本文以隧址区地面塌陷灾害和隧道突涌水灾害作为研究对象,以机器学习作为基本方法,提出了因子及参数耦合优化的 RFC 预测方法和 CatBoost-可靠度联合预测方法,分别应用于隧址区地面塌陷易发性预测和隧道涌水量预测,并取得了较好的预测效果。但限于个人的研究水平和时间,本文还存在以下不足,有待进一步展开研究:

1.机器学习预测模型最重要的是预测水平的优劣,参与模型训练的样本数据的数量越丰富,类型越全面,模型的优化就有更多的可变性,最终的预测结果就有更多且更好的可能性。本文中隧址区地面塌陷灾害的样本数和隧道突涌水预测指标的选取不够丰富和完整,仍有扩充的空间,以此提高预测模型的鲁棒性和泛化性能,从而在提升模型预测能力的同时增加适应性,可以应用于更多不同工程环境下的隧道灾害预测。

2.本文中机器学习-可靠度联合预测方法只用于隧道涌水量预测,是由于可靠度分析方法需要获取随机变量的分布状态,数值型变量的分布状态可以用联合概率密度来代表,并且拉丁超立方抽样也只适用于数值型变量。然而实际工程问题(如地面塌陷易发性)中存在部分非数值型变量,例如地层岩性这样的类别型变量,能否将其引入可靠度分析取决于能否合理地将类别型变量数值化,因此,解决类别型变量在可靠度分析中的处理会有利于机器学习-可靠度联合预测方法的更广泛应用。

参考文献

- [1] 洪开荣.我国隧道及地下工程近两年的发展与展望[J].隧道建设,2017,37(02):123-134.
- [2] 洪开荣,冯欢欢.中国公路隧道近10年的发展趋势与思考[J].中国公路学报,2020,33(12):62-76.
- [3] 田四明,王伟,杨昌宇,等.中国铁路隧道40年发展与展望[J].隧道建设(中英文),2021,41(11):1903-1930.
- [4] 李术才,许振浩,黄鑫,等.隧道突水突泥致灾构造分类、地质判识、孕灾模式与典型案例分折[J].岩石力学与工程学报,2018,37(05):1041-1069.
- [5] 李术才,王康,李利平,等.岩溶隧道突水灾害形成机理及发展趋势[J].力学学报,2017,49(1):22-30.
- [6] 殷颖,田军,张永杰.岩溶隧道灾害案例统计分析研究[J].公路工程,2018,43(4):210-214, 273.
- [7] 曹聪,李庆华.中梁山地区(长江——嘉陵江之间)地面塌陷调查评价报告[R].重庆:重庆市地质矿产勘查开发局南江水文地质工程地质队, 2018.
- [8] 康彦仁.岩溶塌陷的形成机制[J].广西地质,1989(02):83-90.
- [9] 王滨,贺可强.岩溶塌陷临界土洞的极限平衡高度公式[J].岩土力学,2006(03):458-462.
- [10] 贾龙,蒙彦,管振德.岩溶土洞演化及其数值模拟分析[J].中国岩溶,2014,33(03):294-298.
- [11] 吴庆华,张伟,刘煜,等.基于物理模型试验的岩溶塌陷定量研究[J].长江科学院院报,2018,35(3):52-58.
- [12] 张海坦,李庆华,邓书金.歌乐山岩溶地面塌陷发育特征[J].中国岩溶,2015(1):58-63.
- [13] 高培德,王林峰.覆盖型岩溶塌陷的塌陷机制分析[J].中国岩溶,2017,36(6):770-776.
- [14] 薛明明,陈学军,宋宇,等.基于FLAC3D不同降雨速率下土洞致塌规律研究[J].中国岩溶,2022,41(6):905-914.
- [15] Zhao Y, Shi Y, Wu F, et al. Characterization of the sinkhole failure mechanism induced by concealed cave: A case study[J]. ENGINEERING FAILURE ANALYSIS, 2021, 119: 1-8.
- [16] Aihua W, Duo L, Yahong Z, et al. A novel combination approach for karst collapse susceptibility assessment using the analytic hierarchy process, catastrophe, and entropy model[J]. NATURAL HAZARDS, 2020, 105: 1-26.
- [17] 吴远斌,殷仁朝,雷明堂,等.重庆中梁山地区隧道工程影响下岩溶塌陷形成演化模式及防治对策[J].中国岩溶,2021,40(2):246-252.
- [18] 强壮.重庆市某岩溶山区地面塌陷机理及易发性评价研究[D].重庆大学,2021.
- [19] 陈学军,陈李洁,宋宇,等.熵权-正态云模型岩溶塌陷预测分析[J].工程地质学报,2019,27(6):1389-1394.

- [20] Yonyyao W, Shulin S, Jingjun H, et al. A study on karst development characteristics and key control factors of collapse in Xuzhou, eastern China[J]. CARBONATES AND EVAPORITES, 2018, 33(3): 359-373.
- [21] Mariano D N, Palmira M, Diego D M, et al. Landslide Susceptibility Assessment of Wildfire Burnt Areas through Earth-Observation Techniques and a Machine Learning-Based Approach[J]. Remote Sensing, 2020, 12(15): 1-28.
- [22] Zhou X, Wen H, Zhang Y, et al. Landslide susceptibility mapping using hybrid random forest with GeoDetector and RFE for factor optimization[J]. Geoscience Frontiers, 2021, 12(5): 1-19.
- [23] P R, M R, B M. A review of statistically-based landslide susceptibility models[J]. EARTH-SCIENCE REVIEWS, 2018, 180: 60-91.
- [24] Calista M, Menna V, Mancinelli V, et al. Rockfall and Debris Flow Hazard Assessment in the SW Escarpment of Montagna del Morrone Ridge (Abruzzo, Central Italy)[J]. Water, 2020, 12(4): 1206-1206.
- [25] Taheri K, Missimer T M, Mohseni H, et al. Enhancing spatial prediction of sinkhole susceptibility by mixed waters geochemistry evaluation: application of ROC and GIS[J]. Environmental Earth Sciences, 2021, 80(14): 1-28.
- [26] 孙德亮, 马祥龙, 唐小娅, 等. 基于不同因子分级的滑坡易发性区划对比——以万州区为例[J]. 重庆师范大学学报(自然科学版), 2021, 38(05): 43-54.
- [27] 薛蒙蒙. 山区道路沿线滑坡易发性随机森林和支持向量机评价模型[D]. 重庆大学, 2020.
- [28] Titti G, Borgatti L, Zou Q, et al. Landslide susceptibility in the Belt and Road Countries: continental step of a multi-scale approach[J]. Environmental Earth Sciences, 2021, 80(18): 1-18.
- [29] Wu Y, Jiang X, Guan Z, et al. AHP-based evaluation of the karst collapse susceptibility in Tailai Basin, Shandong Province, China[J]. Environmental Earth Sciences, 2018, 77(12): 1-14.
- [30] Yao C, Yuan F, Meng F, et al. Study on risk assessment method of Karst collapse—Taking the Karst collapse in Linyi urban areas as an example[J]. IOP Conference Series: Earth and Environmental Science, 2019, 310(5): 1-10.
- [31] Hu J, Motagh M, Wang J, et al. Karst Collapse Risk Zonation and Evaluation in Wuhan, China Based on Analytic Hierarchy Process, Logistic Regression, and InSAR Angular Distortion Approaches[J]. Remote Sensing, 2021, 13(24): 5063-5063.
- [32] 白永学, 漆泰岳, 李有道, 等. 基于LSSVM对盾构施工诱发地面塌陷变形预测[J]. 岩石力学与工程学报, 2013, 32(S2): 3666-3674.

- [33] Hanghang D, Qiang W, Dekang Z, et al. Risk assessment of karst collapse using an integrated fuzzy analytic hierarchy process and grey relational analysis model[J]. *Geomechanics and Engineering*, 2019, 18(5): 515-525.
- [34] Zongwei D, Jia T, Xuhang L, et al. Influences of Groundwater Movement on Karst Collapse Based on GIS[J]. *IOP Conference Series: Earth and Environmental Science*, 2018, 170(2): 1-11.
- [35] Subedi P, Subedi K, Thapa B, et al. Sinkhole susceptibility mapping in Marion County, Florida: Evaluation and comparison between analytical hierarchy process and logistic regression based approaches[J]. *Scientific Reports*, 2019, 9(1): 1-18.
- [36] Alsanea D, Abdullah W. Sinkhole Susceptibility Hazard Mapping Using Analytical Hierarchy Process and GIS Tools for the State of Kuwait[J]. *ASCE-ASME Journal of Risk and Uncertainty in Engineering Systems, Part A: Civil Engineering*, 2021, 7(3): 1-12.
- [37] Yong J K, Boo H N, Ryan S, et al. Development of Sinkhole Susceptibility Map of East Central Florida[J]. *Natural Hazards Review*, 2020, 21(4): 1-15.
- [38] Sun D, Wen H, Wang D, et al. A random forest model of landslide susceptibility mapping based on hyperparameter optimization using Bayes algorithm[J]. *GEOMORPHOLOGY*, 2020, 362: 107201.
- [39] 谢静峰, 谭飞, 焦玉勇, 等. 基于因子分析的GA-ELM模型岩溶地面塌陷预测[J]. *工程地质学报*, 2021, 29(02): 536-544.
- [40] V. Vakhshoori, M. Zare. Landslide susceptibility mapping by comparing weight of evidence, fuzzy logic, and frequency ratio methods[J]. *Geomatics, Natural Hazards and Risk*, 2016, 7(5): 1731-1752.
- [41] Kamal T, Francisco G, Hassan M, et al. Sinkhole susceptibility mapping using the analytical hierarchy process (AHP) and magnitude - frequency relationships: A case study in Hamadan province, Iran[J]. *GEOMORPHOLOGY*, 2015, 234: 64-79.
- [42] Kamal T, Himan S, Kamran C, et al. Sinkhole susceptibility mapping: A comparison between Bayes - based machine learning algorithms[J]. *LAND DEGRADATION & DEVELOPMENT*, 2019, 30(7): 730-745.
- [43] Lucas Q S, Paulo G, Luiz R B L, et al. Evaluation of susceptibility for terrain collapse and subsidence in karst areas, municipality of Iraquara, Chapada Diamantina (BA), Brazil[J]. *Environmental Earth Sciences*, 2018, 77(16): 1-11.
- [44] Bin Z, Lianze Z, Honglei Y, et al. Subsidence prediction and susceptibility zonation for collapse above goaf with thick alluvial cover: a case study of the Yongcheng coalfield, Henan Province, China[J]. *Bulletin of Engineering Geology and the Environment*, 2016, 75(3): 1117-1132.

- [45] M. A H M R,A. N O,M. A M Z, et al.SINKHOLE SUSCEPTIBILITY HAZARD ZONES USING GIS AND ANALYTICAL HIERARCHICAL PROCESS (AHP): A CASE STUDY OF KUALA LUMPUR AND AMPANG JAYA[J].ISPRS - International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences,2017,XLII-4/W5:145-151.
- [46] Kim Y J,Nam B H,Jung Y, et al.Probabilistic spatial susceptibility modeling of carbonate karst sinkhole[J].ENGINEERING GEOLOGY,2022,306:1-16.
- [47] Li W,Fan X,Huang F, et al.Uncertainties Analysis of Collapse Susceptibility Prediction Based on Remote Sensing and GIS: Influences of Different Data-Based Models and Connections between Collapses and Environmental Factors[J].Remote Sensing,2020,12(24):4134-4134.
- [48] Li Y,Sheng Y,Chai B, et al.Collapse susceptibility assessment using a support vector machine compared with back-propagation and radial basis function neural networks[J].Geomatics, Natural Hazards and Risk,2020,11(1):510-534.
- [49] Mansour Z,Yanick T,Aissa S, et al.The susceptibility analysis of landslide using bivariate and multivariate modeling techniques in western Algeria: case of Fergoug watershed (Beni-Chougrane Mountains)[J].Arabian Journal of Geosciences,2021,14(19):1-19.
- [50] Sumit D.Geographic information system and AHP-based flood hazard zonation of Vaitarna basin, Maharashtra, India[J].Arabian Journal of Geosciences,2018,11(19):1-13.
- [51] Zhou X,Wen H,Li Z, et al.An interpretable model for the susceptibility of rainfall-induced shallow landslides based on SHAP and XGBoost[J].Geocarto International,2022,37(26):3419-13450.
- [52] 林传年,李利平,韩行瑞.复杂岩溶地区隧道涌水预测方法研究[J].岩石力学与工程学报,2008(07):1469-1476.
- [53] 李鹏飞,张顶立,周焯.隧道涌水量的预测方法及影响因素研究[J].北京交通大学学报,2010,34(4):11-15.
- [54] 李铮,何川,杨赛舟,等.不考虑开挖扰动影响的隧道涌水量预测模型试验研究[J].岩石力学与工程学报,2016,35(12):2499-2506.
- [55] 刘常昊,郑万波,吴燕清,等.玉磨铁路景寨隧道富水段涌水量预测方法[J].安全与环境工程,2022,29(4):66-73.
- [56] 王璐.基于遗传算法和支持向量机的西南岩溶越岭隧道涌水量预测[D].成都理工大学,2019.
- [57] 傅鹤林,安鹏涛,伍毅敏,等.考虑排水体系时隧道突涌水分析[J].铁道科学与工程学报,2022,19(11):3335-3342.
- [58] Xiaoguang J,Yayong L,Yunju L, et al.Prediction of city tunnel water inflow and its influence on overlain lakes in karst valley[J].Environmental Earth Sciences,2016,75(16):1-15.

- [59] 魏兴萍,张虹,苏程烜.重庆南山隧道工程涌水隐患研究[J].中国岩溶,2016,35(1):74-80.
- [60] 王飞,刘桂卫,陈则连,等.基于GIS及AHP-熵权法的长大深埋隧道富水评价[J].铁道工程学报,2021,38(10):66-72.
- [61] K. H H,B. N.Significance of Geological Parameters for Predicting Water Inflow in Hard Rock Tunnels[J].ROCK MECHANICS AND ROCK ENGINEERING,2014,47(3):853-868.
- [62] Wang Y,Li J,Wang C, et al.The Deviation of Semi-Theoretical and Semi-Empirical Water Inflow Prediction Formula Based on Sphere Coordinate Conversion and a Grouting Excavation Evaluation Method[J].Applied Sciences,2021,11(24):11956-11956.
- [63] 周玲,杨广庆,杨青潮.基于优化组合模型及重标极差法的岩溶隧道涌水量预测研究[J].武汉大学学报(工学版),2020,53(10):875-882.
- [64] 肖建于,童敏明,姜春露.基于模糊证据理论的煤层底板突水量预测[J].煤炭学报,2012(S1):131-137.
- [65] 李建林,高培强,王心义,等.基于混沌-广义回归神经网络的矿井涌水量预测[J].煤炭科学技术,2022,50(4):149-155.
- [66] Ma D,Duan H,Li W, et al.Prediction of water inflow from fault by particle swarm optimization-based modified grey models[J].Environmental science and pollution research international,2020,27(33):42051-42063.
- [67] Yong F,Lingqiang C,Liubing Z, et al.The risk assessment and prediction of water inflow into tunnels of Guangzhou Metro Line 21[J].IOP Conference Series: Earth and Environmental Science,2019,242(6):1-9.
- [68] Wang S,Li L,Cheng S, et al.Risk assessment of water inrush in tunnels based on attribute interval recognition theory[J].Journal of Central South University,2020,27(2):517-530.
- [69] Xiaobing K,Sheng L,Mo X, et al.Dynamic estimating the karst tunnel water inflow based on monitoring data during excavation[J].ACTA CARSOLOGICA,2019,48(1):1-11.
- [70] 魏晓悦,靳春玲,贡力,等.基于PCA-改进RBF神经网络模型的铁路隧道突水风险评价[J].铁道科学与工程学报,2021,18(3):794-802.
- [71] 毛正君,杨绍战,朱艳艳,等.基于F-AHP法的隧道突涌水风险等级评价[J].铁道科学与工程学报,2017,14(6):1332-1339.
- [72] 胡迪勇.基于隐伏溶腔空间特征的隧道围岩稳定性及涌突水灾害防治研究[D].成都理工大学,2021.
- [73] 欧光照.基于机器学习的隧道施工期工程灾害风险评估研究[D].中国地质大学,2022.
- [74] 王连国,宋扬.煤层底板突水组合人工神经网络预测[J].岩土工程学报,2001,23(4):502-504.

- [75] Golian M,Teshnizi E S,Nakhaei M.Prediction of water inflow to mechanized tunnels during tunnel-boring-machine advance using numerical simulation[J].HYDROGEOLOGY JOURNAL,2018,26(8):2827-2851.
- [76] Han-Song X,Chong J,Jia-Li H, et al.Analytical Solution for the Steady-State Karst Water Inflow into a Tunnel[J].GEOFLUIDS,2019,2019:1-9.
- [77] 仇文岗,唐理斌,陈福勇,等.基于4种超参数优化算法及随机森林模型预测TBM掘进速度[J].应用基础与工程科学学报,2021,29(5):1186-1200.
- [78] Fu H,An P,Chen L, et al.Analysis of Tunnel Water Inrush Considering the Influence of Surrounding Rock Permeability Coefficient by Excavation Disturbance and Ground Stress[J].Applied Sciences,2021,11(8):3645-3645.
- [79] Shu-Cai L,Peng H,Li-Ping L, et al.Gaussian process model of water inflow prediction in tunnel construction and its engineering applications[J].Tunnelling and Underground Space Technology incorporating Trenchless Technology Research,2017,69:155-161.
- [80] Nguyen N,Tong K T,Lee S, et al.Prediction compressive strength of cement-based mortar containing metakaolin using explainable Categorical Gradient Boosting model[J].ENGINEERING STRUCTURES,2022,269:114768.
- [81] Grbčić L,Družeta S,Mauša G, et al.Coastal water quality prediction based on machine learning with feature interpretation and spatio-temporal analysis[J].ENVIRONMENTAL MODELLING & SOFTWARE,2022,155:105458.
- [82] Kaiser M,Günnemann S,Disse M.Regional-scale prediction of pluvial and flash flood susceptible areas using tree-based classifiers[J].JOURNAL OF HYDROLOGY,2022,612(PA):1-23.
- [83] Lee S,Vo T P,Thai H, et al.Strength prediction of concrete-filled steel tubular columns using Categorical Gradient Boosting algorithm[J].ENGINEERING STRUCTURES,2021,238:112109.
- [84] 孔瑞瑶,谢涛,马明,等.CatBoost模型在水深反演中的应用[J].测绘通报,2022(7):33-37.
- [85] 陈点点,陈芸芝,冯险峰,等.基于超参数优化CatBoost算法的河流悬浮物浓度遥感反演[J].地球信息科学学报,2022,24(4):780-791.
- [86] 王遇国.岩溶隧道突水灾害与防治研究[D].中国铁道科学研究院,2010.
- [87] 鲁海峰,姚多喜.采动底板突水危险性的结构体系可靠度分析[J].中国矿业大学学报,2014,43(06):995-1002.
- [88] Karl Y,Chrysothemis P,Spyridon K.Spatial variability of karst and effect on tunnel lining and water inflow. A probabilistic approach[J].Tunnelling and Underground Space Technology incorporating Trenchless Technology Research,2020,97(C):103248.

- [89] Dall A V, Neven A, de Rooij R, et al. Probabilistic estimation of tunnel inflow from a karstic conduit network[J]. ENGINEERING GEOLOGY, 2023, 312: 1-14.
- [90] Yiqing H, Xiaoli R, Linjian M, et al. Uncertainty Analysis on Risk Assessment of Water Inrush in Karst Tunnels[J]. MATHEMATICAL PROBLEMS IN ENGINEERING, 2016, 2016: 1-11.
- [91] Shi S, Guo W, Li S, et al. Prediction of tunnel water inflow based on stochastic deterministic three-dimensional fracture network[J]. Tunnelling and Underground Space Technology incorporating Trenchless Technology Research, 2023, 135: 1-16.
- [92] Arthur L S. Some Studies in Machine Learning Using the Game of Checkers[J]. IBM JOURNAL OF RESEARCH AND DEVELOPMENT, 1959, 3(3): 206-226.
- [93] 常志璐, 黄发明, 蒋水华, 等. 基于多尺度分割方法的斜坡单元划分及滑坡易发性预测[J]. 工程科学与技术, 2023, 55(01): 184-195.
- [94] 窦杰, 向子林, 许强, 等. 机器学习在滑坡智能防灾减灾中的应用与发展趋势[J]. 地球科学, 2022: 1-18.
- [95] 侯儒宁, 李志, 陈宁生, 等. 基于流域单元和堆叠集成模型的天山地区泥石流易发性评估建模[J]. 地球科学, 2022: 1-25.
- [96] 周聂, 侯精明, 陈光照, 等. 基于机器学习的山洪灾害快速预报方法[J]. 水资源保护, 2022, 38(02): 32-40.
- [97] 陈昌富, 李伟, 张嘉睿, 等. 山区公路边坡工程智能分析与设计研究进展[J]. 湖南大学学报(自然科学版), 2022, 49(07): 15-31.
- [98] 李志轩. 基于物质点法的边坡稳定可靠性和大变形分析[D]. 大连理工大学, 2022.
- [99] 郑帅, 姜谔男, 张峰瑞, 等. 基于机器学习与可靠度算法的围岩动态分级方法及其工程应用[J]. 岩土力学, 2019(s1): 308-318.
- [100] Ma L, Fu T, Blaschke T, et al. Evaluation of Feature Selection Methods for Object-Based Land Cover Mapping of Unmanned Aerial Vehicle Imagery Using Random Forest and Support Vector Machine Classifiers[J]. ISPRS International Journal of Geo-Information, 2017, 6(2): 51.
- [101] 刘永垚, 第宝锋, 詹宇, 等. 基于随机森林模型的泥石流易发性评价——以汶川地震重灾区为例[J]. 山地学报, 2018, 36(05): 765-773.
- [102] 刘坚, 李树林, 陈涛. 基于优化随机森林模型的滑坡易发性评价[J]. 武汉大学学报(信息科学版), 2018, 43(7): 1085-1091.
- [103] 张书豪, 吴光. 随机森林与GIS的泥石流易发性及可靠性[J]. 地球科学, 2019, 44(09): 3115-3134.
- [104] Leo B. Random Forests[J]. MACHINE LEARNING, 2001, 45(1): 5-32.
- [105] 周志华. 机器学习[M]. 北京: 清华大学出版社, 2015: 171.
- [106] Leo B. Bagging Predictors[J]. MACHINE LEARNING, 1996, 24(2): 123-140.

- [107]Robert E S.The Strength of Weak Learnability[J].MACHINE LEARNING,1990,5(2):197-227.
- [108]Seymour G.Statistical Theory[J].TECHNOMETRICS,2012,5(3):411-411.
- [109]高峰,黄兴,刘泉声,等.基于人工神经网络多模型迁移学习的隧(巷)道机械化掘进装备控制参数自主决策方法[J].岩石力学与工程学报,2022:1-16.
- [110]Saeid NIKBAKHT,Cosmin ANITESCU,Timon RABCZUK.利用遗传算法优化神经网络超参数 (英文) [J].Journal of Zhejiang University-Science A(Applied Physics & Engineering),2021,22(06):407-426.
- [111]吴佳,陈森朋,陈修云,等.基于强化学习的模型选择和超参数优化[J].电子科技大学学报,2020,49(02):255-261.
- [112]张明.结构可靠度分析:方法与程序[M].北京:科学出版社,2009:7.
- [113]M. D M,R. J B,W. J C.A Comparison of Three Methods for Selecting Values of Input Variables in the Analysis of Output From a Computer Code[J].TECHNOMETRICS,2012,42(1):55-61.
- [114]康彦仁.论岩溶塌陷形成的致塌模式[J].水文地质工程地质,1992(04):32-34.
- [115]康彦仁.试论岩溶地面塌陷的类型划分[J].中国岩溶,1984(02):151-160.
- [116]徐卫国,赵桂荣.论岩溶塌陷形成机理[J].煤炭学报,1986(02):1-11.
- [117]周正,李大华,廖云平,等.重庆中梁山岩溶地面塌陷特征及形成机理[J].中国岩溶,2022,41(1):67-78.
- [118]赵博超,朱蓓,王弘元,等.浅谈岩溶塌陷的影响因素与模型研究[J].中国岩溶,2015,34(05):515-521.
- [119]陈明晓.岩溶覆盖层塌陷的原因分析及其半定量预测[J].岩石力学与工程学报,2002(02):285-289.
- [120]王慧.山区地质灾害易发性区划与降雨诱发时空联合预报研究[D].重庆大学,2016.
- [121]王劲峰,徐成东.地理探测器:原理与展望[J].地理学报,2017,72(01):116-134.
- [122]Jasper S,Hugo L,Ryan P A.Practical Bayesian Optimization of Machine Learning Algorithms[J].CoRR,2012,abs/1206.2944.
- [123]Rasmussen C E,Williams C K I.Gaussian Processes for Machine Learning[M].The MIT Press,2005:3.
- [124]Eric B,Vlad M C,Nando D F.A Tutorial on Bayesian Optimization of Expensive Cost Functions, with Application to Active User Modeling and Hierarchical Reinforcement Learning[J].CoRR,2010,abs/1012.2599.
- [125]王桂林,强壮,曹聪,等.基于地理探测器与层次分析法的岩溶地面塌陷易发性评价——以重庆中梁山地区为例[J].中国岩溶,2022,41(01):79-87.

- [126] 杨卓, 马超. 基于BP神经网络方法的岩溶隧道突涌水风险预测[J]. 隧道建设, 2016, 36(11): 1337-1342.
- [127] Mahmoodzadeh A, Mohammadi M, M Gharrib Noori K, et al. Presenting the best prediction model of water inflow into drill and blast tunnels among several machine learning techniques[J]. AUTOMATION IN CONSTRUCTION, 2021, 127: 103719.
- [128] David N R, Yakir A R, Hilary K F, et al. Detecting Novel Associations in Large Data Sets[J]. SCIENCE, 2011, 334(6062): 1518-1524.
- [129] 李朝阳. 基于数据学习的岩溶隧道突涌水风险评估及预警研究[D]. 中国矿业大学; 中国矿业大学(江苏), 2020.
- [130] Branco P, Torgo L I, Ribeiro R P. SMOGN: a Pre-processing Approach for Imbalanced Regression[J]. Proceedings of Machine Learning Research, 2017, 74: 36-50.
- [131] 刘林. 基于随机响应面法的边坡可靠性研究——以会理县下湾子滑坡为例[D]. 成都理工大学, 2018.
- [132] 李术才, 贺鹏, 李利平, 等. 隧道岩质围岩亚级分级可靠度分析方法及其工程应用[J]. 岩土力学, 2018, 39(3): 967-976.

C.学位论文数据集

关键词		密级		中图分类号	
机器学习；耦合优化方法；易发性预测；可靠度；涌水量预测		公开		TU	
学位授予单位名称	学位授予单位代码	学位类别		学位级别	
重庆大学	10611	专业学位		硕士	
论文题名		并列题名		论文语种	
基于机器学习的隧址区地面塌陷易发性与隧道涌水量预测方法及应用研究		无		中文	
作者姓名	郝晋渝		学号	202016131193t	
培养单位名称			培养单位代码		
重庆大学			10611		
学科专业	研究方向		学制	学位授予年	
土木水利	岩土工程		三年	2023 年 6 月	
论文提交日期	2023. 06		论文总页数	145	
导师姓名	王桂林		职称	正高级工程师	
答辩委员会主席			郑光俊		
电子版论文提交格式					
文本（√） 图像（） 视频（） 音频（） 多媒体（） 其他（）					