

学号：2021110230

密级：



東華理工大學
EAST CHINA UNIVERSITY OF TECHNOLOGY

硕士学位论文 (学术学位)

基于机器学习的隧道涌水突泥风险预测研究

姓 名： 陈名煜
专 业 名 称： 计算机科学与技术
研 究 方 向： 计算机应用技术
指 导 教 师： 刘志锋（副教授）
培 养 学 院： 信息工程学院

二〇二四年六月



East China University of Technology

Dissertation for Master's Degree

Thesis: Research on Risk Prediction of Tunnel Water Gushing and Mud Bursting Based on Machine Learning

Candidate: Chen Mingyu

Specialization: Computer Science and Technology

Research Field: Computer Application Technology

Mentor: Liu Zhifeng (Associate Professor)

June, 2024

东华理工大学硕士学位论文中文摘要首页用纸

毕业论文题目：基于机器学习的隧道涌水突泥风险预测研究

计算机科学与技术 专业 2021 级硕士生姓名：陈名煜

指导教师（姓名、职称）：刘志锋、副教授

摘 要

涌水突泥作为隧道施工过程中发生频率较高的地质灾害之一，其风险因素复杂不确定，一旦发生不仅耽误施工进度，还会造成重大经济损失，甚至是人员伤亡。本文基于多种机器学习算法对隧道涌水突泥风险展开预测研究，主要研究内容和成果如下：

（1）构建涌水突泥灾害案例库及风险评估指标体系。运用调查法、统计分析法等收集了国内外 118 条隧道共 251 起涌水突泥灾害事故，统计致灾因素与后果，对涌水突泥致灾因素进行辨识和分类，构建了涌水突泥灾害案例库；从工程地质、水文地质及工程施工三类致灾因素中选取 12 个风险评估指标，建立涌水突泥风险评估指标体系；选取涌水量与突泥量、经济损失、人员伤亡和工期延误完善涌水突泥风险等级划分标准，综合判定各隧道涌水突泥事故的风险等级，完成案例库中涌水突泥风险预测的样本数据量化工作。

（2）机器学习算法的改进及涌水突泥风险等级预测。采用 SMOTE 算法实现隧道涌水突泥风险预测样本数均衡化，选取 RF、BPNN 和 SVM 算法构建模型对涌水突泥风险等级进行了预测。为进一步提高模型预测性能，采用 PSO 算法分别对 BPNN 和 SVM 模型进行优化，构建了基于 PSO-BP 和 PSO-SVM 算法的隧道涌水突泥风险预测模型，通过混淆矩阵、准确率、精准率、召回率和 F1 值进行模型性能评价，结果表明，在样本测试集上，RF、BPNN、SVM 模型的预测准确率分别为 86.11%、88.89%、87.5%，PSO-BPNN 和 PSO-SVM 模型的预测准确率分别为 94.44%和 97.22%，相较优化前分别提高了 5.55%和 9.72%。PSO-SVM 模型在样本数据集上的风险等级预测准确率最高。

（3）基于机器学习的隧道涌水量预测对比。由于涌水量对风险等级影响较大，因此本文还对涌水量进行预测研究，选取了隧道埋深、地下水位、岩石质量指数和岩层含水性作为隧道涌水量预测指标，整理得到 600 条隧道涌水量样本数据，采用 RBFNN、LSTM 和 ELM 算法对涌水量进行预测，选取 R^2 、RMSE、MAE 和 MBE 四个指标对各模型在样本数据集上的预测表现进行综合分析评价。在预测精度方面，RBFNN、LSTM 和 ELM 模型在测试样本上的 RMSE 值分别为 12.37、11.37 和 7.45，MAE 值分别为 8.23、6.90 和 5.86，三个模型均有较好的预测精度，其中 ELM 模型的预测误差最小。

论文将机器学习中发展较为成熟的相关算法应用于隧道涌水突泥风险预测研究，

设计了 PSO-BP 和 PSO-SVM 算法提高涌水突泥风险等级预测的准确性，同时对影响风险预测的关键因素涌水量进行了预测对比，验证了相关模型的有效性和可行性，对涌水突泥灾害的预防和应对措施具有一定的指导意义。

关键词：隧道，涌水突泥，机器学习，风险等级预测，涌水量预测

东华理工大学硕士学位论文英文摘要首页用纸

THESIS: Research on the Risk Prediction of Tunnel Water Gushing
and Mud Bursting Based on Machine Learning

SPECIALIZATION: Computer Science and Technology

POSTGRADUATE: Chen Mingyu

MENTOR: Liu Zhifeng (Associate Professor)

Abstract

As one of the geological disasters with high frequency in the process of tunnel construction, the risk factors of water gushing and mud bursting are complex and uncertain. Once it occurs, it will not only delay the construction progress, but also cause significant economic losses and even casualties. In this paper, based on a variety of machine learning algorithms to predict the risk of water gushing and mud bursting in tunnels, the main research contents and results are as follows:

(1) Build the case base of water gushing and mud bursting disaster and the risk assessment index system. A total of 251 water gushing and mud bursting accidents in 118 tunnels at home and abroad were collected by using the methods of investigation and statistical analysis. The disaster causing factors and consequences were counted, and the disaster causing factors of water gushing and mud bursting were identified and classified, and a case base of water gushing and mud bursting disasters was constructed. 12 risk assessment indicators were selected from three types of disaster causing factors including engineering geology, hydrogeology and engineering construction, and the risk assessment index system of water gushing and mud bursting was established. The water inrush and mud inrush, economic loss, casualties and time delay are selected to improve the risk classification standard of water gushing and mud bursting, comprehensively determine the risk level of each tunnel accident, and complete the sample data quantification of water gushing and mud bursting risk prediction in the case base.

(2) The improvement of machine learning algorithm and the prediction of water gushing and mud bursting risk level. The SMOTE algorithm is used to equalize the sample number of tunnel water gushing and mud bursting risk prediction, and RF, BPNN and SVM algorithms are selected to construct the model to predict the risk level. In order to further improve the prediction performance of the model, the PSO algorithm is used to optimize the BPNN and SVM models respectively, and the tunnel water gushing and mud bursting risk prediction models based on PSO-BP and PSO-SVM algorithms are constructed. The model performance is evaluated by confusion matrix, accuracy, precision, recall and F1 value. The prediction accuracy of RF, BPNN, and SVM models were 86.11%, 88.89%, and 87.5%, respectively. The prediction accuracy of PSO-BPNN and PSO-SVM models were 94.44% and 97.22%, respectively, which were 5.55% and 9.72% higher than those before

optimization. The PSO-SVM model has the highest risk level prediction accuracy on the sample data set.

(3) Comparison of tunnel water inflow prediction based on machine learning. Due to the great influence of water inflow on the water gushing and mud bursting risk level, this paper also carries out the prediction study of water inflow. The tunnel buried depth, underground water level, rock quality designation and rock water content are selected as the prediction indicators of tunnel water inflow, and 600 sample data are obtained. Four indicators, R^2 , RMSE, MAE and MBE, are selected to comprehensively analyze and evaluate the prediction performance of each model on the sample data set. In terms of prediction accuracy, the RMSE values of RBFNN, LSTM and ELM models on the test samples are 12.37, 11.37 and 7.45, respectively, and the MAE values are 8.23, 6.90 and 5.86, respectively. The three models have good prediction accuracy, and the ELM model has the smallest prediction error.

The relatively mature relevant algorithms in machine learning are applied to the risk prediction of tunnel water gushing and mud bursting. The PSO-BP and PSO-SVM algorithms are designed to improve the accuracy of the risk prediction of water gushing and mud bursting. At the same time, the key factors affecting the risk prediction are compared with the water inflow, which verifies the effectiveness and feasibility of the related models. It has certain guiding significance for the prevention and response measures of water gushing and mud bursting.

Keywords: tunnel, water gushing and mud bursting, machine learning, risk grade prediction, water inflow prediction

目 录

1 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	4
1.2.1 隧道涌水突泥风险研究现状.....	4
1.2.2 隧道涌水量预测方法研究现状.....	6
1.2.3 研究现状总结.....	6
1.3 研究内容与技术路线.....	7
1.3.1 研究内容与方法.....	7
1.3.2 创新点.....	8
1.3.3 技术路线.....	8
1.4 研究课题来源.....	9
2 隧道涌水突泥风险研究理论	11
2.1 隧道涌水突泥概述.....	11
2.1.1 隧道涌水突泥的定义及危害.....	11
2.1.2 隧道涌水突泥风险评估流程.....	11
2.1.3 隧道涌水突泥风险评估方法.....	12
2.2 隧道涌水突泥灾害案例库	13
2.2.1 案例来源.....	13
2.2.2 案例库概况.....	14
2.3 隧道涌水突泥致灾因素分析	14
2.3.1 工程地质因素.....	14
2.3.2 水文地质因素.....	18
2.3.3 工程施工因素.....	19
2.4 隧道涌水突泥风险分级标准	20
2.4.1 风险等级评估指标.....	20
2.4.2 涌水突泥风险分级.....	22
2.5 本章小结.....	23
3 隧道涌水突泥风险预测研究	24
3.1 样本数据量化与处理.....	24
3.1.1 样本数据量化.....	24
3.1.2 样本数据预处理.....	25
3.1.3 K 折交叉验证.....	29
3.2 隧道涌水突泥风险预测相关算法	30
3.2.1 随机森林算法.....	30

3.2.2 BP 神经网络算法.....	31
3.2.3 支持向量机算法.....	34
3.2.4 粒子群算法.....	36
3.3 隧道涌水突泥风险预测模型	37
3.3.1 基于 RF 算法的隧道涌水突泥风险预测模型.....	37
3.3.2 基于 BP 神经网络的隧道涌水突泥风险预测模型	38
3.3.3 基于 SVM 算法的隧道涌水突泥风险预测模型.....	42
3.3.4 基于 PSO-BP 算法的隧道涌水突泥风险预测模型.....	43
3.3.5 基于 PSO-SVM 算法的隧道涌水突泥风险预测模型	46
3.4 模型分析与评价.....	48
3.4.1 混淆矩阵.....	48
3.4.2 准确率.....	51
3.4.3 其他重要评价指标.....	51
3.5 本章小结.....	53
4 隧道涌水量预测研究	55
4.1 隧道涌水量预测指标.....	55
4.2 隧道涌水量数据分析.....	56
4.2.1 样本数据统计.....	56
4.2.2 样本数据相关性分析.....	58
4.2.3 样本数据预处理.....	59
4.3 隧道涌水量预测方法.....	59
4.3.1 径向基函数神经网络.....	59
4.3.2 长短期记忆网络.....	60
4.3.3 极限学习机算法.....	61
4.4 隧道涌水量预测模型.....	63
4.4.1 基于 RBF 神经网络的隧道涌水量预测模型	63
4.4.2 基于 LSTM 算法的隧道涌水量预测模型.....	65
4.4.3 基于 ELM 算法的隧道涌水量预测模型	67
4.5 模型分析与评价.....	69
4.6 本章小结.....	71
5 总结与展望.....	72
5.1 总结.....	72
5.2 展望.....	73
参考文献.....	74

1 绪论

1.1 研究背景及意义

隧道是现代城市交通建设中不可或缺的重要组成部分,不同类型的隧道在社会经济发展和人们的生产生活中发挥着重要作用,如公路隧道和铁路隧道可以穿越山脉、河流和城市等地形障碍,为人们的出行和物资的运输提供便捷,隧道内部的设计还可以减少交通噪音和空气污染;地铁隧道可以缓解城市交通拥堵问题,改善民众的出行条件,加强区域间的交通联系,促进城市化进程;水工隧道用于引水、排水和输水等工程,可以将水资源从丰富的地区输送到干旱地区,满足人们的生活用水和农业灌溉等需求;矿山隧道在采矿过程中具有关键性作用,可以提供便捷的进出口通道,确保采矿作业的安全性和高效性。

我国的隧道工程建设在国家政府的大力支持和工程技术的创新发展推动下,取得了令人瞩目的成就,中国正稳步从“隧道大国”向“隧道强国”、从“交通大国”向“交通强国”转变。近些年来,中国隧道不仅在数量上和长度上实现了巨大的跨越,不断创造新的世界纪录,更在隧道的建造技术、质量把控和运营效益上迈向了新的高度^[1]。

以铁路隧道为例,根据最新发布的统计数据和相关资料报告显示^[2],截至 2023 年底,中国已投入运营的铁路隧道共 18573 座,总长 23508km;共建成高速铁路隧道 4561 座,总长 7735km,其中,长度大于 10km 的高速铁路特长隧道 115 座,长约 1471km;已投入运营的特长铁路隧道共 286 座,长约 3869km,其中,长度 20km 以上的特长铁路隧道 13 座,长约 312km。新增运营铁路隧道 622 座,总长度为 1292km;在建铁路隧道 2668 座,总长度为 7110km;规划铁路隧道 5460 座,总长度为 13313km。

2021 年,江苏省太湖隧道施工建设完成并投入运营,隧道全长 15.6 公里,是中国第一个在大型淡水湖泊上建设的公路隧道,也是目前全球最长的湖底公路隧道^[3]。2022 年,中国最北端的公路隧道——小金场隧道于 8 月 1 日正式破土动工,并于 2023 年 12 月 12 日全线顺利贯通,整体工程建设取得阶段性的关键节点胜利。2023 年,生态环境敏感、地质条件复杂、建设工期紧张的四川省夹金山隧道于 9 月完成平行导洞贯通,历时 22 个月,相比计划提前 12 个月,实现了“长隧短打”^[4]。2024 年 1 月,世界在建最长高速公路隧道——中国新疆乌尉天山胜利隧道工程进口端左右主洞开挖完成七成,工程建设取得重大进展,为实现年底隧道左中右三洞全部贯通目标奠定了坚实基础。隧道建成后,将打通南北疆交通运输屏障,缩短通车时间,不仅方便当地人民的出行,更将成为重要的新疆旅游交通廊道,通过旅游业的发展进一步促进新疆的经济繁荣^[5]。各隧道现场实景见图 1.1 至图 1.4 (图片均来自网络)。

在我国隧道建设取得累累硕果的同时,受复杂自然环境和工程施工不当的影响,隧道施工过程中也极易引发诸如涌水突泥、塌方等多种灾害,不仅延误施工周期,耽误施工进度,而且还会造成各类经济损失,甚至是人员伤亡,并导致隧址附近的环境

污染和破坏，造成恶劣的社会影响。




图 1.1 太湖隧道“星空顶”
Figure 1.1 Taihu tunnel "starry roof"




图 1.2 小金场隧道
Figure 1.2 Little golden field tunnel



图 1.3 夹金山隧道
Figure 1.3 Jiajinshan tunnel



图 1.4 天山胜利隧道
Figure 1.4 Tianshan victory tunnel

根据相关学者统计的数据显示^[6]，近 15 年间发生的 109 起隧道施工事故中，死亡人数共计 338 人，受伤人数共计 147 人，隧道施工中的主要事故类型为塌方、涌水突泥和爆炸等^[7]。图 1.5 至图 1.6 分别对隧道事故类型占比和隧道各事故类型的人员伤亡情况进行统计，从图 1.5 和图 1.6 可知，在所有统计的隧道事故类型中，涌水突泥事故占比仅次于塌方，为 10.40%；涌水突泥事故容易造成施工人员的死亡，其伤亡情况严重性仅次于爆炸，平均每次事故的死亡人数和受伤人数分别为 7.3 和 0.3 人次^[8]。




图 1.5 隧道事故类型占比
Figure 1.5 Proportion of tunnel accident types




图 1.6 隧道各事故类型的人员伤亡情况
Figure 1.6 Casualties of tunnel accidents by type

以近年来我国发生的一起相当严重的隧道涌水突泥事故为例^[9]：2019 年 11 月 26 日，云南省临沧市凤庆县的在建云凤高速公路安石隧道一天内共发生两次严重的涌水突泥事故，造成 12 人死亡、10 人受伤和直接经济损失高达 2525.01 万元的严重后果。在第一次涌水突泥发生后，由于现场工程环境复杂不可控，同时工程补救和人员施救措施不当，导致事故现场失去控制，很快发生第二次涌水突泥，人员伤亡和经济损失进一步扩大。安石隧道涌水突泥事故现场见图 1.7 至图 1.8（图片均来自网络）。2020 年 12 月 21 日，中华人民共和国应急管理部评定此次事故为建筑施工领域生产安全事故典型案例。



图 1.7 涌水突泥现场

Figure 1.7 Water gushing and mud bursting scene



图 1.8 消防救援现场

Figure 1.8 Fire rescue scene

长期以来，对隧道涌水突泥风险相关的预测和防范都是众专家学者重点关注和研究的课题，已提出了如地质勘查法、数值模拟法、地质雷达探测法、地下水动力学观测法等发展和运用较为成熟的传统研究方法。随着人工智能的迅速发展，机器学习广泛运用于各学科领域。在隧道涌水突泥风险的相关研究中，利用国内外隧道勘察、施工过程中积累的各类数据资料，机器学习能够综合分析和处理复杂的地质、水文及施

工等多种因素,发现并提取出其中的隐藏关联,并通过学习和优化算法,使得涌水突泥相关风险的评估结果更加客观真实、预测精确度更高,从而指导隧道施工中的涌水突泥风险管控和应对措施,保障施工质量和人员安全。

1.2 国内外研究现状

国内外的专家学者在隧道涌水突泥风险研究各方面都做出了相当大的贡献和指导,包括涌水突泥的灾变机理、致灾因素、风险评估与分级方法等;对隧道涌水的成因以及涌水量的预测研究也颇有建树,本节将以传统研究现状和基于机器学习的研究现状为切入点,对国内外开展的相关研究工作进行讨论。

1.2.1 隧道涌水突泥风险研究现状

(1) 传统隧道涌水突泥风险研究现状

根据马士伟等人^[10]的研究,从地质因素和人为因素进行划分,隧道涌水突泥灾害的形成发生必须具备的基本条件为特殊的地质构造、丰富的地下水源、充足的填充物质和人为的开挖扰动。刘学增和马小君两位学者^[11]提出确定权重的乘积标度法改进层次分析法,同时运用模糊综合评价法确定隧道涌水突泥的安全评价指标体系和评价等级。Li 等人^[12]提出了一个属性综合评价系统用于评估岩溶隧道的突水风险。Li 等人^[13]利用地理信息系统(GIS)技术建立岩溶隧道突水危险性评价系统实现动态预测突水危险性并制定应对措施。Li 等人^[14]综合考虑地下水位、不良地质、地层岩性、地形地貌、地层倾角、开挖、超前地质预报、工程监测等 8 个风险因素,采用模糊数学和层次分析法(AHP)对各因素的风险水平进行定量描述,建立了突水风险评估软件系统。Zhou 等人^[15]提出了一种基于灰色系统理论的岩溶隧道突水风险评估最优分类方法。张志成等学者^[16]在层次分析法的基础上,引入了致灾因子相“乘”形式和致灾因子相关系数,建立了深长隧道涌突水灾害危险性评价模型。Yuan 等人^[17]提出了一种改进的灰色聚类方法对岩溶隧道突水危险性进行系统评价。袁敬强等人^[18]对屡发涌水突泥灾害的广西山心隧道进行全面调研,讨论得出涌水突泥灾害的主要致灾因子包括导水通道畅通性、地表水与地下水的丰富性、汇水负地形条件和经验准备不足的开挖施工活动等。Wang 等人^[19]在系统分析突水影响因素的基础上,确定了地层岩性、不利地质条件、地下水位、地形地貌、地层倾角、可溶岩与不可溶岩接触带、层间裂隙等 7 个因素作为评价指标,同时建立了突水影响因素的层次模型,并采用层次分析法(AHP)确定了各评价指标的权重系数,然后根据综合确定度计算确定隧道突水风险等级并将其成功运用于鸡公岭隧道和霞湖隧道。Chu 等人^[20]提出了一种可行、准确的二级模糊综合评判法对岩溶隧道进行突水风险评估。Wang 等人^[21]综合考虑岩溶水文和工程地质条件,选取地层岩性、不良地质、地下水位和可溶岩接触带等几个主要影响因素作为评价指标,基于集对分析方法(SPA),计算评价指标的等级联系度,将

该方法应用于中国泛巴高速公路鸡公岭隧道。Wang 等人^[22]考虑影响因素的主、客观权重,提出一种基于直觉模糊分析的突水危险性评价模型,并将该模型应用于峡口隧道的突水风险评估。S.C.Li 和 J.Wu^[23]研究了一种岩溶隧道的多因素综合风险评估方法,从岩溶水文地质和工程地质条件、施工因素等方面选取 12 个影响因素作为岩溶隧道综合风险评价指标并确定相应的评价指标分级标准后,对评价指标进行未知测度分析,利用可信度理论准则综合判断风险等级。Wang 等人^[24]选取了 13 个因素作为评价指标,采用层次分析法(AHP)和模糊数学理论建立了基于区间数的计算模型,将其成功应用于齐岳山隧道。Peng 等人^[25]主要通过层次分析法(AHP),建立了隧道突水危险性评估的新型云模型,将该模型应用于龙津溪隧道,对其突水风险等级讲行评价。Lin 等人^[26]将变权理论与云模型理论相结合,构建了基于云模型的岩溶隧道施工风险评价的 VW&ICM 计算模型。Wang 等人^[27]提出了一种基于正态云模型的隧道突水危险性多指标评价新方法,具体采用层次分析法和熵值法相结合的新权重算法计算指标权重,通过云模型理论得到各评价指标的综合确定度确定隧道突水的最终等级。王升等人^[28]提出了一种属性区间辨识模型对岩溶隧道突涌水风险进行系统评价,其创新主要在于评价指标的取值是一个区间,而不是一个确定值,同时引入正态分布理念对传统属性综合评价模型进行非线性改进,提出基于改进直觉模糊理论的综合属性区间测度分析方法,并采用 TFN-AHP 法进行突涌水评价指标权重分析,通过分析岩溶隧道突涌水灾害的地质影响因素和工程影响因素,建立多层次突涌水风险评价指标体系。朱建群和李天正两位专家^[29]等人针对岩溶地区隧道构建了基于危险-危害程度评价指标体系的突水突泥风险评价模型。Wang 等人^[30]基于物元理论和理想点法,提出了一种改进的岩溶隧道突水危险性评价模型。Sun 等人^[31]基于二级模糊综合评判理论和模糊层次分析法(FAHP),提出了针对岩溶隧道的突水危险性评价方法。韩琳等人^[32]将隧道涌水突泥风险影响因素分为工程地质因素、水文地质因素和工程因素三大类并具体细化,进行了涌水突泥风险分级方法的完善和工程应用。

(2) 基于机器学习的隧道涌水突泥风险研究现状

杨卓和马超两位专家^[33]在相关文献调研基础上,选取不良地质、地层岩性、地下水位、地形地貌、岩层倾角和围岩裂隙六个主要因素构建突涌水风险评价指标,并运用 BP 神经网络方法对隧道突涌水风险进行评估。通过收集整理隧道的涌水突泥灾害事故资料,选取不同的涌水突泥风险评估指标,王璐^[34]以隧道涌水突泥灾害引发的涌水量为标准进行等级划分,构建了基于遗传算法和支持向量机的隧道涌水突泥风险评估模型;柏成浩^[35]分别通过构建决策树、随机森林和支持向量机三种智能方法对隧道涌水突泥风险等级进行预测;王凯平^[36]基于弱胶结软岩隧道突水灾变演化特征,应用贝叶斯网络对隧道是否发生突水情况进行预测。Li 等人^[37]基于可靠性理论和 GA-BP 神经网络建立了一种新的定量评价模型对隧道溶洞突水风险等级进行预测。Zhang 等人^[38]利用 SVR 模型成功对岩溶隧道突水风险等级进行预测。

1.2.2 隧道涌水量预测方法研究现状

康小兵等学者^[39]结合重庆走马岭岩溶隧道的工程勘察资料与实时监测数据,根据地下水径模数法和大气降水入渗法,对隧道涌水量进行了初步预测和评价。郭旭晶等人^[40]在分析石太客运专线特长隧道的多种地质环境特征后,通过建立模糊综合评判矩阵,使用模糊综合评价法成功实现对隧道涌水量的预测。任蕊和许模两位学者^[41]运用了 BP 神经网络预测华蓥山隧道不同构造部分的涌水量。Aalianvari 等人^[42]应用模糊菲尔德法和层次分析法对隧道发生涌水突泥灾害时的涌水量进行预测和评估分级。Jin 等人^[43]采用地面动力学方法成功实现对南山地区的隧道涌水量进行预测并取得了不错的预测效果。谢立均^[44]通过隧道涌水专家评判系统对高家湾隧道涌水进行定性预判后,采用地下水径流模数法、大气降水渗入量法、地下水疏干静水量概算法、泉流量汇总法和地下水动力法等多种方法实现对隧道涌水量的预测。Cheng 等人^[45]为了评价更符合隧道实际情况的涌水量,引入了渗透系数随深度变化的经验关系式。王健华等人^[46]提出了基于数值分析法和极限(离散)解析法的涌水量综合预测方法。P.Lin 等人^[47]提出了一种半解析和半数值法相结合的方法对强降雨期间穿越岩溶裂隙带的隧道涌水量进行预测。Zhou 等人^[48]研究了一种考虑非达西效应的隧道涌水量预测分析方法,基于数值结果和参数积分法建立了半经验模型,对水流处于非达西流态的隧道涌水量进行了解析预测。唐宁等人^[49]以复势法和圆岛模型为理论基础,推导了岩溶隧道涌水量预测公式。傅鹤林等人^[50]针对二维渗流模型分析隧道掌子面附近渗流场的局限性,利用反映法将有界含水层用映射原理转变为无界问题,分别构建掌子面前后方涌水简化计算模型。Amiri Vahab 等人^[51]评价了伊朗西北部卡尼西布大坝至乌尔米亚湖(UL)输水隧洞路线的水文地质状况,通过分析、经验和数值方法对隧道涌水量进行了预测。周彩贵等人^[52]分别采用 LSTM、Elman 神经网络和基于偏最小二乘法的多元线性回归方法对引水隧洞施工涌水量进行预测,预测结果表明 LSTM 的预测精度更高。苏培东等人^[53]对红豆山隧道展开研究,将模糊数学模型预测得到的平均涌水量与工程的实际涌水量进行对比分析,最终预测效果较好。Shi 等人^[54]结合蒙特卡洛算法,采用“父-子”和“阶跃结构”修正模式,构建了随机确定性三维裂隙网络渗流模型,同时基于三维裂隙网络渗流模型和流量平衡原理,采用数值计算方法对成功预测岳龙门隧道各里程段涌水量。王成华和牛来福两位学者^[55]在对引水隧洞的涌水量预测研究中将基于偏最小二乘法的多元线性回归方程与 LSTM 算法进行对比,预测结果表明 LSTM 模型可以对涌水量进行更为精准的预测。王青松和刘凯两位专家^[56]基于青岛地铁近海隧道地质资料和勘察报告,构建 BP 神经网络模型预测近海地铁隧道涌水量,为相关工程提供参考。

1.2.3 研究现状总结

在国内外学者的长期不懈努力下,隧道涌水突泥风险在评估方法、模型应用和系

统开发等多个方面取得了相当多的优秀成果和突破,不仅提升了学界对于隧道涌水突泥风险的认知广度和理论深度,而且对隧道的工程实践具有很好的实际指导意义。但就涌水突泥风险预测研究的复杂性和全面性而言,还存在以下一些问题:

(1) 有关隧道涌水突泥的绝大多数研究都是依托于某个隧道展开,仅针对该隧道的地质、水文和施工等情况进行风险等级划分,其评价指标和评价标准并不具有普适性,且无法直接运用于其他隧道的涌水突泥风险评估。若无较多隧道案例样本的统计数据作为支撑,无论是定性描述还是定量取值,都存在以偏概全之嫌。同时,大多数对涌水突泥风险的评估研究主要是考察隧道工程周边的自然地理环境这一有着显著影响的因素,而在施工的措施和质量等人为致灾因素上的关注度不够。

(2) 目前学界对于隧道涌水突泥风险等级的划分标准不一,多以涌水量为风险等级划分依据,较少考虑突泥量这一指标;对涌水量的区间划分较为宽泛,例如,根据通用的涌水量级划分标准可将涌水突泥灾害分类为特大型、大型、中等型和小型,大型突水灾害的涌水量区间划分为 $1000\sim 10000\text{m}^3/\text{h}$,不仅区间极值差距较大,而且灾害后果差别极大,不利于精准制定涌水突泥相关应对措施,若判定为同一风险等级存在不合理性。

(3) 隧道涌水突泥风险研究中针对风险评估指标的定量取值分析不足。相当一部分的风险评估指标及其量化值在一定程度上依赖专家打分等人工经验判断,缺乏真实的定量数据支撑及客观的风险评估和预测方法应用。对于隧道涌水量的预测研究也多为传统方法,基于机器学习理论的预测模型研究不足。

因此,在机器学习迅速发展的趋势下,通过选用合适的算法构建相关模型对隧道涌水突泥风险及涌水量进一步预测研究十分有必要。

1.3 研究内容与技术路线

1.3.1 研究内容与方法

(1) 构建隧道涌水突泥灾害案例库

在隧道涌水突泥风险研究理论基础上,通过调查法、统计分析等方法广泛收集整理隧道涌水突泥灾害事故,综合定量分析与定性描述方法记录下致灾因素和后果,建立隧道涌水突泥灾害案例库。从工程地质因素、水文地质因素和工程施工因素中选取 12 个具体的涌水突泥风险评估指标构建和完善风险评估指标体系,选取涌水突泥量、经济损失、人员伤亡和工期延误构成风险等级评估指标体系。

(2) 基于机器学习相关算法的隧道涌水突泥风险预测研究

根据涌水突泥致灾因素等级与风险等级的划分标准,将案例库中的原始数据和资料合理量化为隧道涌水突泥风险预测数据集,对样本数据进行相关预处理后,构建基于 RF、BPNN、SVM、PSO-BP 和 PSO-SVM 算法的预测模型对隧道涌水突泥风险等级进行预测,通过对比各模型的混淆矩阵、准确率、精准率、召回率以及 F1 值进行

模型性能分析,得到在该样本数据集上对隧道涌水突泥风险等级预测效果最好的模型。

(3) 基于机器学习相关算法的隧道涌水量预测研究

选取隧道埋深、地下水位、岩石质量指数以及岩层含水性作为隧道涌水量预测指标,对样本数据进行相关统计分析和预处理后,采用机器学习中的 RBFNN、LSTM 和 ELM 算法构建隧道涌水量预测模型,通过预测值和真实值的对比以及 R^2 、RMSE、MAE、MBE 四个指标对各预测模型的训练效果和预测效果进行综合分析与评价,从而得到在该样本数据集上隧道涌水量预测精度最高的方法。

1.3.2 创新点

(1) 隧道涌水突泥风险评估指标体系及风险分级方法的完善

将定性分析与定量研究的方法相结合,以定量研究为基础,定性描述为补充,使得隧道涌水突泥风险评估指标分级更为客观准确;在涌水突泥风险分级标准中增加突泥量作为分级因素之一,进一步提出了较为全面的风险评估指标体系和风险分级方法,对隧道涌水突泥风险的致灾因素辨识及分级方法具有一定的补充性和创新性。

(2) 机器学习相关优化算法在隧道涌水突泥风险预测研究中的应用

将机器学习领域中发展较为成熟的 RF、BPNN、SVM 等算法应用于隧道涌水突泥风险预测研究中,设计了 PSO-BP 算法和 PSO-SVM 算法构建隧道涌水突泥风险预测模型,将 RBFNN、LSTM 和 ELM 算法应用于隧道涌水量预测研究,验证了相关模型的有效性和可行性,在机器学习算法的应用方面具有一定的创新性。

1.3.3 技术路线

研究所采用的技术路线如图 1.9。基于机器学习的隧道涌水突泥风险预测研究中,具体流程如下:

(1) 阐述隧道涌水突泥风险相关理论,为后续研究工作提供理论支撑。

(2) 构建隧道涌水突泥灾害案例库。从工程地质、水文地质和工程施工三个方面进行致灾因素的辨识与分析,共选取 12 个风险评估指标,建立风险评估指标体系;选取经济损失、人员伤亡、工期延误和涌水突泥量作为风险分级因素,完成风险分级标准的制定。

(3) 隧道涌水突泥风险等级预测。量化案例库中的灾害数据资料得到样本数据集,选用随机森林、BP 神经网络和支持向量机算法构建隧道涌水突泥风险等级预测模型,采用粒子群算法分别对 BP 神经网络和支持向量机模型进行优化,并通过相关评价指标进行模型对比与分析。

(4) 隧道涌水量预测研究。对涌水量样本数据进行统计分析与处理,选用径向基函数神经网络、长短期记忆网络和极限学习机算法构建隧道涌水量预测模型,并通过相关指标进行模型性能评价。

(5) 总结与展望。




图 1.9 技术路线图

Figure 1.9 Technology Roadmap

1.4 研究课题来源

本研究课题来源于团队负责的技术服务项目“高速公路隧道施工风险大数据可视化智慧管理平台技术研究”（横向）。

2 隧道涌水突泥风险研究理论

2.1 隧道涌水突泥概述

2.1.1 隧道涌水突泥的定义及危害

隧道涌水突泥是指在隧道掘进施工过程中,由于地质条件复杂或者施工方法不当等因素,当钻孔或挖掘到一定深度时,地下水会从孔洞或开挖面向上冒出,同时带来大量泥浆或淤泥。涌水突泥通常发生在地下水位较高或隧道所经过的地层中含有大量泥质物质的地区,特别是当隧址区存在断层破碎带与充填型岩溶构造^[57]。同时,涌水突泥一旦发生,受不当的施工治理措施影响,极易引发二次涌水突泥。研究表明,隧道绝大部分二次涌水突泥的发生与工程单位不作为、不重视甚至是继续盲目施工直接相关^[58]。总之,隧道涌水突泥是一种高风险地质灾害,其发生具有突然性、瞬时性,不仅将使隧道的稳定性受到威胁,还有可能引发塌方、坍塌等其他严重事故,一旦没有做好预防和应急措施,后果将不堪设想。

2.1.2 隧道涌水突泥风险评估流程

根据《铁路隧道风险评估及管理暂行规定》,隧道风险评估与管理基本流程^[59]见图 2.1。




图 2.1 隧道风险评估与管理基本流程图

Figure 2.1 Basic flow chart of tunnel risk assessment and management

结合隧道风险评估与管理基本流程,隧道涌水突泥风险评估流程通常包括以下六个步骤:

(1) 收集基础资料: 获取隧道项目的地质勘探资料、水文地质调查报告、设计文件及施工记录等, 初步了解隧道的基本情况。

(2) 实地勘察, 识别风险因素: 对隧址区进行实地详细勘察是风险评估过程中必不可少的环节, 包括地质分析、水文分析和工程设计等。

①地质分析: 对隧道周边的地质条件进行现场调查, 包括地层岩性、构造情况、断层分布等, 重点关注可能存在的含水层、岩溶区等地质条件, 分析其对涌水突泥的影响。

②水文分析: 通过地下水位监测、水文地质勘察等手段, 获取地下水位、水流速度和降雨量等信息, 结合历史水文资料评估水文地质特征对涌水突泥的影响。

③工程设计: 结合隧道的设计参数, 如隧道断面形状、支护方式等, 评估工程设计可能存在的风险点。

(3) 数值模拟: 对勘察所得的数据进行分析和处理, 使用相关软件, 通过数值模拟等方法评估隧道涌水突泥风险的概率和可能性。

(4) 风险评估: 综合考虑地质条件、水文地质特征、工程设计和数值模拟结果等因素, 对隧道涌水突泥潜在风险进行评估。可以采用定性、定量或定性定量相结合的方法, 确定风险等级。

(5) 预防措施: 根据风险评估结果, 提出相应的风险控制措施和应急预案, 如注浆、排水、加固支护等, 以降低隧道涌水突泥的概率和危害程度并及时应对突发情况。

(6) 定期评估和监测预警: 随着隧道工程的施工和运营, 建立完善的监测和预警系统, 定期对涌水突泥风险进行评估和监测, 及时掌握隧道内部的水流情况, 调整预防措施和应急方案, 降低涌水突泥的可能性和对工程的影响, 保障人员的生命安全。

2.1.3 隧道涌水突泥风险评估方法

根据风险评估过程中所使用的数据和分析手段, 隧道涌水突泥风险评估方法可以分为定性分析法、定量分析法和定性定量相结合三大类, 具体方法见图 2.2。

(1) 定性分析法: 该方法基于专家经验和主观判断, 对隧道涌水突泥风险因素进行定性描述和评估。通过专家讨论、问卷调查等方式, 将风险因素分为不同的等级、类别或描述, 从而对风险进行排序和优先级确定。这种方法相对简单快速, 适用于初期风险筛选和初步决策。此方法简便易行, 但评估结果的客观性较差。

(2) 定量分析法: 该方法通过收集和处理具体的数据、参数和指标, 使用数学模型和统计方法, 基于风险分析理论对隧道涌水突泥风险进行定量测算和评估。常见的定量分析方式包括概率分析、统计分析和数值模拟等。这种方法能够提供更精确的风险量化结果, 帮助施工人员理解和比较各个风险因素的影响程度, 此方法客观性较

好，但需要大量数据支撑，并且模型的建立和运用需要专业技术。

（3）定性和定量相结合的方法：该方法综合利用定性分析和定量分析的优势，既考虑了专家经验和主观判断的因素，又基于实际数据和科学分析进行量化评估。通过将定性描述转化为定量指标、权重或概率，并结合模型和统计分析，对隧道涌水突泥风险进行综合评估。




图 2.2 隧道涌水突泥风险评估方法分类图

Figure 2.2 Classification diagram of risk assessment methods for tunnel water gushing and mud bursting

为保证隧道涌水突泥风险预测研究的全面性和准确性，在查阅大量文献资料中的隧道涌水突泥风险评估实例并调研现有的风险研究方法后，将在评估过程中综合定性分析和定量分析，首先建立起隧道涌水突泥灾害案例库，详细记录下每起灾害事故的数据和资料，以定量分析为基础，定性分析为补充，以期对隧道涌水突泥风险的灾变机理、致灾因素和风险等级划分等有更进一步的认识。

2.2 隧道涌水突泥灾害案例库

2.2.1 案例来源

涌水突泥案例来源均为真实可靠的隧道工程，包括中国知网和 Web of Science 等国内外学术期刊网站、中国土木工程学会隧道及地下工程分会等专业协会的官方网站、相关政府部门官网和新闻媒体的详细报导等。同时，收集部分涌水突泥风险分析与评

级文献资料做补充。

2.2.2 案例库概况

经过大量收集和审查,整理了国内外 118 条隧道的 251 个记录较为详实的隧道涌水突泥灾害事故案例,统计时间段从 1990 年至 2022 年,其中大部分历史灾害案例发生在我国。在 118 条隧道中,有 42 条隧道仅发生一处涌水突泥事故,其他 76 条隧道的不同里程则发生过多处涌水突泥事故;部分隧道在首次涌水突泥事故发生后,因处置措施不当发生了二次涌水突泥。在收集整理的所有文献中,一个文献最多记录 25 条隧道涌水突泥事故数据,一条隧道最多记录 35 个不同里程的数据信息。收集的涌水突泥灾害的隧道包括重庆市的走马岭隧道、贵州省的安理寨隧道、云南省的祥云隧道、湖北省的鸡公岭隧道、四川省的狮子寨隧道等等,其中部分隧道发生涌水突泥灾害的具体里程不明确。

通过对隧道涌水突泥灾害事故进行详细的资料收集,主要记录下了每起事故的多个致灾因素和发生后果。在认识和掌握隧道涌水突泥发生机理等理论基础上,将致灾因素分为工程地质因素、水文地质因素和工程施工因素三类,再进一步划分为 12 个具体的风险评估指标,其中工程地质因素包括地质构造、地层岩性、岩层厚度、岩层产状、围岩级别、地形地貌、岩溶发育情况共七个评估指标;水文地质因素包括降水及地下水、降雨入渗系数、节理裂隙与地表河流结合度共三个评估指标;工程施工因素包括施工扰动和支护情况两个评估指标。由于隧道涌水突泥的环境影响和社会影响等难以直接评估和统一量化,根据现有文献资料,案例库中灾害事故造成的后果记录主要包括涌水突泥量、人员伤亡、经济损失和工期延误等方面。

2.3 隧道涌水突泥致灾因素分析

通过研读涌水突泥领域内的权威文献及分析大量隧道涌水突泥案例资料,参考各专家已提出的不同涌水突泥风险评估指标体系,总结得出隧道涌水突泥的致灾因素首先可大致分为三类,即一级评估指标为工程地质因素、水文地质因素和工程施工因素,再进一步对其细分为共计 12 个二级定量或定性评估指标。

2.3.1 工程地质因素

工程地质因素对隧道涌水突泥的影响表现在地质构造、地层岩性和地形特点等多个方面,这些因素共同决定了隧道周围岩土的稳定性和地下水的流动情况,直接影响着隧道涌水突泥的风险程度。本节将工程地质因素细分为地质构造、地层岩性、岩层厚度、岩层产状、围岩级别、地形地貌、岩溶发育情况七个类别,在一级评估指标中占比最大。

(1) 地质构造

地质构造评估指标主要是根据隧址区含导水构造和断层破碎带的情况判断其致灾性强弱。当隧道穿越含导水构造和断层破碎带时，这些通道可以成为地下水流的主要路径，增加了隧道涌水突泥的风险。地质构造致灾等级见表 2.1。

表 2.1 地质构造致灾等级表
Table 2.1 Disaster hierarchy of geological structures

致灾等级	地质构造
I	无致灾性，无含导水构造或断层破碎带
II	弱致灾性，单斜构造或有小型含导水构造或断层破碎带宽度小于 10m
III	中等致灾性，有中小型含导水构造或断层破碎带宽度为 10~20m
IV	较强致灾性，有中型含导水构造或断层破碎带宽度为 20~50m
V	强致灾性，褶皱核部或转折带处，有大型含导水构造或断层破碎

(2) 地层岩性

地层岩性对隧道工程的稳定性和安全性有着直接影响，特别是在涌水突泥风险评估中更为关键。地层岩性通常指的是地下岩层的岩石类型、结构、成分、孔隙度等特征。在各隧道涌水突泥事故案例中收集记录有关地层岩性的定量分析数据主要为 t 系数和可溶岩比例，而定性描述主要是岩石类型和岩石结构，使得后续地层岩性评估指标的数据量化更加准确合理。

① t 系数： t 系数是一个重要的参数，反映了岩土层对水流的传导能力，可以用于描述地层岩石的透水性和可溶性。计算 t 系数的公式如式 (2.1)。

$$t = 0.63B_1 + 0.259B_2 + 0.105B_3 \quad (2.1)$$

式 (2.1) 中， B_1 、 B_2 和 B_3 分别表示强、中等和弱溶解性岩层的比例。

②可溶岩比例：可溶岩是指对水具有较强溶解作用的岩石，通常是由含有溶解性矿物质的火成岩或沉积岩经过长时间的化学侵蚀和风化作用形成的。可溶岩比例是指在某一地质区域或特定地层中，可溶性岩石所占的比例。可溶岩在地下水的侵蚀下容易形成溶洞，增加隧道涌水的可能性。

③岩性类型和岩石结构：岩性类型直接影响着隧道工程的稳定性和隧道内部的水土条件。岩石结构是指岩石内部的构造特征，岩石的结构受到矿物颗粒的形状、大小、结晶程度以及晶粒的排列方式、岩石的变形历史等多种因素的影响，不同类型的岩石具有不同的结构特征，对隧道涌水突泥灾害的发生具有一定的影响性。地层岩性致灾等级见表 2.2。

表 2.2 地层岩性致灾等级表
Table 2.2 Stratigraphic lithology disaster grade table

致灾等级	t 系数	可溶岩占比(%)	岩性类型	岩石结构
I	$t < 0.042$	0~20	砂岩、页岩、泥岩等	粗晶结构
II	$0.042 < t < 0.104$	20~50	泥质灰岩、泥质白云岩等	亮晶结构
III	$0.104 < t < 0.254$	50~80	灰质白云岩、白云岩等	粒屑结构
IV	$t > 0.254$	80~100	灰岩、白云质灰岩等	泥晶结构

(3) 岩层厚度

岩层厚度是指地层中某一岩石单元在垂直方向上的延伸距离,岩层较厚的地区可能储存更多的地下水,从而增加隧道涌水突泥的风险。岩层厚度致灾等级见表 2.3。

表 2.3 岩层厚度致灾等级表

Table 2.3 Grade of disaster caused by rock thickness

致灾等级	岩层厚度(m)	描述
I	<0.1	薄层
II	0.1~0.3	薄层-中厚层
III	0.3~0.7	中厚层
IV	0.7~1	厚层-中厚层
V	>1	厚层、巨厚层

(4) 岩层产状

岩层产状是指岩石在地下的分布情况和特征,通常包括倾向、倾角、节理发育情况等。隧道涌水突泥灾害案例库中对于各隧道岩层产状资料的收集主要包括岩层倾角数据和岩层产状描述,岩层倾角是指岩层面与水平面的夹角,是描述岩层产状的重要参数之一。大量研究文献表明,当岩层倾角位于 25°~65° 范围内时,最有利于隧道涌水突泥风险的发生,因此判定在该在岩层倾角范围区间内的涌水突泥致灾等级最高。岩层产状致灾等级见表 2.4。

表 2.4 岩层产状致灾等级表

Table 2.4 Grade of disaster caused by occurrence of rock strata

致灾等级	岩层倾角(°)	岩层产状
I	0~10	导水能力极差,不利于地下岩溶发育
II	80~90	导水能力较差,弱利于地下岩溶发育
III	10~25/65~80	导水能力较强,中等利于地下岩溶发育
IV	25~65	导水能力强,利于地下岩溶发育

(5) 围岩级别

围岩级别是在工程和地质领域中对岩石围岩稳定性状况的评定和分类,级别越高表示围岩质量越好。参考《铁路隧道设计规范》和《公路隧道设计规范》,隧道围岩可以分为 6 个级别,不同级别的隧道围岩描述及围岩基本质量指标见表 2.5。

表 2.5 围岩级别致灾等级表

Table 2.5 Class of surrounding rock disaster class

致灾等级	围岩级别	围岩主要描述	围岩基本质量指标
I	I	坚硬岩,岩体完整,巨整体状	>550
II	II	较坚硬岩,岩体较完整,块整体构造	550~451
III	III	较软硬质岩,岩体较破碎,碎状镶嵌构造	450~351
IV	IV	较软岩或软硬质岩互层,岩体较破碎	350~251
V	V	极破碎各类岩体,碎、裂状,松散构造	≤250
VI	VI	软塑状粘性土及潮湿、饱和粉细砂层、软土等	

(6) 地形地貌

地形地貌的汇水量和汇水能力是评估隧道涌水突泥风险的重要致灾因素之一,研

究主要从地形坡度、负地形面积占比这两个定量数据以及负地形描述这一定性描述进行致灾等级划分。地形地貌致灾等级见表 2.6。

①地形坡度：地形坡度定义为单位水平距离内的垂直高差。就涌水风险，而言地形坡度影响地下水的流向和流速。在较陡峭的地形中，地下水流动速度较快，可能会引发隧道内大量涌水。此外，陡峭的坡度可能意味着隧道需要穿越不同的地质层次，这些地层中的水文地质条件差异可能增加涌水的不确定性和风险；就突泥风险而言，陡峭的地形中的土体更容易受到重力的影响而发生位移，尤其是在地下水位较高的情况下。当隧道开挖过程中遇到这种不稳定的土体，就可能出现突泥现象。

②负地形面积及占比：负地形是指地表低于周围地表或水平线的地形，通常出现在山谷、河谷、盆地等低洼地区。负地形面积占比则是指负地形在整个隧址区中所占的比例。负地形通常是雨水和地下水的集聚区域，如果隧道穿越负地形区域，隧道工程可能会遇到水文地质条件复杂的情况，而当负地形面积较大时，地表水流量可能较大，容易增加隧道涌水突泥风险。

表 2.6 地形地貌致灾等级表
Table 2.6 Topographic and geomorphologic disaster level

致灾等级	地形地貌	地形坡度(°)	负地形占比(%)	负地形描述
I	不易引发灾害	>60	0	无负地形
II	弱利于引发灾害	45~60	<10	较小范围负地形
III	中等利于引发灾害	30~45	10~30	小范围负地形
IV	易引发灾害	10~30	30~60	中等范围负地形
V	极易引发灾害	<10	>60	大范围负地形

(7) 岩溶发育情况

岩溶发育越强烈，隧道涌水突泥灾害发生的可能性越大。具体表现在：

①岩溶地区地下水位较高且地下水系统复杂，地下水可能会通过岩溶裂隙和溶洞进入隧道，增加涌水风险。

②岩溶地区岩层结构不稳定，存在坍塌、滑坡等风险，这可能导致隧道开挖过程中岩层垮塌，增加突泥风险。

③岩溶地区常常存在地下河流系统，地下河流的水位和流速变化可能影响隧道周围岩体的稳定性，增加涌水风险。

隧道穿越的岩溶水动力分带可以从侧面反映隧道的岩溶发育情况，根据地质学者的研究，岩溶水动力分带主要分为垂直渗流带、深部循环带、季节变动带和水平径流带。隧道的岩溶发育特征及岩溶水动力分带致灾等级划分见表 2.7。

表 2.7 岩溶发育情况致灾等级表
Table 2.7 Karst development of disaster level table

致灾等级	岩溶发育特征	岩溶水动力分带
I	不利于岩溶发育	垂直渗流带
II	弱（有利于）岩溶发育	深部循环带
III	中等程度（有利于）岩溶发育	水平-垂直交替循环带
IV	强（有利于）岩溶发育	季节变动带

2.3.2 水文地质因素

水文地质因素主要是表征在水文因素与地质因素的共同作用下对隧道涌水突泥风险的影响，包括降水及地下水、降雨入渗系数、节理裂隙与地表河流结合度。

(1) 降水及地下水

降水和地下水联系紧密，因此将降水与地下水合并为同一个致灾因素。降水特别是连续性降水是引发隧道涌水突泥风险的重要致灾条件之一，因此尽可能统计了各隧道涌水突泥灾害事故发生时的前 24 小时或一周内的降水量，一周内降水量以至少一次的最高等级降雨级别认定为这周的降水量情况。降水及地下水致灾等级见表 2.8。

表 2.8 降水及地下水致灾等级表

Table 2.8 Scale of disaster caused by precipitation and groundwater

致灾等级	24h 内降水量(mm)	一周内降水量	地下水位(m)	降水量描述
I	<10	小雨或无雨，基本无致灾性	<0	无致灾性
II	10~25	中雨，弱致灾性	$0 \leq h < 30$	弱致灾性
III	25~50	大雨，较强致灾性	$30 \leq h < 60$	中等致灾性
IV	>50	暴雨及以上，强致灾性	≥ 60	强致灾性

(2) 降雨入渗系数

降雨入渗系数是指单位时间内单位面积土壤或岩石对降雨水分的渗透能力。降雨入渗系数受多种因素影响，是一个综合性的定量衡量指标。研究表明，在相同的水文地质条件下，降雨入渗系数与隧道涌水量成正比。由于部分隧道的降雨入渗系数缺失，参考《铁路工程水文地质勘测规程（TB 10049-1996）》文件，近似确定降水入渗系数区间。降水入渗系数 α 经验数据表见表 2.9，降雨入渗系数致灾等级见表 2.10。

表 2.9 降水入渗系数 α 经验数据表

Table 2.9 Precipitation infiltration coefficient α empirical data table

地层名称	α	地层名称	α
粉质黏土	0.01~0.02	较完整岩石	0.10~0.15
粉土	0.02~0.05	较破碎岩石	0.15~0.18
粉砂	0.05~0.08	破碎岩石	0.18~0.20
细砂	0.08~0.12	极破碎岩石	0.20~0.25
中砂	0.12~0.18	岩溶微弱发育	0.01~0.10
粗砂	0.18~0.24	岩溶弱发育	0.10~0.15
圆砾（夹砂）	0.24~0.30	岩溶中等发育	0.15~0.20
卵石（夹砂）	0.30~0.35	岩溶强烈发育	0.20~0.50
完整岩石	0.1~0.10		

表 2.10 降雨入渗系数致灾等级表

Table 2.10 Scale of rainfall infiltration coefficient causing disaster

致灾等级	降雨入渗系数
I	<0.05
II	0.05~0.1
III	0.1~0.15
IV	0.15~0.25
V	0.25~0.5

(3) 节理裂隙与地表河流结合度

节理裂隙与地表河流的结合度主要指节理裂隙与地表河流之间的相互作用关系和影响程度。节理裂隙与地表河流的结合度在一定程度上影响着隧道涌水突泥风险的发生。当隧道周围的岩石中存在较多的节理裂隙，并且这些节理裂隙与地表河流相连时，可能引起节理裂隙的扩张和岩石的破坏，加大隧道涌水突泥的风险程度。因此该评估指标主要从裂隙发育及地表河流情况判断是否利于岩溶发育，进而判断该指标的涌水突泥风险致灾等级。节理裂隙与地表河流结合度致灾等级见表 2.11。

表 2.11 节理裂隙与地表河流结合度致灾等级表

Table 2.11 Disaster grade of joint fissure and surface river

致灾等级	节理裂隙与地表河流结合度
I	裂隙基本不发育，无地表河流，不利于岩溶发育
II	裂隙发育较差，无地表河流，弱有利于岩溶发育
III	裂隙中等程度发育，有地表河流，中等有利于岩溶发育
IV	裂隙强发育，有地表河流，强有利于岩溶发育

2.3.3 工程施工因素

人为施工是引发隧道涌水突泥的直接致灾因素之一，其中施工扰动和支护情况对隧道涌水突泥风险的发生具有较大的影响。

(1) 施工扰动

施工扰动指在工程施工过程中对地下岩土或地质构造进行破坏、改变或影响的行为。施工扰动致灾等级见表 2.12。

表 2.12 施工扰动致灾等级表

Table 2.12 Construction disturbance caused disaster grade table

致灾等级	施工扰动
I	未钻探时，无扰动
II	未爆破时，扰动较小
III	超前钻探，扰动程度和范围大
IV	爆破开挖，扰动程度和范围最大

(2) 支护情况

科学合理的支护设计可以提高隧道的稳定性和安全性，减少地质灾害的发生，并

有效降低隧道涌水和突泥等风险。从收集整理的隧道涌水突泥灾害事故中明显发现，在隧道发生第一次涌水突泥灾害后，不采取安全适当的支护措施极易造成二次甚至多次涌水突泥，导致涌水突泥的致灾程度进一步加重，造成更严重的灾害后果。支护情况致灾等级见表 2.13。

表 2.13 支护情况致灾等级表

Table 2.13 Disaster rating table of support condition

致灾等级	支护情况
I	运营期内，已过混凝土养护龄期
II	二次衬砌完成
III	初期支护完成
IV	无支护

2.4 隧道涌水突泥风险分级标准

对于隧道涌水突泥风险等级，需要综合考虑多方面因素进行判定。以国内现行规范《铁路隧道风险评估及管理暂行规定》中提出的相关分级标准为基础，同时查阅对比其他权威研究文献，依据灾害案例库中记录的风险发生后果评定涌水突泥风险等级，加入现有研究中鲜少考虑的突泥量指标，具体选取涌水突泥量和人员伤亡、经济损失、工期延误各因素对风险发生后果的严重程度进行更为准确的衡量。

2.4.1 风险等级评估指标

(1) 涌水突泥量

①涌水量

涌水量是隧道涌水突泥风险研究中易于量测且相当重要的数据之一，往往和灾害严重程度直接相关。通常情况下，对于大型涌水突泥灾害的涌水量的划分区间为 $1000\text{m}^3/\text{h} \sim 10000\text{m}^3/\text{h}$ ，就区间极值而言相差极大，若依此划分为同一量级，这对于涌水突泥灾害的认识和预防措施将产生重大误导，因此，需要对涌水量区间进行更加细致的划分，以便于下文构建风险预测研究模型，得到更加准确的模型预测结果。

查阅专业文献资料^[60]后，有学者提出的涌水量亚级分级见表 2.14。对案例库中各涌水突泥事故的实际涌水量分布区间进行分析后，为更好地进行风险等级判定和预测，最终将上述涌水量分级进行合并后得到涌水量等级划分见表 2.15。

表 2.14 隧道涌水量亚级分级表

Table 2.14 Tunnel water inflow subgrade classification table

等级	涌水量(m ³ /h)
I	≤10
II	10~100
III ₁	100~550
III ₂	550~1000
IV ₁	1000~4000
IV ₂	4000~7000
IV ₃	7000~10000
V	≥10000

表 2.15 隧道涌水量等级表

Table 2.15 Grade of water inflow in tunnel

等级	涌水量(m ³ /h)
I	≤100
II	100~1000
III	1000~7000
V	≥7000

②突泥量

由于隧道涌水突泥风险研究中对于突泥量等级区间划分的研究较少,参考专业学者李相辉博士提出的突泥量等级划分见表 2.16。

表 2.16 隧道突泥量等级表

Table 2.16 Scale of tunnel mud discharge

等级	突泥量(m ³)
I	<3000
II	3000~5000
III	5000~10000
V	≥10000

(2) 其他风险等级评估指标

①人员伤亡

依据《铁路隧道风险评估及管理暂行规定》,人员伤亡等级划分见表 2.17。人员伤亡情况包括轻伤、重伤和死亡三类。

表 2.17 人员伤亡等级表

Table 2.17 Casualty scale table

人员伤亡等级	伤亡人数/个	人员伤亡描述
I	轻伤人数为 1	人员伤亡轻微
II	重伤人数为 1 或轻伤人数为 2~10	人员伤亡比较严重
III	死亡人数为 1~2 或重伤人数为 2~10	人员伤亡严重
IV	死亡人数为 3~9 或重伤人数>10	人员伤亡相当严重
V	死亡人数>9	人员伤亡极其严重

②经济损失

依据《铁路隧道风险评估及管理暂行规定》，经济损失等级划分见表 2.18。

表 2.18 经济损失等级表

Table 2.18 Scale of economic losses

经济损失等级	经济损失/万元	经济损失描述
I	<30	经济损失轻微
II	30~100	经济损失比较严重
III	100~300	经济损失严重
IV	300~1000	经济损失相当严重
V	>1000	经济损失极其严重

③工期延误

依据《铁路隧道风险评估及管理暂行规定》，工期延误等级划分见表 2.19。

表 2.19 工期延误等级表

Table 2.19 Schedule of construction delays

工期延误等级	工期延误/月	工期延误描述
I	<0.01	工期延误轻微
II	0.01~0.1	工期延误比较严重
III	0.1~1	工期延误严重
IV	1~10	工期延误相当严重
V	>10	工期延误极其严重

2.4.2 涌水突泥风险分级

在隧道涌水突泥灾害案例中，绝大多数都记录下了灾害发生时的涌水突泥量，以此作为涌水突泥风险分级的主要依据。针对少部分涌水突泥量数据缺失的灾害事故，综合选取人员伤亡、经济损失和工期延误三个涌水突泥风险分级指标完成风险分级，其风险等级判定标准为：若该隧道的涌水突泥量出现数据缺失情况，则参考其他三个风险分级评估指标进行风险等级判定。在三个指标中，以最高等级的评估指标作为涌水突泥风险等级；当有两个指标等级相同时，按照更高一级进行涌水突泥风险等级认定。隧道涌水突泥风险分级见表 2.20。

表 2.20 隧道涌水突泥风险等级表

Table 2.20 Risk level of tunnel water gushing and mud bursting

风险等级	风险描述
I	弱风险
II	中等风险
III	强风险
IV	极强风险

2.5 本章小结

本章主要内容总结如下：

（1）系统介绍隧道涌水突泥风险的定义及危害、评估流程和评估方法等理论，为隧道涌水突泥风险研究的相关流程及评估方法提供科学合理的理论支撑。

（2）收集整理 118 条隧道的 251 个涌水突泥灾害案例，从真实可靠的隧道工程及涌水突泥风险分析与评级资料中统计致灾因素与后果，构建隧道涌水突泥灾害案例库。

（3）对涌水突泥致灾因素进行辨识和分类，初步构建涌水突泥风险评估指标体系，选取的工程地质因素为地质构造、地层岩性、岩层厚度、岩层产状、围岩级别、地形地貌和岩溶发育情况 7 个评估指标，水文地质因素为降水及地下水、降雨入渗系数、节理裂隙与地表河流结合度 3 个评估指标，工程施工因素为施工扰动和支护情况 2 个评估指标，共计 12 个风险评估指标。案例的记录综合定量分析与定性描述，致灾因素等级的评定以定量数据为主，定量描述作为补充，使得隧道涌水突泥事故致灾因素等级的评定更为客观合理。

（4）以涌水突泥量和经济损失、人员伤亡、工期延误构建风险等级评估标准，结合定量分析与定性描述，综合判定各隧道涌水突泥事故的风险等级。

通过上述研究内容与工作，为下文隧道涌水突泥风险预测的数据来源提供理论基础并完成科学合理的原始数据积累。

3 隧道涌水突泥风险预测研究

3.1 样本数据量化与处理

3.1.1 样本数据量化

对国内外 251 个隧道涌水突泥灾害事故案例进行统计和分类，同时查阅《公路桥梁和隧道工程施工安全风险评估制度及指南解析》和《铁路隧道风险评估及管理暂行规定》等官方文件，对隧道涌水突泥的风险因素进行辨识，完成指标的分级量化工作。根据各指标特点及对涌水突泥的影响规律，确定隧道涌水突泥风险评估指标体系分别为地质构造 I_1 、地层岩性 I_2 、岩层厚度 I_3 、岩层产状 I_4 、围岩级别 I_5 、地形地貌 I_6 、岩溶发育情况 I_7 、降水及地下水 I_8 、降雨入渗系数 I_9 、节理裂隙与地表河流结合度 I_{10} 、施工质量 I_{11} 和支护设计，共计 12 个风险评估指标，将风险评估指标划分为 I、II、III、IV、V、VI 共 6 个等级，从低到高表示各评估指标引起隧道涌水突泥风险的可能性。根据隧道涌水突泥风险分级标准，涌水突泥风险等级 G 分为弱风险、中等风险、强风险和极强风险，分别对应风险等级 1、2、3、4，依据灾害发生后果的严重程度，判定涌水突泥风险等级。量化后得到的部分隧道涌水突泥风险预测样本数据集见表 3.1。

表 3.1 隧道涌水突泥风险预测数据集（部分）

Table 3.1 Risk prediction data set of tunnel water gushing and mud bursting (partial)													
序号	I_1	I_2	I_3	I_4	I_5	I_6	I_7	I_8	I_9	I_{10}	I_{11}	I_{12}	G
1	3	4	3	1	5	2	2	1	3	2	3	4	3
2	3	4	1	1	5	4	1	4	4	2	2	4	2
3	3	4	1	1	3	5	4	1	4	1	3	3	3
4	2	2	3	1	4	1	1	4	4	1	3	3	3
5	3	2	2	1	4	1	1	4	4	1	3	3	1
6	2	2	2	1	4	1	1	4	4	1	3	3	1
8	3	4	1	1	5	3	1	4	1	1	2	2	3
9	3	4	1	2	5	1	1	2	4	2	3	1	4
10	3	4	1	2	5	1	1	1	4	1	2	1	1
11	2	4	2	1	4	1	3	4	4	2	2	2	3
12	3	4	2	1	5	4	5	4	4	1	3	1	4
13	2	4	2	2	5	4	2	1	2	1	2	1	2
14	3	1	2	1	2	1	1	2	4	3	3	3	2
15	4	1	2	1	5	1	1	4	2	2	3	3	3
16	3	1	2	1	3	5	1	1	1	1	2	3	1
17	4	1	1	4	5	5	2	3	4	1	2	1	4
18	3	2	2	4	4	1	1	4	5	2	2	2	3
19	3	2	2	4	4	1	1	4	4	2	2	2	3
20	3	1	2	4	4	1	1	4	4	2	2	2	2

经统计,现有的 251 个隧道涌水突泥风险预测的样本数据中,各风险等级的样本分布并不均匀,图 3.1 至图 3.2 为不同风险等级的样本数情况,由图可知,251 个样本数据中风险等级为 1 的样本个数为 58,占比 23.1%;风险等级为 2 的样本个数为 39,占比 15.5%;风险等级为 3 的样本个数为 90,占比 35.9%;风险等级为 4 的样本个数为 64,占比 25.5%。




图 3.1 不同风险等级的样本数




图 3.2 不同风险等级的占比

Figure 3.1 Number of samples for different risk levels Figure 3.2 The proportion of different risk levels

3.1.2 样本数据预处理

(1) 样本数均衡化

由于收集整理的隧道涌水突泥真实灾害案例有限,实际数据往往会存在一定程度上的分布不均,而多数研究模型都是以样本数据均匀分布为假设前提,为不影响隧道涌水突泥风险评估模型的构建及预测效果,需要对该样本数据不均衡问题进行处理。常见的数据均衡处理方法包括随机欠采样(Random UnderSampling, RUS)、随机过采样(Random Oversampling, ROS)和合成少数类过采样技术(Synthetic Minority Over-sampling Technique, SMOTE)等。针对隧道涌水突泥风险预测数据集样本量较少的情况,从多数类样本中随机删除一些样本使得多数类样本和少数类样本达到平衡的 RUS 算法显然是不合适的。下面对合成过采样生成算法中的 ROS 算法和 SMOTE 算法进行介绍。

1) ROS 算法

ROS 算法在少数类样本上采用随机过采样处理,增加到与多类别的样本数相同的数目。ROS 算法流程见图 3.2, 主要步骤为:

①通过对训练数据集的读取,将其划分为 m 个少数类与 1 个多数类。将少数类的第 i 个样本数量记为 N_{minority}^i , 多数类样本数量记为 N_{majority} 。

②每个少数类与多数类之间的样本差异 $\Delta_{\text{minority}}^i$ 由式 (3.1) 计算:

$$\Delta_{\text{minority}}^i = N_{\text{majority}} - N_{\text{minority}}^i \cdots i \in [1, m] \quad (3.1)$$

③对于第 i 个少数类，类别内的样本以式（3.2）的方式被随机选择并进行复制直到产生 $\Delta_{\text{minority}}^i$ 个新样本：

$$x_{\text{new}} = x_n \quad (3.2)$$

其中， x_n 是从第 i 个少数类中随机选择的样本。

④重复第3步，直到全部少数类样本数目达到 N_{majority} 。




图 3.3 ROS 算法流程图

Figure 3.3 Flow chart of the ROS algorithm

2) SMOTE 算法

SMOTE 算法是一种以随机过采样算法为基础的改良过采样方法，其基本思想是通过 K 近邻找出少数类样本点的 K 个近邻样本点，在这些样本点当中选择与其相距最近的少数类样本点，按照一定的规则，即随机选择的 N 个邻近点进行差值乘上一个 $[0,1]$ 范围的阈值，线性的插入新的样本点，以此来达到均衡数据集的目的^[61]。SMOTE 算法相对于基础的过采样方法降低了过拟合问题，合成数据可以在训练过程中被用来增加模型的泛化能力和鲁棒性。

SMOTE 算法的具体过程描述如下：

输入：少数类样本集 $D_{\text{min}}(x_1, x_2, x_3, \dots, x_m)$ ， m 为少数类样本数量，采样倍率 N ，样本近邻数 k 。

Step1: 对于 D_{min} 中的每个少数类样本 $x_i(x_1, x_2, x_3, \dots, x_m)$ ，根据公式（3.3）计算其他少数类样本 x_j 的欧式距离。

$$\text{dist}(x_i, x_j) = \sqrt{\sum_{i=1}^m (x_{ii} - x_{ji})^2} \quad (3.3)$$

Step2: 按照从远到近的顺序，得到每个少数类样本 x_i 的 k 个近邻样本集合 D_{x_i} 。

Step3: 根据采样倍率 N 从 D_{x_i} 中随机选取样本，根据公式（3.4）合成新样本加入到原始少数类集合中。

$$x_{new} = x_i + rand(0,1) * |x_i - x_j| \quad (3.4)$$

其中, $rand(0,1)$ 代表 0 到 1 之间的任意数字。

Step4: 重复 N 次, 直至该数据集达到相对均衡为止。

Step5: 将采样后的集合 D_{min}^{new} 输出。

输出: 合成后的少数类样本集合 D_{min}^{new} 。

SMOTE 算法相对 ROS 算法而言, 具有如下优点:

①考虑样本间关系: SMOTE 算法在合成新的少数类样本时考虑了邻近样本之间的关系, 生成的合成样本更有可能代表真实数据分布, 而 ROS 算法只是简单地复制少数类样本, 这可能会导致一些重要信息被忽略或丢失, 特别是对于少数类样本的特征信息。

②减少过拟合风险: 由于 SMOTE 算法生成的合成样本是通过在特征空间内插值得到的, 可以减少模型对原始数据集的依赖性, 降低过拟合的风险, 而 ROS 算法可能会增加模型对复制样本的依赖性, 导致过拟合问题。

③数据增强效果更好: SMOTE 算法可以更好地扩展数据集的边界, 增加数据的多样性和丰富性。相比之下, ROS 算法只是简单地复制样本, 不能达到同样的数据增强效果。

根据原始数据集的特点, 选用 SMOTE 算法对样本数少的 1、2、4 三个涌水突泥风险等级进行过采样处理, 使得每个风险等级的样本数均为 90, 样本数均衡处理结果对比见图 3.4 和表 3.2。




图 3.4 样本数均衡处理结果对比图

Figure 3.4 Comparison of the result of sample number equalization

表 3.2 样本数均衡处理结果对比

Table 3.2 Comparison of the results of sample balancing

涌水突泥风险等级	原样本数	SMOTE 算法处理后的样本数
1	58	90
2	39	90
3	90	90
4	64	90

(2) 样本数据集划分

经 SMOTE 算法处理后的隧道涌水突泥风险预测数据集共计 360 条，每条样本记录中包括 12 个特征因子和 4 个分类标签，特征因子为选取的 12 个隧道涌水突泥风险评估指标，每条数据的分类标签为涌水突泥风险等级，等级为 1 表示风险性最弱，等级为 4 表示风险性最强。实验开始前将样本数据打乱，由于样本数据量相对较少，因此设置训练集与测试集的比值为 8:2，即选取 288 个样本作为训练集，剩下的 72 个样本作为测试集。打乱样本可以减小模型对数据顺序的依赖性，帮助模型更好地学习数据的分布特征，提高模型的泛化能力和稳定性，从而获得更好的训练效果。

(3) 样本数据归一化

对于隧道涌水突泥风险预测样本而言，不同的评估指标有不同的量纲，因此在模型训练前要将样本数据归一化到一定范围内。在机器学习中，最大最小归一化是一种常用的原始数据缩放方法^[62]，也称 Min-Max 标准化，其原理是将原始数据按照最小值和最大值进行线性变换，使得数据映射到[0,1]之间。这种方法的优点是能够保留原始数据的分布信息，同时消除不同特征之间的量纲影响，其数据转换过程如式(3.5)。

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)} \quad (3.5)$$

其中， x 表示原始数据值， x' 表示归一化后的数据值， $\min(x)$ 表示研究的样本数据中的最小值， $\max(x)$ 表示研究的样本数据中的最大值， $\max(x) - \min(x)$ 表示同组研究样本数据之间的极差值^[63]。

(4) 分类标签处理

在隧道涌水突泥风险预测样本中，需要进一步对样本数据的分类标签进行独热编码处理。在机器学习领域，独热编码（One-Hot Encoding）是一种处理分类数据的常用方法，其目的是通过对分类变量进行形式转换，提高算法的处理速度和模型的性能。假设有一个分类特征包含了 N 个可能的类别，独热编码会为每个类别分配一个唯一的二进制向量，该向量的长度等于类别的数量 N ；对于给定的某个类别，它对应向量中的一个元素会被标记为 1，而其他所有元素都是 0。这样，每个类别都被转换成了一个长度为 N 的向量，这个向量在一个位置上是 1，在其他位置上是 0。独热编码通过将分类变量转换为二进制向量，避免了算法错误地解释类别之间的数值顺序或大小关系，适用于该隧道涌水突泥风险等级预测问题。不同涌水突泥风险等级的独热编码见表 3.3。

表 3.3 不同风险等级的独热编码

Table 3.3 One-hot encoding for different risk levels

风险等级	独热编码
1	[1,0,0,0]
2	[0,1,0,0]
3	[0,0,1,0]
4	[0,0,0,1]

3.1.3 K 折交叉验证

K 折交叉验证 (K-fold cross-validation) 是一种在机器学习中常用的模型评估方法, 主要用于评估模型对未知数据的泛化能力, 这种方法尤其适用于数据量不是很大时, 可以更充分地利用有限的的数据, 减少模型评估的偶然性。K 折交叉验证示意图如图 3.5 所示, K 折交叉验证的基本步骤为:

(1) 数据集划分: 首先将全部数据集平均划分为 K 个大小相似的互斥子集 (即 $D = D_1 \text{ or } D_2 \text{ or } \dots \text{ or } D_i$), 其中每个子集 D_i 都应和数据集 D 中不同标签样本保持数据分布的一致性。

(2) 模型训练与验证: 每次选取其中的一个子集作为验证集, 剩余的 K-1 个子集合并后作为训练集, 训练模型并评估在验证集上的性能。

(3) 重复过程: 重复上一步 K 次, 每次选择不同的子集作为验证集, 以确保每个子集都有一次成为验证集的机会。

(4) 评估分析: 将这 K 次的模型性能评估结果 (如准确率、精准率、召回率等指标) 进行平均, 得到最终的模型性能估计。




图 3.5 K 折交叉验证示意图

Figure 3.5 K-fold cross-validation diagram

综合考量数据集的特点等因素,在模型训练过程中设置 6 折交叉验证,即将数据集分成 6 份,依次取其中 5 份作为训练集,剩下的 1 份作为验证集,重复这个过程 6 次,确保每份数据都被用作一次验证集,减少因特定数据集划分而引入的偶然性。在样本量相对较少的情况下,这样划分具有以下优势:

(1) 更多的训练数据:在 6 折交叉验证中,每次训练时使用的数据约占原始数据集的 83.3%,这意味着模型每次训练时可以学习到更多的数据,有利于提高模型的泛化能力。

(2) 评估的稳定性和准确性:通过增加折数,模型被评估的次数也增加了,这可以提供更多的评估结果,使得评估结果更加稳定和可靠。

(3) 减少过拟合的风险:由于每次训练使用的数据更多,模型有更多的机会学习数据的真实分布,而不是噪声或异常值,有助于减少模型过拟合的风险,尤其是在数据集不是特别大时。

(4) 模型参数优化:增加交叉验证的折数意味着模型需要在不同的训练集或测试集组合上表现良好才能获得较高的平均性能评分。这有利于模型的参数优化设置,提高模型在各种情况下的鲁棒性。

3.2 隧道涌水突泥风险预测相关算法

3.2.1 随机森林算法

随机森林(Random Forest, RF)是一种集成学习算法,常用于解决分类问题。随机森林最早于 1995 年由 Leo Breiman 和 Adele Cutler 提出,其原理是对训练数据进行随机抽样,通过构建多个决策树模型,将其合并实现分类预测,提高整体的预测准确性。随机森林算法还可以评估特征的重要性,通过计算特征在决策树中的采用频率和划分质量,得到每个特征对分类结果的贡献程度^[64]。

随机森林的构建包括两个重要的随机性过程:样本的随机选择和特征的随机选择。随机森林算法示意图如图 3.6。在分类任务中,随机森林一般通过以下步骤进行预测:

(1) 样本随机:假设训练数据集共有 M 个对象的数据,从样本数据中通过有放回抽样(Bootstrap)随机抽取 N 个样本,每一次取出的样本不完全相同,这些样本组成了决策树的训练数据集。

(2) 特征随机:假设每个样本数据都有 K 个特征,从所有特征中随机选取 $k(k < K)$ 个特征,选择最佳分割属性作为节点建立 CART 决策树,决策树成长期间 k 的大小始终不变。

(3) 重复前面的步骤,建立 m 棵 CART 决策树,这些树都要完全成长且不被修剪,形成森林。

(4) 根据这些树的预测结果进行投票,决定样本最后的预测类别。




图 3.6 随机森林算法示意图
Figure 3.6 Random forest algorithm schematic

3.2.2 BP 神经网络算法

BP 神经网络（Back Propagation Neural Network, BPNN）是一种应用十分广泛的人工神经网络模型。BP 神经网络基于反向传播算法，通过多层神经元网络构建复杂的非线性关系，每个神经元都与相邻层所有神经元相连，并且具有可调节的权重值。BP 神经网络可以通过调整网络结构和学习参数适应不同的数据分布和复杂的分类问题，并且利用多个计算单元并行计算，提高模型的计算效率。




图 3.7 三层 BP 神经网络结构图
Figure 3.7 Structure diagram of three-layer BP neural network

以三层感知器（即单一隐藏层）的 BP 神经网络为例，见图 3.7，对 BP 神经网络原理进行阐述。

①输入层向量： $X = (x_1, x_2, \dots, x_i, \dots, x_n)^T$

②隐藏层输出向量： $Y = (y_1, y_2, \dots, y_j, \dots, y_m)^T$

③输出层输出向量： $O = (o_1, o_2, \dots, o_k, \dots, o_l)^T$

④期望输出向量： $d = (d_1, d_2, \dots, d_k, \dots, d_l)^T$

⑤输入层到隐藏层之间的权值矩阵： $V = (v_1, v_2, \dots, v_j, \dots, v_m)$

⑥隐藏层到输出层之间的权值矩阵： $W = (\omega_1, \omega_2, \dots, \omega_j, \dots, \omega_l)$

对于输出层第 k 个神经元的输出值 O_k 可以表示为式 (3.6)。

$$O_k = f(net_k), k=1, 2, \dots, l \quad (3.6)$$

式中 net_k 为输出层第 k 个节点的输入值，表示前一层各节点加权后输出值 y_j 的总和，如式 (3.7)。

$$net_k = \sum_{j=0}^m \omega_{jk} y_j, k=1, 2, \dots, l \quad (3.7)$$

式中 ω_{jk} 为隐藏层第 j 个节点与输出层第 k 个节点之间的连接权重。隐藏层有式 (3.8) 和式 (3.9)。

$$y = f(net_j), j=1, 2, \dots, m \quad (3.8)$$

$$net_j = \sum_{i=0}^n v_{ij} x_i, j=1, 2, \dots, m \quad (3.9)$$

其中 v_{ij} 为输入层第 i 个节点到隐藏层第 j 个节点的连接权重。 $f(x)$ 是传递函数，实际应用中一般采用单极性 Sigmoid 函数，其函数表达式为 $f(x) = \frac{1}{1+e^{-x}}$ ，其导数形式为式 (3.10)。

$$f'(x) = f(x)[1 - f(x)] \quad (3.10)$$

(1) 网络误差与权值调整

输出值与期望值之间的均方误差函数 E ，可分别表示为式 (3.11) 和式 (3.12)。

$$E = \frac{1}{2}(d - O)^2 = \frac{1}{2} \sum_{k=1}^l [d_k - o_k]^2 \quad (3.11)$$

$$E = \frac{1}{2} \sum_{k=1}^l [d_k - f(net_k)]^2 = \frac{1}{2} \sum_{k=1}^l \left[d_k - f\left(\sum_{j=0}^m \omega_{jk} y_j\right) \right]^2 \quad (3.12)$$

其中， d_k 、 o_k 分别表示第 k 个输入向量在该输入向量维度上的输出值、第 k 个

输入向量在该输出维度上的实际值。在这一步的基础上,进一步展开至输出层:

$$E = \frac{1}{2} \sum_{k=1}^l \left\{ d_k - f \left[\sum_{j=0}^m \omega_{jk} f(\text{net}_j) \right] \right\}^2 = \frac{1}{2} \sum_{k=1}^l \left\{ d_k - f \left[\sum_{j=0}^m \omega_{jk} f \left(\sum_{i=0}^n \omega_{ji} v_{ij} x_i \right) \right] \right\} \quad (3.13)$$

$$\Delta \omega_{jk} = -\eta \frac{\partial E}{\partial \omega_{jk}}, j = 0, 1, 2, \dots, m; k = 1, 2, \dots, l \quad (3.14)$$

$$\Delta v_{ij} = -\eta \frac{\partial E}{\partial v_{ij}}, i = 0, 1, 2, \dots, m; j = 1, 2, \dots, m \quad (3.15)$$

其中,负号代表梯度下降,常数 $\eta \in (0,1)$ 表示比例系数,也就是学习率^[65],这些参数都会影响网络的输出结果。在整个推导过程中,对输出层有 $j=0,1,2,\dots,m; k=1,2,\dots,l$ 。对于隐藏层有 $i=0,1,2,\dots,n; j=1,2,\dots,m$ 。

(2) BP算法推导

$$\text{对于输出层,式(3.15)可写为: } \Delta \omega_{jk} = -\eta \frac{\partial E}{\partial \omega_{jk}} = -\eta \frac{\partial E}{\partial \text{net}_k} \frac{\partial \text{net}_k}{\partial \omega_{jk}}$$

$$\text{对于隐藏层,式(3.15)可写为: } \Delta v_{ij} = -\eta \frac{\partial E}{\partial v_{ij}} = -\eta \frac{\partial E}{\partial \text{net}_j} \frac{\partial \text{net}_j}{\partial v_{ij}}$$

对于隐藏层,利用式(3.12)可得到式(3.16)。

$$\frac{\partial E}{\partial y_j} = -\sum_{k=1}^l (d_k - o_k) f'(net_k) \omega_{jk} \quad (3.16)$$

将以上结果代入式(3.13)中,并应用式(3.10): $f(x) = \frac{1}{1+e^{-x}}$,得到式(3.17)和式(3.18)。

$$\delta_k^o = (d_k - o_k) o_k (1 - o_k) \quad (3.17)$$

$$\delta_j^y = \left[\sum_{k=1}^l (d_k - o_k) f'(net_k) \omega_{jk} \right] f'(net_j) = \left(\sum_{k=1}^l \delta_k^o \omega_{jk} \right) y_j (1 - y_j) \quad (3.18)$$

至此完成两个误差信号推导。将式(3.17)代回式(3.13),得到三层BP神经网络的学习算法中输入层与隐藏层神经元之间的连接权值、隐藏层与输出层神经元之间的连接权值调整计算公式分别为式(3.19)和式(3.20)。

$$\Delta v_{ij} = \eta \delta_j^y x_i = \eta \left(\sum_{k=1}^l \delta_k^o \omega_{jk} \right) y_j (1 - y_j) x_i \quad (3.19)$$

$$\Delta \omega_{jk} = \eta \delta_k^o y_j = \eta (d_k - o_k) o_k (1 - o_k) y_j \quad (3.20)$$

通过不断修改输入层与隐藏层之间、隐藏层与输出层之间节点的连接权值和阈值,BP神经网络可以有效地将误差沿梯度方向降低^[66],并通过反复训练和学习,最终确定最小误差相对应的网络各层连接权重与阈值,直到满足允许误差条件,模型训练结

束，BP神经网络模型训练的核心步骤如图 3.8 所示^[67]。




图 3.8 BP 神经网络模型训练的核心步骤

Figure 3.8 The core steps of BP neural network model training

3.2.3 支持向量机算法

支持向量机（Support Vector Machine，SVM）是一种常用的监督学习算法，尤其在处理分类任务时表现出色。在处理分类任务时，SVM 试图找到一个超平面，以最大化地分隔不同类别的数据。在处理不同的样本时，支持向量机有着不同的机理作用，当样本线性可分时，支持向量机可以进行快速有效的划分，线性可分的最优超平面见图 3.9。当样本线性不可分时，则需要将输入空间映射到高维空间，转化为线性可分，见图 3.10。




图 3.9 线性可分的最优超平面示意图

Figure 3.9 Diagram of the linearly separable optimal hyperplane




图 3.10 线性不可分的最优超平面示意图

Figure 3.10 Diagram of an optimal hyperplane that is linearly indivisible

(1) 核函数

SVM 中几种常见的核函数如下:

①线性核 (Linear Kernel), 见公式 (3.21)。

$$k(x_1, x_2) = \langle x_1, x_2 \rangle \quad (3.21)$$

线性核函数特征空间的维度与输入空间的维度相同, 该核函数适用于拥有大量的固定长度的特征表示的对象。

②多项式核 (Polynomial Kernel), 见公式 (3.22)。

$$\begin{cases} k(x_i, x_j) = (x_i^t x_j)^d, d \geq 1 \\ K(x_i, x_j) = (x_i \cdot x_j + 1)^d \end{cases} \quad (3.22)$$

多项式核函数针对非线性问题会将问题映射到维度高的空间进行解决, 多项式核函数是全局属性的。正如上式, 当参数 d 变大时, 得到映射后的维度也会变得越大, 这将会导致计算量增加。

③高斯核 (Gaussian Kernel), 即径向基核函数 (Radial Basis Function), 见式 (3.23)。

$$k(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right), \sigma > 0 \quad (3.23)$$

多项式核函数具有全局属性, 而高斯核相反, 它是局部属性。对掺杂有噪声的数据, 该核函数具有很强的抵抗能力, 其作用范围可以通过本身的一些参数计算得出。参数 σ 与作用范围反关系, 该参数越大, 范围效果也就越小。这正好印证了其局部属性。

④Sigmoid 核, 见公式 (3.24)。

$$k(x_i, x_j) = \tanh(\beta x_i^t x_j + \theta), \beta > 0 \quad (3.24)$$

在机器学习中, 逻辑回归模型便是利用 Sigmoid 函数。

(2) 多分类

原始的 SVM 是为二分类问题设计的, 在多分类任务中, SVM 需要通过特定的策略处理多个类别, 具体有两种策略: 一对多 (OneVsRestClassifier, OvR) 和一对一 (OneVsOneClassifier, OvO)。

①一对多 (OvR): 对于 K 个类别的问题, 训练 K 个不同的 SVM 分类器。每个分类器将一个类别的样本与其他所有类别的样本区分开。在预测时, 选择得分最高的分类器类别作为最终预测结果。

②一对一 (OvO): 对于 K 个类别的问题, 每两个类别之间训练一个分类器。在预测时, 对每个分类器的投票结果进行统计, 选取最终得票最多的类别作为预测结果。

3.2.4 粒子群算法

粒子群优化算法 (Particle Swarm Optimization, PSO) 是一种基于群体智能的优化算法, 该算法由 Eberhart 和 Kennedy 于 1995 年提出。PSO 算法的基本思想来源于对鸟类捕食行为的观察和模拟。PSO 算法模拟了鸟群或鱼群等动物社会的行为, 通过个体之间的协作和信息共享寻找解空间中的最优解。PSO 算法已被广泛应用于函数优化、神经网络训练、模糊系统控制以及其他科学和工程领域的优化问题。

假定有一个 N 维空间, 有一个种群数量为 P 的群落, 则粒子 j 在 N 维空间的位置如式 (3.25)。

$$Y_j = (y_{j1}, y_{j2}, \dots, y_{jn}) \quad (3.25)$$

粒子 i 在 N 维的搜索速度如式 (3.26)。

$$V_j = (v_{j1}, v_{j2}, \dots, v_{jn}) \quad (3.26)$$

个体极值 (即粒子 j 在 N 维所经历的最优位置) 如式 (3.27)。

$$P_{jbest} = (p_{j1}, p_{j2}, \dots, p_{jn}) \quad (3.27)$$

全局极值 (全部粒子所经历的最优位置) 如式 (3.28)。

$$P_{best} = (p_1, p_2, \dots, p_n) \quad (3.28)$$

每个粒子根据式 (3.29)、式 (3.30) 和式 (3.31) 调节自己的速度及位置:

$$v_{jn}(g+1) = w \cdot v_{jn}(g) + C_1 \cdot R_1(g) \cdot (P_{jbest} - Y_j(g)) + C_2 \cdot R_2(g) \cdot (P_{best}(g) - Y_j(g)) \quad (3.29)$$

$$\begin{cases} \mathbf{V}_J = \mathbf{V}_{\max}, \mathbf{V}_J \geq \mathbf{V}_{\max} \\ \mathbf{V}_J = -\mathbf{V}_{\max}, \mathbf{V}_J < -\mathbf{V}_{\max} \end{cases} \quad (3.30)$$

$$y_{jn}(g+1) = y_{jn}(g) + v_{jn}(g+1) \quad (3.31)$$

式中, w 为惯性系数, C_1 、 C_2 为加速常数, R_1 、 $R_2 \in [0,1]$ 。

调整自身最优位置 P_{jbest} 和群体最优位置 P_{best} :

$$P_{jbest}(g+1) = \begin{cases} P_{jbest}(g), f(x_j(g+1)) \geq f(P_{jbest}(g)) \\ x_j(g+1), f(x_j(g+1)) < f(P_{jbest}(g)) \end{cases} \quad (3.32)$$

$$p_{jbest}(g) \in \{p_{0best}(g), p_{1best}(g), \dots, p_{(n-1)best}(g), p_{nbest}(g)\} \quad (3.33)$$

$$|f(p_{best}(g))| = \min \{f(p_{0best}(g)), f(p_{1best}(g)), \dots, f(p_{nbest}(g))\} \quad (3.34)$$

PSO 算法基本流程见图 3.11。




图 3.11 PSO 算法基本流程图
Figure 3.11 PSO algorithm basic flow chart

3.3 隧道涌水突泥风险预测模型

选用随机森林、BP 神经网络和支持向量机算法构建隧道涌水突泥风险预测模型，并采用粒子群算法分别对 BP 神经网络和支持向量机模型进行优化，以期进一步提高在该隧道涌水突泥风险预测样本上的风险等级预测准确率。

3.3.1 基于 RF 算法的隧道涌水突泥风险预测模型

在对隧道涌水突泥风险预测的样本数据进行预处理后，经反复测试，构建随机森林模型的主要超参数最优值设置见表 3.4，将最优超参数值放入 `TreeBagger()`函数训练随机森林模型，建立样本数据集中特征和标签之间的关联。

表 3.4 RF 模型的主要超参数设置

Table 3.4 Major hyperparameter settings for RF model

超参数	说明	值
n_estimators	cart 决策树数目	50
max_depth	树的最大深度	10
min_samples_split	叶子节点最少样本数	1

RF 模型误差曲线见图 3.12，从图中可知，随着决策树数目的增加，随机森林算法在训练集上的误差不断降低，当决策树数目为 20 左右时，RF 模型的误差曲线开始趋于平稳，此时误差为 0.04538，随机森林模型的分类预测性能较好。

图 3.13 为隧道涌水突泥风险各评估指标对于预测结果输出的重要性。从图中可知，地质构造、地层岩性、岩溶发育情况、节理裂隙与地表河流结合度和支护情况等

因素对于隧道涌水突泥风险等级预测结果的影响较大，与实际情况相吻合，在隧道施工过程中需重点关注。




图 3.12 RF 模型误差曲线图

Figure 3.12 RF model error curve




图 3.13 评估指标重要性

Figure 3.13 Evaluating the importance of indicators

图 3.14 至图 3.15 为 RF 模型的预测结果，图中的突刺代表预测错误，涌水突泥风险预测等级与真实等级不一致。对预测结果进行排序处理后，直观可得模型在训练集上的预测准确率达到 94.79%，在测试集上的预测准确率为 86.11%。




图 3.14 训练集预测结果

Figure 3.14 The predictive results of the training set




图 3.15 测试集预测结果

Figure 3.15 Test the predicted results of the test set

3.3.2 基于 BP 神经网络的隧道涌水突泥风险预测模型

(1) BP 神经网络结构设计

BP 神经网络通常包含输入层、隐藏层（一个或多个）和输出层。每一层包含若干个神经元（即节点），相邻层之间的神经元通过权重连接。

1) 输入层节点数：输入层节点数通常由输入数据的特征数确定，每个输入节点对应输入数据的一个特征。在隧道涌水突泥风险预测的样本数据集中，共有 12 个输入特征，由此确定输入层节点数为 12。

2) 输出层节点数: 在分类预测问题中, 输出层节点数通常等于类别的数量。在该样本数据集中, 共有 4 个预测类别, 由此确定输出层节点数为 4。

3) 隐藏层个数和节点数

提取输入层的特征, 可以有一个或多个隐藏层。隐藏层的层数和节点数是影响 BP 神经网络性能的关键因素。隐藏层个数和节点数越多, 网络的学习能力越强, 预测精度越高, 但也会使得训练时间过长, 容易导致过拟合。为使模型达到最佳的训练效果, 在满足结果精度的前提下, 应尽可能选取最紧凑的网络结构同时减少隐藏层的节点数。通常情况下, 应考虑 3 层 BP 神经网络 (即一个隐藏层), 同时选择合适的隐藏层节点数, 使得误差尽可能降低。由此, 确定单一隐藏层的 BP 神经网络模型结构。

BP 神经网络隐藏层节点数没有标准的确定规则, 但通常存在一个最佳隐藏层节点数, 范围一般在输入层节点数和输出层节点数之间, 也可以由公式法进行初步选取, 再由实验测试比较得出最佳隐藏层节点数。

① 公式初选

最佳隐藏层节点数 m 的选取范围经验公式如式 (3.35)。

$$m = \sqrt{n + o} + k \quad (3.35)$$

式中, n 为输入层节点数; o 为输出层节点数; k 的取值范围为 1~10 之间的整数。

将已确定的输入层和输出层节点数带入公式计算可得隐藏层节点数 m 的取值范围为 [5, 14]。

② 实验测试

通过实验测试比较不同隐藏层节点数在样本数据集上的均方误差值 (MSE), 选取 MSE 值最小时的隐藏层节点数作为 BP 神经网络模型的最佳隐藏层节点数。不同隐藏层节点数的 MSE 值见表 3.5, 变化曲线见图 3.16。

表 3.5 不同隐藏层节点数的 MSE 值

Table 3.5 Comparison results of MSE with different number of hidden layer nodes

隐藏层节点数	MSE 值
5	0.3799
6	0.2437
7	0.2863
8	0.3546
9	0.2796
10	0.3025
11	0.2513
12	0.3888
13	0.3134
14	0.3301




图 3.16 不同隐藏层节点数的 MSE 值变化曲线图

Figure 3.16 MSE value change curve of the number of nodes in different hidden layers

由图表可知,当隐藏层节点数为 6 时,此时在样本数据集上具有最小的 MSE 值,为 0.2437,由此确定 BP 神经网络模型的结构为 12-6-4,见图 3.17,图中 w 为权重, b 为偏置。




图 3.17 BPNN 模型结构图

Figure 3.17 BPNN model structure diagram

(2) BP 神经网络参数及函数设置

BP 神经网络训练超参数设置见表 3.6。

表 3.6 BP 神经网络训练超参数设置

Table 3.6 BP neural network training hyperparameter setting

超参数	说明	值
epochs	最大迭代次数	1000
goal	目标训练误差	10^{-6}
lr	学习率	0.01
gradient	梯度阈值	10^{-7}

BP 神经网络模型中的相关函数设置如下: 隐藏层的激活函数采用 ReLU 函数; 输出层的激活函数采用 softmax 函数, 该函数可以将输出转换为概率分布, 表示每个类别的预测概率; 损失函数采用交叉熵损失函数 (Cross-Entropy Loss), 以有效地衡量预测概率分布与真实标签之间的差异; 优化器采用 adam 函数。通过训练, BP 神经网络可以学习到将输入特征映射到多个类别标签上的非线性关系, 从而实现对新样本的有效分类。

图 3.18 展示了训练过程中 BP 神经网络对于样本数据按比例随机选取训练集、验证集、测试集以及总体结果的回归情况。图中回归值 R 也称相关系数，表示真实值和预测值之间的相关性， R 越接近于 1，表明二者关系越密切，越接近于 0，表明二者关系随机性越大^[68]。由图及图中数据可知，BP 神经网络模型在训练集、验证集、测试集和总体结果上的 R 值分别为 0.95741、0.92944、0.95892、0.95344，均比较接近于 1，表明涌水突泥风险等级的预测值和真实值相关程度非常大，进一步验证了模型参数及函数选择的正确性。




图 3.18 回归图

Figure 3.18 Regression graph

(3) 仿真测试

模型训练结束后，进行仿真测试，得到训练集和测试集的预测值。图 3.19 至图 3.20 为 BP 神经网络评估模型的预测结果，模型在训练集上的预测准确率为 98.61%，在测试集上的预测准确率为 88.89%。




图 3.19 训练集预测结果




图 3.20 测试集预测结果

Figure 3.19 The predictive results of the training set Figure 3.20 Test the predicted results of the test set

3.3.3 基于 SVM 算法的隧道涌水突泥风险预测模型

构建支持向量机模型对隧道涌水突泥风险等级进行预测的实验过程主要步骤如下：

- (1) 完成实验数据的相关准备工作；
- (2) 选择策略

根据 3.2.3 节中对多分类及其策略的介绍，一对多策略是指对每一个类别都用一个分类器进行划分，由于需要对隧道涌水突泥风险进行四个等级的分类预测，使用一对多的策略就是将样本中的涌水突泥风险等级具体划分为 1 级类别和非 1 级类别、2 级类别和非 2 级类别、3 级类别和非 3 级类别、4 级类别和非 4 级类别，共 4 个二分类完成涌水突泥风险等级划分。而一对一策略则是指为每一对类别使用一个分类器进行划分，以本研究为例，采用一对一策略会将涌水突泥风险等级划分为 1 级类别和 2 级类别、1 级类别和 3 级类别、1 级类别和 4 级类别、2 级类别和 3 级类别、2 级类别和 4 级类别、3 级类别和 4 级类别共 6 个二分类完成涌水突泥风险等级划分。在进行预测划分时，以最终投票数的多少预测涌水突泥风险等级，如果出现票数相等时，选择置信度最高的类。相较于一对多策略而言，选取一对一策略的计算时间更久，时间复杂度更高，经分析后采用 SVM 进行隧道涌水突泥风险等级预测时，选用一对多策略。

- (3) 核函数及超参数设置

SVM 的核函数通常有三类：线性核 (Linear Kernel)、多项式核 (Polynomial Kernel) 和径向基函数核 (Radial Basis Function Kernel, RBF)，经反复实验，最终选取径向基函数核构建 rbf-svm 模型。选定 rbf 核函数后，详细超参数设置见表 3.7。

表 3.7 SVM 模型超参数设置
Table 3.7 SVM model hyperparameter setting

超参数	说明	值
g	核函数中的 gama 函数参数	0.01
c	惩罚因子	1
cache size	cache 内存大小(m)	40MB
e	设置允许的终止判据	0.001
h	是否使用启发式	1

图 3.21 至图 3.22 为 SVM 模型的预测结果,对预测结果进行排序处理后,模型在训练集上的预测准确率达到 90.63%,在测试集上的预测准确率为 87.5%。




图 3.21 训练集预测结果




图 3.22 测试集预测结果

Figure 3.21 The predictive results of the training set Figure 3.22 Test the predicted results of the test set

3.3.4 基于 PSO-BP 算法的隧道涌水突泥风险预测模型

由于 BP 神经网络是通过随机初始化得到网络权重和偏置值后进行训练,容易陷入局部最优的情况,影响模型的最终性能,因此选择采用 PSO 算法确定其最优初始权重和偏置值,通过 PSO 算法的全局搜索能力自适应地调整搜索策略,找到合适的权重和偏差,从而增强 BP 神经网络的收敛速度和学习水平,提升模型的分类预测效果。PSO-BP 算法流程见图 3.23。

实验中使用 PSO 算法优化 3.3.2 节中构建的 BP 神经网络基本模型,原始 BP 神经网络模型中的结构设计、相关参数和函数设置不做改变。经反复测试后,PSO 算法的最优超参数设置见表 3.8。模型训练过程中,当学习因子 c_1 、 c_2 均为 4.492 时,模型表现效果最佳。




图 3.23 PSO-BP 算法优化流程图

Figure 3.23 PSO-BP algorithm optimizes flow chart

表 3.8 PSO 算法的最优超参数设置

Table 3.8 Optimal hyperparameter setting of PSO algorithm

超参数	说明	值
c_1	初始学习因子	5
c_2	初始学习因子	5
maxgen	初始种群更新次数	50
sizepop	初始种群规模	5
$V_{\max}$	最大速度	1.0
$V_{\min}$	最小速度	-1.0
$pop_{\max}$	最大边界	2.0
$pop_{\min}$	最小边界	-2.0

PSO-BPNN 模型训练过程中对样本数据按比例随机选取训练集、验证集、测试集以及总体结果的回归情况见图 3.24。由图及图中数据可知，PSO-BPNN 预测模型在训练集、验证集、测试集和总体结果上的 R 值分别为 0.99438、0.9457、0.9695、0.98339，均接近于 1，表明涌水突泥风险等级的预测值和真实值的相关程度非常强，说明了模型参数选择的合理性。

仿真实验后，PSO-BPNN 模型迭代误差变化见图 3.25。由于模型训练过程中进行了 6 折交叉验证，通过计算训练集上对风险等级类别预测的错误率，可以关联模型迭代过程中的适应度值。从图中可知，随着粒子群迭代次数不断增加，模型适应度值和错误率逐渐降低，在迭代到第 46 次时收敛到最小，错误率为 0.03472。




图 3.24 回归图

Figure 3.24 Regression graph




图 3.25 PSO-BP 模型迭代误差变化图

Figure 3.25 Iterative error variation diagram of PSO-BP model

图 3.26 至图 3.27 为 PSO-BPNN 模型的预测结果，模型在训练集上的预测准确率为 96.53%，在测试集上的预测准确率为 94.44%，优化后的评估模型相较原始 BPNN 模型的预测准确率提高了 5.55%。




图 3.26 训练集预测结果




图 3.27 测试集预测结果

Figure 3.26 The predictive results of the training set Figure 3.27 Test the predicted results of the test set

3.3.5 基于 PSO-SVM 算法的隧道涌水突泥风险预测模型

SVM 本质上是一个二分类器，直接应用于多分类（如四分类）任务需要采用一对多（OvR）或一对一（OvO）等策略，这会增加模型的复杂度和计算成本。PSO 可以帮助优化这些多分类策略的实现，以提高整体的分类预测性能。PSO-SVM 的算法流程见图 3.28。




图 3.28 PSO-SVM 算法流程图

Figure 3.28 Flow chart of PSO-SVM algorithm

使用 PSO 算法对 3.3.3 节中构建的 SVM 基本模型进行优化, 原始 SVM 模型中的相关参数和函数设置不做改变。经反复测试后, PSO-SVM 算法的超参数设置见表 3.9, 经过寻优后最佳参数 c 为 3.6086, 最佳参数 g 为 18.7565。

表 3.9 PSO-SVM 算法的超参数设置

Table 3.9 Hyperparameter setting of PSO-SVM algorithm

超参数	说明	值
pso_option.c1	pso 参数局部搜索能力	1.5
pso_option.c2	pso 参数全局搜索能力	1.7
pso_option.maxgen	最大进化数量	100
pso_option.sizepop	种群最大数量	5
pso_option.k	速率和粒子的关系($V = kX$)	0.6
pso_option.wV	速率更新公式中速度前面的弹性系数	1
pso_option.wP	种群更新公式中速度前面的弹性系数	1
pso_option.v	交叉验证次数	6
pso_option.popcmax	SVM 参数 c 变化的最大值	100
pso_option.popcmin	SVM 参数 c 变化的最小值	0.1
pso_option.pogpmax	SVM 参数 g 变化的最大值	100
pso_option.pogpmin	SVM 参数 g 变化的最小值	0.1

仿真实验后, PSO-SVM 的模型迭代适应度曲线见图 3.29, 同样用错误率与适应度值进行关联。从图 3.29 中可知, 随着粒子群迭代次数不断增加, 交叉验证的错误率不断降低, 在粒子群算法迭代到第 17 次时错误率不再降低, 达到收敛状态, 此时错误率为 0.02778。




图 3.29 适应度曲线图

Figure 3.29 Fitness graph

图 3.30 至图 3.31 为 PSO-SVM 评估模型的预测结果, 模型在训练集上的预测准确率为 99.3%, 在测试集上的预测准确率为 97.22%, 优化后的评估模型相比原始 SVM

模型的预测准确率提高了 9.72%。




图 3.30 训练集预测结果




图 3.31 测试集预测结果

Figure 3.30 The predictive results of the training set Figure 3.31 Test the predicted results of the test set

3.4 模型分析与评价

对于各隧道涌水突泥风险预测模型，选用混淆矩阵（Confusion Matrix）、准确率（Accuracy）、精准率（Precision）、召回率（Recall）和 F1 值对模型性能进行综合分析评价。

3.4.1 混淆矩阵

对于建立的隧道涌水突泥风险预测模型，其预测结果共有四种情况，见表 3.10。

表 3.10 模型预测的 4 种情况

Table 3.10 4 scenarios predicted by the model

真实结果	预测结果	
	正类	反类
正类	True Positive (TP)	False Negative (FN)
反类	False Positive (FP)	True Negative (TN)

真正类（True Positive，TP）表示模型将正类正确地预测为正类的样本数量；假反类（False Negative，FN）表示模型将正类错误地预测为反类的样本数量；假正类（False Positive，FP）表示模型将反类错误地预测为正类的样本数量；真反类（True Negative，TN）表示模型将反类正确地预测为反类的样本数量。四种预测结果之和为样本总数量。

混淆矩阵（Confusion Matrix）常用于对分类模型的性能评估，反映模型在各个类别上的表现，展示模型的预测结果与真实标签之间的差异，同时揭示哪些预测类别之间容易发生混淆。

对于预测 4 个涌水突泥风险级别的多分类问题,混淆矩阵将是一个 4×4 的矩阵,其中矩阵的行表示真实风险等级,列表示预测风险等级。矩阵的对角线元素表示分类正确的数量,即实际风险等级和预测风险等级相同的情况;非对角线上的元素表示分类预测错误的数量,即实际风险等级和预测风险等级不一致的情况。

RF、BPNN、SVM、PSO-BPNN 和 PSO-SVM 预测模型的训练集混淆矩阵和测试集混淆矩阵见图 3.32 至图 3.41。




图 3.32 RF 的训练集混淆矩阵

Figure 3.32 RF training set confusion matrix




图 3.33 RF 的测试集混淆矩阵

Figure 3.33 RF test set confusion matrix




图 3.34 BPNN 的训练集混淆矩阵

Figure 3.34 BPNN training set confusion matrix




图 3.35 BPNN 的测试集混淆矩阵

Figure 3.35 BPNN test set confusion matrix




图 3.36 SVM 的训练集混淆矩阵

Figure 3.36 SVM training set confusion matrix




图 3.37 SVM 的测试集混淆矩阵

Figure 3.37 SVM test set confusion matrix




图 3.38 PSO-BP 的训练集混淆矩阵

Figure 3.38 PSO-BP training set confusion matrix




图 3.39 PSO-BP 的测试集混淆矩阵

Figure 3.39 PSO-BP test set confusion matrix




图 3.40 PSO-SVM 的训练集混淆矩阵

Figure 3.40 PSO-SVM training set confusion matrix




图 3.41 PSO-SVM 的测试集混淆矩阵

Figure 3.41 PSO-SVM test set confusion matrix

3.4.2 准确率

准确率（Accuracy）是用于评价分类预测模型性能的一项重要指标。它表示模型在所有样本中正确预测的比例，即分类预测正确的样本数量与总样本数量的比值，计算公式如式（3.36）。

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.36)$$

RF、BPNN、SVM、PSO-BPNN 和 PSO-SVM 模型在样本数据集上对隧道涌水突泥风险等级预测的准确率（保留两位小数）见表 3.11。

表 3.11 各模型预测准确率

Table 3.11 Prediction accuracy of each model

预测模型	准确率	
	训练集	测试集
RF	94.79%	86.11%
BPNN	98.61%	88.89%
SVM	90.63%	87.5%
PSO-BPNN	96.53%	94.44%
PSO-SVM	99.31%	97.22%

从表中可知，经实验测试选取最优参数构建的各风险预测模型中：

（1）RF、BPNN、SVM 各模型在测试集上的风险等级预测准确率分别为 86.11%、88.89%、87.5%。

（2）使用 PSO 算法对 BPNN 和 SVM 基本模型进行优化，构建的 PSO-BPNN 和 PSO-SVM 模型在测试集上的风险等级预测准确率分别为 94.44%和 97.22%，PSO-BPNN 模型相较 BPNN 模型在测试集上的预测准确率提高了 5.55%，PSO-SVM 模型相较 SVM 模型在测试集上的预测准确率提高了 9.72%。

（3）各隧道涌水突泥风险预测模型中，PSO-SVM 模型在该样本测试集上的风险等级预测准确率最高，预测效果最好；PSO-SVM 模型在该数据集上具有较好的涌水突泥风险预测能力。

3.4.3 其他重要评价指标

准确率是评价分类预测模型性能的重要指标之一，但在某些情况下可能不足以全面评估模型的表现。因此，在实际应用中，需要综合考虑准确率和其他评价指标，以全面评估模型的性能。通过观察各预测模型的混淆矩阵，可以计算出其他常用的性能指标，包括精准率、召回率和 F1 值。

精准率是所有预测为正类的样本中真正类的比例，精准率越高表示模型将负类误判为正类的概率越低；计算公式如式（3.37）。

$$precision = \frac{TP}{TP + FP} \quad (3.37)$$

召回率是所有真正类中被正确预测为正类的比例，召回率越高表示模型漏掉正类的概率越低；计算公式如式（3.38）。

$$recall = \frac{TP}{TP + FN} \quad (3.38)$$

F1 值是衡量分类模型的精确度指标，兼顾了精准率和召回率^[69]，可以看作是二者均值的调和平均数，其范围在[0,1]之间，越接近 1 模型的性能越好，反之则越差，计算公式如式（3.39）。

$$F1 = \frac{2 \times precision \times recall}{precision + recall} \quad (3.39)$$

由测试集混淆矩阵计算得出各模型在不同涌水突泥风险等级上的预测精准率、召回率和 F1 值及其平均值见表 3.12 至表 3.16。

表 3.12 RF 模型评价指标值

Table 3.12 RF model evaluation index value

风险等级	精准率	召回率	F1 值
I	93.8%	93.8%	93.8%
II	80%	92.3%	85.71%
III	100%	66.7%	80.02%
IV	76%	100%	86.36%
平均值	87.45%	88.2%	86.47%

表 3.13 BP 模型评价指标值

Table 3.13 BP model evaluation index value

风险等级	精准率	召回率	F1 值
I	100%	93.8%	96.8%
II	94.1%	100%	96.96%
III	85%	81%	82.95%
IV	80%	84.2%	83.69%
平均值	89.78%	89.75%	90.1%

表 3.14 SVM 模型评价指标值

Table 3.14 SVM model evaluation index value

风险等级	精准率	召回率	F1 值
I	94.4%	94.4%	94.4%
II	81.3%	92.9%	86.67%
III	83.3%	78.9%	81.04%
IV	90%	85.7%	87.8%
平均值	87.25%	87.98%	87.48%

表 3.15 PSO-BPNN 模型评价指标值

Table 3.15 PSO-BPNN model evaluation index value

风险等级	精准率	召回率	F1 值
I	94.7%	94.7%	94.7%
II	95.7%	95.7%	95.7%
III	100%	87.5%	93.33%
IV	87.5%	100%	93.33%
平均值	94.48%	94.48%	94.27%

表 3.16 PSO-SVM 模型评价指标值

Table 3.16 PSO-SVM model evaluation index value

风险等级	精准率	召回率	F1 值
I	95.2%	100%	97.54%
II	100%	95%	97.44%
III	100%	92.9%	96.32%
IV	94.7%	100%	97.28%
平均值	97.5%	96.98%	97.15%

在涌水突泥风险等级预测的精准率均值评价指标中, RF 模型最高为 87.45%, BPNN 模型最高为 89.78%, SVM 模型最高为 87.25%; 在召回率均值评价指标中, RF 模型最高为 88.2%, BPNN 模型最高为 89.75%, SVM 模型最高为 87.98%; 在 F1 均值评价指标中, RF 模型最高为 86.47%, BPNN 模型最高为 90.1%, SVM 模型最高为 87.48%;

BPNN 预测模型经过 PSO 算法优化后, 涌水突泥风险等级的预测精准率均值从 89.78%提升到 94.48%, 提升了 4.7%, 召回率均值从 89.75%提升到 94.48%, 提升了 4.73%, F1 均值由 90.1%提升到 94.27%, 提升了 4.17%; SVM 预测模型经过 PSO 算法优化后, 涌水突泥风险等级的预测精准率均值从 87.25%提升到 97.5%, 提升了 10.25%, 召回率均值从 87.98%提升到 96.98%, 提升了 9%, F1 均值由 87.48%提升到 97.15%, 提升了 9.67%。

从以上各表中可知, 在 RF、BPNN、SVM、PSO-BPNN 和 PSO-SVM 各风险等级预测模型中, PSO-SVM 模型在隧道涌水突泥风险预测数据集上的综合预测表现最好。

3.5 本章小结

本章主要内容总结如下:

(1) 在隧道涌水突泥风险研究的系统理论上, 对隧道涌水突泥灾害案例库中的 251 个涌水突泥记录依据风险评估指标体系及分级、风险等级划分标准进行数据量化, 得到隧道涌水突泥风险预测的样本数据集。针对原始样本个数较少且样本中各涌水突泥风险等级分布不均的问题, 采用 SMOTE 算法实现样本数据均衡化并扩充一定的样本数据量。

(2) 选取 RF、BPNN 和 SVM 三种机器学习算法构建隧道涌水突泥风险等级预

测模型，根据样本特点在模型训练过程中采用 6 折交叉验证避免模型过拟合。通过混淆矩阵、准确率、精准率、召回率和 F1 值进行模型性能评价，经反复实验测试后选取最优参数的各模型中，RF、BPNN 和 SVM 模型在该样本测试数据集上的风险等级预测准确率分别为 86.11%、88.89%和 87.5%，综合其他模型性能评价指标，表明 RF、BPNN 和 SVM 模型在隧道涌水突泥风险预测样本数据集上的预测效果较好。

（3）为进一步提高模型预测率，选用 PSO 算法分别对 BPNN 和 SVM 原始模型进行优化，构建基于 PSO-BP 和 PSO-SVM 算法的隧道涌水突泥风险预测模型。预测结果表明，PSO-BPNN 和 PSO-SVM 模型在测试样本上的风险等级预测准确率分别为 94.44%和 97.22%，相比原始模型分别提高了 5.55%和 9.72%；综合其他模型性能评价指标，在隧道涌水突泥风险预测各模型中，PSO-SVM 模型在该样本数据集上具有最佳的预测性能，预测效果表现最好。

4 隧道涌水量预测研究

在第 2、3 章对隧道涌水突泥的致灾因素、灾害后果及风险等级预测进行研究的基础上,根据有关文献资料,本章进一步收集整理对涌水突泥风险等级影响较大的隧道涌水量影响因素及相关数据,并使用机器学习算法对隧道涌水量进行预测,以期准确认识隧道涌水的成因,把握隧道涌水发生的规律,获得更加精准的涌水量预测方法,对涌水突泥风险有更加深入的认识。

4.1 隧道涌水量预测指标

通过搜集大量隧道涌水突泥案例的基础工作及查阅与隧道涌水量预测相关的专业文献,得出不同于隧道涌水突泥风险等级预测的多评估指标,对隧道涌水量的预测应尽量选择关联性不强的影响因子,预测指标过多不仅需要耗费大量的时间和成本获取相应的数据,而且容易导致预测结果的准确性下降,而预测指标过少也会使得预测效果不佳。在已发表的有关隧道涌水量预测的研究文献中^[70-71],收集整理得到一份隧道涌水量样本,其中选取了隧道埋深(H)、地下水位(h)、岩石质量指标(Rock Quality Designation, RQD)和岩层含水性(W)作为预测评估指标,均已被证明在实际工程实践中对隧道涌水量的影响很大。

(1) 隧道埋深

隧道埋深定义为隧道开挖断面顶部至自然地面的垂直距离,通常用于描述隧道在地下的深度。根据《水利水电工程地质勘察规范》文件,隧道根据埋深可划分为浅埋隧道、深埋隧道和超深隧道,其分类见表 4.1。

表 4.1 隧道埋深划分表
Table 4.1 Tunnel depth division table

隧道埋深(H)	隧道类型
$H < 300\text{m}$	浅埋隧道
$300\text{m} \leq H < 500\text{m}$	深埋隧道
$H \geq 500\text{m}$	超深隧道

(2) 地下水位

地下水位是指地下水面的高程位置,是地下水在地下岩石和土壤中的自然水平面。地下水位高度的变化会受到降雨、蒸发、地形、地质构造等因素的影响。地下水位是影响隧道涌水量的主要动态因素之一,当地下水位较高时,地下岩石或土壤中的孔隙和裂隙中存储的水被压力推动,容易形成涌水现象,从而导致涌水量的增加。相反,当地下水位较低时,压力差减小,涌水量也可能减少。

(3) 岩石质量指标

RQD 即岩石质量指标,由美国人迪尔(Deere)提出,该指标被广泛地应用于评

价岩体的完整性，并作为岩石质量分级的一项重要指标，其定义为岩芯中长度等于或大于 10cm 的连续、无损的柱状岩芯段之和与钻孔进尺总长度之比，计算公式如式（4.1）。

$$RQD = \frac{\sum l_{\geq 10cm}}{L} \times 100\% \tag{4.1}$$

RQD 值越高表示岩芯的完整性越好，岩石质量越高；反之，则表示岩芯的完整性越差，岩石质量越差。表 4.2 是 RQD 分级表。

表 4.2 RQD 分级表
Table 4.2 RQD Grading table

RQD(%)	岩体质量评价
<25	极差
25-50	差
50-75	较好
75-95	好
>95	极好

（4）岩层含水性

岩层含水性也是影响隧道涌水量大小的重要指标之一。例如，灰岩、石灰岩和白云岩的含水性大于泥岩和页岩的含水性；强溶解度含水层的涌水发生概率远大于弱溶解度含水层。

4.2 隧道涌水量数据分析

4.2.1 样本数据统计

收集整理的隧道涌水量样本共计 600 条数据，均来自近几十年国内外公路隧道、铁路隧道和水工隧洞等有文献资料记录的真实涌水突泥案例统计，该样本中的数据均为专业研究人员在前人工作基础上结合自身研究所得的有效参数，具有真实性和可信度。隧道涌水量数据集的部分样本见表 4.3。

表 4.3 隧道涌水量数据集（部分）
Table 4.3 Tunnel inflow data set (partial)

序号	H(m)	h(m)	RQD(%)	W(m³/hm)	WI(m³/h)
1	55	23	67	3.2	73.6
2	43	21	32	5.5	83.6
3	56	43	45	4.3	89.8
4	54	34	67	8.5	91.9
5	44	23	54	7.6	92
6	54	22	32	12.4	109
8	38	24	46	5	76.3

9	67	35	45	4.4	74.9
10	98	63	67	6.6	83.8
11	118	76	89	13.7	88.7
12	112	38	54	4.8	64.5
13	100	67	56	3.6	82.6
14	34	19	53	3.6	80.6
15	48	21	23	3.4	71.7
16	65	23	46	1.6	63.5
17	70	45	78	2.3	79.8
18	34	13	65	1.5	67.8
19	93	12	43	3.6	54.7
20	84	34	57	1.7	66.9
21	73	32	65	1.2	70.6
22	83	11	12	1.8	69.4
23	95	18	13	2.3	72.9
24	67	27	14	2.8	76.5
25	64	43	12	2.3	81.5
26	53	34	56	3.4	81.5
27	45	22	43	3.1	73.6
28	57	27	14	3.5	79.2
29	53	45	15	3.2	88.7
30	67	43	45	3.6	82.5
31	54	27	32	6.3	105.1
32	56	26	56	8.8	108.7
33	225	200	66	6.4	117.3
34	230	194	54	4.1	140.9
35	342	274	45	2.7	188.4
36	312	283	34	5.4	212.1
38	84	34	57	1.7	66.9

统计隧道涌水量样本数据中隧道埋深(H)、地下水位(h)、岩石质量指数(RQD)、岩层含水性(W)和涌水量(WI)各指标数据的最小值、最大值、极差、平均值、中位值和(样本)标准差见表 4.4 (保留两位小数)。

表 4.4 隧道涌水量数据统计

Table 4.4 Tunnel water inflow data statistics

统计类型	H(m)	h(m)	RQD(%)	W(m ³ /hm)	WI/(m ³ /h)
最小值	15	0	4	1	7.2
最大值	350	312	99	33.6	343.7
极差	335	312	95	32.6	336.5
平均值	97.02	56.31	48.34	5.78	60.65
中位值	67	34	45	4.8	62.95
(样本)标准差	77.48	64.00	21.06	3.90	42.54

4.2.2 样本数据相关性分析

根据 4.1 小节中对隧道涌水量各预测指标的相关解释，结合专业文献资料，分析可得预测指标中的隧道埋深（H）、地下水位（h）和岩层含水性（W）与隧道涌水量（WI）具有一定的正相关性，而岩石质量指标（RQD）则与隧道涌水量（WI）具有一定的负相关性。为进一步探究分析各预测指标之间、各预测指标与涌水量的相关性，进行 Pearson 相关系数的计算并绘制热力图。

Pearson 相关系数是衡量两个变量线性相关程度的统计指标，最早由统计学家 Karl Pearson 提出，一般用字母 r 表示。计算公式如式（4.2）。

$$r = \frac{\sum(x - \bar{x})(y - \bar{y})}{\sqrt{\sum(x - \bar{x})^2 \sum(y - \bar{y})^2}} \tag{4.2}$$

式中， x 和 y 分别为变量 X 和 Y 的具体值， $\bar{x}$ 和 $\bar{y}$ 分别为变量 X 和 Y 的平均值。

Pearson 相关系数的取值范围为[-1,1]，具体数值表示了变量间线性关系的方向和强度。

- （1）当相关系数为 0 时， X 和 Y 无关系。
- （2）当 X 的值增大（减小）， Y 值增大（减小），两个变量为正相关，相关系数的取值范围为[0,1]。
- （3）当 X 的值增大（减小）， Y 值减小（增大），两个变量为负相关，相关系数的取值范围为[-1,0]。

相关系数的绝对值越大，相关性越强，相关系数越接近于 1 或-1，相关度越强，相关系数越接近于 0，相关度越弱。一般可通过以下取值范围判断[0,1]区间变量的相关强度，见表 4.5。

表 4.5 相关系数关联强度表
Table 4.5 Correlation strength table of correlation coefficient

相关系数	相关性描述
0.8~1.0	极强相关
0.6~0.8	强相关
0.4~0.6	中等程度相关
0.2~0.4	弱相关
0.0~0.2	极弱相关或无相关

样本数据中各预测指标与涌水量之间相关系数的热力图见图 4.1。由图中可验证，地下水位（h）和岩层含水性（W）与隧道涌水量（WI）的相关性最大，相关性系数分别为 0.57 和 0.51，均达到中等程度相关性；隧道埋深（H）与涌水量（WI）也表现出较好的相关性，相关系数为 0.39；岩石质量指标（RQD）与隧道涌水量 WI 的相关系数为-0.24，表现出一定的负相关性。




图 4.1 热力图

Figure 4.1 Thermal map

4.2.3 样本数据预处理

隧道涌水量样本数据集共计 600 条，每条样本记录中包含 4 个特征因子和 1 个输出值，特征因子为选取的 4 个隧道涌水量预测指标：隧道埋深（H）、地下水位（h）、岩石质量指标（RQD）和岩层含水性（W），输出值为隧道涌水量（WI）。实验开始前将样本数据打乱，设置训练集与测试集的比值为 8: 2，即模型训练过程中选取 480 个样本作为训练集，剩下的 120 个样本作为测试集，同时对样本数据进行最大最小归一化处理。

4.3 隧道涌水量预测方法

在查阅对该隧道涌水量样本进行相关理论研究和预测的文献后，参考陈克霖^[71]曾采用线性回归、Elman 神经网络及 LSTM 算法对部分样本成功实现涌水量预测，其中 LSTM 算法的预测效果最好，研究选用 LSTM 算法及 RBF 神经网络、ELM 算法对该样本进行涌水量预测，以期达到更好的预测效果。

4.3.1 径向基函数神经网络

径向基函数神经网络（Radial Basis Function Neural Network, RBFNN）是一种特殊类型的前馈神经网络，以其结构简单、非线性逼近能力强、泛化能力好等特点广泛

应用于多个领域。网络的模型由三层构成，在神经网络中，输入层用于将输入向量转移到隐藏层。隐藏层通过高斯函数将非线性函数转换为高维线性可分空间，增加模型的非线性拟合能力。

控制 RBFNN 模型预测效果的参数由惯性权重、神经元中心的位置以及神经元的宽度决定。训练 RBFNN 模型过程中，输入神经网络中的参数如式 (4.3)。

$$x = [x_1, x_2, \dots, x_n]^T_{1 \times n} \quad (4.3)$$

输出节点如式 (4.4)。

$$O = [o_1, o_2, \dots, o_m]^T_{1 \times m} \quad (4.4)$$

隐藏层激活函数对其权重进行线性加权组合可得到神经网络第 i 个神经元输出的均方误差如式 (4.5)。

$$E(i) = \frac{1}{m} \sum_{k=1}^m (o_k(i) - y_k(i))^2 \quad (4.5)$$

在训练的过程中，以所有输出神经元的均方误差来衡量模型的好坏，经过隐藏层激活函数对其权重进行线性加权组合可得到第 j 次迭代的均方误差如式 (4.6)。

$$MSE_{train}(j) = \frac{1}{Nu} \sum_i^{Nu} E_i(j) \quad (4.6)$$

其中， Nu 表示输出神经元的个数， $E_i(j)$ 代表第 j 次迭代中神经网络输出神经元的均方误差。当模型存在误差时，为了减小误差，采用梯度下降法调节神经网络参数。

4.3.2 长短期记忆网络

长短期记忆网络 (Long Short-Term Memory, LSTM) 是一种特殊的循环神经网络 (Recurrent Neural Network, RNN)，LSTM 通过引入门控机制来有效地捕捉长期依赖关系，它包括三个门控单元：遗忘门 (Forget Gate)、输入门 (Input Gate) 和输出门 (Output Gate) 以及一个细胞状态 (Cell State)。这些门控单元通过学习得到的权重来控制信息的流动，从而更好地保存和更新信息。




图 4.2 LSTM 记忆单元经典结构图

Figure 4.2 Typical structure diagram of LSTM memory cell

图 4.2 为 LSTM 记忆单元经典结构图。从图中可以看出，在任意时间步 t ，前一时刻的隐含层状态变量 h_{t-1} 、记忆单元的状态变量 C_{t-1} ，以及当前时刻的输入信息 x_t 作为输入进入神经单元^[72]。模型依次通过遗忘门 f_t 、输入门 i_t 和输出门 o_t 这三个控制机制得到 t 时刻的隐含状态变量 h_t 和状态变量 C_t 。最终，输出层将得到 LSTM 在 t 时刻的计算结果 y ，并由 h_t 传入。同时，在 $t+1$ 时刻， h_t 和 C_t 开始重新计算。在 t 时刻，计算 LSTM 隐含层，以求出输出值，计算过程如式 (4.7)。

$$\begin{aligned}
 f_t &= \sigma(U_f x_t + W_f h_{t-1} + b_f) , \\
 i_t &= \sigma(U_i x_t + W_i h_{t-1} + b_i) , \\
 \tilde{c}_t &= \tanh(U_c x_t + W_c h_{t-1} + b_c) , \\
 c_t &= f_t c_{t-1} + i_t \tilde{c}_t , \\
 o_t &= \sigma(U_o x_t + W_o h_{t-1} + b_o) , \\
 h_t &= O_t \tanh(c_t)
 \end{aligned} \tag{4.7}$$

其中，

$$\sigma = \frac{1}{1 + \exp(-x)} \tag{4.8}$$

式 (4.7) 中， $c_t \in R^m$ 为记忆单元状态参数； $x_t \in R^n$ 为输入参数； $h_t \in R^m$ 表示输出变量， $U_{(\cdot)} \in R^{m \times p}$ 和 $W_{(\cdot)} \in R^{m \times p}$ 表示加权矩阵； $b_{(\cdot)} \in R^m$ 是对学习进行不断优化的偏置向量， σ 表示 sigmoid 激活函数，其值在 (0,1) 范围内， $\tanh(x)$ 值域在 (0,1) 区间。

4.3.3 极限学习机算法

极限学习机 (Extreme Learning Machine, ELM) 于 2004 年提出，是一种单隐藏层前馈神经网络，其主要特点是其隐藏层节点的权重和偏置可以随机生成，而不需要通过反向传播算法进行调整，只需求解输出层权重即可。这种训练方式使得 ELM 在训练速度上大大超过传统的神经网络训练方法，同时还能保持较好的泛化性能。




图 4.3 ELM 网络结构图

Figure 4.3 ELM network structure diagram

典型的单隐藏层神经网络结构见图 4.3，输入层与隐藏层，输出层与隐藏层之间全连接。其中，输入层有 n 个神经元，对应 n 个输入变量；隐藏层有 l 个神经元，输出层有 m 个神经元，对应 m 个输出变量。输入层与隐藏层之间的连接权值 w 如式 (4.9)。

$$w = \begin{bmatrix} w_{11} & w_{12} & \cdots & w_{1n} \\ w_{21} & w_{22} & \cdots & w_{2n} \\ \vdots & \vdots & & \vdots \\ w_{l1} & w_{l2} & \cdots & w_{ln} \end{bmatrix}_{l \times n} \quad (4.9)$$

式中， w_{ij} 为输入层第 i 个神经元和隐含层第 j 个神经元间的连接权值。设置隐含层与输出层之间的连接权值 v 如式 (4.10)。

$$v = \begin{bmatrix} v_{11} & v_{12} & \cdots & v_{lm} \\ v_{21} & v_{22} & \cdots & v_{2m} \\ \vdots & \vdots & & \vdots \\ v_{l1} & v_{l2} & \cdots & v_{lm} \end{bmatrix}_{l \times m} \quad (4.10)$$

式中， v_{jp} 为隐含层第 j 个神经元与输出层第 p 个神经元间的连接权值。设置隐含层神经元的阈值 t 如式 (4.11)。

$$t = \begin{bmatrix} t_1 \\ t_2 \\ \vdots \\ t_l \end{bmatrix}_{l \times 1} \quad (4.11)$$

设有 Q 个样本的训练输入矩阵 X 、输出矩阵 Y 分别如式 (4.12) 和式 (4.13)。

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1Q} \\ x_{21} & x_{22} & \cdots & x_{2Q} \\ \vdots & \vdots & & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nQ} \end{bmatrix}_{n \times Q} \quad (4.12)$$

$$Y = \begin{bmatrix} y_{11} & y_{12} & \cdots & y_{1Q} \\ y_{21} & y_{22} & \cdots & y_{2Q} \\ \vdots & \vdots & & \vdots \\ y_{m1} & y_{m2} & \cdots & y_{mQ} \end{bmatrix}_{m \times Q} \quad (4.13)$$

$$T = \begin{bmatrix} \sum_{i=1}^l v_{i1} g(w_i x_j + t_i) \\ \sum_{i=1}^l v_{i2} g(w_i x_j + t_i) \\ \vdots \\ \sum_{i=1}^l v_{im} g(w_i x_j + t_i) \end{bmatrix}_{m \times l} \quad (j=1, 2, \dots, Q) \quad (4.14)$$

设隐含层神经元的激活函数为 $g(x)$ ，由图 4.3 可得网络的输出 T 如式 (4.14)。

综上所述，ELM 只需确定隐含层神经元的个数和隐含层神经元的激活函数^[73]，就能计算出 v 。

4.4 隧道涌水量预测模型

4.4.1 基于 RBF 神经网络的隧道涌水量预测模型

(1) RBF 神经网络结构设计

RBF 神经网络模型结构包括输入层、输出层和隐藏层。隐藏层通常只有一个，这个隐藏层包含一组径向基函数，用于对输入数据进行非线性映射。

1) 输入层节点数：输入层节点数等于样本数据的特征数量，隧道涌水量预测样本的特征数量为 4，因此 RBFNN 的输入层节点数为 4。

2) 隐藏层节点数：隐藏层是 RBF 神经网络的核心，每个隐藏层节点都是一个径向基函数。这些径向基函数中最常用的是高斯函数。每个隐藏层节点都有一个“中心”，这个中心是在特征空间中的一个点，每个节点计算输入数据到其中心点的距离，通过径向基函数转换这个距离，得到该层的输出。这一过程实际上是在进行一种非线性映射。由于隧道涌水量预测的训练样本共 480 个，因此可以设置隐藏层节点数为 480。通常情况下训练样本个数越多，隐藏层节点数越多。

3) 输出层节点数：隐藏层的输出会被送入输出层。输出层一般使用线性函数将隐藏层的输出加权求和，生成最终的预测结果。对于回归问题，输出层的节点数通常为 1。因此对于隧道涌水量的回归预测问题，设置输出层节点数为 1。

综上所述，径向基函数神经网络模型结构为 4-480-1，见图 4.4，图中 w 为权重， b 为偏置。




图 4.4 RBFNN 模型结构图

Figure 4.4 RBFNN model structure diagram

(2) RBF 神经网络参数及函数设置

在 RBF 神经网络中，最核心的概念之一就是径向基函数本身及其扩展速度(σ)，这对网络的性能有着直接影响。径向基函数是一种实值函数，其输出值仅依赖于输入值与某一中心点之间的距离。在 RBF 神经网络中，这种函数被用作隐藏层神经元的激活函数，常见的激活函数包括 Sigmoid、正弦 (Sine)、高斯 (Gaussian) 等。经反复测试，RBFNN 中选用 Sigmoid 函数作为隐藏层神经元的激活函数。

扩展速度(σ)是控制 RBF 宽度的参数,它直接影响 RBF 的平滑度和泛化能力,实验过程中设置的扩展速度越小($\sigma \leq 1$),训练集上可以达到相对好的隧道涌水量预测效果,但容易导致过拟合;设置的扩展速度越大,又会出现欠拟合问题。经多次测试,在保证预测准确性的前提下,最终设置径向基函数的扩展速度为 10。

图 4.5 至图 4.6 为 RBFNN 模型在隧道涌水量训练集和测试集上的预测值散点图,图中横坐标代表样本数据中的隧道涌水量真实值,纵坐标代表模型得出的隧道涌水量预测值,虚线上的值表示隧道涌水量的真实值与预测值相等的情况。图 4.7 至图 4.8 分别为 RBFNN 模型在训练集和测试集上得出的隧道涌水量预测值与真实结果对比图。由图可知,RBFNN 在隧道涌水量训练集上的均方根误差(RMSE)为 8.23,在测试集上的均方根误差(RMSE)为 12.37。




图 4.5 训练集预测结果散点图

Figure 4.5 Scatter plot of training set results




图 4.6 测试集预测结果散点图

Figure 4.6 Scatter plot of test set results




图 4.7 训练集预测结果

Figure 4.7 The predictive results of the training set




图 4.8 测试集预测结果

Figure 4.8 The predictive results of the test set

4.4.2 基于 LSTM 算法的隧道涌水量预测模型

在 Matlab 中构建 LSTM 模型：首先建立输入层，在隧道涌水量预测问题中，共有 4 个输入特征。由于预测输出的涌水量之间没有直接关系，只有 4 个输入特征对涌水量的预测数据有影响，因而不需要多个层来捕捉输出之间的关联，且收集的样本总量较少，为避免过拟合，使用单层的 LSTM 网络结构构建模型。设置隐藏层的单元个数为 4；设置 ReLU 为激活函数；输出层即全连接层，由于输出数据为涌水量，因此设置 1 个神经元。LSTM 优化方法选取：

(1) 梯度下降 (Gradient Descent)：基本的优化方法，通过计算损失函数关于模型参数的梯度来更新参数。

(2) 随机梯度下降 (Stochastic Gradient Descent, SGD)：每次迭代中仅使用部分数据来计算梯度，加速训练过程。

(3) 批量梯度下降 (Batch Gradient Descent)：使用全部数据计算梯度更新参数。

(4) AdaGrad：自适应学习率的方法，根据参数的历史梯度调整学习率。

(5) RMSProp (Root Mean Square Propagation)：对 AdaGrad 进行改进，解决学习率不断减小的问题。

(6) Adam (Adaptive Moment Estimation)：结合了动量优化和 RMSProp 的优点，是目前广泛使用的优化器之一。

选取 Adam 对 LSTM 网络进行训练。LSTM 网络模型的主要超参数设置见表 4.6。训练过程中对数据集随机打乱，同时设置学习率下降，在模型训练到 800 次时，初始学习率乘以 0.5（学习率下降因子）变为 0.005。

表 4.6 LSTM 网络模型的主要超参数设置

Table 4.6 Major hyperparameter settings for LSTM model

超参数	说明	值
MaxEpochs	最大迭代次数	1200
InitialLearnRate	初始学习率	0.01
LearnRateDropFactor	学习率下降因子	0.5
LearnRateDropPeriod	学习率下降经过的迭代次数	800

图 4.9 至图 4.10 为模型训练完成后在训练集和测试集上的涌水量预测值散点图。图 4.11 至图 4.12 分别为 LSTM 模型在训练集和测试集上得出的隧道涌水量预测值与真实结果对比图。由图可知，LSTM 在隧道涌水量训练集上的均方根误差（RMSE）为 7.17，在测试集上的均方根误差（RMSE）为 11.37。




图 4.9 训练集预测结果散点图
Figure 4.9 Scatter plot of training set results




图 4.10 测试集预测结果散点图
Figure 4.10 Scatter plot of test set results




图 4.11 训练集预测结果
Figure 4.11 The predictive results of the training set




图 4.12 测试集预测结果

Figure 4.12 The predictive results of the test set

4.4.3 基于 ELM 算法的隧道涌水量预测模型

ELM 模型具有简单的结构和较高的计算效率，模型实现的主要步骤如下：

- ①确定样本的训练集和测试集；
- ②根据样本数据量和维度设置隐含层神经元的个数 L ；
- ③在区间(0,1)中，随机生成输入权值 w 和阈值 b ；
- ④选取隐含层神经元的激活函数 $g(x)$ ，计算输出矩阵 H 及其伪逆矩阵 H^+ ；
- ⑤计算权重矩阵 $\hat{\beta}$ ；
- ⑥依据求得的 $\hat{\beta}$ 实现对样本数据的快速预测。

ELM 算法的网络模型结构包括三层：输入层、单个隐藏层以及输出层。ELM 的显著特点是隐藏层的权重和偏置在初始化之后不再改变，而输出层的权重则通过一次性计算而非迭代训练得到，这使得 ELM 在训练效率上具有明显优势。

(1) 输入层节点数：这一层负责接收输入数据，输入层的节点数等于样本数据的特征数量，即为 4。

(2) 隐藏层节点数：ELM 的核心在于其单个隐藏层。经反复测试，设置隐藏层节点数 (num_hiddens) 为 50，激活函数为 sigmoid 函数。

(3) 输出层节点数：隐藏层的输出通过线性组合形成输出层的结果。对于隧道涌水量的回归预测问题，设置输出层节点数为 1。

构建 ELM 模型后可知，输入到隐藏层的权重 (IW) 为 50×4 的矩阵向量，隐藏层的偏置 (B) 为 50×1 的矩阵向量，隐藏层到输出层的权重 (LW) 为 50×1 的矩阵

向量。

图 4.13 至图 4.14 为 ELM 模型在隧道涌水量训练集和测试集上的预测值散点图，图 4.15 至图 4.16 分别为 ELM 模型在训练集和测试集上得出的隧道涌水量预测值与真实结果对比图。由图可知，ELM 在隧道涌水量训练集上的均方根误差（RMSE）为 7.02，在测试集上的均方根误差（RMSE）为 7.45。




图 4.13 训练集预测结果散点图

Figure 4.13 Scatter plot of training set result




图 4.14 测试集预测结果散点图

Figure 4.14 Scatter plot of test set results




图 4.15 训练集预测结果

Figure 4.15 The predictive results of the training set




图 4.16 测试集预测结果

Figure 4.16 The predictive results of the test set

4.5 模型分析与评价

对于以上隧道涌水量预测模型,选用决定系数(Coefficient of Determination, R^2)、均方根误差(Root Mean Squared Error, RMSE)、平均绝对误差(Mean Absolute Error, MAE)和平均偏差误差(Mean Bias Error, MBE)四个指标进行综合分析评价。 R^2 、RMSE、MAE 和 MBE 的计算公式如式(4.15)至式(4.18)。

$$R^2 = 1 - \frac{\sum_{i=1}^n (y'_i - y_i)^2}{\sum_{i=1}^n (y_i - \bar{y}_i)^2} \quad (4.15)$$

$$\text{RMSE} = \sqrt{\left(\frac{1}{n}\right) \sum_{i=1}^n (y_i - y'_i)^2} \quad (4.16)$$

$$\text{MAE} = \left(\frac{1}{n}\right) \sum_{i=1}^n |y_i - y'_i| \quad (4.17)$$

$$\text{MBE} = \left(\frac{1}{n}\right) \sum_{i=1}^n (y_i - y'_i) \quad (4.18)$$

式中, y_i 为实际值, y'_i 为预测值, $\bar{y}_i$ 和 y'_i 为实际值和预测值的平均值。

(1) R^2

R^2 用于衡量模型对观测数据的拟合程度,取值范围为[0,1]。 R^2 越接近 1 表示模型对数据的拟合程度越好,反之拟合程度越差,具体解释意义见表 4.7。

表 4.7 R^2 解释意义表
Table 4.7 Explanatory meaning table of R^2

R^2	解释意义
1	模型完美拟合数据，即预测值与观测值完全一致
0	模型无法解释观测值的变异，预测值与观测值之间没有线性关系
<0	模型拟合得比随机猜测还要差

(2) RMSE

RMSE 是评估回归模型性能中常用的衡量预测值与真实值之间差异的指标，RMSE 值越小，表示模型的预测误差越小，预测效果越好。通常情况下，RMSE 值应当与预测目标的单位相同。

(3) MAE

MAE 同样用于衡量模型的预测误差大小，MAE 的值越小，说明模型的预测准确性越高。MAE 的单位和预测目标的单位相同。与 RMSE 不同的是，MAE 对异常值比较敏感，即一个极端的离群值可能会对 MAE 造成较大的影响。

(4) MBE

在回归预测中，MBE 用于衡量模型的预测值与真实值之间的平均偏差程度。MBE 的值可以为正或负，表示预测值相对于真实值的平均偏差方向。如果 MBE 值为正，表示模型的预测值普遍高于真实值；如果 MBE 值为负，表示模型的预测值普遍低于真实值。MBE 的绝对值越小，表示模型的预测偏差越小，即模型更准确地预测了真实值。

表 4.8 各模型评价指标值
Table 4.8 Evaluation index value of each model

预测 模型	R^2		RMSE		MAE		MBE	
	训练集	测试集	训练集	测试集	训练集	测试集	训练集	测试集
RBFNN	0.95	0.87	8.23	12.37	5.56	8.23	-1.60	-2.33
LSTM	0.95	0.92	7.17	11.37	5.13	6.90	-1.33	-0.70
ELM	0.96	0.95	7.02	7.45	5.43	5.86	-1.01	-0.48

表 4.8 为 RBFNN、LSTM 和 ELM 预测模型在样本训练集和测试集上的 R^2 、RMSE、MAE 和 MBE 值（保留两位小数），从表中可知：

(1) RBFNN、LSTM 和 ELM 预测模型在测试集上的 R^2 值分别为 0.87、0.92 和 0.95，均接近于 1，表明三个模型对数据的拟合程度较好，其中 ELM 模型的拟合程度最好；

(2) RBFNN、LSTM 和 ELM 预测模型在测试集上的 RMSE 值分别为 12.37、11.37 和 7.45，MAE 值分别为 8.23、6.90 和 5.43，表明构建的三个模型中 ELM 模型对隧道涌水量的预测准确性和精度最高；

(3) RBFNN、LSTM 和 ELM 预测模型在测试集上的 MBE 值分别为-2.33、-0.70 和-0.48，表明三个预测模型对隧道涌水量的整体预测结果偏低于真实值，其中 ELM 模型对隧道涌水量的整体预测结果偏差最小。

综上所述，在构建的 RBFNN、LSTM 和 ELM 隧道涌水量预测模型中，ELM 模

型在该样本数据集上的整体预测效果最好。

4.6 本章小结

在隧道涌水突泥风险预测的相关研究中,进一步对影响风险等级的关键因素涌水量进行预测。本章首先选取隧道埋深、地下水位、岩石质量指标、岩层含水性四个隧道涌水量有效预测指标,分析其对隧道涌水量的影响。其次,收集 600 条包含这些预测指标及涌水量的样本数据集,进行统计与相关性分析后,构建最优参数的 RBFNN、LSTM 和 ELM 模型对隧道涌水量进行预测,并选取 R^2 、RMSE、MAE 和 MBE 四个评价指标对模型的预测精度进行综合分析,结果表明,RBFNN、LSTM 和 ELM 模型在测试集上的 RMSE 值分别为 12.37、11.37 和 7.45,MAE 值分别为 8.23、6.90 和 5.86,三个模型在该隧道涌水量预测样本上均有较好的预测精度,其中 ELM 模型的预测效果最好。

5 总结与展望

5.1 总结

论文以隧道涌水突泥风险为研究对象,基于相关风险研究理论基础,运用多种机器学习算法对隧道涌水突泥风险进行相关的预测研究,对于机器学习算法在该领域的应用有一定的借鉴和参考意义,对涌水突泥灾害的预防和应对措施具有一定的指导意义。主要研究内容及取得的成果总结如下:

(1) 基于隧道涌水突泥风险研究理论基础,收集整理 118 个隧道共 251 起隧道涌水突泥灾害事故案例,详细记录下事故的致灾因素及后果,以定量分析为基础,定性描述为补充,构建隧道涌水突泥灾害案例库。参考相关研究文献并结合案例库中的灾害事故真实情况,综合自然因素与人为因素,对隧道涌水突泥风险致灾因素辨识与分类,从工程地质、水文地质及工程施工三类致灾因素中分别选取地质构造、地层岩性、岩层厚度、岩层产状、围岩级别、地形地貌、岩溶发育情况、降水及地下水、降雨入渗系数、节理裂隙与地表河流结合度、施工质量和支护设计共计 12 个风险评估指标,建立隧道涌水突泥风险评估指标体系;从涌水量与突泥量、经济损失、人员伤亡、工期延误五个指标中完善涌水突泥风险等级划分标准。

(2) 对案例库中收集整理的隧道涌水突泥灾害事故数据进行量化,得到隧道涌水突泥风险等级预测数据集。对样本数据进行均衡化及归一化等预处理后,选用机器学习算法中的 RF、BPNN 和 SVM 算法构建隧道涌水突泥风险预测基本模型,为提高模型在样本数据上的风险等级预测准确率,选用 PSO 算法分别对 BPNN 和 SVM 模型进行优化,构建基于 PSO-BP 算法和 PSO-SVM 算法的隧道涌水突泥风险预测模型。通过实验仿真测试并使用混淆矩阵、准确率、精准率、召回率和 F1 值对各模型进行对比分析。预测分析结果表明,RF、BPNN、SVM、PSO-BPNN 和 PSO-SVM 各预测模型在测试集上的涌水突泥风险等级预测准确率分别为 86.11%、88.89%、87.5%、94.44%和 97.22%,F1 值分别为 86.47%、90.1%、87.48%、94.27%和 97.15%,各模型设置最优参数后均能在该样本数据集上实现较好的预测效果,其中 PSO-SVM 预测模型在该样本数据集上的风险等级预测准确率最高,模型整体表现最好。

(3) 基于机器学习相关算法对影响隧道涌水突泥风险等级的关键因素涌水量进行预测。选取隧道埋深、地下水位、岩石质量指数和岩层含水性作为隧道涌水量预测指标,收集整理 600 条样本数据,对样本数据进行统计及相关性分析后,根据样本数据特点选用机器学习算法中的 RBFNN、LSTM 和 ELM 算法对涌水量进行预测,经实验与仿真测试后,通过 R²、RMSE、MAE 和 MBE 四个指标对各模型在样本数据集上的预测表现进行综合评价。在预测精度方面,RBFNN、LSTM 和 ELM 模型在测试集上的 RMSE 值分别为 12.37、11.37 和 7.45,MAE 值分别为 8.23、6.90 和 5.86,构建的三个隧道涌水量预测模型中,ELM 模型在该样本数据上的预测误差最小,整体预测效果最好。

5.2 展望

由于隧道涌水突泥灾害事故案例及相关涌水量数据的有限性,收集整理用于预测研究的数据量相对较少。在后续的研究中,相关学者可以共享更多的隧道涌水突泥灾害事故案例资料和涌水量相关数据,促进对隧道涌水突泥风险各方面的进一步研究。

基于建立的隧道涌水突泥风险等级预测模型和隧道涌水量预测模型,下一步可以开发相应的系统程序并应用于其他隧道工程中进行施工风险评估,在实践中检验模型的实用性和可行性,同时对模型加以完善,提高模型的适用性和泛化性。

参考文献

- [1]《中国公路学报》编辑部.中国交通隧道工程学术研究综述·2022[J].中国公路学报,2022,35(04):1-40.
- [2]巩江峰,王伟,王芳,等.截至2023年底中国铁路隧道情况统计及2023年新开通重点项目隧道情况介绍[J].隧道建设(中英文),2024,44(02):377-392.
- [3]方忠强,张鹏,涂齐亮,等.太湖隧道智能运营设施设计方案研究[J].地下空间与工程学报,2023,19(01):220-228+246.
- [4]王眉灵.修隧道变“翻山”为“穿山” 冬季过夹金山将不再难[N].四川日报,2021-12-27(002).
- [5]李玲,张凤华.中交天和胜利向天山[N].中国交通报,2023-07-24(005).
- [6]刘辉,张智超,王林娟.2004—2008年我国隧道施工事故统计分析[J].中国安全科学学报,2010,20(01):96-100+179.
- [7]胡群芳,秦家宝.2003—2011年地铁隧道施工事故统计分析[J].地下空间与工程学报,2013,9(03):705-710.
- [8]郑艾辰,黄锋,林志,等.2008年至2016年我国隧道工程施工安全事故统计与分析[J].施工技术,2017,46(S1):833-836.
- [9]违法违规分包工程勘察 盲目救援12人遇难[J].劳动保护,2021,(03):56-57.
- [10]马士伟,梅志荣,张军伟.长大隧道突水突泥灾害的地质构造量化评价与监测预警[J].现代隧道技术,2009,46(02):99-104.
- [11]刘学增,马小君.隧道穿越断层破碎带突水涌泥模糊安全评价[J].地下空间与工程学报,2009,5(S2):1786-1790.
- [12]Li S ,Zhou Z ,Li L , et al. Risk assessment of water inrush in karst tunnels based on attribute synthetic evaluation system [J]. Tunnelling and Underground Space Technology incorporating Trenchless Technology Research, 2013, 38 50-58.
- [13]Li X ,Li Y . Research on risk assessment system for water inrush in the karst tunnel construction based on GIS: Case study on the diversion tunnel groups of the Jinping II Hydropower Station [J]. Tunnelling and Underground Space Technology incorporating Trenchless Technology Research, 2014, 40 182-191.
- [14]Li L ,Lei T ,Li S , et al. Risk assessment of water inrush in karst tunnels and software development [J]. Arabian Journal of Geosciences, 2015, 8 (4): 1843-1854.

- [15]Zhou Z ,Li S ,Li L , et al. An optimal classification method for risk assessment of water inrush in karst tunnels based on the grey system [J]. Geomechanics and Engineering, 2015, 8 (5): 631-647.
- [16]张志成,卢浩,李集,等.一种深长隧道涌突水灾害危险性评价模型及其应用[J].中国地质灾害与防治学报,2015,26(04):67-74.
- [17]Yuan Y ,Li S ,Zhang Q , et al. Risk assessment of water inrush in karst tunnels based on a modified grey evaluation model: Sample as Shangjiawan Tunnel [J]. Geomechanics and Engineering, 2016, 11 (4): 493-513.
- [18]袁敬强,陈卫忠,黄世武,等.全强风化花岗岩隧道突水灾害机制与协同治理技术研究[J].岩石力学与工程学报,2016,35(S2):4164-4171.
- [19]Wang Y ,Yin X ,Jing H , et al. A novel cloud model for risk analysis of water inrush in karst tunnels [J]. Environmental Earth Sciences, 2016, 75 (22).
- [20]Chu H ,Xu G ,Yasufuku N , et al. Risk assessment of water inrush in karst tunnels based on two-class fuzzy comprehensive evaluation method [J]. Arabian Journal of Geosciences, 2017, 10 (7).
- [21]Wang Y ,Jing H ,Yu L , et al. Set pair analysis for risk assessment of water inrush in karst tunnels [J]. Bulletin of Engineering Geology and the Environment, 2017, 76 (3): 1199-1207.
- [22]Wang Y ,Chen F ,Yin X , et al. Study on the risk assessment of water inrush in karst tunnels based on intuitionistic fuzzy theory [J]. Geomatics, Natural Hazards & Risk, 2019, 10 (1): 1070-1083.
- [23]Li C S ,Wu J . A multi-factor comprehensive risk assessment method of karst tunnels and its engineering application [J]. Bulletin of Engineering Geology and the Environment, 2019, 78 (3): 1761-1776.
- [24]Wang X ,Li S ,Xu Z , et al. An interval risk assessment method and management of water inflow and inrush in course of karst tunnel excavation [J]. Tunnelling and Underground Space Technology incorporating Trenchless Technology Research, 2019, 92 103033-103033.
- [25]Yaxiong P ,Li W ,Qingjun Z , et al. Risk assessment of water inrush in tunnel through water-rich fault based on AHP-Cloud model [J]. Geomatics, Natural Hazards and Risk, 2020, 11 (1): 301-317.
- [26]Lin C ,Zhang M ,Zhou Z , et al. A new quantitative method for risk assessment of water inrush in karst tunnels based on variable weight function and improved cloud model [J]. Tunnelling and Underground Space Technology incorporating Trenchless Technology Research, 2020, 95 103136-103136.

- [27]Wang X ,Shi K ,Shi Q , et al. A Normal Cloud Model-Based Method for Risk Assessment of Water Inrush and Its Application in a Super-Long Tunnel Constructed by a Tunnel Boring Machine in the Arid Area of Northwest China [J]. *Water*, 2020, 12 (3): 644.
- [28]王升,李利平,成帅,等.基于改进属性区间辨识模型的隧道突涌水灾害风险评价方法(英文)[J].*中南大学学报英文版(英文版)*,2020,27(02):517-530.
- [29]朱建群,李天正.基于突变理论的岩溶隧道突水突泥风险评估模型及其应用研究(英文)[J].*中南大学学报英文版(英文版)*,2020,27(05):1587-1598.
- [30]Wang S ,Li L ,Cheng S , et al. Model on Improved Variable Weight-Matter Element Theory for Risk Assessment of Water Inrush in Karst Tunnels [J]. *Geotechnical and Geological Engineering*, 2021, 39 (5): 1-16.
- [31]Xingliang S ,Guo T ,Xiaolong G , et al. Risk assessment of water inrush in karst tunnels based on fuzzy comprehensive evaluation considering misjudgment losses: a case study [J]. *Arabian Journal of Geosciences*, 2022, 15 (5).
- [32]韩琳,李洪涛,孙雅飞,等.隧道涌水突泥风险分级方法及工程应用[J].*水利水电技术(中英文)*,2023,54(S1):197-202.
- [33]杨卓,马超.基于 BP 神经网络方法的岩溶隧道突涌水风险预测[J].*隧道建设*,2016,36(11):1337-1342.
- [34]王璐.基于遗传算法和支持向量机的西南岩溶越岭隧道涌水量预测[D].*成都理工大学*,2019.
- [35]柏成浩.基于机器学习的岩溶隧道突水突泥灾害风险智能预测方法研究[D].*山东大学*,2021.
- [36]王凯平.弱胶结软岩隧道突水灾变演化特征与预测方法研究[D].*济南大学*,2022.
- [37]Zhaoyang L ,Yingchao W ,Guney C O , et al. Risk assessment of water inrush caused by karst cave in tunnels based on reliability and GA-BP neural network [J]. *Geomatics Natural Hazards and Risk*, 2020, 11 (1): 1212-1232.
- [38]Zhang X ,Wang M ,Feng D , et al. Water Inflow Amount Prediction for Karst Tunnel with Steady Seepage Conditions [J]. *Sustainability*, 2023, 15 (13).
- [39]康小兵,张强,许模.重庆走马岭岩溶隧道涌水量初步研究[J].*工程地质学报*,2006,(01):68-71.
- [40]郭旭晶,黄涛,肖再亮,等.石太客运专线特长隧道涌水灾害预测研究[J].*工程地质学报*,2008,(02):255-257.

- [41]任蕊,许模.阻挡式背斜构造区隧道涌突水量的 BP 网络预测[J].现代隧道技术,2011,48(06):47-52.
- [42]Aalianvari ,Ali ,Katibeh , et al. Application of fuzzy Delphi AHP method for the estimation and classification of Ghomrud tunnel from groundwater flow hazard [J]. Arabian journal of geosciences, 2012, 5 (2): 275-284.
- [43]Jin X ,Li Y ,Luo Y , et al. Prediction of city tunnel water inflow and its influence on overlain lakes in karst valley [J]. Environmental Earth Sciences, 2016, 75 (16).
- [44]谢立均.高家湾特长隧道岩溶区段涌水量预测与评价[D].西南交通大学,2017.
- [45]Cheng P ,Zhao L ,Zhang S , et al. Water inflow forecasting for tunnel considering nonlinear variation of permeability coefficient [J]. Journal of Central South University, 2017, 24 (7): 1612-1618.
- [46]王健华,李术才,李利平,等.隧道岩溶管道型突涌水动态演化特征及涌水量综合预测[J].岩土工程学报,2018,40(10):1880-1888.
- [47]Lin P ,Li C S ,Xu H Z , et al. Water Inflow Prediction during Heavy Rain While Tunneling through Karst Fissured Zones [J]. International Journal of Geomechanics, 2019, 19 (8): 04019093-04019093.
- [48]Jia-Qing Z ,Hong-Bin L ,Changdong L , et al. A semi-empirical model for water inflow into a tunnel in fractured-rock aquifers considering non-Darcian flow [J]. Journal of Hydrology, 2021, 597.
- [49]唐宁,王林峰,周楠,等.一种岩溶隧道涌水量预测的新方法——以中梁山岩溶隧道工程为例[J].人民长江,2021,52(04):141-148.
- [50]傅鹤林,安鹏涛,李凯,等.隧道掌子面附近涌水量预测研究[J].铁道工程学报,2021,38(09):41-47.
- [51]Vahab A ,Mohsen N A . Hydrogeological assessment and estimation of groundwater inflow into the water transmission tunnel to Urmia Lake, Northwestern Iran [J]. Bulletin of Engineering Geology and the Environment, 2022, 81 (3).
- [52]周彩贵,李景,梁庆国,等.水工引水隧洞施工涌水量预测方法对比[J].隧道与地下工程灾害防治,2023,5(01):32-44.
- [53]苏培东,赵熠,邱鹏,等.花岗岩蚀变带隧道涌水量预测研究[J].地下空间与工程学报,2023,19(01):291-301+318.
- [54]Shaoshuai S ,Weidong G ,Shuca L , et al. Prediction of tunnel water inflow based on stochastic deterministic three-dimensional fracture network [J]. Tunnelling and

Underground Space Technology incorporating Trenchless Technology Research, 2023, 135.

[55]王成华,牛来福.引水隧洞涌水量最优预测方法研究[J].水利技术监督,2023,(10):177-181.

[56]王青松,刘凯.基于 BP 神经网络算法预测近海隧道施工涌水量[J].低温建筑技术,2023,45(10):140-142+147.

[57]王德明.泥质断层破碎带隧道突水突泥灾变机理研究及应用[D].山东大学,2017.

[58]李相辉.隧道突泥灾害致灾介质失稳破坏机理研究[D].山东大学,2019.

[59]吴修梅.基于 PSO 优化神经网络的公路隧道塌方风险研究[D].东华理工大学,2023.

[60]李朝阳.基于数据学习的岩溶隧道突涌水风险评估及预警研究[D].中国矿业大学,2020.

[61]邹学钢.基于 ADASYN-SSA-XGBoost 的铀矿测井岩性识别研究[D].东华理工大学,2023.

[62]陈晓星.基于 BP 神经网络和 Borda 法则的油浸式变压器故障诊断[J].现代经济信息,2016,(06):381-383.

[63]路作龙,安爽,杨文晓,等.规划阶段建筑群冷热负荷预测方法研究[J].区域供热,2021,(03):37-44.

[64]刘志锋,陈名煜,吴修梅,等.基于人工智能方法的隧道塌方风险预测研究[J].水力发电,2024,50(03):31-38.

[65]王瑛,赵谦,曹玮.基于 E-BP 神经网络的科技奖励评价模型研究[J].科技进步与对策,2011,28(10):111-114.

[66]贾子铎,柳淑学,李金宣,等.基于 BP 神经网络对横浪作用下系泊油船的运动量预测分析[J].水道港口,2022,43(04):430-436.

[67]谷趁趁,翟长远,陈立平,等.基于激光雷达的树形靶标冠层叶面积探测模型研究[J].农业机械学报,2021,52(11):278-286.

[68]王涛.基于 PSO-SVM 的黑龙江省水资源承载力分析[D].黑龙江大学,2023.

[69]吴浩然,吴红兰,孙有朝,等.基于改进 KNN 算法的飞行员工作负荷评估[J].航空计算技术,2022,52(05):77-81.

[70]欧光照.基于机器学习的隧道施工工期工程灾害风险评估研究[D].中国地质大学,2022.

[71]陈克霖.水工引水隧洞施工对围岩渗流场影响研究[D].兰州交通大学,2022.

- [72]曹晋镠,刘芳,申志福.基于长短期记忆网络的 TBM 掘进预测模型及围岩等级对预测精度的影响[J].土木工程学报,2022,55(S2):92-102.
- [73]宋博文.基于极限学习机和迁移学习的水轮机状态预测方法[D].哈尔滨理工大学,2023.