



硕士专业学位论文

数据驱动的亭南煤矿工作面涌水量
预测研究

Research on data-driven water inflow
prediction of Tingnan Coal Mine

作者：丁莹莹
校内导师：卜昌森 教授
企业导师：刘永强 高工

华北科技学院

2024 年 6 月



硕士专业学位论文

数据驱动的亭南煤矿工作面涌水量
预测研究

Research on data-driven water inflow
prediction of Tingnan Coal Mine

作者：丁莹莹

校内导师：卜昌森 教授

企业导师：刘永强 高工

导师组组长：连会青

导师组成员：尹尚先、李小明、
易四海、郑贵强、

华北科技学院

2024 年 6 月

中图分类号 TD7

学校代码 11104

UDC

密 级 公开

华北科技学院
硕士专业学位论文

数据驱动的亭南煤矿工作面涌水量预测研究
Research on data-driven water inflow prediction
of Tingnan Coal Mine

作 者 丁莹莹

校内导师 卜昌森

企业导师 刘永强

申请学位 硕士专业学位

培养单位 研究生部

学科专业 安全工程

研究方向 矿井水害防治

答辩委员会主席 曹代勇

评 阅 人

二〇二四年六月

摘 要

煤炭是世界上最重要的能源之一，作为全球能源供应的重要组成部分，其地位不可忽视。煤炭作为重要的原材料，在钢铁、化工、建材等工业领域具有广泛的应用，对于国家的经济发展起着重要的推动作用。煤炭开采过程中矿井水害是一种常见的地质灾害，对矿山的安全生产产生了严重威胁。为了减少矿井水害事故的发生，对涌水量的分析、预测和控制具有重要意义。矿井工作面是矿井中的重要工作区域，也是矿井生产的核心部分。对矿井工作面的涌水量进行准确预测，能充分确保矿山安全、优化资源配置、提高工作效率等。另外，随着现代智能化技术的应用，越来越多的矿山进入了智能化监测时代，通过配备智能化监测设备获得的数据对于矿山的安全生产状况具有参考性的价值，为了提高监测数据的充分应用，以及提高对矿井工作面涌水量预测精度，本文以陕西亭南煤矿 207 工作面为例，充分利用可获取的监测数据，采用机器学习方法，进行如下两种类型的矿井工作面涌水量预测研究：

（1）为提高采煤工作面涌水量预测准确度，收集大量工作面涌水量历史观测数据进行整理、统计、分析，将涌水量稳定性、周期性和季节性特征考虑在内，提出了基于数据驱动的 CEEMDAN 和混合时间序列模型工作面涌水量预测方法。首先，运用自适应噪声完备集合经验模态分解算法（CEEMDAN）将涌水量数据分成 7 个本征模态函数(IMF)分量，克服数据本身噪声影响。其次，运用麻雀搜索算法（SSA）优化的长短期记忆网络（LSTM）和差分整合移动平均自回归（ARIMA）构建的混合时间序列模型，根据分解的本征分量的不同特征进行预测。最后，将预测得到的各分量结果根据时域融合进行叠加，得到最终的预测值。将提出的基于 CEEMDAN 和改进的混合时间序列模型与 BP 神经网络、GRU、LSTM、ARIMA 和 SSA-LSTM 模型在同一涌水量数据集上进行了对比实验。结果表明，所提模型预测结果的平均绝对误差和均方根误差、模型拟合系数分别降低为 6.36 m³/h、10.6 m³/h、95%，相对于其他模型评价指标均得到显著改善。该模型克服了其他相关影响因素的干扰，提高了预测精度，加快了预测速度，适用于工作面涌水量预测。

（2）为了提高预测结果的准确性和稳定性，基于钻孔水位和微震能量数据与涌水量的强关联性，选择钻孔水位和微震能量数据作为多因素特征变量，结合卷积神经网络（CNN）与门控循环单元（GRU）构建新的网络结构，并在新的网络结构上加入注意力机制（Attention），融合麻雀搜索（SSA）算法优化网络参数，建立了 SSA-CG-Attention 预测模型。将提出的模型与其他模型进行对比实验，结果表明：SSA 算法以最少迭代次数快速寻优，且避免了局部最优解

的缺陷；与单因素涌水量预测模型相比，SSA-CG-Attention 多因素预测模型的绝对误差（MAE）、均方根误差（RMSE）以及平均绝对百分比误差（MAPE）分别降低到了 5.24 m³/h、7.25 m³/h、6 %，表明多因素约束使模型更加准确、可靠、稳定。

该论文有图 30 幅，表 12 个，参考文献 116 篇。

关键词：涌水量预测；时间序列；多因素；组合模型；数据驱动

Abstract

Coal is one of the most important energy sources in the world, and as an important part of the global energy supply, its position cannot be ignored. As an important raw material, coal is widely used in iron and steel, chemical industry, building materials and other industrial fields, and plays an important role in promoting the economic development of the country. Mine water disaster is a common geological disaster in the process of coal mining, which poses a serious threat to mine safety production. In order to reduce the occurrence of mine water accidents, it is of great significance to analyze, forecast and control the water inflow. Mine working face is an important working area in a mine, and it is also the core part of mine production. Accurate prediction of the water inflow of mine working face can fully ensure mine safety, optimize resource allocation and improve work efficiency. In addition, with the application of modern intelligent technology, more and more mines have entered the era of intelligent monitoring, and the data obtained through intelligent monitoring equipment has a reference value for the safety production of mines. In order to improve the full application of monitoring data and improve the prediction accuracy of the water inflow of the mine working face, this paper takes the 207 working face of Tingnan Coal Mine in Shaanxi Province as an example. By making full use of available monitoring data and adopting machine learning method, the following two types of mine face water inflow prediction research are carried out:

(1) In order to improve the prediction accuracy of coal face water inflow, a large number of historical observation data of working face water inflow were collected for collation, statistics and analysis, and the data-driven CEEMDAN and mixed time series models for working face water inflow prediction were proposed, taking the stability, periodicity and seasonal characteristics of water inflow into account. Firstly, the adaptive noise complete set empirical Mode decomposition algorithm (CEEMDAN) is used to divide the water inflow data into 7 intrinsic mode function (IMF) components to overcome the noise effect of the data itself. Secondly, the mixed time series model constructed by Sparrow Search algorithm (SSA) optimized long short-term memory network (LSTM) and differential integrated moving average autoregression (ARIMA) is used to make predictions according to different characteristics of decomposed eigencomponents. Finally, the predicted results of each component are superimposed according to time domain fusion, and the final predicted

value is obtained. The proposed hybrid time series model based on CEEMDAN and the improved model were compared with BP neural network, GRU, LSTM, ARIMA and SSA-LSTM models on the same water inflow data set. The results show that the mean absolute error, root mean square error and model fitting coefficient of the proposed model are reduced to 6.36 m³/h, 10.6 m³/h and 95%, respectively, which are significantly improved compared with other model evaluation indexes. The model overcomes the interference of other related factors, improves the prediction accuracy and speeds up the prediction speed, and is suitable for the prediction of water inflow in the working face.

(2) In order to improve the accuracy and stability of prediction results, based on the strong correlation between borehole water level and microseismic energy data and water inflow, borehole water level and microseismic energy data are selected as multi-factor characteristic variables, and a new network structure is constructed by combining convolutional neural network (CNN) and gated cycle unit (GRU). The Attention mechanism is added to the new network structure, the sparrow search (SSA) algorithm is integrated to optimize the network parameters, and the SSA-CG-attention prediction model is established. The proposed model is compared with other models, and the results show that the SSA algorithm optimizes quickly with the least number of iterations, and avoids the defect of local optimal solution. Compared with the single-factor water inflow prediction model, the absolute error (MAE), root mean square error (RMSE) and mean absolute percentage error (MAPE) of the SSA-CG-Attention multi-factor prediction model were reduced to 5.24 m³/h, 7.25 m³/h and 6%, respectively. It is shown that the multi-factor constraint makes the model more accurate, reliable and stable.

This paper contains 30 figures, 12 tables, and 116 references.

Keywords: Water inflow prediction; Time series; Multi-factor; Combination model; data-driven

目 录

1 绪论.....	1
1.1 研究背景及意义(Research background and significance).....	1
1.2 国内外研究现状(Research status at home and abroad)	2
1.3 研究目标与研究内容(Research objectives and contents).....	5
1.4 技术路线及创新点(Technical route and innovation points)	7
2 数据来源.....	11
2.1 研究区概况(Overview of the study area)	11
2.2 地质概况(Geological overview)	13
2.3 水文地质概况(Hydrogeological profile)	17
2.4 研究数据情况(Relevant data of water inflow in the studyarea)....	20
2.5 本章小结(Summary of this chapter)	21
3 基于经典方法的涌水量预计	23
3.1 解析法(Analytical method)	23
3.2 面积比拟法(Area analogy method)	25
3.3 本章小结(Summary of this chapter)	26
4 基于 CEEMDAN-SSA-LSTM-ARIMA 模型的单序列涌水量预测	27
4.1 相关理论基础(Relevant theoretical basis).....	27
4.2 数据分析(Data analysis)	30
4.3 模型构建(Model construction).....	36
4.4 预测结果(Forecast result)	37
4.5 对比分析(Comparative analysis)	39
4.6 本章小结(Summary of this chapter)	42
5 基于 SSA-CG-Attention 模型的多因素涌水量预测	45
5.1 相关基础理论(Relevant basic theory)	45
5.2 特征变量选取(Feature variable selection).....	49
5.3 模型构建(Model construction).....	51
5.4 预测结果对比分析(Comparative analysis of forecast results).....	52
5.5 本章小结(Summary of this chapter)	57
6 结论与展望.....	59
6.1 结论(Conclusions)	59
6.2 展望(Outlook).....	60
参考文献.....	61

图清单

图序号	图名称	页码
图 1-1	技术路线图	8
Figure 1-1	Technology Roadmap	8
图 2-1	井田位置示意图	11
Figure 2-1	Location diagram of the well field	11
图 2-2	亭南井田范围示意图	12
Figure 2-2	Schematic diagram of the scope of Tingnan well field	12
图 2-3	亭南煤矿地层特征	14
Figure 2-3	Formation characteristics of Tingnan Coal mine	14
图 2-4	207 工作面地层综合柱状图	15
Figure 2-4	Comprehensive column diagram of strata on working face 207	15
图 2-5	亭南煤矿煤层厚度等值线图	16
Figure 2-5	Contour map of seam thickness in Tingnan Coal Mine	16
图 2-6	影响回采的其它地质情况表	17
Figure 2-6	lists other geological conditions affecting mining	17
图 2-7	对工作面有影响的含、隔水层情况	17
Figure 2-7	Water-containing and water-retaining layers affecting the working face	17
图 2-8	207 工作面钻孔地层厚度数据	19
Figure 2-8	Summary of formation thickness data of borehole in 207 face	19
图 2-9	作面微震监测系统和水位监测孔分布图	20
Figure 2-9	Face microseismic monitoring system and water level monitoring hole distribution	20
图 2-10	微震能量、水位与涌水量的关系图	21
Figure 2-10	Relationship diagram of microseismic energy, water level, and water inflow	21
图 3-1	207 工作面煤层开采厚度与涌水量曲线图	25
Figure3-1	207 Working face coal seam thickness and water inflow curve diagram	25
图 4-1	LSTM 网络结构图	28
Figure 4-1	LSTM network structure diagram	28
图 4-2	涌水量分解趋势序列图	32
Figure 4-2	Sequence diagram of decomposition trend of water inflow	32
图 4-3	涌水量分解的季节性序列图	33
Figure 4-3	Seasonal sequence diagram of water inflow decomposition	33
图 4-4	涌水量分解的随机序列图	33
Figure 4-4	Random sequence diagram of water inflow decomposition	33
图 4-5	工作面涌水量随推进长度变化曲线	34
Figure 4-5	Variation curve of the water inflow of the working face with the advancing length	34
图 4-6	CEEMDAN-SSA-LSTM-ARIMA 模型流程图	36

Figure 4-6	Flowchart of the CEEMDAN-SSA-LSTM-ARIMA model	36
图 4-7	模态分解结果	37
Figure 4-7	odal Decomposition Results	37
图 4-8	各分量预测结果	38
Figure 4-8	Prediction results of each component	38
图 4-9	CEMDAN-SSA-LSTM-ARIMA 模型预测结果	39
Figure 4-9	CEMDAN-SSA-LSTM-ARIMA model prediction result	39
图 4-10	优化算法适应度结果对比	40
Figure 4-10	Comparison of fitness results of optimization algorithms	40
图 4-11	各模型预测结果对比	41
Figure 4-11	Comparison of prediction results of various models	41
图 5-1	CNN 的基本结构	46
Figure 5-1	Basic structure of CNN	46
图 5-2	GRU 结构单元	47
Figure 5-2	GRU Structural Unit	47
图 5-3	Attention 单元结构	48
Figure 5-3	Attention Unit Structure	48
图 5-4	SSA-CG-Attention 模型流程图	52
Figure 5-4	Flowchart of the SSA-CG-Attention model	52
图 5-5	SSA-CG-Attention 模型预测结果	53
Figure 5-5	Prediction Results of SSA-CG-Attention Model	53
图 5-6	各模型预测结果	56
Figure 5-6	Prediction Results of Each Model	56

表清单

表序号	表名称	页码
表 2-1	工作面位置简表	13
Table 2-1	Summary Table of Workface Locations	13
表 2-2	煤层顶底板情况表	16
Table 2-2	Top and bottom conditions of coal seam	16
表 2-3	亭南井田含水层与隔水层特征表	18
Table 2-3	Characteristics of aquifer and aquifer in Tingnan well field	18
表 3-1	207 工作面侏罗系涌水量计算结果	24
Table 3-1	Calculation result of Jurassic water inrush in 207 working face	24
表 3-2	207 工作面不同开采厚度的涌水量计算结果	24
Table 3-2	Calculation results of water inflow at different mining thicknesses of working face 207	24
表 4-1	涌水量统计分析数据	31
Table 4-1	Statistical analysis data of surge quantity	31
表 4-2	各分量单位根检验结果	37
Table 4-2	Unit root test results of each component	37
表 4-3	各模型预测对比结果	42
Table 4-3	Comparison Results of Forecast of Various Models	42
表 5-1	微震数据、水位数据和涌水量数据 Spearman 相关系数	49
Table 5-1	Spearman correlation coefficients of microseismic data, water level data, and water inflow data	49
表 5-2	多因素、单因素模型对比结果	55
Table 5-2	Comparison Results of Multifactor and Single Factor Models	55
表 5-3	模型评估方差	56
Table 5-3	Model Evaluation Variance	56
表 5-4	各模型预测对比结果	57
Table 5-4	Comparison Results of Forecast of Various Models	57

1 绪论

1 Introduction

1.1 研究背景及意义 (Research background and significance)

全球煤炭储量十分充裕，煤炭作为一种重要的能源矿产资源具有重要地位^[1]。随着我国经济迅速发展，对能源的需求也在逐渐增加，煤炭作为重要的能源供给，开采量也在不断上升。然而，伴随着煤炭开采量的增加，煤炭开采过程中的安全事故呈现出逐渐上升的趋势。据统计数据显示，近一半的矿山事故与地下水存在关联^[2]。矿井水害对煤矿生产构成了严重的威胁。首先，水害事故频繁发生，尤其是在一些新建矿井和生产规模较大的矿井中，水害问题尤为突出。由于新建矿井和生产规模较大的矿井开采强度高，含水层结构遭受到严重破坏，极易引发矿井水害灾害。这种情况在我国的国有重点煤矿中尤为普遍，大约一半的国有重点煤矿都受到了水害的威胁^[3]。矿井水害不仅影响煤矿的安全生产，也制约了我国经济的快速发展。水害事故会导致人员伤亡和财产损失，同时还会造成大量的煤炭资源无法开采，这不仅是一种资源的浪费，也会对环境造成破坏。因此，解决矿井水害问题对于确保矿工的安全，保障煤矿安全生产，促进国家经济稳健可持续发展都有重要意义。

水害的发生主要表现为涌水量增大，短时间内大量的水突然涌入地下矿井空间，造成了矿井水害，涌水量是矿井水害发生的最直观的表现和预测方式。水害防治工作的基础数据包括且不局限于：矿压、裂隙带发育高度、掘进工作面进度等地质相关参数和涌水量、钻孔水位、微震能量等矿井水害相关参数。目前，水害参数的预测中基于矿井涌水量预测计算的理论和方法占比基数较大，但到目前为止，涌水量预测模型的预测数值误差较大，很难达到精准预测^[4]。造成这种误差的原因可以概括为以下三个方面：地质环境与水文地质条件模糊不清、水文地质参数不具备代表性、预测模型的建立缺乏代表性^[5]。要保证涌水量预测的准确性，必须提供可靠的水文地质参数，并且满足或理想化各个预测模型的适用条件。但由于煤矿开采普遍存在周期长、难度大等问题，且开采过程中伴随着大大小小的矿井事故，导致现场地质以及水文地质资料缺失或混乱现象严重，很难满足预测模型的要求。另外，由于矿井涌水量数据无法通过传感器实时监测，都是煤矿领域专家结合地质参数通过公式计算而来，使得涌水量数据的预测值都是以年、月、日为单位，难以满足实时的需求^[6]。针对以上涌水量预测模型搭建时各个方面的局限性与预测能力不足的问题，近年来，逐渐有学者针对采区钻孔水位、微震能量等其它水害参数展开预测，反映矿区

地下水的动态变化过程，预防水害的发生。基于前人研究的基础上，继续引入信息化技术^[7-9]，提高煤矿水害参数预测方法的精确度，进一步实现对矿井水害的预测预警，对确保煤矿安全生产以及水害防治工作具有重要意义。

1.2 国内外研究现状 (Research status at home and abroad)

矿井水害监测数据属于典型的非线性非平稳性^[10-12]的时序数据，矿井水害监测数据的预测常常体现在涌水量的预测上。近几年，随着深度学习的发展，国内外研究学者将深度学习应用在矿井水害的预测中，为矿井水害防治提供一定依据，对矿井水害的超前预警起到辅助决策作用。

1.2.1 时序数据预测研究现状

时间序列数据(Time Series Data, TSD)是一种按时间顺序排列的数据，用于记录某个主体在不同时间点的测量数值，包括了监测时间和监测数据两个关键要素。目前，各工业领域不断完善传感器监测系统，生产过程中积累了大量传感器时序数据，例如矿井水文数据、电力负荷数据以及风速数据等等。目前对于时序数据的研究有很多，根据不同领域的不同需求，包括时序数据的预测、分类以及异常值检测等等。时序数据预测就是通过某个模型总结历史时间序列的特征规律，从而预测其未来变化趋势的方法^[13]。涌水量数据是典型的时序数据，长短时记忆网络常用于涌水量预测研究中^[14-15]。

目前，时序数据预测主要分为三大类：基于统计学、基于传统机器学习和基于深度学习的预测。

(1) 统计学方法是根据时间序列所呈现出的规律，通过数理统计学方法建立模型，研究统计规律^[16]，涉及到指数平滑预测模型^[17]、自回归模型^[18]、移动平均模型^[19]、自回归滑动平均模型^[20]、自回归移动平均预测模型^[21]等等，这些模型可以帮助我们预测随机数据序列的趋势和规律，并且此类模型简单高效，但是过分依赖稳定性的假设条件，如果直接输入非平稳性数据，预测效果很难满足要求。对非平稳数据，需要对其进行差分处理，然后建立预测模型，不具备通用性。并且此类模型只适应于小样本数据集，对于数据量较大的输入，预测效果并不是很理想^[22]。

(2) 传统机器学习的模型包括：SVM 回归、BP 神经网络、随机森林预测模型等。在煤与瓦斯突出预测方面，郑晓亮等^[23]提出了一种新的方法，即将数据挖掘多重填补(MI)算法与支持向量机(SVM)结合，以解决训练数据量不足和数据集缺失严重的问题。他们通过扩充数据集并利用 SVM 进行训练和测试，发现这种结合模型可以有效提高煤与瓦斯突出事故的识别率。郑方燕^[24]等人对时栅时序数据建立 BP 神经网络预测模型，通过 BP 拟合时栅实测角度值历史

时刻与当前时刻间的映射关系，发现其潜在变化规律，预测出下一个周期内时栅的测量角度值。钟登华^[25]等人建立随机森林回归模型拟合坝料含水率变化和气象因素间的非线性关系，对坝料含水变化进行精准预测。乔伟^[26]等人通过粒子群优化算法（PSO）对支持向量机回归（SVR）进行参数优化，对煤矿导水裂隙带高度进行预测，为矿井水害防治提供有力的科学依据和技术支持。机器学习相比于统计学方法对具有非稳定、非线性特点的数据集预测效果较好，但是，因为传统机器学习模型的输出仅考虑上一时刻输入，忽略了长时序数据历史时刻输入的影响，使得模型的预测效果并不能完全满足工业需求。而且传统机器学习的预测模型参数估计复杂，在数据量较大的情况下预测误差较大。

（3）深度学习的预测模型包括：集成深度学习、多时间尺度 RNN^[27-28]、LSTM^[29-30]、GRU^[31-32]和 Transformer^[33-34]神经网络等等。此类模型在训练过程中可以挖掘时序数据在时间上与空间上的依赖关系，相比于统计学模型具有更高的适用性，善于处理非线性关系的数据，而且可以关注传统机器学习所忽略的长距离历史时刻输入对预测结果的影响。在实践中，深度学习预测模型往往展现出较好的预测效果。

1.2.2 矿井涌水量预测研究现状

矿井水害对矿井安全生产以及矿工生命安全造成严重损害，随着矿井涌水对采矿造成的威胁进一步恶化^[35-36]，矿井涌水问题得到了越来越多的关注。一般常用的矿井涌水量预测方法根据他们的主要特征和理论基础，可以分为确定性方法和不确定性方法。

确定性方法包括数值模拟法、解析法等。大多数学者基于 modflow 或数值模拟以及 GMS 等方式的水害模拟进行矿井涌水量预测^[37-39]研究，通过对矿井涌水量进行预测来实现对矿井水害的超前预警^[40-41]。孙刚友等^[42]、罗奇斌等^[43]、Chengxin J 等^[44]都利用数值模拟方法对矿井研究，实现了对矿井涌水量的预测；Xiong Z 等^[45]利用离散裂隙网络三维仿真软件研究了隧道顶板突水；Chen X 等^[46]以祁东煤矿为案例，非固结和承压含水层下采矿过程中突水危险区域的预测；侯恩科等^[47-48]利用数值模拟方法对矿井水文地质条件分析和模拟并预测涌水量。但数值模拟需要大量观测数据和高精度地质信息，模型概化地质原型的程度决定了预测的精度，整体预测结果偏差较大。陈思佳^[49]采用以大井法分段原理为基础的解析法预测工作面顶板涌水量；另外，一部分学者基于地下水动力学，对矿井涌水量进行预测。王春刚等^[50]通过开展对井田的地质研究，构建了渗流偏微分方程，计算不同时间段的涌水量，该方法适用于地质环境复杂的矿区，预测结果存在一定误差。彭辉才等^[51]通过水均衡法对贵州绿塘煤矿的涌水量进行预测。水均衡法是一种根据矿区地质条件和水文地质参数建立的预测涌水量

的方法，它基于补给、径流、排泄和源汇等条件建立水平衡方程。尽管该方法所需参数较少，但难以充分考虑地下水补排关系的各个组成部分。但随着大数据和机器学习技术的发展，基于历史监测数据的预测模型越来越受到重视，这些方法不依赖于详细的物理模型，而是通过分析历史数据来预测未来的涌水量。

非确定性方法包括比拟法、统计法、人工智能法等。宋武元^[52]采用水文地质比拟法对矿井地质条件进行分析，并基于分析结果对矿井涌水量进行预测；苗霖田等^[53]通过对香山煤矿的其他矿区水文地质资料的比拟，成功实现了对该矿区涌水量的长短期预测。这些使用典型方法的涌水量预测计算出的涌水量常常是一个静态的值，不能实时反应涌水量变化的动态过程，与实际涌水量差距较大。另外，使用水文地质比较法进行预测的前提是目标矿井必须存在与其水文地质条件相似且正在生产的矿井，通过与其他矿井在实践中积累的水文地质数据进行比较，推断涌水量的预测值。这种方法计算简便，但准确性较低，适用范围受到一定限制。王档良等^[54]运用统计方法对涌水量进行预测，该方法简单易行，但对数据及操作人员依赖性很强。吴卫忠等^[55]利用人工智能方法建立时间序列模型对涌水量进行预测，具有运算速度快，适应性强的特点，但仅利用涌水量历史数据进行研究预测，精确度低且稳定性弱。

王晓蕾等^[56]针对涌水量预测，建议将来应当建立多因素综合模型，通过扩展改进传统的单一因素预测模型，来提高预测精度和适用范围^[57-58]。然而，目前涌水量预测领域中较少有研究多因素涌水量预测模型的情况。许延春等^[59]提出了一种基于微震监测的工作面底板突水全时空预警的方法，进一步证实了微震数据预测涌水量具备可行性。

矿井涌水量预测是对整个矿井的涌水情况进行预测，这种预测研究较为常见。熊鹏等^[60]利用数值模拟方法对矿井涌水量进行预测，但由于预测范围较广，面临着数据量不足、复杂性增加、干扰因素增加等问题导致预测精度较低。因此，矿井工作面涌水量预测更具精确性和针对性，可以更准确的提供涌水量变化信息，以便采取合适的安全措施。

1.2.3 数据驱动的涌水量预测研究现状

近些年，随着计算机技术的发展，深度学习网络的普及，越来越多的学者从数据本身的性质和规律出发，尝试改进模型结构，并将其他领域常用算法应用到预测领域中，由于不同领域产生的数据不同，数据所具备的特性也不相同。因此，需要充分考虑数据特性建立对应的预测模型。模型预测相较于传统的预测方法，精度会具有不同程度的提升。另外在对矿井水害的预测上，一般较多的是对涌水量数据进行的单序列直接预测，刘慧等^[61]运用时间序列预测模型对矿井涌水量进行预测。史新国等^[62]对水害数据进行处理应用，构建了矿井水害

智能预测模型,提高了矿井水害预测结果的科学性,为煤矿的安全生产提供了数据支撑。赵晓丹等^[63]通过三种深度学习网络对涌水量数据进行预测,实现了对矿井涌水量的预测,并对结果误差进行了分析,具有较大的应用潜力。但这种仅考虑涌水量历史数据的单因素方法仅考虑涌水量历史数据,忽略了其他因素的影响。因此,还需增加考虑其他有关矿井水害的影响因素。微震能量是指在地下岩体中由于地质构造变化、岩石应力破裂等引起的微小地震活动所释放的能量^[64-65]。微震能量的变化可以反映地下岩体的应力状态和破裂活动,而岩体的应力状态和破裂活动与涌水量的变化有关^[66]。当微震能量增大,岩石破裂增大,导水裂隙带发育,导致涌水量的增加^[67]。余国锋等^[68]利用 RNN 神经网络对微震数据监测预警,实现对煤层底板突水的预警。李健林等^[69]基于矿井水害特征提出了混沌-广义神经网络对水害涌水量进行预测,将矿井涌水量的影响因素考虑在内,不仅提高了模型的预测精度而且模型的适用性也有所提升。多种因素相互制约,并通过模型学习更多数据中的规律进行预测,预测结果具有一定优越性。邢金莎^[70]在明渠流量数据、管道流量数据、温度等水文参数的基础上建立深度学习预测模型,提高了预测结果的准确度。

1.2.4 目前存在的问题

综合以上研究现状,目前各学者对涌水量预测已进入了较为深入的研究,但还存在一定问题:

(1) 但针对涌水量预测,预测范围较广、复杂性增加、干扰因素增多等导致涌水量预测准确率低。

(2) 针对传统经典方法的涌水量预测,一般不能展现动态过程,与实际结果相差较大。由于深度学习的发展,开启了涌水量预测的新道路。随着模型的更新迭代,涌水量预测的精确度也有待进一步提高。

(3) 涌水量影响因素是多因素的,目前使用涌水量历史时序数据进行预测较多,多因素涌水量预测研究亟待开展。

1.3 研究目标与研究内容 (Research objectives and contents)

1.3.1 研究目标

本文的研究目标是基于涌水量相关数据特性,从两个方面实现对涌水量的预测。首先是基于涌水量数据特征提出的 CEEMDAN-SSA-LSTM-ARIMA 混合时间序列模型对矿井工作面实现单因素时序预测。其次,全面分析涌水量相关因素,确定与该工作面涌水量最为相关且易获取的数据,提出 SSA-CG-Attention 多因素涌水量预测模型并通过与单因素模型、多因素模型对比研究以

及模型稳定性研究确定多因素模型的优越性，以实现水害参数的超前预警，对水害防治、预警工作提供辅助决策作用。

1.3.2 研究内容

本文以从亭南煤矿 207 工作面获取到的涌水量、钻孔水位、微震能量数据为研究对象，在对矿井工作面涌水量预测国内外研究现状的基础上，分析探索数据规律，有针对性的建立不同适用性预测模型，并且根据数据、模型特征以及应用场景等方面对模型评价指标进行分析，有针对性的选择合适的评价指标，以确保模型在实际应用中的有效性和可靠性。主要研究内容如下：

（1）涌水量及相关数据特点研究

主要包括涌水量数据的季节性研究、周期性研究、平稳性研究以及钻孔水位数据、微震数据和涌水量之间的相关可行性研究。由于时代发展，许多矿井基本都配备了水文监测系统，实现对相关水文数据的监测。得到的数据如涌水量数据可以反应矿井不同的特征，但是由于煤矿井下环境恶劣，监测收集到的数据存在很严重的噪声情况，如数据间断、数据缺失等，这给后期预测带来了很大困难。为解决这一问题，需要对数据进行数据分析、异常值处理等操作。对预处理之后的涌水量数据使用 SPSS 构建季节性 ARIMA 模型将时间序列分解成趋势数据、季节性数据、随机数据，得到其季节性规律。通过绘制涌水量与推进距离之间的折线图以及对应阶段的对应，得到涌水量周期性规律。通过对涌水量进行单位根检验进行稳定性分析，得到稳定性规律。在多因素涌水量预测阶段，通过对所选钻孔水位数据、微震数据以及涌水量进行斯尔曼相关性系数的计算，研究钻孔水位数据、微震数据与涌水量之间的相关性。根据三者对应地质信息的变化情况得到对应规律说明将钻孔水位数据、微震数据作为参数进行多因素涌水量预测的可行性。

（2）涌水量预测模型研究

学习模态分解算法、循环神经网络、麻雀搜索算法等深度学习的基本理论知识，对每种算法模型进行深入分析，了解其优势、不足以及适用条件等，根据涌水量及相关数据的特征对应建立不同的时间序列预测模型。

单因素混合涌水量预测模型：根据涌水量数据的稳定性、周期性，季节性特征建立 CEEMDAN-SSA-LSTM-ARIMA 的单因素混合时间序列预测模型。由于涌水量本身具有的非平稳性和非线性特征，首先通过 CEEMDAN 将涌水量数据分解为多维子分量，减小在预测中带来的误差。然后在分解为不同分量的基础上，研究其稳定性，并针对各分量特征分别建立 SSA-LSTM 网络模型和 ARIMA 模型，根据不同分量数据特征分别输入到不同模型中预测。将不同分量预测结果，根据时域相加的方法，进行叠加融合，得到最终的涌水量预测结果。

多序列涌水量预测模型：结合微震数据和钻孔水位数据两个特征因素，建立 SSA-CG-Attention 模型。其中 CNN 用于提取非线性特征，GRU 用于捕捉序列信息，Attention 用于加强对重要信息的关注，SSA 用于优化参数。微震数据和钻孔水位作为特征变量，将这两个特征作为输入值输入到 SSA-CG-Attention 模型中，可以更全面地考虑工作面涌水量的关联因素，从而提高预测的准确性和稳定性，为工作面采取相应的排水措施提供依据，有利于保障工作面的安全。

(3) 在亭南煤矿 207 工作面上，采集相关数据进行验证，将提出的两种预测模型通过与不同的预测模型评估指标进行对比分析，得到所提多因素涌水量预测模型的优越性。主要是通过单因素模型对比验证即各单因素涌水量预测模型预测结果准确性的对比，确定所提单因素涌水量预测模型的优越性。通过多因素模型对比即各多因素涌水量预测模型预测结果准确性的对比，确定所提多因素涌水量预测模型的优越性。通过单、多因素模型对比即单因素涌水量预测模型和多因素涌水量预测模型的预测结果对比分析确定多因素涌水量预测模型的预测结果准确性更具优势。通过稳定性对比即多因素涌水量预测模型和单因素涌水量预测模型预测结果的稳定性对比，确定多因素涌水量的稳定性优势。

1.4 技术路线及创新点 (Technical route and innovation points)

1.4.1 技术路线

针对亭南煤矿的水害监测预警数据，分析数据特征，根据不同数据特征建立涌水量预测模型，通过对不同类型的涌水量预测模型在不同方面进行对比分析，确定本文涌水量预测模型的优越性。为亭南煤矿的水害防治提供一定的技术支持，并为水害的监测预警提供辅助决策作用，技术路线图如图 1-1 所示。




图 1-1 技术路线图

Figure 1-1 Technology roadmap

1.4.2 创新点

基于数据驱动的亭南煤矿工作面涌水量预测研究的创新点主要体现在三个方面，对涌水量相关数据的规律研究，涌水量预测模型的构建，包括单因素涌水量预测模型和多因素涌水量预测模型以及模型优越性确定。

(1) 建立了 CEEMDAN-SSA-LSTM-ARIMA 单因素混合时间序列预测模型，克服了由于涌水量数据的不稳定性导致预测结果较低的问题，同时避免了

局部最优解问题，提升了预测准确性。

(2) 建立了 SSA-CG-Attention 多因素涌水量预测模型。确定了孔水位和微震数据为预测特征指标，综合考虑模型网络结构，实现了对涌水量更准确、更稳定的预测。

2 数据来源

2 Data source

数据来源于数据取于位于陕西省中西部-黄陇侏罗纪煤田中段的彬长矿区中部的亭南煤矿 207 工作面。本章详细介绍数据来源区域情况、数据情况以及模型评估指标，为后续研究奠定基础。

2.1 研究区概况 (Overview of the study area)

亭南煤矿位于陕西省中西部-黄陇侏罗纪煤田中段的彬长矿区中部，隶属于咸阳市长武县亭口镇。煤矿东北部是 312 国道、福银高速公路和西平铁路，所处地区有便利的交通条件，便于煤炭外运。位于亭口镇中心，距离长武县城北部 20 公里，距离彬县县城东侧 20 公里，距离西安市约为 170 千米。（见图 2-1）。井田东西长约 11.3 km，南北走向宽大致为 5.1 km，面积为 35.5484 平方千米。采矿范围由 15 个拐点圈定（见图 2-2），东西长约 11.3 km，南北宽约 5.1 km，面积 35.5486 km²。1997 年 8 月国家计委批复（计交能[1997]1351 号）亭南煤矿的设计生产能力为 120 万吨/年，2006 年经陕西省煤炭工业局批复（陕煤局发[2015]98 号），核定矿井生产能力 500 万吨/年。2020 年核定生产能力 450 万吨/年。主要开采 4 号煤层，该矿井采用了综合采煤放顶回采工艺，采用了倾向长壁后退式综合机械化采煤方式，机械设备负责煤矿下采，而综合采煤支架负责支护。




图 2-1 井田位置示意图

Figure 2-1 Location diagram of the well field




图 2-2 亭南井田范围示意图

Figure 2-2 Schematic diagram of the scope of Tingnan well field

207 工作面位于二盘区中部，是二盘区的第五个工作面。具体位置及井上下关系如表 2-2 所示，该工作面的采煤层为延安组 4 煤，存在一定倾角，倾角约为 0 至 8 度，平均约为 4 度，厚度在 13.6 至 21.2 米之间，平均约为 18.0 米，上分层回采厚度在 7.0 至 8.0 米之间，平均约为 7.5 米。开切眼到 1350 米处的回采厚度约为 6.5 米，1350 米到停采线处的回采厚度约为 9 米。206 工作面位于 207 工作面东侧，运输顺槽相隔 30 m 煤柱，实炭区位于 207 工作面西侧，轨道大巷保护煤柱位于 207 工作面南侧，井田边界位于 207 工作面北侧。207 运输顺槽与胶带输送机大巷相连，巷道总长 2558 m；207 回风顺槽与回风大巷相通，巷道总长 2578 m；切眼位于矿区北部边界，采用倾向长壁综合机械化后退式采煤法回采，全部垮落法处理顶板。其中 207 面走向长度 2173.9 m，倾向长度为 200 m，于 2017 年 8 月 17 日正式回采，截止 2019 年 5 月 10 日回采结束，共回采长度 2173.9 m。具体工作位置见表 2-1。

表 2-1 工作面位置简表
Table 2-1 Summary table of workplace locations

水平名称	+455m		采区名称		二盘区	
地面标高（m）	+858～+1074		井下标高（m）		+360～+396	
回采对地面设施的影响	207工作面采用综采放顶煤回采工艺进行回采，煤层厚度13.2～21.6m，平均煤厚17.4m，平均采厚为8.6m。另外对回采影响范围内的村庄，已提前进行搬迁，地表无其它建筑物。根据207工作面回采后地表岩移观测数据可知，回采后地表沉降和民房变形等级均在Ⅰ级范围内，水平变形 $\varepsilon \leq 2.0\text{mm/m}$ ；曲率 $K \leq 0.2\text{mm/m}$ ；倾斜 $i \leq 3.0\text{mm/m}$ 。					
井下位置及四邻采掘影响	207工作面位于二盘区的中心位置，207工作面的回风顺槽东侧30m处是206工作面的采空区，而该工作面的西侧和南北侧则分别为实炭区。207运输顺槽与胶带输送机大巷相连，巷道总长2558m；207回风顺槽与回风大巷相通，巷道总长2578m；切眼位于矿区北部边界。					
推采长度(m)	2173.9	工作面长度(m)	200	面积(m ²)	434780	

2.2 地质概况 (Geological overview)

2.2.1 地层概况

亭南煤矿地表覆盖着第四系黄土和新近系红土, 仅在泾河、黑河河谷、宇家山南沟及巨家沟出露有白垩系地层。依据钻孔揭露, 区内地层由老到新依次为: 三叠系下统胡家村组, 侏罗系下统富县组, 侏罗系中统延安组、直罗组、安定组, 白垩系下统宜君组、洛河组、华池组, 新近系及第四系。井田地层特征见图 2-3。

地层系统				代号	厚度 (m)	岩性简述	备注
界	系	统	组				
新生界	第四系	全新统		Q ₄	10m左右	砾石、砂、亚粘土组成的次生黄土，疏松，底部砂砾石较多	分布在沟谷、河床及河滩阶地
		上更新统	马兰组	Q ₃	5~8	浅黄色黄土，疏松，垂直节理发育，含蜗牛化石	分布于塬面
		中下更新统		Q ₁₋₂	80~100	中部为浅棕黄色亚粘土质黄土，含钙质结核；下部为浅灰黄色、浅棕黄色粉砂质粘土与褐红色古土壤互层，含分散状大钙质结核	分布于塬面黄土层以下，不整合于新近系及中生界多组地层以上
	新近系			N	50~90	棕红色粘土、砂质粘土，底部常见浅棕红色砂砾石层	出露于河谷及沟谷两侧，与下伏白垩系华池组假整合接触
中生界	白垩系	下统	华池组	K _{1h}	$\frac{0 \sim 51.70}{30.13}$	上部为灰色泥质粉砂岩；中部为紫灰色、灰绿色泥岩、砂质泥岩夹同色粉-细砂岩；下部为黄绿色、浅灰绿色粉-细砂岩夹泥岩	仅在泾河、黑河河谷及巨家沟地表有出露，与下伏洛河组整合接触
			洛河组	K _{1l}	$\frac{207.75 \sim 340.83}{287.29}$	棕红色巨厚层状细~中~粗长石砂岩夹同色含砾粗砂岩及暗棕红色泥岩。下部为中~粗砂岩，上部为中~细砂岩	区内普遍沉积，地表仅在泾河、黑河河谷及宇家山南沟有出露，与下伏宜君组整合接触
			宜君组	K _{1y}	$\frac{6.44 \sim 47.70}{29.27}$	紫红色、浅紫红色巨厚层状中~粗砂岩夹含砾粗砂岩透镜体	区内普遍沉积，与下伏侏罗系安定组假整合接触
	侏罗系	中统	安定组	J _{2a}	$\frac{15.33 \sim 87.60}{53.03}$	紫红色、棕红色砂质泥岩、粉~细砂岩夹浅棕红色、紫灰色砂岩，底部为巨厚层状含砾粗砂岩-细砾岩	区内普遍沉积，与下伏直罗组假整合接触
			直罗组	J _{2z}	$\frac{1.51 \sim 41.20}{21.53}$	上部为紫红色、紫杂色及灰绿色泥岩夹灰绿色砂岩，含黄铁矿结核；中下部为灰绿色、灰白色粗砂岩夹灰绿色砂质泥岩；底部为灰白色含砾粗砂岩，有时可见细砂岩	区内普遍沉积，与下伏延安组假整合接触

图 2-3 亭南煤矿地层特征

Figure 2-3 Formation characteristics of Tingnan coal mine

207 工作面地层与煤矿整体类似，但少了华池组（K_{1h}），新近系（N），工作面地层综合柱状图如图 2-4 所示。









系	组	柱状 1: 200	层厚
第四系			92.6
白 垩 系	洛河组		345.1
	宜君组		34.9
侏 罗 系	安定组		61.7
	直罗组		30.3
	延安组		90.08
	富县组		21.6
三叠系	胡家村组		17.5

图 2-4 207 工作面地层综合柱状图

Figure 2-4 Comprehensive column diagram of strata on working face 207

2.2.2 煤层

亭南煤矿主采煤层为 4 煤，平均厚度 10.75 m，含煤系数 18.99 %，主要由暗煤组成，期间有较少亮煤和丝炭条带，整体为黑色的半暗煤。上部煤炭的结构为块状或条带状，下部的结构一般为破碎状或粒状，同时具有垂直裂隙。该煤层相对稳定，沿着向斜轴部逐渐变薄，煤层厚度变化较大。矿区煤层厚度的等值线图如图 2-5 所示。207 工作面位于二盘区西侧，是二盘区第 5 个回采工




Figure 2-5 Contour map of seam thickness in Tingnan Coal Mine

表 2-2 煤层顶底板情况表

名称	岩性	厚度/m	岩性特征
老顶	粗砂岩	19.0	粗粒砂岩：灰白色，块状构造，成份主为石英，长石，含少量云母片炭屑与暗色矿物，颗粒呈圆状，分选中等。钙质胶结，坚硬，富含黄铁矿结核与晶粒。 细粒砂岩：浅灰色，分选均匀，钙质胶结，含炭屑。
	细砂岩	14.0~61.0	
直接顶	砂质泥岩	2.07	灰黑色，含植物叶部化石，具水平~缓波状层理，含砂量在20%左右。
		1.3~5.06	
直接底	泥岩	1.98	褐灰色，块状，含鲕粒，顶部1.10m厚，含植物根部化石。
		0.94~3.2	
老底	砂质泥岩	9.51	灰绿色，显水平层理。中部含泥岩薄层，见光滑面，底部含粗砂岩。
		2.8~19.8	

该区域跨越南玉子向斜轴部, 根据已有地质勘探资料, 构造相对简单。根据勘探资料显示, 南玉子向斜轴部自 112 号孔向东呈 NEE 向延伸, 其倾角较小且较平缓。工作面从向斜的北翼开始进行俯采, 经过向斜轴部平缓段, 然后进入向斜南翼仰采段, 这对回采影响不大。在该区域未观测到较大的断层, 而在向斜轴附近的煤岩层有些破碎。




图 2-6 亭南井田构造纲要图

Figure 2-6 Structural outline of Tingnan mine field

2.2.4 影响回采的其它地质情况

矿山回采受到多种地质条件的影响，包括高瓦斯和煤尘爆炸危险、自燃倾向以及冲击地压倾向等，具体内容见图 2-7。




图 2-7 影响回采的其它地质情况表

Figure 2-7 Lists other geological conditions affecting mining

2.3 水文地质概况 (Hydrogeological profile)

2.3.1 含、隔水层

煤矿内岩层按其含水性、含水类型及水力特征，可划分为 7 个含水层组和 4 个隔水层，各含、隔水层对应地层见表 2-3 所示。

表 2-3 亭南井田含水层与隔水层特征表

Table 2-3 Characteristics of aquifer and aquifer in Tingnan well field

地层名称		含、隔水层名称		含、隔水层特征
系	组			
第四系	——	冲、洪积含水层（I）		一般5~10m，最大14m，分布于泾河、黑河沟谷中。
	——	黄土孔隙~裂隙潜水含水层（II）		60~80m，分布于巨家塬东北部残塬宽梁地段。
新近系	小章沟组	红土隔水层段（III）		51.60~83.90m，分布于黄土梁塬地段。
		砂卵砾含水层段（IV）		2.30~9.61mm，断续分布于红土层底部。（弱富水）
白垩系	华池组	泥岩相对隔水层段（V）		厚度南薄北厚，中东部缺失，北部黑河河谷地段及西南局部地段厚度20~30m，余则厚度小于10m。
	洛河组	砂岩孔隙~裂隙含水层（VI）		东南部厚度100m左右，西南部厚200~300m，全井田分布。（中等富水）
	宜君组	砾岩孔隙~裂隙含水层（VII）		6.44~47.70m，平均29.96m，全井田分布。（弱富水）
侏罗系	安定组	泥岩隔水层（VIII）		东部泾河、黑河河谷地段厚30~60m，中部10~20m，西部30~40m，平均53.61m，井田大部分分布，局部地段缺失，如3-1号孔。
	直罗组	砂岩裂隙含水层（IX）		中部及北部厚20~30m，中南部和西南部厚度不足10m，平均21.53m，全井田分布。（弱富水）
	延安组	裂隙含水层（X）	4煤	井田东北及西南部厚50~70m，中部及东南厚30~50m，其余地段小于30m，全井田分布。（及弱富水）
	富县组	隔水层（XI）		0~33.25m，平均10.19m，部分地段缺失。

其中，对工作面影响较大的有白垩系下统宜君组孔隙~裂隙承压含水层，渗透系数 0.020 m/d，单位涌水量 0.0088 L/s.m，富水性弱；白垩系下统洛河组孔隙~裂隙承压含水层组，含水层平均渗透系数为 0.09579 m/d，洛河含水层单位涌水量 0.25345 L/s.m，洛河组为特厚砂砾岩含水层，富水性中等。根据 207 工作面回采情况：工作面推采长度 2173.9 m，回采厚度为 5.0~9.5 m，最大回采厚度为 9.5 m。裂采比根据二盘区工作面实测裂采比 22.7 倍进行计算，导水裂缝带发育高度为 215.65 m，工作面回采后导水裂缝带波及白垩系洛河组含水层。

207 工作面主要受 4 煤顶板白垩系承压含水层水害威胁。参照 ZK8-1、3-1 号钻孔（图 2-8），207 工作面 4 煤顶板至洛河组底界距离约 173.0 m~182.0 m，回采后导水裂隙带沟通洛河组。洛河组含水层岩性主要以中粒砂岩、粗粒砂岩和粗砾岩为主，渗透系数为 0.0241 m/d。虽然渗透性及富水性均较弱，但巨厚

含水层静储量丰富，导致工作面涌水量居高不下，起伏剧烈。

参考钻孔	地层					
	4煤厚度/m	4煤以上延安组厚度/m	直罗组厚度/m	安定组厚度/m	宜君组厚度/m	4煤顶板至洛河组底界厚度/m
ZK8-1	19.8	66.3	18.4	62.8	34.5	182.0
3-1	19.6	66.2	26.8	48.5	31.5	173.0

图 2-8 207 工作面钻孔地层厚度数据

Figure 2-8 Summary of formation thickness data of borehole in 207 face

2.3.2 充水水源

大气降水：在 2006 年至 2020 年期间，本区的年平均降雨量为 524.8 毫米，降雨主要集中在 7-9 月。207 工作面地表地形起伏不平，沟壑纵横，降雨大部分以地表径流形式流入黑河、泾河，没有直接影响井田，同时矿井直接充水的含水层深埋在直罗组和延安组的砂岩裂隙中，不会受降雨影响。洛河组砂岩裂隙含水层多分布在陡坎坡谷中，并且不利于降雨渗透。因此，大气降水对矿井涌水量影响不大。

地表水：地表水资源主要涵盖泾河、黑河、亭口水库以及反调节水库。泾河贯穿井田东部，河流自北向南，其流量范围在 $8150.00 \sim 1.03 \text{ m}^3/\text{s}$ 之间，平均流量为 $57.70 \text{ m}^3/\text{s}$ 。在 1911 年，泾河曾发生规模空前的洪水，流量高达 $157000 \text{ m}^3/\text{s}$ 。相较之下，黑河源自煤矿东北边缘，向东南流动，全程穿越煤矿约 2.4 km，平均流量为 $2.78 \text{ m}^3/\text{s}$ ，历史最高流量达 $1160.00 \text{ m}^3/\text{s}$ 。此外，磨子沟和安化沟也为黑河的支流，尽管其流量相对较小。泾河和黑河的水流状态呈现侵蚀冲刷特征，水流湍急，且河床底部缺乏稳定的隔水层。煤矿周边的抽水井数据表明，并无隔水层存在。矿井开采可能导致洛河宜君组承压水水头急剧下降，从而可能使地表水源向洛河宜君含水层组补给，成为矿井充水的间接来源。亭口水库枢纽工程和反调节蓄水工程同样位于井田范围内，构成地表水资源的一部分。亭口水库枢纽工程位于黑河干流下游，坝址位于亭南井田范围内。与 207 工作面距离较远，洛河宜君组含水层垂向具有分段性，含水层主要接受侧向补给，下段渗透性差，上、下端之间水力联系弱。采动破坏及井下探放水钻孔已局部波及到洛河宜君组下段含水层，但上段含水层通过补给下段含水层间接向工作面充水，受上、下段水力联系不密切的影响，采动对洛河组上段含水层影响小，水库位于洛河组含水层上部，因此，采动对水库的影响也小。黑河水位标高 $+849.21 \sim +853.52 \text{ m}$ ，亭口水库蓄水后正常蓄水位 $+893.0 \text{ m}$ ，校核洪水

位+895.68 m，亭口水库蓄水后水位将高出黑河河谷底部约 40~45 m。中塬沟沟谷最低标高为+857 m，反调节水库正常蓄水位+920.3 m，校核洪水位+921.0 m，反调节水库蓄水后水位将高出中塬沟谷最低部约 64 m。

充水含水层：在煤矿开采过程中，工作面会形成底板破坏区和顶板导水裂隙带，位于这两个区域的水层直接供水给工作面。而在这两个区域之外的水层，虽然不直接供水给工作面，但在开采过程中可能会间接补给直接供水的水层，称为间接供水水层。207 工作面的煤层底板为富县组隔水层，平均厚度为 10.19m，隔水性能良好。因此，原本并未考虑工作面底板存在直接供水水层。由于 4 煤埋深较深，距第四系 445m 以上，除河谷外第四系底部有约 40m 厚的古黄土层，基底为新近系中统小章沟组红土隔水层段，具有良好的隔水性能。新近系砂卵砾石含水层下方为华池组隔水层。因此，在 207 工作面的开采中，第四系和新近系的水层不会对工作面产生影响，主要会影响工作面开采的仍是直接供水水层，包括侏罗系延安组砂岩裂隙水层、侏罗系直罗组砂岩裂隙承压水层、白垩系宜君组砾岩孔隙至裂隙水层以及白垩系洛河组砂岩孔隙至裂隙水层。

老空水：邻近工作面存在老空水，工作面开采主要出水水源是直接含水层，老空水关联钻孔水位波动较小。

2.4 研究数据情况 (Relevant data of water inflow in the study area)

涌水量数据来源于陕西彬长矿区亭南煤矿 207 工作面 2017 年到 2019 年一个完整的回采过程中。从开始回采的无涌水量，随周期来压，涌水量阶梯式增长，达到 928 m³/h。

工作面微震监测系统布置图以及水位监测钻孔平面图如图 2-9 所示。




图 2-9 工作面微震监测系统和水位监测孔分布图

Figure 2-9 Face microseismic monitoring system and water level monitoring hole distribution

为实现在该工作面微震时间的实时监控，对二盘区进行监测系统设置，确保微震监测系统覆盖整个二盘区，在该工作面布置了 1 个监测探头和 4 个拾震

器，以便及时监测分析数据、扩大预警范围并采取防护措施。这套微震监测系统可监测工作面回采过程中的煤岩破裂情况，获得微震监测数据。本研究用水位数据来自该工作面白垩系洛河组 3-1 观测孔，该观测孔数据距离工作面最近且数据最全。

对获取到的数据使用线性插值补齐缺失数据。具体的微震数据、水位数据与涌水量数据如图 2-10 所示。




图 2-10 微震能量、钻孔水位与涌水量数据

Figure 2-10 Microseismic energy, borehole water level and water inflow data

2.5 本章小结 (Summary of this chapter)

本章对亭南煤矿以及矿井内 207 工作面的区域位置、地质及水文地质情况等进行了总结介绍。通过对矿井区域、地质以及水文地质条件的了解和学习，为下一步涌水量相关数据的分析以及预测模型的建立打下坚实基础。本章还对实验数据进行了整理和说明，为下一步数据分析和涌水量预测模型的建立验证奠定基础。

3 基于经典方法的涌水量预计

3 Water inflow prediction based on classical methods

解析法、比拟法等经典方法的涌水量预测是较为传统的计算方法，也是目前使用较多，认可程度较强的方法，但也存在一定的局限性。本章通过经典方法对涌水量的预测，说明传统方法的局限性，引出基于深度学习的涌水量预测方法。

3.1 解析法 (Analytical method)

煤层回采产生的垮落带波及范围内的含水层，将直接向矿井充水，为矿井直接充水含水层。开采过程中主要受白垩系下统洛河组、宜君组、侏罗系中统直罗组和延安组含水层水影响，充水含水层均已揭露，特别是白垩系洛河组含水层水已经成为矿井涌水的主要构成部分。在导水裂缝带波及范围内的涌水量分别按不同含水层进行计算，导水裂缝带波及范围内的含水层为侏罗系、白垩系宜君组和部分洛河组，这 3 部分含水层涌水分别进行计算如下。

(1) 侏罗系含水层涌水量计算

在开采过程中，导水裂隙带必然会完全波及到侏罗系含水层，长期放水将导致承压含水层向无压含水层转变。含水层涌水按承压水转无压计算公式如式 (3-1)。

$$\begin{aligned}
 Q &= 1.366K \frac{2HM - M^2 - (H - S)^2}{\lg R_0 - \lg r_0} \\
 R &= 10S\sqrt{K} \\
 R_0 &= R + r_0 \\
 r_0 &= \eta \frac{a+b}{4}
 \end{aligned} \tag{3-1}$$

其中：渗透系数 K ；含水层厚度 M ；疏降水头高度 S ；引用半径 R_0 ；预测区折算半径 r_0 ；影响半径 R ；含水层底板到井中水位置的距离 h ；计算区的边长 a 、 b ； η 为系数。

根据现场相关试验和水文地质数据侏罗系渗透系数 K 取 0.0004591m/d，厚度 M 取 100.4m，水位标高 H 为 456.12m。

水位降深 $S=H-0.5M=405.92$ ；

207 采面形状为长方形， a 取 2260m， b 取 202m，大井引用半径 r_0 为 645.70m；

影响半径 R 为 86.97m； $R_0=R+r_0=86.97+645.75=732.72$ m。

最终，计算 207 工作面涌水量为 $37.61\text{m}^3/\text{h}$ 。207 工作面涌水量计算成果见表 3-1。

表 3-1 207 工作面侏罗系涌水量计算结果

Table 3-1 Calculation result of Jurassic water inrush in 207 working face

含水层	r_0 /m	R /m	R_0 /m	S /m	Q	
					m^3/d	m^3/h
侏罗系	645.75	86.97	645.75	405.92	902.68	37.61

(2) 白垩系含水层涌水量计算

水文地质参数参照 G3、ZK6-5 资料（G3 水位标高+820.61m，ZK6-5 水位标高取+781.41m）计算，根据现场相关试验和水文地质数据白垩系统渗透系数 K 取 0.05m/d 。 M 为白垩系宜君组和洛河组导水裂隙带波及的厚度；G3 距侏罗系顶板水柱高度： $H_1=820.61-539.519=257.51\text{m}$ ；ZK6-5:距侏罗系顶板水柱高度： $H_2=781.4-547.195=141.66\text{m}$ ；平均水柱高度 H 为： $H=199.58\text{m}$ ； $R_0=R+r_0=421.46+645.75=1067.21\text{m}$ 。工作面面积 $F=2246\times 202=453692\text{m}^2$ ；水头损失（水位降幅） $H=26\text{m}$ ；不同煤层开采厚度，白垩系洛河组组含水层涌水量预计结果参见下表 3-2，并绘制煤层开采厚度与涌水量相关曲线图 3-1。

表 3-2 207 工作面不同开采厚度的涌水量计算结果

Table 3-2 207 Calculation results of water influx at different mining thicknesses in the working face

序号	4煤 开采 厚度 /m	渗透 参数 $K(\text{m}/\text{d})$	水柱高 度 $H(\text{m})$	含水 层厚 度 $M(\text{m})$	水位降 深 $S(\text{m})$	引用影 响半径 $R_0(\text{m})$	大井引 用半径 $r_0(\text{m})$	白垩系 Q (m^3/d)	白垩系 Q (m^3/h)	工作面 涌水量 Q (m^3/h)
1	6									37.61
2	7									37.61
3	8									37.61
4	9	0.05	199.58	12	180.53	1067.21	645.75	1453.03	60.54	98.15
5	10	0.05	200.58	30	180.53	1052.53	645.75	3634.05	151.42	189.03
6	11	0.05	201.58	48	180.53	1052.53	645.75	5595.24	233.14	270.75
7	12	0.05	202.58	66	180.53	1052.53	645.75	7336.59	305.69	343.30
8	13	0.05	204.58	84	180.53	1052.53	645.75	8858.10	369.09	406.70
9	14	0.05	205.58	102	180.53	1052.53	645.75	10159.78	423.32	460.93
10	15	0.05	206.58	120	180.53	1052.53	645.75	11241.62	468.40	506.01
11	16	0.05	207.58	138	180.53	1052.53	645.75	12103.62	504.32	524.82




图 3-1 207 工作面煤层开采厚度与涌水量曲线图

Figure 3-1 207 Working face coal seam thickness and water inflow curve diagram

由图 3-1 得，由于煤层开采厚度的增加，工作面涌水量总体也随之增加。采厚为 6-8m 时，工作面涌水量并不随着采厚的变化而增加；采厚为 9m 时，工作面涌水量增加随之放缓，因此。选取白垩系含水层涌水量取采厚为 10m 时的 189.03m³/h。

(3) 导水裂缝带未受波及洛河组含水层涌水量

①根据西部风井抽水试验洛河组含水层渗透系数，K（洛河）取 0.09579m/d；

$$②F=2300*200=460000\text{m}^2$$

③水头损失 $H=50.6\text{m}$ (根据 205 工作面附近钻孔 G2 号钻孔水位变化得出：2013.6 开采开始时水位标高 838.8m 与 2014 年 11 月份回采结束时水位标高 788.2m，得出工作面最大水头损失 $H=838.8-788.2=50.6\text{m}$)；

$$④L=211.7 \text{ (白垩系洛河组含水层厚度)} - 7.3 \text{ (导水裂缝带波及洛河组厚度)} = 204.4\text{m}$$

根据达西定律计算未受导水裂缝带波及洛河组含水层涌水量，计算公式如式 (3-2)。

$$Q=KFh/L \quad (3-2)$$

计算得涌水量为 45.5 m³/h。

根据解析法计算 207 工作面正常涌水量为 272.14 m³/h，最大涌水量取正常涌水量的 2 倍，为 544.28 m³/h。

3.2 面积比拟法 (Area analogy method)

当采掘工作推进到 2018 年 12 月份时, 207 工作面回采长度 2260 m, 面宽 202 m, 取与之开采条件类似的 205 工作面进行面积比拟预计涌水量, 205 工作面回采长度 2162 m, 面宽 200 m, 回采期间正常涌水量为 190 m³/h。

$$Q_{207 \text{ 正常}} = Q_{205} (F_{207}/F_{205})^{1/2} = 200.6.1 \text{ m}^3/\text{h}$$

根据面积比拟法所得 207 工作面的正常涌水量为 200.6 m³/h, 最大涌水量取正常涌水量 2 倍, 为 401.2 m³/h。

3.3 本章小结 (Summary of this chapter)

本章使用解析法等物理机制方法对涌水量进行预测。分别利用解析法、面积比拟法对 207 工作面涌水量进行预测, 并通过对两种方法得到的预测结果与原数据进行对比分析。得到结论: 使用物理机制预测涌水量一般使用得到的正常涌水量值作为整体涌水量预测值, 与涌水量实际值相差较大, 预测效果不理想。由于解析法和面积比拟法缺乏时间维度的考虑, 其中解析法通常关注的是在某一特定时刻的涌水量, 而不是随时间变化的过程。因此, 它无法充分考虑水文地质条件随时间的演变, 如季节性变化、降雨事件等对涌水量的影响。而面积比拟法是根据相似工作面面积比例确定涌水量, 也无时间概念。因此, 一般将基于物理机制的经典方法涌水量预测归纳为静态结果, 不用于涌水量动态预测预警, 为涌水量预测模型建立奠定基础。

4 基于 CEEMDAN-SSA-LSTM-ARIMA 模型的单序列涌水量预测

4 Single series water inflow prediction based on CEEMDAN-SSA-LSTM-ARIMA model

为提高采煤工作面涌水量预测准确度,本章在相关理论的基础上,收集大量工作面涌水量历史观测数据进行整理、统计、分析,将涌水量稳定性、周期性和季节性特征考虑在内,提出了基于数据驱动的 CEEMDAN 和混合时间序列模型工作面涌水量预测方法。首先,运用自适应噪声完备集合经验模态分解算法(CEEMDAN)将涌水量数据分成 7 个本征模态函数(IMF)分量,克服数据本身噪声影响。其次,运用麻雀搜索算法(SSA)优化的长短期记忆网络(LSTM)和差分整合移动平均自回归(ARIMA)构建的混合时间序列模型,根据分解的本征分量不同特征进行预测。最后,将各分量预测结果融合,得到最终涌水量预测结果。将提出的基于 CEEMDAN 和改进的混合时间序列模型与 BP 神经网络、GRU、LSTM、ARIMA 和 SSA-LSTM 模型在研究区进行对比实验得到预测结果。并根据模型、数据特点选取合适的模型评价指标^[71-74],通过评估指标进行具体数值的比较分析,探讨组合模型精准度和适用性。

4.1 相关理论基础(Relevant theoretical basis)

4.1.1 完全自适应噪声集合经验模态分解算法(CEEMDAN)

完全自适应噪声集合经验模态分解(CEEMDAN)算法是一种用于信号处理和分析的方法^[75]。它是经验模态分解(EMD)算法的改进版本,旨在解决 EMD 算法在处理非线性和非平稳信号时的一些问题^[76]。针对 EMD 算法的模式分解问题以及 EEMD 和 CEEMD 分解算法中存在白噪声残留的问题,TORRES 提出了完全自适应噪声集合经验模态分解(CEEDAN)算法^[77]。该算法是在 EMD 算法的基础上结合 EEMD 方法抵消噪声的思想。具体操作为:在处理原始信号时,采用不同的高斯噪声来模拟信号的复杂性,并对其进行经验模态分解(EMD)以获得各个模态分量。再对这些模态分量进行总体平均,得到了一组称为完全自适应噪声集合经验模态分解算法(CEEMDAN)分解的第一个本征分量。随后,在得到分量的基础上去除残差。继续循环以上操作,确定最后的残差为单调后停止循环。这样,得到若干个本征模态分量,这些分量能够帮助我们更好地理解原始信号的结构和变化规律。通过以上的处理步骤,我们可

以更准确地分析原始信号并获得更多有用的信息。具体步骤为:

(1) 在原始信号 $S(t)$ 中加入 M 个高斯噪声 $n_k(t)$ 得到 $S_k(t)$, 具体计算公式如式 (4-1)。

$$S_k(t) = S(t) + (-1)^q * n_k(t) \quad q=1,2; k=1,2..M \quad (4-1)$$

(2) $S_k(t)$ 通过 EMD 分解得到 M 个模态分量 $C_k^1(t)$ 和残差 $r_k^1(t)$, 具体计算公式如式 (4-2)。

$$C_k^1(t) + r_k^1(t) = EMD(S_k(t)) \quad k=1,2..M \quad (4-2)$$

(3) 对 M 个模态分量进行总体平均得到 CEEMDAN 分解的第 1 个本征模态分量 $C^1(t)$, 具体计算公式如式 (4-3)。

$$C^1(t) = \frac{1}{M} \sum_{k=0}^M C_k^1(t) \quad (4-3)$$

(4) 用原始数据减去一阶本征模态函数得到一阶残差 $r^1(t)$, 具体计算公式如式 (4-4)。

$$r^1(t) = S(t) - C^1(t) \quad (4-4)$$

(5) 更新残差, 重复以上步骤, 等到残差信号不能在分解, 停止操作, 即可得到若干个本征模态分量。

4.1.2 长短时记忆神经网络 (LSTM)

长短期记忆网络 (LSTM) 是时间循环神经网络的一种, 旨在解决传统 RNN 长期依赖问题^[78-80]。LSTM 的网络结构图如图 4-1 所示。




图 4-1 LSTM 网络结构图

Figure 4-1 LSTM network structure diagram

主要包括三个门, 遗忘门即输入的信息通过遗忘门进行计算后, 仅保留一部分信息。更新门将新输入的信息经过更新门计算会保留下一部分新的信息, 最后对遗忘门和更新门两部分信息加起来, 更新原信息的状态。输出门即更新后的信息输出。

4.1.3 ARIMA 模型 (ARIMA)

自回归移动平均模型 (ARIMA), 是一种时间序列分析方法, 它可以用来

预测未来的趋势^[81-83]。AR 用来描述当前值与历史值之间的关系，如式（4-5）。MA 移动平均模型关注自回归模型中的误差项累加，如式（4-6）。I 是差分模型，差分被用来对时间序列数据进行处理，可以将非平稳的时间序列数据转化为平稳的数据，从而更容易地进行预测和分析。通过对时间序列数据的差分，消除趋势和季节性，使得数据更加稳定和可预测。差分模型在 ARIMA 中扮演着重要的角色，帮助我们更好地理解 and 预测时间序列数据的行为，计算公式如式（4-7）。

$$y_t = \mu + \sum_{i=1}^p \gamma_i y_{t-i} + \varepsilon_t \quad (4-5)$$

$$y_t = \mu + \varepsilon_t + \sum_{i=1}^p \theta_i \varepsilon_{t-i} \quad (4-6)$$

$$\Delta y = y_t - y_{t-1} \quad (4-7)$$

式中： y_t 为当前值； μ 为常数项； γ_i 为自相关系数； ε 为误差； θ_i 为滑动平均系数； p 为阶数。

ARIMA 模型有三个参数： p 、 d 、 q 。其中， p 为自回归阶数是指模型使用的历史观测值数， q 为移动平均阶数是指模型使用的历史误差数， d 为差分阶数是指需要对原始数据进行多少次差分才能使其平稳。ARIMA 一般常用于稳定数据的预测。

4.1.4 麻雀搜索算法（SSA）

麻雀搜索算法（SSA）是一种启发式搜索算法，该算法模拟了麻雀在寻找食物时的行为，以寻找解决问题的最佳途径^[84-85]。将优化问题转化为麻雀在寻找食物时的行为。主要步骤为：初始化种群、适应度计算、更新位置、保存参数、判断终止条件^[86]。

该算法的全局搜索能力强：SSA 不仅能够搜索全局最优解，而且收敛速度比其他算法更快，收敛能力更高，算法简单易用，需要迭代次数少。SSA 算法适用于优化问题和非线性问题的求解，特别是那些需要全局搜索的优化问题。目前，SSA 算法被成功应用在机器学习、智能控制系统、电力系统以及医疗图像分析等领域，显示出其广泛的适用性和良好效果。

本模型中使用验证集的均方差为适应度函数作为判断优化程度的标准，适应度计算公式如式（4-8）。

$$\begin{aligned} fitness &= \frac{1}{1 + MSE} \\ MSE &= \frac{1}{n} \sum_{i=1}^n |y - y_i|^2 \end{aligned} \quad (4-8)$$

式中， n 代表样本数量； y 代表样本实际值； y_i 代表样本预测值。

更新位置时分为 3 种情况：

更发现者的位置，具体公式如式（4-9）。

$$X_{ij}^{N+1} = \begin{cases} X_{ij}^N \times \exp\left(\frac{-i}{\partial \times N_{\max}}\right) & R_2 < S \\ X_{ij}^N + Q \times L & R_2 \geq S \end{cases} \quad (4-9)$$

式中： X_{ij}^{N+1} 表示第 i 个麻雀在第 j 维的位置信息； N 为迭代次数； ∂ 为属于 $[0,1]$ 的随机数； $N_{\max}$ 为最大迭代次数； R_2 警戒值； $S \in [0.5,1]$ 为安全阈值； Q 为服从正态分布的随机数； L 为 $1 \times d$ 的全 1 矩阵。

更新跟随者的位置，即适应度靠后麻雀的位置。具体公式如式（4-10）。

$$X_{ij}^{N+1} = \begin{cases} Q \times \exp\left(\frac{X_{\text{worst}}^N - X_{ij}^N}{\beta^2}\right) & i > n/2 \\ X_p^{N+1} + |X_{ij}^N - X_p^{N+1}| \times A^+ L & \text{其他} \end{cases} \quad (4-10)$$

式中： X_{ij}^{N+1} 表示第 i 个麻雀在第 j 维的位置信息； X_p^{N+1} 为发现者占据的最佳位置； X_{worst}^N 为当前最差位置； $A^+ = A^T(AA^T)^{-1}$ ， A 为每个元素为 1 或 -1 的 $(1 \times d)$ 维矩阵。 Q 为服从正态分布的随机数； L 为 $1 \times d$ 的全 1 矩阵。

更新部分麻雀位置，即警戒者的位置。具体公式如式（4-11）。

$$X_{ij}^{N+1} = \begin{cases} X_{\text{best}}^N + \beta \times |X_{ij}^N - X_{\text{best}}^N| & f_i > f_g \\ X_{ij}^N + K \times \left(\frac{|X_{ij}^N - X_{\text{worst}}^N|}{(f_i - f_w) + \varepsilon}\right) & f_i = f_g \end{cases} \quad (4-11)$$

式中： X_{ij}^{N+1} 表示第 i 个麻雀在第 j 维的位置信息； X_{best}^N 为当前全局最优位置； β 和 $K \in [-1,1]$ ，均为随机数； f_i 为适应度； f_g 和 f_w 分别为最优和最差； ε 为常数。

使用 SSA 搜索全局最优解，收敛速度更快，收敛能力更高，算法简单易用，需要迭代次数更少。

4.2 数据分析 (Data analysis)

4.2.1 统计分析

统计分析是一种通过收集、整理、分析和解释数据来揭示数据背后规律和趋势的方法^[87]。它可以帮助我们理解数据的特征、关系和变化，并从中得出结论和做出决策。本文对涌水量时间序列进行统计分析，得到总量、平均值、标准差，峰度，偏度、变异系数等统计计量数据如表 4-1。

表 4-1 涌水量统计分析数据

Table 4-1 Statistical analysis data of surge quantity

变量名	样本量	最大值	最小值	平均值	标准差	中位数	方差	峰度	偏度	变异系数 (CV)
涌水量	547	928	25	640.289	250.419	750	62709.506	0.742	0.828	0.391

该时间序列的标准差为 250.419，方差为 62709.506，涌水量的观测值相对于平均值 640.289 的离散程度较大，可能具有不稳定特性。峰度为 0.742，涌水量的分布相对于正态分布来说略微平坦。偏度为 0.828 大于 0，为右偏分布趋势，峰度为 0.828 大于 0，时间序列呈现尖峰态特征，分布稍微右倾。2017~2019 年矿井年平均涌水量 640.289 m³/h，最大涌水量 928 m³/h，总量为 350237 m³，矿井涌水量的复杂性使得判断矿井是否存在突水变得更加困难。由于涌水量的不确定性，采掘工程和矿井安全可能会受到严重威胁。同时，由于防治水工作的困难度较高，需要投入大量工程量来应对这一问题。基于涌水量样本，变异系数 (CV) 为 0.391，大于 0.15，当前数据中可能存在异常值，通常需要对异常的或者表现得较为突出的指标进行分析处理，故不作处理的情况下，预测结果准确率较低。但涌水量数据一般具有实际意义，且异常数据应是我们更加关注的的数据，若简单的删除，不符合实际意义。因此，本文欲根据模型的选择克服数据的噪声影响。

4.2.2 季节性分析

季节性分析是一种用于研究时间序列数据中季节性变动模式的方法^[88]。它通过对时间序列数据进行分析 and 建模，以揭示数据中固定周期性变化的规律性。季节性分析主要用于识别和理解数据中季节性因素的影响，可应用于各个领域，如经济学、市场营销、气象学等^[89]。常用的方法包括：

季节指数法 (Seasonal Index Method): 通过计算每个季节的平均值与整体平均值的比例，来评估季节性因素对数据的影响程度。

移动平均法: 通过计算一定时间窗口内的均值，来平滑数据并观察季节性变化的趋势。

季节分解法: 通过将数据分解为趋势、季节、残差等组成部分，来分析季节性的周期性变动。

自回归移动平均模型: 包括 ARMA 和季节性自回归移动平均模型 (SARMA): 利用时间序列的自相关和移动平均性质，建立模型来描述季节性

变动。

回归模型：将季节性因素作为解释变量，建立回归模型来分析季节性对其他因素的影响。从而进行合理的预测和决策。它可以帮助人们理解季节性变动的规律，预测季节性趋势，并制定相应的策略和决策。

本研究利用 SPSS 软件中的季节性 ARIMA 模型对涌水量时间序列进行分解，可以了解趋势变化、随机波动和季节性变化的影响。通过这种方法，可以初步确定涌水量数据是否存在季节性效应。趋势数据图、季节性数据图、随机数据图如图 4-2~图 4-4 所示。




图 4-2 涌水量分解趋势序列图

Figure 4-2 Sequence diagram of decomposition trend of water inflow




图 4-3 涌水量分解的季节性序列图

Figure 4-3 Seasonal sequence diagram of water inflow decomposition




图 4-4 涌水量分解的随机序列图

Figure 4-4 Random sequence diagram of water inflow decomposition

趋势数据是指长期数据中的总体趋势方向，呈现出递增特征。季节性数据指的是在特定时间段内呈现重复性趋势。随机数据说明这些是时间序列数据中

的波动。故涌水数据存在季节性规律，在夏季或多雨季应注意涌水量的监测预测。

4.2.3 周期性分析

周期性分析是一种通过观察和分析时间序列数据中的周期性变动来揭示和预测周期性模式的方法^[90]。周期性是一种在一定时间范围内反复出现的模式或趋势，比如季节性、月度循环等。周期性分析旨在识别和量化这种重复出现的模式，并通过对历史数据的观察来预测未来的周期性变动^[91]。通过周期性分析可以帮助理解 and 解释数据的周期性变化，并为决策和规划提供有关未来的指导。

本文通过对工作面推进距离和涌水量之间呈现出的规律，为涌水量预测预警提供一定支持。207 工作面涌水量随推进距离变化如图 4-5 所示。




图 4-5 涌水量与随推进长度关系

Figure 4-5 Relationship between surge volume and length with advancement

随着工作面的进展，207 工作面的涌水量整体表现出增加趋势，并且随开采距离增加，在不同时间段出现突发性增加现象。根据矿井实际数据情况统计，由于节假日或维修等情况导致停采后，涌水量会突然增加，这表明在工作面停止采矿后，顶板岩层依然在发生缓慢的运动。另外，结合其他工作面的沉陷规律，回采工作面正上方测点，在工作面推过测点 50-100m 之后，测点下沉速度开始明显上升，待推过测点约 200m 左右时，下沉速度达到最大，涌水量也突

然增加，并随着工作面继续推进，下沉速度开始下降，涌水量变得平缓，因此当回采工作每推进 200m 左右时应注意涌水量的监测预警。

4.2.4 平稳性分析

平稳性分析是对时间序列数据进行的一种分析方法，用于判断数据是否具有平稳性^[92]。平稳性是指数据的均值和方差在时间上保持不变的性质^[93]。

常用的方法包括：

观察法：通过绘制数据的时间序列图来观察数据的趋势、季节性和周期性变化，以判断数据是否具有平稳性。

均值和方差检验：通过计算数据的滚动均值和滚动方差来判断数据是否具有平稳性。如果滚动均值和滚动方差在时间上保持稳定，那么数据可以被认为平稳的。

自相关函数（ACF）和偏自相关函数（PACF）：自相关函数和偏自相关函数是用于分析时间序列数据的统计工具。通过观察 ACF 和 PACF 的图形，可以判断数据是否具有平稳性。

单位根检验：单位根检验是用来确定时间序列数据平稳性的方法之一，包括 ADF 检验、PP 检验等。

通过平稳性分析，可以确定数据是否具有平稳性，进而选择合适的时间序列模型和相应的分析方法。

本文使用单位根检验对工作面涌水量进行平稳性分析。单位根检验是一种用来检验时间序列数据是否具有单位根（即非平稳性）的统计方法。时间序列模型一般要求时间序列平稳性，建立模型前需要验证数据的平稳性，基于此对数据进行单位根（ADF）检验。ADF 检验的结果通常包括 ADF 统计量的值、临界值、 P 值和判断结果。 P 值越小，拒绝原假设的概率越大，即时间序列数据越可能是平稳的。ADF 检验的计算公式如式（4-12）。

$$ADF = (Y_t - Y_{t-1}) - \sigma(Y_{t-1} - Y_{t-2}) + \dots + \sigma_p(Y_{t-p} - Y_{t-p-1}) \quad (4-12)$$

其中， Y_t 表示时间序列数据的当前观测值， Y_{t-1} 表示上一个观测值， Y_{t-p} 表示 p 期前的观测值。 δ 为回归系数， p 为滞后阶数。每个差分项 $(Y_t - Y_{t-1})$ 、 $(Y_{t-1} - Y_{t-2})$ 、 $\dots$ 、 $(Y_{t-p} - Y_{t-p-1})$ 代表了时间序列数据的一阶差分，即当前观测值与上一个观测值之间的差异。通过对这些差分项进行回归分析，判断回归系数 δ 的显著性，从而判断时间序列数据是否具有单位根（非平稳性）。根据以上公式得到原始数据的 P 值为 0.213 大于 0.05，故原始数据为不平稳数据。

4.3 模型构建 (Model construction)

基于 CEEMDAN 和改进的混合时间序列模型工作面涌水量预测整体流程如图 4-6 所示。




图 4-6 CEEMDAN-SSA-LSTM-ARIMA 模型流程图

Figure 4-6 Flowchart of the CEEMDAN-SSA-LSTM-ARIMA model

基于 CEEMDAN 和改进的混合涌水量预测模型整体预测步骤如下：

- 1) 对收集到的涌水量数据插值补全后进行分析。主要包括周期性、季节性以及平稳性分析。
- 2) 将涌水量通过 CEEMDAN 算法分解，得到各本征模态函数分量和残差余量。
- 3) 对各分量进行稳定性分析。
- 4) 构建混合时间序列模型。该模型有两部分组成，一部分是由麻雀搜索算法优化的长短期记忆网络，另一部分是自回归移动平均模型。根据分量特征将具有稳定性特征的分量输入到优化过的预测模型中进行预测，将不具有稳定性的分量输入到自回归移动平均模型进行预测，利用自回归移动平均模型先差分的特性抵消数据的不稳定性。
- 5) 将各分量预测结果根据时域融合进行叠加融合，得到最终的预测值。时域融合叠加公式如式 (4-13)。

$$y(t)=\sum_{i=1}^n(w_i\times x_i(t))$$

(4-13)

式中： $y(t)$ 为对应 t 时刻最终的预测结果， W_i 为每个分量的权重， $x_i(t)$ 为对应 t 时刻分量的值。

4.4 预测结果 (Forecast result)

4.4.1 基于 CEEMDAN 分解的数据平稳化处理

通过 CEEMDAN 分解后，涌水量数据的各个子分量具有不同的特征尺度，有助于减少涌水量数据本身的非平稳性和非线性对预测结果造成的误差。本文中将涌水量分成 7 个分量，如图 4-7 所示。




图 4-7 模态分解结果

Figure 4-7 Modal decomposition results

经过 CEEMDAN 得到的七个本征模态进行单位根检验（ADF），结果如表 4-2 所示。

表 4-2 各分量单位根检验结果

Table 4-2 Unit root test results of each component

数据	IMF0	IMF1	IMF2	IMF3	IMF4	IMF5	IMF6
ADF	0.000***	0.000***	0.000***	0.000***	0.000***	0.081	0.007

由表可知, IMF5 的概率 P 值为 0.081 大于 0.05 为不平稳数据, 对具有不稳定性的分量, 通过差分消除后进行 ARIMA 预测。其余本征分量的单位根 (ADF) 检验结果均小于 0.05, 均为平稳数据。

4.4.2 涌水量预测结果

将经过 CEEMDAN 分解的子序列分为 80% 的训练集和 20% 的测试集。利用混合时间序列对这些子序列进行训练, 然后进行未来值的预测。将各分量分别划分为训练集和测试集。其中, 训练时将具有平稳特征的分量 IMF1、IMF2、IMF3、IMF4、IMF6 分别输入到 SSA 算法优化的 LSTM 神经网络中, 学习各分量变化规律并分别进行预测。将具有不稳定性的分量 IMF5 输入到 ARIMA 模型中进行预测, 利用 ARIMA 模型优先差分特性消除数据不稳定性, 得到更精确结果。IMF5 预测结果如图 4-8 所示。




图 4-8 各分量预测结果

Figure 4-8 Prediction results of each component

将预测得到的结果根据时域融合进行叠加得到最终涌水量预测结果, 如图 4-9 所示。




图 4-9 CEMDAN-SSA-LSTM-ARIMA 模型预测结果

Figure 4-9 CEMDAN-SSA-LSTM-ARIMA model prediction result

4.5 对比分析 (Comparative analysis)

4.5.1 单因素模型评价指标选取

结合具体的数据特点和实验对 MAPE、RMSE、MAE 以及 R^2 四个模型评价指标从数据分布、极端值、预测误差度量的特点、预测误差的重要性进行分析, 通过改变测试集、引入异常值、改变不同的模型训练参数四种方式进行实验验证, 得到最终的、具有代表性的、更贴合本文的模型评价指标。

数据分布: 根据涌水量数据的统计分析, 用数量数据分布呈现偏倚情况, MAPE 指标会对于预测误差更为敏感, 因为它是基于百分比误差的计算。而对于均方根误差 (RMSE) 和平均绝对误差 (MAE) 来说, 它们对于数据的绝对误差更为敏感。

极端值: 矿井工作面涌水量数据源自于矿山开采过程中, 数据集中存在极端值或异常值, 这些指标的灵敏度可能会受到影响。特别是 MAPE 指标, 由于其基于百分比误差的计算, 对于极端值更为敏感。

预测误差度量的特点: MAPE 是一种相对误差度量指标, 它将预测误差与真实值进行比较, 并以百分比的形式表示。相比之下, 可决定系数、RMSE 和 MAE 是绝对度量指标, 它们直接衡量预测误差的大小。在矿井单因素涌水量预测中更关注预测误差的大小而不仅仅关注相对误差的比较, 那么选择可决定系数、RMSE 和 MAE 作为评价指标会更合适。

预测误差的重要性: 在矿井涌水量预测中, 准确预测涌水量的绝对误差比

相对误差的比较更重要。因为涌水量的准确预测对于矿井的安全和运营至关重要。因此，使用可决系数、RMSE 和 MAE 这些直接衡量预测误差的指标，可以更直观地了解模型的预测精度和偏差。

误差指标的灵敏度测试：首先通过改变测试集，将本文模型在不同数据集上进行测试 MAPE 变化更大。其次引入异常值，改变原数据集引入异常值，MAPE 变化更高大。最后通过改变模型参数，对本文模型改变不同的训练参数，几个误差评价指标变化相差不大。

通过对分析判断与客观灵敏度实验联合得到，使用可决定系数、RMSE 和 MAE 这些直接衡量预测误差的指标，更直观地了解模型的预测精度和偏差。

4.5.2 优化算法效果对比分析

为避免局部最优解的问题，对模型进行参数优化。在进行模型参数优化时，需要对验证数据的评估误差进行统计和分析。为了确定每个参数组合的适应性，需要计算验证数据评估误差的综合绝对值之和，并将其作为个体适应度值。通过对适应度值的评估，找到最优的参数组合，从而优化模型的性能和准确性，从而提高模型的预测能力和泛化能力。将遗传算法（GA）、粒子群算法（PSO）、麻雀搜索算法（SSA）的模型适应度收敛情况进行对比，如图 4-10 所示。




图 4-10 优化算法适应度结果对比

Figure 4-10 Comparison of fitness results of optimization algorithms

实验结果表明：SSA 的适应度值最小，说明该个体得到的参数是最优的。SSA 的适应度值最快、最早达到最优，说明模型最快达到收敛。因此使用 SSA

搜索全局最优解，不仅收敛速度更快，而且收敛能力更高，需要迭代次数更少。

4.5.3 各预测模型结果对比分析

为了验证本文提出的改进的混合时间序列预测模型的准确率，将其与 BP 神经网络、门控循环单元（GRU）、长短期记忆网络（LSTM）、自回归积分滑动平均模型（ARIMA）和 SSA-LSTM 模型在同一数据集上进行对比实验，实验结果如图 4-11 所示。




图 4-11 不同模型预测结果

Figure 4-11 Results of different model predictions

得到的具体评价指标值如表 4-3 所示。

表 4-3 各模型预测对比结果

Table 4-3 Comparison results of forecast of various models

模型	MAE	RMSE	R ² (%)
BP	16.14	19.25	0.56
GRU	15.28	17.38	0.64
LSTM	9.90	13.33	0.79
ARIMA	8.14	11.73	0.84
SSA-LSTM	7.54	10.92	0.89
基于CEEMDAN和混合时间序列工 作面涌水量预测模型（CEEMDAN- SSA-LSTM-ARIMA）	6.36	10.60	0.95

涌水量作为典型的时序数据，常使用传统的 BP 神经网络进行预测，但该方法预测精度低且网络结构难以确定。涌水量属于典型的时序数据，但仅使用单一的长短时记忆网络进行预测，往往会由于数据本身的噪音干扰预测结果，故采用完全自适应模态分解算法将数据本身的不稳定性因素降低，可有效提高预测效果。

通过对比实验可得：相较于传统的 BP 神经网络，本文提出的模型在各种评价指标中均提升很多。相较于单一长短时记忆网络，平均绝对误差降低到了 6.36；均方根误差降低到了 10.6；R² 提升到了 95%。相比于 BP 神经网络、GRU、LSTM、ARIMA 和 SSA-LSTM 模型平均绝对误差（MAE）分别降低了 9.78m³/h、8.92m³/h、3.54m³/h、1.78m³/h、1.18m³/h，均方根误差（RMSE）分别降低了 8.65m³/h、6.78m³/h、2.73m³/h、1.13m³/h、0.32m³/h。结果表明，基于 CEEMDAN 和改进的混合时间序列模型预测准确率高，能更加准确的预测工作面涌水量。

4.6 本章小结（Summary of this chapter）

本章以亭南煤矿 207 工作面涌水量数据为基础，分析该组数据的统计规律、季节性规律、周期性规律以及平稳性规律，并根据数据特点选取合适的神经网络，构建了基于 CEEMDAN-SSA-LSTM-ARIMA 单因素混合时间序列涌水量预测模型。通过在研究区上的对比实验，可得，涌水量数据用传统的 BP 神经网络预测，预测精度低且网络结构难以确定。涌水量属于典型的时序数据，但仅使用单一的长短时记忆网络进行预测，往往会由于数据本身的噪音干扰预测结果，故采用完全自适应模态分解算法将数据本身的不稳定性因素降低，可有效提高预测效果。根据模型、数据特点选取 R²、MAE、RMSE 作为本实验的模型评价指标，通过对比实验可得：相较于传统的 BP 神经网络，本文提出的模型在各种评价指标中均提升很多。相较于单一长短时记忆网络，平均绝对误差降

低到了 6.36；均方根误差降低到了 10.6； R^2 提升到了 95%。相比于 BP 神经网络、GRU、LSTM、ARIMA 和 SSA-LSTM 模型平均绝对误差（MAE）分别降低了 $9.78\text{m}^3/\text{h}$ 、 $8.92\text{m}^3/\text{h}$ 、 $3.54\text{m}^3/\text{h}$ 、 $1.78\text{m}^3/\text{h}$ 、 $1.18\text{m}^3/\text{h}$ ，均方根误差（RMSE）分别降低了 $8.65\text{m}^3/\text{h}$ 、 $6.78\text{m}^3/\text{h}$ 、 $2.73\text{m}^3/\text{h}$ 、 $1.13\text{m}^3/\text{h}$ 、 $0.32\text{m}^3/\text{h}$ 。结果表明，基于 CEEMDAN 和改进的混合时间序列模型预测准确率高，能更加准确的预测工作面涌水量。

5 基于 SSA-CG-Attention 模型的多因素涌水量预测

5 Multi-factor water inflow prediction based on SSA-CG-Attention model

本章在相关理论的基础上，构建多因素模型，在研究区工作面进行对比实验，验证模型的优越性、可行性，通过评估指标进行具体数值的比较分析，探讨多因素预测模型精准度和适用性。

为了提高预测结果的准确性和稳定性，本章在相关理论的基础上，基于钻孔水位和微震能量数据与涌水量的强关联性，着重分析涌水量各因素间的相关关系，以及多模型参数选取的可行性，确定选择其作为多因素特征变量，结合卷积神经网络（CNN）与门控循环单元（GRU）构建新的网络结构，加入注意力机制（Attention），融合麻雀搜索（SSA）算法优化网络参数，建立了 SSA-CG-Attention 预测模型。将提出的 SSA-CG-Attention 模型的多因素涌水量预测与单因素模型和多因素模型分别在研究区进行对比实验得到预测结果。并根据模型、数据特点选取合适的模型评价指标，通过评估指标进行具体数值的比较分析，探讨多因素预测模型精准度和适用性。

5.1 相关基础理论（Relevant basic theory）

5.1.1 CNN 卷积神经网络

卷积神经网络（Convolutional Neural Network，CNN）是一种深度学习模型，使用反向传播算法进行训练。通过卷积层、池化层和全连接层构建网络结构，如图像和音频^[94]。它在图像识别、目标检测、图像分割等任务中取得了显著的成功。

CNN 的核心思想是利用卷积操作和池化操作来提取特征，从而实现对复杂数据的有效处理和识别^[95]。通过不断堆叠层次和参数学习，实现对特征的高级抽象和复杂关系的建模。CNN 的基本结构如图 5-1 所示。该模型使用卷积层提取水位数据的有效非线性局部特征，池化层用于压缩提取的特征并生成更重要的特征信息，以提高泛化能力，这两者共同构成了 CNN 模型的框架。




图 5-1 CNN 的基本结构

Figure 5-1 Basic structure of CNN

5.1.2 Dropout 随机失活层

随机失活层（Dropout Layer）是一种在神经网络中应用的正则化技术，用于减少过拟合并提高模型的泛化能力^[96]。它在训练过程中以一定的概率将神经元的输出置为零，从而随机地丢弃（失活）一部分神经元^[97]。在训练过程中，对于每个训练样本和每个训练批次，随机失活层以一定的概率 p 将神经元的输出置为零。这意味着在每次前向传播过程中，所有部分神经元对当前样本进行计算和传递信息。在反向传播过程中，只有被保留下来的神经元（即没有被失活的神经元）才会更新其权重。被失活的神经元不参与权重更新，因此不会对它们进行训练。通过随机失活层使网络中的神经元被迫独立地学习有用的特征，而不是依赖于其他神经元。这有助于减少神经元之间的共适应性（co-adaptation），使网络更加鲁棒，并减少过拟合的风险。随机失活层的概率 p 通常设置在 0.2 到 0.5 之间。较大的失活概率可能导致更多的神经元被失活，因此会增加模型的鲁棒性，但也可能降低模型的表达能力。随机失活层在深度学习中被广泛使用，并已证明对提高模型的性能和泛化能力非常有效。它可以应用于各种类型的神经网络，包括卷积神经网络（CNN）和循环神经网络（RNN）。

该模型中的 dropout 率设置为 0.2，在防止过拟合的同时提高模型的泛化能力，减少训练时间。具体计算公式如（5-1）。

$$y = \frac{x * m}{p} \quad (5-1)$$

式中， x 是输入的特征， m 是一个与 x 相同大小的二值掩码，每个元素独立地以概率 p 取值 1，以概率 $(1-p)$ 取值 0， y 是输出的特征。在测试阶段，需要将 m 的值固定为全 1。

5.1.3 GRU 神经网络

GRU（Gated Recurrent Unit，门控循环单元）是一种改进后的循环神经网络模型^[98]，其基于 LSTM 模型并增加了门控机制来更好地处理长时序列数据。具体来说，GRU 模型引入了重置门和更新门，其中重置门用于确定是否保留上

一时刻的状态信息，更新门则控制当前时刻状态的更新^[99]。这样，GRU 模型能够在保证信息传递的同时，更好地处理长时序数据。在时间序列预测中，GRU 模型可以用于单变量预测和多变量预测。本模型中 GRU 通过学习钻孔埋深和水位历史观测值序列之间的关系，从而预测涌水量未来的观测值序列。

GRU 结构单元如图 5-2 所示。




图 5-2 GRU 结构单元

Figure 5-2 GRU structural unit

其中， x_t 为 t 时刻输入变量； h_t 、 h_{t-1} 分别为当前隐藏层输出、上一时刻隐藏层输出； r_t 为重置门输出； z_t 为更新门输出； $\otimes$ 为向量间的逐元素相乘； $\oplus$ 为向量间的逐元素相加； δ 为 sigmoid 函数，可将数据变为 $[0,1]$ 范围； $\tanh$ 为 tanh 函数，可将数据变为 $[-1,1]$ 范围。可将数据转化为 $[-1,1]$ 范围。

5.1.4 全连接层

全连接层（Fully Connected Layer），也被称为密集连接层或全连接层，是神经网络中的一种常见层类型^[100]。在全连接层中，每个神经元都与上一层的所有神经元建立连接，每个连接都有一个权重，用于对输入数据进行加权求和。接着，经过加权求和后的结果将使用激活函数进行非线性处理，最终产生输出。全连接层的作用是将前一层的特征映射转化为更高级的特征表示^[101]。通过学习输入数据之间的复杂非线性关系，从而提取更抽象的特征。全连接层通常出现在神经网络的最后几层，它们负责对输入数据进行整合和综合，以进行最终的分类、预测或生成任务。每个神经元通过加权求和前一层所有神经元的输出，并且每个神经元都有自己的偏置值（bias）。这样的连接方式可以使得网络具有更大的表达能力，但同时也增加了模型的复杂性和计算量。

该模型利用全连接层对先前提取的特征进行非线性转换，以捕捉特征之间的复杂关联，并最终输出预测涌水量的结果。其核心操作就是矩阵向量乘积，如式（5-2）。

$$Y = W * X \quad (5-2)$$

式中, Y 为最终的特征输出, W 为各特征值的权重, X 为提取出的特征向量。

5.1.5 Attention 注意力机制

Attention 机制是一种模型, 它能够通过处理输入序列, 然后产生一个单独的输出序列^[102]。它可以为序列中的每个元素计算一个权重, 并将权重与输入向量相乘以得到上下文向量, 该上下文向量可以用于下一个时间步骤的预测^[103]。本模型中 Attention 模块计算各因素的权重并输入到全连接层中。Attention 单元结构如图 5-3 所示。




图 5-3 Attention 单元结构

Figure 5-3 Attention unit structure

其中, a_i 为隐注意力权重值; $y_1, y_2, y_3, \dots, y_i$ 为输入序列; $h_1, h_2, h_3, \dots, h_i$ 为对应于输入序列的隐藏层状态; h' 为最终的特征向量;

注意力机制 (Attention) 算法公式如 (5-3)。

$$\text{Attention}(Q, K, V) = \text{soft max} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (5-3)$$

式中, T 表示向量的转置; 实验过程中, 训练得到 W_Q , W_K 和 W_V 三个参数矩阵, 输入矩阵 X 分别与这三个参数相乘, 生成 Q 、 K 和 V 。Attention 不直接使用 X , 而是使用 Q 、 K 和 V 这三个矩阵相乘得到的矩阵, 增强模型的拟合能力。 d_k 为 K 的维度大小, 对相似度矩阵每个元素除以 $\sqrt{d_k}$ 。这个除法被称为 Scale。当 d_k 很大时, QK^T 的乘法结果方差变大, 进行 Scale 可以使方差变小, 训练时梯度更新更稳定。Softmax 是归一化函数, 用来对向量做归一化处理, 经过归一化处理后可以得到了一个权重矩阵, 在这个矩阵中, 值的权重越大, 相似度越高。

5.2 特征变量选取 (Feature variable selection)

5.2.1 相关性分析

常用的相关性分析有，Pearson 相关性分析、Spearman 相关性分析和 Kendall's tau-b 相关性分析^[104]。Pearson 相关性分析适用于变量之间线性关系的检验，可用于计算两个连续变量间的相关系数^[105]。Spearman 相关性分析适用于变量之间非线性关系的检验，可用于计算两个有序变量或等级变量间的相关系数^[106]。Kendall's tau-b 相关性分析适用于变量之间的排序关系的检验，可用于计算两个有序变量或等级变量间的相关系数，不受样本大小和分布等因素的影响，适用于小样本或非正态分布的数据^[107]。Spearman 相关性分析还可以处理等级数据，符合矿井涌水量的实际统计类型且 Spearman 相关性分析更加鲁棒，对于非正态分布和有异常值的数据更加适用。因此，本文使用 SPSS 对涌水量数据、微震数据和水位数据进行 Spearman 相关性分析。Spearman 相关系数表如表 5-1 所示。

表 5-1 微震数据、水位数据和涌水量数据 Spearman 相关系数
Table 5-1 Spearman correlation coefficients of microseismic data, water level data, and water inflow data

	涌水量	能量级	水位
涌水量	1 (0.000***)	0.434 (0.000***)	0.708 (0.000***)
能量级	0.434 (0.000***)	1 (0.000***)	-0.033 (0.586)
水位	0.708 (0.000***)	-0.033 (0.586)	1 (0.000***)

注：***代表 1% 的显著性水平

相关系数范围为-1 到 1，数值越接近-1 或 1，表示相关性越强；接近 0，则表示相关性较弱或不存在。显著性水平表明了相关系数的显著性，当 p 值小于 0.01 时，相关性被认为是显著的。本数据中，水位和涌水量之间的相关性系数为 0.708，且显著性水平小于 0.01，说明水位和水深之间存在显著相关性。涌水量和能量级之间的相关性系数为 0.434，说明二者之间存在显著相关性。在矿井水害中，钻孔水位和涌水通常是正向关系。也就是说，当钻孔水位升高时，涌水量也会增加。这是因为钻孔水位的升高意味着矿山水体的压力增加，水体向矿井内部流动的速度也会加快，从而导致更多的水涌入矿井中。微震数据和涌水量通常也是正向关系，微震能量级较高的区域存在着较大的应力释放和岩石裂隙扩张等现象，这些现象可能会导致矿井岩体的不稳定和涌水等水害发生；相反，微震能量级较低的区域则表明岩体较稳定，涌水风险较小。另外，由图 2-7 微震能量、水位与涌水量的关系图可知，当发生涌水量时候，钻孔水位会急速下降。当微震能量较大时，涌水量会增加。钻孔水位和微震能量与涌水密切相关，可以将钻孔水位数据和微震数据作为涌水量预测的两个特征因素预测涌

水量。

5.2.2 可行性分析

亭南煤矿具有完善的水情监测系统结合矿井实际监测情况确定水害风险监测指标,杨艺^[108]等对该矿井可以获得的监测指标使用组合赋权法确定权重,其权重排序为:井下突(涌)水量>微震监测数据>降水量>水位>采空区积水量>物探成果>水压>防治水工程>排水系统能力>水质>地层构造>水温>河流水位>水文地质基础工作。根据矿井煤层开采前后顶板覆岩的破坏情况,在顶板发生突水过程中,含水层水位、工作面涌水量以及顶板导水裂隙带发育高度在极短时间内都发生了较大的变化。

亭南煤矿涌水为承压水,出水与涌水量同步变化,因此将水位作为涌水量预测的一个特征变量具有可行性。

微震数据能够反应底板断层和裂隙带的发育情况,确定断层尖端的扩展情况,从而为预测涌水量提供了重要依据^[109]。微震能量的变化可以反映地下岩体的应力状态和破裂活动,而岩体的应力状态和破裂活动与涌水量的变化有关^[110]。当微震能量增大,岩石破裂增大,导水裂隙带更发育,导致涌水量的增加^[111]。因此,微震能量数据作为涌水量预测的一个特征因素具有可行性。

另外,也有学者指出通过对水位和能量数据的监测分析,可以有效地预测涌水量的变化趋势^[112-113]。因此,本实验选择矿井含水层水位数据和微震监测数据作为预测涌水量的两个主控因素。

5.2.3 可获得性分析

将矿井微震数据和矿井水位监测数据作为涌水量多因素预测的特征指标需要符合可获得性标准的原因在于,只有可获得的数据才能被有效地用于建立预测模型,进行监测和分析。数据的可获得性意味着数据相对容易获取,不受技术或经济条件的限制。这样的数据才能够在实践中得到广泛应用,发挥其作用。

可获得性标准一般包括以下几个方面:

(1) 数据获取成本:数据的获取成本应该比较低,不会对整体预测系统的成本造成过大的负担。对于矿井微震数据和矿井水位监测数据来说,获取成本应该比较低,可以通过矿山现有的监测设备或者简单的监测仪器获取。

(2) 数据获取难度:数据的获取应该相对简便,不需要过于复杂的技术手段或程序。对于矿井微震数据和矿井水位监测数据来说,通常可以通过已经部署在矿井中的监测设备或传感器来获取,因此获取难度相对较低。

(3) 数据采集自动化程度:数据的采集应该具有一定的自动化程度,能够实现数据的实时或定期采集,并且能够自动记录和传输。对于矿井微震数据和

矿井水位监测数据，现代的监测设备通常具有一定的自动化功能，能够满足这一标准。

综上所述，将矿井微震数据和矿井水位监测数据作为涌水量多因素预测的特征指标需要符合可获得性标准。这些数据应该具有较低的获取成本、相对简便的获取方式以及一定的自动化程度。符合可获得性标准的数据才能够在实践中得到广泛应用，为矿井涌水量的预测提供有效的支持。

5.3 模型构建 (Model construction)

本文提出一种基于 SSA-CG-Attention 模型的水害参数涌水量预测方法，具体实现流程如图 4-4 所示。本方法首先对采集到的水位数据、微震数据以及涌水量数据进行预处理以及相关可行性分析，并划分训练集和测试集。其次，构造 CG-Attention 模型。该模型采用两层一维卷积层提取非线性局部特征，中间使用最大池化层提取更为关键的特征信息，利用两部分结构共同组成了 CNN 框架，以自动提取矿井水害参数内部特征。并加入注意力机制，提高对输入数据的特征专注力。

本模型主要提取到的内部特征包括两个方面：第一是空间特征和部分时间特征；通过卷积层的操作，CNN 可以在不同的空间位置上提取特征，并捕捉到空间上的模式和变化。对于一维时间序列数据，可以将其转换为二维形式，将时间作为一个维度，并在卷积层中进行卷积操作。这样，CNN 可以在时间维度上提取一些局部的时间特征。第二是周期性特征和频域特征。在 CNN 的卷积层之后，添加的池化层来降低维度和提取更加抽象的特征。这样的操作可以捕捉到一些周期性的模式。

建立了 GRU 时序特征层，旨在学习 CNN 框架提取的局部特征的内部动态变化规律，逐步从局部特征中提取更复杂的全局特征。在构建 GRU 时序特征层时，全局特征指的是从局部特征中经过迭代提取后得到的表示整体序列的特征。这里的全局特征主要是序列（数据）中的长期依赖关系和内部动态变化规律。由 GRU 提取出的全局特征具体指的是 GRU 模型的隐藏状态。在每个时间步，GRU 模型都会更新隐藏状态，并将其传递到下一个时间步。隐藏状态可以被看作是对序列数据的全局理解和编码，它包含了序列中的长期依赖关系和内部动态变化规律。隐藏状态可以看作是对整个序列的抽象表示，其中融合了序列中的关键信息和上下文。GRU 模型在处理序列数据时，通过学习和更新隐藏状态，能够逐步提取出重要的特征并捕捉序列中的长期依赖关系。隐藏状态具有一定的记忆性，它会保留和传递之前时间步的信息，从而能够更好地捕捉到序列中的动态变化。随着 GRU 模型的迭代进行，隐藏状态会不断地更新和调整，最终捕捉到序列的全局特征。

本模型通过引入 Dropout 层来减少过拟合现象，并优化模型的泛化能力，同时减少训练时间。利用注意力机制对 GRU 隐藏层提取的时间信息进行加权处理，更有效地利用时间序列属性，挖掘深层次的时间相关性。通过全连接层将前面提取的特征，主要包括 CNN 提取的内部特征、GRU 提取的全局特征以及注意力机制（Attention）通过对时序数据中的重要部分进行加权处理，从而提取时序模式特征，经过非线性变化，提取这些特征之间的关联，最后输出最终涌水量预测结果。

在网络参数优化部分本文采用麻雀搜索算法(SSA)优化算法更新各层的网络参数，验证集的均方差为适应度函数作为判断优化程度的标准。模型结构如图 5-4 所示。




图 5-4 SSA-CG-Attention 模型流程图

Figure 5-4 Flowchart of the SSA-CG-Attention model

5.4 预测结果对比分析（Comparative analysis of forecast results）

5.4.1 涌水量预测结果

SSA-CG-Attention 模型对亭南煤矿涌水量预测结果如图 5-5 所示。




图 5-5 SSA-CG-Attention 模型预测结果

Figure 5-5 Prediction results of SSA-CG-Attention model

由预测结果可知, SSA-CG-Attention 多因素涌水量预测模型预测结果较为准确, 具有一定优越性。

5.4.2 多因素模型评价指标选取

在矿井工作面多因素涌水量预测中, 模型评价指标的选择非常重要。矿井涌水量多因素预测模型的指标选取根据对 MAPE、RMSE、MAE 和 R-squared 这四个指标的说明, 选出更适合多因素模型的评价指标。

(1) 平均绝对百分比误差 (MAPE): MAPE 是一种常用的评价指标, 用于衡量模型预测结果误差的平均百分比。MAPE 越低, 表示模型的预测能力越好。在矿井涌水量预测中, MAPE 可以帮助判断模型的预测准确性, 对于矿井工作面涌水量的预测来说, 预测误差的百分比很重要。

(2) 均方根误差 (RMSE): RMSE 是用来衡量模型预测误差的标准差。它考虑了预测值与真实值之间的差异的平方, 可以衡量预测误差的大小。RMSE 越低, 表示模型的预测能力越好。在矿井涌水量预测中, RMSE 可以帮助判断模型的预测准确性, 并且对于异常值的影响比较敏感。

(3) 平均绝对误差 (MAE): 通过计算预测值与真实值之间的绝对差异来衡量预测的准确性。它可以帮助我们了解预测误差的平均大小。MAE 越低, 表示模型的预测能力越好。在矿井涌水量预测中, MAE 可以帮助判断模型的预测准确性, 并且对于异常值的影响较小。

(4) 可决定系数 (R-squared): 可决系数是一个衡量模型解释能力的指标, 它表示模型可以解释观测值方差的比例。数值在 0 到 1 之间, 越接近 1 则代表

模型对观测值的解释能力越强。然而，在矿井涌水量多因素预测中，R-squared 可能并不适合作为评价指标，因为矿井涌水量的预测关系到多种因素的影响，并且很难通过一个线性模型来完全解释涌水量的变化。因此，R-squared 无法准确地评估模型的预测能力。

在矿井工作面涌水量预测中，涌水量单因素预测模型的评价指标比多因素更合适选择可决定系数 (coefficient of determination)、也称为 R-squared。

涌水量单因素预测模型选择 R-squared 作为评价指标的原因：

(1) 简单性：涌水量单因素预测模型只考虑一个因素对涌水量的影响，因此模型相对简单。相比之下，多因素模型需要考虑多个因素之间的复杂关系，模型更加复杂。

(2) 变量解释能力：涌水量单因素模型只考虑一个因素，可以更好地解释涌水量的变化。通过计算 R-squared，我们可以评估模型对涌水量的变异性的解释能力。R-squared 值越接近 1，表示模型能够解释涌水量变异性的比例越高。

(3) 预测准确性：涌水量单因素模型的评价指标中，R-squared 可以有助于评估模型的预测准确性。R-squared 越高，表示模型的预测能力越好，能够更准确地预测涌水量。

尽管多因素模型能够考虑更多因素对涌水量的影响，但是由于复杂性和解释能力的挑战，多因素模型的评价指标不适合选择 R-squared。在多因素模型中，更适合选择其他的评价指标，如均方根误差 (RMSE)、平均绝对误差 (MAE) 和平均绝对百分比误差 (MAPE) 等来评估模型的预测准确性和误差大小。

综上所述，MAPE、RMSE 和 MAE 更适合作为矿井涌水量预测模型的评价指标，因为它们能够衡量模型的预测准确性和误差大小。而 R-squared 无法准确地评估涌水量预测模型的能力。目标是预测误差度量：可决系数是一种模型解释方差能力的指标，而 MAPE、RMSE 和 MAE 是一种预测误差度量指标。在矿井多因素涌水量预测中，更关注预测误差的大小而不是仅仅关注方差的解释能力，那么选择 MAPE、RMSE 和 MAE 作为评价指标会更合适。

5.4.3 单因素与多因素模型对比

矿井涌水量预测一般分为两类，一类是单因素预测，使用历史观察数据，学习历史数据特征进行预测^[114]。另一种是多因素预测，使用矿井水害数据进行预测^[115]。由于矿井数据难以获取以及处理较为困难，单因素预测方法较多。对同一时间内仅使用涌水量历史数据进行单因素模型预测，与使用钻孔水位数据以及微震数据的多因素模型预测对比实验，结果如表 5-2 所示。

使用涌水量历史数据预测结果仅考虑了历史趋势和变化规律，仅提供单一时间序列信息，容易出现误判和漏判。而使用钻孔水位以及微震数据预测工

作面涌水量，多因素输入互为约束，信息获取更全面，结果输出更稳定、更准确，可以大大降低误报漏报几率，提高工作面预测可靠性、准确性和精度。

表 5-2 多因素、单因素预测模型评估指标结果

Table 5-2 Results of evaluation indicators for multifactor and single-factor prediction models

类型	模型	MAE	RMSE	MAPE/ (%)
单因素	BP	16.14	19.25	2.0
	LSTM	14.90	15.33	1.8
	GRU	14.44	15.70	1.8
	SSA-CG-Attention	14.14	15.73	1.7
多因素	BP	14.14	15.25	1.9
	LSTM	13.61	14.82	1.5
	GRU	12.81	13.83	1.4
	SSA-CG-Attention	5.24	7.25	0.6

5.4.4 模型稳定性对比

模型稳定性是指模型对于输入数据的微小变化或扰动的鲁棒性，即模型在输入数据发生轻微改变时，输出结果的变化程度^[116]。一个稳定的模型应该对于输入数据的小变化具有一定的容忍度，不会导致剧烈的输出结果变化。

模型稳定性对于机器学习和深度学习模型非常重要，因为在现实世界中，输入数据常常包含一定程度的噪声、不确定性或变化。一个稳定的模型可以更好地适应这些变化，提高模型的泛化能力和鲁棒性。

本文将模型评估指标方差作为模型稳定性判定标准，将同一时间内涌水量历史数据与使用钻孔水位数据和微震数据拆分为训练和测试集，将训练集作为模型训练时的输入。将测试集用于验证训练结束的模型，并记录每个模型的结果。进行多次拆分和应用模型的迭代，以减少随机性和提高结果的准确性。分析每次迭代的结果，并计算每个模型的评估指标方差。计算公式如式（5-4）。

$$D = \sum_{j=1}^m \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n} \quad (5-4)$$

式中， m 代表 M 个模型评价指标， n 代表迭代次数， $\bar{x}$ 代表每次迭代指标的平均值。

本次稳定性实验，选取在迭代次数为 20，即进行 20 次重复实验获取方差。最终得到的方差结果如表 5-3 所示。

实验结果表明：多因素模型的方差和普遍较小。因此，多因素模型一般比单因素模型预测结果更稳定。

表 5-3 模型评估方差

Table 5-3 Model evaluation variance

类型	模型	方差和
单因素	BP	15.89
	LSTM	17.70
	GRU	17.00
	SSA-CG-Attention	12.01
多因素	BP	13.10
	LSTM	13.30
	GRU	10.50
	SSA-CG-Attention	8.90

5.4.5 多因素模型对比

将本文 SSA-CG-Attention 预测模型和序列线性规划算法（SLP）、多层感知机预测算法（MLP）、支持向量机回归模型（SVR）、GRU、LSTM 模型以及由麻雀搜索算法优化的 GRU、LSTM 模型在同一数据集上进行对比实验，得到结果如图 5-6 所示。




图 5-6 各模型预测结果

Figure 5-6 Prediction results of each model

模型评估指标如表 5-4 所示。

表 5-4 各预测模型评估指标结果

Table 5-4 Results of indicators for the assessment of forecasting models

模型	MAE	RMSE	MAPE/ (%)
MLP	25.18	26.69	2.8
SLP	21.70	25.40	2.4
SVR	14.60	19.16	1.6
LSTM	13.61	14.82	1.5
GRU	12.81	14.43	1.4
SSA-LSTM	11.28	13.83	1.2
SSA-GRU	8.09	9.98	0.9
SSA-CG-Attention	2.91	6.34	0.3

由表 5-4 可以看出：SSA-CG-Attention 预测模型的 MAPE、RMSE 和 MAPE 三个评价指标均优于 SLP、MLP、SVR、GRU、LSTM 模型；组合麻雀搜索算法寻找最优超参数，GRU 和 LSTM 模型的涌水量的预测准确度指标均有改善，但 CG-Attention 模型的提升效果最显著；SSA-CG-Attention 模型预测涌水量的 RMSE 仅为 $6.34 \text{ m}^3/\text{h}$ ，比 MLP、SLP、SVR、LSTM、GRU 以及 SSA 优化的 LSTM 和 GRU 模型，分别降低了 $20.35 \text{ m}^3/\text{h}$ 、 $19.06 \text{ m}^3/\text{h}$ 、 $12.82 \text{ m}^3/\text{h}$ 、 $8.48 \text{ m}^3/\text{h}$ 、 $8.09 \text{ m}^3/\text{h}$ 、 $7.49 \text{ m}^3/\text{h}$ 、 $3.64 \text{ m}^3/\text{h}$ ，进一步验证了本文所提出的 SSA-CG-Attention 预测模型的优越性。

5.5 本章小结 (Summary of this chapter)

本章为了提高预测结果的准确性和稳定性，通过相关可行性研究确定涌水量相关可行因素作为多因素模型构建的数据基础。着重介绍了相关模型的相关理论，构建了基于 SSA-CG-Attention 多因素涌水量预测模型，并基于实验矿区工作面数据进行验证，并根据模型、数据特点选取合适的模型评价指标。

通过与单因素模型进行对比实验得到使用涌水量历史数据预测结果仅考虑了历史趋势和变化规律，仅能提供单一时间序列信息，容易出现误判和漏判。而使用钻孔水位以及微震数据预测工作面涌水量，多因素输入互为约束，信息获取更全面，结果输出更稳定、更准确，可以大大降低误报漏报几率，提高工作面预测可靠性、准确性和精度的结论。

将模型评估指标方差作为模型稳定性判定标准，通过与单因素预测模型、多因素预测模型的稳定性对比，得到多因素模型更具稳定性的结论。

通过与多因素模型对比消融实验，根据模型评价指标得到 SSA-CG-Attention 预测模型的 MAPE、RMSE 和 MAPE 三个评价指标均优于 SLP、MLP、SVR、GRU、LSTM 模型；组合麻雀搜索算法寻找最优超参数，GRU 和 LSTM 模型的评价指标值都有所下降，但 CG-Attention 模型的指标下降最多；SSA-CG-Attention 模型预测涌水量的 RMSE 仅为 $6.34 \text{ m}^3/\text{h}$ ，比 MLP、SLP、SVR、

LSTM、GRU 以及 SSA 优化的 LSTM 和 GRU 模型，分别降低了 20.35 m³/h、19.06 m³/h、12.82 m³/h、8.48 m³/h、8.09 m³/h、7.49 m³/h、3.64 m³/h，进一步验证了本文所提出的 SSA-CG-Attention 预测模型的有效性和优越性。多因素涌水量预测模型的优越性。

6 结论与展望

6 Conclusions and outlook

6.1 结论 (Conclusions)

本文在对矿井工作面涌水量预测国内外研究现状的基础上, 分析探索数据规律, 有针对性的建立不同的预测模型, 并且根据数据、模型特征以及应用场景等方面对模型评价指标进行分析, 有针对性的选择合适的评价指标, 以确保模型在实际应用中的有效性和可靠性。首先为提高采煤工作面涌水量预测准确度, 收集了大量工作面涌水量历史观测数据进行整理、统计、分析, 将涌水量稳定性、周期性和季节性特征考虑在内, 提出了基于数据驱动的 CEEMDAN 和混合时间序列模型工作面涌水量预测方法。克服了其他相关影响因素的干扰, 提高了预测精度, 加快了预测速度, 适用于工作面涌水量预测, 精度高。其次, 为了提高预测结果的准确性和稳定性, 基于钻孔水位和微震能量数据与涌水量的强关联性, 选择其作为多因素特征变量, 结合卷积神经网络 (CNN) 与门控循环单元 (GRU) 构建新的网络结构, 加入注意力机制 (Attention), 融合麻雀搜索 (SSA) 算法优化网络参数, 建立了 SSA-CG-Attention 预测模型并证明了多因素约束使模型更加准确、可靠、稳定。具体得出的结论如下:

(1) 本研究引入了 CEEMDAN 和改进的混合时间序列模型, 用于预测矿井工作面涌水量。结果表明, 所提方法能够较为准确地预测涌水量, 具有较高的实用价值, 为工作面涌水量预测提供了新的思路和方法。通过对涌水量预测数据的研究说明了工作面涌水量时间序列受到采动周期性影响, 具有周期性; 受季节性因素影响, 具有季节性; 总体上呈现非平稳特征。为涌水预测的研究和模型的选取提供参考。针对采煤工作面涌水量数据特征提出的基于 CEEMDAN 和改进的混合时间序列工作面涌水量预测模型, 利用 CEEMDAN 算法进行数据分解, 在保留原数据现实含义的基础上, 避免噪声对预测结果的影响, 克服了数据不稳定性。运用 SSA 引入了随机性, 避免了局部最优解问题; 针对分量不同特征采用不同时间序列预测方法, 提升了预测准确性。

(2) 探究了钻孔水位数据、微震数据与工作面涌水量数据之间的相关性, 因此, 将水位数据、微震数据作为工作面涌水量预测特征输入值输入到提出的多因素涌水量预测模型中, 抑制了涌水量预测的偶然性。相比单因素预测模型, 预测结果更加准确、可靠、稳定。根据涌水量相关影响因素提出的 SSA-CG-Attention 模型可用于涌水量多因素预测, 提取时序特征, 兼顾数据局部特征, 将注意力集中在相关的输入元素上, 尽可能多学习输入数据特征, 同时通过麻

雀搜索算法优化模型参数，以最少的迭代次数快速寻找网络参数，避免局部最优解的缺陷，提升了预测准确性。

6.2 展望 (Outlook)

本文提出的基于 CEEMDAN-SSA-LSTM-ARIMA 模型的单序列涌水量预测模型，在仅考虑涌水量自身时间序列的基础上进行改进预测以提高涌水量的预测准确率，但未考虑其他因素的影响，并且由于深度学习模型更新迭代快，则涌水量预测模型应随之迭代，进一步提升涌水量预测效率。

本文提出的基于 SSA-CG-Attention 模型的多因素涌水量预测，虽在深度学习算法的基础上引入了其他涌水量影响因素，提高了预测稳定性和准确性，但是仍然存在不足之处：

(1) 本文仅与深度学习各类型预测方法进行对比分析以确定模型的优越性，与解析法、数值法、水均衡法等确定性预测方法未进行对比实验，下一步可以继续寻找两类预测方法的契合点进行对比实验探究。

(2) 该模型仅考虑了水位数据和微震数据，下一步可以继续获取其他相关影响因素数据，如多组水位，降雨量等，对多因素预测模型进行深入探究。

参考文献

- [1] Yang D,Qiu H,Ma S,et al.Slow surface subsidence and its impact on shallow loess landslides in a coal mining area[J].Catena,2022,2(09):105830.
- [2] Zhang J C,Shen B H.Coal mining under aquifers in China: a case study[J].International Journal of Rock Mechanics and Mining Sciences, 2004, 41(04):629–639.
- [3] 方树林.中国煤矿灾害防治技术研究现状与发展趋势[J].洁净煤技术,2012,18(01):90-91.
- [4] 梁犁丽,胡宇丰,柳长顺,等.矿井涌水量多方法预测与对比分析[J].人民黄河,2021,43(S2):66-68.
- [5] 朱愿福,王长申,李彦周,等.改进的灰色系统理论预测矿井涌水量[J].煤田地质与勘探,2014, 42(04):44-49.
- [6] Li Z L, Gao T Y,Guo C,et al. A gated recurrent unit network model for predicting open channel flow in coal mines based on attention mechanisms[J].IEEE Access,2020, 8(0):119819-119828.
- [7] 靳德武,乔伟,李鹏,等.煤矿防治水智能化技术与装备研究现状及展望[J].煤炭科学技术,2019,47(03):10-17.
- [8] 张磊,许博,刘斌,等.煤矿防治水智能化技术研究现状及展望[J].陕西煤炭,2022,41(06):224-226+231.
- [9] 彭苏萍.深部煤炭资源赋存规律与开发地质评价研究现状及今后发展趋势[J].煤炭学报,2008(02):1-11+27.
- [10] Zhang K M,Chi T N.Real time prediction of irregular periodic time series data[J].Journal of Forecasting.2020;39(03):501-511.
- [11] Lee Y L, Woan L B, Kong H L.Forecasting with information extracted from the residuals of ARIMA in financial time series using continuous wavelet transform[J].International Journal of Business Intelligence and Data Mining,2023,22(1-2).
- [12] Daraghmi Y A,Daadoo M.Improved dynamic route guidance based on Holt-Winters-Taylor method for traffic flow prediction[J].International Journal of Traffic and Transportation Engineering,2015,04(03):75-83.
- [13] Wang J.Prediction model of pulmonay tuberculosis based on gray kernel AR-SVM model [J].Cluster Computing, 2019,22(02):4383-4387.
- [14] 张润畦,商芷萱,蒋知廷,等.基于灰色系统理论与 ARIMA 模型对涌水量预测研究[J].华北科技学院学报,2022,19(01):13-20.
- [15] 王学文,李素华,谢嘉成,等.机器人运动学与时序预测融合驱动的刮板输送机调直方法[J].煤炭学报,2021,46(02):652-666.

- [16] 田东,韦鑫化,王悦,等.基于 MA-ARIMA-GASVR 的食用菌温室温度预测[J].农业工程学报,2020,36(03):190-197.
- [17] David A K,Thomas A O.An ARMA model for short-term prediction of hepatitis B Virus seropositivity among blood donors in Lafia-Nigeria[J].Journal ofScientific Research and Reports, 2019,24(01):1-11.
- [18] Kang J,Dua Z T,Tang L.Online short-term traffic flow prediction method for LS-SVM [J].Application Research of Computers, 2018,35(10),91-94.
- [19] 刘航舵.基于循环神经网络的瓦斯灾害预测预警研究[D].西安科技大学,2020.
- [20] 闫杨,孙丽君,朱兰婷.基于时空相关性的短时交通流量预测方法[J].计算机工程,2020,46(01):31-37.
- [21] 陈路倩.基于麻雀搜索算法优化 LSTM 的超短期风速预测[D].江西财经大学,2022.
- [22] 王堃,郑晨,张立中,等.一种基于 SARIMA-LSTM 模型的电网主机负载预测方法[J].计算机工程与科学,2022,44(11):2064-2070.
- [23] 郑晓亮,来文豪,薛生.MI 和 SVM 算法在煤与瓦斯突出预测中的应用[J].中国安全科学学报,2021,31(01):75-80.
- [24] 郑方燕,陈鹏霖,石海峰,等.基于 BP 神经网络的时栅时序预测测量研究[J].仪表技术与传感器,2020,00(01):96-99.
- [25] 钟登华,田耕,关涛,等.基于混沌时序-随机森林回归的堆石坝料加水量预测研究[J].水力发电学报,2018,37(08):1-12.
- [26] 乔伟,韩昌民,李连刚,等.煤矿导水裂隙带高度预测的 PSO-SVR 法及应用[J].煤炭科技,2022,43(04):77-84.
- [27] Zhao L L, Wang J J, Hu Y, et al.Paed on an inception RNN attention network[J].Sequence for PPI Prediction Based on an Inception RNN Attention Network[J].Molecular Therapy-Nucleic Acids,2020,(22):198-208.
- [28] 潘少波.基于 RNN 的瓦斯浓度多参数融合预测研究[D].西安科技大学,2020.
- [29] Bisagno N,Saltori C, Zhang B, et al.Embedding group and obstacle information in LSTM networks for human trajectory prediction in crowded scenes[J].Computer Vision and Image Understanding,2021,203(P0):103-126.
- [30] 贾澎涛,苗云凤.基于堆叠 LSTM 的多源矿压预测模型分析[J].矿业研究与开发,2021,41(08):79-82.
- [31] Wang Y,Zhou X,LiangL,et al.Shart-term wind speed forecast based on least squares supportvector machine[J].Journal of Information Processing Systems,2018,14(06):1385-1397.
- [32] 刘超,雷晨,李树刚,等.基于 CNN-GRU 的瓦斯浓度预测模型及应用[J].中国安全生产科学技术,2022,18(09):62-68.

- [33] 黄飞虎,赵红磊,弋沛玉,等.一种改进 Transformer 的电力负荷预测方法[J].现代电力,2023,40(01):50-58.
- [34] 秦梦月,杨斌,王旭.内蒙古通格朗井田先期开采地段矿井涌水量预测[J].中国煤炭地质,2022,34(S1):77-81+90.
- [35] Theis C V.The relation between the lowering of piezometric surface and the rate and duration of discharge of well using ground water storage[J].rans Amer Geophys Union,1935,(02):519-524.
- [36] Theis C V.The effect of a weli on the flow of a nearby stream[J].Eos,Transactions American Geophysical Union,1941,22(03):734-738.
- [37] 熊鹏,谢永生,韩冬,等.基于 Visual Modflow 的刚果(金)迪兹瓦露天矿地下涌水量预测[J].科学技术与工程,2022,22(28):12324-12330.
- [38] 张浩楠.基于 Visual Modflow 的采煤工作面涌水量预测研究[J].价值工程,2022,41(23):117-119.
- [39] Majdi A,Hassani F P,Nasiri M Y.Prediction of the height of destressed zoneabove the mined panel roof in longwall coal mining[J].InternationalJournal of Coal Geology,2012,8.
- [40] Yin H Y,Zhao C Y,Zhai Y T,et al.Application of comprehensive support techniques to roadway tunneling in vicinity of Ordovician carbonate confined aquifers under complicated tectonic conditions[J].Carbonates and Evaporites,2020,35(04).
- [41] 王璐玮.基于 BIM 和 Modflow 的隧道涌水量预测研究[J].山西交通科技,2022(05):93-95.
- [42] 孙刚友,胡清珍,康钦容等.基于大井法和地下水模型系统数值模拟方法的某矿坑涌水量预测对比分析[J].科学技术与工程,2023,23(21):9024-9031.
- [43] 罗奇斌,赵宝峰,毛旭阁,等.基于数值模拟方法的煤矿开采涌水量预测分析[J].西北大学学报(自然科学版),2022,52(06):1100-1110.
- [44] Chengxin J ,Huapeng S ,Ya L , et al. Numerical simulation of groundwater under complex karst conditions and the prediction of roadway gushing in a coal mine: a case study in the Guang'an Longtan Reservoir in Sichuan Province, China [J]. Acta Geochimica, 2016, 35 (01): 72-84.
- [45] Xiong Z,Wang M,Shi S Set al.water inrush analysis of the longmen mountain tunnel based on a 3D simulation of the discrete fracture network[J].Open Geosciences,2017,9(01).
- [46] Chen X. A novel hybrid model based on an improved seagull optimization algorithm for Short-Term wind speed forecasting[J].Processes,2021,09(02):387-387.
- [47] 侯恩科,龙天文,樊志刚.解析法预测文家坡煤矿工作面涌水量[J].矿业安全与环保,2019,46(05):80-84.
- [48] 侯恩科,席慧琴,文强,等.基于 GMS 的隐伏火烧区下煤层开采工作面涌水量预测[J].安全

与环境学报,2022,22(05):2482-2492.

- [49] 陈思佳,骆祖江.“分段大井法”预测矿井工作面涌水量[J].国煤炭地质,2016(01):41-43.
- [50] 王春刚,方刚,刘洋.榆横北区巴拉素井田不同时期矿井涌水量预测[J].煤矿安全,2020,51(06):212-217.
- [51] 彭辉才,徐卫东,付青,等.贵州绿塘煤矿涌水量预测研究[J].南水北调与水利科技,2013,11(02):58-61.
- [52] 宋武元.某矿区水文地质条件分析及矿坑涌水量预测[J].地下水,2022,44(06):60-62.
- [53] 苗霖田,贺晓浪,张建军,等.矿井涌水量的时间序列分析-水文地质比拟法预测[J].中国煤炭,2017,43(03):32-35.
- [54] 王档良,房亚飞,邓国伟,等.基于改进多元回归模型与 GIS 的陕北凉水井矿井工作面涌水量预测[J].煤炭科技,2022,43(04):85-92.
- [55] 吴卫忠,邓忠,陈余道,等.广西盘龙铅锌矿涌水量时间序列变化特征分析及 ARIMA 预测[J].桂林理工大学学报,2023,43(03):406-413.
- [56] 王晓蕾.煤矿开采矿井涌水量预测方法现状及发展趋势[J].科学技术与工程,2020,20(30):12255-12267.
- [57] 李建林,高培强,王心义,等.基于混沌-广义回归神经网络的矿井涌水量预测[J].煤炭科学技术,2022,50(04):149-155.
- [58] 张慧玲. 基于改进无偏灰色模型矿井涌水量预测[J]. 中国水运(下半月), 2023, 23 (08): 53-55..
- [59] 许延春,黄磊. 基于微震监测的工作面底板突水全时空预警方法[J]. 煤炭科学技术, 2023, 51 (01): 369-382.
- [60] 熊鹏,谢永生,韩冬,等.基于 Visual Modflow 的刚果(金)迪兹瓦露天矿地下涌水量预测[J].科学技术与工程,2022,22(28):12324-12330.
- [61] 刘慧,刘桂芹,宁殿艳等.基于 VMD-DBN 的矿井涌水量预测方法[J].煤田地质与勘探,2023,51(06):13-21.
- [62] 史新国,翟勃,王卫龙.基于大数据智能的煤矿水害预测数据建模研究[J].自动化与仪器仪表,2021(10):37-40.
- [63] 刘晓丹,潘国营.基于三种时间序列模型的矿井涌水量预测[J].矿业安全与环保, 2022, 49(02):91-95+101.
- [64] 阚吉亮.顶板深孔爆破震动释能与结构调控防冲机理及应用研究[D].中国矿业大学,2023.
- [65] 李青松.基于微震动态响应规律的瓦斯突出综合预警方法及其应用研究[D].中国矿业大学,2022.
- [66] 周然然.多重扰动煤体冲击地压影响因素及防治技术研究[D].华北科技学院,2023.
- [67] 高德焱.构造煤储层水平井造洞穴应力释放区扩展规律与诱导机制研究[D].中国矿业大

学,2023.

- [68] 余国锋.基于微震和神经网络的煤层底板突水预警技术研究[D].安徽理工大学,2022.
- [69] 李建林,高培强,王心义,等.基于混沌-广义回归神经网络的矿井涌水量预测[J].煤炭科学技术,2022,50(04):149-155.
- [70] 邢金莎.基于深度学习的矿井水文参数分析与预测[D].西安科技大学,2021.
- [71] 石梦鑫.基于注意力机制神经网络的遥测数据预测方法[D].中国科学院大学(中国科学院国家空间科学中心), 2020.
- [72] 周夕雨.基于 PSO-LSTM 的湖泊溶解氧浓度变化分析及预测[D].江西理工大学,2023.
- [73] 亓金磊.基于机器学习算法的土层地震反应预测模型研究[D].中国地震局工程力学研究所,2021.
- [74] 孙津.结合气溶胶光学厚度的北京市 PM_{2.5}小时浓度分布估计与个体暴露评估[D].中国科学院大学(中国科学院空天信息创新研究院),2021.
- [75] 张又才,朱伏平.基于全矢 CEEMDAN 滚动轴承故障诊断研究[J].机械设计,2023,40(S2):68-72.
- [76] 刘佳昕,周风波. EMD 算法的改进及在信号去噪中的应用[J]. 电子制作, 2024, 32 (04): 73-75+27.
- [77] 孙薇,杨众志.基于二次分解和自适应鲸鱼优化算法的碳价格混合预测研究[J].电力科学与工程, 2023, 39 (09): 71-78.
- [78] 刘建伟,宋志妍. 循环神经网络研究综述[J].控制与决策, 2022, 37 (11): 2753-2768.
- [79] 李兰茹,孟涵,姚成.基于 SSA-LSTM 模型的增江流域洪水模拟[J].水利技术监督, 2023,(12):152-157.
- [80] 李树娴,张晓骏,胡成雨.基于 LSTM 的政策效应预测模型及其应用[J].统计与决策,2023,39(23):34-39.
- [81] 湛桢文,常军.SSA-SARIMA 组合模型的桥梁健康状态预测[J].苏州科技大学学报(工程技术版),2023,36(04):8-12.
- [82] 包文华,刘海瑞,方圆,等.基于 CNN-ARIMA 的交通路口短周期交通车流量预测方法[J].汽车实用技术,2023,48(22):178-182.
- [83] 李军,梁宵,梁嘉城,等.基于 ARIMA-GM 改进算法的建筑负荷预测[J].电气自动化,2023,45(06):59-61.
- [84] 鑫康,刘萍,芦庆和,等.基于改进麻雀搜索算法优化 SVR 和 FLAC3D 的开采地表沉降预测[J].矿业研究与开发,2023,43(10):110-118.
- [85] 邵良杉,毕圣昊,王彦彬,等.基于 ISSA-ELM 的煤与瓦斯突出危险等级预测[J].中国安全生产科学技术,2023,19(09):76-82.
- [86] Xue J,Shen B.A novel swam ineligence optimization approachisparow search algorithm

- [J].Systems Science and Control Engineering,2020,8(01).22-34.
- [87] 王凯军.数据要素的产权分析与治理机制[D].西南财经大学,2022.
- [88] 随奥迪.基于时间序列特征分析的灰色预测拓展模型及其在能源领域的应用[D].江南大学,2022.
- [89] Zhang S Q,Luo J,W S Y,et al.Oil price forecasting: A hybrid GRU neural network based on decomposition - reconstruction methods[J].Expert Systems With Applications, 2023, 218
- [90] 刘振羽.基于时间序列大数据的基因表达调控网络推断方法研究[D].内蒙古农业大学,2022.
- [91] 徐敏.基于地理标记照片的入境游客流动网络多时空尺度特征及其演化模式[D].南京师范大学,2019.
- [92] 范雅文.时间序列模型中几类统计检验问题的研究[D].江西财经大学,2023.
- [93] 郭少松.基于时间序列异常检测的监控系统研究与实现[D].长安大学,2023.
- [94] 张康康.基于机器学习的 Android 恶意代码静态检测方法研究与应用[D].南昌大学,2023.
- [95] Aser A,Joseph P V,Brady R C,et al.A frequency-velocity CNN for developing near-surface 2D vs images from linear-array, active-source wavefield measurements[J].Computers and Geotechnics,2023,156
- [96] 卢廷玉.基于深度学习的遥感影像作物精细分类方法研究[D].哈尔滨师范大学,2023.
- [97] 孟庆禹.基于变分 Dropout 的深度神经网络建模优化及在尾状核的应用[D].山西医科大学,2023.
- [98] 王淞瑶,张智晟.基于量子加权多层级 GRU 神经网络的综合能源系统多元负荷短期预测[J].电力系统保护与控制,2022,50(23):85-93.
- [99] Zhang X H,Chen X H,Zheng G C,et al.Improved prediction of chlorophylla concentrations in reservoirs by GRU neural network based on particle swarm algorithm optimized variational modal decomposition[J].Environmental Research,2023,22(01),115259-115259.
- [100] 席翔.基于数据增强与多尺度卷积神经网络的入侵检测方法[D].北京化工大学,2023.
- [101] 李家忻.基于深度学习的多模态磁共振图像肺部肿块分割方法研究[D].北京交通大学,2022.
- [102] 陈学勤.基于深度表示学习的在线社交网络信息传播相关技术研究[D].电子科技大学,2022.
- [103] 高凯悦,牟莉,张英博. PCC-BiLSTM-GRU-Attention 组合模型预测方法[J].计算机系统应用, 2022, 31 (07): 365-371.
- [104] Raadt D A,Warrens J M,Bosker J R,et al.A comparison of reliability coefficients for ordinal rating scales[J].Journal of Classification,2021:1-25.
- [105] Hira L ,Priyank Y ,Anupma K,et al.Role of computed tomography in estimation of residual

- renal function at one year after donor nephrectomy: comparison with nuclear scintigraphy [J].Saudi Journal of Kidney Diseases and Transplantation,2021,32(04):993-998.
- [106] 袁从灏,李宁,牛科.基于聚类和相关性分析的交通拥堵状况分析[J].北京信息科技大学学报(自然科学版),2018,33(03):36-41.
- [107] Nicolas G D,Alice M M ,Edouard L,et al.Correlations for untargeted GC×GC-HRTOF-MS metabolomics of colorectal cancer[J].Metabolomics,2023,19(10):85-85.
- [108] 杨艺.亭南煤矿水害风险预警指标和预警方法研究[D].华北科技学院,2022.
- [109] 连会青,杨艺,杨松霖,等. 基于微震监测技术的煤矿顶板水害预测[J]. 煤矿安全, 2023,54(5):49–55.
- [110] 冯博.高地应力区开挖作用下地下洞室围岩破坏机制与稳定性分析[D].大连理工大学,2021.
- [111] 马莲净,王颂,赵宝峰,等.导水裂隙带高度的混沌麻雀搜索-BP 神经网络预测模型 [J]. 采矿技术,2023,23(04):71-77.
- [112] 乔伟,靳德武,王皓,等.基于云服务的煤矿水害监测大数据智能预警平台构建[J].煤炭学报,2020,45(07):2619-2627.
- [113] 查华胜,张海江,连会青,等.潘二煤矿 A 组煤层底板灰岩水害微震监测[J].煤炭学报,2022,47(08):3001-3014.
- [114] 王瑞.基于 LSTM-GRU 的矿井涌水量预测预警方法研究[D].华北科技学院,2023.
- [115] 刘小明.复杂地质条件下煤矿水害形成机理与防控技术研究[D].西安科技大学,2020.
- [116] 桂韬,奚志恒,郑锐,等.基于深度学习的自然语言处理鲁棒性研究综述[J].计算机学报,2024,47 (01):90-112.

学位论文数据集

关键词*	密级*	中图分类号*	UDC	论文资助
	公开	TD7		
学位授予单位名称*	学位授予单位代码*	学位类别*	学位级别*	
华北科技学院	11104	资源与环境硕士学位	硕士	
论文题名*		并列题名*	论文语种*	
数据驱动的亭南煤矿工作面涌水量预测研究			中文	
作者姓名*	丁莹莹	学号*	202108570089	
培养单位名称*	培养单位代码*	培养单位地址	邮编	
华北科技学院	11104	河北三河燕郊	065201	
学科专业*	研究方向*	学制*	学位授予年*	
安全工程	矿井水害防治	3	2024	
论文提交日期*				
导师姓名*	卜昌森	职称*	教授	
评阅人		答辩委员会主席*	答辩委员会成员	
		曹代勇		
电子版论文提交格式 文本（ ） 图像（ ） 视频（ ） 音频（ ） 多媒体（ ） 其他（ ） 推荐格式：application/msword; application/pdf				
电子版论文出版（发布）者	电子版论文出版（发布）地		权限声明	
论文总页数*		88		
注：共 33 项，其中带*为必填数据，共 22 项。				